

数理统计讲义

minamomo

Monday 15th June, 2026

References:

- [1] 数理统计 (第三版), 韦来生, 2025.
- [2] 概率论, 复旦大学, 1979.
- [3] Real Analysis(4th edition), Royden, 2020.
- [4] 数理统计学教程, 陈希孺, 倪国熙, 1988.
- [5] 概率论, 复旦大学, 1979.

Marks:

1. 概率空间 Ω , 样本空间 $\mathcal{X}$, 随机变量 (样本) X (r.v.), 随机向量 $\mathbf{X}$, 分布函数 F (d.f.), 密度函数 f , 概率 $\mathbb{P}$, 期望 $\mathbb{E}$, 方差 Var , 协方差 Cov , 相关系数 ρ .
 2. Gamma 函数 Γ , Beta 函数 B .
 3. 均匀分布 U , 正态分布 N , 指数分布 Exp , Poisson 分布 Poi , 卡方分布 χ_n^2 , 学生分布 t_n , F 分布 F , Gamma 分布 Γ .
 4. 独立同分布 i.i.d., 几乎处处 a.e./a.s., 依概率 pr., 依分布 dist.
 5. 参数空间 Θ, Λ , 似然函数 L , 似然比 λ
-
1. **Definition.**
 2. **Theorem.**
 3. **Example.**
 4. **Exercise.**
 5. **Algorithm.**

Preface

“概率论在某种程度上是数学分析的习题课, 数理统计就是数学分析和概率论的习题课的感觉一样.”

2026.3.6

“所有的模型都是错的.”

2026.4.10

本讲义根据 2026 年春数理统计课程内容整理.

概率论所研究对象是以各种形式给出的分布, 包括概率 P , 分布 F 以及密度 f , 连同分布的各种特征, 包括期望 $\mathbb{E}$, 方差 Var , 协方差 Cov 等. 总而言之, 概率论的目标在于对给定的分布, 分析这个分布下随机事件发生的特征并加以描述.

统计学的目标则恰恰相反. 统计学的研究对象是概率论的研究结果, 即实际发生的随机事件, 而统计学的研究目标则是概率论的研究对象, 即分析随机事件数据服从的分布. 对分布本身加以估计, 就称为统计估计, 对分布带来的结果加以估计, 就称为假设检验, 应用估计的结果, 就称为决策理论.

minamomo

2026.4 于中国上海

This page intentionally left blank.

Contents

1	统计学基础	7
1.1	样本与分布	7
1.2	正态分布的统计量	12
1.3	χ^2 分布, t 分布与 F 分布	15
1.3.1	χ^2 分布	15
1.3.2	t 分布	18
1.3.3	F 分布	21
1.4	顺序统计量	23
1.5	渐近分布 *	28
2	统计估计	33
2.1	点估计理论	33
2.2	矩估计与极大似然估计	38
2.2.1	矩估计	38
2.2.2	极大似然估计	40
2.3	一致最小方差无偏估计	47
2.3.1	无偏估计的改进	47
2.3.2	充分统计量与完全统计量 *	50
2.3.3	一致最小方差无偏估计的存在性	55
2.3.4	Cramer-Rao 不等式	59
2.4	再论极大似然估计 *	62
2.5	区间估计理论	64
2.6	枢轴变量法	65
3	假设检验	73
3.1	参数假设检验	73
3.1.1	参数假设检验	73
3.1.2	似然比检验	78

3.2	非参数假设检验	84
3.2.1	秩检验	84
3.2.2	χ^2 检验	87
3.2.3	2×2 列联表	89
4	分析学结论	91
4.1	广义积分	91
4.2	收敛定理	93

Chapter 1

统计学基础

1.1 样本与分布

总体和样本是数理统计的基础研究对象.

Definition 1.1.(总体和样本) 总体 (population) 是指研究对象所满足的, 实际上的分布 F . 总体分布在实际问题中往往是存在但未知的. 服从总体分布的随机变量称为样本 (sample). 样本往往被认为是已知的. 样本的所有可能取值的集合称为样本空间 (sample space).

统计学的一个目标是通过样本还原总体分布, 即将总体分布近似地表示成样本 $\{X_k\}_{k=1}^n$ 的函数.

作为例子, 我们来看概率论是如何通过分布分析随机事件的特征的.

Example 1.1.(正态分布的总体方差) 给定 n 维随机向量 $\mathbf{X}$, 每个分量独立同分布, 服从正态分布 $N(\mu, \sigma^2)$, 通过这些随机变量可以构造若干新随机变量, 例如

$$A = \frac{1}{n} \sum_{k=1}^n (X_k - \mu)^2$$

就是典型的例子. 我们求其期望和方差. 根据独立性

$$\mathbb{E}(A) = \mathbb{E}\left((X_1 - \mu)^2\right) = \mathbb{E}\left(X_1^2 - 2X_1\mu + \mu^2\right).$$

注意依照方差的定义以及正态分布的性质

$$\mathbb{E}\left(X_1^2\right) - \mathbb{E}(X_1)^2 = \text{Var}(X_1) \implies \mathbb{E}\left(X_1^2\right) = \mu^2 + \sigma^2,$$

代入得

$$\mathbb{E}(A) = \mu^2 + \sigma^2 - 2\mu^2 + \mu^2 = \sigma^2.$$

考虑 $Y_k = X_k - \mu$ 服从 $N(0, \sigma^2)$, 有

$$\text{Var}(A) = \text{Var}\left(\frac{1}{n} \sum_{k=1}^n Y_k^2\right) = \frac{1}{n^2} \mathbb{E}\left(\left(\sum_{k=1}^n Y_k^2\right)^2\right) - \sigma^4.$$

对平方项展开, 并利用独立性得

$$\mathbb{E}\left(\left(\sum_{k=1}^n Y_k^2\right)^2\right) = \mathbb{E}\left(\sum_{k=1}^n Y_k^4 + \sum_{i \neq j} (Y_i Y_j)^2\right) = n \mathbb{E}(Y_1^4) + n(n-1) \mathbb{E}(Y_1^2)^2.$$

根据期望的定义

$$\mathbb{E}(Y_1^4) = \int_{\mathbb{R}} x^4 f(x) dx = \frac{1}{\sqrt{2\pi}\sigma} \int_{\mathbb{R}} x^4 \exp\left(-\frac{x^2}{2\sigma^2}\right) dx.$$

作分部积分得

$$\mathbb{E}(Y_1^4) = \frac{1}{\sqrt{2\pi}\sigma} \int_{\mathbb{R}} x^4 \exp\left(-\frac{x^2}{2\sigma^2}\right) dx = \frac{-\sigma^2}{\sqrt{2\pi}\sigma} \int_{\mathbb{R}} x^3 d \exp\left(-\frac{x^2}{2\sigma^2}\right),$$

即得

$$\mathbb{E}(Y_1^4) = \frac{3\sigma^2}{\sqrt{2\pi}\sigma} \int_{\mathbb{R}} x^2 \exp\left(-\frac{x^2}{2\sigma^2}\right) dx = 3\sigma^2 \mathbb{E}(Y_1^2) = 3\sigma^4.$$

代入得

$$\text{Var}(A) = \frac{n \mathbb{E}(Y_1^4) + n(n-1) \mathbb{E}(Y_1^2)^2}{n^2} - \sigma^4 = \frac{2}{n} \sigma^4.$$

下面构造的随机变量与之对应.

Example 1.2.(正态分布的样本方差) 给定 n 维随机向量 $\mathbf{X}$, 每个分量独立同分布, 服从正态分布 $N(\mu, \sigma^2)$, 定义随机变量

$$B = \frac{1}{n-1} \sum_{k=1}^n (X_k - \bar{X})^2.$$

注意到可以作变形

$$\begin{aligned}
 B &= \frac{1}{n-1} \sum_{k=1}^n (X_k - \bar{X})^2 \\
 &= \frac{1}{n-1} \sum_{k=1}^n (X_k^2 - 2X_k\bar{X} + \bar{X}^2) \\
 &= \frac{1}{n-1} \left(\sum_{k=1}^n X_k^2 - 2n\bar{X}^2 + n\bar{X}^2 \right) \\
 &= \frac{1}{n(n-1)} \left(n \sum_{k=1}^n X_k^2 - \left(\sum_{k=1}^n X_k \right)^2 \right) \\
 &= \frac{1}{n(n-1)} \left(n \sum_{k=1}^n X_k^2 - \sum_{k=1}^n X_k^2 - \sum_{i \neq j} X_i X_j \right) \\
 &= \frac{1}{n} \sum_{k=1}^n X_k^2 - \frac{1}{n(n-1)} \sum_{i \neq j} X_i X_j.
 \end{aligned}$$

取期望即得

$$\mathbb{E}(B) = \mathbb{E}(X_1^2) - \mathbb{E}(X_1)^2 = \text{Var}(X_1) = \sigma^2.$$

由于 X_k 同分布, 在只有一个变量时我们也直接记作 X . 为求方差, 写为

$$\text{Var}(B) = \text{Cov}(B, B),$$

即

$$\text{Cov} \left(\frac{1}{n} \sum_{k=1}^n X_k^2 - \frac{1}{n(n-1)} \sum_{i \neq j} X_i X_j, \frac{1}{n} \sum_{k=1}^n X_k^2 - \frac{1}{n(n-1)} \sum_{i \neq j} X_i X_j \right).$$

依照定义协方差具有双线性, 于是可以逐项展开, 且根据对称性有

$$\text{Var}(B) = \text{Cov} \left(X_1^2 - X_1 X_2, \frac{1}{n} \sum_{k=1}^n X_k^2 - \frac{1}{n(n-1)} \sum_{i \neq j} X_i X_j \right).$$

注意到独立变量的协方差为 0, 可知上式为

$$\frac{1}{n} \text{Cov} \left(X_1^2, X_1^2 - 2X_1 X_2 \right) - \frac{1}{n} \text{Cov} \left(X_1 X_2, X_1^2 + X_2^2 - 2\frac{n-2}{n-1}(X_1 + X_2)X_3 - \frac{2X_1 X_2}{n-1} \right).$$

依照定义和对称性计算得

$$\begin{aligned}
 \text{Var}(B) &= \frac{1}{n} \left(\text{Cov} \left(X_1^2, X_1^2 \right) - 4 \text{Cov} \left(X_1^2, X_1 X_2 \right) \right) \\
 &\quad + \frac{1}{n(n-1)} \left(4(n-2) \text{Cov} \left(X_1 X_2, X_1 X_3 \right) + 2 \text{Cov} \left(X_1 X_2, X_1 X_2 \right) \right) \\
 &= \frac{1}{n} \left(\mathbb{E} \left(X_1^4 \right) - \mathbb{E} \left(X_1^2 \right)^2 - 4 \mathbb{E} \left(X_1^3 X_2 \right) + 4 \mathbb{E} \left(X_1^2 \right) \mathbb{E} \left(X_1 X_2 \right) \right) \\
 &\quad + \frac{4(n-2)}{n(n-1)} \left(\mathbb{E} \left(X_1^2 X_2 X_3 \right) - \mathbb{E} \left(X_1 X_2 \right) \mathbb{E} \left(X_1 X_3 \right) \right) \\
 &\quad + \frac{2}{n(n-1)} \left(\mathbb{E} \left(X_1^2 X_2^2 \right) - \mathbb{E} \left(X_1 X_2 \right)^2 \right).
 \end{aligned}$$

依照独立性有

$$\begin{aligned}\text{Var}(B) &= \frac{1}{n} \left(\mathbb{E}(X^4) - \mathbb{E}(X^2)^2 - 4\mathbb{E}(X^3)\mathbb{E}(X_1) + 4\mathbb{E}(X^2)\mathbb{E}(X)^2 \right) \\ &\quad + \frac{4(n-2)}{n(n-1)} \left(\mathbb{E}(X^2)\mathbb{E}(X)^2 - \mathbb{E}(X)^4 \right) + \frac{2}{n(n-1)} \left(\mathbb{E}(X^2)^2 - \mathbb{E}(X)^4 \right).\end{aligned}$$

利用矩生成函数或特征函数可以计算 n 阶矩

$$\mathbb{E}(X) = \mu, \quad \mathbb{E}(X^2) = \mu^2 + \sigma^2, \quad \mathbb{E}(X^3) = \mu^3 + 3\mu\sigma^2, \quad \mathbb{E}(X^4) = \mu^4 + 6\mu^2\sigma^2 + 3\sigma^4,$$

代入计算得

$$\text{Var}(B) = \frac{2}{n-1}\sigma^4.$$

由此我们可以计算两者之间的关系.

Example 1.3.(总体方差与样本方差的相关系数) Example 1.1.和Example 1.2.中定义的随机变量 A, B , 可以计算协方差

$$\text{Cov}(A, B) = \text{Cov} \left((X_1 - \mu)^2, \frac{1}{n} \sum_{k=1}^n X_k^2 - \frac{1}{n(n-1)} \sum_{i \neq j} X_i X_j \right).$$

仍然依照独立性

$$\text{Cov}(A, B) = \text{Cov} \left((X_1 - \mu)^2, \frac{1}{n} X_1^2 - \frac{2}{n} X_1 X_2 \right) = \frac{1}{n} \text{Cov} (X_1^2 - 2\mu X_1, X_1^2 - 2X_1 X_2).$$

展开计算得

$$\text{Cov}(A, B) = \frac{2}{n}\sigma^4.$$

依照相关系数的定义

$$\rho(A, B) = \frac{\text{Cov}(A, B)}{\sqrt{\text{Var}(A)\text{Var}(B)}} = \frac{\frac{2}{n}\sigma^4}{\sqrt{\frac{2}{n}\sigma^4 \cdot \frac{2}{n-1}\sigma^4}} = \sqrt{\frac{n-1}{n}}.$$

我们看到以上样本具有很好的性质: 独立性允许我们分别计算期望, 而同分布允许我们用对称性化简, 由此引出了如下定义.

Definition 1.2.(简单随机样本) 独立同分布 (i.i.d.) 的有限个样本称为简单随机样本.

简单随机样本的分布函数和密度函数就是

$$F_n(\mathbf{x}) = \prod_{k=1}^n F(x_k), \quad f_n(\mathbf{x}) = \prod_{k=1}^n f(x_k).$$

简单随机样本对还原总体分布提供了很好的条件, 这就是统计推断. 然而有限个样本不足以确定某个分布, 因此需要假定某种分布的类型. 选定某种分布类型, 例如 Poisson 分布, 正态分布等, 其所有可能分布称为分布族, 参数的全体取值称为参数空间.

利用样本可以构造出分布的若干特征, 用来近似总体分布的特征.

Definition 1.3.(统计量) 给定 n 个样本 $\{X_k\}_{k=1}^n$, 任何一个样本的函数

$$\varphi(X_1, X_2, \dots, X_n)$$

称为统计量.

尤其要强调的是统计量的函数中不能含有总体分布的参数, 而只能由样本和 $\mathbb{R}$ 中元以及若干函数构成. 均值 $\bar{X}$, 方差 $\text{Var}(X)$, 中位数, 最大值等都是常见的统计量.

我们可以用函数编码样本的信息.

Definition 1.4.(经验分布函数) 样本 $\{X_k\}_{k=1}^n$ 的经验分布函数 (empirical distribution function, EDF) 定义为

$$F_n(x) = \frac{1}{n} \sum_{k=1}^n \chi(X_k \leq x), \quad \chi(P) = \begin{cases} 1, & P = \mathbf{T}, \\ 0, & P = \mathbf{F}. \end{cases}$$

1.2 正态分布的统计量

在这一部分, 我们主要研究各个统计量作为随机变量的数值特征.

Example 1.4.(正态分布顺序统计量的期望) 设 $\{X_k\}_{k=1}^n$ 独立同分布, 服从标准正态分布 $N(0, 1)$. 考虑其最大值

$$X = \max_{1 \leq k \leq n} \{X_k\}$$

的概率分布

$$F(x) = \mathbb{P}(X \leq x) = \prod_{k=1}^n \mathbb{P}(X_k \leq x) = \Phi(x)^n.$$

于是期望

$$\mathbb{E}(X) = \int_{\mathbb{R}} x d\mathbb{P}(X \leq x) = - \int_{\mathbb{R}} x d(1 - \Phi(x)^n) = \int_{\mathbb{R}} (1 - \Phi(x)^n) dx.$$

其展开的主项为 $\sqrt{2 \ln n}$.

对样本 $\{X_k\}_{k=1}^n$, 我们尤其关心以下两个先前讨论过的统计量.

Definition 1.5.(样本均值和样本方差) 给定 n 个样本 $\{X_k\}_{k=1}^n$, 定义**样本均值**

$$\bar{X} = \frac{1}{n} \sum_{k=1}^n X_k$$

和**样本方差**

$$S^2 = \frac{1}{n-1} \sum_{k=1}^n (X_k - \bar{X})^2.$$

我们先作简要分析.

Example 1.5.(样本均值和样本方差的线性代数刻画) 给定 n 个样本 $\{X_k\}_{k=1}^n$, 注意到

$$\bar{X} = \frac{1}{n} \sum_{k=1}^n X_k = \frac{1}{n} \begin{bmatrix} 1 & 1 & \cdots & 1 \end{bmatrix} \begin{bmatrix} X_1 \\ X_2 \\ \vdots \\ X_n \end{bmatrix} = \frac{1}{n} \mathbf{1}^T \mathbf{X},$$

以及

$$S^2 = \frac{1}{n-1} \sum_{k=1}^n (X_k - \bar{X})^2 = \frac{n}{n-1} \left(\frac{1}{n} \sum_{k=1}^n X_k^2 - \bar{X}^2 \right),$$

展开得

$$S^2 = \frac{n}{n-1} \left(\frac{1}{n} \mathbf{X}^T \mathbf{X} - \frac{1}{n^2} \mathbf{X}^T \mathbf{1} \mathbf{1}^T \mathbf{X} \right) = \frac{1}{n-1} \mathbf{X}^T \left(I - \frac{1}{n} \mathbf{1} \mathbf{1}^T \right) \mathbf{X}.$$

这启示我们把 $\mathbf{1}$ 单位化为 $\mathbf{1} = \|\mathbf{1}\| \hat{\mathbf{1}} = \sqrt{n} \mathbf{e}_1$, 则样本均值和样本方差可以写为

$$\bar{X} = \frac{1}{\sqrt{n}} \mathbf{e}_1^T \mathbf{X}, \quad S^2 = \frac{1}{n-1} \mathbf{X}^T (I - \mathbf{e}_1 \mathbf{e}_1^T) \mathbf{X}.$$

对单位向量 $\mathbf{e}_1$, 一个自然的想法是将之扩充为一组标准正交基 $\{\mathbf{e}_k\}_{k=1}^n$, 于是

$$S^2 = \frac{1}{n-1} \mathbf{X}^T (I - \mathbf{e}_1 \mathbf{e}_1^T) \mathbf{X} = \frac{1}{n-1} \mathbf{X}^T \left(\sum_{k=2}^n \mathbf{e}_k \mathbf{e}_k^T \right) \mathbf{X} = \frac{1}{n-1} \sum_{k=2}^n (\mathbf{e}_k^T \mathbf{X})^2.$$

由于这是一组标准正交基, 构成正交矩阵 $Q = [\mathbf{e}_1 \ \mathbf{e}_2 \ \cdots \ \mathbf{e}_n]$, 于是 $\mathbf{e}_k^T \mathbf{X}$ 恰好是 $Q^T \mathbf{X}$ 的 k -分量. 这表明样本均值可以看作 $\mathbf{Y} = Q^T \mathbf{X}$ 的 1-分量, 而样本方差可以看作 $\mathbf{Y}$ 的后 $n-1$ 个分量的平方均值.

上例说明在适当的线性变换下, 样本均值和样本方差都可以看作某种均值, 从而简化讨论. 因此有必要研究一些分布下的样本在线性变换, 尤其是正交变换下的性质.

Theorem 1.1.(正态分布的正交不变性) 给定 n 个样本 $\{X_k\}_{k=1}^n$ 独立同正态分布 $N(\mu, \sigma^2)$, 则对正交变换 Q , $\mathbf{Y} = Q\mathbf{X}$ 的各个分量也独立, 且服从正态分布. 特别地, 当 $\mu = 0$ 时, $\mathbf{Y}$ 的各个分量独立同分布 $N(0, \sigma^2)$.

Proof. 先考虑对 $\mathbf{X}$ 作一般的线性组合

$$L(\mathbf{X}) = \sum_{k=1}^n c_k X_k,$$

根据特征函数理论, 对每个 $X = X_k$ 有

$$\psi_X(t) = \mathbb{E}(\exp(itX)) = \exp\left(i\mu t - \frac{1}{2}\sigma^2 t^2\right),$$

可知

$$\psi_{L(\mathbf{X})}(t) = \mathbb{E}\left(\exp\left(it \sum_{k=1}^n c_k X_k\right)\right) = \prod_{k=1}^n \mathbb{E}(\exp(ic_k t X_k)),$$

代入展开得

$$\psi_{L(\mathbf{X})}(t) = \exp\left(i\mu t \sum_{k=1}^n c_k - \frac{1}{2}\sigma^2 t^2 \sum_{k=1}^n c_k^2\right),$$

这就说明 $L(\mathbf{X})$ 服从正态分布

$$L(\mathbf{X}) \sim N\left(\mu \sum_{k=1}^n c_k, \sigma^2 \sum_{k=1}^n c_k^2\right).$$

现在考虑正交矩阵 Q , 则 $\mathbf{Y} = Q\mathbf{X}$ 的每个分量服从正态分布

$$Y_i \sim N\left(\mu \sum_{k=1}^n a_{ik}, \sigma^2 \sum_{k=1}^n a_{ik}^2\right) = N\left(\mu \sum_{k=1}^n a_{ik}, \sigma^2\right).$$

为证独立性, 只要计算协方差. 根据协方差的双线性可知

$$\text{Cov}(Y_i, Y_j) = \sum_{k=1}^n \sum_{l=1}^n a_{ik} a_{jl} \text{Cov}(X_k, X_l) = \sigma^2 \sum_{k=1}^n a_{ik} a_{jk} = \sigma^2 (Qe_i)^T (Qe_j).$$

根据正交矩阵的性质, $i \neq j$ 时上式为 0, 于是 $\mathbf{Y}$ 各分量独立. 最后当 $\mu = 0$ 时, 代入 Y_i 的分布可知独立同分布. $\square$

结合 **Example 1.5.** 的讨论, 由于样本均值和样本方差本质分别依赖 Y_1 以及 $\{Y_k\}_{k=2}^n$, 从而也是独立的. 样本均值是容易计算的.

$$\bar{X} = \sum_{k=1}^n \frac{1}{n} X_k \sim N\left(\mu, \frac{\sigma^2}{n}\right).$$

为了讨论样本方差, 由于这是 $n-1$ 个独立正态分布样本的平方和, 只要讨论此种形式的密度函数. 我们暂时只考虑独立同分布的情形.

Example 1.6.(正态分布的样本方差) 给定样本 $\{X_k\}_{k=1}^n$ 独立同正态分布 $N(0, \sigma^2)$, 则样本方差

$$S^2 = \frac{1}{n-1} \sum_{k=2}^n Y_k^2.$$

根据 **Theorem 1.1.** 的结果, 每个 Y_k 服从正态分布 $N(0, \sigma^2)$, 于是特征函数

$$\psi_{Y^2}(t) = \mathbb{E}(\exp(itY^2)) = \frac{1}{\sqrt{2\pi}\sigma} \int_{\mathbb{R}} \exp\left(itx^2 - \frac{1}{2\sigma^2}x^2\right) dx = (1 - 2i\sigma^2 t)^{-\frac{1}{2}}.$$

于是 S^2 的特征函数

$$\psi_{S^2}(t) = \left(1 - \frac{2i\sigma^2}{n-1}t\right)^{-\frac{n-1}{2}}.$$

计算密度函数

$$f_{S^2}(x) = \frac{1}{2\pi} \int_{\mathbb{R}} e^{-itx} \left(1 - \frac{2i\sigma^2}{n-1}t\right)^{-\frac{n-1}{2}} dt = \left(\frac{n-1}{2\sigma^2}\right)^{\frac{n-1}{2}} \frac{x^{\frac{n-1}{2}-1}}{\Gamma\left(\frac{n-1}{2}\right)} \exp\left(-\frac{(n-1)x}{2\sigma^2}\right).$$

1.3 χ^2 分布, t 分布与 F 分布

1.3.1 χ^2 分布

独立正态分布的平方和称为 χ^2 分布.

Definition 1.6. (χ^2 分布) 给定 n 个样本 $\{X_k\}_{k=1}^n$ 独立同标准正态分布, 称随机变量

$$\xi = \sum_{k=1}^n X_k^2$$

服从的分布为自由度为 n 的 χ^2 分布, 记作 $\xi \sim \chi_n^2$.

我们可以计算其密度函数.

Theorem 1.2. (χ^2 分布的密度函数) 设 ξ 是服从自由度为 n 的 χ^2 分布的随机变量, 则其概率密度函数为

$$f_n(x) = \begin{cases} \frac{1}{2^{\frac{n}{2}} \Gamma(\frac{n}{2})} x^{\frac{n}{2}-1} e^{-\frac{x}{2}}, & x > 0, \\ 0, & x \leq 0. \end{cases}$$

其中

$$\Gamma(t) = \int_0^{+\infty} x^{t-1} e^{-x} dx.$$

Proof. 依照概率分布的定义

$$F_n(x) = \mathbb{P} \left(\sum_{k=1}^n X_k^2 \leq x \right) = \int_{\sum_{k=1}^n x_k^2 \leq x} \left(\frac{1}{\sqrt{2\pi}} \right)^n \exp \left(-\frac{1}{2} \sum_{k=1}^n x_k^2 \right) dx_1 \cdots dx_n.$$

考虑换元

$$\begin{cases} x_1 = \rho \cos \theta_1 \cos \theta_2 \cdots \cos \theta_{n-1}, \\ x_2 = \rho \cos \theta_1 \cos \theta_2 \cdots \sin \theta_{n-1}, \\ x_3 = \rho \cos \theta_1 \cos \theta_2 \cdots \sin \theta_{n-2}, \\ \cdots, \\ x_n = \rho \sin \theta_1. \end{cases}$$

相应的 Jacobi 行列式为

$$\det(J) = \rho^{n-1} \varphi(\theta),$$

其中 $\varphi(\theta)$ 表示只与 $\{\theta_k\}_{k=1}^{n-1}$ 有关的函数. 此后我们将任意常数记作待定的 C_n , 得到

$$F_n(x) = C_n \int_{\rho^2 \leq x} \exp \left(-\frac{1}{2} \rho^2 \right) \rho^{n-1} \varphi(\theta) d\rho d\theta_1 \cdots d\theta_{n-1}.$$

注意到区域 $\rho^2 \leq x$ 相当于 $\rho \in [0, \sqrt{x}]$ 而 θ_k 在固定范围内变化, 即 θ 的范围不依赖于 x , 从而被视作常数 C_n 的部分, 于是

$$F_n(x) = \begin{cases} C_n \int_0^{\sqrt{x}} \exp\left(-\frac{1}{2}\rho^2\right) \rho^{n-1} d\rho, & x > 0, \\ 0, & x \leq 0. \end{cases}$$

由于这是概率分布, 令 $x \rightarrow +\infty$ 必定得到 1, 即

$$C_n \int_0^{+\infty} \exp\left(-\frac{1}{2}\rho^2\right) \rho^{n-1} d\rho = 1.$$

作换元 $r = \frac{1}{2}\rho^2$ 可以看出

$$C_n \int_0^{+\infty} e^{-r} (2r)^{\frac{n-1}{2}} (2r)^{-\frac{1}{2}} dr = C_n 2^{\frac{n}{2}-1} \Gamma\left(\frac{n}{2}\right) = 1.$$

这就给出了 C_n 的值. 现在只要对分布函数求导

$$\frac{d}{dx} \int_0^{\sqrt{x}} \exp\left(-\frac{1}{2}\rho^2\right) \rho^{n-1} d\rho = x^{\frac{n-1}{2}} e^{-\frac{x}{2}} \frac{1}{2\sqrt{x}},$$

代入 C_n 的值即证. □

我们也称以

$$f(x) = \frac{1}{\beta^\alpha \Gamma(\alpha)} x^{\alpha-1} e^{-\frac{x}{\beta}}$$

为密度函数的分布为参数 α, β 的 Γ 分布, 记作 $X \sim \Gamma(\alpha, \beta)$. 则 χ^2 分布相当于 $\Gamma\left(\frac{n}{2}, \frac{1}{2}\right)$. 由于指数分布的密度函数为

$$f(x) = \lambda e^{-\lambda x}, \quad x > 0,$$

因此自由度为 2 的 χ^2 分布恰好是指数分布 $\text{Exp}\left(\frac{1}{2}\right)$. 一般的指数分布可以通过变换改写为 $\text{Exp}\left(\frac{1}{2}\right)$ 的形式.

利用密度函数可以计算 k 阶矩.

Theorem 1.3. (χ^2 分布的 k 阶矩) 设 ξ 是服从自由度为 n 的 χ^2 分布的随机变量, 则对任意 $k > -\frac{n}{2}$, k 阶矩

$$\mathbb{E}(\xi^k) = 2^k \frac{\Gamma\left(\frac{n}{2} + k\right)}{\Gamma\left(\frac{n}{2}\right)}.$$

特别地, 取 $n = 1$ 得到标准正态分布的偶数阶矩

$$\mathbb{E}(X^{2k}) = \mathbb{E}(\xi^k) = (2k-1)!!.$$

Proof. 利用密度函数

$$\mathbb{E}(\xi^k) = \int_{\mathbb{R}} x^k f_n(x) dx = \int_0^{+\infty} \frac{1}{2^{\frac{n}{2}} \Gamma(\frac{n}{2})} x^{\frac{n}{2}+k-1} e^{-\frac{x}{2}} dx = 2^k \frac{\Gamma(\frac{n}{2} + k)}{\Gamma(\frac{n}{2})}.$$

特别地, 取 $n = 1$ 得 $\xi = X^2$, 于是

$$\mathbb{E}(X^{2k}) = 2^k \frac{\Gamma(\frac{1}{2} + k)}{\Gamma(\frac{1}{2})} = (2k - 1)!!.$$

□

我们回顾**Example 1.3.**中计算的相关系数.

Example 1.7.(总体方差与样本方差的相关系数) **Example 1.1.**和**Example 1.2.**中定义的随机变量

$$A = \frac{1}{n} \sum_{k=1}^n (X_k - \mu)^2, \quad B = \frac{1}{n-1} \sum_{k=1}^n (X_k - \bar{X})^2.$$

观察相关系数的定义

$$\rho(A, B) = \frac{\text{Cov}(A, B)}{\sqrt{\text{Var}(A) \text{Var}(B)}}$$

可知 $\rho(\alpha A, \beta B) = \rho(A, B)$. 于是只要计算

$$\rho \left(\sum_{k=1}^n (X_k - \mu)^2, \sum_{k=1}^n (X_k - \bar{X})^2 \right)$$

即可. 注意到

$$\sum_{k=1}^n (X_k - \mu)^2 = \sum_{k=1}^n (X_k - \bar{X})^2 + n(\bar{X} - \mu)^2,$$

根据**Theorem 1.1.**的结果, 样本均值 $\bar{X}$ 和样本方差 S^2 独立, 因此根据协方差的双线性只要计算

$$\frac{\text{Cov} \left(\sum_{k=1}^n (X_k - \bar{X})^2, \sum_{k=1}^n (X_k - \bar{X})^2 \right)}{\sqrt{\text{Var} \left(\sum_{k=1}^n (X_k - \mu)^2 \right) \text{Var} \left(\sum_{k=1}^n (X_k - \bar{X})^2 \right)}} = \sqrt{\frac{\text{Var} \left(\sum_{k=1}^n (X_k - \bar{X})^2 \right)}{\text{Var} \left(\sum_{k=1}^n (X_k - \mu)^2 \right)}}.$$

根据**Theorem 1.1.**的结果, 两者分别相当于自由度为 $n-1$ 和 n 的 χ^2 分布, 于是根据**Theorem 1.3.**可求出

$$\rho(A, B) = \sqrt{\frac{n-1}{n}}.$$

Exercise 1.1. 设 $X_1, X_2, \dots, X_n$ 独立, 分别服从正态分布 $N(0, \sigma_i^2)$, 定义随机变量

$$\xi = \sum_{i=1}^n \frac{(X_i - Z)^2}{\sigma_i^2}, \quad Z = \frac{\sum_{i=1}^n \frac{X_i}{\sigma_i^2}}{\sum_{i=1}^n \frac{1}{\sigma_i^2}},$$

求 ξ 的分布.

Solution. 为了使细节更清晰, 作换元 $w_i = \frac{1}{\sigma_i}$ 和 $Y_i = \frac{X_i}{\sigma_i}$, 则定义变为

$$\xi = \sum_{i=1}^n (Y_i - w_i Z)^2, \quad Z = \frac{\sum_{i=1}^n w_i Y_i}{\sum_{i=1}^n w_i^2}.$$

其中 Y_i 独立同分布 $N(0, 1)$. 现在可以展开

$$\xi = \sum_{i=1}^n Y_i^2 + \left(\sum_{i=1}^n w_i^2 \right) Z^2 - 2 \left(\sum_{i=1}^n w_i Y_i \right) Z = \sum_{i=1}^n Y_i^2 - \frac{(\sum_{i=1}^n w_i Y_i)^2}{\sum_{i=1}^n w_i^2}.$$

立刻看出这是 $\mathbf{Y}$ 的二次型. 为了写成更标准的二次型, 定义

$$u_i = \frac{w_i}{\sqrt{\sum_{i=1}^n w_i^2}}$$

构成单位向量 $\mathbf{u}$, 则

$$\xi = \mathbf{Y}^T \mathbf{Y} - (\mathbf{u}^T \mathbf{Y})^2 = \mathbf{Y}^T (I - \mathbf{u} \mathbf{u}^T) \mathbf{Y}.$$

以 $\mathbf{u} = \mathbf{u}_1$ 为第一列构造正交阵 U , 并作正交变换 $\mathbf{Z} = U^T \mathbf{Y}$, 则

$$\xi = \mathbf{Z}^T U^T (I - \mathbf{u} \mathbf{u}^T) U \mathbf{Z} = \mathbf{Z}^T (I - (U^T \mathbf{u})(\mathbf{u}^T U)) \mathbf{Z} = \sum_{i=2}^n Z_i^2.$$

根据 **Theorem 1.1** 可知 Z_i 独立同分布 $N(0, 1)$, 依照 **Definition 1.6** 可知 $\xi \sim \chi_{n-1}^2$.

1.3.2 t 分布

正态分布与独立正态分布的平方平均之商称为 t 分布.

Definition 1.7. (t 分布) 给定 n 个样本 $\{X_k\}_{k=1}^n$ 和一个样本 Y 独立同标准正态分布, 称随机变量

$$T = Y \left(\frac{1}{n} \sum_{k=1}^n X_k^2 \right)^{-\frac{1}{2}}$$

服从的分布为自由度为 n 的 t 分布, 记作 $\xi \sim t_n$.

我们可以计算其密度函数.

Theorem 1.4. (t 分布的密度函数) 设 T 是服从自由度为 n 的 t 分布的随机变量, 则其概率密度函数为

$$f_n(t) = \frac{\Gamma\left(\frac{n+1}{2}\right)}{\Gamma\left(\frac{n}{2}\right)\sqrt{n\pi}} \left(1 + \frac{t^2}{n}\right)^{-\frac{n+1}{2}}.$$

Proof. 依照概率分布的定义

$$F_n(t) = \mathbb{P}\left(\frac{\sqrt{n}Y}{\sqrt{\xi}} \leq t\right) = \int_{\frac{\sqrt{ny}}{\sqrt{x}} \leq t} \frac{1}{\sqrt{2\pi}} e^{-\frac{y^2}{2}} \frac{1}{2^{\frac{n}{2}} \Gamma\left(\frac{n}{2}\right)} x^{\frac{n}{2}-1} e^{-\frac{x}{2}} dx dy.$$

考虑换元

$$\begin{cases} u = \frac{y}{\sqrt{x}}, \\ v = \sqrt{x}. \end{cases}$$

相应的 Jacobi 行列式为

$$\det(J) = \det\begin{pmatrix} 0 & 2v \\ v & u \end{pmatrix} = -2v^2,$$

于是

$$F_n(t) = \int_{\sqrt{nu} \leq t, v \geq 0} \frac{1}{\sqrt{2\pi}} e^{-\frac{u^2 v^2}{2}} \frac{1}{2^{\frac{n}{2}} \Gamma\left(\frac{n}{2}\right)} v^{n-2} e^{-\frac{1}{2}v^2} 2v^2 du dv.$$

整理得

$$F_n(t) = \frac{1}{2^{\frac{n}{2}-1} \Gamma\left(\frac{n}{2}\right)} \int_{-\infty}^{\frac{t}{\sqrt{n}}} \left(\int_0^{+\infty} \frac{1}{\sqrt{2\pi}} v^n e^{-\frac{v^2}{2}(u^2+1)} dv \right) du.$$

作换元 $z = \frac{1}{2}(u^2 + 1)v^2$ 可得括号内为

$$\int_0^{+\infty} \frac{1}{\sqrt{2\pi}} \left(\sqrt{\frac{2z}{u^2+1}} \right)^n e^{-z} \frac{1}{\sqrt{2z(u^2+1)}} dz.$$

利用 Gamma 函数可以写为

$$\frac{2^{\frac{n-1}{2}}}{\sqrt{2\pi}(u^2+1)^{\frac{n+1}{2}}} \int_0^{+\infty} z^{\frac{n-1}{2}} e^{-z} dz = \frac{2^{\frac{n-1}{2}} \Gamma\left(\frac{n+1}{2}\right)}{\sqrt{2\pi}(u^2+1)^{\frac{n+1}{2}}}.$$

代入得

$$F_n(t) = \frac{1}{2^{\frac{n}{2}-1} \Gamma\left(\frac{n}{2}\right)} \int_{-\infty}^{\frac{t}{\sqrt{n}}} \frac{2^{\frac{n}{2}-1} \Gamma\left(\frac{n+1}{2}\right)}{\sqrt{\pi}(u^2+1)^{\frac{n+1}{2}}} du = \frac{\Gamma\left(\frac{n+1}{2}\right)}{\sqrt{\pi} \Gamma\left(\frac{n}{2}\right)} \int_{-\infty}^{\frac{t}{\sqrt{n}}} (u^2+1)^{-\frac{n+1}{2}} du.$$

对 t 求导即得密度函数

$$f_n(t) = \frac{\Gamma\left(\frac{n+1}{2}\right)}{\sqrt{n\pi} \Gamma\left(\frac{n}{2}\right)} \left(1 + \frac{t^2}{n}\right)^{-\frac{n+1}{2}}.$$

□

特别地, 如果取 $n = 1$, 则变为

$$f_1(t) = \frac{1}{\pi(1+t^2)}$$

是 Cauchy 分布. 令 $n \rightarrow \infty$, 则依照 e 的定义和 Stirling 公式变为

$$\lim_{n \rightarrow \infty} f_n(t) = \frac{\sqrt{\frac{n}{2}}}{\sqrt{n\pi}} \exp\left(-\frac{1}{2}t^2\right) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}t^2\right),$$

即标准正态分布.

利用密度函数可以计算 k 阶矩.

Theorem 1.5. (t 分布的 k 阶矩) 设 T 是服从自由度为 n 的 t 分布的随机变量, 则对任意 $k < n$, k 阶矩

$$\mathbb{E}(T^k) = \begin{cases} n^{\frac{k}{2}} \frac{\Gamma(\frac{k+1}{2})\Gamma(\frac{n-k}{2})}{\Gamma(\frac{n}{2})\Gamma(\frac{1}{2})}, & 2 \mid k, \\ 0, & 2 \nmid k. \end{cases}$$

Proof. 利用密度函数

$$\mathbb{E}(T^k) = \int_{\mathbb{R}} t^k f_n(t) dt = \int_{\mathbb{R}} t^k \frac{\Gamma(\frac{n+1}{2})}{\sqrt{n\pi}\Gamma(\frac{n}{2})} \left(1 + \frac{t^2}{n}\right)^{-\frac{n+1}{2}} dt.$$

当 $2 \nmid k$ 时, 被积函数是奇函数, 从而积分值为 0. 当 $2 \mid k$ 时, 考虑换元 $z = \frac{t^2}{n}$, 恰好得到 Beta 函数

$$\mathbb{E}(T^k) = \frac{n^{\frac{k}{2}}\Gamma(\frac{n+1}{2})}{\sqrt{\pi}\Gamma(\frac{n}{2})} \int_0^{+\infty} z^{\frac{k-1}{2}} (1+z)^{-\frac{n+1}{2}} dz = \frac{n^{\frac{k}{2}}\Gamma(\frac{n+1}{2})}{\sqrt{\pi}\Gamma(\frac{n}{2})} B\left(\frac{k+1}{2}, \frac{n-k}{2}\right),$$

展开为 Gamma 函数即证. □

Exercise 1.2. 设 $X_1, X_2, \dots, X_{n+1}$ 独立同正态分布 $N(\mu, \sigma^2)$, 定义前 n 项的均值和方差

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i, \quad S^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2.$$

定义随机变量

$$\xi = \frac{X_{n+1} - \bar{X}}{S} \sqrt{\frac{n-1}{n+1}},$$

求 ξ 的分布.

Solution. 此形式类似于 t 分布, 为构造出类似形式, 考虑 X_{n+1} 和 $\bar{X}$ 是独立随机变量, 分别服从 $N(\mu, \sigma^2)$ 和 $N(\mu, \frac{\sigma^2}{n})$, 因此利用特征函数容易计算 $X_{n+1} - \bar{X}$ 的分布为正态分布, 均值为 0, 方差

$$\sigma_{n+1}^2 = \sigma^2 + \frac{\sigma^2}{n} = \frac{n+1}{n} \sigma^2.$$

于是定义随机变量

$$Y = \frac{X_{n+1} - \bar{X}}{\sqrt{\frac{n+1}{n}}\sigma}$$

服从标准正态分布. 代入立即得到

$$\xi = Y \left(\frac{1}{n-1} \sum_{i=1}^n \frac{(X_i - \bar{X})^2}{\sigma^2} \right)^{-\frac{1}{2}}.$$

根据 **Exercise 1.1.** 中取 $\sigma_i = \sigma$ 的结果, 括号内的求和可以变为 $\sum_{i=2}^n Z_i^2$, 其中 Z_i 独立同标准正态分布, 于是上式恰好是 t 分布的定义, 即 $\xi \sim t_{n-1}$.

1.3.3 F 分布

独立正态分布平方的均值之商称为 F 分布.

Definition 1.8. (F 分布) 给定 $m+n$ 个样本 $\{X_i\}_{i=1}^m$ 和 $\{Y_j\}_{j=1}^n$ 独立同标准正态分布, 称随机变量

$$Z = \frac{\frac{1}{m} \sum_{i=1}^m X_i^2}{\frac{1}{n} \sum_{j=1}^n Y_j^2}$$

服从的分布为参数 m, n 的 F 分布, 记作 $Z \sim F_{m,n}$.

我们仍然计算其密度函数.

Theorem 1.6. (F 分布的密度函数) 设 Z 是服从参数 m, n 的 F 分布的随机变量, 则其概率密度函数为

$$f_{m,n}(t) = \begin{cases} \frac{\Gamma(\frac{m+n}{2})}{\Gamma(\frac{m}{2})\Gamma(\frac{n}{2})} m^{\frac{m}{2}} n^{\frac{n}{2}} t^{\frac{m}{2}-1} (n+mt)^{-\frac{m+n}{2}}, & t > 0, \\ 0, & t \leq 0. \end{cases}$$

Proof. 我们记 X_i 的平方和为 X , Y_j 的平方和为 Y , 则分别服从自由度为 m, n 的 χ^2 分布. 依照概率分布的定义

$$F_{m,n}(t) = \mathbb{P} \left(\frac{X/m}{Y/n} \leq t \right) = \int_{\frac{x/m}{y/n} \leq t} \frac{1}{2^{\frac{m+n}{2}} \Gamma(\frac{m}{2}) \Gamma(\frac{n}{2})} x^{\frac{m}{2}-1} y^{\frac{n}{2}-1} e^{-\frac{x+y}{2}} dx dy.$$

考虑换元

$$\begin{cases} u = \frac{x}{y}, \\ v = y. \end{cases}$$

相应的 Jacobi 行列式为

$$\det(J) = \det \left(\begin{bmatrix} 0 & 1 \\ v & u \end{bmatrix} \right) = -v,$$

即得

$$F_{m,n}(t) = \int_{0 \leq u \leq \frac{m}{n}t, v \geq 0} \frac{1}{2^{\frac{m+n}{2}} \Gamma\left(\frac{m}{2}\right) \Gamma\left(\frac{n}{2}\right)} (uv)^{\frac{m}{2}-1} v^{\frac{n}{2}-1} e^{-\frac{(u+1)v}{2}} v du dv.$$

整理得

$$F_{m,n}(t) = \int_0^{\frac{m}{n}t} \left(\frac{u^{\frac{m}{2}-1}}{2^{\frac{m+n}{2}} \Gamma\left(\frac{m}{2}\right) \Gamma\left(\frac{n}{2}\right)} \int_0^{+\infty} v^{\frac{m+n}{2}-1} e^{-\frac{(u+1)v}{2}} dv \right) du.$$

采用同样的方法作换元 $z = \frac{(u+1)v}{2}$ 可得

$$\int_0^{+\infty} v^{\frac{m+n}{2}-1} e^{-\frac{(u+1)v}{2}} dv = \frac{2^{\frac{m+n}{2}} \Gamma\left(\frac{m+n}{2}\right)}{(u+1)^{\frac{m+n}{2}}}.$$

于是

$$F_{m,n}(t) = \frac{\Gamma\left(\frac{m+n}{2}\right)}{\Gamma\left(\frac{m}{2}\right) \Gamma\left(\frac{n}{2}\right)} \int_0^{\frac{m}{n}t} \frac{u^{\frac{m}{2}-1}}{(u+1)^{\frac{m+n}{2}}} du.$$

求导即得密度函数. □

依照定义即知 $F_{1,n}$ 相当于服从 t_n 分布的随机变量的平方的分布, $F_{n,m}$ 相当于服从 $F_{m,n}$ 分布的随机变量的倒数的分布.

我们仍然计算 k 阶矩.

Theorem 1.7. (F 分布的 k 阶矩) 设 Z 是服从参数 m, n 的 F 分布的随机变量, 则对任意 $0 < k < \frac{n}{2}$, k 阶矩

$$\mathbb{E}(Z^k) = \left(\frac{n}{m}\right)^k \frac{\Gamma\left(\frac{m}{2} + k\right) \Gamma\left(\frac{n}{2} - k\right)}{\Gamma\left(\frac{m}{2}\right) \Gamma\left(\frac{n}{2}\right)}.$$

特别地, 当 $n > 2$ 和 $n > 4$ 时有

$$\mathbb{E}(Z) = \frac{n}{n-2}, \quad \text{Var}(Z) = \frac{2n^2(m+n-2)}{m(n-2)^2(n-4)}.$$

Proof. 根据独立性展开

$$\mathbb{E}(Z^k) = \left(\frac{n}{m}\right)^k \mathbb{E}(X^k) \mathbb{E}(Y^{-k}).$$

根据 **Theorem 1.3.** 的结果有

$$\mathbb{E}(X^k) = 2^k \frac{\Gamma\left(\frac{m}{2} + k\right)}{\Gamma\left(\frac{m}{2}\right)}, \quad \mathbb{E}(Y^{-k}) = 2^{-k} \frac{\Gamma\left(\frac{n}{2} - k\right)}{\Gamma\left(\frac{n}{2}\right)},$$

代入即证. □

对正态分布的数据而言, 其样本均值和样本方差恰好服从正态分布和 χ^2 分布, 因此作商恰好是 t 分布和 F 分布, 这刻画了数据波动程度的关系.

1.4 顺序统计量

作为最大值, 最小值的推广, 我们考察顺序统计量.

Definition 1.9.(顺序统计量) 设 $X_1, X_2, \dots, X_n$ 是概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 上的随机变量 (样本), 对每个 $\omega \in \Omega$, 都可对 $\{X_i(\omega)\}$ 排序, 把每个 ω 映到相应序列的从小到大第 k 个值的随机变量, 称为第 k 顺序统计量 $X_{(k)}$.

顺序统计量作为随机变量, 可以研究其分布.

Theorem 1.8.(顺序统计量的分布) 设 $X_1, X_2, \dots, X_n$ 独立同分布 $F(x)$, 则第 k 顺序统计量的概率分布为

$$F_{(k)}(x) = \sum_{i=k}^n C_n^i F(x)^i (1 - F(x))^{n-i} = \frac{n!}{(k-1)!(n-k)!} \int_0^{F(x)} t^{k-1} (1-t)^{n-k} dt.$$

如果 $F(x)$ 的导数存在, 则密度函数为

$$f_{(k)}(x) = \frac{n!}{(k-1)!(n-k)!} F(x)^{k-1} (1 - F(x))^{n-k} f(x).$$

Proof. 依照定义, $F_{(k)}(x)$ 的值是 $\mathbb{P}(X_{(k)} \leq x)$, 即至少有 k 个不大于 x , 这可以分解为恰好有 $k, k+1, \dots, n$ 个不大于 x 的概率和, 即

$$F_{(k)}(x) = \sum_{i=k}^n C_n^i \mathbb{P}(X_1 \leq x)^i \mathbb{P}(X_1 > x)^{n-i} = F_{(k)}(x) = \sum_{i=k}^n C_n^i F(x)^i (1 - F(x))^{n-i}.$$

为了得到积分形式, 只要证明恒等式

$$\sum_{i=k}^n C_n^i x^i (1-x)^{n-i} = \frac{n!}{(k-1)!(n-k)!} \int_0^x t^{k-1} (1-t)^{n-k} dt,$$

这只要对右边作分部积分即可. 最后求导即得

$$f_{(k)}(x) = \frac{n!}{(k-1)!(n-k)!} F(x)^{k-1} (1 - F(x))^{n-k} f(x).$$

□

对这一结果, 可以从古典概型的角度考虑. 比 $X_{(k)}$ 小的有 $k-1$ 个, 有 C_n^{k-1} 种取法, 每个的概率是 $\mathbb{P}(X_1 \leq x) = F(x)$, 比 $X_{(k)}$ 大的有 $n-k$ 个, 有 C_{n-k+1}^{n-k} 种取法, 每个的概率是 $\mathbb{P}(X_1 > x) = 1 - F(x)$, 而 $X_{(k)}$ 本身只剩一种取法, 概率是 $f(x)$, 相乘即得

$$C_n^{k-1} C_{n-k+1}^{n-k} = \frac{n!}{(n-k+1)!(k-1)!} (n-k+1) = \frac{n!}{(k-1)!(n-k)!}.$$

如果相应概率分布 F 的各阶矩存在, 则只要写成积分, 容易看出顺序统计量的各阶矩存在. 反之则不然.

Example 1.8.(Cauchy 分布顺序统计量的 p 阶矩) 设 $X_1, X_2, \dots, X_n$ 独立同 Cauchy 分布, 则

$$F(x) = \frac{1}{2} + \frac{1}{\pi} \arctan x, \quad f(x) = \frac{1}{\pi(1+x^2)}.$$

从而第 k 顺序统计量的密度函数为

$$f_{(k)}(x) = \frac{n!}{(k-1)!(n-k)!} \left(\frac{1}{2} + \frac{1}{\pi} \arctan x \right)^{k-1} \left(\frac{1}{2} - \frac{1}{\pi} \arctan x \right)^{n-k} \frac{1}{\pi(1+x^2)}.$$

其 p 阶矩为

$$\mathbb{E}(X_{(k)}) = \frac{1}{\pi} \frac{n!}{(k-1)!(n-k)!} \int_{\mathbb{R}} \left(\frac{1}{2} + \frac{1}{\pi} \arctan x \right)^{k-1} \left(\frac{1}{2} - \frac{1}{\pi} \arctan x \right)^{n-k} \frac{x^p}{1+x^2} dx.$$

当 $x \rightarrow +\infty$ 时, 有无穷小

$$\frac{1}{2} - \frac{1}{\pi} \arctan x \sim \frac{1}{\pi x},$$

因此只要 $n-k \geq p$ 就在正无穷处积分收敛. 同理可得 $p \leq k-1$ 时在负无穷处积分收敛, 因此第 k 顺序统计量的 $1 \leq p \leq \min\{k-1, n-k\}$ 阶矩存在, 特别地, 当 $k \neq 1, n$ 时期望存在, $k \neq 1, 2, n-1, n$ 时方差存在.

顺序统计量作为随机变量彼此不独立, 因而有必要讨论其联合分布, 不是各分布的乘积.

Theorem 1.9.(顺序统计量的联合分布) 设 $X_1, X_2, \dots, X_n$ 独立同分布 $f(x)$, 则顺序统计量的联合概率密度为

$$f(\mathbf{x}) = \begin{cases} n! \prod_{i=1}^n f(x_i), & x_1 < x_2 < \dots < x_n, \\ 0, & \text{otherwise.} \end{cases}$$

Proof. 我们比较这与 $\mathbf{X}$ 的联合概率密度的关系. 根据独立性, $\mathbf{X}$ 的联合概率密度当然是

$$f_{\mathbf{X}}(\mathbf{x}) = \prod_{i=1}^n f(x_i).$$

对 $\{X_{(k)}\}$ 作置换, 每一个置换给出一个密度非 0 的区域

$$x_{k_1} < x_{k_2} < \dots < x_{k_n},$$

且这 $n!$ 个区域彼此不交, 在相差一个零测区域意义下构成全空间 $\mathbb{R}^n$. 现在在每个区域内定义映射, 使之构成与

$$x_1 < x_2 < \dots < x_n$$

的一一对应, 则顺序统计量在 $\mathbf{x}$ 处的值就是所有被映到该点的概率密度之和, 当然是

$$n! \prod_{i=1}^n f(x_i).$$

□

同样可以从古典概型的角度理解, 也可以如此理解: 顺序统计量落在 $\mathbf{x}$ 附近区域, 当且仅当原始独立统计量落在全部 $n!$ 个置换区域的某个相应位置, 因此概率密度当然是求和.

要求若干顺序统计量的联合密度函数, 只要对其他量作积分即可. 特别地, 可以计算极差 $X_{(1)}, X_{(n)}$ 的联合密度

$$f(x_1, x_n) = \int_{x_1 < x_2 < \cdots < x_n} n! \prod_{i=1}^n f(x_i) dx_2 \cdots dx_{n-1}.$$

考虑中间全部的 $(n-2)!$ 个置换, 得

$$f(x_1, x_n) = \frac{n!}{(n-2)!} \int_{x_1 < x_2, \dots, x_{n-1} < x_n} \prod_{i=1}^n f(x_i) dx_2 \cdots dx_{n-1},$$

直接计算得

$$f(x_1, x_n) = n(n-1)(F(x_n) - F(x_1))^{n-2} f(x_1) f(x_n).$$

注意到如果 X 服从分布函数 $F(x)$, 且 F 连续, 则由于 F 单调

$$\mathbb{P}(F(X) \leq x) = \mathbb{P}(X \leq F^{-1}(x)) = F(F^{-1}(x)) = x, \quad 0 \leq x \leq 1.$$

这说明任何随机变量 X 只要服从某个连续分布 F , 则 $F(X)$ 必然服从均匀分布 $U(0, 1)$, 因此有必要研究均匀分布的顺序统计量.

Example 1.9.(均匀分布的顺序统计量) 设 $X_1, X_2, \dots, X_n$ 独立同分布 $U(0, 1)$. 则根据 **Theorem 1.8.** 的结果, 第 k 顺序统计量的概率密度函数为

$$f_{(k)}(x) = \begin{cases} \frac{n!}{(k-1)!(n-k)!} x^{k-1} (1-x)^{n-k}, & 0 < x < 1, \\ 0, & \text{otherwise.} \end{cases}$$

我们计算其期望

$$\mathbb{E}(X_{(k)}) = \int_0^1 x \frac{n!}{(k-1)!(n-k)!} x^{k-1} (1-x)^{n-k} dx.$$

注意到可以写为

$$\frac{n!}{(k-1)!(n-k)!} \int_0^1 x^{(k+1)-1} (1-x)^{(n+1)-(k+1)} dx,$$

而积分内相当于 $n + 1$ 个随机变量的第 $k + 1$ 个顺序统计量的密度函数, 因此积分结果是系数的倒数

$$\mathbb{E}(X_{(k)}) = \frac{n!}{(k-1)!(n-k)!} \frac{k!(n-k)!}{(n+1)!} = \frac{k}{n+1},$$

这具有对称性, 即第 k 个顺序统计量和倒数第 k 个顺序统计量有相同的期望. 同理可以计算方差

$$\text{Var}(X_{(k)}) = \frac{k(k+1)}{(n+1)(n+2)} - \left(\frac{k}{n+1}\right)^2 = \frac{k(n-k+1)}{(n+1)^2(n+2)},$$

同样可见对称性. 根据 **Theorem 1.9** 的结果, 顺序统计量的联合概率密度为

$$f(\mathbf{x}) = \begin{cases} n!, & 0 < x_1 < x_2 < \cdots < x_n < 1, \\ 0, & \text{otherwise.} \end{cases}$$

对除去 $X_{(i)}, X_{(j)}$ 以外的项积分, 不妨设 $i < j$, 则 $i < k < j$ 的项积分范围为 $[x_i, x_j]$, $k < i$ 的项积分范围为 $[0, x_i]$, $k > j$ 的项积分范围为 $[x_j, 1]$, 再除掉所有排列数

$$f_{(i,j)}(x_i, x_j) = \frac{n!}{(i-1)!(j-i-1)!(n-j)!} x_i^{i-1} (x_j - x_i)^{j-i-1} (1 - x_j)^{n-j}.$$

从而期望

$$\mathbb{E}(X_{(i)}X_{(j)}) = \frac{n!}{(i-1)!(j-i-1)!(n-j)!} \int_{0 < x_i < x_j < 1} x_i^i x_j (x_j - x_i)^{j-i-1} (1 - x_j)^{n-j} dx_i dx_j,$$

利用 Beta 函数的性质, 先对 x_i 积分

$$\int_0^{x_j} x_i^i (x_j - x_i)^{j-i-1} dx_i = x_j^j \int_0^1 t^i (1-t)^{j-i-1} dt = \frac{i!(j-i-1)!}{j!} x_j^j,$$

代入得

$$\mathbb{E}(X_{(i)}X_{(j)}) = \frac{n!}{(n-j)!} \frac{i}{j!} \int_0^1 x_j^{j+1} (1-x_j)^{n-j} dx_j = \frac{i(j+1)}{(n+1)(n+2)}.$$

因而可以求得协方差

$$\text{Cov}(X_{(i)}, X_{(j)}) = \mathbb{E}(X_{(i)}X_{(j)}) - \mathbb{E}(X_{(i)})\mathbb{E}(X_{(j)}) = \frac{i(n-j+1)}{(n+1)^2(n+2)},$$

相关系数

$$\rho(X_{(i)}, X_{(j)}) = \frac{\text{Cov}(X_{(i)}, X_{(j)})}{\sqrt{\text{Var}(X_{(i)}) \text{Var}(X_{(j)})}} = \sqrt{\frac{i(n-j+1)}{j(n-i+1)}}.$$

作为顺序统计量的推广, 我们通过线性插值定义 p 分位数.

Definition 1.10. (p 分位数) 给定 n 个样本 $X_1, X_2, \dots, X_n$, 对 $0 < p < 1$, 定义 p 分位数是顺序统计量的线性组合

$$\epsilon_{n,p} = X_{([(n+1)p])} + ((n+1)p - [(n+1)p]) \left(X_{([(n+1)p] + 1)} - X_{([(n+1)p])} \right).$$

依照定义很明显第 k 顺序统计量就是 $\frac{k}{n+1}$ 分位数. 反之, 小于 p 分位数的最大顺序统计量是 $X_{([np])}$.

1.5 渐近分布 *

本节的结果仅作介绍, 因其涉及较为复杂的估计和引理, 而相关结论不影响后续. 我们首先回顾概率论中随机变量序列的四种收敛.

Definition 1.11.(随机变量序列的收敛) $\{X_n\}$ 是概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 上的随机变量序列, 相应的概率分布函数为 $F_n(x)$. X 是一个随机变量或常数, 相应的分布函数为 $F(x)$.

1. 如果对任意 $\omega \in \Omega \setminus N$, 其中 N 是一个零测集, 都有

$$\lim_{n \rightarrow \infty} X_n(\omega) = X(\omega),$$

称 $\{X_n\}$ 几乎处处收敛 (a.e.) 到 X .

2. 如果对任意 $\varepsilon > 0$, 有

$$\lim_{n \rightarrow \infty} \mathbb{P}(\{\omega \in \Omega \mid |X_n(\omega) - X(\omega)| < \varepsilon\}) = 1,$$

称 $\{X_n\}$ 依概率收敛 (pr.) 到 X .

3. 如果对某个 $\alpha > 0$, 有

$$\lim_{n \rightarrow \infty} \mathbb{E}(|X_n - X|^\alpha) = 0,$$

称 $\{X_n\}$ 满足 L^α 收敛或 α 阶矩收敛到 X .

4. 如果对任意 $x \in \mathbb{R}$ 是 $F(x)$ 的连续点, 都有

$$\lim_{n \rightarrow \infty} F_n(x) = F(x),$$

则称 X_n 依分布收敛 (dist.) 到 $F(x)$.

大数定律和中心极限定理都从描述了某种收敛性质. 对样本而言, 我们把依分布收敛视作大样本条件下的极限分布, 也称为这组样本的**渐近分布 (asymptotic distribution)**. 例如当样本充分大时, 小于 p 分位数的最大顺序统计量 $X_{([np])}$ 与 p 分位数十分接近, 可以作为其估计.

为了求得一些样本的渐近分布, 我们需要以下引理, 作为中心极限定理的某种推广.

Theorem 1.10.(de Moivre-Laplace, 局部极限定理, local limit theorem) 设随机变量 S_n 服从二项分布 $B(n, p)$, 即 n 次 Bernoulli 试验成功的次数, 满足

$$\mathbb{P}(S_n = x) = C_n^x p^x (1-p)^{n-x}.$$

则对一个给定的有界区间 $I = [a, b]$ 和整数 $k = k(n)$ 使得 $\frac{k-np}{\sqrt{np(1-p)}} \in I$, 当 $n \rightarrow \infty$ 时, 有等价无穷小

$$\mathbb{P}(S_n = k) \approx \frac{1}{\sqrt{2\pi np(1-p)}} \exp \left(-\frac{1}{2} \left(\frac{k-np}{\sqrt{np(1-p)}} \right)^2 \right).$$

Proof. 我们证明更强的结论. 对一个收敛到 $p \in (0, 1)$ 的序列 $\{p_n\} \subseteq (0, 1)$, 整数 k_n 和给定的有界区间 $I = [a, b]$ 使得 $\frac{k_n-np_n}{\sqrt{np_n(1-p_n)}} \in I$ 恒成立, 当 $n \rightarrow \infty$ 时, 有等价无穷小

$$C_n^{k_n} p_n^{k_n} (1-p_n)^{n-k_n} \approx \frac{1}{\sqrt{2\pi np_n(1-p_n)}} \exp \left(-\frac{1}{2} \left(\frac{k_n-np_n}{\sqrt{np_n(1-p_n)}} \right)^2 \right).$$

记 $\lambda(n) = \frac{k_n-np_n}{\sqrt{np_n(1-p_n)}}$, 则根据

$$\frac{k_n}{n} = p_n + \lambda(n) \sqrt{\frac{p_n(1-p_n)}{n}}, \quad \frac{n-k_n}{n} = 1-p_n - \lambda(n) \sqrt{\frac{p_n(1-p_n)}{n}}$$

以及有界性 $p_n \in (0, 1)$ 和 $\lambda(n) \in I$, 可知 k_n 和 $n-k_n$ 都是 $n \rightarrow \infty$ 的无穷大, 因此有 Stirling 公式

$$C_n^{k_n} = \frac{n!}{k_n!(n-k_n)!} \approx \frac{\sqrt{2\pi n} \left(\frac{n}{e}\right)^n}{\sqrt{2\pi k_n} \left(\frac{k_n}{e}\right)^{k_n} \sqrt{2\pi(n-k_n)} \left(\frac{n-k_n}{e}\right)^{n-k_n}},$$

整理得

$$C_n^{k_n} \approx \frac{1}{\sqrt{2\pi}} \sqrt{\frac{n}{k_n(n-k_n)}} \frac{n^n}{k_n^{k_n} (n-k_n)^{n-k_n}}.$$

现在把 $p_n^{k_n} (1-p_n)^{n-k_n}$ 分配

$$C_n^{k_n} p_n^{k_n} (1-p_n)^{n-k_n} \approx \frac{1}{\sqrt{2\pi}} \sqrt{\frac{n}{k_n(n-k_n)}} \left(\frac{np_n}{k_n}\right)^{k_n} \left(\frac{n(1-p_n)}{n-k_n}\right)^{n-k_n}.$$

我们用 $\lambda(n)$ 和 $q_n = 1-p_n$ 将上式改写为

$$\frac{1}{\sqrt{2\pi np_n q_n} \varphi(n)} \exp \left(-k_n \ln \left(1 + \lambda(n) \sqrt{\frac{q_n}{np_n}} \right) + (k_n - n) \ln \left(1 - \lambda(n) \sqrt{\frac{p_n}{nq_n}} \right) \right),$$

其中

$$\varphi(n) = \left(1 + \lambda(n) \sqrt{\frac{q_n}{np_n}} \right) \left(1 - \lambda(n) \sqrt{\frac{p_n}{nq_n}} \right).$$

当然 $\lambda(n)$ 有界, 从而 $\ln$ 的两项都是 $n \rightarrow \infty$ 的无穷小, 用

$$\ln(1+x) = x - \frac{x^2}{2} + \frac{x^3}{3} - \dots$$

将指数内第一项展开到二阶, 由于 $p_n \rightarrow p \in (0, 1)$, 在 n 充分大时 p_n/q_n 是一个有界量, 于是第一项变为

$$-(np_n + \lambda(n)\sqrt{np_nq_n}) \left(\lambda(n)\sqrt{\frac{q_n}{np_n}} - \frac{1}{2}\lambda(n)^2 \frac{q_n}{np_n} + o\left(\frac{1}{n}\right) \right),$$

整理得

$$-\lambda(n)\sqrt{np_nq_n} - \frac{1}{2}\lambda(n)^2q_n + o(1).$$

同理可得另一项

$$\lambda(n)\sqrt{np_nq_n} - \frac{1}{2}\lambda(n)^2p_n + o(1),$$

而同样由各项有界性得 $\varphi(n)$ 的极限为 1, 因此有等价无穷小

$$C_n^{k_n} p_n^{k_n} (1-p_n)^{n-k_n} \approx \frac{1}{\sqrt{2\pi np_nq_n}} \exp\left(-\frac{1}{2}\lambda(n)^2\right),$$

这就是所需证明的. □

虽然局部极限定理的描述是对随机变量 S_n 的, 但其结果是一个纯分析的结论, 即在某些条件下的等价无穷小, 这允许我们在更广泛的情况里应用局部极限定理. 由此可以求得以下渐近分布.

Theorem 1.11. (p 分位数的渐近分布) 设 $0 < p < 1$, 随机变量 (样本) $X_1, X_2, \dots, X_n$ 独立同分布, 分布函数 $F(x)$ 密度函数存在且连续. 如果整数 $k = k(n)$ 使得

$$\lim_{n \rightarrow \infty} \frac{k - np}{\sqrt{n}} = 0,$$

则当 $n \rightarrow \infty$ 时, 随机变量序列

$$\sqrt{\frac{n}{p(1-p)}} f(F^{-1}(p)) (X_{(k)} - F^{-1}(p))$$

依分布收敛到标准正态分布 $N(0, 1)$.

Proof. 根据 **Theorem 1.8.** 的结果, 顺序统计量 $X_{(k)}$ 的密度函数

$$f_{(k)}(x) = \frac{n!}{(k-1)!(n-k)!} F(x)^{k-1} (1-F(x))^{n-k} f(x).$$

利用随机变量函数的密度公式, 对

$$\varphi_n(x) = \sqrt{\frac{n}{p(1-p)}} f(F^{-1}(p)) (x - F^{-1}(p))$$

所求的 $\varphi_n(X_{(k)})$ 的密度函数为

$$f_n(x) = \frac{n!}{(k-1)!(n-k)!} \sqrt{\frac{p(1-p)}{n}} F(\varphi_n^{-1}(x))^{k-1} (1-F(\varphi_n^{-1}(x)))^{n-k} \frac{f(\varphi_n^{-1}(x))}{f(F^{-1}(p))}.$$

对每个固定的 x , 根据 F 的连续性

$$\lim_{n \rightarrow \infty} \varphi_n^{-1}(x) = F^{-1}(p) + \lim_{n \rightarrow \infty} \frac{p(1-p)}{n} \frac{x}{f(F^{-1}(p))} = F^{-1}(p) \implies \lim_{n \rightarrow \infty} F(\varphi_n^{-1}(x)) = p.$$

于是可以取 $p_n(x) = F(\varphi_n^{-1}(x))$ 收敛到 p , 有展开

$$p_n(x) = F(\varphi_n^{-1}(x)) = p + \sqrt{\frac{p(1-p)}{n}}x + o\left(\frac{1}{\sqrt{n}}\right),$$

可知

$$\lim_{n \rightarrow \infty} \frac{k - np_n(x)}{\sqrt{np_n(x)(1-p_n(x))}} = \lim_{n \rightarrow \infty} \frac{k - np_n(x)}{\sqrt{np(1-p)}} = \lim_{n \rightarrow \infty} \left(\frac{k - np}{\sqrt{np(1-p)}} - x + o(1) \right) = -x$$

当然属于区间 $I = B(-x, r(x))$. 于是将上式改写为

$$f_n(x) = C_n^k p_n(x)^k (1-p_n(x))^{n-k} \sqrt{\frac{p(1-p)}{n}} \frac{k}{p_n(x)} \frac{f(\varphi_n^{-1}(x))}{f(F^{-1}(p))},$$

对每个固定的 x , 根据 [Theorem 1.10](#) 的结果立即得到 $f_n(x)$ 的估计

$$\frac{\sqrt{p(1-p)}}{\sqrt{2\pi p_n(x)(1-p_n(x))}} \exp\left(-\frac{1}{2} \left(\frac{k - np_n(x)}{\sqrt{np_n(x)(1-p_n(x))}} \right)^2\right) \frac{k}{np_n(x)} \frac{f(\varphi_n^{-1}(x))}{f(F^{-1}(p))}.$$

根据条件有估计

$$\frac{k}{n} = p + o\left(\frac{1}{\sqrt{n}}\right), \quad p_n(x) = p + o(1),$$

于是两者的商当然趋于 1, 进而有逐点极限

$$\lim_{n \rightarrow \infty} f_n(x) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}x^2\right) \cdot 1 \cdot \frac{f(F^{-1}(p))}{f(F^{-1}(p))} = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} = \Phi'(x).$$

现在要证明分布函数有同样的收敛情形. 注意到 f_n 和 Φ' 在 $\mathbb{R}$ 上的积分均为 1, 根据 Lebesgue 控制收敛定理 [Theorem B.6](#) 可证

$$\lim_{n \rightarrow \infty} \int_{\mathbb{R}} |f_n(t) - \Phi'(t)| dt = 0,$$

进而根据三角不等式

$$|F_n(x) - \Phi(x)| = \left| \int_{-\infty}^x f_n(t) dt - \Phi(x) \right| \leq \int_{\mathbb{R}} |f_n(t) - \Phi'(t)| dt$$

一致收敛于 0 对每一点 $x \in \mathbb{R}$ 成立, 这就证明了依分布收敛. □

之所以称为 p 分位数的渐近分布, 因为在以上条件下 $k = k(n)$ 在 $[np]$ 的一个邻域内, 当然可以取为 $[np]$, 作为 p 分位数的合理估计. 依照正态分布的性质, 在以上条件下, 结论也可以写为随机变量序列

$$\sqrt{n} \left(X_{(k)} - F^{-1}(p) \right)$$

依分布收敛到正态分布

$$N \left(0, \frac{p(1-p)}{f(F^{-1}(p))^2} \right),$$

或随机变量序列

$$\sqrt{n} f(F^{-1}(p)) \left(X_{(k)} - F^{-1}(p) \right)$$

依分布收敛到正态分布 $N(0, p(1-p))$.

现在可以给出一些分布下样本 p 分位数的渐近分布.

Example 1.10. (若干分布 p 分位数的渐近分布) 注意到

$$\lim_{n \rightarrow \infty} \frac{[np] - np}{\sqrt{n}} = 0,$$

根据 **Theorem 1.11** 得到随机变量序列

$$\sqrt{n} f(F^{-1}(p)) \left(X_{([np])} - F^{-1}(p) \right)$$

依分布收敛到正态分布 $N(0, p(1-p))$, 其中 $X_{([np])}$ 是 p 分位数的近似. 取 $F(x)$ 为均匀分布, 则密度函数是 $(0, 1)$ 上的常值函数, 随机变量序列

$$\sqrt{n} \left(X_{([np])} - p \right)$$

依分布收敛到正态分布 $N(0, p(1-p))$. 对 Cauchy 分布而言

$$f(x) = \frac{1}{\pi(1+x^2)}, \quad F(x) = \frac{1}{\pi} \arctan x + \frac{1}{2},$$

在 $p = \frac{1}{2}$ (中位数) 处最简单, 即随机变量序列 $\sqrt{n} X_{([n/2])}$ 依分布收敛到 $N(0, \frac{\pi^2}{4})$. 对正态分布而言

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp \left(-\frac{1}{2} \frac{(x-\mu)^2}{\sigma^2} \right),$$

同样在 $p = \frac{1}{2}$ 处, 随机变量序列 $\sqrt{n} X_{([n/2])}$ 依分布收敛到 $N(0, \frac{\pi\sigma^2}{2})$.

最后 **Theorem B.7** 给出了求渐近分布的重要方法, 允许我们由依分布收敛的结果出发推知其他结果, 即对求极限的过程作四则运算.

Chapter 2

统计估计

2.1 点估计理论

回顾概率论的目标是根据分布函数分析随机变量的数值特征, 而数理统计则是通过得到的随机变量特征推断分布函数. 分布函数的全体构成集合, 而对给定的样本必然存在能够很好地符合其特征的分布函数. 然而分布函数的数量如此庞大, 以致几乎不可能找到适当的分布函数. 一个合理而折中的做法是考虑一系列具有某种共性的函数族, 将函数估计问题变为参数估计问题.

常规情况下我们会假设分布族由参数 $\lambda \in \Lambda$ 给出, 即

$$\mathcal{F} = \{F_\lambda \mid \lambda \in \Lambda\}.$$

例如正态分布族由参数 μ, σ 给出, 即

$$\mathcal{F} = \left\{ F_{\mu, \sigma} = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) \mid (\mu, \sigma) \in \Lambda \right\}.$$

更一般地, 我们的信息可能不足以把可能的分布函数范围用有限个参数统一表达, 例如既有可能是正态分布, 又有可能是指数分布的情况, 此时分布族则可以更直接地看作可能的分布函数的全体, 以自身为参数.

除了分布函数本身以外, 我们还对由分布函数给出的一些数值特征感兴趣, 这由分布函数唯一决定, 因而记作 $\theta = \theta(F)$. 例如均值

$$\mu = \int_{\mathbb{R}} x dF(x)$$

和总体方差

$$\sigma^2 = \int_{\mathbb{R}^2} \frac{(x-y)^2}{2} dF(x)dF(y),$$

又如中位数 $F^{-1}\left(\frac{1}{2}\right)$ 和概率 $F(x_0)$ 等. 因此一个重要的目标就是通过给定的样本 (随机变量), 独立且服从某个未知的正态分布 F , 估计参数 $\theta(F)$. 根据样本得到的估计值

常记作

$$\hat{\theta} = \hat{\theta}(X_1, X_2, \dots, X_n),$$

因此我们的目标可以表述为: 如何选取适当的函数 $\hat{\theta}$, 使得估计值尽可能好, 这就称为点估计.

Definition 2.1.(点估计) 给定总体 F_λ , λ 未必是实数, 称为总体参数, 从中抽取样本 $X_1, X_2, \dots, X_n$. $g(\lambda)$ 是关于总体参数的实值函数, 如果 $\hat{g}(\mathbf{X})$ 是 $g(\lambda)$ 的一个估计, 则称 $\hat{g}(\mathbf{X})$ 是 $g(\lambda)$ 的估计量 (estimator), 称此方法为点估计 (point estimation).

一个很好的情况是, λ 确实是实参数 (组), 于是 $g(\lambda)$ 就变为实变函数, 如果能找到 λ 的一个很好的估计 $\hat{\lambda} = \hat{\lambda}(\mathbf{X})$, 则取 $\hat{g}(\mathbf{X}) = g(\hat{\lambda})$ 就是 $g(\lambda)$ 的很好的估计. 使用参数估计近似数值特征估计的原则称为懒惰原则 (lazy statistician rule).

为了评估**Definition 2.1.**中 $\hat{g}(\mathbf{X})$ 与 $g(\lambda)$, 或者在懒惰原则下, $\hat{\lambda} = \hat{\lambda}(\mathbf{X})$ 与 λ 的接近程度, 需要一些评估函数.

Definition 2.2.(无偏性) 设 $X_1, X_2, \dots, X_n$ 是总体 F_λ 中抽取的样本, $\hat{g}(\mathbf{X})$ 是 $g(\lambda)$ 的一个估计量, 如果

$$\mathbb{E}(\hat{g}(\mathbf{X})) = g(\lambda)$$

对每一组相应于 λ 的样本 $\mathbf{X}$ 都成立, 则称 $\hat{g}(\mathbf{X})$ 是 $g(\lambda)$ 的一个无偏估计 (unbiased estimation).

作为估计接近程度的函数, 依照大数定律, 无偏性意味着当样本量增大时, 估计值会趋近于真实值.

Example 2.1.(总体方差的无偏估计) 回顾样本方差

$$S_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

和总体方差

$$\sigma^2 = \int_{\mathbb{R}^2} \frac{(x-y)^2}{2} dF(x)dF(y).$$

根据**Example 1.2.**的结果有 $\mathbb{E}(S_n^2) = \sigma^2$, 这说明样本方差是总体方差的无偏估计.

Example 2.2.(均匀分布的无偏估计) 考虑分布族 $F_\theta \sim U(0, \theta)$, 给定 n 个样本, 根据**Example 1.9.**作伸缩变换, 顺序统计量的期望

$$\mathbb{E}(X_{(k)}) = \frac{k}{n+1} \theta.$$

于是

$$\hat{\theta} = \frac{n+1}{k} X_{(k)}, \quad 1 \leq k \leq n$$

给出了 n 个无偏估计.

我们当然希望从所有的无偏估计中选一些性质更好的, 一种常见方式是关注方差.

Definition 2.3.(均方损失) 设 $X_1, X_2, \dots, X_n$ 是总体 F_λ 中抽取的样本, $\hat{g}(\mathbf{X})$ 是 $g(\lambda)$ 的一个估计量. 定义

$$\text{MSE}(\hat{g}(\mathbf{X})) = \mathbb{E} \left((\hat{g}(\mathbf{X}) - g(\lambda))^2 \right) = \text{Var}(\hat{g}(\mathbf{X})) + (\mathbb{E}(\hat{g}(\mathbf{X})) - g(\lambda))^2$$

称为**均方损失 (mean squared error)**.

对无偏估计而言, 右边第二项为 0, 此时均方损失就是方差. 如果方差对一切参数 $\lambda \in \Lambda$ 都 (最) 小, 则称这个估计的有效性 (最) 强. 特别地, 对无偏估计有以下定义.

Definition 2.4.(有效性) 设 $X_1, X_2, \dots, X_n$ 是总体 F_λ 中抽取的样本, $\hat{g}_1(\mathbf{X})$ 和 $\hat{g}_2(\mathbf{X})$ 是 $g(\lambda)$ 的两个无偏估计量. 如果对一切参数 $\lambda \in \Lambda$, 有

$$\text{Var}(\hat{g}_1(\mathbf{X})) \leq \text{Var}(\hat{g}_2(\mathbf{X}))$$

恒成立, 且至少存在一个 λ 使严格不等号成立, 则称估计量 $\hat{g}_1(\mathbf{X})$ 比 $\hat{g}_2(\mathbf{X})$ 更有效.

Exercise 1.3. 设 $X_1, X_2, \dots, X_n$ 是总体 $N(\mu, \sigma^2)$ 中抽取的简单样本, 对 σ^2 有估计

$$\hat{\theta} = c_n \sum_{k=1}^n (X_k - \bar{X})^2.$$

试求 c_n 取何值时均方误差最小, 并求出最小值.

Solution. 依照**Definition 2.3.**计算均方损失

$$\text{MSE}(\hat{\theta}) = c_n^2 \mathbb{E} \left(\left(\sum_{k=1}^n (X_k - \bar{X})^2 \right)^2 \right) - 2c_n \sigma^2 \mathbb{E} \left(\sum_{k=1}^n (X_k - \bar{X})^2 \right) + \sigma^4.$$

根据**Exercise 1.1.**的结果, 取 $\sigma_i = \sigma$ 即知

$$\frac{1}{\sigma^2} \sum_{k=1}^n (X_k - \bar{X})^2 \sim \chi_{n-1}^2,$$

根据**Theorem 1.3.**的结果即得前两阶矩为 $n-1$ 和 n^2-1 , 代入得

$$\text{MSE}(\hat{\theta}) = c_n^2 (n^2 - 1) \sigma^4 - 2c_n (n - 1) \sigma^4 + \sigma^4.$$

要使之取最小值, 必须

$$\frac{\partial}{\partial c_n} = 2c_n(n^2 - 1)\sigma^4 - 2(n - 1)\sigma^4 = 0 \implies c_n = \frac{1}{n + 1},$$

此时

$$\text{MSE}(\hat{\theta}) = \frac{2}{n + 1}\sigma^4.$$

Example 2.3.(均匀分布的有效性) 设 $X_1, X_2, \dots, X_n$ 是总体 $F_\theta \sim U(0, \theta)$ 中抽取的简单样本. 依照 **Example 2.2.** 对 θ 有估计

$$\hat{\theta} = \frac{n + 1}{k} X_{(k)}.$$

我们已经说明过这是 n 个无偏估计, 于是均方损失

$$\text{MSE}(\hat{\theta}) = \text{Var}(\hat{\theta}) = \frac{(n + 1)^2}{k^2} \text{Var}(X_{(k)}).$$

根据 **Example 1.9.** 的结果

$$\text{MSE}(\hat{\theta}) = \frac{(n + 1)^2}{k^2} \frac{k(n - k + 1)}{(n + 1)^2(n + 2)} = \frac{n - k + 1}{k(n + 2)} \geq \frac{1}{n(n + 2)},$$

取等当且仅当 $k = n$. 再考虑无偏估计 $\hat{\theta} = 2\bar{X}$, 容易计算均方损失

$$\text{MSE}(\hat{\theta}) = 4 \text{Var}(\bar{X}) = \frac{1}{3n} \leq \frac{1}{n(n + 2)}$$

显然是有效性更强的估计, 且取等当且仅当 $n = 1$. 再考虑带参数 c_n 的估计 $\hat{\theta} = c_n X_{(n)}$, 则均方损失

$$\text{MSE}(\hat{\theta}) = c_n^2 \text{Var}(X_{(n)}) + (c_n \mathbb{E}(X_{(n)}) - \theta)^2.$$

由于 $\frac{X_{(n)}}{\theta} \sim U(0, 1)$, 再次利用 **Example 1.9.** 的结果

$$\text{MSE}(\hat{\theta}) = c_n^2 \theta^2 \frac{n}{(n + 1)^2(n + 2)} + \left(c_n \theta \frac{n}{n + 1} - \theta\right)^2.$$

同理计算偏导数可得最小值点为 $c_n = \frac{n+2}{n+1}$, 代入得最小值

$$\text{MSE}(\hat{\theta}) = \frac{1}{(n + 1)^2} \theta^2.$$

我们希望当样本量足够大时, 估计量收敛于估计参数的真实值, 由此将给出了衡量估计量的若干指标. 在 **Definition 1.11.** 中我们回顾了若干收敛模式, 据此分别给出指标.

Definition 2.5.(相合性) 设 $X_1, X_2, \dots, X_n$ 是总体 F_λ 中抽取的样本, $\hat{g}_n(\mathbf{X})$ 是 $g(\lambda)$ 的一个估计量.

1. 如果对任意 $\omega \in \Omega \setminus N$, 其中 N 是一个零测集, 都有

$$\lim_{n \rightarrow \infty} \hat{g}_n(\mathbf{X}(\omega)) = g(\lambda),$$

即随机变量 $\hat{g}_n(\mathbf{X})$ 几乎处处收敛到 $g(\lambda)$, 则称 $\hat{g}_n(\mathbf{X})$ 是 $g(\lambda)$ 的**强相合估计 (strongly consistent estimation)**.

2. 如果对任意 $\varepsilon > 0$, 有

$$\lim_{n \rightarrow \infty} \mathbb{P}(\{\omega \in \Omega \mid |\hat{g}_n(\mathbf{X}(\omega)) - g(\lambda)| < \varepsilon\}) = 1,$$

即随机变量 $\hat{g}_n(\mathbf{X})$ 依概率收敛到 $g(\lambda)$, 则称 $\hat{g}_n(\mathbf{X})$ 是 $g(\lambda)$ 的**弱相合估计 (weakly consistent estimation)**.

3. 如果对某个 $\alpha > 0$, 有

$$\lim_{n \rightarrow \infty} \mathbb{E}(|\hat{g}_n(\mathbf{X}) - g(\lambda)|^\alpha) = 0,$$

称 $\hat{g}_n(\mathbf{X})$ 是 $g(\lambda)$ 的 α 阶矩相合估计.

4. 如果对于任意的 $\varepsilon > 0$, 级数

$$\sum_{n=1}^{\infty} P(|\hat{g}_n(\mathbf{X}) - g(\lambda)| > \varepsilon) < \infty$$

都成立, 则称 $\hat{g}_n(\mathbf{X})$ **完全收敛 (complete convergence)** 于 $g(\lambda)$.

强相合估计是几乎处处收敛, 当然应该用强大数定律或 Borel-Cantelli 引理证明, 而弱相合估计是依概率收敛, 一般常用弱大数定律, Markov 不等式和 Chebyshev 不等式.

2.2 矩估计与极大似然估计

2.2.1 矩估计

正如分析学中我们用 Taylor 多项式逼近函数, 每一阶多项式的系数由 $\frac{f^{(n)}(x_0)}{n!}$ 给出, 在统计学中我们用 n 阶矩逼近分布函数. 采用求 Taylor 多项式一样的方法, 如果需要前 n 阶矩匹配, 我们必须待定分布函数 F 的 n 个参数

$$F(x) = F(\lambda_1, \lambda_2, \dots, \lambda_n)(x).$$

则可以计算 $1 \leq k \leq n$ 阶矩

$$E_k(\lambda_1, \lambda_2, \dots, \lambda_n) = \mathbb{E}(X^k) = \int_{\mathbb{R}} x^k dF(x).$$

如果给定了 n 个样本 $X_1, X_2, \dots, X_n$, 经验分布函数

$$F_n(x) = \frac{1}{n} \sum_{k=1}^n \chi(X_k \leq x)$$

编码了样本的所有信息, 因此可用样本矩

$$\hat{E}_{n,k} = \int_{\mathbb{R}} x^k dF_n(x) = \frac{1}{n} \sum_{i=1}^n X_i^k$$

近似分布矩, 即考虑方程组

$$E_k(\lambda_1, \lambda_2, \dots, \lambda_n) = \hat{E}_{n,k},$$

由此解出参数 $\{\lambda_k\}$ 的值, 并把得到的分布作为实际分布的估计, 这就称为矩估计方法.

一般而言, 利用矩估计方法分为三步: 计算带参数的 k 阶矩 (数值), 解出参数关于 k 阶矩的表达式 (数值), 并代入估计 $\hat{E}_{n,k}$ 求出参数的估计 $\hat{\lambda}$ (随机变量).

Algorithm 2.1.(矩估计) 给定分布族 $F(x) = F(x; \lambda_1, \lambda_2, \dots, \lambda_r)$, 其中 λ_k 是实参数, 以及 n 个简单样本 $X_1, X_2, \dots, X_n$, 要估计参数的函数 $\varphi = \varphi(\lambda_1, \lambda_2, \dots, \lambda_r)$. 计算前 r 阶矩

$$E_{n,k}(\lambda_1, \lambda_2, \dots, \lambda_r) = \mathbb{E}(X^k) = \int_{\mathbb{R}} x^k dF(x; \lambda_1, \lambda_2, \dots, \lambda_r), \quad 1 \leq k \leq r,$$

由此反解出

$$\lambda_k = \psi_k(E_{n,1}, E_{n,2}, \dots, E_{n,r}),$$

并用样本矩估计分布矩

$$\hat{E}_{n,k} = \frac{1}{n} \sum_{i=1}^n X_i^k,$$

得到参数估计

$$\hat{\lambda}_k = \psi_k(\hat{E}_{n,1}, \hat{E}_{n,2}, \dots, \hat{E}_{n,r})$$

以及函数估计

$$\hat{\varphi} = \varphi(\hat{\lambda}_1, \hat{\lambda}_2, \dots, \hat{\lambda}_r).$$

由此得到的 $\hat{\varphi}$ 称为 φ 的**矩估计 (moment estimation)**.

Example 2.4.(均匀分布的矩估计) 设 $X_1, X_2, \dots, X_n$ 是总体 $F \sim U(a, b)$ 中抽取的简单样本. 我们计算 k 阶矩

$$\mathbb{E}(X^k) = \int_a^b x^k \frac{1}{b-a} dx = \frac{1}{k+1} \frac{b^{k+1} - a^{k+1}}{b-a},$$

由于只要估计两个参数, 取前两个

$$\begin{cases} \mathbb{E}(X) = \frac{1}{2}(a+b), \\ \mathbb{E}(X^2) = \frac{1}{3}(a^2 + ab + b^2) \end{cases} \implies \begin{cases} a = \mathbb{E}(X) - \sqrt{3(\mathbb{E}(X^2) - \mathbb{E}(X)^2)}, \\ b = \mathbb{E}(X) + \sqrt{3(\mathbb{E}(X^2) - \mathbb{E}(X)^2)}. \end{cases}$$

代入得

$$\begin{cases} \hat{a} = \bar{X} - \sqrt{3}S_n, \\ \hat{b} = \bar{X} + \sqrt{3}S_n. \end{cases}$$

正如 Taylor 展开可以在任意一点进行, 矩估计也可以在任何 p 分位数处进行, 特别地可以在均值处进行. 考虑中心矩

$$E_k(\lambda_1, \lambda_2, \dots, \lambda_n) = \mathbb{E}((X - \mu)^k) = \int_{\mathbb{R}} (x - \mu)^k dF(x)$$

和

$$\hat{E}_{n,k} = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k$$

即可. 由于 (原点) 矩和中心矩可以互相通过多项式表出, 因此计算得到的分布在同阶条件下是完全一致的.

矩估计的每个样本矩

$$\hat{E}_{n,k} = \int_{\mathbb{R}} x^k dF_n(x) = \frac{1}{n} \sum_{i=1}^n X_i^k \implies \mathbb{E}(\hat{E}_{n,k}) = \mathbb{E}(X_i^k) = \mathbb{E}(X^k)$$

显然是相应的无偏估计和强相合估计 (独立同分布强大数定律), 然而解方程得到的每个参数 $\hat{\lambda}_k$ 作为 $\hat{E}_{n,k}$ 的函数则未必是 λ_k 的无偏估计, 不过依照 **Theorem B.8.** 可知只要这个函数是连续的, 则仍然是强相合估计.

2.2.2 极大似然估计

我们先考虑如下例子.

Example 2.5.(二项分布的极大似然估计) 设 X_0 是总体 $F \sim B(n, p)$ 中抽取的简单样本, 即总体分布

$$\mathbb{P}(X = k) = C_n^k p^k (1-p)^{n-k}.$$

既然 X_0 作为实际发生的样本被我们观测到, 那么总体分布中 X_0 的概率应该很高, 因而将 p 取为最有可能使 X_0 发生的参数是一个合理的估计. 代入得

$$\mathbb{P}(X = X_0) = C_n^{X_0} p^{X_0} (1-p)^{n-X_0},$$

为寻找 p 使之最大, 考虑导数

$$\frac{\partial}{\partial p} (p^{X_0} (1-p)^{n-X_0}) = 0 \iff (1-p)X_0 = p(n-X_0) \iff p = \frac{1}{n}X_0,$$

因此取估计

$$\hat{p} = \frac{1}{n}X_0.$$

如果取的独立样本变多, 则依照大数定律, 使样本发生的可能性越大, 结果也就越精确. 如果给定从总体分布 F 取出的 n 个独立样本 $X_1, X_2, \dots, X_n$, 则这些样本被观测到的概率为

$$\mathbb{P}(X_1, X_2, \dots, X_n) = \prod_{i=1}^n \mathbb{P}(X = X_i) = \prod_{i=1}^n F(X_i).$$

对连续分布的情形, 上式恒为 0, 因此我们要考虑在 X_i 附近发生概率最大, 即

$$\prod_{i=1}^n \mathbb{P}(|X - X_i| \leq \varepsilon) \sim C\varepsilon^n \prod_{i=1}^n f(X_i).$$

如果参数的选取使得以上函数最大, 则得到的分布最有可能使观测到的样本发生, 即最大化了样本发生的**可能性/似然 (likelihood)**. 我们给出具体的算法.

Algorithm 2.2.(极大似然估计) 给定分布族 $F(x) = F(x; \lambda_1, \lambda_2, \dots, \lambda_r)$, 其中 λ_k 是实参数, 以及 n 个简单样本 $X_1, X_2, \dots, X_n$, 要估计参数的函数 $\varphi = \varphi(\lambda_1, \lambda_2, \dots, \lambda_r)$. 计算**似然函数 (likelihood function)**

$$L(\lambda_1, \lambda_2, \dots, \lambda_r) = \prod_{i=1}^n f(x_i; \lambda_1, \lambda_2, \dots, \lambda_r).$$

对离散分布而言, 也可用 F 代替 f . 为了求似然函数的最大值, 对各参数求偏导数并令

$$\frac{\partial}{\partial \lambda_k} L(\lambda_1, \lambda_2, \dots, \lambda_r) = 0,$$

解得

$$\lambda_k = \psi_k(x_1, x_2, \dots, x_k).$$

代入样本得到参数估计

$$\hat{\lambda}_k = \psi_k(X_1, X_2, \dots, X_n)$$

以及函数估计

$$\hat{\varphi} = \varphi(\hat{\lambda}_1, \hat{\lambda}_2, \dots, \hat{\lambda}_r).$$

由此得到的 $\hat{\varphi}$ 称为 φ 的**极大似然估计 (maximum likelihood estimation)**.

极大似然估计的好处是不受分布函数各阶矩存在性的影响, 只要给定适当的参数空间, 使似然函数取最大值的参数组总是存在.

Example 2.6.(均匀分布的极大似然估计) 设 $X_1, X_2, \dots, X_n$ 是总体 $F \sim U(a, b)$ 中抽取的简单样本. 可以写出似然函数

$$L(a, b) = \prod_{i=1}^n \frac{\chi(a \leq x_i \leq b)}{b - a}.$$

很明显在

$$a = \min_{1 \leq i \leq n} \{x_i\}, \quad b = \max_{1 \leq i \leq n} \{x_i\}$$

处取到, 于是代入得

$$\hat{a} = X_{(1)}, \quad \hat{b} = X_{(n)}.$$

我们可以验证其有效性. 根据**Theorem 1.8.**的结果, 密度函数

$$f_{(1)}(x) = n \frac{(b-x)^{n-1}}{(b-a)^n}, \quad f_{(n)}(x) = n \frac{(x-a)^{n-1}}{(b-a)^n}, \quad x \in (a, b).$$

于是期望

$$\mathbb{E}(\hat{a}) = \frac{na + b}{n + 1}, \quad \mathbb{E}(\hat{b}) = \frac{a + nb}{1 + n},$$

因而不是无偏估计. 注意到

$$\mathbb{P}(|\hat{a} - a| \geq \varepsilon) = 1 - \int_{a-\varepsilon}^{a+\varepsilon} f_{(1)}(x) dx = \left(1 - \frac{\varepsilon}{b-a}\right)^n,$$

当 $n \rightarrow \infty$ 时极限为 0, 对 $\hat{b}$ 有类似的结果, 因而都是弱相合估计.

Exercise 1.4. 设 $X_1, X_2, \dots, X_n$ 是总体 $F \sim U(a, b)$ 中抽取的简单样本. 则有极大似然估计

$$\hat{a} = X_{(1)}, \quad \hat{b} = X_{(n)}.$$

证明 $\hat{a}, \hat{b}$ 是 a, b 的强相合估计和 α 阶矩相合估计.

Proof. 我们只证明 $\hat{a}, \hat{b}$ 完全同理. 在 **Example 2.6.** 中已经估计了

$$\mathbb{P}(|\hat{a}_n - a| \geq \varepsilon) = \left(1 - \frac{\varepsilon}{b-a}\right)^n,$$

于是等比级数

$$\sum_{n=1}^{\infty} \mathbb{P}(|\hat{a}_n - a| \geq \varepsilon) = \left(1 - \frac{\varepsilon}{b-a}\right) \frac{b-a}{\varepsilon} = \frac{b-a}{\varepsilon} - 1 < \infty.$$

根据 Borel-Cantelli 引理 **Theorem B.9.**, 除去一个零测集 N 以外, 所有点 $\omega \in \Omega \setminus N$ 都落在至多有限个集合

$$E_n = \{\omega \in \Omega \mid |\hat{a}_n(\mathbf{X}(\omega)) - a| \geq \varepsilon\},$$

这就是说对任意 $\omega \in \Omega \setminus N$, 当 n 充分大时, 就有

$$|\hat{a}_n(\mathbf{X}(\omega)) - a| < \varepsilon,$$

此即几乎处处收敛

$$\lim_{n \rightarrow \infty} \hat{a}_n(\mathbf{X}(\omega)) = a.$$

为证 α 阶矩相合, 只需证

$$\lim_{n \rightarrow \infty} \mathbb{E}(|X_{(1)} - a|^\alpha) = 0.$$

为此, 计算

$$\mathbb{E}(|X_{(1)} - a|^\alpha) = \int_a^b (x-a)^\alpha n \frac{(b-x)^{n-1}}{(b-a)^n} dx.$$

作换元 $t = \frac{b-x}{b-a}$ 得

$$\mathbb{E}(|X_{(1)} - a|^\alpha) = n(b-a)^\alpha \int_0^1 (1-t)^\alpha t^{n-1} dt = n(b-a)^\alpha B(n, \alpha+1).$$

根据 Beta 函数与 Gamma 函数以及阶乘的关系 **Theorem A.1.**, **Theorem A.2.**

$$\mathbb{E}(|X_{(1)} - a|^\alpha) = (b-a)^\alpha \frac{n!}{\Gamma(n+\alpha+1)}.$$

根据 Stirling 公式, 当 $n \rightarrow \infty$ 时等价无穷小

$$\frac{n!}{\Gamma(n+\alpha+1)} \approx \sqrt{\frac{n}{n+\alpha}} \cdot \frac{n^n}{(n+\alpha)^{n+\alpha}} \cdot e^\alpha \approx e^\alpha n^{-\alpha},$$

于是

$$\lim_{n \rightarrow \infty} \mathbb{E}(|X_{(1)} - a|^\alpha) = 0.$$

□

求极值是求导运算, 往往比求矩的积分运算更容易计算. 极大似然估计还保留了较多分布信息, 而不是仅仅取决于各阶矩.

Example 2.7.(Poisson 分布的极大似然估计) 设 $X_1, X_2, \dots, X_n$ 是总体 $F \sim \text{Poi}(\lambda)$ 中抽取的简单样本. 似然函数

$$L(\lambda) = \left(\prod_{i=1}^n x_i! \right)^{-1} \exp \left(-n\lambda + \ln \lambda \sum_{i=1}^n x_i \right).$$

由于指数函数单调, 只要让

$$-n\lambda + \ln \lambda \sum_{i=1}^n x_i$$

最大, 于是

$$\frac{\partial}{\partial \lambda} \left(-n\lambda + \ln \lambda \sum_{i=1}^n x_i \right) = -n + \frac{1}{\lambda} \sum_{i=1}^n x_i = 0 \iff \lambda = \frac{1}{n} \sum_{i=1}^n x_i$$

处取到, 于是代入得 $\hat{\lambda} = \bar{X}$.

由于单调变换不改变最大值点, 因此常用对数变换将连乘变为连加, 再求导计算最大值点.

Example 2.8.(指数分布的矩估计和极大似然估计) 设 $X_1, X_2, \dots, X_n$ 是总体 $F \sim \text{Exp}(\lambda)$ 中抽取的简单样本. 计算一阶矩

$$\mathbb{E}(X) = \int_0^{+\infty} \lambda x e^{-\lambda x} dx = \int_0^{+\infty} e^{-\lambda x} dx = \frac{1}{\lambda},$$

解得

$$\lambda = \mathbb{E}(X)^{-1}.$$

代入样本矩得

$$\hat{\lambda} = \left(\frac{1}{n} \sum_{i=1}^n X_i \right)^{-1} = \bar{X}^{-1}.$$

似然函数

$$L(\lambda) = \lambda^n \exp \left(-\lambda \left(\sum_{i=1}^n x_i \right) \right).$$

求对数

$$\ln L(\lambda) = n \ln \lambda - \lambda \left(\sum_{i=1}^n x_i \right).$$

令

$$\frac{\partial}{\partial \lambda} \left(n \ln \lambda - \lambda \left(\sum_{i=1}^n x_i \right) \right) = \frac{n}{\lambda} - \sum_{i=1}^n x_i = 0 \iff \lambda = \left(\frac{1}{n} \sum_{i=1}^n x_i \right)^{-1}$$

处取到, 于是代入得 $\hat{\lambda} = \bar{X}^{-1}$, 恰好与矩估计相同.

Example 2.9.(正态分布的极大似然估计) 设 $X_1, X_2, \dots, X_n$ 是总体 $F \sim N(\mu, \sigma^2)$ 中抽取的简单样本. 似然函数

$$L(\mu, \sigma) = (2\pi)^{-\frac{n}{2}} \sigma^{-n} \exp \left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 \right).$$

注意到含 μ 的项

$$\sum_{i=1}^n (x_i - \mu)^2$$

是二次函数, 极大值必然在

$$\frac{\partial}{\partial \mu} \left(\sum_{i=1}^n (x_i - \mu)^2 \right) = \sum_{i=1}^n 2(\mu - x_i) = 0 \implies \mu = \frac{1}{n} \sum_{i=1}^n x_i$$

处取到, 而与 σ 无关, 故最大值实际上是关于 σ 的函数

$$L(\sigma) = (2\pi)^{-\frac{n}{2}} \sigma^{-n} \exp \left(-\frac{1}{2\sigma^2} \left(\sum_{i=1}^n x_i^2 - \frac{1}{n} \left(\sum_{i=1}^n x_i \right)^2 \right) \right).$$

求对数

$$\ln L(\sigma) = -\frac{n}{2} \ln 2\pi - n \ln \sigma - \frac{1}{2\sigma^2} \left(\sum_{i=1}^n x_i^2 - \frac{1}{n} \left(\sum_{i=1}^n x_i \right)^2 \right)$$

令

$$\frac{\partial}{\partial \lambda} \left(-n \ln \sigma - \frac{1}{2\sigma^2} \left(\sum_{i=1}^n x_i^2 - \frac{1}{n} \left(\sum_{i=1}^n x_i \right)^2 \right) \right) = 0 \iff \sigma^2 = \frac{1}{n} \sum_{i=1}^n x_i^2 - \left(\frac{1}{n} \sum_{i=1}^n x_i \right)^2$$

处取到, 于是代入得

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n X_i, \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \left(\frac{1}{n} \sum_{i=1}^n X_i \right)^2.$$

当然也可以直接对 μ, σ 分别求偏导, 解得

$$\mu = \frac{1}{n} \sum_{i=1}^n x_i, \quad \sigma^2 = \frac{1}{n} \sum_{i=1}^n \left(x_i - \frac{1}{n} \sum_{i=1}^n x_i \right)^2.$$

不过此时要计算 Hesse 矩阵并证明其负定. 例如我们考虑对数似然

$$\ln L(\mu, \sigma) = -\frac{n}{2} \ln 2\pi - n \ln \sigma - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2,$$

有

$$\frac{\partial}{\partial \mu} \ln L(\mu, \sigma) = -\frac{1}{\sigma^2} \sum_{i=1}^n (\mu - x_i), \quad \frac{\partial}{\partial \sigma} \ln L(\mu, \sigma) = -\frac{n}{\sigma} + \frac{1}{\sigma^3} \sum_{i=1}^n (x_i - \mu)^2,$$

Hesse 矩阵

$$H(\mu, \sigma) = \begin{bmatrix} -\frac{n}{\sigma^2} & \frac{2}{\sigma^3} \sum_{i=1}^n (\mu - x_i) \\ \frac{2}{\sigma^3} \sum_{i=1}^n (\mu - x_i) & \frac{n}{\sigma^2} - \frac{3}{\sigma^4} \sum_{i=1}^n (\mu - x_i)^2 \end{bmatrix}.$$

计算顺序主子式, 第一项显然为负, 第二项即行列式在以上求出的 μ 和 σ 处的值

$$\frac{n}{\sigma^2} \left(\frac{3}{\sigma^4} \sum_{i=1}^n (\mu - x_i)^2 - \frac{n}{\sigma^2} \right) - \left(\frac{2}{\sigma^3} \sum_{i=1}^n (\mu - x_i) \right)^2 = \frac{2n}{\sigma^6} \sum_{i=1}^n (\mu - x_i)^2 > 0.$$

这就证明了负定, 从而确为最大值, 同样给出了

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n X_i, \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \left(\frac{1}{n} \sum_{i=1}^n X_i \right)^2.$$

考虑以下场景: 选定教室的 n 个电灯记录寿命, 理论上每个电灯损坏将获得一个样本, 最终得到独立同分布的 $X_1, X_2, \dots, X_n$. 实际上电灯的寿命可能很长, 在有限时间内无法观察到全部样本, 而只能记录前 r 个灯损坏的时间, 这恰好是前 r 个顺序统计量. 因此有必要对顺序统计量做极大似然估计.

Example 2.10. (顺序统计量的极大似然估计) 设 $X_1, X_2, \dots, X_n$ 是总体 $F \sim \text{Exp}(\lambda)$ 中抽取的简单样本, 前 r 个顺序统计量为 $X_{(1)}, X_{(2)}, \dots, X_{(r)}$. 似然函数是前 r 个顺序统计量的“概率”, 即联合密度函数. 根据 Theorem 1.9 的结果作积分

$$L(\lambda) = \int_{x_r < x_{r+1} < \dots < x_n} n! \lambda^n \exp \left(-\lambda \sum_{i=1}^n x_i \right) dx_{r+1} \cdots dx_n.$$

考虑排列则

$$L(\lambda) = \int_{x_k > x_r, k \geq r+1} \frac{n!}{(n-r)!} \lambda^n \exp \left(-\lambda \sum_{i=1}^n x_i \right) dx_{r+1} \cdots dx_n,$$

计算得

$$L(\lambda) = \frac{n!}{(n-r)!} \lambda^r \exp \left(-\lambda \sum_{i=1}^r x_i \right) (1 - F(x_r))^{n-r}.$$

注意到 $F(x) = 1 - e^{-\lambda x}$, 于是

$$\ln L(\lambda) = \ln \frac{n!}{(n-r)!} + r \ln \lambda - \lambda \sum_{i=1}^r x_i - \lambda(n-r)x_r.$$

求偏导

$$\frac{\partial}{\partial \lambda} \ln L(\lambda) = \frac{r}{\lambda} - \sum_{i=1}^r x_i - (n-r)x_r = 0 \implies \lambda = r \left(\sum_{i=1}^r x_i + (n-r)x_r \right)^{-1}.$$

于是估计

$$\hat{\lambda} = r \left(\sum_{i=1}^r X_{(i)} + (n-r)x_{(r)} \right)^{-1}.$$

我们发现在取对数之后, 似然函数都具有 $a \ln \lambda - b\lambda^\alpha$ 的形式, 这某种程度上衡量了估计量对应的分布函数和实际分布函数的损失 (loss/cost/error).

Example 2.11.(损失函数) 回顾**Example 2.5.**, 如果取单次 Bernoulli 试验, 而将样本数增加到 n 个, 可以求得似然函数

$$\ln L(p) = \sum_{i=1}^n (\ln C_n^{x_i} + x_i \ln p + (1-x_i) \ln(1-p)).$$

似然函数取最大值当且仅当负对数似然的平均

$$-\frac{1}{n} \sum_{i=1}^n (x_i \ln p + (1-x_i) \ln(1-p))$$

取最小值. 现在我们可以把 p 代入估计值 $\hat{p}$, 则负对数似然越小意味着 $\hat{p}$ 能够更好地拟合真实分布, 或者说上式刻画了某种程度上估计分布与实际分布的损失, 称为**二元交叉熵损失 (binary cross-entropy loss)**. 由于值的平移不会改变极值点, 也可以考虑减去信息熵

$$-\frac{1}{n} \sum_{i=1}^n (x_i \ln x_i + (1-x_i) \ln(1-x_i)),$$

得到

$$\frac{1}{n} \sum_{i=1}^n \left(x_i \ln \frac{x_i}{p} + (1-x_i) \ln \frac{1-x_i}{1-p} \right),$$

称为 **KL 散度 (Kullback-Leibler divergence)**.

2.3 一致最小方差无偏估计

2.3.1 无偏估计的改进

回顾**Definition 2.3.**中我们定义了均方损失,除了用 n 阶矩展开,样本发生的似然,当然也可以用均方误差刻画估计的有效程度.然而均方损失最小化是对全体函数空间求最小值点的泛函问题,而函数空间的大小可能超出所需的范围,因此我们希望在函数空间中某个性质较好的子集上最小化均方损失.

尽管我们希望在所有无偏估计中寻找最小值点,下例说明无偏估计并不总是存在的.

Example 2.12.(无偏估计的存在性) 再次回顾**Example 2.5.**,只给一个样本 $X \sim B(n, p)$. 这次我们考察统计量 $g(p) = \frac{1}{p}$ 的估计 $\hat{g}(X)$, 如果这是无偏估计, 则

$$\mathbb{E}(\hat{g}(X)) = \sum_{k=0}^n \hat{g}(k) \mathbb{P}(X = k) = \sum_{k=0}^n \hat{g}(k) C_n^k p^k (1-p)^{n-k} = g(p) = \frac{1}{p}.$$

然而多项式函数至多只有有限个零点,因此上式不可能对一切 $p \in (0, 1)$ 恒成立,因此 $g(p)$ 不存在无偏估计.

在存在无偏估计的估计问题中,可以在无偏估计中找均方误差最小,即有效性最好的估计.

Definition 2.6.(一致最小方差无偏估计) 设 $X_1, X_2, \dots, X_n$ 是总体 F_λ 中抽取的样本. 如果 $g(\lambda)$ 存在无偏估计, 则称为**可估函数 (estimable function)**. 设 $\hat{g}^*(\mathbf{X})$ 是 $g(\lambda)$ 的一个无偏估计, 如果对一切无偏估计 $\hat{g}(\mathbf{X})$, 对一切参数 $\lambda \in \Lambda$, 都有

$$\text{MSE}(\hat{g}^*(\mathbf{X})) = \mathbb{E}((\hat{g}^*(\mathbf{X}) - g(\lambda))^2) \leq \mathbb{E}((\hat{g}(\mathbf{X}) - g(\lambda))^2) = \text{MSE}(\hat{g}(\mathbf{X}))$$

恒成立, 也即

$$\text{Var}(\hat{g}^*(\mathbf{X})) \leq \text{Var}(\hat{g}(\mathbf{X})),$$

也即 $\hat{g}^*(\mathbf{X})$ 最有效, 则称 $\hat{g}^*(\mathbf{X})$ 是 $g(\lambda)$ 的**一致最小方差无偏估计 (uniformly minimum variance unbiased estimator, UMVUE)**.

如果已经存在无偏估计, 我们当然希望从这个无偏估计出发获得方差更小的无偏估计. 一个技巧是考虑条件期望. 我们先回顾条件期望的定义.

Definition 2.7.(条件期望) 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, X, Y 是两个随机变量. 定义 X 在条件 $Y = y$ 下的条件期望

$$\mathbb{E}(X | Y = y) = \int_{\mathbb{R}} x f_{X|Y}(x | y) dx = \int_{\mathbb{R}} x \frac{f_{X,Y}(x, y)}{f_Y(y)} dx.$$

则 $h(y) = \mathbb{E}(X | Y = y)$ 给出了一个实变函数, 其生成的随机变量 $h(Y) = \mathbb{E}(X | Y)$ 称为 X 关于 Y 的条件期望. 其分布为

$$\mathbb{P}(\mathbb{E}(X | Y) \leq t) = \mathbb{P}(\{\omega \in \Omega | \mathbb{E}(X | Y = Y(\omega)) \leq t\}).$$

特别地, 当 $Y = X$ 时可以计算联合密度函数

$$f_{X,X}(x, y) = \frac{\partial^2}{\partial x \partial y} F_{X,X}(x, y) = \frac{\partial^2}{\partial x \partial y} \mathbb{P}(X \leq x, X \leq y) = \frac{\partial^2}{\partial x \partial y} \mathbb{P}(X \leq \min\{x, y\}).$$

利用

$$\min\{x, y\} = \frac{x + y - |x - y|}{2}$$

上式可以求导

$$\frac{\partial^2}{\partial x \partial y} F_X \left(\frac{x + y - |x - y|}{2} \right) = \frac{\partial}{\partial x} \left(f_X \left(\frac{x + y - |x - y|}{2} \right) \frac{1 + \operatorname{sgn}(x - y)}{2} \right).$$

而 sgn 在 0 处导数为 Dirac 函数 $2\delta(0)$, 因此

$$f_{X,X}(x, y) = f'_X \left(\frac{x + y - |x - y|}{2} \right) \frac{1 - \operatorname{sgn}(x - y)^2}{4} + f_X \left(\frac{x + y - |x - y|}{2} \right) \delta(x - y).$$

当 $x \neq y$ 时第一项为 0, 而 $x = y$ 时第一项是有限数, 积分后为 0, 因此可以认为

$$f_{X,X}(x, y) = f_X(\min\{x, y\})\delta(x - y).$$

代入得

$$\mathbb{E}(X | X = y) = \int_{\mathbb{R}} x \frac{f_{X,X}(x, y)}{f_X(y)} dx = \int_{\mathbb{R}} x \frac{f_X(x)\delta(x - y)}{f_X(y)} dx = \int_{\mathbb{R}} x\delta(x - y)dx = y,$$

从而 $\mathbb{E}(X | X) = X$.

现在利用条件期望对无偏估计加以改造.

Example 2.13. (无偏估计的改进) 设 $X_1, X_2, \dots, X_n$ 是总体 F_λ 中抽取的样本. 如果已经存在 $g(\lambda)$ 的一个无偏估计 $\hat{g}(\mathbf{X})$, 任意选定一个随机变量 $T = T(\mathbf{X})$, 考察关于 T 的随机变量函数

$$h(T) = \mathbb{E}(\hat{g}(\mathbf{X}) | T).$$

其期望

$$\mathbb{E}(h(T)) = \int_{\mathbb{R}} h(t)f_T(t)dt = \int_{\mathbb{R}} \mathbb{E}(\hat{g}(\mathbf{X}) | T = t)f_T(t)dt,$$

展开得

$$\mathbb{E}(h(T)) = \int_{\mathbb{R}} \left(\int_{\mathbb{R}} x \frac{f_{\hat{g}(\mathbf{X}), T}(x, t)}{f_T(t)} dx \right) f_T(t)dt = \int_{\mathbb{R}^2} x f_{\hat{g}(\mathbf{X}), T}(x, t) dx dt = \mathbb{E}(\hat{g}(\mathbf{X})) = g(\lambda).$$

这就是说, 如果 $h(T)$ 是一个统计量, 则也是 $g(\lambda)$ 的一个无偏估计. 考虑方差

$$\text{Var}(\hat{g}(\mathbf{X})) = \mathbb{E} \left(((\hat{g}(\mathbf{X}) - h(T)) + (h(T) - g(\lambda)))^2 \right),$$

展开为

$$\mathbb{E} \left((\hat{g}(\mathbf{X}) - h(T))^2 \right) + \mathbb{E} \left((h(T) - g(\lambda))^2 \right) + 2\mathbb{E} \left((\hat{g}(\mathbf{X}) - h(T)) (h(T) - g(\lambda)) \right).$$

我们已经看到对条件期望求期望等于无条件期望

$$\mathbb{E} (\mathbb{E} (\hat{g}(\mathbf{X}) \mid T)) = \mathbb{E} (\hat{g}(\mathbf{X})),$$

同理可得

$$\begin{aligned} \mathbb{E} ((\hat{g}(\mathbf{X}) - h(T)) (h(T) - g(\lambda))) &= \mathbb{E} (\mathbb{E} ((\hat{g}(\mathbf{X}) - h(T)) (h(T) - g(\lambda)) \mid T)) \\ &= \mathbb{E} ((h(T) - g(\lambda)) \mathbb{E} (\hat{g}(\mathbf{X}) - h(T) \mid T)) \\ &= \mathbb{E} ((h(T) - g(\lambda)) (\mathbb{E} (\hat{g}(\mathbf{X}) \mid T) - h(T))) \end{aligned}$$

依照 $h(T)$ 的定义即得后一项为 0, 从而整体为 0, 于是

$$\text{Var}(\hat{g}(\mathbf{X})) = \mathbb{E} \left((\hat{g}(\mathbf{X}) - h(T))^2 \right) + \mathbb{E} \left((h(T) - g(\lambda))^2 \right).$$

第一项作为平方的期望当然为正, 于是

$$\text{Var}(\hat{g}(\mathbf{X})) \geq \mathbb{E} \left((h(T) - g(\lambda))^2 \right) = \text{Var}(h(T)).$$

这就是说, 如果 $h(T)$ 是一个统计量, 则也是 $g(\lambda)$ 的更有效的无偏估计.

注意以上讨论都有假设 $h(T)$ 是一个统计量, 这当然不是总成立的.

Example 2.14. (正态分布无偏估计的改进) 设 $X_1, X_2, \dots, X_n$ 是总体 $N(\mu, 1)$ 中抽取的简单样本. 则 $\bar{X}$ 和 X_1 都是 μ 的无偏估计. 考虑 $T = \bar{X}$, 则根据对称性

$$h(T) = \mathbb{E}(X_1 \mid \bar{X}) = \bar{X},$$

这确实是一个无偏估计, 且相较 X_1 的方差 1 而言, 有

$$\text{Var}(\bar{X}) = \frac{1}{n^2} \sum_{k=1}^n \text{Var}(X_k) = \frac{1}{n} \leq 1,$$

从而是一个合理的改进. 再考虑 $T = X_1$, 有

$$h(T) = \mathbb{E}(\bar{X} \mid X_1) = \frac{1}{n} \mathbb{E}(X_1 \mid X_1) + \frac{1}{n} \sum_{k=2}^n \mathbb{E}(X_k \mid X_1) = \frac{1}{n} X_1 + \frac{n-1}{n} \mu.$$

这里式中出现了待估计参数 μ , 也就不是估计, 当然无所谓无偏估计.

Example 2.15.(Bernoulli 分布无偏估计的改进) 设 $X_1, X_2, \dots, X_n$ 是总体 $B(1, p)$ 中抽取的简单样本. 则 X_1 都是 μ 的无偏估计. 考虑 $T = \bar{X}$, 则

$$h(T) = \mathbb{E}(X_1 | \bar{X}) = \mathbb{P}(X_1 = 1 | \bar{X}),$$

于是

$$h(t) = \mathbb{P}(X_1 = 1 | \bar{X} = t) = \frac{\mathbb{P}(X_1 = 1, \bar{X} = t)}{\mathbb{P}(\bar{X} = t)} = \frac{p C_{n-1}^{nt-1} p^{nt-1} (1-p)^{n-nt}}{C_n^{nt} p^{nt} (1-p)^{n-nt}} = t,$$

即 $h(T) = T = \bar{X}$.

2.3.2 充分统计量与完全统计量 *

一个重要的问题是什么时候上述 $h(T)$ 成为估计量.

Definition 2.8.(充分统计量) 设 $X_1, X_2, \dots, X_n$ 是总体 F_λ 中抽取的样本. 如果统计量 $T = T(\mathbf{X})$ 使得条件分布 $F_{\mathbf{X}|T}$ 与 λ 无关, 则称 T 是 λ 的**充分统计量** (sufficient statistics).

在充分统计量假设下, $h(T)$ 总是一个无偏估计.

Theorem 2.1.(Rao-Blackwell) 设 $X_1, X_2, \dots, X_n$ 是总体 F_λ 中抽取的简单样本, $T(\mathbf{X})$ 是充分统计量, $\hat{g}(\mathbf{X})$ 是 $g(\lambda)$ 的无偏估计, 则 $h(T) = \mathbb{E}(\hat{g}(\mathbf{X}) | T)$ 是 $g(\lambda)$ 的无偏估计, 且

$$\text{Var}(h(T)) \leq \text{Var}(\hat{g}(\mathbf{X}))$$

恒成立, 且取等当且仅当 $\hat{g}(\mathbf{X}) = h(T)$ 几乎处处成立.

Proof. 由于 $h(T) = \mathbb{E}(\hat{g}(\mathbf{X}) | T)$ 与 λ 无关, 从而是一个统计量, 进而是估计量. 同**Example 2.13.**的方法, 计算

$$\mathbb{E}(h(T)) = \int_{\mathbb{R}} h(t) f_T(t) dt = \int_{\mathbb{R}^2} x f_{\hat{g}(\mathbf{X}), T}(x, t) dx dt = \mathbb{E}(\hat{g}(\mathbf{X})) = g(\lambda),$$

从而是 $g(\lambda)$ 的一个无偏估计. 方差

$$\text{Var}(\hat{g}(\mathbf{X})) = \mathbb{E} \left(((\hat{g}(\mathbf{X}) - h(T)) + (h(T) - g(\lambda)))^2 \right),$$

且

$$\begin{aligned}\mathbb{E}((\hat{g}(\mathbf{X}) - h(T))(h(T) - g(\lambda))) &= \mathbb{E}(\mathbb{E}((\hat{g}(\mathbf{X}) - h(T))(h(T) - g(\lambda)) | T)) \\ &= \mathbb{E}((h(T) - g(\lambda)) \mathbb{E}(\hat{g}(\mathbf{X}) - h(T) | T)) \\ &= \mathbb{E}((h(T) - g(\lambda)) (\mathbb{E}(\hat{g}(\mathbf{X}) | T) - h(T)))\end{aligned}$$

于是

$$\text{Var}(\hat{g}(\mathbf{X})) = \mathbb{E}((\hat{g}(\mathbf{X}) - h(T))^2) + \mathbb{E}((h(T) - g(\lambda))^2) \geq \text{Var}(h(T)),$$

取等当且仅当

$$\mathbb{E}((\hat{g}(\mathbf{X}) - h(T))^2) = \int_{\mathbb{R}^n} (\hat{g}(\mathbf{x}) - h(T(\mathbf{x})))^2 d\mathbf{x} = 0,$$

当且仅当 $\hat{g}(\mathbf{X}) = h(T)$ 几乎处处成立. $\square$

Example 2.16. (Bernoulli 分布的充分统计量) 设 $X_1, X_2, \dots, X_n$ 是总体 $B(1, p)$ 中抽取的简单样本. 则对 $T = \sum_{k=1}^n X_k$, 条件分布

$$\mathbb{P}(X_k = x_k, 1 \leq k \leq n | T = t) = \frac{\mathbb{P}(X_k = x_k, 1 \leq k \leq n, T = t)}{\mathbb{P}(T = t)} = \frac{p^{\sum x_k} (1-p)^{n-\sum x_k}}{C_n^t p^t (1-p)^{n-t}}$$

仅当 $t = \sum x_k$ 时成立, 其他情况取 0. 进而计算得

$$\mathbb{P}(X_k = x_k, 1 \leq k \leq n | T = t) = \begin{cases} \frac{1}{C_n^t}, & t = \sum x_k, \\ 0, & \text{otherwise} \end{cases}$$

与 p 无关, 从而是充分统计量, 进而 $T = \bar{X}$ 也是充分统计量.

一般的求充分统计量的方法由以下定理给出.

Theorem 2.2. (Fisher-Neyman, 因子分解定理) 设 $X_1, X_2, \dots, X_n$ 是总体 F_λ 中抽取的简单样本, 分布函数 $f(\mathbf{x}, \lambda)$, $\mathbf{T} = \mathbf{T}(\mathbf{X})$ 是 $k \leq n$ 维统计量, 其中 $\mathbf{T}$ 可微且梯度非 0. 则 $\mathbf{T}$ 为充分统计量的充要条件是存在函数 g, h 使得密度函数

$$f_{\mathbf{X}}(\mathbf{x}, \lambda) = g(\mathbf{T}(\mathbf{x}), \lambda) h(\mathbf{x}).$$

Proof. 根据逆映射定理存在一一变换 $\mathbf{Y} = \varphi(\mathbf{X})$, 使得 $\mathbf{Y}$ 的前 k 项是 $\mathbf{T}$. 先证必要性, 假设 $\mathbf{T}$ 为充分统计量, 即条件密度 $f_{\mathbf{Y}}(\mathbf{y} | \mathbf{T} = \mathbf{t})$ 与 λ 无关, 于是根据条件密度公式可以写为

$$f_{\mathbf{Y}}(\mathbf{y}, \lambda) = f_{\mathbf{Y}}(\mathbf{y} | \mathbf{T} = \mathbf{t}) f_{\mathbf{T}}(\mathbf{t}, \lambda).$$

设逆变换 φ^{-1} 的 Jacobi 行列式为 J , 当然与 λ 无关, 则

$$f_{\mathbf{X}}(\mathbf{x}, \lambda) = f_{\mathbf{Y}}(\mathbf{y}, \lambda)J = f_{\mathbf{Y}}(\mathbf{y} \mid \mathbf{T} = \mathbf{t})Jf_{\mathbf{T}}(\mathbf{t}, \lambda).$$

取

$$h(\mathbf{x}) = f_{\mathbf{Y}}(\mathbf{y} \mid \mathbf{T} = \mathbf{t})J$$

两项均与 λ 无关, 而

$$g(\mathbf{T}(\mathbf{x}), \lambda) = f_{\mathbf{T}}(\mathbf{t}, \lambda) = \frac{\partial^k}{\partial t_1 \cdots \partial t_k} \mathbb{P}_{\lambda}(\mathbf{T}(\mathbf{X}) \leq \mathbf{t}),$$

这就说明因子分解存在. 再证充分性, 假设

$$f_{\mathbf{X}}(\mathbf{x}, \lambda) = g(\mathbf{T}(\mathbf{x}), \lambda)h(\mathbf{x}),$$

则同样有联合密度

$$f_{\mathbf{Y}}(\mathbf{y}, \lambda) = f_{\mathbf{X}}(\mathbf{x}, \lambda)K = g(\mathbf{T}(\mathbf{x}), \lambda)h(\mathbf{x})K = g(\mathbf{T}(\mathbf{x}), \lambda)h(\varphi^{-1}(\mathbf{y}))K,$$

其中 K 是 φ 的 Jacobi 行列式. 后两项当然与 λ 无关, 为求 $\mathbf{T}$ 的密度函数只要做积分

$$f_{\mathbf{T}}(\mathbf{t}, \lambda) = \int_{\mathbb{R}^{n-k}} f_{\mathbf{Y}}(\mathbf{y}, \lambda) dy_{k+1} \cdots dy_n = g(\mathbf{T}(\mathbf{x}), \lambda) \int_{\mathbb{R}^{n-k}} h(\varphi^{-1}(\mathbf{y}))K dy_{k+1} \cdots dy_n.$$

于是条件密度

$$f_{\mathbf{Y}}(\mathbf{y} \mid \mathbf{T} = \mathbf{t}) = \frac{f_{\mathbf{Y}}(\mathbf{y}, \lambda)}{f_{\mathbf{T}}(\mathbf{t}, \lambda)} = h(\varphi^{-1}(\mathbf{y}))K \left(\int_{\mathbb{R}^{n-k}} h(\varphi^{-1}(\mathbf{y}))K dy_{k+1} \cdots dy_n \right)^{-1}$$

各项均与 λ 无关, 因此 $\mathbf{T}$ 是充分统计量. □

作为例子, 我们可以给出一些分布的充分统计量.

Example 2.17. (正态分布的充分统计量) 设 $X_1, X_2, \dots, X_n$ 是总体 $N(\mu, \sigma^2)$ 中抽取的简单样本, 则密度函数

$$f(\mathbf{x}, \mu, \sigma) = (2\pi)^{-\frac{n}{2}} \sigma^{-n} \exp \left(-\frac{1}{2\sigma^2} \left(\sum_{k=1}^n x_k^2 - 2\mu \sum_{k=1}^n x_k + n\mu^2 \right) \right),$$

根据因子分解定理取充分统计量

$$T_1(\mathbf{X}) = \sum_{k=1}^n X_k^2, \quad T_2(\mathbf{X}) = \sum_{k=1}^n X_k.$$

当然也可以取 $\bar{X}$ 和 S^2 .

Example 2.18. (均匀分布的充分统计量) 设 $X_1, X_2, \dots, X_n$ 是总体 $U(0, \theta)$ 中抽取的简单样本, 则密度函数

$$f(\mathbf{x}, \theta) = \frac{1}{\theta^n} I_{(0, \theta)}(x_{(n)}),$$

最后的 $x_{(n)}$ 表示最大值, 当然有一个值从而最大值超过 θ 的概率密度为 0. 根据因子分解定理可以取充分统计量 $T = X_{(n)}$.

任意给定了一个充分统计量, 都可以由此方法改进一个无偏估计. 然而, 剩余的问题是, 原始无偏估计和充分统计量有多种选取, 哪一种能得到最有效的无偏估计?

Theorem 2.2. 说明充分统计量可由因子分解求得, 这样求得的充分统计量 (相差一个变换意义下) 是唯一的. 现在我们考虑什么时候得到的改进与初始无偏估计的选取无关.

Definition 2.9. (完全统计量) 设 $X_1, X_2, \dots, X_n$ 是总体 F_λ 中抽取的样本. 如果统计量 $T = T(\mathbf{X})$ 使得对任意实函数 ψ 满足

$$\mathbb{E}(\psi(T)) = 0$$

对一切 λ 恒成立, 都有

$$\mathbb{P}(\psi(T) = 0) = 1,$$

即 $\psi(T) = 0$ 几乎处处成立, 对一切 λ 恒成立, 则称 T 是 λ 的**完全统计量** (complete statistics).

从泛函分析的角度看, $\mathbb{E}(\psi(T)) = 0$ 即

$$\int_{\mathbb{R}} \psi(t) dF_T(t; \lambda) = \int_{\mathbb{R}} \psi(t) f_T(t; \lambda) dt = 0$$

对一切 λ 恒成立, 这相当于说函数族 $\{f_T(t; \lambda)\}$ 与 ψ 正交, 推出的结果相当于说 ψ 在相差一个零测集的意义下是零函数, 即不存在非零函数 ψ 与 $\{f_T(t; \lambda)\}$ 都正交, 也即 $\{f_T(t; \lambda)\}$ 构成函数空间的一族生成元, 这就是完备性的定义.

如果 T 是一个完全统计量, 那么任意两个无偏估计 $\hat{g}_1(\mathbf{X})$ 和 $\hat{g}_2(\mathbf{X})$ 加以改进后得到 $h_1(T)$ 和 $h_2(T)$ 作为无偏估计当然满足

$$\mathbb{E}((h_1 - h_2)(T)) = 0,$$

于是根据完全统计量的定义 h_1 和 h_2 至多在一个零测集上不同, 即不同无偏估计改进后几乎处处相同.

Example 2.19. (Bernoulli 分布的完全统计量) 设 $X_1, X_2, \dots, X_n$ 是总体 $B(1, p)$ 中抽取的简单样本. 则对 $T = \sum_{k=1}^n X_k$, 如果对一切 $0 < p < 1$, 都有 $\psi(T)$ 的期望为 0, 即

$$\mathbb{E}(\psi(T)) = \sum_{k=0}^n \psi(k) \mathbb{P}(\psi(T) = k) = \sum_{k=0}^n \psi(k) C_n^k p^k (1-p)^{n-k} = 0$$

对 $p \in (0, 1)$ 恒成立, 则 n 次多项式有多于 n 个零点必为零多项式, 进而系数 $\psi(k) = 0$, 即 $\psi(T) = 0$ 恒成立, 于是 T 是完全统计量.

Example 2.20. (均匀分布的完全统计量) 设 $X_1, X_2, \dots, X_n$ 是总体 $U(0, \theta)$ 中抽取的简单样本. 则根据 **Example 1.9**, $T = X_{(n)}$ 的密度函数为

$$f(x) = \frac{nx^{n-1}}{\theta^n} I_{(0, \theta)}(x).$$

如果对一切 $\theta > 0$, 都有 $\psi(T)$ 的期望为 0, 即

$$\mathbb{E}(\psi(T)) = \frac{n}{\theta^n} \int_0^\theta \psi(t) t^{n-1} dt = 0$$

对 $\theta > 0$ 恒成立, 则对 θ 求导得

$$\psi(\theta) \theta^{n-1} = 0$$

恒成立, 进而系数 $\psi(\theta) = 0$, 即 $\psi(T) = 0$ 恒成立, 于是 T 是完全统计量.

一般的求完全统计量的方法由以下定理给出.

Theorem 2.3. (指数族的完全统计量) 设 $X_1, X_2, \dots, X_n$ 是总体 F_λ 中抽取的简单样本, λ 有 $k \leq n$ 个分量, $\mathbf{T} = \mathbf{T}(\mathbf{X})$ 是 k 维统计量, 且 $\mathbf{T}$ 是可逆向量函数. 如果联合分布

$$f_{\mathbf{X}}(\mathbf{x}, \lambda) = C(\lambda) \exp \left(\sum_{j=1}^n \lambda_j T_j(\mathbf{x}) \right) h(\mathbf{x}),$$

且 λ 的全体构成的参数空间有内点, 则 $\mathbf{T}(\mathbf{X})$ 是完全统计量.

Proof. 先求 $\mathbf{T}$ 的分布函数. 依照定义

$$\mathbb{P}_\lambda(\mathbf{T}(\mathbf{X}) \leq \mathbf{t}) = \mathbb{P}_\lambda(\mathbf{X} \in \mathbf{T}^{-1}((-\infty, \mathbf{t}))) = \int_{\mathbf{T}^{-1}((-\infty, \mathbf{t}))} f_{\mathbf{X}}(\mathbf{x}, \lambda) d\mathbf{x}.$$

代入得

$$C(\lambda) \int_{\mathbf{T}^{-1}((-\infty, \mathbf{t}))} \exp \left(\sum_{j=1}^n \lambda_j T_j(\mathbf{x}) \right) h(\mathbf{x}) d\mathbf{x} = C(\lambda) \int_{-\infty}^{\mathbf{t}} \exp \left(\sum_{j=1}^k \lambda_j t_j \right) h^*(\mathbf{t}) d\mathbf{t}.$$

于是

$$f_{\mathbf{T}}(\mathbf{t}, \lambda) = C(\lambda) \exp \left(\sum_{j=1}^k \lambda_j t_j \right) h^*(\mathbf{t}).$$

不妨设内点是 $\lambda = 0$, 否则只需做一个平移. 任意函数 ψ 使得

$$\mathbb{E}(\psi(\mathbf{T})) = \int_{\mathbb{R}} \psi(\mathbf{t}) C(\lambda) \exp \left(\sum_{j=1}^k \lambda_j t_j \right) h^*(\mathbf{t}) d\mathbf{t} = 0,$$

将 ψ 分解为 $\psi^+ - \psi^-$, 则有

$$\int_{\mathbb{R}} \psi^+(\mathbf{t}) \exp\left(\sum_{j=1}^k \lambda_j t_j\right) h^*(\mathbf{t}) d\mathbf{t} = \int_{\mathbb{R}} \psi^-(\mathbf{t}) \exp\left(\sum_{j=1}^k \lambda_j t_j\right) h^*(\mathbf{t}) d\mathbf{t}.$$

现在由于 λ 是内点, 在某邻域内复解析, 进而在某邻域中的任意一点 $\lambda_j = u_j + i v_j$ 的虚部 $v_j \in \mathbb{R}$ 都有

$$\int_{\mathbb{R}} \psi^+(\mathbf{t}) \exp\left(i \sum_{j=1}^k v_j t_j\right) h^*(\mathbf{t}) d\mathbf{t} = \int_{\mathbb{R}} \psi^-(\mathbf{t}) \exp\left(i \sum_{j=1}^k v_j t_j\right) h^*(\mathbf{t}) d\mathbf{t}.$$

依照可积性

$$\psi^+(\mathbf{t}) h^*(\mathbf{t}) d\mathbf{t} = d\mathbf{u}^+, \quad \psi^-(\mathbf{t}) h^*(\mathbf{t}) d\mathbf{t} = d\mathbf{u}^-,$$

则上式变为 $\mathbf{u}^+$ 和 $\mathbf{u}^-$ 的特征函数, 从而特征函数相等导致分布函数几乎处处相等, 即 $\psi = \psi^+ - \psi^- = 0$ 几乎处处成立, 这就说明 $\mathbf{T}$ 是完全统计量. $\square$

注意到常见分布都是指数族的形式, 可以写出其充分统计量.

Example 2.21. (若干分布的充分完全统计量) 指数分布的密度函数

$$f(\mathbf{x}, \lambda) = \lambda^n \exp\left(-\lambda \sum_{k=1}^n x_k\right)$$

是指数族, 从而

$$T(\mathbf{X}) = \sum_{k=1}^n X_k$$

是完全统计量. 同样道理, Poisson 分布也以这个形式的 T 为完全统计量. 正态分布的密度函数

$$f(\mathbf{x}, \mu, \sigma) = (2\pi)^{-\frac{n}{2}} \sigma^{-n} \exp\left(-\frac{\mu^2}{2\sigma^2}\right) \exp\left(-\frac{1}{2\sigma^2} \left(\sum_{k=1}^n x_k^2 - 2\mu \sum_{k=1}^n x_k\right)\right).$$

是指数族, 从而

$$T_1(\mathbf{X}) = \sum_{k=1}^n X_k^2, \quad T_2(\mathbf{X}) = \sum_{k=1}^n X_k$$

是完全统计量. 事实上, 根据因子分解定理, 这些也是充分统计量.

2.3.3 一致最小方差无偏估计的存在性

借助充分统计量和完全统计量的概念, 我们可以给出一致最小方差无偏估计存在的充分条件.

Theorem 2.4.(Lehmann-Scheffe) 设 $X_1, X_2, \dots, X_n$ 是总体 F_λ 中抽取的简单样本, $g(\lambda)$ 为可估函数, $T = T(\mathbf{X})$ 为充分完全统计量. 若 $\hat{g}(T)$ 是 $g(\lambda)$ 的无偏估计, 则是其一致最小方差无偏估计, 且在相差一个零测集的意义下唯一.

Proof. 设 $\varphi(\mathbf{X})$ 是任意 $g(\lambda)$ 的无偏估计, 考虑

$$h(T) = \mathbb{E}(\varphi(\mathbf{X}) \mid T).$$

由于 T 是充分统计量, $h(T)$ 与 λ 无关, 从而是统计量. 根据 **Example 2.13.** 的结果, $h(T)$ 也是 $g(\lambda)$ 的无偏估计, 且方差

$$\text{Var}(h(T(\mathbf{X}))) \leq \text{Var}(\varphi(\mathbf{X})).$$

注意到 T 是完全统计量, 且

$$\mathbb{E}(\hat{g}(T(\mathbf{X})) - h(T(\mathbf{X}))) = \mathbb{E}(\hat{g}(T(\mathbf{X}))) - \mathbb{E}(h(T(\mathbf{X}))) = g(\lambda) - g(\lambda) = 0,$$

依照定义可知 $\hat{g}(T(\mathbf{X}))$ 与 $h(T(\mathbf{X}))$ 至多相差一个零测集. 立即得到

$$\text{Var}(\hat{g}(T(\mathbf{X}))) = \text{Var}(h(T(\mathbf{X}))) \leq \text{Var}(\varphi(\mathbf{X})),$$

这就说明 $\hat{g}(T(\mathbf{X}))$ 确实是一致最小方差无偏估计. 再次重复上述讨论, 另有一致最小方差无偏估计与之差的期望为 0, 从而根据完全统计量的定义至多相差一个零测集. $\square$

这个定理给出了求一致最小方差无偏估计的通用方法. 作为例子, 我们看以下分布族的一致最小方差无偏估计.

Example 2.22.(Bernoulli 分布的 UMVUE) 设 $X_1, X_2, \dots, X_n$ 是总体 $B(1, p)$ 中抽取的简单样本. 则根据 **Example 2.16.** 和 **Example 2.19.** 可知 $T(\mathbf{X}) = \bar{X}$ 是充分完全统计量, 且期望 $\mathbb{E}(T(\mathbf{X})) = p$, 于是 **Theorem 2.4.** 这就是 p 的一致最小方差无偏估计. 当然也可以通过 **Example 2.15.** 的改进得到这个无偏估计.

现在考虑 $g(p) = p(1 - p)$, 已经知道 $\bar{X}$ 是充分完全统计量, 且注意到

$$p(1 - p) = \mathbb{E}(X_1(1 - X_2)),$$

则作改进

$$h(T) = \mathbb{E}(X_1(1 - X_2) \mid T) = \frac{1}{n}T + \frac{1}{n(n-1)}T(T-1) = \frac{1}{n-1}T + \frac{1}{n(n-1)}T^2.$$

根据 **Theorem 2.4.** 可知这是 $g(\lambda)$ 的一致最小方差无偏估计.

Example 2.23. (Poisson 分布的 UMVUE) 设 $X_1, X_2, \dots, X_n$ 是总体 $\text{Poi}(\lambda)$ 中抽取的简单样本. 根据 **Example 2.21.** 的结果, $T(\mathbf{X}) = \bar{X}$ 是充分完全统计量. 根据 $\mathbb{E}(\bar{X}) = \lambda$ 和 **Theorem 2.4.** 可知 T 是 λ 的一致最小方差无偏估计.

现在求 λ^r 的一致最小方差无偏估计. 记 $S = n\bar{X}$, 假设 $h(S)$ 是所需的估计, 则根据无偏性必须

$$\sum_{i=0}^{\infty} h(i) \frac{(n\lambda)^i}{i!} e^{-n\lambda} = \lambda^r$$

对一切 $\lambda > 0$ 恒成立. 作展开

$$\sum_{i=0}^{\infty} h(i) \frac{(n\lambda)^i}{i!} = \lambda^r e^{n\lambda} = \sum_{j=r}^{\infty} \frac{n^{j-r} \lambda^j}{(j-r)!}.$$

由于对 $\lambda > 0$, 各项系数必须相等, 于是

$$h(S) = \begin{cases} \frac{1}{n^r} S(S-1) \cdots (S-r+1), & S = r, r+1, \dots, \\ 0, & \text{otherwise} \end{cases}$$

就是所要的 λ^r 的一致最小方差无偏估计. 特别地取 $r = 1$ 就能看出 $\frac{1}{n}S = T$ 是 λ 的一致最小方差无偏估计.

Example 2.24. (指数分布的 UMVUE) 设 $X_1, X_2, \dots, X_n$ 是总体 $\text{Exp}(\lambda)$ 中抽取的简单样本. 根据 **Example 2.21.** 的结果, $T(\mathbf{X}) = n\bar{X}$ 是充分完全统计量. 我们知道指数分布 $2\lambda X_k$ 服从自由度为 2 的 χ^2 分布, 于是和 $2\lambda T$ 服从自由度为 $2n$ 的 χ^2 分布, 因此根据 **Theorem 1.3** 可得

$$\mathbb{E}\left(\frac{1}{2\lambda T}\right) = 2^{-1} \frac{\Gamma(n-1)}{\Gamma(n)} = \frac{1}{2(n-1)} \implies \mathbb{E}\left(\frac{1}{T}\right) = \frac{\lambda}{n-1}.$$

于是 $\frac{n-1}{T}$ 是 λ 的一致最小方差无偏估计.

再考虑 $h(T)$ 是 $e^{-\lambda x_0}$ 的无偏估计, 则利用 $2\lambda T$ 服从 χ_{2n}^2 , 可知 $2\lambda T$ 的分布

$$f(x) = \begin{cases} \frac{1}{2^n \Gamma(n)} x^{n-1} e^{-\frac{x}{2}}, & x > 0, \\ 0, & x \leq 0. \end{cases}$$

于是

$$\mathbb{E}(h(T)) = \int_0^{+\infty} h\left(\frac{t}{2\lambda}\right) \frac{1}{2^n \Gamma(n)} t^{n-1} e^{-\frac{t}{2}} dt = \int_0^{+\infty} h(u) \frac{\lambda^n}{\Gamma(n)} u^{n-1} e^{-\lambda u} du.$$

根据无偏性必须有

$$\int_0^{+\infty} h(u) \frac{\lambda^n}{\Gamma(n)} u^{n-1} e^{-\lambda(u-x_0)} du = 1.$$

如果取

$$h(t) = \frac{(t - x_0)^{n-1}}{t^{n-1}} I_{(x_0, +\infty)}(t)$$

被积函数就成为平移 x_0 的 Gamma 分布的密度函数, 而

$$h(T) = \frac{(T - x_0)^{n-1}}{T^{n-1}} I_{(x_0, +\infty)}(T)$$

又是充分完全统计量 T 的函数, 于是根据 **Theorem 2.4**, T 就是 $e^{-\lambda x_0}$ 的一致最小方差无偏估计.

Example 2.25. (均匀分布的 UMVUE) 设 $X_1, X_2, \dots, X_n$ 是总体 $U(1, \lambda)$ 中抽取的简单样本. 根据 **Example 2.18** 和 **Example 2.20**, 可知 $T(\mathbf{X}) = X_{(n)}$ 是充分完全统计量. 根据 **Example 2.3**, 可知 θ 有无偏估计 $\frac{n+1}{n} X_{(n)}$, 根据 **Theorem 2.4**, 可知这就是 θ 的一致最小方差无偏估计.

由此我们归纳一般的计算 UMVUE 的方法: 通过因子分解定理找到充分统计量, 利用 **Theorem 2.4** 或 **Definition 2.9**, 证明这是完全统计量, 写出这个统计量 T 的分布函数, 再通过 T 的函数期望 $\mathbb{E}(h(T))$ 凑出待估计参数 $g(\lambda)$ 即可.

以下定理给出了一致最小方差无偏估计存在的充要条件.

Theorem 2.5. (零无偏估计) 设 $X_1, X_2, \dots, X_n$ 是总体 F_λ 中抽取的简单样本, $\hat{g}(\mathbf{X})$ 是 $g(\lambda)$ 的一个无偏估计, 且其方差有限. 则 $\hat{g}(\mathbf{X})$ 是 $g(\lambda)$ 的一致最小方差无偏估计的充要条件为任意期望为 0 的统计量 $I(\mathbf{X})$ 和一切 λ 都有

$$\text{Cov}(\hat{g}(\mathbf{X}), I(\mathbf{X})) = \mathbb{E}(\hat{g}(\mathbf{X})I(\mathbf{X})) = 0.$$

Proof. 先证充分性. 对任意无偏估计 $\varphi(\mathbf{X})$, 取

$$I(\mathbf{X}) = \varphi(\mathbf{X}) - \hat{g}(\mathbf{X}) \implies \mathbb{E}(I(\mathbf{X})) = g(\lambda) - g(\lambda) = 0.$$

于是有展开

$$\text{Var}(\varphi(\mathbf{X})) = \text{Var}(\hat{g}(\mathbf{X}) + I(\mathbf{X})) = \text{Var}(\hat{g}(\mathbf{X})) + \text{Var}(I(\mathbf{X})) + 2 \text{Cov}(\hat{g}(\mathbf{X}), I(\mathbf{X})).$$

协方差为 0, 于是

$$\text{Var}(\varphi(\mathbf{X})) \geq \text{Var}(\hat{g}(\mathbf{X})),$$

这就是说 $\hat{g}(\mathbf{X})$ 是 $g(\lambda)$ 的一致最小方差无偏估计.

再证必要性. 任取统计量 $I(\mathbf{X})$ 使得 $\mathbb{E}(I(\mathbf{X})) = 0$, 则

$$\text{Cov}(\hat{g}(\mathbf{X}), I(\mathbf{X})) = \mathbb{E}((\hat{g}(\mathbf{X}) - g(\lambda))I(\mathbf{X})) = \mathbb{E}(\hat{g}(\mathbf{X})I(\mathbf{X})).$$

如果 $\text{Var}(I(\mathbf{X})) = 0$, 根据协方差的定义或相关系数的范围 $[-1, 1]$ 易知

$$\text{Cov}(\hat{g}(\mathbf{X}), I(\mathbf{X}))^2 \leq \text{Var}(\hat{g}(\mathbf{X})) \text{Var}(I(\mathbf{X})) = 0,$$

因此

$$\text{Cov}(\hat{g}(\mathbf{X}), I(\mathbf{X})) = \mathbb{E}(\hat{g}(\mathbf{X})I(\mathbf{X})) = 0.$$

如果 $\text{Var}(I(\mathbf{X})) > 0$, 考虑

$$h_t(\mathbf{X}) = \hat{g}(\mathbf{X}) + tI(\mathbf{X}),$$

则

$$\text{Var}(h_t(\mathbf{X})) = \text{Var}(\hat{g}(\mathbf{X})) + 2t \text{Cov}(\hat{g}(\mathbf{X}), I(\mathbf{X})) + t^2 \text{Var}(I(\mathbf{X})).$$

进一步配方

$$\text{Var}(\hat{g}(\mathbf{X})) + \text{Var}(I(\mathbf{X})) \left(t + \frac{\text{Cov}(\hat{g}(\mathbf{X}), I(\mathbf{X}))}{\text{Var}(I(\mathbf{X}))} \right)^2 - \frac{\text{Cov}(\hat{g}(\mathbf{X}), I(\mathbf{X}))^2}{\text{Var}(I(\mathbf{X}))},$$

只要取

$$t = -\frac{\text{Cov}(\hat{g}(\mathbf{X}), I(\mathbf{X}))}{\text{Var}(I(\mathbf{X}))} \implies \text{Var}(h_t(\mathbf{X})) = \text{Var}(\hat{g}(\mathbf{X})) - \frac{\text{Cov}(\hat{g}(\mathbf{X}), I(\mathbf{X}))^2}{\text{Var}(I(\mathbf{X}))}.$$

注意到 $\hat{g}(\mathbf{X})$ 是 $g(\lambda)$ 的一致最小方差无偏估计, 当然有上式不小于 $\text{Var}(\hat{g}(\mathbf{X}))$, 这就说明

$$\text{Cov}(\hat{g}(\mathbf{X}), I(\mathbf{X})) = \mathbb{E}(\hat{g}(\mathbf{X})I(\mathbf{X})) = 0.$$

□

2.3.4 Cramer-Rao 不等式

除了通过无偏估计的改进逐步得到一致最小方差无偏估计, 如果能够找到一个下界, 以及恰好取到这个下界的无偏估计, 那么这当然就是一致最小方差无偏估计.

如果能够找到一个下界, 那么逼近这个下界可以催生出更好的估计方法, 或者可以找到接近下界但高效的估计方法.

我们的估计目标是方差

$$\text{Var}(\hat{g}(\mathbf{x})) = \int_{\mathbb{R}^n} (\hat{g}(\mathbf{x}) - g(\lambda))^2 f(\mathbf{x}, \lambda) d\mathbf{x},$$

而条件是无偏估计

$$\mathbb{E}(\hat{g}(\mathbf{x})) = \int_{\mathbb{R}^n} \hat{g}(\mathbf{x}) f(\mathbf{x}, \lambda) d\mathbf{x} = g(\lambda).$$

一个合理的想法是使用积分的 Cauchy-Schwarz 不等式. 为此需要构造一个适当的辅助函数, 这个函数应当具有很好的性质. 我们引入如下定义.

Definition 2.10.(Cramer-Rao 正则分布族与 Fisher 信息量) 设 $\{F_\lambda\}$ 是单参数分布族, 参数空间是某个开区间 $U \subseteq \mathbb{R}$. 如果密度函数存在且满足 $f_\lambda > 0$ 的集合相同, 同时以下偏导数存在且

$$\frac{\partial}{\partial \lambda} \int_{\mathbb{R}} f_\lambda(x) dx = \frac{\partial F_\lambda(x)}{\partial \lambda} = \int_{\mathbb{R}} \frac{\partial f_\lambda(x)}{\partial \lambda} dx,$$

以及以下期望存在且

$$0 < I(\lambda) = \mathbb{E} \left(\left(\frac{\partial \ln f_\lambda(X)}{\partial \lambda} \right)^2 \right) < \infty,$$

则称该分布族为 Cramer-Rao 正则分布族. $I(\lambda)$ 称为分布 F_λ 的 Fisher 信息量.

在这个条件下, 可以给出方差下界的估计. 这个估计未必是可以达到的.

Theorem 2.6.(Cramer-Rao 不等式) 设 $\{F_\lambda\}$ 是 Cramer-Rao 正则分布族, $g(\lambda)$ 是可微函数, $X_1, X_2, \dots, X_n$ 是总体 F_λ 中抽取的简单样本, $I(\lambda)$ 是其 Fisher 信息量, $\hat{g}(\mathbf{X})$ 是其无偏估计, 使得

$$\frac{\partial}{\partial \lambda} \int_{\mathbb{R}^n} \hat{g}(\mathbf{x}) f_\lambda(\mathbf{x}) d\mathbf{x} = \int_{\mathbb{R}^n} \hat{g}(\mathbf{x}) \frac{\partial f_\lambda(\mathbf{x})}{\partial \lambda} d\mathbf{x}.$$

则有

$$\text{Var}(\hat{g}(\mathbf{X})) \geq \frac{g'(\lambda)^2}{nI(\lambda)}.$$

Proof. 定义

$$S_\lambda(\mathbf{x}) = \frac{\partial \ln f_\lambda(\mathbf{x})}{\partial \lambda} = \sum_{k=1}^n \frac{\partial \ln f_\lambda(x_k)}{\partial \lambda}.$$

则由正则条件

$$\mathbb{E}(S_\lambda(\mathbf{X})) = \sum_{k=1}^n \int_{\mathbb{R}} \frac{\partial \ln f_\lambda(x_k)}{\partial \lambda} f_\lambda(x_k) dx_k = n \frac{\partial}{\partial \lambda} \int_{\mathbb{R}} f_\lambda(x) dx = 0.$$

注意这里表明每项都有 0 的期望. 于是

$$\text{Cov}(\hat{g}(\mathbf{X}), S_\lambda(\mathbf{X})) = \mathbb{E}(\hat{g}(\mathbf{X}) S_\lambda(\mathbf{X})) - g(\lambda) \mathbb{E}(S_\lambda(\mathbf{X})) = \mathbb{E}(\hat{g}(\mathbf{X}) S_\lambda(\mathbf{X})).$$

进一步展开为

$$\int_{\mathbb{R}^n} \hat{g}(\mathbf{x}) \frac{\partial f_\lambda(\mathbf{x})}{\partial \lambda} d\mathbf{x} = \frac{\partial}{\partial \lambda} \int_{\mathbb{R}^n} \hat{g}(\mathbf{x}) f_\lambda(\mathbf{x}) d\mathbf{x} = \frac{\partial}{\partial \lambda} \mathbb{E}(\hat{g}(\mathbf{X})) = g'(\lambda).$$

另一方面有

$$\text{Var}(S_\lambda(\mathbf{X})) = \sum_{k=1}^n \text{Var} \left(\frac{\partial \ln f_\lambda(X_k)}{\partial \lambda} \right) = \sum_{k=1}^n \mathbb{E} \left(\left(\frac{\partial \ln f_\lambda(X_k)}{\partial \lambda} \right)^2 \right) = nI(\lambda).$$

根据 Cauchy-Schwarz 不等式或相关系数的范围 $[-1, 1]$

$$\text{Var}(\hat{g}(\mathbf{X})) \text{Var}(S_\lambda(\mathbf{X})) \geq \text{Cov}(\hat{g}(\mathbf{X}), S_\lambda(\mathbf{X}))^2 = g'(\lambda)^2,$$

代入即证. $\square$

我们可以检验之前求得的 UMVUE 是否达到这个下界.

Example 2.25. (若干 UMVUE 的 Cramer-Rao 等式) 根据指数族的性质可知以下都满足 Cramer-Rao 正则条件.

根据 **Example 2.22.** Bernoulli 分布 $B(1, p)$ 的参数 p 有估计 $\bar{X}$. 计算 Fisher 信息量

$$I(p) = \mathbb{E} \left(\left(\frac{\partial}{\partial p} (X \ln p + (1 - X) \ln(1 - p)) \right)^2 \right) = \mathbb{E} \left(\frac{(X - p)^2}{p^2(1 - p)^2} \right) = \frac{1}{p(1 - p)}.$$

于是根据 **Theorem 2.6.** 有估计

$$\text{Var}(\bar{X}) \geq \frac{1}{nI(\lambda)} = \frac{p(1 - p)}{n}.$$

当然有

$$\text{Var}(\bar{X}) = \frac{1}{n} \text{Var}(X) = \frac{p(1 - p)}{n}.$$

于是这确实是 p 的一致最小方差无偏估计.

根据 **Example 2.23.** Poisson 分布 $\text{Poi}(\lambda)$ 的参数 λ 有估计 $\bar{X}$. 计算 Fisher 信息量

$$I(\lambda) = \mathbb{E} \left(\left(\frac{\partial}{\partial \lambda} (-\lambda + X \ln \lambda - \ln X!) \right)^2 \right) = \mathbb{E} \left(\frac{(X - \lambda)^2}{\lambda^2} \right) = \frac{1}{\lambda}.$$

于是下界为 $\frac{\lambda}{n}$, 当然也是 $\bar{X}$ 的方差.

根据 **Example 2.24.** 指数分布 $\text{Poi}(\lambda)$ 的参数 $\frac{1}{\lambda}$ 有估计 $\bar{X}$. 计算 Fisher 信息量

$$I(\lambda) = \mathbb{E} \left(\left(\frac{\partial}{\partial \lambda} (\ln \lambda - \lambda X) \right)^2 \right) = \mathbb{E} \left(\left(\frac{1}{\lambda} - X \right)^2 \right) = \frac{1}{\lambda^2}.$$

于是下界为 $\frac{1}{n\lambda^2}$, 当然也是 $\bar{X}$ 的方差.

最后考虑正态分布 $N(\mu, \sigma^2)$, $\bar{X}$ 当然是 μ 的无偏估计, 其方差为 $\frac{\sigma^2}{n}$. 为证这是 μ 的一致最小方差无偏估计, 计算 Fisher 信息量

$$I(\mu) = \mathbb{E} \left(\left(\frac{\partial}{\partial \mu} \left(-\frac{1}{2\sigma^2} (X - \mu)^2 \right) \right)^2 \right) = \mathbb{E} \left(\frac{(X - \mu)^2}{\sigma^4} \right) = \frac{1}{\sigma^2},$$

于是下界

$$\frac{1}{nI(\mu)} = \frac{\sigma^2}{n}$$

恰好与 $\bar{X}$ 的方差相等, 这就完成了证明.

2.4 再论极大似然估计 *

在讨论了充分完全统计量之后, 再回顾极大似然估计, 我们将发现其拥有很多好的性质.

Theorem 2.7.(极大似然估计的充分完全性) 设 $X_1, X_2, \dots, X_n$ 是总体 F_λ 中抽取的简单样本, λ 的极大似然估计 $\hat{\lambda}$ 存在唯一, 则 $\hat{\lambda}$ 是任意一组充分统计量的函数. 如果总体是指数族形式, 即

$$f_{\mathbf{x}}(\mathbf{x}, \lambda) = C(\lambda) \exp \left(\sum_{j=1}^n \lambda_j T_j(\mathbf{x}) \right) h(\mathbf{x}),$$

则 $\hat{\lambda}$ 是任意一组完全统计量的函数.

Proof. 设 T 是一个充分统计量, 则根据因子分解定理 **Theorem 2.2.**, 似然函数

$$L(\lambda) = \prod_{k=1}^n f_\lambda(x_k) = g(\mathbf{T}(\mathbf{x}), \lambda) h(\mathbf{x}),$$

其中 $h(\mathbf{x})$ 与 λ 无关. 由于极大似然估计唯一存在, 则使上式达到最大值的点唯一存在, 即优化问题

$$\max_{\lambda \in \Lambda} \{g(\mathbf{T}(\mathbf{x}), \lambda)\}$$

有唯一解 $\lambda = \hat{\lambda}$, 这当然由 T 唯一确定, 因此 $\hat{\lambda}$ 由 $\mathbf{T}$ 决定.

如果总体是指数族形式, 类似地有

$$L(\lambda) = C(\lambda) \exp \left(\sum_{j=1}^n \lambda_j T_j(\mathbf{x}) \right) h(\mathbf{x}),$$

于是优化问题

$$\max_{\lambda \in \Lambda} \left\{ C(\lambda) \exp \left(\sum_{j=1}^n \lambda_j T_j(\mathbf{x}) \right) \right\}$$

存在唯一解 $\lambda = \hat{\lambda}$ 由 $\mathbf{T}$ 唯一决定. □

如果我们把似然函数视作优化问题

$$\max_{\lambda \in \Lambda} \left\{ \frac{1}{n} \sum_{k=1}^n \ln f_\lambda(x_k) \right\},$$

当 n 充分大时, 在一定条件下根据大数定律优化问题依概率收敛到

$$\max_{\lambda \in \Lambda} \{ \mathbb{E}(\ln f_\lambda(X)) \} = \max_{\lambda \in \Lambda} \left\{ \int_{\mathbb{R}} f_{\lambda_0}(x) \ln f_\lambda(x) dx \right\},$$

其中 λ_0 是 X 满足的真实参数. 这说明我们也可以直接考虑如上优化问题.

Definition 2.11.(熵和 Kullback-Leibler 散度) 给定带参数的分布 f_λ , 定义

$$\mathbb{E}(-\ln f_\lambda(X)) = \int_{\mathbb{R}} -f_\lambda(x) \ln f_\lambda(x) dx$$

为 f_λ 的**熵 (entropy)**. 给定两个概率密度 p, q , 定义 p 相对于 q 的熵

$$\int_{\mathbb{R}} p(x) \ln \frac{p(x)}{q(x)} dx$$

为 **Kullback-Leibler 散度 (Kullback-Leibler divergence)**, 记作 $D_{\text{KL}}(p||q)$.

于是上述优化问题相当于找到带常数项的

$$\int_{\mathbb{R}} f_{\lambda_0}(x) \ln f_{\lambda_0}(x) dx - \int_{\mathbb{R}} f_{\lambda_0}(x) \ln f_\lambda(x) dx = D_{\text{KL}}(f_{\lambda_0}||f_\lambda)$$

的最小值.

为了找到极大似然函数的最值, 当然应该考虑导数

$$L'(\lambda) = \frac{1}{n} \sum_{k=1}^n \frac{\partial}{\partial \lambda} \ln f_\lambda(X_k),$$

称为**得分函数 (score function)**. 根据中心极限定理有依分布收敛

$$\sqrt{n} \left(L'(\lambda) - \mathbb{E} \left(\frac{\partial}{\partial \lambda} \ln f_\lambda(X) \right) \right) \rightarrow N \left(0, \text{Var} \left(\frac{\partial}{\partial \lambda} \ln f_\lambda(X) \right) \right).$$

在 $\lambda = \lambda_0$ 处, 期望

$$\mathbb{E} \left(\frac{\partial}{\partial \lambda} \ln f_\lambda(X) \right) = \int_{\mathbb{R}} \frac{1}{f_{\lambda_0}(x)} \frac{\partial}{\partial \lambda} f_\lambda(x) |_{\lambda=\lambda_0} f_{\lambda_0}(x) dx = \left(\frac{\partial}{\partial \lambda} \int_{\mathbb{R}} f_\lambda(x) dx \right)_{\lambda=\lambda_0} = 0,$$

于是有依分布收敛

$$\sqrt{n} L'(\lambda_0) \rightarrow N(0, I(\lambda_0)).$$

在 λ_0 处 $L(\lambda)$ 取最大值, 作 Taylor 展开

$$0 = L'(\lambda) = L'(\lambda_0) + L''(\lambda_0)(\lambda - \lambda_0) + o\left(\frac{1}{n}\right).$$

于是有

$$\sqrt{n}(\hat{\lambda} - \lambda_0) \approx \frac{\sqrt{n} L'(\lambda_0)}{L''(\lambda_0)}.$$

依照大数定律有依概率收敛

$$L''(\lambda_0) = \left(\frac{1}{n} \sum_{k=1}^n \frac{\partial^2}{\partial \lambda^2} \ln f_\lambda(X_k) \right)_{\lambda=\lambda_0} \rightarrow \mathbb{E} \left(\frac{\partial^2}{\partial \lambda^2} \ln f_\lambda(X) \right)_{\lambda=\lambda_0}.$$

计算可得

$$\mathbb{E} \left(\frac{\partial^2}{\partial \lambda^2} \ln f_\lambda(X) \right)_{\lambda=\lambda_0} = \left(\int_{\mathbb{R}} \frac{\partial^2}{\partial \lambda^2} f_\lambda(x) \right)_{\lambda=\lambda_0} - \left(\int_{\mathbb{R}} \frac{1}{f_\lambda(x)} \left(\frac{\partial}{\partial \lambda} f_\lambda(x) \right)^2 \right)_{\lambda=\lambda_0} = -I(\lambda_0).$$

于是根据**Theorem B.7**有依分布收敛

$$\sqrt{n}(\hat{\lambda} - \lambda_0) \rightarrow N \left(0, \frac{1}{I(\lambda_0)} \right).$$

2.5 区间估计理论

许多时候我们不需要估计具体的参数值, 而是参数值的范围, 使得目标有相当的概率达成. 例如餐厅选择布置座位的数量, 使得有相当大的概率 p 使顾客均有座位坐. 由此引发区间估计的概念.

Definition 2.12.(区间估计) 给定总体 F_λ , 从中抽取样本 $X_1, X_2, \dots, X_n$. $g(\lambda)$ 是关于总体参数的实值函数, 如果 $\hat{g}_1(\mathbf{X}) \leq \hat{g}_2(\mathbf{X})$ 是 $g(\lambda)$ 的一个估计 (统计量), 则称随机区间 $[\hat{g}_1(\mathbf{X}), \hat{g}_2(\mathbf{X})]$ 是 $g(\lambda)$ 的**区间估计 (interval estimation)**.

衡量一个估计是否给出了我们需要的相当大的概率, 有两种方案: 固定一个区间长度, 寻找该长度的所有区间中给出最大概率者; 以及固定一个要求的概率, 寻找所有给出此概率的区间中长度最小者. 前者需要取定区间长度, 这是一个 $(0, +\infty)$ 的值, 后者需要取定概率, 这是一个 $(0, 1)$ 的值. 在应用中我们选用后者, 这也符合直观上需要满足相当大的概率的认知.

Definition 2.13.(置信水平, 置信系数与置信区间) 给定总体 F_λ , 从中抽取样本 $X_1, X_2, \dots, X_n$. $g(\lambda)$ 是关于总体参数的实值函数, 如果随机区间 $[\hat{g}_1(\mathbf{X}), \hat{g}_2(\mathbf{X})]$ 是 $g(\lambda)$ 的区间估计, 则其包含 $g(\lambda)$ 的概率

$$\mathbb{P}(\hat{g}_1(\mathbf{X}) \leq g(\lambda) \leq \hat{g}_2(\mathbf{X}))$$

称为此区间估计的**置信水平 (confidence level)**. 置信水平的下确界

$$\inf_{\lambda \in \Lambda} \{\mathbb{P}(\hat{g}_1(\mathbf{X}) \leq g(\lambda) \leq \hat{g}_2(\mathbf{X}))\}$$

称为此区间估计的**置信系数 (confidence coefficient)**. 如果

$$\inf_{\lambda \in \Lambda} \{\mathbb{P}(\hat{g}_1(\mathbf{X}) \leq g(\lambda) \leq \hat{g}_2(\mathbf{X}))\} \geq 1 - \alpha,$$

则称此区间估计有 $1 - \alpha$ 的置信度. 具有 $1 - \alpha$ 的置信度的区间估计称为**置信水平为 $1 - \alpha$ 的置信区间 (confidence interval)**.

2.6 枢轴变量法

以下给出了一个求置信区间的例子.

Example 2.26. (正态分布已知方差的均值区间估计) 设 $X_1, X_2, \dots, X_n$ 是从正态总体 $N(\mu, \sigma^2)$ 中抽取的简单样本, 其中 σ 已知. 则我们知道 $\bar{X}$ 是 μ 的一个点估计, 且 $\frac{\sqrt{n}(\bar{X}-\mu)}{\sigma}$ 服从 $N(0, 1)$. 如果我们采用 $\bar{X}$ 进行估计, 则由于 $N(0, 1)$ 在 0 处单峰, 相同置信度下以 0 为中心的区间估计有最短的长度, 因此令

$$\mathbb{P}\left(-c \leq \frac{\sqrt{n}(\bar{X}-\mu)}{\sigma} \leq c\right) = 1 - \alpha,$$

则

$$\mathbb{P}\left(\frac{\sqrt{n}(\bar{X}-\mu)}{\sigma} > c\right) = \frac{\alpha}{2}.$$

因此 c 就是标准正态分布的上 $\frac{\alpha}{2}$ 分位数 $u_{\frac{\alpha}{2}}$, 解得置信度为 $1 - \alpha$ 的一个置信区间为

$$\left[\bar{X} - \frac{\sigma}{\sqrt{n}}u_{\frac{\alpha}{2}}, \bar{X} + \frac{\sigma}{\sqrt{n}}u_{\frac{\alpha}{2}}\right].$$

当然也可以用 $X_1 = X$ 作为 μ 的点估计, 则得到的结果恰好是 $n = 1$ 的情形, 相应的区间长度为 $2\sigma u_{\frac{\alpha}{2}}$.

比较上例的两种区间估计, 通过 $\bar{X}$ 给出的区间估计使用了更多样本的信息, 获得了长度更短的区间估计, 即通过增加样本减小了不确定性.

下例相应展现了 σ 未知时 μ 的区间估计, 可以想见, 拥有的信息更少了, 因此获得的区间长度也会更大.

Example 2.27. (正态分布未知方差的均值区间估计) 设 $X_1, X_2, \dots, X_n$ 是从正态总体 $N(\mu, \sigma^2)$ 中抽取的简单样本, 其中 σ 未知. 此时 $\bar{X}$ 仍然是 μ 的一个点估计, 类似 **Example 2.26.** 构造的正态分布, 为了将之转化为已知分布, 根据 **Example 1.6.** 的结果有

$$S^2 = \frac{1}{n-1} \sum_{k=1}^n (X_k - \bar{X})^2$$

可以视作 $n-1$ 个服从 $N(0, \sigma^2)$ 的独立正态变量的平方和, 且与 $\bar{X}$ 独立. 而 $\sqrt{n}(\bar{X}-\mu)$ 服从 $N(0, \sigma^2)$, 因此

$$T = \frac{\sqrt{n}(\bar{X}-\mu)}{S} = \sqrt{n}(\bar{X}-\mu) \left(\frac{1}{n-1} \sum_{k=1}^n (X_k - \bar{X})^2 \right)^{-\frac{1}{2}}$$

服从 t_{n-1} . 由于 t 分布的密度函数也是对称单峰的, 因此最优 (长度最短) 区间估计为

$$\mathbb{P}\left(-t_{n-1, \frac{\alpha}{2}} \leq T \leq t_{n-1, \frac{\alpha}{2}}\right) = 1 - \alpha,$$

解得置信度为 $1 - \alpha$ 的一个置信区间为

$$\left[\bar{X} - \frac{S}{\sqrt{n}} t_{n-1, \frac{\alpha}{2}}, \bar{X} + \frac{S}{\sqrt{n}} t_{n-1, \frac{\alpha}{2}} \right].$$

区间长度的均值为

$$2 \frac{\sigma}{\sqrt{n}} t_{n-1, \frac{\alpha}{2}},$$

与 **Example 2.26** 相比, 有 $u_{\frac{\alpha}{2}} \leq t_{n-1, \frac{\alpha}{2}}$, 因为 σ 已知给出了更多信息, 当然会得到确定性更好的结果.

这两个例子给出了求区间估计的一个一般性方法, 称为枢轴变量法.

Algorithm 2.3.(枢轴变量法) 给定分布族 F_λ , 其中 λ 是实参数, 以及 n 个简单样本 $X_1, X_2, \dots, X_n$, 要估计参数的函数为 $g(\lambda)$. 先找一个点估计 $\hat{g}(\mathbf{X})$, 再考虑从这个点估计出发构造一个带有 λ 的随机变量函数 $\varphi(\mathbf{X}, \lambda, \hat{g}(\mathbf{X}))$, 使得其分布 F_φ 是熟知的且与 λ 无关. 这个随机变量函数称为枢轴变量. 设 F_φ 的上 α_1, α_2 分位点为 f_{α_1} 和 f_{α_2} , 即 $1 - F(f_{\alpha_i}) = \alpha_i$. 如果 $\alpha_2 - \alpha_1 = \alpha$, 则根据

$$f_{\alpha_1} \leq \varphi(\mathbf{X}, \lambda, \hat{g}(\mathbf{X})) \leq f_{\alpha_2}$$

解出 λ 关于 $\hat{g}(\mathbf{X})$ 和 $\mathbf{X}$ 的范围是一个区间 $I(\mathbf{X})$, 则

$$\mathbb{P}(\lambda \in I(\mathbf{X})) = \mathbb{P}(f_{\alpha_1} \leq \varphi(\mathbf{X}, \lambda, \hat{g}(\mathbf{X})) \leq f_{\alpha_2}) = F(f_{\alpha_2}) - F(f_{\alpha_1}) = 1 - \alpha,$$

就得到置信度为 $1 - \alpha$ 的置信区间 $I(\mathbf{X})$.

要注意根据点估计的选取不同, 得到的区间估计也不同, 因此这样得到的区间估计未必是最优的. 事实上, 最优的区间估计可能未必可以由此方法得到, 一般而言只要得到一个较好的区间估计即可.

用同样方法, 可以得到正态分布 σ^2 的区间估计.

Example 2.28.(正态分布已知均值的方差区间估计) 设 $X_1, X_2, \dots, X_n$ 是从正态总体 $N(\mu, \sigma^2)$ 中抽取的简单样本, 其中 μ 已知. 此时根据 **Example 1.1**. 总体方差

$$\frac{1}{n} \sum_{k=1}^n (X_k - \mu)^2$$

是 σ^2 的一个点估计, 且注意到 $\frac{X_k - \mu}{\sigma}$ 独立服从 $N(0, 1)$, 可知

$$\frac{1}{\sigma^2} \sum_{k=1}^n (X_k - \mu)^2$$

是独立正态变量的和, 服从 χ_n^2 分布, 于是有

$$\mathbb{P}\left(\chi_{n,1-\frac{\alpha}{2}}^2 \leq \frac{1}{\sigma^2} \sum_{k=1}^n (X_k - \mu)^2 \leq \chi_{n,\frac{\alpha}{2}}^2\right) = 1 - \alpha,$$

解得置信度为 $1 - \alpha$ 的一个置信区间为

$$\left[\left(\chi_{n,\frac{\alpha}{2}}^2\right)^{-1} \left(\sum_{k=1}^n (X_k - \mu)^2\right), \left(\chi_{n,1-\frac{\alpha}{2}}^2\right)^{-1} \left(\sum_{k=1}^n (X_k - \mu)^2\right) \right].$$

然而 χ_n^2 分布不是对称单峰的, 因此这样得到的区间估计未必是最优的. 要想找到最优区间, 设

$$A_1 = \chi_{n,\alpha_1}^2, \quad A_2 = \chi_{n,\alpha_2}^2,$$

则需要满足 $\alpha_1 - \alpha_2 = 1 - \alpha$, 即

$$\int_{A_1}^{A_2} f_n(x) dx = 1 - \alpha,$$

其中 $f_n(x)$ 是 χ_n^2 的密度函数. 区间长度为

$$\left(\sum_{k=1}^n (X_k - \mu)^2\right) \left(\frac{1}{A_1} - \frac{1}{A_2}\right),$$

因此相当于要求满足以上积分方程约束的 $\frac{1}{A_1} - \frac{1}{A_2}$ 最小值. 采用 Lagrange 乘子法, Lagrange 函数

$$L(A_1, A_2, \lambda) = \frac{1}{A_1} - \frac{1}{A_2} + \lambda \left(\int_{A_1}^{A_2} f_n(x) dx - (1 - \alpha) \right),$$

对 A_1, A_2 求偏导得

$$\frac{\partial L}{\partial A_1} = -\frac{1}{A_1^2} - \lambda f_n(A_1), \quad \frac{\partial L}{\partial A_2} = \frac{1}{A_2^2} + \lambda f_n(A_2),$$

令导数为 0, 解得 $A_1^2 f_n(A_1) = A_2^2 f_n(A_2)$, 对 χ_n^2 分布而言 $x^2 f_n(x) = c$ 一定有两解. 根据 [Theorem 1.2](#) 的结果, 得到方程

$$A_1^{\frac{n+2}{2}} e^{-\frac{A_1}{2}} = A_2^{\frac{n+2}{2}} e^{-\frac{A_2}{2}}.$$

与积分方程联立可得到相应的数值解.

Example 2.29. (正态分布未知均值的方差区间估计) 设 $X_1, X_2, \dots, X_n$ 是从正态总体 $N(\mu, \sigma^2)$ 中抽取的简单样本, 其中 μ 未知. 此时根据 [Example 1.2](#) 样本方差

$$S^2 = \frac{1}{n-1} \sum_{k=1}^n (X_k - \bar{X})^2$$

是 σ^2 的一个点估计, 且注意到这相当于 $n-1$ 个独立服从 $N(0, \sigma^2)$ 随机变量的平方的平均, 可知

$$\frac{1}{\sigma^2} \sum_{k=1}^n (X_k - \bar{X})^2$$

服从 χ_{n-1}^2 分布, 于是同样有置信度为 $1-\alpha$ 的置信区间形如

$$\left[\left(\chi_{n-1, \alpha_2}^2 \right)^{-1} \left(\sum_{k=1}^n (X_k - \bar{X})^2 \right), \left(\chi_{n-1, \alpha_1}^2 \right)^{-1} \left(\sum_{k=1}^n (X_k - \bar{X})^2 \right) \right],$$

其中 $\alpha_1 - \alpha_2 = 1 - \alpha$, 而最优区间同样可以通过 **Example 2.28** 的 Lagrange 乘子法得到.

以上我们处理了正态分布参数的区间估计的全部四种情况, 如果给定的样本来自两个不同正态分布, 则需要考虑 $\mu_1, \mu_2, \sigma_1, \sigma_2$ 是否已知, 情况数将会大大增加. 所幸其中一些情形是无效的, 例如 μ_1 已知估计 $\mu_1 - \mu_2$, 由此我们只考虑以下两例的情形.

Example 2.30. (双正态分布方差比的区间估计) 设 $X_1, X_2, \dots, X_m$ 是从正态总体 $N(\mu_1, \sigma_1^2)$ 中抽取的简单样本, 设 $Y_1, Y_2, \dots, Y_n$ 是从正态总体 $N(\mu_2, \sigma_2^2)$ 中抽取的简单样本, 其中 μ_1, μ_2 未知. 根据 **Example 1.2**, 样本方差

$$S_1^2 = \frac{1}{m-1} \sum_{i=1}^m (X_i - \bar{X})^2, \quad S_2^2 = \frac{1}{n-1} \sum_{j=1}^n (Y_j - \bar{Y})^2$$

是 σ_1^2, σ_2^2 的点估计, 且分别相当于 $m-1, n-1$ 个独立服从 $N(0, \sigma_1^2), N(0, \sigma_2^2)$ 随机变量的平方的平均, 可知

$$\frac{1}{\sigma_1^2} \sum_{i=1}^m (X_i - \bar{X})^2, \quad \frac{1}{\sigma_2^2} \sum_{j=1}^n (Y_j - \bar{Y})^2$$

分别服从 $\chi_{m-1}^2, \chi_{n-1}^2$ 分布, 于是比值

$$\frac{\sigma_2^2}{\sigma_1^2} \left(\sum_{i=1}^m (X_i - \bar{X})^2 \right) \left(\sum_{j=1}^n (Y_j - \bar{Y})^2 \right)^{-1}$$

服从 $F_{m-1, n-1}$ 分布. 于是置信度为 $1-\alpha$ 的置信区间形如

$$\left[\left(F_{m-1, n-1, \alpha_2} \right)^{-1} \frac{S_1^2}{S_2^2}, \left(F_{m-1, n-1, \alpha_1} \right)^{-1} \frac{S_1^2}{S_2^2} \right],$$

其中 $\alpha_1 - \alpha_2 = 1 - \alpha$. 常用的是等尾的置信区间, 即取 $\alpha_1 = 1 - \frac{\alpha}{2}, \alpha_2 = \frac{\alpha}{2}$. 均值已知的情形当然也可以用此方法估计, 或者利用均值构造更好的置信区间.

均值差的估计则较为困难.

Example 2.31. (双正态分布均值差的区间估计) 设 $X_1, X_2, \dots, X_m$ 是从正态总体 $N(\mu_1, \sigma_1^2)$ 中抽取的简单样本, 设 $Y_1, Y_2, \dots, Y_n$ 是从正态总体 $N(\mu_2, \sigma_2^2)$ 中抽取的简单样本, 其中 σ_1, σ_2 未知. 均值差 $\mu_1 - \mu_2$ 有点估计 $\bar{X} - \bar{Y}$, 且服从正态分布

$$N\left(\mu_1 - \mu_2, \frac{\sigma_1^2}{m} + \frac{\sigma_2^2}{n}\right).$$

如果 σ_1, σ_2 已知, 则直接有

$$\mathbb{P}\left(-u_{\frac{\alpha}{2}} \leq \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{m} + \frac{\sigma_2^2}{n}}} \leq u_{\frac{\alpha}{2}}\right) = 1 - \alpha,$$

于是区间估计为

$$\left[\bar{X} - \bar{Y} - u_{\frac{\alpha}{2}} \sqrt{\frac{\sigma_1^2}{m} + \frac{\sigma_2^2}{n}}, \bar{X} - \bar{Y} + u_{\frac{\alpha}{2}} \sqrt{\frac{\sigma_1^2}{m} + \frac{\sigma_2^2}{n}}\right].$$

如果 σ_1, σ_2 未知时, 我们需要用其他统计量代替未知的 σ_1^2 和 σ_2^2 , 一个想法是使用 S_1^2 和 S_2^2 , 则需要使用服从 χ^2 分布的

$$\frac{1}{m+n-2} \left(\frac{1}{\sigma_1^2} \sum_{i=1}^m (X_i - \bar{X})^2 + \frac{1}{\sigma_2^2} \sum_{j=1}^n (Y_j - \bar{Y})^2 \right).$$

很明显只有 $\sigma_1 = \sigma_2 = \sigma$ 时能用此方法消去 σ , 即让两个随机变量相除, 构造

$$T = \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma^2}{m} + \frac{\sigma^2}{n}}} \left(\frac{1}{m+n-2} \left(\frac{1}{\sigma^2} \sum_{i=1}^m (X_i - \bar{X})^2 + \frac{1}{\sigma^2} \sum_{j=1}^n (Y_j - \bar{Y})^2 \right) \right)^{-\frac{1}{2}}$$

是标准正态分布除上 χ^2 分布开根, 从而服从 t_{m+n-2} 分布. 整理得

$$T = \frac{m+n-2}{\sqrt{\frac{1}{m} + \frac{1}{n}}} \left(\sum_{i=1}^m (X_i - \bar{X})^2 + \sum_{j=1}^n (Y_j - \bar{Y})^2 \right)^{-\frac{1}{2}} ((\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)),$$

取 t 分布的 $\frac{\alpha}{2}$ 分位数解不等式即得区间估计

$$\left[\bar{X} - \bar{Y} - \frac{m+n}{m+n-2} \sqrt{mn} S t_{m+n-2, \frac{\alpha}{2}}, \bar{X} - \bar{Y} + \frac{m+n}{m+n-2} \sqrt{mn} S t_{m+n-2, \frac{\alpha}{2}} \right],$$

其中

$$S^2 = \frac{1}{m+n} \left(\sum_{i=1}^m (X_i - \bar{X})^2 + \sum_{j=1}^n (Y_j - \bar{Y})^2 \right).$$

一般未知 σ_1, σ_2 的情形则无法用此方法解决. 如果允许损失一定的信息, 可以考虑舍弃 X_i, Y_j 中较多者多出的数据, 不妨设 $m \geq n$, 则只保留 $X_k, Y_k (1 \leq k \leq n)$, 并令 $Z_k = X_k - Y_k$ 服从 $N(\mu_1 - \mu_2, \sigma_1^2 + \sigma_2^2)$, 这可以看作 n 个单正态分布 $N(\mu, \sigma^2)$ 的样本, 于是根据 **Example 2.27** 的结果有区间估计

$$\left[\bar{X} - \bar{Y} - \frac{S}{\sqrt{n}} t_{n-1, \frac{\alpha}{2}}, \bar{X} - \bar{Y} + \frac{S}{\sqrt{n}} t_{n-1, \frac{\alpha}{2}} \right],$$

其中 S^2 是 Z_k 的样本方差. 或者当 m, n 充分大时, 根据 **Theorem B.7** 和中心极限定理, 有依分布收敛

$$\frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{\frac{S_1^2}{m} + \frac{S_2^2}{n}}} \rightarrow \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{m} + \frac{\sigma_2^2}{n}}},$$

因此在 σ_1, σ_2 已知的情形中把 σ_1^2, σ_2^2 替换为 S_1^2, S_2^2 即得区间估计的近似

$$\left[\bar{X} - \bar{Y} - u_{\frac{\alpha}{2}} \sqrt{\frac{S_1^2}{m} + \frac{S_2^2}{n}}, \bar{X} - \bar{Y} + u_{\frac{\alpha}{2}} \sqrt{\frac{S_1^2}{m} + \frac{S_2^2}{n}} \right].$$

现在考虑正态分布以外的其他分布, 此时没有 χ^2, t, F 等现成的分布供我们使用, 因此就目前的论述环境下对绝大多数情形很难给出精确的置信区间. 但如果接受渐近区间估计, 则可以考虑极限分布, 再代入相应的数值.

Example 2.32. (指数分布的区间估计) 设 $X_1, X_2, \dots, X_n$ 是从指数总体 $\text{Exp}(\lambda)$ 中抽取的简单样本. 根据 **Example 2.24** 可知 $\bar{X}$ 是 $\frac{1}{\lambda}$ 的无偏估计, 且根据 **Theorem 1.2** 的推论可知 $T = 2\lambda n \bar{X}$ 服从 χ_{2n}^2 . 设 α_1, α_2 满足 $\alpha_1 - \alpha_2 = 1 - \alpha$, 则有

$$\mathbb{P}(\chi_{2n, \alpha_1}^2 \leq 2\lambda n \bar{X} \leq \chi_{2n, \alpha_2}^2) = 1 - \alpha,$$

于是置信度 $1 - \alpha$ 的置信区间为

$$\left[\frac{\chi_{2n, \alpha_1}^2}{2n\bar{X}}, \frac{\chi_{2n, \alpha_2}^2}{2n\bar{X}} \right].$$

Example 2.33. (均匀分布的区间估计) 设 $X_1, X_2, \dots, X_n$ 是从均匀总体 $U(0, \theta)$ 中抽取的简单样本. 根据 **Example 2.25** 可知 $X_{(n)}$ 是 θ 的无偏估计. 考察 $Z = \frac{\theta}{T}$ 的分布

$$F_Z(x) = \mathbb{P}(Z \leq x) = 1 - \mathbb{P}\left(\frac{\theta}{x} > X_{(n)}\right) = 1 - \mathbb{P}\left(\frac{\theta}{x} > X_k\right)^n = 1 - \left(\frac{1}{\theta x}\right)^n = 1 - x^{-n}$$

与 θ 无关. 设 Z 的区间估计为 $[a, b] (a \geq 1)$, 则要满足置信度 $1 - \alpha$ 相当于

$$a^{-n} - b^{-n} = 1 - \alpha.$$

由此可以解出 $b - a$ 关于 a 的函数

$$b - a = \left(\frac{1}{a^n} - 1 + \alpha \right)^{-\frac{1}{n}} - a$$

在取非负值的区间内关于 a 单调上升, 因此取 $a = 1$, 而解得 $b = \alpha^{-\frac{1}{n}}$, 于是区间估计为

$$\left[X_{(n)}, \alpha^{-\frac{1}{n}} X_{(n)} \right].$$

Example 2.34. (Bernoulli 分布的区间估计) 设 $X_1, X_2, \dots, X_n$ 是从 Bernoulli 总体 $B(1, p)$ 中抽取的简单样本. 根据 **Example 2.22** 可知 $\bar{X}$ 是 p 的无偏估计. 但 p 并不直接反映位置或尺度, 因此难以构造熟知的分布. 我们考虑中心极限定理

$$\frac{\sqrt{n}(\bar{X} - p)}{\sqrt{p(1-p)}} \rightarrow N(0, 1),$$

因此用 **Theorem B.7** 有

$$\frac{\sqrt{n}(\bar{X} - p)}{\sqrt{\bar{X}(1 - \bar{X})}} \rightarrow N(0, 1),$$

于是有渐近区间估计

$$\left[\bar{X} - u_{\frac{\alpha}{2}} \sqrt{\frac{\bar{X}(1 - \bar{X})}{n}}, \bar{X} + u_{\frac{\alpha}{2}} \sqrt{\frac{\bar{X}(1 - \bar{X})}{n}} \right].$$

Chapter 3

假设检验

3.1 参数假设检验

3.1.1 参数假设检验

首先考虑假设检验的一个经典案例：一位女士声称自己有通过品茶鉴别茶的制作过程，是把茶加进奶里还是把奶加进茶里。我们的目标是通过有限次试验结果，判断她是否有这个能力。

从女士的角度看，她认为自己有鉴别能力，因此要否定这一点需要提供足够的否定自己有鉴别能力的证据。反之从试验者的角度看，默认所有人都无法鉴别，因此女士需要给出足够的证明自己有鉴别能力的证据。类似地，制药厂认为自己的药物是有效的，否定则要给出证据证明药物无效，而监管局认为药物一般都是无效的，否定则要给出证据证明药物有效。从这些例子可以看出，原始假设的不同，意味着通过统计数据判别的过程不同，这引出了以下定义。

Definition 3.1.(原假设与对立假设) 给定总体 F_θ ，从中抽取样本 $X_1, X_2, \dots, X_n$ 。对参数 θ 有一个估计范围 $\Theta_0 \subseteq \Theta$ ，如果倾向于接受 $\theta \in \Theta_0$ ，则称该命题为**原假设 (null hypothesis)**，记作 H_0 ，相应 $\theta \notin \Theta_0$ ，也即 $\theta \in \Theta \setminus \Theta_0 = \Theta_1$ ，称为**对立假设/备择假设 (alternative hypothesis)**，记作 H_1 。

根据观察到的样本不同，我们会选择接受原假设或拒绝原假设。

Definition 3.2.(检验拒绝域与统计量) 给定总体 F_θ ，从中抽取样本 $X_1, X_2, \dots, X_n$ ，设 $\mathbf{X}$ 所在的样本空间为 Ω 。一个子集 $\mathcal{A} \subseteq \Omega$ 称为**拒绝域 (reject region)**，如果当 $\mathbf{X} \in \mathcal{A}$ 时拒绝原假设，而 $\mathbf{X} \notin \mathcal{A}$ 时接受原假设。如果存在统计量 $T = T(\mathbf{X})$ 和常数 c ，使得 $\mathbf{X} \in \mathcal{A}$ 当且仅当 $T > c$ ，则称 T 是相应于拒绝域 $\mathcal{A}$ 的检验统计量， c 称为**临界值 (critical value)**。

假设检验所要做的, 就是为一个需要检验的假设 $H_0 \leftrightarrow H_1$, 构造一个合适的拒绝域 $\mathcal{A} \subseteq \Omega$, 即找到一个足够大的 H_0 不大可能发生的区域 $\mathcal{A} \subseteq \Omega$. 从这里也可以看出, 如果 $\mathbf{X}$ 落在了 H_0 有一定可能发生的区域, 则也接受原假设, 即我们倾向于接受原假设, 这也是不能随意交换原假设和备择假设的原因.

一个常见选取拒绝域的方法是, 用 $\mathbf{X}$ 估计参数 $\hat{\theta}(\mathbf{X})$, 则 $\hat{\theta} \in \Theta_1$ 就选取为拒绝域.

如果选定了一个拒绝域, 采用功效函数评估其效果. 功效函数仅由拒绝域的选取决定, 决定后只与参数 θ 有关.

Definition 3.3.(功效函数) 给定总体 F_θ , 从中抽取样本 $X_1, X_2, \dots, X_n$, 设 $\mathbf{X}$ 所在的样本空间为 Ω , $\mathcal{A} \subseteq \Omega$ 是拒绝域. 定义关于该拒绝域的功效函数

$$\beta(\theta) = \mathbb{P}(\mathbf{X} \in \mathcal{A})$$

是给定分布下样本落在拒绝域内的概率.

从功效函数的定义看, 功效函数对每个可能的参数指出了拒绝的概率, 一个好的拒绝域应该使得功效函数对 Θ_0 中参数赋予低概率, 而对 Θ_1 中参数赋予高概率. 因为如果原假设真实成立, 则 $\mathbf{X}$ 有低概率落在拒绝域中, 即 $\beta(\theta)$ 应该取低概率, 反之亦然.

试验的结果有一定的随机性, 即女士有无鉴别能力, 和试验结果显示我们认为女士是否有鉴别能力, 所有组合都有可能发生.

Definition 3.4.(弃真与取伪) 给定总体 F_θ , 从中抽取样本 $X_1, X_2, \dots, X_n$, 设 $\mathbf{X}$ 所在的样本空间为 Ω , $\mathcal{A} \subseteq \Omega$ 是拒绝域. 如果 $\theta \in \Theta_0$, 则 $\beta(\theta)$ 表示样本落在拒绝域的概率, 即真实情况为接受原假设但得出拒绝的结果, 称为**弃真/第一类错误 (type I error)**, 记其概率为 $\alpha(\theta)$, 且在 $\theta \in \Theta_1$ 上取 0. 如果 $\theta \in \Theta_1$, 则 $1 - \beta(\theta)$ 表示样本不落在拒绝域的概率, 即真实情况为拒绝原假设但得出接受的结果, 称为**取伪/第二类错误 (type II error)**, 记其概率为 $\gamma(\theta)$, 且在 $\theta \in \Theta_0$ 上取 0. 功效函数直接给出了弃真和取伪的概率.

在数理统计中, 我们往往只控制第一类错误, 即尽可能减少弃真. 不控制第二类错误会导致取伪增加, 即接受原假设的概率高于实际概率, 因此参数假设检验倾向于保护原假设, 这再次说明原假设和备择假设不能随意交换.

Definition 3.5.(检验水平) 给定总体 F_θ , 从中抽取样本 $X_1, X_2, \dots, X_n$, 设 $\mathbf{X}$ 所在的样本空间为 Ω , $\mathcal{A} \subseteq \Omega$ 是拒绝域. 在原假设正确, 即 $\theta \in \Theta_0$ 的条件下, 拒绝原假设 (弃真) 的概率上确界

$$\alpha = \sup_{\theta \in \Theta_0} \{\beta(\theta)\}$$

称为**检验水平**.

最后, 如果总体分布关于参数未必连续, 则需要扩展拒绝域的定义.

Definition 3.6.(检验函数) 给定总体 F_θ , 从中抽取样本 $X_1, X_2, \dots, X_n$, 设 $\mathbf{X}$ 所在的样本空间为 Ω , $\mathcal{A} \subseteq \Omega$ 是拒绝域. 定义关于此拒绝域的**检验函数**为

$$\psi(\mathbf{X}) = \begin{cases} 1, & \mathbf{X} \in \mathcal{A}, \\ 0, & \mathbf{X} \notin \mathcal{A}. \end{cases}$$

则其期望

$$\mathbb{E}(\psi(\mathbf{X})) = \mathbb{P}(\mathbf{X} \in \mathcal{A}) = \beta(\theta)$$

就是功效函数. 如果以上检验函数的定义在某些点处无法决断, 通常是 $\mathbf{X} \in \mathcal{A}$ 可以转化为检验统计量 $T(\mathbf{X}) > c$ 的情形, 则在该点处引入一个随机化检验

$$\psi(\mathbf{X}) = \begin{cases} 1, & T > c, \\ r, & T = c, \\ 0, & T < c. \end{cases}$$

从期望上看, 这相当于在 $T = c$ 处额外做了一个成功率为 r 的随机试验.

以正态分布为例看如何构造假设检验.

Example 3.1.(正态分布的双边检验) 设 $X_1, X_2, \dots, X_n$ 是从正态总体 $N(\mu, \sigma^2)$ 中抽取的简单样本, 其中 σ 已知. 考虑检验问题

$$H_0 : \mu = \mu_0 \leftrightarrow H_1 : \mu \neq \mu_0.$$

由于 $\bar{X}$ 是 μ 的一个点估计, 如果原假设成立, 则

$$T = \frac{\sqrt{n}(\bar{X} - \mu_0)}{\sigma}$$

服从标准正态分布. 如果取 $|T|$ 为检验统计量, 设临界值为 c , 就有检验水平

$$\mathbb{P}(|T| > c | \mu = \mu_0) = 2(1 - \Phi(c)).$$

令其值为 α , 得

$$c = \Phi^{-1}\left(1 - \frac{\alpha}{2}\right) = u_{\frac{\alpha}{2}},$$

于是选取拒绝域为

$$\mathcal{A} = \left\{ \mathbf{X} \in \Omega \mid |\bar{X} - \mu_0| > \frac{\sigma}{\sqrt{n}} u_{\frac{\alpha}{2}} \right\}.$$

比较 **Example 2.26.**, 可见 μ 的区间估计的补集正是本例中的拒绝域, 这给出了决定拒绝域的一个一般方法: 决定一个参数的区间估计, 并把其补集用作拒绝域.

Example 3.2.(正态分布的单边检验) 设 $X_1, X_2, \dots, X_n$ 是从正态总体 $N(\mu, \sigma^2)$ 中抽取的简单样本, 其中 σ 已知. 考虑检验问题

$$H_0 : \mu \leq \mu_0 \leftrightarrow H_1 : \mu > \mu_0.$$

类似 **Example 3.1.**, 拒绝域应当具有形式

$$\mathcal{A} = \left\{ \mathbf{X} \in \Omega \mid \bar{X} - \mu_0 > \frac{c}{\sqrt{n}} \right\}.$$

计算功效函数

$$\mathbb{P}(\sqrt{n}(\bar{X} - \mu_0) > c) = \mathbb{P}\left(\frac{\sqrt{n}(\bar{X} - \mu)}{\sigma} > \frac{c - \sqrt{n}(\mu - \mu_0)}{\sigma}\right) = 1 - \Phi\left(\frac{c - \sqrt{n}(\mu - \mu_0)}{\sigma}\right).$$

检验水平是上述在 $\mu \leq \mu_0$ 的上确界, 即

$$\sup_{\mu \leq \mu_0} \left\{ 1 - \Phi\left(\frac{c - \sqrt{n}(\mu - \mu_0)}{\sigma}\right) \right\} = 1 - \Phi\left(\frac{c}{\sigma}\right),$$

令检验水平为 α , 得到

$$c = \sigma \left(\Phi^{-1}(1 - \alpha) \right) = \sigma u_\alpha,$$

于是拒绝域为

$$\mathcal{A} = \left\{ \mathbf{X} \in \Omega \mid \bar{X} - \mu_0 > \frac{\sigma}{\sqrt{n}} u_\alpha \right\}.$$

这个问题与

$$H_0 : \mu = \mu_0 \leftrightarrow H_1 : \mu > \mu_0, \quad H_0 : \mu < \mu_0 \leftrightarrow H_1 : \mu \geq \mu_0$$

完全相同, 因为取上确界的步骤结果相同.

类似可得反问题

$$H_0 : \mu > \mu_0 \leftrightarrow H_1 : \mu \leq \mu_0$$

的拒绝域

$$\mathcal{A} = \left\{ \mathbf{X} \in \Omega \mid \bar{X} - \mu_0 < -\frac{\sigma}{\sqrt{n}} u_\alpha \right\}.$$

如果 $\mathbf{X}$ 同时不落在两个拒绝域中, 则总是接受原假设, 这也可以看出保护原假设的特点.

Example 3.3.(正态分布方差未知的均值假设检验) 设 $X_1, X_2, \dots, X_n$ 是从正态总体 $N(\mu, \sigma^2)$ 中抽取的简单样本, 其中 σ 未知. 考虑检验问题

$$H_0 : \mu = \mu_0 \leftrightarrow H_1 : \mu \neq \mu_0.$$

我们已经看到假设检验和区间估计的关系, 根据**Example 2.27.**的结果应当选取检验统计量

$$T = \frac{\sqrt{n}(\bar{X} - \mu_0)}{S} = \sqrt{n}(\bar{X} - \mu_0) \left(\frac{1}{n-1} \sum_{k=1}^n (X_k - \bar{X})^2 \right)^{-\frac{1}{2}}$$

服从 t_{n-1} 分布. 取拒绝域

$$\mathcal{A} = \left\{ \mathbf{X} \in \Omega \mid |T| > t_{n-1, \frac{\alpha}{2}} \right\},$$

则检验水平

$$\mathbb{P}(\mathbf{X} \in \mathcal{A} \mid \mu = \mu_0) = \alpha.$$

对检验问题

$$H_0 : \mu \leq \mu_0 \leftrightarrow H_1 : \mu > \mu_0,$$

设拒绝域形如

$$\mathcal{A} = \{ \mathbf{X} \in \Omega \mid T > c \} = \left\{ \mathbf{X} \in \Omega \mid \frac{\sqrt{n}(\bar{X} - \mu_0)}{S} > c \right\},$$

则功效函数

$$\mathbb{P} \left(\frac{\sqrt{n}(\bar{X} - \mu_0)}{S} > c \right) = \mathbb{P} \left(\frac{\sqrt{n}(\bar{X} - \mu)}{S} > c - \frac{\sqrt{n}(\mu - \mu_0)}{S} \right),$$

如果记 F_t 为 t_{n-1} 的分布函数, 则检验水平

$$\sup_{\mu \leq \mu_0} \left\{ 1 - F_t \left(c - \frac{\sqrt{n}(\mu - \mu_0)}{S} \right) \right\} = 1 - F_t(c) = \alpha \implies c = t_{n-1, \alpha},$$

即拒绝域为

$$\mathcal{A} = \{ \mathbf{X} \in \Omega \mid T > c \} = \left\{ \mathbf{X} \in \Omega \mid \frac{\sqrt{n}(\bar{X} - \mu_0)}{S} > t_{n-1, \alpha} \right\}.$$

Example 3.4.(正态分布方差假设检验) 设 $X_1, X_2, \dots, X_n$ 是从正态总体 $N(\mu, \sigma^2)$ 中抽取的简单样本. 根据**Example 2.28.**, 均值已知时检验问题

$$H_0 : \sigma^2 = \sigma_0^2 \leftrightarrow H_1 : \sigma^2 \neq \sigma_0^2$$

检验水平为 α 的拒绝域选为

$$\mathcal{A} = \left\{ \mathbf{X} \in \Omega \mid \frac{1}{\sigma_0^2} \sum_{k=1}^n (X_k - \mu)^2 > \chi_{n, \frac{\alpha}{2}}^2 \right\} \cup \left\{ \mathbf{X} \in \Omega \mid \frac{1}{\sigma_0^2} \sum_{k=1}^n (X_k - \mu)^2 < \chi_{n, 1 - \frac{\alpha}{2}}^2 \right\}.$$

检验问题

$$H_0 : \sigma^2 \leq \sigma_0^2 \leftrightarrow H_1 : \sigma^2 > \sigma_0^2$$

检验水平为 α 的拒绝域选为

$$\mathcal{A} = \left\{ \mathbf{X} \in \Omega \mid \frac{1}{\sigma_0^2} \sum_{k=1}^n (X_k - \mu)^2 > \chi_{n, \alpha}^2 \right\}.$$

根据 **Example 2.29.**, 均值未知时检验问题

$$H_0 : \sigma^2 = \sigma_0^2 \leftrightarrow H_1 : \sigma^2 \neq \sigma_0^2$$

检验水平为 α 的拒绝域选为

$$\mathcal{A} = \left\{ \mathbf{X} \in \Omega \mid \frac{1}{\sigma_0^2} \sum_{k=1}^n (X_k - \bar{X})^2 > \chi_{n-1, \frac{\alpha}{2}}^2 \right\} \cup \left\{ \mathbf{X} \in \Omega \mid \frac{1}{\sigma_0^2} \sum_{k=1}^n (X_k - \bar{X})^2 < \chi_{n-1, 1 - \frac{\alpha}{2}}^2 \right\}.$$

检验问题

$$H_0 : \sigma^2 \leq \sigma_0^2 \leftrightarrow H_1 : \sigma^2 > \sigma_0^2$$

检验水平为 α 的拒绝域选为

$$\mathcal{A} = \left\{ \mathbf{X} \in \Omega \mid \frac{1}{\sigma_0^2} \sum_{k=1}^n (X_k - \bar{X})^2 > \chi_{n-1, \alpha}^2 \right\}.$$

由此可见, 区间估计的结果可以直接移植到假设检验中来, 只要把区间估计的结果中参数取为相应的实际值, 再解不等式得到 $\mathbf{X}$ 的范围, 作为接受域即可. 类似可得双正态分布均值差和方差比的假设检验, 以及指数分布, 均匀分布和 Bernoulli 分布的参数假设检验, 这里不展开讨论.

3.1.2 似然比检验

回顾 **Algorithm 2.2.** 中似然函数代表了对固定的一组参数, 观测到样本发生的可能性. 在假设检验问题

$$H_0 : \theta \in \Theta_0 \leftrightarrow \theta \in \Theta_1$$

中, 似然函数在观测到样本上取值越大, 意味着相应参数组是真实参数组的可能性越大. 似然函数在 Θ_0 上能取到的最大值

$$L_{\Theta_0}(\mathbf{x}) = \sup_{\theta \in \Theta_0} \{L(\mathbf{x}, \theta)\}$$

给出了对固定样本, 参数 $\theta \in \Theta_0$ 的最大可能性. 如果其值较大, 说明参数 $\theta \in \Theta_0$ 的最大可能性较大, 我们就倾向于相信 $\theta \in \Theta_0$ 确实发生.

Definition 3.7.(似然比) 给定总体 F_θ , 有概率密度, 从中抽取样本 $X_1, X_2, \dots, X_n$. 对检验

$$H_0 : \theta \in \Theta_0 \leftrightarrow H_1 : \theta \in \Theta_1,$$

定义似然比 (likelihood ratio)

$$\lambda(\mathbf{x}) = \frac{\sup_{\theta \in \Theta} \{L(\mathbf{x}, \theta)\}}{\sup_{\theta \in \Theta_0} \{L(\mathbf{x}, \theta)\}}.$$

似然比对每个观测到的样本给出一个实数值, 当原假设成立时, 分母较大, 从而 $\lambda(\mathbf{x})$ 较小 (接近 1), 因此当 $\lambda(\mathbf{x})$ 较小时倾向于接受原假设. 取临界值 c , 定义检验函数

$$\psi(\mathbf{x}) = \begin{cases} 1, & \lambda(\mathbf{x}) > c, \\ r, & \lambda(\mathbf{x}) = c, \\ 0, & \lambda(\mathbf{x}) < c, \end{cases}$$

则其期望就是功效函数. 如果要求检验水平为 α , 则

$$\sup_{\theta \in \Theta_0} \{\mathbb{E}(\psi(\mathbf{X}))\} = \sup_{\theta \in \Theta_0} \{\mathbb{P}(\lambda(\mathbf{X}) > c) + r\mathbb{P}(\lambda(\mathbf{X}) = c)\} = \alpha,$$

由此可定出 c 和 r . 显然 $c > 1$, 否则 $\lambda(\mathbf{x}) > c$ 恒成立, 总是拒绝原假设.

Example 3.5.(Bernoulli 分布的似然比检验) 设 $X_1, X_2, \dots, X_n$ 是从 Bernoulli 总体 $B(1, p)$ 中抽取的简单样本. 考虑检验

$$H_0 : p \leq \frac{1}{2} \leftrightarrow H_1 : p > \frac{1}{2},$$

似然函数

$$L(\mathbf{x}, p) = \prod_{k=1}^n p^{x_k} (1-p)^{1-x_k} = (p^{\bar{x}} (1-p)^{1-\bar{x}})^n.$$

对数似然

$$\ln L(\mathbf{x}, p) = n(\bar{x} \ln p + (1-\bar{x}) \ln(1-p)).$$

求导易见 $\bar{x} = p$ 处取最大值, 于是似然比

$$\lambda(\mathbf{x}) = \begin{cases} 1, & \bar{x} \leq \frac{1}{2}, \\ (2\bar{x}(1-\bar{x}))^n, & \bar{x} > \frac{1}{2}. \end{cases}$$

现在拒绝域有形式

$$\mathcal{A} = \{\mathbf{X} \in \Omega \mid \lambda(\mathbf{X}) > c\},$$

功效函数

$$\beta(p) = \mathbb{P}(\lambda(\mathbf{X}) > c) = \mathbb{P}\left(\left(2\bar{X}^{\bar{X}}(1-\bar{X})^{1-\bar{X}}\right)^n > c, \bar{X} > \frac{1}{2}\right).$$

注意到 $h(x) = x \ln x + (1-x) \ln(1-x)$ 在 $x > \frac{1}{2}$ 上严格单调上升, 于是可设 $h(x) = \frac{1}{n} \ln c - \ln 2$ 在 $x > \frac{1}{2}$ 上的解为 $x = c_0$, 则

$$\beta(p) = \mathbb{P}(\bar{X} > c_0) \implies \sup_{p \leq \frac{1}{2}} \{\beta(p)\} = \mathbb{P}\left(\bar{X} > c_0 \mid p = \frac{1}{2}\right).$$

由于 $n\bar{X}$ 服从 $B(n, p)$, 得到检验水平为 $1 - F(nc_0)$, 其中 F 是 $B\left(n, \frac{1}{2}\right)$ 的分布函数, 进而设 $b = b_{n, \frac{1}{2}, \alpha}$ 是上 α 分位点, 有 $c_0 = \frac{1}{n}b$, 代入 $h(c_0) = \frac{1}{n} \ln c - \ln 2$ 解得

$$c = \left(\frac{2}{n}\right)^n b^b (n-b)^{n-b},$$

于是拒绝域选为

$$\mathcal{A} = \left\{ \mathbf{X} \in \Omega \mid \lambda(\mathbf{X}) > \left(\frac{2}{n}\right)^n b^b (n-b)^{n-b} \right\}.$$

注意到 $\bar{X}$, 进而 $\lambda(\mathbf{X})$ 不会取到全体实数, 因此要使拒绝域的检验水平为严格的 α , 还需要引入一次随机化检验 r , 这里从略.

Example 3.6.(正态分布均值的似然比检验) 设 $X_1, X_2, \dots, X_n$ 是正态总体 $N(\mu, \sigma^2)$ 中抽取的简单样本. 考虑检验

$$H_0 : \mu = \mu_0 \leftrightarrow H_1 : \mu \neq \mu_0,$$

似然函数

$$L(\mathbf{x}, \mu, \sigma^2) = \prod_{k=1}^n \frac{1}{\sqrt{2\pi\sigma}} \exp\left(-\frac{(x_k - \mu)^2}{2\sigma^2}\right) = (2\pi\sigma^2)^{-\frac{n}{2}} \exp\left(-\frac{1}{2\sigma^2} \sum_{k=1}^n (x_k - \mu)^2\right).$$

根据**Example 2.9.**的结果在

$$\mu = \bar{x}, \quad \sigma^2 = \frac{1}{n} \sum_{k=1}^n (x_k - \bar{x})^2$$

处取最大值, 对 Θ_0 同样可知在

$$\sigma^2 = \frac{1}{n} \sum_{k=1}^n (x_k - \mu_0)^2$$

处取最大值, 于是似然比

$$\lambda(\mathbf{x}) = \left(\frac{2\pi e}{n} \sum_{k=1}^n (x_k - \bar{x})^2 \right)^{-\frac{n}{2}} \left(\frac{2\pi e}{n} \sum_{k=1}^n (x_k - \mu_0)^2 \right)^{\frac{n}{2}} = \left(\frac{\sum_{k=1}^n (x_k - \mu_0)^2}{\sum_{k=1}^n (x_k - \bar{x})^2} \right)^{\frac{n}{2}}.$$

如果构造

$$T_\mu(\mathbf{X}) = \frac{\sqrt{n}(\bar{X} - \mu)}{S},$$

则

$$\lambda(\mathbf{x}) = \left(1 + \frac{1}{n-1} T_{\mu_0}(\mathbf{x})^2 \right)^{\frac{n}{2}}$$

关于 $|T|$ 严格单调上升, 因此拒绝域有形式

$$\mathcal{A} = \{\mathbf{X} \in \Omega \mid \lambda(\mathbf{X}) > c'\} = \{\mathbf{X} \in \Omega \mid |T_{\mu_0}(\mathbf{X})| > c\},$$

检验水平

$$\beta(\mu_0) = \mathbb{P}(|T(\mathbf{X})| > c).$$

注意到 $\mu = \mu_0$ 的条件下 T 服从 t_{n-1} 分布, 于是 $c = t_{n-1, \frac{\alpha}{2}}$ 时检验水平为 α , 相应的拒绝域

$$\mathcal{A} = \left\{ \mathbf{X} \in \Omega \mid \left| \frac{\sqrt{n}(\bar{X} - \mu)}{S} \right| > t_{n-1, \frac{\alpha}{2}} \right\}.$$

现在如果考虑检验

$$H_0 : \mu \leq \mu_0 \leftrightarrow H_1 : \mu > \mu_0,$$

则似然比的分子不变, 分母变为

$$\sup_{\mu \leq \mu_0, \sigma^2 > 0} \left\{ (2\pi\sigma^2)^{-\frac{n}{2}} \exp \left(-\frac{1}{2\sigma^2} \sum_{k=1}^n (x_k - \mu)^2 \right) \right\},$$

展开为

$$\sup_{\mu \leq \mu_0, \sigma^2 > 0} \left\{ (2\pi\sigma^2)^{-\frac{n}{2}} \exp \left(-\frac{1}{2\sigma^2} \sum_{k=1}^n (x_k - \bar{x})^2 - \frac{n(\bar{x} - \mu)^2}{2\sigma^2} \right) \right\}.$$

当 $\bar{x} > \mu_0$ 时, 对固定的 σ^2 在 $\mu = \mu_0$ 处取最大值, 此时和上一检验完全相同, 当 $\bar{x} \leq \mu_0$ 时, 在 $\mu = \bar{x}$ 处取最大值, 因此 $\lambda(\mathbf{x}) = 1$ 即得

$$\lambda(\mathbf{x}) = \begin{cases} 1, & \bar{x} \leq \mu_0, \\ \left(1 + \frac{1}{n-1} T_{\mu_0}(\mathbf{x})^2 \right)^{\frac{n}{2}}, & \bar{x} > \mu_0. \end{cases}$$

再次, 拒绝域为

$$\mathcal{A} = \{\mathbf{X} \in \Omega \mid T_{\mu_0}(\mathbf{X}) > t_{n-1, \alpha}\}.$$

Example 3.7.(正态分布方差的似然比检验) 设 $X_1, X_2, \dots, X_n$ 是正态总体 $N(\mu, \sigma^2)$ 中抽取的简单样本. 考虑检验

$$H_0 : \sigma^2 = \sigma_0^2 \leftrightarrow H_1 : \sigma^2 \neq \sigma_0^2,$$

似然函数的计算不依赖检验假设, 因此与 **Example 3.6.** 的结果相同, 不同的是似然比的分子变为

$$\sup_{\mu, \sigma^2 = \sigma_0^2} \left\{ (2\pi\sigma^2)^{-\frac{n}{2}} \exp \left(-\frac{1}{2\sigma^2} \sum_{k=1}^n (x_k - \mu)^2 \right) \right\} = (2\pi\sigma_0^2)^{-\frac{n}{2}} \exp \left(-\frac{1}{2\sigma_0^2} \sum_{k=1}^n (x_k - \bar{x})^2 \right),$$

代入得似然比

$$\lambda(\mathbf{x}) = \left(\frac{e}{n\sigma_0^2} \sum_{k=1}^n (x_k - \bar{x})^2 \right)^{-\frac{n}{2}} \exp \left(\frac{1}{2\sigma_0^2} \sum_{k=1}^n (x_k - \bar{x})^2 \right).$$

令

$$T(\mathbf{X}) = \frac{1}{\sigma_0^2} \sum_{k=1}^n (X_k - \bar{X})^2, \quad \lambda(\mathbf{X}) = \left(\frac{e}{n} T(\mathbf{X}) \right)^{-\frac{n}{2}} \exp \left(\frac{1}{2} T(\mathbf{X}) \right),$$

可见 λ 关于 T 先减后增, 因此 $\lambda(T) = c$ 有两解 $T = c_1$ 和 $T = c_2$, 不妨设 $c_1 < c_2$. 则拒绝域

$$\mathcal{A} = \{\mathbf{X} \in \Omega \mid \lambda(\mathbf{X}) > c\} = \{\mathbf{X} \in \Omega \mid T(\mathbf{X}) < c_1\} \cup \{\mathbf{X} \in \Omega \mid T(\mathbf{X}) > c_2\}.$$

注意到在 $\sigma^2 = \sigma_0^2$ 的条件下 $T(\mathbf{X})$ 服从 χ_{n-1}^2 分布, 于是取

$$\mathcal{A} = \left\{ \mathbf{X} \in \Omega \mid T(\mathbf{X}) < \chi_{n-1, 1-\frac{\alpha}{2}}^2 \right\} \cup \left\{ \mathbf{X} \in \Omega \mid T(\mathbf{X}) > \chi_{n-1, \frac{\alpha}{2}}^2 \right\}.$$

对检验

$$H_0 : \sigma^2 \leq \sigma_0^2 \leftrightarrow H_1 : \sigma^2 > \sigma_0^2,$$

类似地有

$$\lambda(\mathbf{x}) = \begin{cases} 1, & T(\mathbf{x}) \leq n, \\ \left(\frac{e}{n} T(\mathbf{x}) \right)^{-\frac{n}{2}} \exp \left(\frac{1}{2} T(\mathbf{x}) \right), & T(\mathbf{x}) > n. \end{cases}$$

此时 λ 关于 T 严格单调上升, 因此拒绝域

$$\mathcal{A} = \left\{ \mathbf{X} \in \Omega \mid T(\mathbf{X}) > \chi_{n-1, \alpha}^2 \right\}.$$

Exercise 1.4. 设 $X_1, X_2, \dots, X_n$ 是正态总体 $N(\mu, \sigma^2)$ 中抽取的简单样本. 求

$$H_0 : \mu = 0, \sigma^2 = 1 \leftrightarrow H_1 : \mu \neq 0 \text{ or } \sigma^2 \neq 1$$

检验水平为 α 的一个拒绝域.

Solution. 似然函数

$$L(\mathbf{x}, \mu, \sigma^2) = (2\pi\sigma^2)^{-\frac{n}{2}} \exp\left(-\frac{1}{2\sigma^2} \sum_{k=1}^n (x_k - \mu)^2\right).$$

在

$$\mu = \bar{x}, \quad \sigma^2 = \frac{1}{n} \sum_{k=1}^n (x_k - \bar{x})^2$$

处取最大值, 于是似然比

$$\lambda(\mathbf{x}) = \left(\frac{e}{n} \sum_{k=1}^n (x_k - \bar{x})^2\right)^{-\frac{n}{2}} \exp\left(\frac{1}{2} \sum_{k=1}^n x_k^2\right).$$

令检验统计量

$$T(\mathbf{X}) = \sum_{k=1}^n (X_k - \bar{X})^2,$$

则

$$\frac{2}{n} \ln \lambda(\mathbf{X}) = -\ln\left(\frac{1}{n} T(\mathbf{X})\right) + \frac{1}{n} T(\mathbf{X}) + \bar{X}^2 - 1.$$

考察

$$R(\mathbf{X}) = \frac{T(\mathbf{X})}{n} - 1,$$

则根据中心极限定理

$$\sqrt{n}R(\mathbf{X}) = \sqrt{n}\left(\frac{T(\mathbf{X})}{n} - 1\right) = \frac{T(\mathbf{X}) - n}{\sqrt{n}}$$

依分布收敛到 $N(0, 2)$, 且根据大数定律 $R(\mathbf{X})$ 依概率收敛到 0, 则把 $2 \ln \lambda(\mathbf{X})$ 除 $n\bar{X}^2$ 外在 $R(\mathbf{X})$ 处展开可见这一项依分布收敛到 χ_1^2 , 且与 $n\bar{X}^2$ 独立, 因此 $2 \ln \lambda(\mathbf{X})$ 依分布收敛到 χ_2^2 . 因此渐近拒绝域为

$$\mathcal{A} = \{\mathbf{X} \in \Omega \mid 2 \ln \lambda(\mathbf{X}) > \chi_{2,\alpha}^2\}.$$

由于假设检验依赖于选定的检验水平 α 以及相应的分布分位数表, 对于一个实际观测的样本, 我们只能得到接受和拒绝原假设的结论, 为了衡量观测样本与接受和拒绝的相差程度, 引入 p 值概念与检验水平 α 比较.

Definition 3.8. (p 值) 给定总体 F_θ , 从中抽取样本 $X_1, X_2, \dots, X_n$, 取定拒绝域 $\mathcal{A} \subseteq \Omega$. 如果检验统计量 $T = T(\mathbf{X})$ 服从分布 G , 则 $G(T)$ 服从均匀分布 $U(0, 1)$, 定义 $1 - G(T)$ 在观测样本上的取值为相应的 p 值 (p -value).

3.2 非参数假设检验

3.2.1 秩检验

Definition 3.9.(秩) 设 $X_1, X_2, \dots, X_n$ 是从未知连续总体中抽取的简单样本, $X_{(k)}$ 是第 k 个顺序统计量. 如果 $X_i = X_{(k)}$, 即 X_i 是这组样本从小到大第 k 个, 则称 k 是 X_i 在这组样本中的**秩 (rank)**, 记作 R_i . 全体秩构成统计量

$$\mathbf{R} = (R_1, R_2, \dots, R_n),$$

称为这组样本的**秩统计量 (rank statistics)**.

如果未知总体中的所有分布均连续, 则 X_i 几乎一定两两不等. 此时根据对称性 $\mathbf{R}$ 取 $1, 2, \dots, n$ 的任何一个排列, 即 $\mathbf{X}$ 的任意一个大小关系等概率, 于是设 σ 是 $1, 2, \dots, n$ 的任意排列, 有 $\mathbb{P}(\mathbf{R} = \sigma) = \frac{1}{n!}$.

既然秩统计量是统计量, 我们可以计算其统计特征. 回顾**Definition 1.4.**, 有

$$R_i = \sum_{k=1}^n \chi(X_k \leq X_i) = nF_n(X_i).$$

Example 3.8.(秩统计量的统计特征) 设 $X_1, X_2, \dots, X_n$ 是未知连续总体中抽取的简单样本, $\mathbf{R}$ 为相应的秩统计量. 则单个秩统计量的概率

$$\mathbb{P}(R_i = k) = \sum_{\sigma(i)=k} \mathbb{P}(\mathbf{R} = \sigma) = \frac{(n-1)!}{n!} = \frac{1}{n}.$$

期望

$$\mathbb{E}(R_i) = \sum_{k=1}^n k \mathbb{P}(R_i = k) = \frac{n(n+1)}{2} \frac{1}{n} = \frac{n+1}{2}.$$

方差

$$\text{Var}(R_i) = \mathbb{E}(R_i^2) - \mathbb{E}(R_i)^2 = \frac{1}{n} \sum_{k=1}^n k^2 - \left(\frac{n+1}{2}\right)^2 = \frac{(n+1)(n-1)}{12}.$$

两个秩统计量的协方差

$$\text{Cov}(R_i, R_j) = \mathbb{E}(R_i R_j) - \mathbb{E}(R_i) \mathbb{E}(R_j).$$

第一项

$$\mathbb{E}(R_i R_j) = \sum_{r \neq s} r s \mathbb{P}(R_i = r, R_j = s) = \frac{1}{n(n-1)} \sum_{r \neq s} r s,$$

计算得

$$\frac{1}{n(n-1)} \left(\left(\frac{n(n+1)}{2} \right)^2 - \frac{n(n+1)(2n+1)}{6} \right) = \frac{(n+1)(3n+2)}{12},$$

代入得

$$\text{Cov}(R_i, R_j) = \frac{(n+1)(3n+2)}{12} - \frac{(n+1)^2}{4} = -\frac{n+1}{12}.$$

相关系数

$$\rho(R_i, R_j) = \frac{\text{Cov}(R_i, R_j)}{\sqrt{\text{Var}(R_i) \text{Var}(R_j)}} = -\frac{1}{n-1}.$$

对未知总体而言, 我们关心的往往是真实分布的某种性质, 而不是分布本身, 例如分布是否关于 0 对称, 这需要提取有关符号的信息.

Definition 3.10.(符号秩) 设 $X_1, X_2, \dots, X_n$ 是从未知连续总体中抽取的简单样本, 样本绝对值 $|X_1|, |X_2|, \dots, |X_n|$ 的秩为 $R_1^+, R_2^+, \dots, R_n^+$. 定义

$$\mathbf{R}^+ = (\text{sgn}(X_1)R_1^+, \text{sgn}(X_2)R_2^+, \dots, \text{sgn}(X_n)R_n^+)$$

为这组样本的符号秩.

Theorem 3.1.(符号秩的独立性) 设 $X_1, X_2, \dots, X_n$ 是从关于 0 对称的连续总体 F 中抽取的简单样本. 则 $\text{sgn}(X_i)$ 各项与 $|X_i|$ 各项独立, 进而 $\text{sgn}(X_i)$ 各项与 $(R_1^+, R_2^+, \dots, R_n^+)$ 独立.

Proof. 直接计算

$$\mathbb{P}(\text{sgn}(X_i) = 1, |X_i| \leq x) = \mathbb{P}(0 < X_i \leq x) = F(x) - \frac{1}{2},$$

而

$$\mathbb{P}(\text{sgn}(X_i) = 1) = \frac{1}{2}, \quad \mathbb{P}(|X_i| \leq x) = F(x) - F(-x) = 2F(x) - 1,$$

于是

$$\mathbb{P}(\text{sgn}(X_i) = 1, |X_i| \leq x) = \mathbb{P}(\text{sgn}(X_i) = 1)\mathbb{P}(|X_i| \leq x),$$

从而独立. 而 X_i 与 X_j 本身独立, 当然 $\text{sgn}(X_i)$ 与 $|X_j|$ 独立. □

另一个关于未知总体的重要问题是两个未知总体是否相同. 例如从两个未知总体中取出简单样本 $X_1, X_2, \dots, X_m$ 和 $Y_1, Y_2, \dots, Y_n$, 如何根据这些样本判断未知总体是

否相同. 例如在生物实验中实验组和对照组数据是否服从相同分布, 将说明某个因素变化是否显著有效.

Definition 3.11.(Wilcoxon 两样本秩和) 设 $X_1, X_2, \dots, X_m$ 和 $Y_1, Y_2, \dots, Y_n$ 是从两个未知连续总体中抽取的简单样本, 这 $m+n$ 个混合样本的秩为 $R_1, R_2, \dots, R_{m+n}$. 定义前 m 个秩和

$$W_n = \sum_{k=1}^m R_k$$

为 **Wilcoxon 两样本秩和**.

W_n 表示 X_i 对应的秩和, 如果 W_n 偏小, 则相当于 X_i 整体偏小, 有理由相信 X_i 服从的分布与 Y_j 不同, W_n 偏大同理.

Example 3.9.(Wilcoxon 两样本秩和的统计特征) 设 $X_1, X_2, \dots, X_m, Y_1, Y_2, \dots, Y_n$ 是从同一个未知连续总体中抽取的简单样本, 这 $m+n$ 个样本的秩为 $R_1, R_2, \dots, R_{m+n}$, W_n 是 Wilcoxon 两样本秩和. 则根据 **Example 3.8** 的结果, 期望

$$\mathbb{E}(W_n) = \sum_{k=1}^m \mathbb{E}(R_k) = m \frac{m+n+1}{2},$$

方差

$$\text{Var}(W_n) = \sum_{k=1}^m \text{Var}(R_k) + \sum_{i \neq j} \text{Cov}(R_i, R_j),$$

代入得

$$m \frac{(m+n+1)(m+n-1)}{12} - m(m-1) \frac{m+n+1}{12} = \frac{mn(m+n+1)}{12}.$$

考察

$$W_n = \sum_{k=1}^m \left(\sum_{i=1}^m \chi(X_i \leq X_k) + \sum_{j=1}^n \chi(Y_j \leq X_k) \right) = \frac{m(m+1)}{2} + \sum_{k=1}^m \sum_{j=1}^n \chi(Y_j \leq X_k),$$

则

$$U = \sum_{k=1}^m \sum_{j=1}^n \chi(Y_j \leq X_k)$$

是遍历和的形式, 称为 Mann-Whitney U 统计量. 其期望

$$\mathbb{E}(U) = mn\mathbb{P}(Y \leq X)$$

给出了 $\mathbb{P}(Y \leq X)$ 的估计. 一般而言, 如果一个参数 (这里是 $\mathbb{P}(Y \leq X)$) 的估计可以写为某个统计量的期望, 则称该统计量是 U 统计量. 利用 Hoeffding 定理可以说明有依分布收敛

$$\frac{U - \mathbb{E}(U)}{\sqrt{\text{Var}(U)}} \rightarrow N(0, 1) \implies \frac{W_n - \mathbb{E}(W_n)}{\sqrt{\text{Var}(W_n)}} \rightarrow N(0, 1).$$

以上讨论说明我们可以采用 Wilcoxon 两样本秩和估计 $\mathbb{P}(Y \leq X)$ 的大小, 如果估计值偏离 $\frac{1}{2}$ 很远, 则认为 X_i 和 Y_j 服从的总体不同. 这一方法称为 Wilcoxon-Mann-Whitney 检验.

3.2.2 χ^2 检验

Mendel 豌豆实验中, 获取了四种性状豌豆的数量, 要验证这一数量的比例是否服从 $9:3:3:1$ 的分布, 即是否服从离散分布

$$\mathbb{P}(X = x_1) = \frac{9}{16}, \quad \mathbb{P}(X = x_2) = \mathbb{P}(X = x_3) = \frac{3}{16}, \quad \mathbb{P}(X = x_4) = \frac{1}{16}.$$

一般的问题如下: 设 F 是一个离散分布, 在 $x_1, x_2, \dots, x_r$ 处取值, 原假设是对概率的一个估计

$$H_0: \mathbb{P}(X = x_k) = p_k \quad (k = 1, 2, \dots, r).$$

$X_1, X_2, \dots, X_n$ 是从 F 中抽取的简单样本, x_k 被这 n 个数取到 N_k 次, 即

$$N_k = \sum_{i=1}^n \chi(X_i = x_k)$$

是随机变量. 为了决断接受或拒绝原假设, 我们需要原假设条件下一个统计量的分布作为特征.

Theorem 3.2.(Pearson) 设 $X_1, X_2, \dots, X_n$ 是从离散总体 F 中抽取的简单样本, 其中 F 只取 $x_1, x_2, \dots, x_r$. 如果 $\mathbb{P}(X = x_k) = p_k$, $\{X_i\}_{i=1}^n$ 中 x_k 被取到 N_k 次, 则

$$K_n = \sum_{k=1}^r \frac{(N_k - np_k)^2}{np_k}$$

依分布收敛到 χ_{r-1}^2 .

Proof. 按照定义 $N_k = n_k (k = 1, 2, \dots, r)$ 的概率是 X_i 的全部 $n!$ 种排列中除掉每个 n_k 内部 X_i 的排列, 再乘上每种排列的概率

$$\mathbb{P}(N_k = n_k) = \mathbb{P}(N_k = n_k, k = 1, 2, \dots, r) = \frac{n!}{n_1! \dots n_r!} p_1^{n_1} \dots p_r^{n_r}.$$

其特征函数

$$\psi_N(t_1, \dots, t_r) = \mathbb{E} \left(\exp \left(i \sum_{k=1}^r t_k N_k \right) \right) = \sum_{n_1 + \dots + n_r = n} \mathbb{P}(N_k = n_k) \exp \left(i \sum_{k=1}^r t_k n_k \right).$$

代入得

$$\sum_{n_1 + \dots + n_r = n} \frac{n!}{n_1! \dots n_r!} p_1^{n_1} \dots p_r^{n_r} \exp \left(i \sum_{k=1}^r t_k N_k \right) = n! \sum_{n_1 + \dots + n_r = n} \prod_{k=1}^r \frac{1}{n_k!} (p_k e^{it_k})^{n_k}.$$

根据多项式定理这就是

$$\psi_N(t_1, \dots, t_r) = \left(\sum_{k=1}^r p_k e^{it_k} \right)^n$$

的展开式. 现在令

$$Y_k = \frac{N_k - np_k}{\sqrt{np_k}}, \quad K_n = \sum_{k=1}^r Y_k^2,$$

则可以计算相应的特征函数

$$\psi_Y(t_1, \dots, t_r) = \mathbb{E} \left(\exp \left(i \sum_{k=1}^r t_k Y_k \right) \right) = \mathbb{E} \left(\exp \left(i \sum_{k=1}^r \frac{t_k N_k}{\sqrt{np_k}} - i \sum_{k=1}^r t_k \sqrt{np_k} \right) \right).$$

后一项与 N_k 无关, 从而作为常系数可以通过 $\mathbb{E}$, 得到

$$\exp \left(-i \sum_{k=1}^r t_k \sqrt{np_k} \right) \mathbb{E} \left(\exp \left(i \sum_{k=1}^r \frac{t_k}{\sqrt{np_k}} N_k \right) \right),$$

观察 ψ_N 可得

$$\psi_Y(t_1, \dots, t_r) = \exp \left(-i \sum_{k=1}^r t_k \sqrt{np_k} \right) \psi_N \left(\frac{t_1}{\sqrt{np_1}}, \dots, \frac{t_r}{\sqrt{np_r}} \right).$$

现在对

$$\ln \psi_Y = -i \sum_{k=1}^r t_k \sqrt{np_k} + n \ln \sum_{k=1}^r p_k e^{i \frac{t_k}{\sqrt{np_k}}}$$

作 $n \rightarrow \infty$ 的展开, 首先

$$e^{i \frac{t_k}{\sqrt{np_k}}} = 1 + i \frac{t_k}{\sqrt{np_k}} - \frac{t_k^2}{2np_k} + O(n^{-\frac{3}{2}}),$$

于是

$$\sum_{k=1}^r p_k e^{i \frac{t_k}{\sqrt{np_k}}} = \sum_{k=1}^r p_k + \sum_{k=1}^r i \frac{t_k}{\sqrt{n}} \sqrt{p_k} - \sum_{k=1}^r \frac{t_k^2}{2n} + O(n^{-\frac{3}{2}}),$$

整理得

$$\sum_{k=1}^r p_k e^{i \frac{t_k}{\sqrt{np_k}}} = 1 + \frac{i}{\sqrt{n}} \sum_{k=1}^r t_k \sqrt{p_k} - \frac{1}{2n} \sum_{k=1}^r t_k^2 + O(n^{-\frac{3}{2}}).$$

再对外侧 $\ln$ 展开得 $\ln \psi_Y(t_1, \dots, t_r)$ 为

$$-i \sum_{k=1}^r t_k \sqrt{np_k} + n \left(\frac{i}{\sqrt{n}} \sum_{k=1}^r t_k \sqrt{p_k} - \frac{1}{2n} \sum_{k=1}^r t_k^2 + \frac{1}{2} \left(\frac{i}{\sqrt{n}} \sum_{k=1}^r t_k \sqrt{p_k} \right)^2 + O(n^{-\frac{3}{2}}) \right),$$

整理得

$$\ln \psi_Y(t_1, \dots, t_r) = -\frac{1}{2} \sum_{k=1}^r t_k^2 - \frac{1}{2} \left(\sum_{k=1}^r t_k \sqrt{p_k} \right)^2 + O(n^{-\frac{1}{2}}).$$

取极限, 记

$$p = (\sqrt{p_1}, \dots, \sqrt{p_r})^T, \quad t = (t_1, \dots, t_r)^T,$$

则上式可以改写为二次型

$$\lim_{n \rightarrow \infty} \ln \psi_Y(t) = -\frac{1}{2} t^T t - \frac{1}{2} (t^T p)^2 = -\frac{1}{2} t^T (I - pp^T) t.$$

注意到 p 是单位向量, 可以作为第一个行向量扩展为正交阵 Q , 则考虑随机向量 $Z = QY$, 第一个分量

$$Z_1 = \sum_{k=1}^r \frac{N_k - np_k}{\sqrt{n}} = \frac{n - n}{\sqrt{n}} = 0,$$

于是根据正交阵不改变向量 2 范数, 有

$$K_n = \sum_{k=2}^r Z_k^2.$$

注意到

$$t^T Z = Z^T t = (QY)^T t = Y^T (Q^T t) = (Q^T t)^T Y,$$

计算特征函数

$$\psi_Z(t) = \mathbb{E} \left(\exp \left(i t^T Z \right) \right) = \mathbb{E} \left(\exp \left(i (Q^T t)^T Y \right) \right) = \psi_Y(Q^T t),$$

于是根据 Q 第一行为 p 其他各行与 p 正交, 有

$$\lim_{n \rightarrow \infty} \ln \psi_Z(t) = -\frac{1}{2} (Q^T t)^T (I - pp^T) (Q^T t) = -\frac{1}{2} \sum_{k=2}^r t_k^2,$$

根据连续性

$$\lim_{n \rightarrow \infty} \psi_Z(t) = \exp \left(-\frac{1}{2} \sum_{k=2}^r t_k^2 \right) = \prod_{k=2}^r e^{-\frac{1}{2} t_k^2},$$

这说明极限分布中 Z_k 是独立的标准正态分布, 而 K_n 的极限是 $r-1$ 个独立标准正态分布的平方和, 当然服从 χ_{r-1}^2 分布. $\square$

3.2.3 2×2 列联表

作为应用, 我们考察所谓 2×2 列联表, 即两个 Bernoulli 分布 $B(1, p_1)$ 和 $B(1, p_2)$ 是否独立的问题.

Example 3.10. (2×2 列联表) 设有两个 Bernoulli 分布 F_1 和 F_2 , 从联合分布中取样本, 得到 F_1 成功 F_2 成功, F_1 成功 F_2 失败, F_1 失败 F_2 成功, F_1 失败 F_2 失败的样本数分别为 a, b, c, d , 满足样本数 $n = a + b + c + d$. 考虑原假设是这两个 Bernoulli 分布独立, 则在此条件下 F_1 成功 F_2 成功有估计

$$\hat{p}_1 = \frac{a+b}{n} \frac{a+c}{n},$$

以此类推得到其余 $\hat{p}_k$, 则计算

$$K_n = \frac{\left(a - n \frac{a+b}{n} \frac{a+c}{n}\right)^2}{n \frac{a+b}{n} \frac{a+c}{n}} + \frac{\left(b - n \frac{b+a}{n} \frac{b+d}{n}\right)^2}{n \frac{b+a}{n} \frac{b+d}{n}} + \frac{\left(c - n \frac{c+a}{n} \frac{c+d}{n}\right)^2}{n \frac{c+a}{n} \frac{c+d}{n}} + \frac{\left(d - n \frac{d+b}{n} \frac{d+c}{n}\right)^2}{n \frac{d+b}{n} \frac{d+c}{n}}.$$

代入 $n = a + b + c + d$, 分子恰好相同, 即上式为

$$\frac{(ad - bc)^2}{n(a + b)(a + c)} + \frac{(ad - bc)^2}{n(b + a)(b + d)} + \frac{(ad - bc)^2}{n(c + a)(c + d)} + \frac{(ad - bc)^2}{n(d + b)(d + c)}.$$

通分得到

$$\frac{(ad - bc)^2}{n} \frac{(a + b + c + d)^2}{(a + b)(c + d)(a + c)(b + d)} = \frac{(ad - bc)^2(a + b + c + d)}{(a + b)(c + d)(a + c)(b + d)}.$$

根据**Theorem 3.2.**, 如果把上式视作关于 $n = a + b + c + d$ 的随机变量, 则由于未知参数为 p_1, p_2 是两个, 自由度 $r = 2$, 上式极限分布是 χ_1^2 . 记上式为 χ^2 , 则如果 χ^2 落在 χ_1^2 的高概率区间内, 则有理由接受原假设, 反之如果 χ^2 很大, 则有理由拒绝原假设, 即认为两个分布相关.

Chapter 4

分析学结论

4.1 广义积分

以下是本书可能涉及的积分运算结果, 读者可以在任何一本微积分或数学分析中找到证明. 我们不再赘述有关广义积分敛散性和积分交换次序的问题.

Theorem A.1.(Gamma 函数) Gamma 函数

$$\Gamma(s) = \int_0^{+\infty} x^{s-1} e^{-x} dx, \quad s > 0$$

满足 $\Gamma(s+1) = s\Gamma(s)$. 特别地, 在正整数 $n \in \mathbb{N}^*$ 上取值为 $\Gamma(n) = (n-1)!$.

Proof. 利用分部积分

$$\Gamma(s+1) = - \int_0^{+\infty} x^s de^{-x} = s \int_0^{+\infty} e^{-x} x^{s-1} dx - x^s e^{-x} \Big|_0^{+\infty} = s\Gamma(s).$$

特别地

$$\Gamma(1) = \int_0^{+\infty} e^{-x} dx = -e^{-x} \Big|_0^{+\infty} = 1,$$

归纳可知 $\Gamma(n) = (n-1)!$. □

Theorem A.2.(Beta 函数) Beta 函数

$$B(\alpha, \beta) = \int_0^1 x^{\alpha-1} (1-x)^{\beta-1} dx, \quad \alpha, \beta > 0$$

满足

$$B(\alpha, \beta) = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha+\beta)}.$$

Proof. 注意到对任意常数 $y > 0$, 有

$$\Gamma(\alpha) = \int_0^{+\infty} (xy)^{\alpha-1} e^{-xy} d(xy) = y^\alpha \int_0^{+\infty} x^{\alpha-1} e^{-xy} dx.$$

作换元 $x = \frac{y}{1+y}$ 可得

$$B(\alpha, \beta) = \int_0^{+\infty} \left(\frac{y}{1+y} \right)^{\alpha-1} \left(1 - \left(\frac{y}{1+y} \right) \right)^{\beta-1} d\left(\frac{y}{1+y} \right) = \int_0^{+\infty} \frac{y^{\alpha-1}}{(1+y)^{\alpha+\beta}} dy.$$

于是

$$B(\alpha, \beta) \Gamma(\alpha + \beta) = \int_0^{+\infty} \int_0^{+\infty} y^{\alpha-1} x^{\alpha+\beta-1} e^{-x(1+y)} dx dy.$$

先对 y 积分得

$$\int_0^{+\infty} y^{\alpha-1} e^{-xy} dy = x^{-\alpha} \Gamma(\alpha),$$

于是

$$B(\alpha, \beta) \Gamma(\alpha + \beta) = \Gamma(\alpha) \int_0^{+\infty} x^{\beta-1} e^{-x} dx = \Gamma(\alpha) \Gamma(\beta).$$

□

4.2 收敛定理

以下是本书可能涉及的积分收敛定理, 读者可以在任何一本实分析中找到证明.

Theorem B.1.(一致收敛定理) 设 $\{f_n\}$ 为有限正测度集 E 上的一列有界可测函数. 如果 $\{f_n\}$ 一致收敛到 f , 则

$$\lim_{n \rightarrow \infty} \int_E f_n(x) dx = \int_E \left(\lim_{n \rightarrow \infty} f_n(x) \right) dx = \int_E f(x) dx.$$

Proof. 由一致收敛和逐项有界可知极限函数有界, 且极限函数作为可测函数列的极限也可测. 任取 $\varepsilon > 0$, 依照一致有界存在 $N(\varepsilon) \in \mathbb{N}^*$, 使得当 $n > N(\varepsilon)$ 时

$$|f(x) - f_n(x)| < \frac{\varepsilon}{m(E)}.$$

于是有估计

$$\left| \int_E f(x) dx - \int_E f_n(x) dx \right| \leq \int_E |f(x) - f_n(x)| dx \leq \frac{\varepsilon}{m(E)} m(E) = \varepsilon.$$

令 $\varepsilon \rightarrow 0^+$ 即证. □

Theorem B.2.(有界收敛定理) 设 $\{f_n\}$ 为有限正测度集 E 上的一列可测函数. 如果 $\{f_n\}$ 一致有界 M 且点点收敛到 f , 则

$$\lim_{n \rightarrow \infty} \int_E f_n(x) dx = \int_E \left(\lim_{n \rightarrow \infty} f_n(x) \right) dx = \int_E f(x) dx.$$

Proof. 极限函数作为可测函数列的极限也可测且有界 M . 对任意 $\varepsilon > 0$, 依照 Egoroff 定理存在可测子集 $A \subseteq E$, 使得 $\{f_n\}$ 在 A 上一致收敛到 f 而 $m(E \setminus A) < \frac{\varepsilon}{4M}$. 根据一致收敛存在 $N(\varepsilon) \in \mathbb{N}^*$, 当 $n > N(\varepsilon)$ 时

$$|f_n(x) - f(x)| < \frac{\varepsilon}{2m(E)}.$$

于是有估计

$$\left| \int_E f(x) dx - \int_E f_n(x) dx \right| \leq \int_A |f(x) - f_n(x)| dx + \int_{E \setminus A} (|f(x)| + |f_n(x)|) < \varepsilon.$$

□

Theorem B.3.(Fatou) 设 $\{f_n\}$ 为 E 上的一列非负可测函数. 如果 $\{f_n\}$ 在 E 上几乎处处收敛到 f , 则

$$\int_E f(x) dx \leq \liminf_{n \rightarrow \infty} \int_E f_n(x) dx.$$

Proof. 在相差零测集 (不影响积分值) 的条件下, 不妨设在 E 上点点收敛. 依照 Lebesgue 积分的定义, 对任意 E 上在有限测度子集 $E_0 \subseteq E$ 外为零的有界可测函数 h 满足 $0 \leq h \leq f$, 令 $h_n = \min\{h, f_n\}$, M 为 h 的界, 则依照定义 $\{h_n\}$ 点点收敛到 h , 则根据有界收敛定理 **Theorem B.2**.

$$\lim_{n \rightarrow \infty} \int_E h_n(x) dx = \lim_{n \rightarrow \infty} \int_{E_0} h_n(x) dx = \int_{E_0} \left(\lim_{n \rightarrow \infty} h_n(x) \right) dx = \int_{E_0} h(x) dx = \int_E h(x) dx.$$

由于 $h_n \leq f_n$, 两边积分并取下确界得

$$\int_E h(x) dx = \liminf_{n \rightarrow \infty} \int_E h_n(x) dx \leq \liminf_{n \rightarrow \infty} \int_E f_n(x) dx.$$

依照非负可测函数的 Lebesgue 积分定义即证. $\square$

Theorem B.4.(单调收敛定理) 设 $\{f_n\}$ 为 E 上的一列非负可测函数, 在每一点处 $\{f_n(x)\}$ 单调上升. 如果 $\{f_n\}$ 在 E 上几乎处处收敛到 f , 则

$$\lim_{n \rightarrow \infty} \int_E f_n(x) dx = \int_E \left(\lim_{n \rightarrow \infty} f_n(x) \right) dx = \int_E f(x) dx.$$

Proof. 根据 Fatou 引理 **Theorem B.3** 即得

$$\int_E f(x) dx \leq \liminf_{n \rightarrow \infty} \int_E f_n(x) dx.$$

依照单调性

$$f_n \leq f \implies \int_E f_n(x) dx \leq \int_E f(x) dx \implies \limsup_{n \rightarrow \infty} \int_E f_n(x) dx \leq \int_E f(x) dx,$$

两式结合即证. $\square$

Theorem B.5.(Lebesgue 控制收敛定理) 设 $\{f_n\}$ 为 E 上的一列可测函数几乎处处收敛到 f , $\{g_n\}$ 为 E 上的一列非负可测函数几乎处处收敛到可积函数 g , 使得 $|f_n(x)| \leq g_n(x)$ 恒成立. 若

$$\lim_{n \rightarrow \infty} \int_E g_n(x) dx = \int_E g(x) dx < \infty,$$

则

$$\lim_{n \rightarrow \infty} \int_E f_n(x) dx = \int_E \left(\lim_{n \rightarrow \infty} f_n(x) \right) dx = \int_E f(x) dx.$$

Proof. 不妨设收敛均为点点收敛. 注意到 $\{g_n - f_n\}$ 和 $\{g_n + f_n\}$ 是非负可测函数列, 点点收敛到 $g - f$ 和 $g + f$, 根据 Fatou 引理 **Theorem B.3** 即得

$$\int_E (g(x) - f(x)) dx \leq \liminf_{n \rightarrow \infty} \int_E (g_n(x) - f_n(x)) dx.$$

由于所有积分均被 g 的积分控制从而有限, 于是

$$\int_E g(x)dx - \int_E f(x)dx \leq \liminf_{n \rightarrow \infty} \int_E g_n(x)dx - \limsup_{n \rightarrow \infty} \int_E f_n(x)dx.$$

由于 g_n 积分收敛到 g 的积分, 即得

$$\limsup_{n \rightarrow \infty} \int_E f_n(x)dx \leq \int_E f(x)dx.$$

同理可证

$$\liminf_{n \rightarrow \infty} \int_E f_n(x)dx \geq \int_E f(x)dx,$$

两式结合即证. □

Theorem B.6.(Scheffe) 设 $\{f_n\}$ 为 E 上的一列可积函数, 几乎处处收敛到可积函数 f . 则

$$\lim_{n \rightarrow \infty} \int_E |f(x) - f_n(x)|dx = 0 \iff \lim_{n \rightarrow \infty} \int_E |f_n(x)|dx = \int_E |f(x)|dx.$$

Proof. 先证必要性. 注意到

$$|f_n(x)| \leq |f(x) - f_n(x)| + |f(x)| := g_n(x),$$

于是 g_n 点点收敛到 f , 满足

$$\lim_{n \rightarrow \infty} \int_E g_n(x)dx = \lim_{n \rightarrow \infty} \int_E |f(x) - f_n(x)|dx + \int_E |f(x)|dx = \int_E |f(x)|dx < \infty,$$

根据 Lebesgue 控制收敛定理 **Theorem B.5.** 即证.

再证充分性. 此时取

$$g_n(x) = |f(x)| + |f_n(x)| \geq |f(x) - f_n(x)|,$$

则

$$\lim_{n \rightarrow \infty} \int_E g_n(x)dx = \lim_{n \rightarrow \infty} \int_E |f_n(x)|dx + \int_E |f(x)|dx = 2 \int_E |f(x)|dx < \infty,$$

根据 Lebesgue 控制收敛定理 **Theorem B.5.**

$$\lim_{n \rightarrow \infty} \int_E |f(x) - f_n(x)|dx = \lim_{n \rightarrow \infty} \int_E 0dx = 0.$$

□

Theorem B.7.(Slutsky) 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 为概率空间, 其上的随机变量序列 $\{X_n\}$ 依分布收敛到 X , $\{Y_n\}$ 依概率收敛到常数 c , 则只要以下有意义, 四则运算 $\{X_n + Y_n\}$, $\{X_n Y_n\}$, $\{X_n / Y_n\}$ 分别依分布收敛到 $X + c$, cX 和 X/c .

Proof. 要证依分布收敛, 相当于证明在连续点处点点收敛, 以下只考虑连续的情形. 对任意 $\varepsilon > 0$, 有

$$\mathbb{P}(X_n + Y_n \leq x) \leq \mathbb{P}(X_n + Y_n \leq x, |Y_n - c| < \varepsilon) + \mathbb{P}(|Y_n - c| \geq \varepsilon).$$

第一项不超过

$$\mathbb{P}(X_n \leq x - c + \varepsilon, |Y_n - c| < \varepsilon) \leq \mathbb{P}(X_n \leq x - c + \varepsilon),$$

而第二项在 $n \rightarrow \infty$ 时趋于 0 (依概率收敛的定义), 因此取极限得

$$\limsup_{n \rightarrow \infty} \mathbb{P}(X_n + Y_n \leq x) \leq \lim_{n \rightarrow \infty} \mathbb{P}(X_n \leq x - c + \varepsilon) = F(x - c + \varepsilon),$$

最后一个等号是依分布收敛的定义. 同理可得

$$\mathbb{P}(X_n + Y_n \leq x) \geq \mathbb{P}(X_n \leq x - c - \varepsilon) - \mathbb{P}(|Y_n - c| \geq \varepsilon),$$

取极限得

$$\liminf_{n \rightarrow \infty} \mathbb{P}(X_n + Y_n \leq x) \geq \lim_{n \rightarrow \infty} \mathbb{P}(X_n \leq x - c - \varepsilon) = F(x - c - \varepsilon).$$

由于 F 连续, 在以上两式取 $\varepsilon \rightarrow 0^+$ 得到

$$\lim_{n \rightarrow \infty} \mathbb{P}(X_n + Y_n \leq x) = F(x - c),$$

这就是 $X + c$ 的分布函数, 即依分布收敛到 $X + c$. 对乘法的情形, 用 $\frac{x}{c \pm \varepsilon}$ 代替 $x - c \pm \varepsilon$ 即可, 除法的情形也类似. $\square$

Theorem B.8.(连续映射定理) 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 为概率空间, 其上的随机变量序列 $\{X_n\}$ 几乎处处/依概率收敛到 X . 对任意连续函数 $\varphi: \mathbb{R} \rightarrow \mathbb{R}$, 有随机变量序列 $\{\varphi(X_n)\}$ 几乎处处/依概率收敛到 $\varphi(X)$.

Proof. 几乎处处的情形是显然的, 因为连续函数保持极限, 有几乎处处

$$\lim_{n \rightarrow \infty} \varphi(X_n(\omega)) = \varphi\left(\lim_{n \rightarrow \infty} X_n(\omega)\right) = \varphi(X(\omega)).$$

对依概率收敛的情形, 先讨论 φ 在紧集 $[-n, n]$ 上连续. 对任意 $\varepsilon > 0$, 由紧集上的连续函数一致连续, 对每一点 $x \in \mathbb{R}$ 存在 $\delta(\varepsilon) > 0$, 使得只要 $|t - x| < \delta(\varepsilon)$, 就有 $|\varphi(t) - \varphi(x)| < \varepsilon$. 于是有估计

$$\mathbb{P}(|\varphi(X_n) - \varphi(X)| \geq \varepsilon) \leq \mathbb{P}(|X_n - X| \geq \delta(\varepsilon)) + \mathbb{P}(|\varphi(X_n) - \varphi(X)| \geq \varepsilon, |X_n - X| < \delta(\varepsilon)).$$

由 $\delta(\varepsilon)$ 的定义第二项恒为 0, 因此两边取极限, 由 $\{X_n\}$ 依概率收敛可得

$$\lim_{n \rightarrow \infty} \mathbb{P}(|\varphi(X_n) - \varphi(X)| \geq \varepsilon) \leq \lim_{n \rightarrow \infty} \mathbb{P}(|X_n - X| \geq \delta(\varepsilon)) = 0.$$

现在考虑 $\mathbb{R}$ 上连续的情形, 由于 $\mathbb{P}(\Omega) = 1$, 对任意 $\eta > 0$, 存在 $M(\eta) \in \mathbb{N}^*$, 使得

$$\mathbb{P}(|X_n| + |X| \geq M(\eta)) \leq \eta,$$

于是取 $n = M(\eta)$, 用同样方法可得

$$\mathbb{P}(|\varphi(X_n) - \varphi(X)| \geq \varepsilon) \leq \mathbb{P}(|X_n - X| \geq \delta(\varepsilon, \eta)) + \eta.$$

依次取 $n \rightarrow \infty$ 和 $\eta \rightarrow 0$ 即证. □

Theorem B.9. (Borel-Cantelli) 设 E_n 是一列可测集合, 若级数

$$\sum_{n=1}^{\infty} m(E_n) < \infty,$$

则

$$m\left(\limsup_{n \rightarrow \infty} E_n\right) = 0.$$

Proof. 根据测度的连续性和可列可加性

$$m\left(\limsup_{n \rightarrow \infty} E_n\right) = \lim_{m \rightarrow \infty} m\left(\bigcup_{n=m}^{\infty} E_n\right) \leq \lim_{m \rightarrow \infty} \sum_{n=m}^{\infty} m(E_n).$$

注意到收敛性

$$\lim_{m \rightarrow \infty} \sum_{n=m}^{\infty} m(E_n) = \sum_{n=1}^{\infty} m(E_n) - \lim_{m \rightarrow \infty} \sum_{n=1}^{m-1} m(E_n) = 0.$$

即得

$$m\left(\limsup_{n \rightarrow \infty} E_n\right) = 0,$$

即 (除了上述零测集以外) 几乎处处的点至多属于有限多个 E_n . □