数理统计讲义

minamomo

Thursday 16th April, 2026

References:

[1] 数理统计 (第三版), 韦来生, 2025.
[2] 概率论, 复旦大学, 1979.
[3] Real Analysis(4th edition), Royden, 2020.

Marks:

1. 概率空间 Ω, 样本空间 $\mathscr{X}$, 随机变量 (样本)X(r.v.), 随机向量 $\mathbf{X}$, 分布函数 F(d.f.), 密度函数 f, 概率 $\mathbb{P}$, 期望 $\mathbb{E}$, 方差 Var, 协方差 Cov, 相关系数 ρ.
2. Gamma 函数 Γ, Beta 函数 B.
3. 均匀分布 U, 正态分布 N, 指数分布 Exp, 卡方分布 χ_n^2, 学生分布 t_n.
4. 独立同分布 i.i.d., 几乎处处 a.e./a.s., 依概率 pr., 依分布 dist.

1. **Definition**.
2. **Theorem**.
3. **Example**.
4. **Exercise**.
5. **Algorithm**

Preface

“概率论在某种程度上是数学分析的习题课, 数理统计就是数学分析和概率论的习题课的感觉一样.”

2026.3.6

“所有的模型都是错的.”

2026.4.10

本讲义根据 2026 年春数理统计课程内容整理.

概率论所研究对象是以各种形式给出的分布, 包括概率 P, 分布 F 以及密度 f, 连同分布的各种特征, 包括期望 $\mathbb{E}$, 方差 Var, 协方差 Cov 等. 总而言之, 概率论的目标在于对给定的分布, 分析这个分布下随机事件发生的特征并加以描述.

统计学的目标则恰恰相反. 统计学的研究对象是概率论的研究结果, 即实际发生的随机事件, 而统计学的研究目标则是概率论的研究对象, 即分析随机事件数据服从的分布. 对分布本身加以估计, 就称为统计估计, 对分布带来的结果加以估计, 就称为假设检验, 应用估计的结果, 就称为决策理论.

minamomo

2026.4 于中国上海

This page intentionally left blank.

Contents

1 统计学基础 **7**

1.1 样本与分布 7

1.2 正态分布的统计量 12

1.3 χ^2 分布, t 分布与 F 分布 15

1.3.1 χ^2 分布 15

1.3.2 t 分布 18

1.3.3 F 分布 21

1.4 顺序统计量 23

1.5 渐近分布 * 28

2 统计估计 **33**

2.1 点估计 33

2.2 点估计方法 38

2.2.1 矩估计 38

2.2.2 极大似然估计 40

3 假设检验 **43**

4 决策理论 **45**

5 分析结论表 **47**

5.1 广义积分 47

5.2 收敛定理 49

This page intentionally left blank.

Chapter 1

统计学基础

1.1 样本与分布

总体和样本是数理统计的基础研究对象.

Definition 1.1.(总体和样本) **总体 (population)** 是指研究对象所满足的, 实际上的分布 F. 总体分布在实际问题中往往是存在但未知的. 服从总体分布的随机变量称为**样本 (sample)**. 样本往往被认为是已知的. 样本的所有可能取值的集合称为**样本空间 (sample space)**.

统计学的一个目标是通过样本还原总体分布, 即将总体分布近似地表示成样本 $\{X_k\}_{k=1}^n$ 的函数.

作为例子, 我们来看概率论是如何通过分布分析随机事件的特征的.

Example 1.1.(正态分布的总体方差) 给定 n 维随机向量 $\mathbf{X}$, 每个分量独立同分布, 服从正态分布 $N(\mu, \sigma^2)$, 通过这些随机变量可以构造若干新随机变量, 例如

$$A = \frac{1}{n}\sum_{k=1}^{n}(X_k - \mu)^2$$

就是典型的例子. 我们求其期望和方差. 根据独立性

$$\mathbb{E}(A) = \mathbb{E}\left((X_1 - \mu)^2\right) = \mathbb{E}\left(X_1^2 - 2X_1\mu + \mu^2\right).$$

注意依照方差的定义以及正态分布的性质

$$\mathbb{E}\left(X_1^2\right) - \mathbb{E}(X_1)^2 = \mathrm{Var}(X_1) \implies \mathbb{E}\left(X_1^2\right) = \mu^2 + \sigma^2,$$

代入得

$$\mathbb{E}(A) = \mu^2 + \sigma^2 - 2\mu^2 + \mu^2 = \sigma^2.$$

考虑 $Y_k = X_k - \mu$ 服从 $N(0, \sigma^2)$, 有

$$\mathrm{Var}(A) = \mathrm{Var}\left(\frac{1}{n}\sum_{k=1}^{n} Y_k^2\right) = \frac{1}{n^2}\mathbb{E}\left(\left(\sum_{k=1}^{n} Y_k^2\right)^2\right) - \sigma^4.$$

对平方项展开, 并利用独立性得

$$\mathbb{E}\left(\left(\sum_{k=1}^{n} Y_k^2\right)^2\right) = \mathbb{E}\left(\sum_{k=1}^{n} Y_k^4 + \sum_{i\neq j}(Y_iY_j)^2\right) = n\mathbb{E}\left(Y_1^4\right) + n(n-1)\mathbb{E}\left(Y_1^2\right)^2.$$

根据期望的定义

$$\mathbb{E}\left(Y_1^4\right) = \int_{\mathbb{R}} x^4 f(x)\mathrm{d}x = \frac{1}{\sqrt{2\pi}\sigma}\int_{\mathbb{R}} x^4 \exp\left(-\frac{x^2}{2\sigma^2}\right)\mathrm{d}x.$$

作分部积分得

$$\mathbb{E}\left(Y_1^4\right) = \frac{1}{\sqrt{2\pi}\sigma}\int_{\mathbb{R}} x^4 \exp\left(-\frac{x^2}{2\sigma^2}\right)\mathrm{d}x = \frac{-\sigma^2}{\sqrt{2\pi}\sigma}\int_{\mathbb{R}} x^3 \mathrm{d}\exp\left(-\frac{x^2}{2\sigma^2}\right),$$

即得

$$\mathbb{E}\left(Y_1^4\right) = \frac{3\sigma^2}{\sqrt{2\pi}\sigma}\int_{\mathbb{R}} x^2 \exp\left(-\frac{x^2}{2\sigma^2}\right)\mathrm{d}x = 3\sigma^2\mathbb{E}\left(Y_1^2\right) = 3\sigma^4.$$

代入得

$$\mathrm{Var}(A) = \frac{n\mathbb{E}\left(Y_1^4\right) + n(n-1)\mathbb{E}\left(Y_1^2\right)^2}{n^2} - \sigma^4 = \frac{2}{n}\sigma^4.$$

下面构造的随机变量与之对应.

Example 1.2.(正态分布的样本方差) 给定 n 维随机向量 $\mathbf{X}$, 每个分量独立同分布, 服从正态分布 $N(\mu, \sigma^2)$, 定义随机变量

$$B = \frac{1}{n-1}\sum_{k=1}^{n}(X_k - \overline{X})^2.$$

注意到可以作变形

$$
\begin{aligned}
B &= \frac{1}{n-1}\sum_{k=1}^{n}(X_k-\overline{X})^2 \\
&= \frac{1}{n-1}\sum_{k=1}^{n}\left(X_k^2-2X_k\overline{X}+\overline{X}^2\right) \\
&= \frac{1}{n-1}\left(\sum_{k=1}^{n}X_k^2-2n\overline{X}^2+n\overline{X}^2\right) \\
&= \frac{1}{n(n-1)}\left(n\sum_{k=1}^{n}X_k^2-\left(\sum_{k=1}^{n}X_k\right)^2\right) \\
&= \frac{1}{n(n-1)}\left(n\sum_{k=1}^{n}X_k^2-\sum_{k=1}^{n}X_k^2-\sum_{i\neq j}X_iX_j\right) \\
&= \frac{1}{n}\sum_{k=1}^{n}X_k^2-\frac{1}{n(n-1)}\sum_{i\neq j}X_iX_j.
\end{aligned}
$$

取期望即得

$$\mathbb{E}(B)=\mathbb{E}\left(X_1^2\right)-\mathbb{E}(X_1)^2=\mathrm{Var}(X_1)=\sigma^2.$$

由于 X_k 同分布, 在只有一个变量时我们也直接记作 X. 为求方差, 写为

$$\mathrm{Var}(B)=\mathrm{Cov}(B,B),$$

即

$$\mathrm{Cov}\left(\frac{1}{n}\sum_{k=1}^{n}X_k^2-\frac{1}{n(n-1)}\sum_{i\neq j}X_iX_j,\frac{1}{n}\sum_{k=1}^{n}X_k^2-\frac{1}{n(n-1)}\sum_{i\neq j}X_iX_j\right).$$

依照定义协方差具有双线性, 于是可以逐项展开, 且根据对称性有

$$\mathrm{Var}(B)=\mathrm{Cov}\left(X_1^2-X_1X_2,\frac{1}{n}\sum_{k=1}^{n}X_k^2-\frac{1}{n(n-1)}\sum_{i\neq j}X_iX_j\right).$$

注意到独立变量的协方差为 0, 可知上式为

$$\frac{1}{n}\mathrm{Cov}\left(X_1^2,X_1^2-2X_1X_2\right)-\frac{1}{n}\mathrm{Cov}\left(X_1X_2,X_1^2+X_2^2-2\frac{n-2}{n-1}(X_1+X_2)X_3-\frac{2X_1X_2}{n-1}\right).$$

依照定义和对称性计算得

$$
\begin{aligned}
\mathrm{Var}(B)=&\frac{1}{n}\left(\mathrm{Cov}\left(X_1^2,X_1^2\right)-4\,\mathrm{Cov}\left(X_1^2,X_1X_2\right)\right) \\
&+\frac{1}{n(n-1)}\left(4(n-2)\,\mathrm{Cov}\left(X_1X_2,X_1X_3\right)+2\,\mathrm{Cov}\left(X_1X_2,X_1X_2\right)\right) \\
=&\frac{1}{n}\left(\mathbb{E}\left(X_1^4\right)-\mathbb{E}\left(X_1^2\right)^2-4\mathbb{E}\left(X_1^3X_2\right)+4\mathbb{E}\left(X_1^2\right)\mathbb{E}\left(X_1X_2\right)\right) \\
&+\frac{4(n-2)}{n(n-1)}\left(\mathbb{E}\left(X_1^2X_2X_3\right)-\mathbb{E}\left(X_1X_2\right)\mathbb{E}\left(X_1X_3\right)\right) \\
&+\frac{2}{n(n-1)}\left(\mathbb{E}\left(X_1^2X_2^2\right)-\mathbb{E}\left(X_1X_2\right)^2\right).
\end{aligned}
$$

依照独立性有

$$\begin{aligned}\operatorname{Var}(B) =& \frac{1}{n}\left(\mathbb{E}\left(X^4\right)-\mathbb{E}\left(X^2\right)^2-4\mathbb{E}\left(X^3\right)\mathbb{E}\left(X_1\right)+4\mathbb{E}\left(X^2\right)\mathbb{E}\left(X\right)^2\right)\\ &+\frac{4(n-2)}{n(n-1)}\left(\mathbb{E}\left(X^2\right)\mathbb{E}\left(X\right)^2-\mathbb{E}\left(X\right)^4\right)+\frac{2}{n(n-1)}\left(\mathbb{E}\left(X^2\right)^2-\mathbb{E}\left(X\right)^4\right).\end{aligned}$$

利用矩生成函数或特征函数可以计算 n 阶矩

$$\mathbb{E}\left(X\right)=\mu,\quad \mathbb{E}\left(X^2\right)=\mu^2+\sigma^2,\quad \mathbb{E}\left(X^3\right)=\mu^3+3\mu\sigma^2,\quad \mathbb{E}\left(X^4\right)=\mu^4+6\mu^2\sigma^2+3\sigma^4,$$

代入计算得

$$\operatorname{Var}(B)=\frac{2}{n-1}\sigma^4.$$

由此我们可以计算两者之间的关系.

Example 1.3.(总体方差与样本方差的相关系数) **Example 1.1.**和**Example 1.2.**中定义的随机变量 A, B, 可以计算协方差

$$\operatorname{Cov}(A,B)=\operatorname{Cov}\left((X_1-\mu)^2,\frac{1}{n}\sum_{k=1}^{n}X_k^2-\frac{1}{n(n-1)}\sum_{i\neq j}X_iX_j\right).$$

仍然依照独立性

$$\operatorname{Cov}(A,B)=\operatorname{Cov}\left((X_1-\mu)^2,\frac{1}{n}X_1^2-\frac{2}{n}X_1X_2\right)=\frac{1}{n}\operatorname{Cov}\left(X_1^2-2\mu X_1,X_1^2-2X_1X_2\right).$$

展开计算得

$$\operatorname{Cov}(A,B)=\frac{2}{n}\sigma^4.$$

依照相关系数的定义

$$\rho(A,B)=\frac{\operatorname{Cov}(A,B)}{\sqrt{\operatorname{Var}(A)\operatorname{Var}(B)}}=\frac{\frac{2}{n}\sigma^4}{\sqrt{\frac{2}{n}\sigma^4\cdot\frac{2}{n-1}\sigma^4}}=\sqrt{\frac{n-1}{n}}.$$

我们看到以上样本具有很好的性质: 独立性允许我们分别计算期望, 而同分布允许我们用对称性化简, 由此引出了如下定义.

Definition 1.2.(简单随机样本) 独立同分布 (i.i.d.) 的有限个样本称为简单随机样本.

简单随机样本的分布函数和密度函数就是

$$F_n(\mathbf{x})=\prod_{k=1}^{n}F(x_k),\quad f_n(\mathbf{x})=\prod_{k=1}^{n}f(x_k).$$

简单随机样本对还原总体分布提供了很好的条件, 这就是统计推断. 然而有限个样本不足以确定某个分布, 因此需要假定某种分布的类型. 选定某种分布类型, 例如 Poisson 分布, 正态分布等, 其所有可能分布称为分布族, 参数的全体取值称为参数空间.

利用样本可以构造出分布的若干特征, 用来近似总体分布的特征.

Definition 1.3.(统计量) 给定 n 个样本 $\{X_k\}_{k=1}^n$, 任何一个样本的函数

$$\varphi(X_1, X_2, \ldots, X_n)$$

称为统计量.

尤其要强调的是统计量的函数中不能含有总体分布的参数, 而只能由样本和 $\mathbb{R}$ 中元以及若干函数构成. 均值 $\overline{X}$, 方差 $\mathrm{Var}(X)$, 中位数, 最大值等都是常见的统计量.

我们可以用函数编码样本的信息.

Definition 1.4.(经验分布函数) 样本 $\{X_k\}_{k=1}^n$ 的**经验分布函数 (empirical distribution function, EDF)** 定义为

$$F_n(x) = \frac{1}{n}\sum_{k=1}^{n}\chi(X_k \le x), \quad \chi(P) = \begin{cases} 1, & P = \mathbf{T}, \\ 0, & P = \mathbf{F}. \end{cases}$$

1.2 正态分布的统计量

在这一部分, 我们主要研究各个统计量作为随机变量的数值特征.

Example 1.4.(正态分布顺序统计量的期望) 设 $\{X_k\}_{k=1}^n$ 独立同分布, 服从标准正态分布 $N(0,1)$. 考虑其最大值

$$X = \max_{1\le k\le n}\{X_k\}$$

的概率分布

$$F(x) = \mathbb{P}(X \le x) = \prod_{k=1}^n \mathbb{P}(X_k \le x) = \Phi(x)^n.$$

于是期望

$$\mathbb{E}(X) = \int_{\mathbb{R}} x\mathrm{d}\mathbb{P}(X \le x) = -\int_{\mathbb{R}} x\mathrm{d}\left(1-\Phi(x)^n\right) = \int_{\mathbb{R}} \left(1-\Phi(x)^n\right)\mathrm{d}x.$$

其展开的主项为 $\sqrt{2\ln n}$.

对样本 $\{X_k\}_{k=1}^n$, 我们尤其关心以下两个先前讨论过的统计量.

Definition 1.5.(样本均值和样本方差) 给定 n 个样本 $\{X_k\}_{k=1}^n$, 定义**样本均值**

$$\overline{X} = \frac{1}{n}\sum_{k=1}^n X_k$$

和**样本方差**

$$S^2 = \frac{1}{n-1}\sum_{k=1}^n (X_k - \overline{X})^2.$$

我们先作简要分析.

Example 1.5.(样本均值和样本方差的线性代数刻画) 给定 n 个样本 $\{X_k\}_{k=1}^n$, 注意到

$$\overline{X} = \frac{1}{n}\sum_{k=1}^n X_k = \frac{1}{n}\begin{bmatrix}1 & 1 & \cdots & 1\end{bmatrix}\begin{bmatrix}X_1\\X_2\\\vdots\\X_n\end{bmatrix} = \frac{1}{n}\mathbf{1}^T\mathbf{X},$$

以及

$$S^2 = \frac{1}{n-1}\sum_{k=1}^n (X_k - \overline{X})^2 = \frac{n}{n-1}\left(\frac{1}{n}\sum_{k=1}^n X_k^2 - \overline{X}^2\right),$$

展开得

$$S^2 = \frac{n}{n-1}\left(\frac{1}{n}\mathbf{X}^T\mathbf{X} - \frac{1}{n^2}\mathbf{X}^T\mathbf{1}\mathbf{1}^T\mathbf{X}\right) = \frac{1}{n-1}\mathbf{X}^T\left(I - \frac{1}{n}\mathbf{1}\mathbf{1}^T\right)\mathbf{X}.$$

这启示我们把 $\mathbf{1}$ 单位化为 $\mathbf{1} = \|\mathbf{1}\|\hat{\mathbf{1}} = \sqrt{n}\mathbf{e}_1$, 则样本均值和样本方差可以写为

$$\overline{X} = \frac{1}{\sqrt{n}}\mathbf{e}_1\mathbf{X}, \quad S^2 = \frac{1}{n-1}\mathbf{X}^T\left(I - \mathbf{e}_1\mathbf{e}_1^T\right)\mathbf{X}.$$

对单位向量 $\mathbf{e}_1$, 一个自然的想法是将之扩充为一组标准正交基 $\{\mathbf{e}_k\}_{k=1}^n$, 于是

$$S^2 = \frac{1}{n-1}\mathbf{X}^T\left(I - \mathbf{e}_1\mathbf{e}_1^T\right)\mathbf{X} = \frac{1}{n-1}\mathbf{X}^T\left(\sum_{k=2}^n \mathbf{e}_k\mathbf{e}_k^T\right)\mathbf{X} = \frac{1}{n-1}\sum_{k=2}^n(\mathbf{e}_k^T\mathbf{X})^2.$$

由于这是一组标准正交基, 构成正交矩阵 $Q = \begin{bmatrix}\mathbf{e}_1 & \mathbf{e}_2 & \cdots & \mathbf{e}_n\end{bmatrix}$, 于是 $\mathbf{e}_k^T\mathbf{X}$ 恰好是 $Q^T\mathbf{X}$ 的 k-分量. 这表明样本均值可以看作 $\mathbf{Y} = Q^T\mathbf{X}$ 的 1-分量, 而样本方差可以看作 $\mathbf{Y}$ 的后 $n-1$ 个分量的平方均值.

上例说明在适当的线性变换下, 样本均值和样本方差都可以看作某种均值, 从而简化讨论. 因此有必要研究一些分布下的样本在线性变换, 尤其是正交变换下的性质.

Theorem 1.1.(正态分布的正交不变性) 给定 n 个样本 $\{X_k\}_{k=1}^n$ 独立同正态分布 $N(\mu, \sigma^2)$, 则对正交变换 Q, $\mathbf{Y} = Q\mathbf{X}$ 的各个分量也独立, 且服从正态分布. 特别地, 当 $\mu = 0$ 时, $\mathbf{Y}$ 的各个分量独立同分布 $N(0, \sigma^2)$.

Proof. 先考虑对 $\mathbf{X}$ 作一般的线性组合

$$L(\mathbf{X}) = \sum_{k=1}^n c_k X_k,$$

根据特征函数理论, 对每个 $X = X_k$ 有

$$\psi_X(t) = \mathbb{E}\left(\exp\left(\mathrm{i}tX\right)\right) = \exp\left(\mathrm{i}\mu t - \frac{1}{2}\sigma^2 t^2\right),$$

可知

$$\psi_{L(\mathbf{X})}(t) = \mathbb{E}\left(\exp\left(\mathrm{i}t\sum_{k=1}^n c_k X_k\right)\right) = \prod_{k=1}^n \mathbb{E}\left(\exp(\mathrm{i}c_k t X_k)\right),$$

代入展开得

$$\psi_{L(\mathbf{X})}(t) = \exp\left(\mathrm{i}\mu t\sum_{k=1}^n c_k - \frac{1}{2}\sigma^2 t^2\sum_{k=1}^n c_k^2\right),$$

这就说明 $L(\mathbf{X})$ 服从正态分布

$$L(\mathbf{X}) \sim N\left(\mu\sum_{k=1}^n c_k, \sigma^2\sum_{k=1}^n c_k^2\right).$$

现在考虑正交矩阵 Q, 则 $\mathbf{Y} = Q\mathbf{X}$ 的每个分量服从正态分布

$$Y_i \sim N\left(\mu\sum_{k=1}^n a_{ik}, \sigma^2\sum_{k=1}^n a_{ik}^2\right) = N\left(\mu\sum_{k=1}^n a_{ik}, \sigma^2\right).$$

为证独立性, 只要计算协方差. 根据协方差的双线性可知

$$\mathrm{Cov}(Y_i, Y_j) = \sum_{k=1}^{n}\sum_{l=1}^{n} a_{ik}a_{jl}\,\mathrm{Cov}(X_k, X_l) = \sigma^2 \sum_{k=1}^{n} a_{ik}a_{jk} = \sigma^2 (Qe_i)^T (Qe_j).$$

根据正交矩阵的性质, $i \neq j$ 时上式为 0, 于是 $\mathbf{Y}$ 各分量独立. 最后当 $\mu = 0$ 时, 代入 Y_i 的分布可知独立同分布. □

结合**Example 1.5.**的讨论, 由于样本均值和样本方差本质分别依赖 Y_1 以及 $\{Y_k\}_{k=2}^n$, 从而也是独立的. 样本均值是容易计算的.

$$\overline{X} = \sum_{k=1}^{n} \frac{1}{n} X_k \sim N\left(\mu, \frac{\sigma^2}{n}\right).$$

为了讨论样本方差, 由于这是 $n-1$ 个独立正态分布样本的平方和, 只要讨论此种形式的密度函数. 我们暂时只考虑独立同分布的情形.

Example 1.6.(正态分布的样本方差) 给定样本 $\{X_k\}_{k=1}^n$ 独立同正态分布 $N(0, \sigma^2)$, 则样本方差

$$S^2 = \frac{1}{n-1}\sum_{k=2}^{n} Y_k^2.$$

根据**Theorem 1.1.**的结果, 每个 Y_k 服从正态分布 $N(0, \sigma^2)$, 于是特征函数

$$\psi_{Y^2}(t) = \mathbb{E}\left(\exp\left(\mathrm{i}tY^2\right)\right) = \frac{1}{\sqrt{2\pi}\sigma}\int_{\mathbb{R}} \exp\left(\mathrm{i}tx^2 - \frac{1}{2\sigma^2}x^2\right)\mathrm{d}x = (1 - 2\mathrm{i}\sigma^2 t)^{-\frac{1}{2}}.$$

于是 S^2 的特征函数

$$\psi_{S^2}(t) = \left(1 - \frac{2\mathrm{i}\sigma^2}{n-1}t\right)^{-\frac{n-1}{2}}.$$

计算密度函数

$$f_{S^2}(x) = \frac{1}{2\pi}\int_{\mathbb{R}} \mathrm{e}^{-\mathrm{i}tx}\left(1 - \frac{2\mathrm{i}\sigma^2}{n-1}t\right)^{-\frac{n-1}{2}}\mathrm{d}t = \left(\frac{n-1}{2\sigma^2}\right)^{\frac{n-1}{2}} \frac{x^{\frac{n-1}{2}-1}}{\Gamma\left(\frac{n-1}{2}\right)} \exp\left(-\frac{(n-1)x}{2\sigma^2}\right).$$

1.3 χ^2 分布, t 分布与 F 分布

1.3.1 χ^2 分布

独立正态分布的平方和称为 χ^2 **分布**.

Definition 1.6.(χ^2 分布) 给定 n 个样本 $\{X_k\}_{k=1}^n$ 独立同标准正态分布, 称随机变量

$$\xi = \sum_{k=1}^n X_k^2$$

服从的分布为自由度为 n 的 χ^2 分布, 记作 $\xi \sim \chi_n^2$.

我们可以计算其密度函数.

Theorem 1.2.(χ^2 分布的密度函数) 设 ξ 是服从自由度为 n 的 χ^2 分布的随机变量, 则其概率密度函数为

$$f_n(x) = \begin{cases} \frac{1}{2^{\frac{n}{2}}\Gamma\left(\frac{n}{2}\right)} x^{\frac{n}{2}-1}\mathrm{e}^{-\frac{x}{2}}, & x > 0, \\ 0, & x \le 0. \end{cases}$$

其中

$$\Gamma(t) = \int_0^{+\infty} x^{t-1}\mathrm{e}^{-x}\mathrm{d}x.$$

Proof. 依照概率分布的定义

$$F_n(x) = \mathbb{P}\left(\sum_{k=1}^n X_k^2 \le x\right) = \int_{\sum_{k=1}^n x_k^2 \le x} \left(\frac{1}{\sqrt{2\pi}}\right)^n \exp\left(-\frac{1}{2}\sum_{k=1}^n x_k^2\right) \mathrm{d}x_1 \cdots \mathrm{d}x_n.$$

考虑换元

$$\begin{cases} x_1 = \rho\cos\theta_1\cos\theta_2\cdots\cos\theta_{n-1}, \\ x_2 = \rho\cos\theta_1\cos\theta_2\cdots\sin\theta_{n-1}, \\ x_3 = \rho\cos\theta_1\cos\theta_2\cdots\sin\theta_{n-2}, \\ \cdots, \\ x_n = \rho\sin\theta_1. \end{cases}$$

相应的 Jacobi 行列式为

$$\det(J) = \rho^{n-1}\varphi(\theta),$$

其中 $\varphi(\theta)$ 表示只与 $\{\theta_k\}_{k=1}^{n-1}$ 有关的函数. 此后我们将任意常数记作待定的 C_n, 得到

$$F_n(x) = C_n \int_{\rho^2 \le x} \exp\left(-\frac{1}{2}\rho^2\right) \rho^{n-1}\varphi(\theta)\mathrm{d}\rho\mathrm{d}\theta_1\cdots\mathrm{d}\theta_{n-1}.$$

注意到区域 $\rho^2 \le x$ 相当于 $\rho \in [0, \sqrt{x}]$ 而 θ_k 在固定范围内变化, 即 θ 的范围不依赖于 x, 从而被视作常数 C_n 的部分, 于是

$$F_n(x) = \begin{cases} C_n \int_0^{\sqrt{x}} \exp\left(-\frac{1}{2}\rho^2\right) \rho^{n-1} \mathrm{d}\rho, & x > 0, \\ 0, & x \le 0. \end{cases}$$

由于这是概率分布, 令 $x \to +\infty$ 必定得到 1, 即

$$C_n \int_0^{+\infty} \exp\left(-\frac{1}{2}\rho^2\right) \rho^{n-1} \mathrm{d}\rho = 1.$$

作换元 $r = \frac{1}{2}\rho^2$ 可以看出

$$C_n \int_0^{+\infty} \mathrm{e}^{-r} (2r)^{\frac{n-1}{2}} (2r)^{-\frac{1}{2}} \mathrm{d}r = C_n 2^{\frac{n}{2}-1} \Gamma\left(\frac{n}{2}\right) = 1.$$

这就给出了 C_n 的值. 现在只要对分布函数求导

$$\frac{\mathrm{d}}{\mathrm{d}x} \int_0^{\sqrt{x}} \exp\left(-\frac{1}{2}\rho^2\right) \rho^{n-1} \mathrm{d}\rho = x^{\frac{n-1}{2}} \mathrm{e}^{-\frac{x}{2}} \frac{1}{2\sqrt{x}},$$

代入 C_n 的值即证. □

我们也称以

$$f(x) = \frac{1}{\beta^\alpha \Gamma(\alpha)} x^{\alpha-1} \mathrm{e}^{-\frac{x}{\beta}}$$

为密度函数的分布为参数 α, β 的 Γ 分布, 记作 $X \sim \Gamma(\alpha, \beta)$. 则 χ^2 分布相当于 $\Gamma\left(\frac{n}{2}, \frac{1}{2}\right)$. 由于指数分布的密度函数为

$$f(x) = \lambda \mathrm{e}^{\lambda x}, \quad x > 0,$$

因此自由度为 2 的 χ^2 分布恰好是指数分布 $\mathrm{Exp}\left(\frac{1}{2}\right)$. 一般的指数分布可以通过变换改写为 $\mathrm{Exp}\left(\frac{1}{2}\right)$ 的形式.

利用密度函数可以计算 k 阶矩.

Theorem 1.3.(χ^2 分布的 k 阶矩) 设 ξ 是服从自由度为 n 的 χ^2 分布的随机变量, 则对任意 $k > -\frac{n}{2}$, k 阶矩

$$\mathbb{E}\left(\xi^k\right) = 2^k \frac{\Gamma\left(\frac{n}{2} + k\right)}{\Gamma\left(\frac{n}{2}\right)}.$$

特别地, 取 $n = 1$ 得到标准正态分布的偶数阶矩

$$\mathbb{E}\left(X^{2k}\right) = \mathbb{E}\left(\xi^k\right) = (2k-1)!!.$$

Proof. 利用密度函数

$$\mathbb{E}\left(\xi^k\right)=\int_{\mathbb{R}} x^k f_n(x)\mathrm{d}x=\int_0^{+\infty}\frac{1}{2^{\frac{n}{2}}\Gamma\left(\frac{n}{2}\right)}x^{\frac{n}{2}+k-1}\mathrm{e}^{-\frac{x}{2}}\mathrm{d}x=2^k\frac{\Gamma\left(\frac{n}{2}+k\right)}{\Gamma\left(\frac{n}{2}\right)}.$$

特别地, 取 $n=1$ 得 $\xi=X^2$, 于是

$$\mathbb{E}\left(X^{2k}\right)=2^k\frac{\Gamma\left(\frac{1}{2}+k\right)}{\Gamma\left(\frac{1}{2}\right)}=(2k-1)!!.$$

□

我们回顾**Example 1.3.**中计算的相关系数.

Example 1.7.(总体方差与样本方差的相关系数) **Example 1.1.**和**Example 1.2.**中定义的随机变量

$$A=\frac{1}{n}\sum_{k=1}^n(X_k-\mu)^2,\quad B=\frac{1}{n-1}\sum_{k=1}^n(X_k-\overline{X})^2.$$

观察相关系数的定义

$$\rho(A,B)=\frac{\mathrm{Cov}(A,B)}{\sqrt{\mathrm{Var}(A)\,\mathrm{Var}(B)}}$$

可知 $\rho(\alpha A,\beta B)=\rho(A,B)$. 于是只要计算

$$\rho\left(\sum_{k=1}^n(X_k-\mu)^2,\sum_{k=1}^n(X_k-\overline{X})^2\right)$$

即可. 注意到

$$\sum_{k=1}^n(X_k-\mu)^2=\sum_{k=1}^n(X_k-\overline{X})^2+n\left(\overline{X}-\mu\right)^2,$$

根据**Theorem 1.1.**的结果, 样本均值 $\overline{X}$ 和样本方差 S^2 独立, 因此根据协方差的双线性只要计算

$$\frac{\mathrm{Cov}\left(\sum\limits_{k=1}^n(X_k-\overline{X})^2,\sum\limits_{k=1}^n(X_k-\overline{X})^2\right)}{\sqrt{\mathrm{Var}\left(\sum\limits_{k=1}^n(X_k-\mu)^2\right)\mathrm{Var}\left(\sum\limits_{k=1}^n(X_k-\overline{X})^2\right)}}=\sqrt{\frac{\mathrm{Var}\left(\sum\limits_{k=1}^n(X_k-\overline{X})^2\right)}{\mathrm{Var}\left(\sum\limits_{k=1}^n(X_k-\mu)^2\right)}}.$$

根据**Theorem 1.1.**的结果, 两者分别相当于自由度为 $n-1$ 和 n 的 χ^2 分布, 于是根据**Theorem 1.3.**可求出

$$\rho(A,B)=\sqrt{\frac{n-1}{n}}.$$

Exercise 1.1. 设 $X_1, X_2, \ldots, X_n$ 独立, 分别服从正态分布 $N(0, \sigma_i^2)$, 定义随机变量

$$\xi = \sum_{i=1}^{n} \frac{(X_i - Z)^2}{\sigma_i^2}, \quad Z = \frac{\sum_{i=1}^{n} \frac{X_i}{\sigma_i^2}}{\sum_{i=1}^{n} \frac{1}{\sigma_i^2}},$$

求 ξ 的分布.

Solution. 为了使细节更清晰, 作换元 $w_i = \frac{1}{\sigma_i}$ 和 $Y_i = \frac{X_i}{\sigma_i}$, 则定义变为

$$\xi = \sum_{i=1}^{n} (Y_i - w_i Z)^2, \quad Z = \frac{\sum_{i=1}^{n} w_i Y_i}{\sum_{i=1}^{n} w_i^2}.$$

其中 Y_i 独立同分布 $N(0,1)$. 现在可以展开

$$\xi = \sum_{i=1}^{n} Y_i^2 + \left(\sum_{i=1}^{n} w_i^2\right) Z^2 - 2\left(\sum_{i=1}^{n} w_i Y_i\right) Z = \sum_{i=1}^{n} Y_i^2 - \frac{\left(\sum_{i=1}^{n} w_i Y_i\right)^2}{\sum_{i=1}^{n} w_i^2}.$$

立刻看出这是 $\mathbf{Y}$ 的二次型. 为了写成更标准的二次型, 定义

$$u_i = \frac{w_i}{\sqrt{\sum_{i=1}^{n} w_i^2}}$$

构成单位向量 $\mathbf{u}$, 则

$$\xi = \mathbf{Y}^T\mathbf{Y} - (\mathbf{u}^T\mathbf{Y})^2 = \mathbf{Y}^T(I - \mathbf{u}\mathbf{u}^T)\mathbf{Y}.$$

以 $\mathbf{u} = \mathbf{u}_1$ 为第一列构造正交阵 U, 并作正交变换 $\mathbf{Z} = U^T\mathbf{Y}$, 则

$$\xi = \mathbf{Z}^T U^T (I - \mathbf{u}\mathbf{u}^T) U \mathbf{Z} = \mathbf{Z}^T (I - (U^T\mathbf{u})(\mathbf{u}^T U))\mathbf{Z} = \sum_{i=2}^{n} Z_i^2.$$

根据**Theorem 1.1.**可知 Z_i 独立同分布 $N(0,1)$, 依照**Definition 1.6.**可知 $\xi \sim \chi_{n-1}^2$.

1.3.2 t 分布

正态分布与独立正态分布的平方平均之商称为 t **分布**.

Definition 1.7.(t 分布) 给定 n 个样本 $\{X_k\}_{k=1}^n$ 和一个样本 Y 独立同标准正态分布, 称随机变量

$$T = Y\left(\frac{1}{n}\sum_{k=1}^{n} X_k^2\right)^{-\frac{1}{2}}$$

服从的分布为自由度为 n 的 t 分布, 记作 $\xi \sim t_n$.

我们可以计算其密度函数.

Theorem 1.4.(t 分布的密度函数) 设 T 是服从自由度为 n 的 t 分布的随机变量, 则其概率密度函数为

$$f_n(t)=\frac{\Gamma\left(\frac{n+1}{2}\right)}{\Gamma\left(\frac{n}{2}\right)\sqrt{n\pi}}\left(1+\frac{t^2}{n}\right)^{-\frac{n+1}{2}}.$$

Proof. 依照概率分布的定义

$$F_n(t)=\mathbb{P}\left(\frac{\sqrt{n}Y}{\sqrt{\xi}}\le t\right)=\int_{\frac{\sqrt{n}y}{\sqrt{x}}\le t}\frac{1}{\sqrt{2\pi}}\mathrm{e}^{-\frac{y^2}{2}}\frac{1}{2^{\frac{n}{2}}\Gamma\left(\frac{n}{2}\right)}x^{\frac{n}{2}-1}\mathrm{e}^{-\frac{x}{2}}\mathrm{d}x\mathrm{d}y.$$

考虑换元

$$\begin{cases}u=\frac{y}{\sqrt{x}},\\ v=\sqrt{x}.\end{cases}$$

相应的 Jacobi 行列式为

$$\det(J)=\det\left(\begin{bmatrix}0 & 2v\\ v & u\end{bmatrix}\right)=-2v^2,$$

于是

$$F_n(t)=\int_{\sqrt{n}u\le t,v\ge 0}\frac{1}{\sqrt{2\pi}}\mathrm{e}^{-\frac{u^2v^2}{2}}\frac{1}{2^{\frac{n}{2}}\Gamma\left(\frac{n}{2}\right)}v^{n-2}\mathrm{e}^{-\frac{1}{2}v^2}2v^2\mathrm{d}u\mathrm{d}v.$$

整理得

$$F_n(t)=\frac{1}{2^{\frac{n}{2}-1}\Gamma\left(\frac{n}{2}\right)}\int_{-\infty}^{\frac{t}{\sqrt{n}}}\left(\int_0^{+\infty}\frac{1}{\sqrt{2\pi}}v^n\mathrm{e}^{-\frac{v^2}{2}(u^2+1)}\mathrm{d}v\right)\mathrm{d}u.$$

作换元 $z=\frac{1}{2}(u^2+1)v^2$ 可得括号内为

$$\int_0^{+\infty}\frac{1}{\sqrt{2\pi}}\left(\sqrt{\frac{2z}{u^2+1}}\right)^n\mathrm{e}^{-z}\frac{1}{\sqrt{2z(u^2+1)}}\mathrm{d}z.$$

利用 Gamma 函数可以写为

$$\frac{2^{\frac{n-1}{2}}}{\sqrt{2\pi}(u^2+1)^{\frac{n+1}{2}}}\int_0^{+\infty}z^{\frac{n-1}{2}}\mathrm{e}^{-z}\mathrm{d}z=\frac{2^{\frac{n-1}{2}}\Gamma\left(\frac{n+1}{2}\right)}{\sqrt{2\pi}(u^2+1)^{\frac{n+1}{2}}}.$$

代入得

$$F_n(t)=\frac{1}{2^{\frac{n}{2}-1}\Gamma\left(\frac{n}{2}\right)}\int_{-\infty}^{\frac{t}{\sqrt{n}}}\frac{2^{\frac{n}{2}-1}\Gamma\left(\frac{n+1}{2}\right)}{\sqrt{\pi}(u^2+1)^{\frac{n+1}{2}}}\mathrm{d}u=\frac{\Gamma\left(\frac{n+1}{2}\right)}{\sqrt{\pi}\Gamma\left(\frac{n}{2}\right)}\int_{-\infty}^{\frac{t}{\sqrt{n}}}(u^2+1)^{-\frac{n+1}{2}}\mathrm{d}u.$$

对 t 求导即得密度函数

$$f_n(t)=\frac{\Gamma(\frac{n+1}{2})}{\sqrt{n\pi}\Gamma(\frac{n}{2})}\left(1+\frac{t^2}{n}\right)^{-\frac{n+1}{2}}.$$

□

特别地, 如果取 $n=1$, 则变为

$$f_1(t)=\frac{1}{\pi(1+t^2)}$$

是 Cauchy 分布. 令 $n\to\infty$, 则依照 e 的定义和 Stirling 公式变为

$$\lim_{n\to\infty} f_n(t)=\frac{\sqrt{\frac{n}{2}}}{\sqrt{n\pi}}\exp\left(-\frac{1}{2}t^2\right)=\frac{1}{\sqrt{2\pi}}\exp\left(-\frac{1}{2}t^2\right),$$

即标准正态分布.

利用密度函数可以计算 k 阶矩.

Theorem 1.5.(t 分布的 k 阶矩) 设 T 是服从自由度为 n 的 t 分布的随机变量, 则对任意 $k<n$, k 阶矩

$$\mathbb{E}\left(T^k\right)=\begin{cases} n^{\frac{k}{2}}\frac{\Gamma\left(\frac{k+1}{2}\right)\Gamma\left(\frac{n-k}{2}\right)}{\Gamma\left(\frac{n}{2}\right)\Gamma\left(\frac{1}{2}\right)}, & 2\mid k,\\ 0, & 2\nmid k.\end{cases}$$

Proof. 利用密度函数

$$\mathbb{E}\left(T^k\right)=\int_{\mathbb{R}} t^k f_n(t)\mathrm{d}t=\int_{\mathbb{R}} t^k\frac{\Gamma(\frac{n+1}{2})}{\sqrt{n\pi}\Gamma(\frac{n}{2})}\left(1+\frac{t^2}{n}\right)^{-\frac{n+1}{2}}\mathrm{d}t.$$

当 $2\nmid k$ 时, 被积函数是奇函数, 从而积分值为 0. 当 $2\mid k$ 时, 考虑换元 $z=\frac{t^2}{n}$, 恰好得到 Beta 函数

$$\mathbb{E}\left(T^k\right)=\frac{n^{\frac{k}{2}}\Gamma(\frac{n+1}{2})}{\sqrt{\pi}\Gamma(\frac{n}{2})}\int_0^{+\infty} z^{\frac{k-1}{2}}(1+z)^{-\frac{n+1}{2}}\mathrm{d}z=\frac{n^{\frac{k}{2}}\Gamma(\frac{n+1}{2})}{\sqrt{\pi}\Gamma(\frac{n}{2})}B\left(\frac{k+1}{2},\frac{n-k}{2}\right),$$

展开为 Gamma 函数即证. □

Exercise 1.2. 设 $X_1,X_2,\ldots,X_{n+1}$ 独立同正态分布 $N(\mu,\sigma^2)$, 定义前 n 项的均值和方差

$$\overline{X}=\frac{1}{n}\sum_{i=1}^n X_i,\quad S^2=\frac{1}{n}\sum_{i=1}^n(X_i-\overline{X})^2.$$

定义随机变量

$$\xi=\frac{X_{n+1}-\overline{X}}{S}\sqrt{\frac{n-1}{n+1}},$$

求 ξ 的分布.

Solution. 此形式类似于 t 分布, 为构造出类似形式, 考虑 X_{n+1} 和 $\overline{X}$ 是独立随机变量, 分别服从 $N(\mu,\sigma^2)$ 和 $N(\mu,\frac{\sigma^2}{n})$, 因此利用特征函数容易计算 $X_{n+1}-\overline{X}$ 的分布为正态分布, 均值为 0, 方差

$$\sigma_{n+1}^2=\sigma^2+\frac{\sigma^2}{n}=\frac{n+1}{n}\sigma^2.$$

于是定义随机变量

$$Y = \frac{X_{n+1} - \overline{X}}{\sqrt{\frac{n+1}{n}}\sigma}$$

服从标准正态分布. 代入立即得到

$$\xi = Y\left(\frac{1}{n-1}\sum_{i=1}^{n}\frac{(X_i - \overline{X})^2}{\sigma^2}\right)^{-\frac{1}{2}}.$$

根据Exercise 1.1.中取 $\sigma_i = \sigma$ 的结果, 括号内的求和可以变为 $\sum_{i=2}^{n} Z_i^2$, 其中 Z_i 独立同标准正态分布, 于是上式恰好是 t 分布的定义, 即 $\xi \sim t_{n1}$.

1.3.3 F 分布

独立正态分布平方的均值之商称为 F **分布**.

Definition 1.8.(F **分布**) 给定 $m+n$ 个样本 $\{X_i\}_{i=1}^m$ 和 $\{Y_j\}_{j=1}^n$ 独立同标准正态分布, 称随机变量

$$Z = \frac{\frac{1}{m}\sum_{i=1}^{m} X_i^2}{\frac{1}{n}\sum_{j=1}^{n} X_j^2}$$

服从的分布为参数 m, n 的 F 分布, 记作 $Z \sim F_{m,n}$.

我们仍然计算其密度函数.

Theorem 1.6.(F **分布的密度函数**) 设 Z 是服从参数 m, n 的 F 分布的随机变量, 则其概率密度函数为

$$f_{m,n}(t) = \begin{cases} \frac{\Gamma\left(\frac{m+n}{2}\right)}{\Gamma\left(\frac{m}{2}\right)\Gamma\left(\frac{n}{2}\right)} m^{\frac{m}{2}} n^{\frac{n}{2}} t^{\frac{m}{2}-1}(n+mt)^{-\frac{m+n}{2}}, & t > 0, \\ 0, & t \le 0. \end{cases}$$

Proof. 我们记 X_i 的平方和为 X, Y_j 的平方和为 Y, 则分别服从自由度为 m, n 的 χ^2 分布. 依照概率分布的定义

$$F_{m,n}(t) = \mathbb{P}\left(\frac{X/m}{Y/n} \le t\right) = \int_{\frac{x/m}{y/n} \le t} \frac{1}{2^{\frac{m+n}{2}}\Gamma\left(\frac{m}{2}\right)\Gamma\left(\frac{n}{2}\right)} x^{\frac{m}{2}-1} y^{\frac{n}{2}-1} \mathrm{e}^{-\frac{x+y}{2}} \mathrm{d}x\mathrm{d}y.$$

考虑换元

$$\begin{cases} u = \frac{x}{y}, \\ v = y. \end{cases}$$

相应的 Jacobi 行列式为

$$\det(J) = \det\left(\begin{bmatrix} 0 & 1 \\ v & u \end{bmatrix}\right) = -v,$$

即得

$$F_{m,n}(t)=\int_{0\le u\le \frac{m}{n}t,v\ge 0}\frac{1}{2^{\frac{m+n}{2}}\Gamma\left(\frac{m}{2}\right)\Gamma\left(\frac{n}{2}\right)}(uv)^{\frac{m}{2}-1}v^{\frac{n}{2}-1}\mathrm{e}^{-\frac{(u+1)v}{2}}v\mathrm{d}u\mathrm{d}v.$$

整理得

$$F_{m,n}(t)=\int_0^{\frac{m}{n}t}\left(\frac{u^{\frac{m}{2}-1}}{2^{\frac{m+n}{2}}\Gamma\left(\frac{m}{2}\right)\Gamma\left(\frac{n}{2}\right)}\int_0^{+\infty}v^{\frac{m+n}{2}-1}\mathrm{e}^{-\frac{(u+1)v}{2}}\mathrm{d}v\right)\mathrm{d}u.$$

采用同样的方法作换元 $z=\frac{(u+1)v}{2}$ 可得

$$\int_0^{+\infty}v^{\frac{m+n}{2}-1}\mathrm{e}^{-\frac{(u+1)v}{2}}\mathrm{d}v=\frac{2^{\frac{m+n}{2}}\Gamma\left(\frac{m+n}{2}\right)}{(u+1)^{\frac{m+n}{2}}}.$$

于是

$$F_{m,n}(t)=\frac{\Gamma\left(\frac{m+n}{2}\right)}{\Gamma\left(\frac{m}{2}\right)\Gamma\left(\frac{n}{2}\right)}\int_0^{\frac{m}{n}t}\frac{u^{\frac{m}{2}-1}}{(u+1)^{\frac{m+n}{2}}}\mathrm{d}u.$$

求导即得密度函数. □

依照定义即知 $F_{1,n}$ 相当于服从 t_n 分布的随机变量的平方的分布, $F_{n,m}$ 相当于服从 $F_{m,n}$ 分布的随机变量的倒数的分布.

我们仍然计算 k 阶矩.

Theorem 1.7.(F 分布的 k 阶矩) 设 Z 是服从参数 m,n 的 F 分布的随机变量, 则对任意 $0<k<\frac{n}{2}$, k 阶矩

$$\mathbb{E}\left(Z^k\right)=\left(\frac{n}{m}\right)^k\frac{\Gamma\left(\frac{m}{2}+k\right)\Gamma\left(\frac{n}{2}-k\right)}{\Gamma\left(\frac{m}{2}\right)\Gamma\left(\frac{n}{2}\right)}.$$

特别地, 当 $n>2$ 和 $n>4$ 时有

$$\mathbb{E}(Z)=\frac{n}{n-2},\quad \mathrm{Var}(Z)=\frac{2n^2(m+n-2)}{m(n-2)^2(n-4)}.$$

Proof. 根据独立性展开

$$\mathbb{E}\left(Z^k\right)=\left(\frac{n}{m}\right)^k\mathbb{E}\left(X^k\right)\mathbb{E}\left(Y^{-k}\right).$$

根据**Theorem 1.3.**的结果有

$$\mathbb{E}\left(X^k\right)=2^k\frac{\Gamma\left(\frac{m}{2}+k\right)}{\Gamma\left(\frac{m}{2}\right)},\quad \mathbb{E}\left(Y^{-k}\right)=2^{-k}\frac{\Gamma\left(\frac{n}{2}-k\right)}{\Gamma\left(\frac{n}{2}\right)},$$

代入即证. □

对正态分布的数据而言, 其样本均值和样本方差恰好服从正态分布和 χ^2 分布, 因此作商恰好是 t 分布和 F 分布, 这刻画了数据波动程度的关系.

1.4 顺序统计量

作为最大值, 最小值的推广, 我们考察顺序统计量.

Definition 1.9.(顺序统计量) 设 $X_1, X_2, \ldots, X_n$ 是概率空间 $(\Omega, \mathscr{F}, \mathbb{P})$ 上的随机变量 (样本), 对每个 $\omega \in \Omega$, 都可对 $\{X_i(\omega)\}$ 排序, 把每个 ω 映到相应序列的从小到大第 k 个值的随机变量, 称为第 k 顺序统计量 $X_{(k)}$.

顺序统计量作为随机变量, 可以研究其分布.

Theorem 1.8.(顺序统计量的分布) 设 $X_1, X_2, \ldots, X_n$ 独立同分布 $F(x)$, 则第 k 顺序统计量的概率分布为

$$F_{(k)}(x) = \sum_{i=k}^{n} C_n^i F(x)^i (1-F(x))^{n-i} = \frac{n!}{(k-1)!(n-k)!} \int_0^{F(x)} t^{k-1}(1-t)^{n-k} \mathrm{d}t.$$

如果 $F(x)$ 的导数存在, 则密度函数为

$$f_{(k)}(x) = \frac{n!}{(k-1)!(n-k)!} F(x)^{k-1}(1-F(x))^{n-k} f(x).$$

Proof. 依照定义, $F_{(k)}(x)$ 的值是 $\mathbb{P}(X_{(k)} \le x)$, 即至少有 k 个不大于 x, 这可以分解为恰好有 $k, k+1, \ldots, n$ 个不大于 x 的概率和, 即

$$F_{(k)}(x) = \sum_{i=k}^{n} C_n^i \mathbb{P}(X_1 \le x)^i \mathbb{P}(X_1 > x)^{n-i} = F_{(k)}(x) = \sum_{i=k}^{n} C_n^i F(x)^i (1-F(x))^{n-i}.$$

为了得到积分形式, 只要证明恒等式

$$\sum_{i=k}^{n} C_n^i x^i (1-x)^{n-i} = \frac{n!}{(k-1)!(n-k)!} \int_0^x t^{k-1}(1-t)^{n-k} \mathrm{d}t,$$

这只要对右边作分部积分即可. 最后求导即得

$$f_{(k)}(x) = \frac{n!}{(k-1)!(n-k)!} F(x)^{k-1}(1-F(x))^{n-k} f(x).$$

□

对这一结果, 可以从古典概型的角度考虑. 比 $X_{(k)}$ 小的有 $k-1$ 个, 有 C_n^{k-1} 种取法, 每个的概率是 $\mathbb{P}(X_1 \le x) = F(x)$, 比 $X_{(k)}$ 大的有 $n-k$ 个, 有 C_{n-k+1}^{n-k} 种取法, 每个的概率是 $\mathbb{P}(X_1 > x) = 1 - F(x)$, 而 $X_{(k)}$ 本身只剩下一种取法, 概率是 $f(x)$, 相乘即得

$$C_n^{k-1} C_{n-k+1}^{n-k} = \frac{n!}{(n-k+1)!(k-1)!}(n-k+1) = \frac{n!}{(k-1)!(n-k)!}.$$

如果相应概率分布 F 的各阶矩存在, 则只要写成积分, 容易看出顺序统计量的各阶矩存在. 反之则不然.

Example 1.8.(Cauchy 分布顺序统计量的 p 阶矩) 设 $X_1, X_2, \ldots, X_n$ 独立同 Cauchy 分布, 则

$$F(x) = \frac{1}{2} + \frac{1}{\pi}\arctan x, \quad f(x) = \frac{1}{\pi(1+x^2)}.$$

从而第 k 顺序统计量的密度函数为

$$f_{(k)}(x) = \frac{n!}{(k-1)!(n-k)!}\left(\frac{1}{2} + \frac{1}{\pi}\arctan x\right)^{k-1}\left(\frac{1}{2} - \frac{1}{\pi}\arctan x\right)^{n-k}\frac{1}{\pi(1+x^2)}.$$

其 p 阶矩为

$$\mathbb{E}(X_{(k)}) = \frac{1}{\pi}\frac{n!}{(k-1)!(n-k)!}\int_{\mathbb{R}}\left(\frac{1}{2} + \frac{1}{\pi}\arctan x\right)^{k-1}\left(\frac{1}{2} - \frac{1}{\pi}\arctan x\right)^{n-k}\frac{x^p}{1+x^2}\mathrm{d}x.$$

当 $x \to +\infty$ 时, 有无穷小

$$\frac{1}{2} - \frac{1}{\pi}\arctan x \sim \frac{1}{\pi x},$$

因此只要 $n-k \geq p$ 就在正无穷处积分收敛. 同理可得 $p \leq k-1$ 时在负无穷处积分收敛, 因此第 k 顺序统计量的 $1 \leq p \leq \min\{k-1, n-k\}$ 阶矩存在, 特别地, 当 $k \neq 1, n$ 时期望存在, $k \neq 1, 2, n-1, n$ 时方差存在.

顺序统计量作为随机变量彼此不独立, 因而有必要讨论其联合分布, 不是各分布的乘积.

Theorem 1.9.(顺序统计量的联合分布) 设 $X_1, X_2, \ldots, X_n$ 独立同分布 $f(x)$, 则顺序统计量的联合概率密度为

$$f(\mathbf{x}) = \begin{cases} n!\prod\limits_{i=1}^{n} f(x_i), & x_1 < x_2 < \cdots < x_n, \\ 0, & \text{otherwise}. \end{cases}$$

Proof. 我们比较这与 $\mathbf{X}$ 的联合概率密度的关系. 根据独立性, $\mathbf{X}$ 的联合概率密度当然是

$$f_{\mathbf{X}}(\mathbf{x}) = \prod_{i=1}^{n} f(x_i).$$

对 $\{X_{(k)}\}$ 作置换, 每一个置换给出一个密度非 0 的区域

$$x_{k_1} < x_{k_2} < \cdots < x_{k_n},$$

且这 $n!$ 个区域彼此不交, 在相差一个零测区域意义下构成全空间 $\mathbb{R}^n$. 现在在每个区域内定义映射, 使之构成与

$$x_1 < x_2 < \cdots < x_n$$

的一一对应, 则顺序统计量在 $\mathbf{x}$ 处的值就是所有被映到该点的概率密度之和, 当然是

$$n!\prod_{i=1}^{n} f(x_i).$$

□

同样可以从古典概型的角度理解, 也可以如此理解: 顺序统计量落在 $\mathbf{x}$ 附近区域, 当且仅当原始独立统计量落在全部 $n!$ 个置换区域的某个相应位置, 因此概率密度当然是求和.

要求若干顺序统计量的联合密度函数, 只要对其他量作积分即可. 特别地, 可以计算极差 $X_{(1)}, X_{(n)}$ 的联合密度

$$f(x_1, x_n) = \int_{x_1<x_2<\cdots<x_n} n!\prod_{i=1}^{n} f(x_i)\mathrm{d}x_2\cdots\mathrm{d}x_{n-1}.$$

考虑中间全部的 $(n-2)!$ 个置换, 得

$$f(x_1, x_n) = \frac{n!}{(n-2)!}\int_{x_1<x_2,\cdots,x_{n-1}<x_n} \prod_{i=1}^{n} f(x_i)\mathrm{d}x_2\cdots\mathrm{d}x_{n-1},$$

直接计算得

$$f(x_1, x_n) = n(n-1)(F(x_n)-F(x_1))^{n-2}f(x_1)f(x_n).$$

注意到如果 X 服从分布函数 $F(x)$, 且 F 连续, 则由于 F 单调

$$\mathbb{P}(F(X)\le x) = \mathbb{P}(X\le F^{-1}(x)) = F(F^{-1}(x)) = x, \quad 0\le x\le 1.$$

这说明任何随机变量 X 只要服从某个连续分布 F, 则 $F(X)$ 必然服从均匀分布 $U(0,1)$, 因此有必要研究均匀分布的顺序统计量.

Example 1.9.(均匀分布的顺序统计量) 设 $X_1, X_2, \ldots, X_n$ 独立同分布 $U(0,1)$. 则根据**Theorem 1.8.**的结果, 第 k 顺序统计量的概率密度函数为

$$f_{(k)}(x) = \begin{cases} \frac{n!}{(k-1)!(n-k)!}x^{k-1}(1-x)^{n-k}, & 0<x<1, \\ 0, & \text{otherwise}. \end{cases}$$

我们计算其期望

$$\mathbb{E}(X_{(k)}) = \int_0^1 x\frac{n!}{(k-1)!(n-k)!}x^{k-1}(1-x)^{n-k}\mathrm{d}x.$$

注意到可以写为

$$\frac{n!}{(k-1)!(n-k)!}\int_0^1 x^{(k+1)-1}(1-x)^{(n+1)-(k+1)}\mathrm{d}x,$$

而积分内相当于 $n+1$ 个随机变量的第 $k+1$ 个顺序统计量的密度函数, 因此积分结果是系数的倒数

$$\mathbb{E}(X_{(k)}) = \frac{n!}{(k-1)!(n-k)!}\frac{k!(n-k)!}{(n+1)!} = \frac{k}{n+1},$$

这具有对称性, 即第 k 个顺序统计量和倒数第 k 个顺序统计量有相同的期望. 同理可以计算方差

$$\mathrm{Var}(X_{(k)}) = \frac{k(k+1)}{(n+1)(n+2)} - \left(\frac{k}{n+1}\right)^2 = \frac{k(n-k+1)}{(n+1)^2(n+2)},$$

同样可见对称性. 根据**Theorem 1.9.**的结果, 顺序统计量的联合概率密度为

$$f(\mathbf{x}) = \begin{cases} n!, & 0 < x_1 < x_2 < \cdots < x_n < 1, \\ 0, & \text{otherwise}. \end{cases}$$

对除去 $X_{(i)}, X_{(j)}$ 以外的项积分, 不妨设 $i<j$, 则 $i<k<j$ 的项积分范围为 $[x_i, x_j]$, $k<i$ 的项积分范围为 $[0, x_i]$, $k>j$ 的项积分范围为 $[x_j, 1]$, 再除掉所有排列数

$$f_{(i,j)}(x_i, x_j) = \frac{n!}{(i-1)!(j-i-1)!(n-j)!}x_i^{i-1}(x_j-x_i)^{j-i-1}(1-x_j)^{n-j}.$$

从而期望

$$\mathbb{E}(X_{(i)}X_{(j)}) = \frac{n!}{(i-1)!(j-i-1)!(n-j)!}\int_{0<x_i<x_j<1} x_i^i x_j (x_j-x_i)^{j-i-1}(1-x_j)^{n-j}\mathrm{d}x_i\mathrm{d}x_j,$$

利用 Beta 函数的性质, 先对 x_i 积分

$$\int_0^{x_j} x_i^i(x_j-x_i)^{j-i-1}\mathrm{d}x_i = x_j^j\int_0^1 t^i(1-t)^{j-i-1}\mathrm{d}t = \frac{i!(j-i-1)!}{j!}x_j^j,$$

代入得

$$\mathbb{E}(X_{(i)}X_{(j)}) = \frac{n!}{(n-j)!}\frac{i}{j!}\int_0^1 x_j^{j+1}(1-x_j)^{n-j}\mathrm{d}x_j = \frac{i(j+1)}{(n+1)(n+2)}.$$

因而可以求得协方差

$$\mathrm{Cov}(X_{(i)}, X_{(j)}) = \mathbb{E}(X_{(i)}X_{(j)}) - \mathbb{E}(X_{(i)})\mathbb{E}(X_{(j)}) = \frac{i(n-j+1)}{(n+1)^2(n+2)},$$

相关系数

$$\rho(X_{(i)}, X_{(j)}) = \frac{\mathrm{Cov}(X_{(i)}, X_{(j)})}{\sqrt{\mathrm{Var}(X_{(i)})\,\mathrm{Var}(X_{(j)})}} = \sqrt{\frac{i(n-j+1)}{j(n-i+1)}}.$$

作为顺序统计量的推广, 我们通过线性插值定义 p 分位数.

Definition 1.10.(p **分位数**) 给定 n 个样本 $X_1, X_2, \ldots, X_n$, 对 $0 < p < 1$, 定义 p 分位数是顺序统计量的线性组合

$$\epsilon_{n,p} = X_{([(n+1)p])} + ((n+1)p - [(n+1)p]) \left(X_{([(n+1)p]+1)} - X_{([(n+1)p])} \right).$$

依照定义很明显第 k 顺序统计量就是 $\frac{k}{n+1}$ 分位数. 反之, 小于 p 分位数的最大顺序统计量是 $X_{([np])}$.

1.5 渐近分布 *

本节的结果仅作介绍, 因其涉及较为复杂的估计和引理, 而相关结论不影响后续. 我们首先回顾概率论中随机变量序列的四种收敛.

Definition 1.11.(随机变量序列的收敛) $\{X_n\}$ 是概率空间 $(\Omega, \mathscr{F}, \mathbb{P})$ 上的随机变量序列, 相应的概率分布函数为 $F_n(x)$. X 是一个随机变量或常数, 相应的分布函数为 $F(x)$.

1. 如果对任意 $\omega \in \Omega \setminus N$, 其中 N 是一个零测集, 都有
$$\lim_{n\to\infty} X_n(\omega) = X(\omega),$$
称 $\{X_n\}$ 几乎处处收敛 (a.e.) 到 X.

2. 如果对任意 $\varepsilon > 0$, 有
$$\lim_{n\to\infty} \mathbb{P}\left(\{\omega \in \Omega \mid |X_n(\omega) - X(\omega)| < \varepsilon\}\right) = 1,$$
称 $\{X_n\}$ 依概率收敛 (pr.) 到 X.

3. 如果对某个 $\alpha > 0$, 有
$$\lim_{n\to\infty} \mathbb{E}(|X_n - X|^\alpha) = 0,$$
称 $\{X_n\}$ 满足 L^α 收敛或 α 阶矩收敛到 X.

4. 如果对任意 $x \in \mathbb{R}$ 是 $F(x)$ 的连续点, 都有
$$\lim_{n\to\infty} F_n(x) = F(x),$$
则称 X_n 依分布收敛 (dist.) 到 $F(x)$.

大数定律和中心极限定理都从描述了某种收敛性质. 对样本而言, 我们把依分布收敛视作大样本条件下的极限分布, 也称为这组样本的**渐近分布 (asymptotic distribution)**. 例如当样本充分大时, 小于 p 分位数的最大顺序统计量 $X_{([np])}$ 与 p 分位数十分接近, 可以作为其估计.

为了求得一些样本的渐近分布, 我们需要以下引理, 作为中心极限定理的某种推广.

Theorem 1.10.(de Moivre-Laplace, 局部极限定理, local limit theorem) 设随机变量 S_n 服从 Bernoulli 分布 $B(n,p)$, 即 n 次 Bernoulli 试验成功的次数, 满足
$$\mathbb{P}(S_n = x) = C_n^x p^x (1-p)^{n-x}.$$

则对一个给定的有界区间 $I=[a,b]$ 和整数 $k=k(n)$ 使得 $\frac{k-np}{\sqrt{np(1-p)}}\in I$, 当 $n\to\infty$ 时, 有等价无穷小

$$\mathbb{P}(S_n=k)\approx\frac{1}{\sqrt{2\pi np(1-p)}}\exp\left(-\frac{1}{2}\left(\frac{k-np}{\sqrt{np(1-p)}}\right)^2\right).$$

Proof. 我们证明更强的结论. 对一个收敛到 $p\in(0,1)$ 的序列 $\{p_n\}\subseteq(0,1)$, 整数 k_n 和给定的有界区间 $I=[a,b]$ 使得 $\frac{k_n-np_n}{\sqrt{np_n(1-p_n)}}\in I$ 恒成立, 当 $n\to\infty$ 时, 有等价无穷小

$$C_n^{k_n}p_n^{k_n}(1-p_n)^{n-k_n}\approx\frac{1}{\sqrt{2\pi np_n(1-p_n)}}\exp\left(-\frac{1}{2}\left(\frac{k_n-np_n}{\sqrt{np_n(1-p_n)}}\right)^2\right).$$

记 $\lambda(n)=\frac{k_n-np_n}{\sqrt{np_n(1-p_n)}}$, 则根据

$$\frac{k_n}{n}=p_n+\lambda(n)\sqrt{\frac{p_n(1-p_n)}{n}},\quad \frac{n-k_n}{n}=1-p_n-\lambda(n)\sqrt{\frac{p_n(1-p_n)}{n}}$$

以及有界性 $p_n\in(0,1)$ 和 $\lambda(n)\in I$, 可知 k_n 和 $n-k_n$ 都是 $n\to\infty$ 的无穷大, 因此有 Stirling 公式

$$C_n^{k_n}=\frac{n!}{k_n!(n-k_n)!}\approx\frac{\sqrt{2\pi n}\left(\frac{n}{\mathrm{e}}\right)^n}{\sqrt{2\pi k_n}\left(\frac{k_n}{\mathrm{e}}\right)^{k_n}\sqrt{2\pi(n-k_n)}\left(\frac{n-k_n}{\mathrm{e}}\right)^{n-k_n}},$$

整理得

$$C_n^{k_n}\approx\frac{1}{\sqrt{2\pi}}\sqrt{\frac{n}{k_n(n-k_n)}}\frac{n^n}{{k_n}^{k_n}(n-k_n)^{n-k_n}}.$$

现在把 $p_n^{k_n}(1-p_n)^{k_n}$ 分配

$$C_n^{k_n}p_n^{k_n}(1-p_n)^{n-k_n}\approx\frac{1}{\sqrt{2\pi}}\sqrt{\frac{n}{k_n(n-k_n)}}\left(\frac{np_n}{k_n}\right)^{k_n}\left(\frac{n(1-p_n)}{n-k_n}\right)^{n-k_n}.$$

我们用 $\lambda(n)$ 和 $q_n=1-p_n$ 将上式改写为

$$\frac{1}{\sqrt{2\pi np_nq_n}\varphi(n)}\exp\left(-k_n\ln\left(1+\lambda(n)\sqrt{\frac{q_n}{np_n}}\right)+(k_n-n)\ln\left(1-\lambda(n)\sqrt{\frac{p_n}{nq_n}}\right)\right),$$

其中

$$\varphi(n)=\left(1+\lambda(n)\sqrt{\frac{q_n}{np_n}}\right)\left(1-\lambda(n)\sqrt{\frac{p_n}{nq_n}}\right).$$

当然 $\lambda(n)$ 有界, 从而 ln 的两项都是 $n\to\infty$ 的无穷小, 用

$$\ln(1+x)=x-\frac{x^2}{2}+\frac{x^3}{3}-\cdots$$

将指数内第一项展开到二阶, 由于 $p_n \to p \in (0,1)$, 在 n 充分大时 p_n/q_n 是一个有界量, 于是第一项变为

$$-\left(np_n + \lambda(n)\sqrt{np_nq_n}\right)\left(\lambda(n)\sqrt{\frac{q_n}{np_n}} - \frac{1}{2}\lambda(n)^2\frac{q_n}{np_n} + o\left(\frac{1}{n}\right)\right),$$

整理得

$$-\lambda(n)\sqrt{np_nq_n} - \frac{1}{2}\lambda(n)^2q_n + o(1).$$

同理可得另一项

$$\lambda(n)\sqrt{np_nq_n} - \frac{1}{2}\lambda(n)^2p_n + o(1),$$

而同样由各项有界性得 $\varphi(n)$ 的极限为 1, 因此有等价无穷小

$$C_n^{k_n}p_n^{k_n}(1-p_n)^{n-k_n} \approx \frac{1}{\sqrt{2\pi np_nq_n}}\exp\left(-\frac{1}{2}\lambda(n)^2\right),$$

这就是所需证明的. □

虽然局部极限定理的描述是对随机变量 S_n 的, 但其结果是一个纯分析的结论, 即在某些条件下的等价无穷小, 这允许我们在更广泛的情况里应用局部极限定理. 由此可以求得以下渐近分布.

Theorem 1.11.(**p 分位数的渐近分布**) 设 $0 < p < 1$, 随机变量 (样本)$X_1, X_2, \ldots, X_n$ 独立同分布, 分布函数 $F(x)$ 密度函数存在且连续. 如果整数 $k = k(n)$ 使得

$$\lim_{n\to\infty}\frac{k-np}{\sqrt{n}} = 0,$$

则当 $n \to \infty$ 时, 随机变量序列

$$\sqrt{\frac{n}{p(1-p)}}f(F^{-1}(p))\left(X_{(k)} - F^{-1}(p)\right)$$

依分布收敛到标准正态分布 $N(0,1)$.

Proof. 根据**Theorem 1.8.**的结果, 顺序统计量 $X_{(k)}$ 的密度函数

$$f_{(k)}(x) = \frac{n!}{(k-1)!(n-k)!}F(x)^{k-1}(1-F(x))^{n-k}f(x).$$

利用随机变量函数的密度公式, 对

$$\varphi_n(x) = \sqrt{\frac{n}{p(1-p)}}f(F^{-1}(p))\left(x - F^{-1}(p)\right)$$

所求的 $\varphi_n(X_{(k)})$ 的密度函数为

$$f_n(x) = \frac{n!}{(k-1)!(n-k)!}\sqrt{\frac{p(1-p)}{n}}F\left(\varphi_n^{-1}(x)\right)^{k-1}\left(1-F\left(\varphi_n^{-1}(x)\right)\right)^{n-k}\frac{f\left(\varphi_n^{-1}(x)\right)}{f(F^{-1}(p))}.$$

对每个固定的 x, 根据 F 的连续性

$$\lim_{n\to\infty}\varphi_n^{-1}(x)=F^{-1}(p)+\lim_{n\to\infty}\frac{p(1-p)}{n}\frac{x}{f(F^{-1}(p))}=F^{-1}(p)\implies\lim_{n\to\infty}F\left(\varphi_n^{-1}(x)\right)=p.$$

于是可以取 $p_n(x)=F\left(\varphi_n^{-1}(x)\right)$ 收敛到 p, 有展开

$$p_n(x)=F\left(\varphi_n^{-1}(x)\right)=p+\sqrt{\frac{p(1-p)}{n}}x+o\left(\frac{1}{\sqrt{n}}\right),$$

可知

$$\lim_{n\to\infty}\frac{k-np_n(x)}{\sqrt{np_n(x)(1-p_n(x))}}=\lim_{n\to\infty}\frac{k-np_n(x)}{\sqrt{np(1-p)}}=\lim_{n\to\infty}\left(\frac{k-np}{\sqrt{np(1-p)}}-x+o(1)\right)=-x$$

当然属于区间 $I=B(-x,r(x))$. 于是将上式改写为

$$f_n(x)=C_n^kp_n(x)^k\left(1-p_n(x)\right)^{n-k}\sqrt{\frac{p(1-p)}{n}}\frac{k}{p_n(x)}\frac{f\left(\varphi_n^{-1}(x)\right)}{f(F^{-1}(p))},$$

对每个固定的 x, 根据**Theorem 1.10.**的结果立即得到 $f_n(x)$ 的估计

$$\frac{\sqrt{p(1-p)}}{\sqrt{2\pi p_n(x)(1-p_n(x))}}\exp\left(-\frac{1}{2}\left(\frac{k-np_n(x)}{\sqrt{np_n(x)(1-p_n(x))}}\right)^2\right)\frac{k}{np_n(x)}\frac{f\left(\varphi_n^{-1}(x)\right)}{f(F^{-1}(p))}.$$

根据条件有估计

$$\frac{k}{n}=p+o\left(\frac{1}{\sqrt{n}}\right),\quad p_n(x)=p+o(1),$$

于是两者的商当然趋于 1, 进而有逐点极限

$$\lim_{n\to\infty}f_n(x)=\frac{1}{\sqrt{2\pi}}\exp\left(-\frac{1}{2}x^2\right)\cdot1\cdot\frac{f(F^{-1}(p))}{f(F^{-1}(p))}=\frac{1}{\sqrt{2\pi}}\mathrm{e}^{-\frac{x^2}{2}}=\Phi'(x).$$

现在要证明分布函数有同样的收敛情形. 注意到 f_n 和 Φ' 在 $\mathbb{R}$ 上的积分均为 1, 根据 Lebesgue 控制收敛定理可证 (见分析结论表**Theorem B.6.**)

$$\lim_{n\to\infty}\int_{\mathbb{R}}|f_n(t)-\Phi'(t)|\mathrm{d}t=0,$$

进而根据三角不等式

$$|F_n(x)-\Phi(x)|=\left|\int_{-\infty}^{x}f_n(t)\mathrm{d}t-\Phi(x)\right|\le\int_{\mathbb{R}}|f_n(t)-\Phi'(t)|\mathrm{d}t$$

一致收敛于 0 对每一点 $x\in\mathbb{R}$ 成立, 这就证明了依分布收敛. □

之所以称为 p 分位数的渐近分布, 因为在以上条件下 $k=k(n)$ 在 $[np]$ 的一个邻域内, 当然可以取为 $[np]$, 作为 p 分位数的合理估计. 依照正态分布的性质, 在以上条件下, 结论也可以写为随机变量序列

$$\sqrt{n}\left(X_{(k)}-F^{-1}(p)\right)$$

依分布收敛到正态分布

$$N\left(0,\frac{p(1-p)}{f(F^{-1}(p))^2}\right),$$

或随机变量序列

$$\sqrt{n}f(F^{-1}(p))\left(X_{(k)}-F^{-1}(p)\right)$$

依分布收敛到正态分布 $N(0,p(1-p))$.

现在可以给出一些分布下样本 p 分位数的渐近分布.

Example 1.10.(若干分布 p 分位数的渐近分布) 注意到

$$\lim_{n\to\infty}\frac{[np]-np}{\sqrt{n}}=0,$$

根据**Theorem 1.11.**得到随机变量序列

$$\sqrt{n}f(F^{-1}(p))\left(X_{([np])}-F^{-1}(p)\right)$$

依分布收敛到正态分布 $N(0,p(1-p))$, 其中 $X_{([np])}$ 是 p 分位数的近似. 取 $F(x)$ 为均匀分布, 则密度函数是 $(0,1)$ 上的常值函数, 随机变量序列

$$\sqrt{n}\left(X_{([np]])}-p\right)$$

依分布收敛到正态分布 $N(0,p(1-p))$. 对 Cauchy 分布而言

$$f(x)=\frac{1}{\pi(1+x^2)},\quad F(x)=\frac{1}{\pi}\arctan x+\frac{1}{2},$$

在 $p=\frac{1}{2}$(中位数) 处最简单, 即随机变量序列 $\sqrt{n}X_{([n/2])}$ 依分布收敛到 $N\left(0,\frac{\pi^2}{4}\right)$. 对正态分布而言

$$f(x)=\frac{1}{\sqrt{2\pi}\sigma}\exp\left(-\frac{1}{2}\frac{(x-\mu)^2}{\sigma^2}\right),$$

同样在 $p=\frac{1}{2}$ 处, 随机变量序列 $\sqrt{n}X_{([n/2])}$ 依分布收敛到 $N\left(0,\frac{\pi\sigma^2}{2}\right)$.

最后**Theorem B.7.**给出了求渐近分布的重要方法, 允许我们由依分布收敛的结果出发推知其他结果, 即对求极限的过程作四则运算.

Chapter 2

统计估计

2.1 点估计

回顾概率论的目标是根据分布函数分析随机变量的数值特征, 而数理统计则是通过得到的随机变量特征推断分布函数. 分布函数的全体构成集合, 而对给定的样本必然存在能够很好地符合其特征的分布函数. 然而分布函数的数量如此庞大, 以致几乎不可能找到适当的分布函数. 一个合理而折中的做法是考虑一系列具有某种共性的函数族, 将函数估计问题变为参数估计问题.

常规情况下我们会假设分布族由参数 $\lambda \in \Lambda$ 给出, 即

$$\mathscr{F} = \{F_\lambda \mid \lambda \in \Lambda\}.$$

例如正态分布族由参数 μ, σ 给出, 即

$$\mathscr{F} = \left\{F_{\mu,\sigma} = \int_{-\infty}^{x} \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) \mid (\mu, \sigma) \in \Lambda\right\}.$$

更一般地, 我们的信息可能不足以把可能的分布函数范围用有限个参数统一表达, 例如既有可能是正态分布, 又有可能是指数分布的情况, 此时分布族则可以更直接地看作可能的分布函数的全体, 以自身为参数.

除了分布函数本身以外, 我们还对由分布函数给出的一些数值特征感兴趣, 这由分布函数唯一决定, 因而记作 $\theta = \theta(F)$. 例如均值

$$\mu = \int_{\mathbb{R}} x \mathrm{d}F(x)$$

和总体方差

$$\sigma^2 = \int_{\mathbb{R}^2} \frac{(x-y)^2}{2} \mathrm{d}F(x)\mathrm{d}F(y),$$

又如中位数 $F^{-1}\left(\frac{1}{2}\right)$ 和概率 $F(x_0)$ 等. 因此一个重要的目标就是通过给定的样本 (随机变量), 独立且服从某个未知的正态分布 F, 估计参数 $\theta(F)$. 根据样本得到的估计值

常记作

$$\hat{\theta} = \hat{\theta}(X_1, X_2, \ldots, X_n),$$

因此我们的目标可以表述为: 如何选取适当的函数 $\hat{\theta}$, 使得估计值尽可能好, 这就称为点估计.

Definition 2.1.(点估计) 给定总体 F_λ, λ 未必是实数, 称为总体参数, 从中抽取样本 $X_1, X_2, \ldots, X_n$. $g(\lambda)$ 是关于总体参数的实值函数, 如果 $\hat{g}(\mathbf{X})$ 是 $g(\lambda)$ 的一个估计, 则称 $\hat{g}(\mathbf{X})$ 是 $g(\lambda)$ 的**估计量 (estimator)**, 称此方法为**点估计 (point estimination)**.

一个很好的情况是, λ 确实是实参数 (组), 于是 $g(\lambda)$ 就变为实变函数, 如果能找到 λ 的一个很好的估计 $\hat{\lambda} = \hat{\lambda}(\mathbf{X})$, 则取 $\hat{g}(\mathbf{X}) = g(\hat{\lambda})$ 就是 $g(\lambda)$ 的很好的估计. 使用参数估计近似数值特征估计的原则称为**懒惰原则 (lazy statistician rule)**.

为了评估**Definition 2.1.**中 $\hat{g}(\mathbf{X})$ 与 $g(\lambda)$, 或者在懒惰原则下, $\hat{\lambda} = \hat{\lambda}(\mathbf{X})$ 与 λ 的接近程度, 需要一些评估函数.

Definition 2.2.(无偏性) 设 $X_1, X_2, \ldots, X_n$ 是总体 F_λ 中抽取的样本, $\hat{g}(\mathbf{X})$ 是 $g(\lambda)$ 的一个估计量, 如果

$$\mathbb{E}(\hat{g}(\mathbf{X})) = g(\lambda)$$

对每一组相应于 λ 的样本 $\mathbf{X}$ 都成立, 则称 $\hat{g}(\mathbf{X})$ 是 $g(\lambda)$ 的一个**无偏估计 (unbiased estimation)**.

作为估计接近程度的函数, 依照大数定律, 无偏性意味着当样本量增大时, 估计值会趋近于真实值.

Example 2.1.(总体方差的无偏估计) 回顾样本方差

$$S_n^2 = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \overline{X})^2$$

和总体方差

$$\sigma^2 = \int_{\mathbb{R}^2} \frac{(x-y)^2}{2} \mathrm{d}F(x)\mathrm{d}F(y).$$

根据**Example 1.2.**的结果有 $\mathbb{E}(S_n^2) = \sigma^2$, 这说明样本方差是总体方差的无偏估计.

Example 2.2.(均匀分布的无偏估计) 考虑分布族 $F_\theta \sim U(0, \theta)$, 给定 n 个样本, 根据**Example 1.9.**作伸缩变换, 顺序统计量的期望

$$\mathbb{E}(X_{(k)}) = \frac{k}{n+1}\theta.$$

于是

$$\hat{\theta} = \frac{n+1}{k} X_{(k)}, \quad 1 \le k \le n$$

给出了 n 个无偏估计.

我们当然希望从所有的无偏估计中选一些性质更好的, 一种常见方式是关注方差.

Definition 2.3.(均方损失) 设 $X_1, X_2, \ldots, X_n$ 是总体 F_λ 中抽取的样本, $\hat{g}(\mathbf{X})$ 是 $g(\lambda)$ 的一个估计量. 定义

$$\mathrm{MSE}(\hat{g}(\mathbf{X})) = \mathbb{E}\left((\hat{g}(\mathbf{X}) - g(\lambda))^2\right) = \mathrm{Var}\left(\hat{g}(\mathbf{X})\right) + \left(\mathbb{E}\left(\hat{g}(\mathbf{X})\right) - g(\lambda)\right)^2$$

称为**均方损失 (mean squared error)**.

对无偏估计而言, 右边第二项为 0, 此时均方损失就是方差. 如果方差对一切参数 $\lambda \in \Lambda$ 都 (最) 小, 则称这个估计的有效性 (最) 强. 特别地, 对无偏估计有以下定义.

Definition 2.4.(有效性) 设 $X_1, X_2, \ldots, X_n$ 是总体 F_λ 中抽取的样本, $\hat{g}_1(\mathbf{X})$ 和 $\hat{g}_2(\mathbf{X})$ 是 $g(\lambda)$ 的两个无偏估计量. 如果对一切参数 $\lambda \in \Lambda$, 有

$$\mathrm{Var}\left(\hat{g}_1(\mathbf{X})\right) \le \mathrm{Var}\left(\hat{g}_2(\mathbf{X})\right)$$

恒成立, 且至少存在一个 λ 使严格不等号成立, 则称估计量 $\hat{g}_1(\mathbf{X})$ 比 $\hat{g}_2(\mathbf{X})$ 更有效.

Exercise 1.3. 设 $X_1, X_2, \ldots, X_n$ 是总体 $N(\mu, \sigma^2)$ 中抽取的样本, 对 σ^2 有估计

$$\hat{\theta} = c_n \sum_{k=1}^{n} \left(X_k - \overline{X}\right)^2.$$

试求 c_n 取何值时均方误差最小, 并求出最小值.

Solution. 依照**Definition 2.3.**计算均方损失

$$\mathrm{MSE}(\hat{\theta}) = c_n^2 \mathbb{E}\left(\left(\sum_{k=1}^{n}\left(X_k - \overline{X}\right)^2\right)^2\right) - 2c_n\sigma^2\mathbb{E}\left(\sum_{k=1}^{n}\left(X_k - \overline{X}\right)^2\right) + \sigma^4.$$

根据**Exercise 1.1.**的结果, 取 $\sigma_i = \sigma$ 即知

$$\frac{1}{\sigma^2}\sum_{k=1}^{n}\left(X_k - \overline{X}\right)^2 \sim \chi^2_{n-1},$$

根据**Theorem 1.3.**的结果即得前两阶矩为 $n-1$ 和 n^2-1, 代入得

$$\mathrm{MSE}(\hat{\theta}) = c_n^2(n^2-1)\sigma^4 - 2c_n(n-1)\sigma^4 + \sigma^4.$$

要使之取最小值, 必须

$$\frac{\partial}{\partial c_n} = 2c_n(n^2-1)\sigma^4 - 2(n-1)\sigma^4 = 0 \implies c_n = \frac{1}{n+1},$$

此时

$$\mathrm{MSE}(\hat{\theta}) = \frac{2}{n+1}\sigma^4.$$

Example 2.3.(均匀分布的有效性) 设 $X_1, X_2, \ldots, X_n$ 是总体 $F_\theta \sim U(0,\theta)$ 中抽取的样本. 依照**Example 2.2.**对 θ 有估计

$$\hat{\theta} = \frac{n+1}{k}X_{(k)}.$$

我们已经说明过这是 n 个无偏估计, 于是均方损失

$$\mathrm{MSE}(\hat{\theta}) = \mathrm{Var}(\hat{\theta}) = \frac{(n+1)^2}{k^2}\mathrm{Var}\left(X_{(k)}\right).$$

根据**Example 1.9.**的结果

$$\mathrm{MSE}(\hat{\theta}) = \frac{(n+1)^2}{k^2}\frac{k(n-k+1)}{(n+1)^2(n+2)} = \frac{n-k+1}{k(n+2)} \geq \frac{1}{n(n+2)},$$

取等当且仅当 $k=n$. 再考虑无偏估计 $\hat{\theta} = 2\overline{X}$, 容易计算均方损失

$$\mathrm{MSE}(\hat{\theta}) = 4\,\mathrm{Var}(\overline{X}) = \frac{1}{3n} \leq \frac{1}{n(n+2)}$$

显然是有效性更强的估计, 且取等当且仅当 $n=1$. 再考虑带参数 c_n 的估计 $\hat{\theta} = c_n X_{(n)}$, 则均方损失

$$\mathrm{MSE}(\hat{\theta}) = c_n^2\,\mathrm{Var}\left(X_{(n)}\right) + \left(c_n\mathbb{E}\left(X_{(n)}\right) - \theta\right)^2.$$

由于 $\frac{X_{(n)}}{\theta} \sim U(0,1)$, 再次利用**Example 1.9.**的结果

$$\mathrm{MSE}(\hat{\theta}) = c_n^2\theta^2\frac{n}{(n+1)^2(n+2)} + \left(c_n\theta\frac{n}{n+1} - \theta\right)^2.$$

同理计算偏导数可得最小值点为 $c_n = \frac{n+2}{n+1}$, 代入得最小值

$$\mathrm{MSE}(\hat{\theta}) = \frac{1}{(n+1)^2}\theta^2.$$

我们希望当样本量足够大时, 估计量收敛于估计参数的真实值, 由此将给出了衡量估计量的若干指标. 在**Definition 1.11.**中我们回顾了若干收敛模式, 据此分别给出指标.

Definition 2.5.(相合性) 设 $X_1, X_2, \ldots, X_n$ 是总体 F_λ 中抽取的样本, $\hat{g}_n(\mathbf{X})$ 是 $g(\lambda)$ 的一个估计量.

1. 如果对任意 $\omega \in \Omega \setminus N$, 其中 N 是一个零测集, 都有

$$\lim_{n\to\infty} \hat{g}_n(\mathbf{X}(\omega)) = g(\lambda),$$

   即随机变量 $\hat{g}_n(\mathbf{X})$ 几乎处处收敛到 $g(\lambda)$, 则称 $\hat{g}_n(\mathbf{X})$ 是 $g(\lambda)$ 的**强相合估计 (strongly consistent estimation)**.

2. 如果对任意 $\varepsilon > 0$, 有

$$\lim_{n\to\infty} \mathbb{P}\left(\{\omega \in \Omega \mid |\hat{g}_n(\mathbf{X}(\omega)) - g(\lambda)| < \varepsilon\}\right) = 1,$$

   即随机变量 $\hat{g}_n(\mathbf{X})$ 依概率收敛到 $g(\lambda)$, 则称 $\hat{g}_n(\mathbf{X})$ 是 $g(\lambda)$ 的**弱相合估计 (weakly consistent estimation)**.

3. 如果对某个 $\alpha > 0$, 有

$$\lim_{n\to\infty} \mathbb{E}(|\hat{g}_n(\mathbf{X}) - g(\lambda)|^\alpha) = 0,$$

   称 $\hat{g}_n(\mathbf{X})$ 是 $g(\lambda)$ 的 α 阶矩相合估计.

4. 如果对于任意的 $\varepsilon > 0$, 级数

$$\sum_{n=1}^{\infty} P(|\hat{g}_n(\mathbf{X}) - g(\lambda)| > \varepsilon) < \infty$$

   都成立, 则称 $\hat{g}_n(\mathbf{X})$ **完全收敛 (complete convergence)** 于 $g(\lambda)$.

强相合估计是几乎处处收敛, 当然应该用强大数定律或 Borel-Cantelli 引理证明, 而弱相合估计是依概率收敛, 一般常用弱大数定律, Markov 不等式和 Chebyshev 不等式.

2.2 点估计方法

2.2.1 矩估计

正如分析学中我们用 Taylor 多项式逼近函数, 每一阶多项式的系数由 $\frac{f^{(n)}(x_0)}{n!}$ 给出, 在统计学中我们用 n 阶矩逼近分布函数. 采用求 Taylor 多项式一样的方法, 如果需要前 n 阶矩匹配, 我们必须待定分布函数 F 的 n 个参数

$$F(x) = F(\lambda_1, \lambda_2, \ldots, \lambda_n)(x).$$

则可以计算 $1 \leq k \leq n$ 阶矩

$$E_k(\lambda_1, \lambda_2, \ldots, \lambda_n) = \mathbb{E}\left(X^k\right) = \int_{\mathbb{R}} x^k \mathrm{d}F(x).$$

如果给定了 n 个样本 $X_1, X_2, \ldots, X_n$, 经验分布函数

$$F_n(x) = \frac{1}{n}\sum_{k=1}^{n} \chi(X_k \leq x)$$

编码了样本的所有信息, 因此可用样本矩

$$\hat{E}_{n,k} = \int_{\mathbb{R}} x^k \mathrm{d}F_n(x) = \frac{1}{n}\sum_{i=1}^{n} X_i^k$$

近似分布矩, 即考虑方程组

$$E_k(\lambda_1, \lambda_2, \ldots, \lambda_n) = \hat{E}_{n,k},$$

由此解出参数 $\{\lambda_k\}$ 的值, 并把得到的分布作为实际分布的估计, 这就称为矩估计方法.

一般而言, 利用矩估计方法分为三步: 计算带参数的 k 阶矩 (数值), 解出参数关于 k 阶矩的表达式 (数值), 并代入估计 $\hat{E}_{n,k}$ 求出参数的估计 $\hat{\lambda}$(随机变量).

Algorithm 2.1.(矩估计) 给定分布族 $F(x) = F(x; \lambda_1, \lambda_2, \ldots, \lambda_r)$, 其中 λ_k 是实参数, 以及 n 个简单样本 $X_1, X_2, \ldots, X_n$, 要估计参数的函数 $\varphi = \varphi(\lambda_1, \lambda_2, \ldots, \lambda_r)$. 计算前 r 阶矩

$$E_{n,k}(\lambda_1, \lambda_2, \ldots, \lambda_r) = \mathbb{E}\left(X^k\right) = \int_{\mathbb{R}} x^k \mathrm{d}F(x; \lambda_1, \lambda_2, \ldots, \lambda_r), \quad 1 \leq k \leq r,$$

由此反解出

$$\lambda_k = \psi_k(E_{n,1}, E_{n,2}, \ldots, E_{n,r}),$$

并用样本矩估计分布矩

$$\hat{E}_{n,k} = \frac{1}{n}\sum_{i=1}^{n} X_i^k,$$

得到参数估计

$$\hat{\lambda}_k = \psi_k(\hat{E}_{n,1}, \hat{E}_{n,2}, \ldots, \hat{E}_{n,r})$$

以及函数估计

$$\hat{\varphi} = \varphi(\hat{\lambda}_1, \hat{\lambda}_2, \ldots, \hat{\lambda}_r).$$

由此得到的 $\hat{\varphi}$ 称为 φ 的**矩估计 (moment estimation)**.

Example 2.4.(均匀分布的矩估计) 设 $X_1, X_2, \ldots, X_n$ 是总体 $F \sim U(a,b)$ 中抽取的样本. 我们计算 k 阶矩

$$\mathbb{E}\left(X^k\right) = \int_a^b x^k \frac{1}{b-a} \mathrm{d}x = \frac{1}{k+1} \frac{b^{k+1} - a^{k+1}}{b-a},$$

由于只要估计两个参数, 取前两个

$$\begin{cases} \mathbb{E}(X) = \frac{1}{2}(a+b), \\ \mathbb{E}(X^2) = \frac{1}{3}(a^2 + ab + b^2) \end{cases} \implies \begin{cases} a = \mathbb{E}(X) - \sqrt{3\left(\mathbb{E}(X^2) - \mathbb{E}(X)^2\right)}, \\ b = \mathbb{E}(X) + \sqrt{3\left(\mathbb{E}(X^2) - \mathbb{E}(X)^2\right)}. \end{cases}$$

代入得

$$\begin{cases} \hat{a} = \overline{X} - \sqrt{3} S_n, \\ \hat{b} = \overline{X} + \sqrt{3} S_n. \end{cases}$$

正如 Taylor 展开可以在任意一点进行, 矩估计也可以在任何一个 p 分位数处进行, 特别地可以在均值处进行. 考虑中心矩

$$E_k(\lambda_1, \lambda_2, \ldots, \lambda_n) = \mathbb{E}\left((X-\mu)^k\right) = \int_{\mathbb{R}} (x-\mu)^k \mathrm{d}F(x)$$

和

$$\hat{E}_{n,k} = \frac{1}{n} \sum_{i=1}^n (X_i - \overline{X})^k$$

即可. 由于 (原点) 矩和中心矩可以互相通过多项式表出, 因此计算得到的分布在同阶条件下是完全一致的.

矩估计的每个样本矩

$$\hat{E}_{n,k} = \int_{\mathbb{R}} x^k \mathrm{d}F_n(x) = \frac{1}{n} \sum_{i=1}^n X_i^k \implies \mathbb{E}\left(\hat{E}_{n,k}\right) = \mathbb{E}(X_i^k) = \mathbb{E}(X^k)$$

显然是相应的无偏估计和强相合估计 (独立同分布强大数定律), 然而解方程得到的每个参数 $\hat{\lambda}_k$ 作为 $\hat{E}_{n,k}$ 的函数则未必是 λ_k 的无偏估计, 不过依照**Theorem B.8.**可知只要这个函数是连续的, 则仍然是强相合估计.

2.2.2 极大似然估计

我们先考虑如下例子.

Example 2.5.(二项分布的极大似然估计) 设 X_0 是总体 $F \sim B(n,p)$ 中抽取的样本, 即总体分布

$$\mathbb{P}(X=k)=C_n^k p^k(1-p)^{n-k}.$$

既然 X_0 作为实际发生的样本被我们观测到, 那么总体分布中 X_0 的概率应该很高, 因而将 p 取为最有可能使 X_0 发生的参数是一个合理的估计. 代入得

$$\mathbb{P}(X=X_0)=C_n^{X_0}p^{X_0}(1-p)^{n-X_0},$$

为寻找 p 使之最大, 考虑导数

$$\frac{\partial}{\partial p}\left(p^{X_0}(1-p)^{n-X_0}\right)=0 \iff (1-p)X_0=p(n-X_0) \iff p=\frac{1}{n}X_0,$$

因此取估计

$$\hat{p}=\frac{1}{n}X_0.$$

如果取的独立样本变多, 则依照大数定律, 使样本发生的可能性越大, 结果也就越精确. 如果给定从总体分布 F 取出的 n 个独立样本 $X_1,X_2,\ldots,X_n$, 则这些样本被观测到的概率为

$$\mathbb{P}(X_1,X_2,\ldots,X_n)=\prod_{i=1}^n \mathbb{P}(X=X_i)=\prod_{i=1}^n F(X_i).$$

对连续分布的情形, 上式恒为 0, 因此我们要考虑在 X_i 附近发生概率最大, 即

$$\prod_{i=1}^n \mathbb{P}(|X-X_i|\le\varepsilon)\sim C\varepsilon^n\prod_{i=1}^n f(X_i).$$

如果参数的选取使得以上函数最大, 则得到的分布最有可能使观测到的样本发生, 即最大化了样本发生的**可能性/似然 (likelihood)**. 我们给出具体的算法.

Algorithm 2.2.(极大似然估计) 给定分布族 $F(x)=F(x;\lambda_1,\lambda_2,\ldots,\lambda_r)$, 其中 λ_k 是实参数, 以及 n 个简单样本 $X_1,X_2,\ldots,X_n$, 要估计参数的函数 $\varphi=\varphi(\lambda_1,\lambda_2,\ldots,\lambda_r)$. 计算**似然函数 (likelihood function)**

$$L(\lambda_1,\lambda_2,\ldots,\lambda_r)=\prod_{i=1}^n f(x_i;\lambda_1,\lambda_2,\ldots,\lambda_r).$$

对离散分布而言, 也可用 F 代替 f. 为了求似然函数的最大值, 对各参数求偏导数并令

$$\frac{\partial}{\partial\lambda_k}L(\lambda_1,\lambda_2,\ldots,\lambda_r)=0,$$

解得

$$\lambda_k = \psi_k(x_1, x_2, \ldots, x_k).$$

代入样本得到参数估计

$$\hat{\lambda}_k = \psi_k(X_1, X_2, \ldots, X_n)$$

以及函数估计

$$\hat{\varphi} = \varphi(\hat{\lambda}_1, \hat{\lambda}_2, \ldots, \hat{\lambda}_r).$$

由此得到的 $\hat{\varphi}$ 称为 φ 的**极大似然估计 (maximum likelihood estimation)**.

极大似然估计的好处是不受分布函数各阶矩存在性的影响, 只要给定适当的参数空间, 使似然函数取最大值的参数组总是存在.

Example 2.5.(均匀分布的极大似然估计) 设 $X_1, X_2, \ldots, X_n$ 是总体 $F \sim U(a, b)$ 中抽取的样本. 可以写出似然函数

$$L(a, b) = \prod_{i=1}^{n} \frac{\chi(a \le x_i \le b)}{b - a}.$$

很明显在

$$a = \min_{1 \le i \le n} \{x_i\}, \quad b = \max_{1 \le i \le n} \{x_i\}$$

处取到, 于是代入得

$$\hat{a} = X_{(1)}, \quad \hat{b} = X_{(n)}.$$

求极值是求导运算, 往往比求矩的积分运算更容易计算. 极大似然估计还保留了较多分布信息, 而不是仅仅取决于各阶矩.

Example 2.6.(Poisson 分布的极大似然估计) 设 $X_1, X_2, \ldots, X_n$ 是总体 $F \sim \mathrm{Poi}(\lambda)$ 中抽取的样本. 似然函数

$$L(\lambda) = \left(\prod_{i=1}^{n} x_i!\right)^{-1} \exp\left(-n\lambda + \ln\lambda \sum_{i=1}^{n} x_i\right).$$

由于指数函数单调, 只要让

$$-n\lambda + \ln\lambda \sum_{i=1}^{n} x_i$$

最大, 于是

$$\frac{\partial}{\partial\lambda} = -n + \frac{1}{\lambda}\sum_{i=1}^{n} x_i = 0 \iff \lambda = \frac{1}{n}\sum_{i=1}^{n} x_i$$

处取到, 于是代入得 $\hat{\lambda} = \overline{X}$.

Chapter 3

假设检验

Chapter 4

决策理论

Chapter 5

分析结论表

5.1 广义积分

以下是本书可能涉及的积分运算结果, 读者可以在任何一本微积分或数学分析中找到证明. 我们不再赘述有关广义积分敛散性和积分交换次序的问题.

Theorem A.1.(Gamma 函数) Gamma 函数

$$\Gamma(s) = \int_0^{+\infty} x^{s-1}\mathrm{e}^{-x}\mathrm{d}x, \quad s > 0$$

满足 $\Gamma(s+1) = s\Gamma(s)$. 特别地, 在正整数 $n \in \mathbb{N}^*$ 上取值为 $\Gamma(n) = (n-1)!$.

Proof. 利用分部积分

$$\Gamma(s+1) = -\int_0^{+\infty} x^s \mathrm{d}\mathrm{e}^{-x} = s\int_0^{+\infty} \mathrm{e}^{-x}x^{s-1}\mathrm{d}x - x^s\mathrm{e}^{-x}\Big|_0^{+\infty} = s\Gamma(s).$$

特别地

$$\Gamma(1) = \int_0^{+\infty} \mathrm{e}^{-x}\mathrm{d}x = -\mathrm{e}^{-x}\Big|_0^{+\infty} = 1,$$

归纳可知 $\Gamma(n) = (n-1)!$. □

Theorem A.2.(Beta 函数) Beta 函数

$$B(\alpha,\beta) = \int_0^1 x^{\alpha-1}(1-x)^{\beta-1}\mathrm{d}x, \quad \alpha,\beta > 0$$

满足

$$B(\alpha,\beta) = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha+\beta)}.$$

Proof. 注意到对任意常数 $y>0$, 有

$$\Gamma(\alpha)=\int_0^{+\infty}(xy)^{\alpha-1}\mathrm{e}^{-xy}\mathrm{d}(xy)=y^{\alpha}\int_0^{+\infty}x^{\alpha-1}\mathrm{e}^{-xy}\mathrm{d}x.$$

作换元 $x=\frac{y}{1+y}$ 可得

$$B(\alpha,\beta)=\int_0^{+\infty}\left(\frac{y}{1+y}\right)^{\alpha-1}\left(1-\left(\frac{y}{1+y}\right)\right)^{\beta-1}\mathrm{d}\left(\frac{y}{1+y}\right)=\int_0^{+\infty}\frac{y^{\alpha-1}}{(1+y)^{\alpha+\beta}}\mathrm{d}y.$$

于是

$$B(\alpha,\beta)\Gamma(\alpha+\beta)=\int_0^{+\infty}\int_0^{+\infty}y^{\alpha-1}x^{\alpha+\beta-1}\mathrm{e}^{-x(1+y)}\mathrm{d}x\mathrm{d}y.$$

先对 y 积分得

$$\int_0^{+\infty}y^{\alpha-1}\mathrm{e}^{-xy}\mathrm{d}y=x^{-\alpha}\Gamma(\alpha),$$

于是

$$B(\alpha,\beta)\Gamma(\alpha+\beta)=\Gamma(\alpha)\int_0^{+\infty}x^{\beta-1}\mathrm{e}^{-x}\mathrm{d}x=\Gamma(\alpha)\Gamma(\beta).$$

□

5.2 收敛定理

以下是本书可能涉及的积分收敛定理, 读者可以在任何一本实分析中找到证明.

Theorem B.1.(一致收敛定理) 设 $\{f_n\}$ 为有限正测度集 E 上的一列有界可测函数. 如果 $\{f_n\}$ 一致收敛到 f, 则

$$\lim_{n\to\infty}\int_E f_n(x)\mathrm{d}x=\int_E\left(\lim_{n\to\infty}f_n(x)\right)\mathrm{d}x=\int_E f(x)\mathrm{d}x.$$

Proof. 由一致收敛和逐项有界可知极限函数有界, 且极限函数作为可测函数列的极限也可测. 任取 $\varepsilon>0$, 依照一致有界存在 $N(\varepsilon)\in\mathbb{N}^*$, 使得当 $n>N(\varepsilon)$ 时

$$|f(x)-f_n(x)|<\frac{\varepsilon}{m(E)}.$$

于是有估计

$$\left|\int_E f(x)\mathrm{d}x-\int_E f_n(x)\mathrm{d}x\right|\le\int_E|f(x)-f_n(x)|\,\mathrm{d}x\le\frac{\varepsilon}{m(E)}m(E)=\varepsilon.$$

令 $\varepsilon\to0^+$ 即证. □

Theorem B.2.(有界收敛定理) 设 $\{f_n\}$ 为有限正测度集 E 上的一列可测函数. 如果 $\{f_n\}$ 一致有界 M 且点点收敛到 f, 则

$$\lim_{n\to\infty}\int_E f_n(x)\mathrm{d}x=\int_E\left(\lim_{n\to\infty}f_n(x)\right)\mathrm{d}x=\int_E f(x)\mathrm{d}x.$$

Proof. 极限函数作为可测函数列的极限也可测且有界 M. 对任意 $\varepsilon>0$, 依照 Egoroff 定理存在可测子集 $A\subseteq E$, 使得 $\{f_n\}$ 在 A 上一致收敛到 f 而 $m(E\setminus A)<\frac{\varepsilon}{4M}$. 根据一致收敛存在 $N(\varepsilon)\in\mathbb{N}^*$, 当 $n>N(\varepsilon)$ 时

$$|f_n(x)-f(x)|<\frac{\varepsilon}{2m(E)}.$$

于是有估计

$$\left|\int_E f(x)\mathrm{d}x-\int_E f_n(x)\mathrm{d}x\right|\le\int_A|f(x)-f_n(x)|\,\mathrm{d}x+\int_{E\setminus A}(|f(x)|+|f_n(x)|)<\varepsilon.$$

□

Theorem B.3.(Fatou) 设 $\{f_n\}$ 为 E 上的一列非负可测函数. 如果 $\{f_n\}$ 在 E 上几乎处处收敛到 f, 则

$$\int_E f(x)\mathrm{d}x\le\liminf_{n\to\infty}\int_E f_n(x)\mathrm{d}x.$$

Proof. 在相差零测集 (不影响积分值) 的条件下, 不妨设在 E 上点点收敛. 依照 Lebesgue 积分的定义, 对任意 E 上在有限测度子集 $E_0 \subseteq E$ 外为零的有界可测函数 h 满足 $0 \le h \le f$, 令 $h_n = \min\{h, f_n\}$, M 为 h 的界, 则依照定义 $\{h_n\}$ 点点收敛到 h, 则根据有界收敛定理**Theorem B.2.**

$$\lim_{n\to\infty}\int_E h_n(x)\mathrm{d}x = \lim_{n\to\infty}\int_{E_0} h_n(x)\mathrm{d}x = \int_{E_0}\left(\lim_{n\to\infty} h_n(x)\right)\mathrm{d}x = \int_{E_0} h(x)\mathrm{d}x = \int_E h(x)\mathrm{d}x.$$

由于 $h_n \le f_n$, 两边积分并取下确界得

$$\int_E h(x)\mathrm{d}x = \liminf_{n\to\infty}\int_E h_n(x)\mathrm{d}x \le \liminf_{n\to\infty}\int_E f_n(x)\mathrm{d}x.$$

依照非负可测函数的 Lebesgue 积分定义即证. □

Theorem B.4.(单调收敛定理) 设 $\{f_n\}$ 为 E 上的一列非负可测函数, 在每一点处 $\{f_n(x)\}$ 单调上升. 如果 $\{f_n\}$ 在 E 上几乎处处收敛到 f, 则

$$\lim_{n\to\infty}\int_E f_n(x)\mathrm{d}x = \int_E\left(\lim_{n\to\infty} f_n(x)\right)\mathrm{d}x = \int_E f(x)\mathrm{d}x.$$

Proof. 根据 Fatou 引理**Theorem B.3.**即得

$$\int_E f(x)\mathrm{d}x \le \liminf_{n\to\infty}\int_E f_n(x)\mathrm{d}x.$$

依照单调性

$$f_n \le f \implies \int_E f_n(x)\mathrm{d}x \le \int_E f(x)\mathrm{d}x \implies \limsup_{n\to\infty}\int_E f_n(x)\mathrm{d}x \le \int_E f(x)\mathrm{d}x,$$

两式结合即证. □

Theorem B.5.(Lebesgue 控制收敛定理) 设 $\{f_n\}$ 为 E 上的一列可测函数几乎处处收敛到 f, $\{g_n\}$ 为 E 上的一列非负可测函数几乎处处收敛到可积函数 g, 使得 $|f_n(x)| \le g_n(x)$ 恒成立. 若

$$\lim_{n\to\infty}\int_E g_n(x)\mathrm{d}x = \int_E g(x)\mathrm{d}x < \infty,$$

则

$$\lim_{n\to\infty}\int_E f_n(x)\mathrm{d}x = \int_E\left(\lim_{n\to\infty} f_n(x)\right)\mathrm{d}x = \int_E f(x)\mathrm{d}x.$$

Proof. 不妨设收敛均为点点收敛. 注意到 $\{g_n - f_n\}$ 和 $\{g_n + f_n\}$ 是非负可测函数列, 点点收敛到 $g - f$ 和 $g + f$, 根据 Fatou 引理**Theorem B.3.**即得

$$\int_E (g(x) - f(x))\mathrm{d}x \le \liminf_{n\to\infty}\int_E (g_n(x) - f_n(x))\mathrm{d}x.$$

由于所有积分均被 g 的积分控制从而有限, 于是

$$\int_E g(x)\mathrm{d}x - \int_E f(x)\mathrm{d}x \le \liminf_{n\to\infty} \int_E g_n(x)\mathrm{d}x - \limsup_{n\to\infty} \int_E f_n(x)\mathrm{d}x.$$

由于 g_n 积分收敛到 g 的积分, 即得

$$\limsup_{n\to\infty} \int_E f_n(x)\mathrm{d}x \le \int_E f(x)\mathrm{d}x.$$

同理可证

$$\liminf_{n\to\infty} \int_E f_n(x)\mathrm{d}x \ge \int_E f(x)\mathrm{d}x,$$

两式结合即证. □

Theorem B.6.(Scheffe) 设 $\{f_n\}$ 为 E 上的一列可积函数, 几乎处处收敛到可积函数 f. 则

$$\lim_{n\to\infty} \int_E |f(x) - f_n(x)|\mathrm{d}x = 0 \iff \lim_{n\to\infty} \int_E |f_n(x)|\mathrm{d}x = \int_E |f(x)|\mathrm{d}x.$$

Proof. 先证必要性. 注意到

$$|f_n(x)| \le |f(x) - f_n(x)| + |f(x)| := g_n(x),$$

于是 g_n 点点收敛到 f, 满足

$$\lim_{n\to\infty} \int_E g_n(x)\mathrm{d}x = \lim_{n\to\infty} \int_E |f(x) - f_n(x)|\mathrm{d}x + \int_E |f(x)|\mathrm{d}x = \int_E |f(x)|\mathrm{d}x < \infty,$$

根据 Lebesgue 控制收敛定理**Theorem B.5.**即证.
再证充分性. 此时取

$$g_n(x) = |f(x)| + |f_n(x)| \ge |f(x) - f_n(x)|,$$

则

$$\lim_{n\to\infty} \int_E g_n(x)\mathrm{d}x = \lim_{n\to\infty} \int_E |f_n(x)|\mathrm{d}x + \int_E |f(x)|\mathrm{d}x = 2\int_E |f(x)|\mathrm{d}x < \infty,$$

根据 Lebesgue 控制收敛定理**Theorem B.5.**

$$\lim_{n\to\infty} \int_E |f(x) - f_n(x)|\mathrm{d}x = \lim_{n\to\infty} \int_E 0\mathrm{d}x = 0.$$

□

Theorem B.7.(Slutsky) 设 $(\Omega, \mathscr{F}, \mathbb{P})$ 为概率空间, 其上的随机变量序列 $\{X_n\}$ 依分布收敛到 X, $\{Y_n\}$ 依概率收敛到常数 c, 则只要以下有意义, 四则运算 $\{X_n + Y_n\}$, $\{X_nY_n\}$, $\{X_n/Y_n\}$ 分别依分布收敛到 $X + c$, cX 和 X/c.

Proof. 要证依分布收敛, 相当于证明在连续点处点点收敛, 以下只考虑连续的情形. 对任意 $\varepsilon > 0$, 有

$$\mathbb{P}(X_n + Y_n \le x) \le \mathbb{P}(X_n + Y_n \le x, |Y_n - c| < \varepsilon) + \mathbb{P}(|Y_n - c| \ge \varepsilon).$$

第一项不超过

$$\mathbb{P}(X_n \le x - c + \varepsilon, |Y_n - c| < \varepsilon) \le \mathbb{P}(X_n \le x - c + \varepsilon),$$

而第二项在 $n \to \infty$ 时趋于 0(依概率收敛的定义), 因此取极限得

$$\limsup_{n\to\infty} \mathbb{P}(X_n + Y_n \le x) \le \lim_{n\to\infty} \mathbb{P}(X_n \le x - c + \varepsilon) = F(x - c + \varepsilon),$$

最后一个等号是依分布收敛的定义. 同理可得

$$\mathbb{P}(X_n + Y_n \le x) \ge \mathbb{P}(X_n \le x - c - \varepsilon) - \mathbb{P}(|Y_n - c| \ge \varepsilon),$$

取极限得

$$\liminf_{n\to\infty} \mathbb{P}(X_n + Y_n \le x) \ge \lim_{n\to\infty} \mathbb{P}(X_n \le x - c - \varepsilon) = F(x - c - \varepsilon).$$

由于 F 连续, 在以上两式取 $\varepsilon \to 0^+$ 得到

$$\lim_{n\to\infty} \mathbb{P}(X_n + Y_n \le x) = F(x - c),$$

这就是 $X + c$ 的分布函数, 即依分布收敛到 $X + c$. 对乘法的情形, 用 $\frac{x}{c\pm\varepsilon}$ 代替 $x - c \pm \varepsilon$ 即可, 除法的情形也类似. □

Theorem B.8.(连续映射定理) 设 $(\Omega, \mathscr{F}, \mathbb{P})$ 为概率空间, 其上的随机变量序列 $\{X_n\}$ 几乎处处/依概率收敛到 X. 对任意连续函数 $\varphi : \mathbb{R} \to \mathbb{R}$, 有随机变量序列 $\{\varphi(X_n)\}$ 几乎处处/依概率收敛到 $\varphi(X)$.

Proof. 几乎处处的情形是显然的, 因为连续函数保持极限, 有几乎处处

$$\lim_{n\to\infty} \varphi(X_n(\omega)) = \varphi\left(\lim_{n\to\infty} X_n(\omega)\right) = \varphi(X(\omega)).$$

对依概率收敛的情形, 先讨论 φ 在紧集 $[-n, n]$ 上连续. 对任意 $\varepsilon > 0$, 由紧集上的连续函数一致连续, 对每一点 $x \in \mathbb{R}$ 存在 $\delta(\varepsilon) > 0$, 使得只要 $|t - x| < \delta(\varepsilon)$, 就有 $|\varphi(t) - \varphi(x)| < \varepsilon$. 于是有估计

$$\mathbb{P}(|\varphi(X_n) - \varphi(X)| \ge \varepsilon) \le \mathbb{P}(|X_n - X| \ge \delta(\varepsilon)) + \mathbb{P}(|\varphi(X_n) - \varphi(X)| \ge \varepsilon, |X_n - X| < \delta(\varepsilon)).$$

由 $\delta(\varepsilon)$ 的定义第二项恒为 0, 因此两边取极限, 由 $\{X_n\}$ 依概率收敛可得

$$\lim_{n\to\infty}\mathbb{P}(|\varphi(X_n)-\varphi(X)|\geq\varepsilon)\leq\lim_{n\to\infty}\mathbb{P}(|X_n-X|\geq\delta(\varepsilon))=0.$$

现在考虑 $\mathbb{R}$ 上连续的情形, 由于 $\mathbb{P}(\Omega)=1$, 对任意 $\eta>0$, 存在 $M(\eta)\in\mathbb{N}^*$, 使得

$$\mathbb{P}(|X_n|+|X|\geq M(\eta))\leq\eta,$$

于是取 $n=M(\eta)$, 用同样方法可得

$$\mathbb{P}(|\varphi(X_n)-\varphi(X)|\geq\varepsilon)\leq\mathbb{P}(|X_n-X|\geq\delta(\varepsilon,\eta))+\eta.$$

依次取 $n\to\infty$ 和 $\eta\to 0$ 即证. □