数理统计讲义

minamomo

Thursday 9th April, 2026

References:

[1] 数理统计 (第三版), 韦来生, 2025.

Marks:

1. 样本空间 $\mathscr{X}$.

Preface

“正如概率论是数学分析的习题课, 数理统计是数学分析和概率论的习题课的感觉一样.”

minamomo

2026.3 于中国上海

This page intentionally left blank.

Contents

1 统计学基础 **7**

1.1 样本与分布 7

1.2 正态分布的统计量 12

1.3 χ^2 分布, t 分布与 F 分布 15

1.3.1 χ^2 分布 15

1.3.2 t 分布 18

1.3.3 F 分布 21

1.4 顺序统计量 23

1.5 渐近分布 * 28

2 统计估计 **31**

3 假设检验 **33**

4 决策理论 **35**

5 常用积分表 **37**

This page intentionally left blank.

Chapter 1

统计学基础

1.1 样本与分布

概率论所研究对象是以各种形式给出的分布, 包括概率 P, 分布 F 以及密度 f, 连同分布的各种特征, 包括期望 $\mathbb{E}$, 方差 Var, 协方差 Cov 等. 总而言之, 概率论的目标在于对给定的分布, 分析这个分布下随机事件发生的特征并加以描述.

统计学的目标则恰恰相反. 统计学的研究对象是概率论的研究结果, 即实际发生的随机事件, 而统计学的研究目标则是概率论的研究对象, 即分析随机事件数据服从的分布. 对分布本身加以估计, 就称为统计估计, 对分布带来的结果加以估计, 就称为假设检验, 应用估计的结果, 就称为决策理论.

Definition 1.1.(总体和样本) **总体 (population)** 是指研究对象所满足的, 实际上的分布 F. 总体分布在实际问题中往往是存在但未知的. 服从总体分布的随机变量称为**样本 (sample)**. 样本往往被认为是已知的. 样本的所有可能取值的集合称为**样本空间 (sample space)**.

统计学的一个目标是通过样本还原总体分布, 即将总体分布近似地表示成样本 $\{X_k\}_{k=1}^n$ 的函数.

作为例子, 我们来看概率论是如何通过分布分析随机事件的特征的.

Example 1.1.(正态分布的总体方差) 给定 n 维随机向量 $\mathbf{X}$, 每个分量独立同分布, 服从正态分布 $N(\mu, \sigma^2)$, 通过这些随机变量可以构造若干新随机变量, 例如

$$A = \frac{1}{n}\sum_{k=1}^{n}(X_k - \mu)^2$$

就是典型的例子. 我们求其期望和方差. 根据独立性

$$\mathbb{E}(A) = \mathbb{E}\left((X_1 - \mu)^2\right) = \mathbb{E}\left(X_1^2 - 2X_1\mu + \mu^2\right).$$

注意依照方差的定义以及正态分布的性质

$$\mathbb{E}\left(X_1^2\right)-\mathbb{E}(X_1)^2=\mathrm{Var}(X_1) \implies \mathbb{E}\left(X_1^2\right)=\mu^2+\sigma^2,$$

代入得

$$\mathbb{E}(A)=\mu^2+\sigma^2-2\mu^2+\mu^2=\sigma^2.$$

考虑 $Y_k=X_k-\mu$ 服从 $N(0,\sigma^2)$, 有

$$\mathrm{Var}(A)=\mathrm{Var}\left(\frac{1}{n}\sum_{k=1}^{n}Y_k^2\right)=\frac{1}{n^2}\mathbb{E}\left(\left(\sum_{k=1}^{n}Y_k^2\right)^2\right)-\sigma^4.$$

对平方项展开, 并利用独立性得

$$\mathbb{E}\left(\left(\sum_{k=1}^{n}Y_k^2\right)^2\right)=\mathbb{E}\left(\sum_{k=1}^{n}Y_k^4+\sum_{i\neq j}(Y_iY_j)^2\right)=n\mathbb{E}\left(Y_1^4\right)+n(n-1)\mathbb{E}\left(Y_1^2\right)^2.$$

根据期望的定义

$$\mathbb{E}\left(Y_1^4\right)=\int_{\mathbb{R}}x^4f(x)\mathrm{d}x=\frac{1}{\sqrt{2\pi}\sigma}\int_{\mathbb{R}}x^4\exp\left(-\frac{x^2}{2\sigma^2}\right)\mathrm{d}x.$$

作分部积分得

$$\mathbb{E}\left(Y_1^4\right)=\frac{1}{\sqrt{2\pi}\sigma}\int_{\mathbb{R}}x^4\exp\left(-\frac{x^2}{2\sigma^2}\right)\mathrm{d}x=\frac{-\sigma^2}{\sqrt{2\pi}\sigma}\int_{\mathbb{R}}x^3\mathrm{d}\exp\left(-\frac{x^2}{2\sigma^2}\right),$$

即得

$$\mathbb{E}\left(Y_1^4\right)=\frac{3\sigma^2}{\sqrt{2\pi}\sigma}\int_{\mathbb{R}}x^2\exp\left(-\frac{x^2}{2\sigma^2}\right)\mathrm{d}x=3\sigma^2\mathbb{E}\left(Y_1^2\right)=3\sigma^4.$$

代入得

$$\mathrm{Var}(A)=\frac{n\mathbb{E}\left(Y_1^4\right)+n(n-1)\mathbb{E}\left(Y_1^2\right)^2}{n^2}-\sigma^4=\frac{2}{n}\sigma^4.$$

下面构造的随机变量与之对应.

Example 1.2.(正态分布的样本方差) 给定 n 维随机向量 $\mathbf{X}$, 每个分量独立同分布, 服从正态分布 $N(\mu,\sigma^2)$, 定义随机变量

$$B=\frac{1}{n-1}\sum_{k=1}^{n}(X_k-\overline{X})^2.$$

注意到可以作变形

$$
\begin{aligned}
B &= \frac{1}{n-1}\sum_{k=1}^{n}(X_k-\overline{X})^2 \\
&= \frac{1}{n-1}\sum_{k=1}^{n}\left(X_k^2-2X_k\overline{X}+\overline{X}^2\right) \\
&= \frac{1}{n-1}\left(\sum_{k=1}^{n}X_k^2-2n\overline{X}^2+n\overline{X}^2\right) \\
&= \frac{1}{n(n-1)}\left(n\sum_{k=1}^{n}X_k^2-\left(\sum_{k=1}^{n}X_k\right)^2\right) \\
&= \frac{1}{n(n-1)}\left(n\sum_{k=1}^{n}X_k^2-\sum_{k=1}^{n}X_k^2-\sum_{i\neq j}X_iX_j\right) \\
&= \frac{1}{n}\sum_{k=1}^{n}X_k^2-\frac{1}{n(n-1)}\sum_{i\neq j}X_iX_j.
\end{aligned}
$$

取期望即得

$$\mathbb{E}(B)=\mathbb{E}\left(X_1^2\right)-\mathbb{E}(X_1)^2=\mathrm{Var}(X_1)=\sigma^2.$$

由于 X_k 同分布, 在只有一个变量时我们也直接记作 X. 为求方差, 写为

$$\mathrm{Var}(B)=\mathrm{Cov}(B,B),$$

即

$$\mathrm{Cov}\left(\frac{1}{n}\sum_{k=1}^{n}X_k^2-\frac{1}{n(n-1)}\sum_{i\neq j}X_iX_j,\frac{1}{n}\sum_{k=1}^{n}X_k^2-\frac{1}{n(n-1)}\sum_{i\neq j}X_iX_j\right).$$

依照定义协方差具有双线性, 于是可以逐项展开, 且根据对称性有

$$\mathrm{Var}(B)=\mathrm{Cov}\left(X_1^2-X_1X_2,\frac{1}{n}\sum_{k=1}^{n}X_k^2-\frac{1}{n(n-1)}\sum_{i\neq j}X_iX_j\right).$$

注意到独立变量的协方差为 0, 可知上式为

$$\frac{1}{n}\mathrm{Cov}\left(X_1^2,X_1^2-2X_1X_2\right)-\frac{1}{n}\mathrm{Cov}\left(X_1X_2,X_1^2+X_2^2-2\frac{n-2}{n-1}(X_1+X_2)X_3-\frac{2X_1X_2}{n-1}\right).$$

依照定义和对称性计算得

$$
\begin{aligned}
\mathrm{Var}(B)=&\frac{1}{n}\left(\mathrm{Cov}\left(X_1^2,X_1^2\right)-4\,\mathrm{Cov}\left(X_1^2,X_1X_2\right)\right) \\
&+\frac{1}{n(n-1)}\left(4(n-2)\,\mathrm{Cov}\left(X_1X_2,X_1X_3\right)+2\,\mathrm{Cov}\left(X_1X_2,X_1X_2\right)\right) \\
=&\frac{1}{n}\left(\mathbb{E}\left(X_1^4\right)-\mathbb{E}\left(X_1^2\right)^2-4\mathbb{E}\left(X_1^3X_2\right)+4\mathbb{E}\left(X_1^2\right)\mathbb{E}\left(X_1X_2\right)\right) \\
&+\frac{4(n-2)}{n(n-1)}\left(\mathbb{E}\left(X_1^2X_2X_3\right)-\mathbb{E}\left(X_1X_2\right)\mathbb{E}\left(X_1X_3\right)\right) \\
&+\frac{2}{n(n-1)}\left(\mathbb{E}\left(X_1^2X_2^2\right)-\mathbb{E}\left(X_1X_2\right)^2\right).
\end{aligned}
$$

依照独立性有

$$\begin{aligned}\operatorname{Var}(B) =& \frac{1}{n}\left(\mathbb{E}\left(X^4\right)-\mathbb{E}\left(X^2\right)^2-4\mathbb{E}\left(X^3\right)\mathbb{E}\left(X_1\right)+4\mathbb{E}\left(X^2\right)\mathbb{E}\left(X\right)^2\right)\\ &+\frac{4(n-2)}{n(n-1)}\left(\mathbb{E}\left(X^2\right)\mathbb{E}\left(X\right)^2-\mathbb{E}\left(X\right)^4\right)+\frac{2}{n(n-1)}\left(\mathbb{E}\left(X^2\right)^2-\mathbb{E}\left(X\right)^4\right).\end{aligned}$$

利用矩生成函数或特征函数可以计算 n 阶矩

$$\mathbb{E}\left(X\right)=\mu,\quad \mathbb{E}\left(X^2\right)=\mu^2+\sigma^2,\quad \mathbb{E}\left(X^3\right)=\mu^3+3\mu\sigma^2,\quad \mathbb{E}\left(X^4\right)=\mu^4+6\mu^2\sigma^2+3\sigma^4,$$

代入计算得

$$\operatorname{Var}(B)=\frac{2}{n-1}\sigma^4.$$

由此我们可以计算两者之间的关系.

Example 1.3.(总体方差与样本方差的相关系数) **Example 1.1.**和**Example 1.2.**中定义的随机变量 A, B, 可以计算协方差

$$\operatorname{Cov}(A,B)=\operatorname{Cov}\left((X_1-\mu)^2,\frac{1}{n}\sum_{k=1}^{n}X_k^2-\frac{1}{n(n-1)}\sum_{i\neq j}X_iX_j\right).$$

仍然依照独立性

$$\operatorname{Cov}(A,B)=\operatorname{Cov}\left((X_1-\mu)^2,\frac{1}{n}X_1^2-\frac{2}{n}X_1X_2\right)=\frac{1}{n}\operatorname{Cov}\left(X_1^2-2\mu X_1,X_1^2-2X_1X_2\right).$$

展开计算得

$$\operatorname{Cov}(A,B)=\frac{2}{n}\sigma^4.$$

依照相关系数的定义

$$\rho(A,B)=\frac{\operatorname{Cov}(A,B)}{\sqrt{\operatorname{Var}(A)\operatorname{Var}(B)}}=\frac{\frac{2}{n}\sigma^4}{\sqrt{\frac{2}{n}\sigma^4\cdot\frac{2}{n-1}\sigma^4}}=\sqrt{\frac{n-1}{n}}.$$

我们看到以上样本具有很好的性质: 独立性允许我们分别计算期望, 而同分布允许我们用对称性化简, 由此引出了如下定义.

Definition 1.2.(简单随机样本) 独立同分布 (i.i.d.) 的有限个样本称为简单随机样本.

简单随机样本的分布函数和密度函数就是

$$F_n(\mathbf{x})=\prod_{k=1}^{n}F(x_k),\quad f_n(\mathbf{x})=\prod_{k=1}^{n}f(x_k).$$

简单随机样本对还原总体分布提供了很好的条件, 这就是统计推断. 然而有限个样本不足以确定某个分布, 因此需要假定某种分布的类型. 选定某种分布类型, 例如 Poisson 分布, 正态分布等, 其所有可能分布称为分布族, 参数的全体取值称为参数空间.

利用样本可以构造出分布的若干特征, 用来近似总体分布的特征.

Definition 1.3.(统计量) 给定 n 个样本 $\{X_k\}_{k=1}^n$, 任何一个样本的函数

$$\varphi(X_1, X_2, \ldots, X_n)$$

称为统计量.

尤其要强调的是统计量的函数中不能含有总体分布的参数, 而只能由样本和 $\mathbb{R}$ 中元以及若干函数构成. 均值 $\overline{X}$, 方差 $\mathrm{Var}(X)$, 中位数, 最大值等都是常见的统计量.

我们可以用函数编码样本的信息.

Definition 1.4.(经验分布函数) 样本 $\{X_k\}_{k=1}^n$ 的**经验分布函数 (empirical distribution function, EDF)** 定义为

$$F_n(x) = \frac{1}{n}\sum_{k=1}^{n} \chi(X_i \le x), \quad \chi(P) = \begin{cases} 1, & P = \mathbf{T}, \\ 0, & P = \mathbf{F}. \end{cases}$$

1.2 正态分布的统计量

在这一部分, 我们主要研究各个统计量作为随机变量的数值特征.

Example 1.4.(正态分布顺序统计量的期望) 设 $\{X_k\}_{k=1}^n$ 独立同分布, 服从标准正态分布 $N(0,1)$. 考虑其最大值

$$X = \max_{1\le k\le n}\{X_k\}$$

的概率分布

$$F(x) = \mathbb{P}(X \le x) = \prod_{k=1}^n \mathbb{P}(X_k \le x) = \Phi(x)^n.$$

于是期望

$$\mathbb{E}(X) = \int_{\mathbb{R}} x\mathrm{d}\mathbb{P}(X \le x) = -\int_{\mathbb{R}} x\mathrm{d}\left(1-\Phi(x)^n\right) = \int_{\mathbb{R}} \left(1-\Phi(x)^n\right)\mathrm{d}x.$$

其展开的主项为 $\sqrt{2\ln n}$.

对样本 $\{X_k\}_{k=1}^n$, 我们尤其关心以下两个先前讨论过的统计量.

Definition 1.5.(样本均值和样本方差) 给定 n 个样本 $\{X_k\}_{k=1}^n$, 定义**样本均值**

$$\overline{X} = \frac{1}{n}\sum_{k=1}^n X_k$$

和**样本方差**

$$S^2 = \frac{1}{n-1}\sum_{k=1}^n (X_k - \overline{X})^2.$$

我们先作简要分析.

Example 1.5.(样本均值和样本方差的线性代数刻画) 给定 n 个样本 $\{X_k\}_{k=1}^n$, 注意到

$$\overline{X} = \frac{1}{n}\sum_{k=1}^n X_k = \frac{1}{n}\begin{bmatrix}1 & 1 & \cdots & 1\end{bmatrix}\begin{bmatrix}X_1\\X_2\\\vdots\\X_n\end{bmatrix} = \frac{1}{n}\mathbf{1}^T\mathbf{X},$$

以及

$$S^2 = \frac{1}{n-1}\sum_{k=1}^n (X_k - \overline{X})^2 = \frac{n}{n-1}\left(\frac{1}{n}\sum_{k=1}^n X_k^2 - \overline{X}^2\right),$$

展开得

$$S^2 = \frac{n}{n-1}\left(\frac{1}{n}\mathbf{X}^T\mathbf{X} - \frac{1}{n^2}\mathbf{X}^T\mathbf{1}\mathbf{1}^T\mathbf{X}\right) = \frac{1}{n-1}\mathbf{X}^T\left(I - \frac{1}{n}\mathbf{1}\mathbf{1}^T\right)\mathbf{X}.$$

这启示我们把 $\mathbf{1}$ 单位化为 $\mathbf{1} = \|\mathbf{1}\|\hat{\mathbf{1}} = \sqrt{n}\mathbf{e}_1$, 则样本均值和样本方差可以写为

$$\overline{X} = \frac{1}{\sqrt{n}}\mathbf{e}_1\mathbf{X}, \quad S^2 = \frac{1}{n-1}\mathbf{X}^T\left(I - \mathbf{e}_1\mathbf{e}_1^T\right)\mathbf{X}.$$

对单位向量 $\mathbf{e}_1$, 一个自然的想法是将之扩充为一组标准正交基 $\{\mathbf{e}_k\}_{k=1}^n$, 于是

$$S^2 = \frac{1}{n-1}\mathbf{X}^T\left(I - \mathbf{e}_1\mathbf{e}_1^T\right)\mathbf{X} = \frac{1}{n-1}\mathbf{X}^T\left(\sum_{k=2}^n \mathbf{e}_k\mathbf{e}_k^T\right)\mathbf{X} = \frac{1}{n-1}\sum_{k=2}^n(\mathbf{e}_k^T\mathbf{X})^2.$$

由于这是一组标准正交基, 构成正交矩阵 $Q = \begin{bmatrix}\mathbf{e}_1 & \mathbf{e}_2 & \cdots & \mathbf{e}_n\end{bmatrix}$, 于是 $\mathbf{e}_k^T\mathbf{X}$ 恰好是 $Q^T\mathbf{X}$ 的 k-分量. 这表明样本均值可以看作 $\mathbf{Y} = Q^T\mathbf{X}$ 的 1-分量, 而样本方差可以看作 $\mathbf{Y}$ 的后 $n-1$ 个分量的平方均值.

上例说明在适当的线性变换下, 样本均值和样本方差都可以看作某种均值, 从而简化讨论. 因此有必要研究一些分布下的样本在线性变换, 尤其是正交变换下的性质.

Theorem 1.1.(正态分布的正交不变性) 给定 n 个样本 $\{X_k\}_{k=1}^n$ 独立同正态分布 $N(\mu, \sigma^2)$, 则对正交变换 Q, $\mathbf{Y} = Q\mathbf{X}$ 的各个分量也独立, 且服从正态分布. 特别地, 当 $\mu = 0$ 时, $\mathbf{Y}$ 的各个分量独立同分布 $N(0, \sigma^2)$.

Proof. 先考虑对 $\mathbf{X}$ 作一般的线性组合

$$L(\mathbf{X}) = \sum_{k=1}^n c_k X_k,$$

根据特征函数理论, 对每个 $X = X_k$ 有

$$\psi_X(t) = \mathbb{E}\left(\exp\left(\mathrm{i}tX\right)\right) = \exp\left(\mathrm{i}\mu t - \frac{1}{2}\sigma^2 t^2\right),$$

可知

$$\psi_{L(\mathbf{X})}(t) = \mathbb{E}\left(\exp\left(\mathrm{i}t\sum_{k=1}^n c_k X_k\right)\right) = \prod_{k=1}^n \mathbb{E}\left(\exp(\mathrm{i}c_k t X_k)\right),$$

代入展开得

$$\psi_{L(\mathbf{X})}(t) = \exp\left(\mathrm{i}\mu t\sum_{k=1}^n c_k - \frac{1}{2}\sigma^2 t^2\sum_{k=1}^n c_k^2\right),$$

这就说明 $L(\mathbf{X})$ 服从正态分布

$$L(\mathbf{X}) \sim N\left(\mu\sum_{k=1}^n c_k, \sigma^2\sum_{k=1}^n c_k^2\right).$$

现在考虑正交矩阵 Q, 则 $\mathbf{Y} = Q\mathbf{X}$ 的每个分量服从正态分布

$$Y_i \sim N\left(\mu\sum_{k=1}^n a_{ik}, \sigma^2\sum_{k=1}^n a_{ik}^2\right) = N\left(\mu\sum_{k=1}^n a_{ik}, \sigma^2\right).$$

为证独立性, 只要计算协方差. 根据协方差的双线性可知

$$\mathrm{Cov}(Y_i, Y_j) = \sum_{k=1}^{n}\sum_{l=1}^{n} a_{ik}a_{jl}\,\mathrm{Cov}(X_k, X_l) = \sigma^2 \sum_{k=1}^{n} a_{ik}a_{jk} = \sigma^2 (Qe_i)^T (Qe_j).$$

根据正交矩阵的性质, $i \neq j$ 时上式为 0, 于是 $\mathbf{Y}$ 各分量独立. 最后当 $\mu = 0$ 时, 代入 Y_i 的分布可知独立同分布. □

结合**Example 1.5.**的讨论, 由于样本均值和样本方差本质分别依赖 Y_1 以及 $\{Y_k\}_{k=2}^n$, 从而也是独立的. 样本均值是容易计算的.

$$\overline{X} = \sum_{k=1}^{n} \frac{1}{n} X_k \sim N\left(\mu, \frac{\sigma^2}{n}\right).$$

为了讨论样本方差, 由于这是 $n-1$ 个独立正态分布样本的平方和, 只要讨论此种形式的密度函数. 我们暂时只考虑独立同分布的情形.

Example 1.6.(正态分布的样本方差) 给定样本 $\{X_k\}_{k=1}^n$ 独立同正态分布 $N(0, \sigma^2)$, 则样本方差

$$S^2 = \frac{1}{n-1}\sum_{k=2}^{n} Y_k^2.$$

根据**Theorem 1.1.**的结果, 每个 Y_k 服从正态分布 $N(0, \sigma^2)$, 于是特征函数

$$\psi_{Y^2}(t) = \mathbb{E}\left(\exp\left(\mathrm{i}tY^2\right)\right) = \frac{1}{\sqrt{2\pi}\sigma}\int_{\mathbb{R}} \exp\left(\mathrm{i}tx^2 - \frac{1}{2\sigma^2}x^2\right)\mathrm{d}x = (1 - 2\mathrm{i}\sigma^2 t)^{-\frac{1}{2}}.$$

于是 S^2 的特征函数

$$\psi_{S^2}(t) = \left(1 - \frac{2\mathrm{i}\sigma^2}{n-1}t\right)^{-\frac{n-1}{2}}.$$

计算密度函数

$$f_{S^2}(x) = \frac{1}{2\pi}\int_{\mathbb{R}} \mathrm{e}^{-\mathrm{i}tx}\left(1 - \frac{2\mathrm{i}\sigma^2}{n-1}t\right)^{-\frac{n-1}{2}}\mathrm{d}t = \left(\frac{n-1}{2\sigma^2}\right)^{\frac{n-1}{2}} \frac{x^{\frac{n-1}{2}-1}}{\Gamma\left(\frac{n-1}{2}\right)} \exp\left(-\frac{(n-1)x}{2\sigma^2}\right).$$

1.3 χ^2 分布, t 分布与 F 分布

1.3.1 χ^2 分布

独立正态分布的平方和称为 χ^2 分布.

Definition 1.6.(χ^2 分布) 给定 n 个样本 $\{X_k\}_{k=1}^n$ 独立同标准正态分布, 称随机变量

$$\xi = \sum_{k=1}^n X_k^2$$

服从的分布为自由度为 n 的 χ^2 分布, 记作 $\xi \sim \chi_n^2$.

我们可以计算其密度函数.

Theorem 1.2.(χ^2 分布的密度函数) 设 ξ 是服从自由度为 n 的 χ^2 分布的随机变量, 则其概率密度函数为

$$f_n(x) = \begin{cases} \frac{1}{2^{\frac{n}{2}}\Gamma\left(\frac{n}{2}\right)} x^{\frac{n}{2}-1}\mathrm{e}^{-\frac{x}{2}}, & x > 0, \\ 0, & x \le 0. \end{cases}$$

其中

$$\Gamma(t) = \int_0^{+\infty} x^{t-1}\mathrm{e}^{-x}\mathrm{d}x.$$

Proof. 依照概率分布的定义

$$F_n(x) = \mathbb{P}\left(\sum_{k=1}^n X_k^2 \le x\right) = \int_{\sum_{k=1}^n x_k^2 \le x} \left(\frac{1}{\sqrt{2\pi}}\right)^n \exp\left(-\frac{1}{2}\sum_{k=1}^n x_k^2\right) \mathrm{d}x_1 \cdots \mathrm{d}x_n.$$

考虑换元

$$\begin{cases} x_1 = \rho\cos\theta_1\cos\theta_2\cdots\cos\theta_{n-1}, \\ x_2 = \rho\cos\theta_1\cos\theta_2\cdots\sin\theta_{n-1}, \\ x_3 = \rho\cos\theta_1\cos\theta_2\cdots\sin\theta_{n-2}, \\ \cdots, \\ x_n = \rho\sin\theta_1. \end{cases}$$

相应的 Jacobi 行列式为

$$\det(J) = \rho^{n-1}\varphi(\theta),$$

其中 $\varphi(\theta)$ 表示只与 $\{\theta_k\}_{k=1}^{n-1}$ 有关的函数. 此后我们将任意常数记作待定的 C_n, 得到

$$F_n(x) = C_n \int_{\rho^2 \le x} \exp\left(-\frac{1}{2}\rho^2\right) \rho^{n-1}\varphi(\theta)\mathrm{d}\rho\mathrm{d}\theta_1\cdots\mathrm{d}\theta_{n-1}.$$

注意到区域 $\rho^2 \le x$ 相当于 $\rho \in [0, \sqrt{x}]$ 而 θ_k 在固定范围内变化, 即 θ 的范围不依赖于 x, 从而被视作常数 C_n 的部分, 于是

$$F_n(x) = \begin{cases} C_n \int_0^{\sqrt{x}} \exp\left(-\frac{1}{2}\rho^2\right) \rho^{n-1} \mathrm{d}\rho, & x > 0, \\ 0, & x \le 0. \end{cases}$$

由于这是概率分布, 令 $x \to +\infty$ 必定得到 1, 即

$$C_n \int_0^{+\infty} \exp\left(-\frac{1}{2}\rho^2\right) \rho^{n-1} \mathrm{d}\rho = 1.$$

作换元 $r = \frac{1}{2}\rho^2$ 可以看出

$$C_n \int_0^{+\infty} \mathrm{e}^{-r} (2r)^{\frac{n-1}{2}} (2r)^{-\frac{1}{2}} \mathrm{d}r = C_n 2^{\frac{n}{2}-1} \Gamma\left(\frac{n}{2}\right) = 1.$$

这就给出了 C_n 的值. 现在只要对分布函数求导

$$\frac{\mathrm{d}}{\mathrm{d}x} \int_0^{\sqrt{x}} \exp\left(-\frac{1}{2}\rho^2\right) \rho^{n-1} \mathrm{d}\rho = x^{\frac{n-1}{2}} \mathrm{e}^{-\frac{x}{2}} \frac{1}{2\sqrt{x}},$$

代入 C_n 的值即证. □

我们也称以

$$f(x) = \frac{1}{\beta^\alpha \Gamma(\alpha)} x^{\alpha-1} \mathrm{e}^{-\frac{x}{\beta}}$$

为密度函数的分布为参数 α, β 的 Γ 分布, 记作 $X \sim \Gamma(\alpha, \beta)$. 则 χ^2 分布相当于 $\Gamma\left(\frac{n}{2}, \frac{1}{2}\right)$. 由于指数分布的密度函数为

$$f(x) = \lambda \mathrm{e}^{\lambda x}, \quad x > 0,$$

因此自由度为 2 的 χ^2 分布恰好是指数分布 $\mathrm{Exp}\left(\frac{1}{2}\right)$. 一般的指数分布可以通过变换改写为 $\mathrm{Exp}\left(\frac{1}{2}\right)$ 的形式.

利用密度函数可以计算 k 阶矩.

Theorem 1.3.(χ^2 分布的 k 阶矩) 设 ξ 是服从自由度为 n 的 χ^2 分布的随机变量, 则对任意 $k > -\frac{n}{2}$, k 阶矩

$$\mathbb{E}\left(\xi^k\right) = 2^k \frac{\Gamma\left(\frac{n}{2} + k\right)}{\Gamma\left(\frac{n}{2}\right)}.$$

特别地, 取 $n = 1$ 得到标准正态分布的偶数阶矩

$$\mathbb{E}\left(X^{2k}\right) = \mathbb{E}\left(\xi^k\right) = (2k-1)!!.$$

Proof. 利用密度函数

$$\mathbb{E}\left(\xi^k\right)=\int_{\mathbb{R}} x^k f_n(x)\mathrm{d}x=\int_0^{+\infty}\frac{1}{2^{\frac{n}{2}}\Gamma\left(\frac{n}{2}\right)}x^{\frac{n}{2}+k-1}\mathrm{e}^{-\frac{x}{2}}\mathrm{d}x=2^k\frac{\Gamma\left(\frac{n}{2}+k\right)}{\Gamma\left(\frac{n}{2}\right)}.$$

特别地, 取 $n=1$ 得 $\xi=X^2$, 于是

$$\mathbb{E}\left(X^{2k}\right)=2^k\frac{\Gamma\left(\frac{1}{2}+k\right)}{\Gamma\left(\frac{1}{2}\right)}=(2k-1)!!.$$

□

我们回顾**Example 1.3.**中计算的相关系数.

Example 1.7.(总体方差与样本方差的相关系数) **Example 1.1.**和**Example 1.2.**中定义的随机变量

$$A=\frac{1}{n}\sum_{k=1}^n(X_k-\mu)^2,\quad B=\frac{1}{n-1}\sum_{k=1}^n(X_k-\overline{X})^2.$$

观察相关系数的定义

$$\rho(A,B)=\frac{\mathrm{Cov}(A,B)}{\sqrt{\mathrm{Var}(A)\,\mathrm{Var}(B)}}$$

可知 $\rho(\alpha A,\beta B)=\rho(A,B)$. 于是只要计算

$$\rho\left(\sum_{k=1}^n(X_k-\mu)^2,\sum_{k=1}^n(X_k-\overline{X})^2\right)$$

即可. 注意到

$$\sum_{k=1}^n(X_k-\mu)^2=\sum_{k=1}^n(X_k-\overline{X})^2+n\left(\overline{X}-\mu\right)^2,$$

根据**Theorem 1.1.**的结果, 样本均值 $\overline{X}$ 和样本方差 S^2 独立, 因此根据协方差的双线性只要计算

$$\frac{\mathrm{Cov}\left(\sum\limits_{k=1}^n(X_k-\overline{X})^2,\sum\limits_{k=1}^n(X_k-\overline{X})^2\right)}{\sqrt{\mathrm{Var}\left(\sum\limits_{k=1}^n(X_k-\mu)^2\right)\mathrm{Var}\left(\sum\limits_{k=1}^n(X_k-\overline{X})^2\right)}}=\sqrt{\frac{\mathrm{Var}\left(\sum\limits_{k=1}^n(X_k-\overline{X})^2\right)}{\mathrm{Var}\left(\sum\limits_{k=1}^n(X_k-\mu)^2\right)}}.$$

根据**Theorem 1.1.**的结果, 两者分别相当于自由度为 $n-1$ 和 n 的 χ^2 分布, 于是根据**Theorem 1.3.**可求出

$$\rho(A,B)=\sqrt{\frac{n-1}{n}}.$$

Exercise 1.1. 设 $X_1, X_2, \ldots, X_n$ 独立, 分别服从正态分布 $N(0, \sigma_i^2)$, 定义随机变量

$$\xi = \sum_{i=1}^{n} \frac{(X_i - Z)^2}{\sigma_i^2}, \quad Z = \frac{\sum_{i=1}^{n} \frac{X_i}{\sigma_i^2}}{\sum_{i=1}^{n} \frac{1}{\sigma_i^2}},$$

求 ξ 的分布.

Solution. 为了使细节更清晰, 作换元 $w_i = \frac{1}{\sigma_i}$ 和 $Y_i = \frac{X_i}{\sigma_i}$, 则定义变为

$$\xi = \sum_{i=1}^{n} (Y_i - w_i Z)^2, \quad Z = \frac{\sum_{i=1}^{n} w_i Y_i}{\sum_{i=1}^{n} w_i^2}.$$

其中 Y_i 独立同分布 $N(0,1)$. 现在可以展开

$$\xi = \sum_{i=1}^{n} Y_i^2 + \left(\sum_{i=1}^{n} w_i^2\right) Z^2 - 2\left(\sum_{i=1}^{n} w_i Y_i\right) Z = \sum_{i=1}^{n} Y_i^2 - \frac{\left(\sum_{i=1}^{n} w_i Y_i\right)^2}{\sum_{i=1}^{n} w_i^2}.$$

立刻看出这是 $\mathbf{Y}$ 的二次型. 为了写成更标准的二次型, 定义

$$u_i = \frac{w_i}{\sqrt{\sum_{i=1}^{n} w_i^2}}$$

构成单位向量 $\mathbf{u}$, 则

$$\xi = \mathbf{Y}^T\mathbf{Y} - (\mathbf{u}^T\mathbf{Y})^2 = \mathbf{Y}^T(I - \mathbf{u}\mathbf{u}^T)\mathbf{Y}.$$

以 $\mathbf{u} = \mathbf{u}_1$ 为第一列构造正交阵 U, 并作正交变换 $\mathbf{Z} = U^T\mathbf{Y}$, 则

$$\xi = \mathbf{Z}^T U^T (I - \mathbf{u}\mathbf{u}^T) U \mathbf{Z} = \mathbf{Z}^T (I - (U^T\mathbf{u})(\mathbf{u}^T U))\mathbf{Z} = \sum_{i=2}^{n} Z_i^2.$$

根据**Theorem 1.1.**可知 Z_i 独立同分布 $N(0,1)$, 依照**Definition 1.6.**可知 $\xi \sim \chi_{n-1}^2$.

1.3.2 t 分布

正态分布与独立正态分布的平方平均之商称为 t 分布.

Definition 1.7.(t 分布) 给定 n 个样本 $\{X_k\}_{k=1}^n$ 和一个样本 Y 独立同标准正态分布, 称随机变量

$$T = Y\left(\frac{1}{n}\sum_{k=1}^{n} X_k^2\right)^{-\frac{1}{2}}$$

服从的分布为自由度为 n 的 t 分布, 记作 $\xi \sim t_n$.

我们可以计算其密度函数.

Theorem 1.4.(t 分布的密度函数) 设 T 是服从自由度为 n 的 t 分布的随机变量, 则其概率密度函数为

$$f_n(t)=\frac{\Gamma\left(\frac{n+1}{2}\right)}{\Gamma\left(\frac{n}{2}\right)\sqrt{n\pi}}\left(1+\frac{t^2}{n}\right)^{-\frac{n+1}{2}}.$$

Proof. 依照概率分布的定义

$$F_n(t)=\mathbb{P}\left(\frac{\sqrt{n}Y}{\sqrt{\xi}}\le t\right)=\int_{\frac{\sqrt{n}y}{\sqrt{x}}\le t}\frac{1}{\sqrt{2\pi}}\mathrm{e}^{-\frac{y^2}{2}}\frac{1}{2^{\frac{n}{2}}\Gamma\left(\frac{n}{2}\right)}x^{\frac{n}{2}-1}\mathrm{e}^{-\frac{x}{2}}\mathrm{d}x\mathrm{d}y.$$

考虑换元

$$\begin{cases}u=\frac{y}{\sqrt{x}},\\ v=\sqrt{x}.\end{cases}$$

相应的 Jacobi 行列式为

$$\det(J)=\det\left(\begin{bmatrix}0 & 2v\\ v & u\end{bmatrix}\right)=-2v^2,$$

于是

$$F_n(t)=\int_{\sqrt{n}u\le t,v\ge 0}\frac{1}{\sqrt{2\pi}}\mathrm{e}^{-\frac{u^2v^2}{2}}\frac{1}{2^{\frac{n}{2}}\Gamma\left(\frac{n}{2}\right)}v^{n-2}\mathrm{e}^{-\frac{1}{2}v^2}2v^2\mathrm{d}u\mathrm{d}v.$$

整理得

$$F_n(t)=\frac{1}{2^{\frac{n}{2}-1}\Gamma\left(\frac{n}{2}\right)}\int_{-\infty}^{\frac{t}{\sqrt{n}}}\left(\int_0^{+\infty}\frac{1}{\sqrt{2\pi}}v^n\mathrm{e}^{-\frac{v^2}{2}(u^2+1)}\mathrm{d}v\right)\mathrm{d}u.$$

作换元 $z=\frac{1}{2}(u^2+1)v^2$ 可得括号内为

$$\int_0^{+\infty}\frac{1}{\sqrt{2\pi}}\left(\sqrt{\frac{2z}{u^2+1}}\right)^n\mathrm{e}^{-z}\frac{1}{\sqrt{2z(u^2+1)}}\mathrm{d}z.$$

利用 Gamma 函数可以写为

$$\frac{2^{\frac{n-1}{2}}}{\sqrt{2\pi}(u^2+1)^{\frac{n+1}{2}}}\int_0^{+\infty}z^{\frac{n-1}{2}}\mathrm{e}^{-z}\mathrm{d}z=\frac{2^{\frac{n-1}{2}}\Gamma\left(\frac{n+1}{2}\right)}{\sqrt{2\pi}(u^2+1)^{\frac{n+1}{2}}}.$$

代入得

$$F_n(t)=\frac{1}{2^{\frac{n}{2}-1}\Gamma\left(\frac{n}{2}\right)}\int_{-\infty}^{\frac{t}{\sqrt{n}}}\frac{2^{\frac{n}{2}-1}\Gamma\left(\frac{n+1}{2}\right)}{\sqrt{\pi}(u^2+1)^{\frac{n+1}{2}}}\mathrm{d}u=\frac{\Gamma\left(\frac{n+1}{2}\right)}{\sqrt{\pi}\Gamma\left(\frac{n}{2}\right)}\int_{-\infty}^{\frac{t}{\sqrt{n}}}(u^2+1)^{-\frac{n+1}{2}}\mathrm{d}u.$$

对 t 求导即得密度函数

$$f_n(t)=\frac{\Gamma(\frac{n+1}{2})}{\sqrt{n\pi}\Gamma(\frac{n}{2})}\left(1+\frac{t^2}{n}\right)^{-\frac{n+1}{2}}.$$

□

特别地, 如果取 $n=1$, 则变为

$$f_1(t)=\frac{1}{\pi(1+t^2)}$$

是 Cauchy 分布. 令 $n\to\infty$, 则依照 e 的定义和 Stirling 公式变为

$$\lim_{n\to\infty} f_n(t)=\frac{\sqrt{\frac{n}{2}}}{\sqrt{n\pi}}\exp\left(-\frac{1}{2}t^2\right)=\frac{1}{\sqrt{2\pi}}\exp\left(-\frac{1}{2}t^2\right),$$

即标准正态分布.

利用密度函数可以计算 k 阶矩.

Theorem 1.5.(t 分布的 k 阶矩) 设 T 是服从自由度为 n 的 t 分布的随机变量, 则对任意 $k<n$, k 阶矩

$$\mathbb{E}\left(T^k\right)=\begin{cases} n^{\frac{k}{2}}\frac{\Gamma\left(\frac{k+1}{2}\right)\Gamma\left(\frac{n-k}{2}\right)}{\Gamma\left(\frac{n}{2}\right)\Gamma\left(\frac{1}{2}\right)}, & 2\mid k,\\ 0, & 2\nmid k.\end{cases}$$

Proof. 利用密度函数

$$\mathbb{E}\left(T^k\right)=\int_{\mathbb{R}} t^k f_n(t)\mathrm{d}t=\int_{\mathbb{R}} t^k\frac{\Gamma(\frac{n+1}{2})}{\sqrt{n\pi}\Gamma(\frac{n}{2})}\left(1+\frac{t^2}{n}\right)^{-\frac{n+1}{2}}\mathrm{d}t.$$

当 $2\nmid k$ 时, 被积函数是奇函数, 从而积分值为 0. 当 $2\mid k$ 时, 考虑换元 $z=\frac{t^2}{n}$, 恰好得到 Beta 函数

$$\mathbb{E}\left(T^k\right)=\frac{n^{\frac{k}{2}}\Gamma(\frac{n+1}{2})}{\sqrt{\pi}\Gamma(\frac{n}{2})}\int_0^{+\infty} z^{\frac{k-1}{2}}(1+z)^{-\frac{n+1}{2}}\mathrm{d}z=\frac{n^{\frac{k}{2}}\Gamma(\frac{n+1}{2})}{\sqrt{\pi}\Gamma(\frac{n}{2})}B\left(\frac{k+1}{2},\frac{n-k}{2}\right),$$

展开为 Gamma 函数即证. □

Exercise 1.2. 设 $X_1,X_2,\ldots,X_{n+1}$ 独立同正态分布 $N(\mu,\sigma^2)$, 定义前 n 项的均值和方差

$$\overline{X}=\frac{1}{n}\sum_{i=1}^n X_i,\quad S^2=\frac{1}{n}\sum_{i=1}^n(X_i-\overline{X})^2.$$

定义随机变量

$$\xi=\frac{X_{n+1}-\overline{X}}{S}\sqrt{\frac{n-1}{n+1}},$$

求 ξ 的分布.

Solution. 此形式类似于 t 分布, 为构造出类似形式, 考虑 X_{n+1} 和 $\overline{X}$ 是独立随机变量, 分别服从 $N(\mu,\sigma^2)$ 和 $N(\mu,\frac{\sigma^2}{n})$, 因此利用特征函数容易计算 $X_{n+1}-\overline{X}$ 的分布为正态分布, 均值为 0, 方差

$$\sigma_{n+1}^2=\sigma^2+\frac{\sigma^2}{n}=\frac{n+1}{n}\sigma^2.$$

于是定义随机变量

$$Y = \frac{X_{n+1} - \overline{X}}{\sqrt{\frac{n+1}{n}}\sigma}$$

服从标准正态分布. 代入立即得到

$$\xi = Y\left(\frac{1}{n-1}\sum_{i=1}^{n}\frac{(X_i - \overline{X})^2}{\sigma^2}\right)^{-\frac{1}{2}}.$$

根据Exercise 1.1.中取 $\sigma_i = \sigma$ 的结果, 括号内的求和可以变为 $\sum_{i=2}^{n} Z_i^2$, 其中 Z_i 独立同标准正态分布, 于是上式恰好是 t 分布的定义, 即 $\xi \sim t_{n1}$.

1.3.3 F 分布

独立正态分布平方的均值之商称为 F 分布.

Definition 1.8.(F 分布) 给定 $m+n$ 个样本 $\{X_i\}_{i=1}^{m}$ 和 $\{Y_j\}_{j=1}^{n}$ 独立同标准正态分布, 称随机变量

$$Z = \frac{\frac{1}{m}\sum_{i=1}^{m} X_i^2}{\frac{1}{n}\sum_{j=1}^{n} X_j^2}$$

服从的分布为参数 m, n 的 F 分布, 记作 $Z \sim F_{m,n}$.

我们仍然计算其密度函数.

Theorem 1.6.(F 分布的密度函数) 设 Z 是服从参数 m, n 的 F 分布的随机变量, 则其概率密度函数为

$$f_{m,n}(t) = \begin{cases} \frac{\Gamma\left(\frac{m+n}{2}\right)}{\Gamma\left(\frac{m}{2}\right)\Gamma\left(\frac{n}{2}\right)} m^{\frac{m}{2}} n^{\frac{n}{2}} t^{\frac{m}{2}-1}(n+mt)^{-\frac{m+n}{2}}, & t > 0, \\ 0, & t \le 0. \end{cases}$$

Proof. 我们记 X_i 的平方和为 X, Y_j 的平方和为 Y, 则分别服从自由度为 m, n 的 χ^2 分布. 依照概率分布的定义

$$F_{m,n}(t) = \mathbb{P}\left(\frac{X/m}{Y/n} \le t\right) = \int_{\frac{x/m}{y/n} \le t} \frac{1}{2^{\frac{m+n}{2}}\Gamma\left(\frac{m}{2}\right)\Gamma\left(\frac{n}{2}\right)} x^{\frac{m}{2}-1} y^{\frac{n}{2}-1} \mathrm{e}^{-\frac{x+y}{2}} \mathrm{d}x\mathrm{d}y.$$

考虑换元

$$\begin{cases} u = \frac{x}{y}, \\ v = y. \end{cases}$$

相应的 Jacobi 行列式为

$$\det(J) = \det\left(\begin{bmatrix} 0 & 1 \\ v & u \end{bmatrix}\right) = -v,$$

即得

$$F_{m,n}(t)=\int_{0\le u\le \frac{m}{n}t,v\ge 0}\frac{1}{2^{\frac{m+n}{2}}\Gamma\left(\frac{m}{2}\right)\Gamma\left(\frac{n}{2}\right)}(uv)^{\frac{m}{2}-1}v^{\frac{n}{2}-1}\mathrm{e}^{-\frac{(u+1)v}{2}}v\mathrm{d}u\mathrm{d}v.$$

整理得

$$F_{m,n}(t)=\int_0^{\frac{m}{n}t}\left(\frac{u^{\frac{m}{2}-1}}{2^{\frac{m+n}{2}}\Gamma\left(\frac{m}{2}\right)\Gamma\left(\frac{n}{2}\right)}\int_0^{+\infty}v^{\frac{m+n}{2}-1}\mathrm{e}^{-\frac{(u+1)v}{2}}\mathrm{d}v\right)\mathrm{d}u.$$

采用同样的方法作换元 $z=\frac{(u+1)v}{2}$ 可得

$$\int_0^{+\infty}v^{\frac{m+n}{2}-1}\mathrm{e}^{-\frac{(u+1)v}{2}}\mathrm{d}v=\frac{2^{\frac{m+n}{2}}\Gamma\left(\frac{m+n}{2}\right)}{(u+1)^{\frac{m+n}{2}}}.$$

于是

$$F_{m,n}(t)=\frac{\Gamma\left(\frac{m+n}{2}\right)}{\Gamma\left(\frac{m}{2}\right)\Gamma\left(\frac{n}{2}\right)}\int_0^{\frac{m}{n}t}\frac{u^{\frac{m}{2}-1}}{(u+1)^{\frac{m+n}{2}}}\mathrm{d}u.$$

求导即得密度函数. □

依照定义即知 $F_{1,n}$ 相当于服从 t_n 分布的随机变量的平方的分布, $F_{n,m}$ 相当于服从 $F_{m,n}$ 分布的随机变量的倒数的分布.

我们仍然计算 k 阶矩.

Theorem 1.7.(F 分布的 k 阶矩) 设 Z 是服从参数 m,n 的 F 分布的随机变量, 则对任意 $0<k<\frac{n}{2}$, k 阶矩

$$\mathbb{E}\left(Z^k\right)=\left(\frac{n}{m}\right)^k\frac{\Gamma\left(\frac{m}{2}+k\right)\Gamma\left(\frac{n}{2}-k\right)}{\Gamma\left(\frac{m}{2}\right)\Gamma\left(\frac{n}{2}\right)}.$$

特别地, 当 $n>2$ 和 $n>4$ 时有

$$\mathbb{E}(Z)=\frac{n}{n-2},\quad \mathrm{Var}(Z)=\frac{2n^2(m+n-2)}{m(n-2)^2(n-4)}.$$

Proof. 根据独立性展开

$$\mathbb{E}\left(Z^k\right)=\left(\frac{n}{m}\right)^k\mathbb{E}\left(X^k\right)\mathbb{E}\left(Y^{-k}\right).$$

根据**Theorem 1.3.**的结果有

$$\mathbb{E}\left(X^k\right)=2^k\frac{\Gamma\left(\frac{m}{2}+k\right)}{\Gamma\left(\frac{m}{2}\right)},\quad \mathbb{E}\left(Y^{-k}\right)=2^{-k}\frac{\Gamma\left(\frac{n}{2}-k\right)}{\Gamma\left(\frac{n}{2}\right)},$$

代入即证. □

对正态分布的数据而言, 其样本均值和样本方差恰好服从正态分布和 χ^2 分布, 因此作商恰好是 t 分布和 F 分布, 这刻画了数据波动程度的关系.

1.4 顺序统计量

作为最大值, 最小值的推广, 我们考察顺序统计量.

Definition 1.9.(顺序统计量) 设 $X_1, X_2, \ldots, X_n$ 是概率空间 $(\Omega, \mathscr{F}, \mathbb{P})$ 上的随机变量 (样本), 对每个 $\omega \in \Omega$, 都可对 $\{X_i(\omega)\}$ 排序, 把每个 ω 映到相应序列的从小到大第 k 个值的随机变量, 称为第 k 顺序统计量 $X_{(k)}$.

顺序统计量作为随机变量, 可以研究其分布.

Theorem 1.8.(顺序统计量的分布) 设 $X_1, X_2, \ldots, X_n$ 独立同分布 $F(x)$, 则第 k 顺序统计量的概率分布为

$$F_{(k)}(x) = \sum_{i=k}^{n} C_n^i F(x)^i (1-F(x))^{n-i} = \frac{n!}{(k-1)!(n-k)!} \int_0^{F(x)} t^{k-1}(1-t)^{n-k} \mathrm{d}t.$$

如果 $F(x)$ 的导数存在, 则密度函数为

$$f_{(k)}(x) = \frac{n!}{(k-1)!(n-k)!} F(x)^{k-1}(1-F(x))^{n-k} f(x).$$

Proof. 依照定义, $F_{(k)}(x)$ 的值是 $\mathbb{P}(X_{(k)} \le x)$, 即至少有 k 个不大于 x, 这可以分解为恰好有 $k, k+1, \ldots, n$ 个不大于 x 的概率和, 即

$$F_{(k)}(x) = \sum_{i=k}^{n} C_n^i \mathbb{P}(X_1 \le x)^i \mathbb{P}(X_1 > x)^{n-i} = F_{(k)}(x) = \sum_{i=k}^{n} C_n^i F(x)^i (1-F(x))^{n-i}.$$

为了得到积分形式, 只要证明恒等式

$$\sum_{i=k}^{n} C_n^i x^i (1-x)^{n-i} = \frac{n!}{(k-1)!(n-k)!} \int_0^x t^{k-1}(1-t)^{n-k} \mathrm{d}t,$$

这只要对右边作分部积分即可. 最后求导即得

$$f_{(k)}(x) = \frac{n!}{(k-1)!(n-k)!} F(x)^{k-1}(1-F(x))^{n-k} f(x).$$

□

对这一结果, 可以从古典概型的角度考虑. 比 $X_{(k)}$ 小的有 $k-1$ 个, 有 C_n^{k-1} 种取法, 每个的概率是 $\mathbb{P}(X_1 \le x) = F(x)$, 比 $X_{(k)}$ 大的有 $n-k$ 个, 有 C_{n-k+1}^{n-k} 种取法, 每个的概率是 $\mathbb{P}(X_1 > x) = 1 - F(x)$, 而 $X_{(k)}$ 本身只剩下一种取法, 概率是 $f(x)$, 相乘即得

$$C_n^{k-1} C_{n-k+1}^{n-k} = \frac{n!}{(n-k+1)!(k-1)!}(n-k+1) = \frac{n!}{(k-1)!(n-k)!}.$$

如果相应概率分布 F 的各阶矩存在, 则只要写成积分, 容易看出顺序统计量的各阶矩存在. 反之则不然.

Example 1.8.(Cauchy 分布顺序统计量的 p 阶矩) 设 $X_1, X_2, \ldots, X_n$ 独立同 Cauchy 分布, 则

$$F(x) = \frac{1}{2} + \frac{1}{\pi}\arctan x, \quad f(x) = \frac{1}{\pi(1+x^2)}.$$

从而第 k 顺序统计量的密度函数为

$$f_{(k)}(x) = \frac{n!}{(k-1)!(n-k)!}\left(\frac{1}{2} + \frac{1}{\pi}\arctan x\right)^{k-1}\left(\frac{1}{2} - \frac{1}{\pi}\arctan x\right)^{n-k}\frac{1}{\pi(1+x^2)}.$$

其 p 阶矩为

$$\mathbb{E}(X_{(k)}) = \frac{1}{\pi}\frac{n!}{(k-1)!(n-k)!}\int_{\mathbb{R}}\left(\frac{1}{2} + \frac{1}{\pi}\arctan x\right)^{k-1}\left(\frac{1}{2} - \frac{1}{\pi}\arctan x\right)^{n-k}\frac{x^p}{1+x^2}\mathrm{d}x.$$

当 $x \to +\infty$ 时, 有无穷小

$$\frac{1}{2} - \frac{1}{\pi}\arctan x \sim \frac{1}{\pi x},$$

因此只要 $n-k \geq p$ 就在正无穷处积分收敛. 同理可得 $p \leq k-1$ 时在负无穷处积分收敛, 因此第 k 顺序统计量的 $1 \leq p \leq \min\{k-1, n-k\}$ 阶矩存在, 特别地, 当 $k \neq 1, n$ 时期望存在, $k \neq 1, 2, n-1, n$ 时方差存在.

顺序统计量作为随机变量彼此不独立, 因而有必要讨论其联合分布, 不是各分布的乘积.

Theorem 1.9.(顺序统计量的联合分布) 设 $X_1, X_2, \ldots, X_n$ 独立同分布 $f(x)$, 则顺序统计量的联合概率密度为

$$f(\mathbf{x}) = \begin{cases} n!\prod\limits_{i=1}^{n} f(x_i), & x_1 < x_2 < \cdots < x_n, \\ 0, & \text{otherwise}. \end{cases}$$

Proof. 我们比较这与 $\mathbf{X}$ 的联合概率密度的关系. 根据独立性, $\mathbf{X}$ 的联合概率密度当然是

$$f_{\mathbf{X}}(\mathbf{x}) = \prod_{i=1}^{n} f(x_i).$$

对 $\{X_{(k)}\}$ 作置换, 每一个置换给出一个密度非 0 的区域

$$x_{k_1} < x_{k_2} < \cdots < x_{k_n},$$

且这 $n!$ 个区域彼此不交, 在相差一个零测区域意义下构成全空间 $\mathbb{R}^n$. 现在在每个区域内定义映射, 使之构成与

$$x_1 < x_2 < \cdots < x_n$$

的一一对应, 则顺序统计量在 $\mathbf{x}$ 处的值就是所有被映到该点的概率密度之和, 当然是

$$n!\prod_{i=1}^{n} f(x_i).$$

□

同样可以从古典概型的角度理解, 也可以如此理解: 顺序统计量落在 $\mathbf{x}$ 附近区域, 当且仅当原始独立统计量落在全部 $n!$ 个置换区域的某个相应位置, 因此概率密度当然是求和.

要求若干顺序统计量的联合密度函数, 只要对其他量作积分即可. 特别地, 可以计算极差 $X_{(1)}, X_{(n)}$ 的联合密度

$$f(x_1, x_n) = \int_{x_1<x_2<\cdots<x_n} n!\prod_{i=1}^{n} f(x_i)\mathrm{d}x_2\cdots\mathrm{d}x_{n-1}.$$

考虑中间全部的 $(n-2)!$ 个置换, 得

$$f(x_1, x_n) = \frac{n!}{(n-2)!}\int_{x_1<x_2,\cdots,x_{n-1}<x_n} \prod_{i=1}^{n} f(x_i)\mathrm{d}x_2\cdots\mathrm{d}x_{n-1},$$

直接计算得

$$f(x_1, x_n) = n(n-1)(F(x_n)-F(x_1))^{n-2}f(x_1)f(x_n).$$

注意到如果 X 服从分布函数 $F(x)$, 且 F 连续, 则由于 F 单调

$$\mathbb{P}(F(X)\le x) = \mathbb{P}(X\le F^{-1}(x)) = F(F^{-1}(x)) = x, \quad 0\le x\le 1.$$

这说明任何随机变量 F 只要服从某个连续分布 F, 则 $F(X)$ 必然服从均匀分布 $U(0,1)$, 因此有必要研究均匀分布的顺序统计量.

Example 1.9.(均匀分布的顺序统计量) 设 $X_1, X_2, \ldots, X_n$ 独立同分布 $U(0,1)$. 则根据**Theorem 1.8.**的结果, 第 k 顺序统计量的概率密度函数为

$$f_{(k)}(x) = \begin{cases} \frac{n!}{(k-1)!(n-k)!}x^{k-1}(1-x)^{n-k}, & 0<x<1, \\ 0, & \text{otherwise}. \end{cases}$$

我们计算其期望

$$\mathbb{E}(X_{(k)}) = \int_0^1 x\frac{n!}{(k-1)!(n-k)!}x^{k-1}(1-x)^{n-k}\mathrm{d}x.$$

注意到可以写为

$$\frac{n!}{(k-1)!(n-k)!}\int_0^1 x^{(k+1)-1}(1-x)^{(n+1)-(k+1)}\mathrm{d}x,$$

而积分内相当于 $n+1$ 个随机变量的第 $k+1$ 个顺序统计量的密度函数, 因此积分结果是系数的倒数

$$\mathbb{E}(X_{(k)}) = \frac{n!}{(k-1)!(n-k)!}\frac{k!(n-k)!}{(n+1)!} = \frac{k}{n+1},$$

这具有对称性, 即第 k 个顺序统计量和倒数第 k 个顺序统计量有相同的期望. 同理可以计算方差

$$\mathrm{Var}(X_{(k)}) = \frac{k(k+1)}{(n+1)(n+2)} - \left(\frac{k}{n+1}\right)^2 = \frac{k(n-k+1)}{(n+1)^2(n+2)},$$

同样可见对称性. 根据**Theorem 1.9.**的结果, 顺序统计量的联合概率密度为

$$f(\mathbf{x}) = \begin{cases} n!, & 0 < x_1 < x_2 < \cdots < x_n < 1, \\ 0, & \text{otherwise}. \end{cases}$$

对除去 $X_{(i)}, X_{(j)}$ 以外的项积分, 不妨设 $i<j$, 则 $i<k<j$ 的项积分范围为 $[x_i, x_j]$, $k<i$ 的项积分范围为 $[0, x_i]$, $k>j$ 的项积分范围为 $[x_j, 1]$, 再除掉所有排列数

$$f_{(i,j)}(x_i, x_j) = \frac{n!}{(i-1)!(j-i-1)!(n-j)!}x_i^{i-1}(x_j-x_i)^{j-i-1}(1-x_j)^{n-j}.$$

从而期望

$$\mathbb{E}(X_{(i)}X_{(j)}) = \frac{n!}{(i-1)!(j-i-1)!(n-j)!}\int_{0<x_i<x_j<1} x_i^i x_j (x_j-x_i)^{j-i-1}(1-x_j)^{n-j}\mathrm{d}x_i\mathrm{d}x_j,$$

李利用 Beta 函数的性质, 先对 x_i 积分

$$\int_0^{x_j} x_i^i(x_j-x_i)^{j-i-1}\mathrm{d}x_i = x_j^j\int_0^1 t^i(1-t)^{j-i-1}\mathrm{d}t = \frac{i!(j-i-1)!}{j!}x_j^j,$$

代入得

$$\mathbb{E}(X_{(i)}X_{(j)}) = \frac{n!}{(n-j)!}\frac{i}{j!}\int_0^1 x_j^{j+1}(1-x_j)^{n-j}\mathrm{d}x_j = \frac{i(j+1)}{(n+1)(n+2)}.$$

因而可以求得协方差

$$\mathrm{Cov}(X_{(i)}, X_{(j)}) = \mathbb{E}(X_{(i)}X_{(j)}) - \mathbb{E}(X_{(i)})\mathbb{E}(X_{(j)}) = \frac{i(n-j+1)}{(n+1)^2(n+2)},$$

相关系数

$$\rho(X_{(i)}, X_{(j)}) = \frac{\mathrm{Cov}(X_{(i)}, X_{(j)})}{\sqrt{\mathrm{Var}(X_{(i)})\,\mathrm{Var}(X_{(j)})}} = \sqrt{\frac{i(n-j+1)}{j(n-i+1)}}.$$

作为顺序统计量的推广, 我们通过线性插值定义 p 分位数.

Definition 1.10.(*p* **分位数)** 设 $X_1, X_2, \ldots, X_n$ 为概率空间 $(\Omega, \mathscr{F}, \mathbb{P})$ 上的随机变量. 对 $0 < p < 1$, 定义 p 分位数是顺序统计量的线性组合

$$\epsilon_{n,p} = X_{([(n+1)p])} + ((n+1)p - [(n+1)p]) \left(X_{([(n+1)p]+1)} - X_{([(n+1)p])} \right).$$

依照定义很明显第 k 顺序统计量就是 $\frac{k}{n+1}$ 分位数. 反之, 小于 p 分位数的最大顺序统计量是 $X_{([np])}$.

1.5 渐近分布 *

本节的结果仅作介绍, 因其涉及较为复杂的估计和引理, 而相关结论不影响后续. 我们首先回顾概率论中随机变量序列的四种收敛.

Definition 1.11.(随机变量序列的收敛) $\{X_n\}$ 是概率空间 $(\Omega, \mathscr{F}, \mathbb{P})$ 上的随机变量序列, 相应的概率分布函数为 $F_n(x)$. X 是一个随机变量或常数, 相应的分布函数为 $F(x)$.

1. 如果对任意 $\omega \in \Omega \setminus N$, 其中 N 是一个零测集, 都有
$$\lim_{n\to\infty} X_n(\omega) = X(\omega),$$
称 $\{X_n\}$ 几乎处处收敛 (a.e.) 到 X.

2. 如果对任意 $\varepsilon > 0$, 有
$$\lim_{n\to\infty} \mathbb{P}\left(\{\omega \in \Omega \mid |X_n(\omega) - X(\omega)| < \varepsilon\}\right) = 1,$$
称 $\{X_n\}$ 依概率收敛 (pr.) 到 X.

3. 如果对某个 $\alpha > 0$, 有
$$\lim_{n\to\infty} E(|X_n - X|^\alpha) = 0,$$
称 $\{X_n\}$ 满足 L^α 收敛或 α 阶矩收敛到 X.

4. 如果对任意 $x \in \mathbb{R}$ 是 $F(x)$ 的连续点, 都有
$$\lim_{n\to\infty} F_n(x) = F(x),$$
则称 X_n 依分布收敛 (dist.) 到 $F(x)$.

大数定律和中心极限定理都从描述了某种收敛性质. 对样本而言, 我们把依分布收敛视作大样本条件下的极限分布, 也称为这组样本的渐近分布 (asymptotic distribution). 例如当样本充分大时, 小于 p 分位数的最大顺序统计量 $X_{([np])}$ 与 p 分位数十分接近, 可以作为其估计.

为了求得一些样本的渐近分布, 我们需要以下引理, 作为中心极限定理的某种推广.

Theorem 1.10.(de Moivre-Laplace, 局部极限定理, local limit theorem) 设随机变量 S_n 服从 Bernoulli 分布 $B(n,p)$, 即 n 次 Bernoulli 试验成功的次数, 满足
$$\mathbb{P}(S_n = k) = C_n^k p^k (1-p)^{n-k}.$$

则对一个给定的区间 I 和任意整数 k 使得 $\frac{k-np}{\sqrt{np(1-p)}} \in I$, 当 $n \to \infty$ 时, 有等价无穷小

$$\mathbb{P}(S_n = k) \approx \frac{1}{\sqrt{2\pi npq}} \exp\left(-\frac{1}{2}\left(\frac{k-np}{\sqrt{npq}}\right)^2\right).$$

Proof. Omit. □

由此可以求得以下渐近分布.

Theorem 1.11.(p 分位数的渐近分布) 设 $0 < p < 1$, 给定分布 $F(x)$ 使得密度函数存在且连续. 如果 $m = m(n)$ 是关于 n 的正整数变量, 使得

$$\lim_{n\to\infty} \frac{m-np}{\sqrt{n}} = 0,$$

则当 $n \to \infty$ 时, 随机变量序列

$$\sqrt{n} f(F^{-1}(p)) \left(X_{(m)} - F^{-1}(p)\right)$$

依分布收敛到正态分布 $N(0, p(1-p))$.

Proof. Omit. □

之所以成为 p 分位数的渐近分布, 因为在以上条件下 $m = m(n)$ 在 $[np]$ 的一个邻域内, 当然可以取为 $[np]$, 作为 p 分位数的合理估计. 依照正态分布的性质, 在以上条件下, 结论也可以写为随机变量序列

$$\sqrt{n}\left(X_{(m)} - F^{-1}(p)\right)$$

依分布收敛到正态分布

$$N\left(0, \frac{p(1-p)}{f(F^{-1}(p))^2}\right).$$

现在可以给出一些分布下样本 p 分位数的渐近分布.

Example 1.10.(若干分布 p 分位数的渐近分布) 注意到

$$\lim_{n\to\infty} \frac{[np]-np}{\sqrt{n}} = 0,$$

根据**Theorem 1.11.**得到随机变量序列

$$\sqrt{n} f(F^{-1}(p)) \left(X_{([np])} - F^{-1}(p)\right)$$

依分布收敛到正态分布 $N(0,p(1-p))$, 其中 $X_{([np])}$ 是 p 分位数的近似. 取 $F(x)$ 为均匀分布, 则密度函数是 $(0,1)$ 上的常值函数, 随机变量序列

$$\sqrt{n}\left(X_{([np]])}-p\right)$$

依分布收敛到正态分布 $N(0,p(1-p))$. 对 Cauchy 分布而言

$$f(x)=\frac{1}{\pi(1+x^2)},\quad F(x)=\frac{1}{\pi}\arctan x+\frac{1}{2},$$

在 $p=\frac{1}{2}$ 即中位数处最简单, 即随机变量序列 $\sqrt{n}X_{([n/2])}$ 依分布收敛到 $N\left(0,\frac{\pi^2}{4}\right)$. 对正态分布而言

$$f(x)=\frac{1}{\sqrt{2\pi}\sigma}\exp\left(-\frac{1}{2}\frac{(x-\mu)^2}{\sigma^2}\right),$$

同样在 $p=\frac{1}{2}$ 即中位数处最简单, 即随机变量序列 $\sqrt{n}X_{([n/2])}$ 依分布收敛到 $N\left(0,\frac{\pi\sigma^2}{2}\right)$.

最后介绍求渐近分布的重要方法, 允许我们由依分布收敛的结果出发推知其他结果, 即对求极限的过程作四则运算.

Theorem 1.12.(Slutsky) 设 $(\Omega,\mathscr{F},\mathbb{P})$ 为概率空间, 其上的随机变量序列 $\{X_n\}$ 依分布收敛到 X, $\{Y_n\}$ 依概率收敛到常数 c, 则只要以下有意义, 四则运算 $\{X_n+Y_n\}$, $\{X_nY_n\}$, $\{X_n/Y_n\}$ 分别依分布收敛到 $X+c$, cX 和 X/c.

Proof. Omit. □

Chapter 2

统计估计

Chapter 3

假设检验

Chapter 4

决策理论

Chapter 5

常用积分表