

最优化方法课程笔记

minamomo

Tuesday 22nd September, 2026

References:

[1]

Marks:

1.

1. 定义 **Definition**.

2. 定理 **Theorem**.

3. 例题 **Example**.

4. 习题 **Exercise**.

5. 算法 **Algorithm**.

Preface

minamomo
2026.9 于中国上海

This page intentionally left blank.

Contents

1	14th Sept. Lecture 1 绪论	7
1.1	极值点	7
2	21st Sept. Lecture 2 线搜索 I	9
2.1	极值点续	9
2.2	线搜索理论	10
3	28th Sept. Lecture 3 线搜索 II	15

Chapter 1

14th Sept. Lecture 1 绪论

1.1 极值点

优化的含义即找到最小值, 或者更一般化地找到局部最小值, 即极小值.

Definition 1.1.(孤立极值点) 设 f 是 $D \subseteq \mathbb{R}^n$ 上的实值函数, 如果 $x_* \in D$ 使得存在邻域 U , 在 $D \cap U$ 上 $f(x_*) \leq f(x)$ 恒成立, 且取等当且仅当 $x = x_*$, 即 x_* 是 $D \cap U$ 上唯一的极小值点, 则称 x_* 是 f 的**孤立 (isolated)** 极小值点.

Proposition 1.1.(孤立与严格极值点) 设 f 是 $D \subseteq \mathbb{R}^n$ 上的实值函数, 如果 $x_* \in D$ 是 f 的孤立极小值点, 则也是严格极小值点.

Proof. 显然, 因为孤立的定义包含 $f(x_*) \leq f(x)$ 在 $D \cap U$ 上恒成立且取等当且仅当 $x = x_*$. □

Definition 1.2.(下半连续) 设 f 是 $D \subseteq \mathbb{R}^n$ 上的实值函数, 如果 $x^* \in D$ 使得

$$f(x^*) \leq \liminf_{x \rightarrow x^*} f(x)$$

成立, 则称 f 在 x^* 处下半连续.

Definition 1.3.(极小化序列) 设 f 是 $D \subseteq \mathbb{R}^n$ 上的实值函数, 如果序列 $\{x_k\} \subseteq D$ 使得

$$\lim_{k \rightarrow \infty} f(x_k) = \inf_{x \in D} f(x),$$

则称 $\{x_k\}$ 是 f 的极小化序列.

Proposition 1.2. 设 f 是 $D \subseteq \mathbb{R}^n$ 上处处下半连续的实值函数, $\{x_k\} \subseteq D$ 是 f 的极小化序列. 如果 $\{x_k\}$ 有聚点 x_* , 则

$$f(x_*) = \inf_{x \in D} f(x).$$

特别地, 如果 D 列紧, 则总存在聚点, 从而下确界总可以取到.

Proof. 根据下半连续性

$$f(x_*) \leq \liminf_{x \rightarrow x_*} f(x).$$

根据下极限的定义和极小化序列的定义, 当然有

$$\liminf_{x \rightarrow x_*} f(x) \leq \lim_{k \rightarrow \infty} f(x_k) = \inf_{x \in D} f(x).$$

最后根据下确界的定义

$$\inf_{x \in D} f(x) \leq f(x_*),$$

结合三式即证. □

Chapter 2

21st Sept. Lecture 2 线搜索 I

2.1 极值点续

Proposition 2.1.(极值点的刻画) 设 f 是 $D \subseteq \mathbb{R}^n$ 上的光滑实值函数, $x_* \in D$ 是 f 的极小值点, 则 $\nabla f(x_*) = 0$ 且 $\nabla^2 f(x_*)$ 半正定.

Proof. 考虑一阶展开

$$f(x_* + h) = f(x_*) + \nabla f(x_*)^T h + o(\|h\|),$$

根据极小值点的定义只要 $\|h\|$ 充分小, 就有

$$f(x_* + h) \geq f(x_*) \iff \nabla f(x_*)^T h + o(\|h\|) \geq 0$$

恒成立. 如果某个 $\nabla f(x_*)^T h \neq 0$, 则取 h 与 $-h$ 中的某个使之 < 0 , 再沿此方向 $\|h\| \rightarrow 0$ 可知上式 < 0 矛盾, 于是 $\nabla f(x_*) = 0$. 再考虑二阶展开

$$f(x_* + h) = f(x_*) + \nabla f(x_*)^T h + \frac{1}{2} h^T \nabla^2 f(x_*) h + o(\|h\|^2),$$

同样有

$$h^T \nabla^2 f(x_*) h \geq 0$$

对充分小的 $\|h\|$ 恒成立, 则 $\nabla^2 f(x_*)$ 半正定. □

Proposition 2.2.(微分中值定理) 设 f 是 $D \subseteq \mathbb{R}^n$ 上的光滑实值函数, 固定 $x \in D$ 和 h . 则存在 $t \in (0, 1)$ 使得

$$f(x + h) = f(x) + \nabla f(x + th)^T h,$$

或

$$f(x + h) = f(x) + \nabla f(x)^T h + \frac{1}{2} h^T \nabla^2 f(x + th) h.$$

Proof. 考虑构造函数

$$g(t) = f(x + th), \quad g'(t) = \nabla f(x + th)^T h,$$

根据微分中值定理存在 $t \in (0, 1)$, 使得

$$\frac{g(1) - g(0)}{1 - 0} = g'(t) \iff f(x + h) - f(x) = \nabla f(x + th)^T h.$$

根据带 Lagrange 余项的 Taylor 展开式, 存在 $t \in (0, 1)$, 使得

$$g(1) = g(0) + g'(0)(1 - 0) + \frac{1}{2}g''(t)(1 - 0)^2.$$

另一方面

$$g''(t) = h^T \nabla^2 f(x + th) h,$$

代入得

$$f(x + h) = f(x) + \nabla f(x)^T h + \frac{1}{2} h^T \nabla^2 f(x + th) h.$$

□

注意未必存在 $t \in (0, 1)$, 使得

$$\nabla f(x + h) - \nabla f(x) = \nabla^2 f(x + th) h,$$

因为各个分量的微分中值参数未必一致.

2.2 线搜索理论

现在我们研究**线搜索 (line search)**. 线搜索即每次让 x 沿固定方向 p 直线前进 αp , 使得 $f(x + \alpha p) \leq f(x)$, 从而通过收敛找到极小值或近似极小值的优化方法. 这里 α 称为**步长 (step size)**. 对一个取定的可以使函数值减小的方向, 例如梯度方向 $p = \nabla f(x)$, 可以找到某个步长, 使得函数值 $f(x + \alpha p) \leq f(x)$.

一种想法是在所有方向和步长中找到使 $f(x + \alpha p)$ 最小的 p, α , 如果步步贪心, 应当选择 $p = \nabla f(x)$, 而

$$\alpha = \operatorname{argmin}_{\alpha \geq 0} f(x + \alpha p).$$

对二次函数的情形, 可以计算精确的最优方向和步长.

Algorithm 2.1. 设光滑实值函数有形式

$$f(x) = \frac{1}{2} x^T A x - b^T x = \frac{1}{2} \sum_{i,j} a_{ij} x_i x_j - \sum_i b_i x_i,$$

其中 A 正定, 则偏导数

$$\frac{\partial f}{\partial x_k} = \frac{1}{2} \sum_j a_{kj} x_j + \frac{1}{2} \sum_i a_{ik} x_i - b_k = (Ax - b)_k,$$

于是梯度 $\nabla f(x) = Ax - b$. 现在可以取 $p = \nabla f(x)$ 是下降最快方向, 为找到 $f(x + \alpha p)$ 最小的 α , 对 α 求导得

$$\frac{df}{d\alpha} = \nabla f(x + \alpha p)^T p = (A(x + \alpha p) - b)^T p = \alpha p^T A p + (Ax - b)^T p,$$

令其值为 0, 可知应该选取

$$\alpha = -\frac{(Ax - b)^T p}{p^T A p}.$$

现在从初始值 x_0 出发, 到某个点 x_k 后, 选择方向和步长

$$p_k = Ax_k - b, \quad \alpha_k = -\frac{p_k^T p_k}{p_k^T A p_k}.$$

但由于求解困难, 一般而言也只求得近似的 p, α . 问题的关键在于此搜索的收敛性. 为了使算法收敛, α 的选取既不能太大 (超过最小值), 也不能太小 (收敛慢或不收敛). 为此我们需要一些条件使得算法收敛.

假设方向 p 选定, 步长应该使 $f(x + \alpha p) \leq f(x)$, 即令 $\phi(\alpha) \leq \phi(0)$, 其中 $\phi(\alpha) = f(x + \alpha p)$. 根据微分中值定理

$$\phi(\alpha) - \phi(0) = c_1 \phi'(0) \alpha = c_1 \alpha \nabla f(x)^T p,$$

这就是 Armijo 条件. Armijo 条件虽然不能保证算法收敛, 因为 $\alpha = 0$ 总成立, 但可以保证每一步都减小.

Definition 2.1.(Armijo) 设 f 是 $D \subseteq \mathbb{R}^n$ 上的实值函数, 对第 k 步 x_k 选定的方向 p_k , 如果步长 α 满足

$$f(x_k + \alpha p_k) \leq f(x_k) + c_1 \alpha \nabla f(x_k)^T p_k,$$

其中 $c_1 \in (0, 1)$ 是固定常数, 则称步长 α 满足 f 在 x_k 处关于 p_k 的 Armijo 条件.

寻找满足 Armijo 条件的步长可用**回溯法 (backtracking)**, 即选定一个初始 α 和比例 ρ , 如果 α 满足 Armijo 条件则接受, 否则将 $\alpha \rho$ 取为新的步长, 依次类推直到某个 $\alpha \rho^N$ 满足 Armijo 条件.

为了保证算法收敛, 还要求每次下降不能太少. 由于函数光滑, 将之视作 α 的函数 $\phi(\alpha)$, 在最小值点处切线斜率为 0, 因此可以考虑尽量让切线斜率

$$\phi'(\alpha) = \nabla f(x + \alpha p)^T p \geq c_2 \phi'(0),$$

这就是 Wolfe 条件.

Definition 2.2.(Wolfe) 设 f 是 $D \subseteq \mathbb{R}^n$ 上的实值函数, 对第 k 步 x_k 选定的方向 p_k , 如果步长 α 满足 Armijo 条件

$$f(x_k + \alpha p_k) \leq f(x_k) + c_1 \alpha \nabla f(x_k)^T p_k,$$

且满足曲率条件

$$\phi'_k(\alpha) \geq \phi'_k(0) \iff \nabla f(x_k + \alpha p_k)^T p_k \geq c_2 \nabla f(x_k)^T p_k,$$

其中 $\phi_k(\alpha) = f(x_k + \alpha p_k)$, $0 < c_1 < c_2 < 1$, 则称步长 α 满足 f 在 x_k 处关于 p_k 的 Wolfe 条件. 如果曲率条件是绝对值形式的

$$|\phi'_k(\alpha)| \leq -c_2 \phi'_k(0) \iff |\nabla f(x_k + \alpha p_k)^T p_k| \leq -c_2 \nabla f(x_k)^T p_k,$$

则称步长 α 满足 f 在 x_k 处关于 p_k 的强 Wolfe 条件.

我们证明这样的 α 在一定条件下存在.

Proposition 2.3.(Wolfe 条件) 设 f 是 $D \subseteq \mathbb{R}^n$ 上的光滑实值函数, 关于方向 p

$$\{f(x + \alpha p) \mid \alpha \geq 0\}$$

有下界. 则对 $0 < c_1 < c_2 < 1$, 存在步长 α 的一个区间满足强 Wolfe 条件.

Proof. 构造直线

$$l(\alpha) = f(x) + \alpha c_1 \nabla f(x)^T p,$$

则 $l(0) = \phi(0) = f(x)$ 且 $l'(0) = c_1 \nabla f(x)^T p = c_1 \phi'(0)$. 由于 $\phi'(0) \leq 0$, 有 $l'(0) \geq \phi'(0)$, 这说明 α 充分小时 $\phi(\alpha) \leq l(\alpha)$. 根据 $\phi(\alpha)$ 有界而

$$\lim_{\alpha \rightarrow +\infty} l(\alpha) = -\infty,$$

结合光滑性可知存在 α_0 使得 $\phi(\alpha_0) = l(\alpha_0)$. 取 α_0 是满足这些的下确界, 则在 $(0, \alpha_0)$ 上 $\phi(\alpha) \leq l(\alpha)$, 即满足 Armijo 条件. 根据微分中值定理存在 $t \in (0, 1)$ 使得

$$l(\alpha_0) - l(0) = \phi(\alpha_0) - \phi(0) = \phi'(t\alpha_0)\alpha_0,$$

于是取 $\alpha = t\alpha_0$ 就有

$$\phi'(t\alpha_0) = c_1 \nabla f(x)^T p > c_2 \nabla f(x)^T p.$$

根据 $\phi'(\alpha)$ 连续, 在 $t\alpha_0$ 的一个邻域内

$$\phi'(\alpha) > c_2 \nabla f(x)^T p \iff |\phi'(\alpha)| < -c_2 \phi'(0).$$

□

因此我们可以设计算法计算这样的 α .

Algorithm 2.2. 设 f 是 $D \subseteq \mathbb{R}^n$ 上的光滑实值函数, 关于方向 p

$$\{f(x + \alpha p) \mid \alpha \geq 0\}$$

有下界. 则对 $0 < c_1 < c_2 < 1$, 可以先找到一个 $\hat{\alpha}_{k-1}$ 满足 Armijo 条件, 且 $\phi'(\alpha_{i-1}) < 0$, 例如 $\hat{\alpha}_0 = 0$, 则对 $\hat{\alpha}_i > \hat{\alpha}_{i-1}$, 如果以下任意一个满足

1. $\hat{\alpha}_i$ 不满足 Armijo 条件.
2. $\phi(\hat{\alpha}_i) \geq \phi(\hat{\alpha}_{i-1})$.
3. $\phi'(\hat{\alpha}_i) \geq 0$.

则 $(\hat{\alpha}_{i-1}, \hat{\alpha}_i)$ 内存在满足 Wolfe 条件的 α , 这一步称为**框选 (bracket)**. 然后在此区间内作类似二分的搜索, 称为**缩选 (zoom)**.

现在我们考虑计算 f 的极小值点.

Theorem 2.4.(Zoutendijk) 设 f 是 $D \subseteq \mathbb{R}^n$ 上的光滑实值函数, 在包含 $f(x) \leq f(x_0)$ 的一个邻域 U 内连续可微且有下界, p_k 均为下降方向, α_k 满足 Wolfe 条件. 如果 $\nabla f(x)$ Lipschitz 连续, 则

$$\sum_{k=0}^{\infty} \cos^2 \theta_k \|\nabla f(x_k)\|^2$$

收敛, 其中

$$\cos \theta_k = -\frac{\nabla f(x_k)^T p_k}{\|\nabla f(x_k)\| \|p_k\|}.$$

进而若 $\cos \theta_k \geq \delta > 0$ 有正下界, Wolfe 算法会收敛到一点 x_* 使得 $\nabla f(x_*) = 0$.

Proof. 根据 Armijo 条件

$$f(x_{k+1}) - f(x_k) \leq c_1 \alpha_k \nabla f(x_k)^T p_k.$$

为估计下降值, 根据曲率条件

$$(\nabla f(x_{k+1}) - \nabla f(x_k))^T p_k \geq (c_2 - 1) \nabla f(x_k)^T p_k.$$

根据 Lipschitz 连续

$$(\nabla f(x_{k+1}) - \nabla f(x_k))^T p_k \leq L \alpha_k \|p_k\|^2.$$

代入得

$$\alpha_k \geq \frac{(c_2 - 1) \nabla f(x_k)^T p_k}{L \|p_k\|^2},$$

由于 $\nabla f(x_k)^T p_k < 0$, $c_2 < 1$, 上式为正. 再代入得

$$f(x_{k+1}) - f(x_k) \leq -c_1 \frac{(1 - c_2) \nabla f(x_k)^T p_k}{L \|p_k\|^2} \nabla f(x_k)^T p_k = -\frac{c_1(1 - c_2)}{L} \cos^2 \theta_k \|\nabla f(x_k)\|^2,$$

求和得

$$\frac{c_1(1 - c_2)}{L} \sum_{k=0}^{\infty} \cos^2 \theta_k \|\nabla f(x_k)\|^2 \leq f(x_0) - \lim_{k \rightarrow \infty} f(x_k),$$

而 f 在 U 上有下界, 于是右边有限, 从而级数收敛. 如果 $\cos \theta_k \geq \delta$, 则级数逐项趋于 0, 即

$$\lim_{k \rightarrow \infty} \cos^2 \theta_k \|\nabla f(x_k)\|^2 = 0 \implies \lim_{k \rightarrow \infty} \|\nabla f(x_k)\|^2 = 0.$$

由于 $\mathbb{R}^n$ 列紧, 存在 $\{x_k\}$ 的聚点, 于是当 x_k 收敛到 x_* 时, 极限 $\|\nabla f(x_*)\| = 0$, 即 $\nabla f(x_*) = 0$. $\square$

另有一些类似的条件, 例如用两条直线控制的 Goldstein 条件, 相当于两次 Armijo 条件.

Definition 2.3.(Goldstein) 设 f 是 $D \subseteq \mathbb{R}^n$ 上的实值函数, 对第 k 步 x_k 选定的方向 p_k , 如果步长 α 满足

$$f(x_k) + (1 - c)\alpha \nabla f(x_k)^T p_k \leq f(x_k + \alpha p_k) \leq f(x_k) + c\alpha \nabla f(x_k)^T p_k,$$

其中 $c \in (0, 0.5)$, 则称步长 α 满足 f 在 x_k 处关于 p_k 的 Goldstein 条件.

Chapter 3

28th Sept. Lecture 3 线搜索 II