最优化方法课程笔记

minamomo

Saturday 24th October, 2026

References:

[1] Convex Optimization, Stephen Boyd, Lieven Vandenberghe, 2009.

[2] First-Order Methods in Optimization, Amir Beck, 2017.

Marks:

1.

1. 定义 **Definition**.
2. 定理 **Theorem**.
3. 例题 **Example**.
4. 习题 **Exercise**.
5. 算法 **Algorithm**.

Preface

本讲义为 2026 年秋最优化方法课程内容.

minamomo

2026.10 于中国上海

This page intentionally left blank.

Contents

1 14th Sept. Lecture 1 绪论 **7**

1.1 极值点 7

2 21st Sept. Lecture 2 线搜索 **9**

2.1 极值点续 9

2.2 线搜索理论 10

3 28th Sept. Lecture 3 梯度下降 I **15**

3.1 收敛率 15

3.2 凸函数 16

3.3 梯度下降 19

4 12th Oct. Lecture 4 梯度下降 II **25**

4.1 梯度下降 25

4.2 临近梯度法 28

4.3 镜像梯度法 31

5 19th Oct. Lecture 5 Newton 法 **35**

5.1 Newton 法 35

5.2 拟 Newton 法 40

6 26th Oct. Lecture 6 拟 Newton 法 **43**

Chapter 1

14th Sept. Lecture 1 绪论

1.1 极值点

优化的含义即找到最小值, 或者更一般化地找到局部最小值, 即极小值.

Definition 1.1.(孤立极值点) 设 f 是 $D \subseteq \mathbb{R}^n$ 上的实值函数, 如果 $x_* \in D$ 使得存在邻域 U, 在 $D \cap U$ 上 $f(x_*) \leq f(x)$ 恒成立, 且取等当且仅当 $x = x_*$, 即 x_* 是 $D \cap U$ 上唯一的极小值点, 则称 x_* 是 f 的**孤立 (isolated)** 极小值点.

Proposition 1.1.(孤立与严格极值点) 设 f 是 $D \subseteq \mathbb{R}^n$ 上的实值函数, 如果 $x_* \in D$ 是 f 的孤立极小值点, 则也是严格极小值点.

Proof. 显然, 因为孤立的定义包含 $f(x_*) \leq f(x)$ 在 $D \cap U$ 上恒成立且取等当且仅当 $x = x_*$. □

Definition 1.2.(下半连续) 设 f 是 $D \subseteq \mathbb{R}^n$ 上的实值函数, 如果 $x^* \in D$ 使得

$$f(x^*) \leq \liminf_{x \to x^*} f(x)$$

成立, 则称 f 在 x^* 处下半连续.

Definition 1.3.(极小化序列) 设 f 是 $D \subseteq \mathbb{R}^n$ 上的实值函数, 如果序列 $\{x_k\} \subseteq D$ 使得

$$\lim_{k \to \infty} f(x_k) = \inf_{x \in D} f(x),$$

则称 $\{x_k\}$ 是 f 的极小化序列.

Proposition 1.2. 设 f 是 $D \subseteq \mathbb{R}^n$ 上处处下半连续的实值函数, $\{x_k\} \subseteq D$ 是 f 的极小化序列. 如果 $\{x_k\}$ 有聚点 x_*, 则

$$f(x_*) = \inf_{x \in D} f(x).$$

特别地, 如果 D 列紧, 则总存在聚点, 从而下确界总可以取到.

Proof. 根据下半连续性

$$f(x_*) \leq \liminf_{x \to x_*} f(x).$$

根据下极限的定义和极小化序列的定义, 当然有

$$\liminf_{x \to x_*} f(x) \leq \lim_{k \to \infty} f(x_k) = \inf_{x \in D} f(x).$$

最后根据下确界的定义

$$\inf_{x \in D} f(x) \leq f(x_*),$$

结合三式即证. □

Chapter 2

21st Sept. Lecture 2 线搜索

2.1 极值点续

Proposition 2.1.(极值点的刻画) 设 f 是 $D \subseteq \mathbb{R}^n$ 上的光滑实值函数, $x_* \in D$ 是 f 的极小值点, 则 $\nabla f(x_*) = 0$ 且 $\nabla^2 f(x_*)$ 半正定.

Proof. 考虑一阶展开

$$f(x_* + h) = f(x_*) + \nabla f(x_*)^T h + o(\|h\|),$$

根据极小值点的定义只要 $\|h\|$ 充分小, 就有

$$f(x_* + h) \geq f(x_*) \iff \nabla f(x_*)^T h + o(\|h\|) \geq 0$$

恒成立. 如果某个 $\nabla f(x_*)^T h \neq 0$, 则取 h 与 $-h$ 中的某个使之 < 0, 再沿此方向 $\|h\| \to 0$ 可知上式 < 0 矛盾, 于是 $\nabla f(x_*) = 0$. 再考虑二阶展开

$$f(x_* + h) = f(x_*) + \nabla f(x_*)^T h + \frac{1}{2} h^T \nabla^2 f(x_*) h + o(\|h\|^2),$$

同样有

$$h^T \nabla^2 f(x_*) h \geq 0$$

对充分小的 $\|h\|$ 恒成立, 则 $\nabla^2 f(x_*)$ 半正定. □

Proposition 2.2.(微分中值定理) 设 f 是 $D \subseteq \mathbb{R}^n$ 上的光滑实值函数, 固定 $x \in D$ 和 h. 则存在 $t \in (0, 1)$ 使得

$$f(x + h) = f(x) + \nabla f(x + th)^T h,$$

或

$$f(x + h) = f(x) + \nabla f(x)^T h + \frac{1}{2} h^T \nabla^2 f(x + th) h.$$

Proof. 考虑构造函数

$$g(t) = f(x + th), \quad g'(t) = \nabla f(x + th)^T h,$$

根据微分中值定理存在 $t \in (0, 1)$, 使得

$$\frac{g(1) - g(0)}{1 - 0} = g'(t) \iff f(x + h) - f(x) = \nabla f(x + th)^T h.$$

根据带 Lagrange 余项的 Taylor 展开式, 存在 $t \in (0, 1)$, 使得

$$g(1) = g(0) + g'(0)(1 - 0) + \frac{1}{2} g''(t)(1 - 0)^2.$$

另一方面

$$g''(t) = h^T \nabla^2 f(x + th) h,$$

代入得

$$f(x + h) = f(x) + \nabla f(x)^T h + \frac{1}{2} h^T \nabla^2 f(x + th) h.$$

□

注意未必存在 $t \in (0, 1)$, 使得

$$\nabla f(x + h) - \nabla f(x) = \nabla^2 f(x + th) h,$$

因为各个分量的微分中值参数未必一致.

2.2 线搜索理论

现在我们研究**线搜索 (line search)**. 线搜索即每次让 x 沿固定方向 p 直线前进 αp, 使得 $f(x + \alpha p) \leq f(x)$, 从而通过收敛找到极小值或近似极小值的优化方法. 这里 α 称为**步长 (step size)**. 对一个取定的可以使函数值减小的方向, 例如梯度方向 $p = \nabla f(x)$, 可以找到某个步长, 使得函数值 $f(x + \alpha p) \leq f(x)$.

一种想法是在所有方向和步长中找到使 $f(x + \alpha p)$ 最小的 p, α, 如果步步贪心, 应当选择 $p = \nabla f(x)$, 而

$$\alpha = \operatorname{argmin}_{\alpha \geq 0} f(x + \alpha p).$$

对二次函数的情形, 可以计算精确的最优方向和步长.

Algorithm 2.1.(线搜索) 设光滑实值函数有形式

$$f(x) = \frac{1}{2} x^T A x - b^T x = \frac{1}{2} \sum_{i,j} a_{ij} x_i x_j - \sum_i b_i x_i,$$

其中 A 正定, 则偏导数

$$\frac{\partial f}{\partial x_k} = \frac{1}{2}\sum_j a_{kj}x_j + \frac{1}{2}\sum_i a_{ik}x_i - b_k = (Ax-b)_k,$$

于是梯度 $\nabla f(x) = Ax-b$. 现在可以取 $p = -\nabla f(x)$ 是下降最快方向, 为找到 $f(x+\alpha p)$ 最小的 α, 对 α 求导得

$$\frac{\mathrm{d}f}{\mathrm{d}\alpha} = \nabla f(x+\alpha p)^T p = (A(x+\alpha p)-b)^T p = \alpha p^T A p + (Ax-b)^T p,$$

令其值为 0, 可知应该选取

$$\alpha = -\frac{(Ax-b)^T p}{p^T A p}.$$

现在从初始值 x_0 出发, 到某个点 x_k 后, 选择方向和步长

$$p_k = Ax_k - b, \quad \alpha_k = -\frac{p_k^T p_k}{p_k^T A p_k}.$$

但由于求解困难, 一般而言也只需求得近似的 p, α. 问题的关键在于此搜索的收敛性. 为了使算法收敛, α 的选取既不能太大 (超过最小值), 也不能太小 (收敛慢或不收敛). 为此我们需要一些条件使得算法收敛.

假设方向 p 选定, 步长应该使 $f(x+\alpha p) \le f(x)$, 即令 $\phi(\alpha) \le \phi(0)$, 其中 $\phi(\alpha) = f(x+\alpha p)$. 根据微分中值定理

$$\phi(\alpha) - \phi(0) = c_1\phi'(0)\alpha = c_1\alpha\nabla f(x)^T p,$$

这就是 Armijo 条件的形式. Armijo 条件虽然不能保证算法收敛, 因为 $\alpha = 0$ 总成立, 但可以保证每一步都减小.

Definition 2.1.(Armijo) 设 f 是 $D \subseteq \mathbb{R}^n$ 上的实值函数, 对第 k 步 x_k 选定的方向 p_k, 如果步长 α 满足

$$f(x_k + \alpha p_k) \le f(x_k) + c_1\alpha\nabla f(x_k)^T p_k,$$

其中 $c_1 \in (0,1)$ 是固定常数, 则称步长 α 满足 f 在 x_k 处关于 p_k 的 Armijo 条件.

寻找满足 Armijo 条件的步长可用**回溯法 (backtracking)**, 即选定一个初始 α 和比例 ρ, 如果 α 满足 Armijo 条件则接受, 否则将 $\alpha\rho$ 取为新的步长, 依次类推直到某个 $\alpha\rho^N$ 满足 Armijo 条件.

为了保证算法收敛, 还要求每次下降不能太少. 由于函数光滑, 将之视作 α 的函数 $\phi(\alpha)$, 在最小值点处切线斜率为 0, 因此可以考虑尽量让切线斜率

$$\phi'(\alpha) = \nabla f(x+\alpha p)^T p \ge c_2\phi'(0),$$

这就是 Wolfe 条件.

Definition 2.2.(Wolfe) 设 f 是 $D \subseteq \mathbb{R}^n$ 上的实值函数, 对第 k 步 x_k 选定的方向 p_k, 如果步长 α 满足 Armijo 条件

$$f(x_k + \alpha p_k) \leq f(x_k) + c_1 \alpha \nabla f(x_k)^T p_k,$$

且满足曲率条件

$$\phi_k'(\alpha) \geq c_2 \phi_k'(0) \iff \nabla f(x_k + \alpha p_k)^T p_k \geq c_2 \nabla f(x_k)^T p_k,$$

其中 $\phi_k(\alpha) = f(x_k + \alpha p_k)$, $0 < c_1 < c_2 < 1$, 则称步长 α 满足 f 在 x_k 处关于 p_k 的 Wolfe 条件. 如果曲率条件是绝对值形式的

$$|\phi_k'(\alpha)| \leq -c_2 \phi_k'(0) \iff |\nabla f(x_k + \alpha p_k)^T p_k| \leq -c_2 \nabla f(x_k)^T p_k,$$

则称步长 α 满足 f 在 x_k 处关于 p_k 的强 Wolfe 条件.

我们证明这样的 α 在一定条件下存在.

Proposition 2.3.(Wolfe 条件) 设 f 是 $D \subseteq \mathbb{R}^n$ 上的光滑实值函数, 关于方向 p

$$\{f(x + \alpha p) \mid \alpha \geq 0\}$$

有下界. 则对 $0 < c_1 < c_2 < 1$, 存在步长 α 的一个区间满足强 Wolfe 条件.

Proof. 构造直线

$$l(\alpha) = f(x) + \alpha c_1 \nabla f(x)^T p,$$

则 $l(0) = \phi(0) = f(x)$ 且 $l'(0) = c_1 \nabla f(x)^T p = c_1 \phi'(0)$. 由于 $\phi'(0) \leq 0$, 有 $l'(0) \geq \phi'(0)$, 这说明 α 充分小时 $\phi(\alpha) \leq l(\alpha)$. 根据 $\phi(\alpha)$ 有界而

$$\lim_{\alpha \to +\infty} l(\alpha) = -\infty,$$

结合光滑性可知存在 α_0 使得 $\phi(\alpha_0) = l(\alpha_0)$. 取 α_0 是满足这些的下确界, 则在 $(0, \alpha_0)$ 上 $\phi(\alpha) \leq l(\alpha)$, 即满足 Armijo 条件. 根据微分中值定理存在 $t \in (0, 1)$ 使得

$$l(\alpha_0) - l(0) = \phi(\alpha_0) - \phi(0) = \phi'(t\alpha_0)\alpha_0,$$

于是取 $\alpha = t\alpha_0$ 就有

$$\phi'(t\alpha_0) = c_1 \nabla f(x)^T p > c_2 \nabla f(x)^T p.$$

根据 $\phi'(\alpha)$ 连续, 在 $t\alpha_0$ 的一个邻域内

$$\phi'(\alpha) > c_2 \nabla f(x)^T p \iff |\phi'(\alpha)| < -c_2 \phi'(0).$$

□

因此我们可以设计算法计算这样的 α.

Algorithm 2.2. 设 f 是 $D \subseteq \mathbb{R}^n$ 上的光滑实值函数, 关于方向 p

$$\{f(x+\alpha p) \mid \alpha \geq 0\}$$

有下界. 则对 $0 < c_1 < c_2 < 1$, 可以先找到一个 $\hat{\alpha}_{k-1}$ 满足 Armijo 条件, 且 $\phi'(\hat{\alpha_{i-1}}) < 0$, 例如 $\hat{\alpha}_0 = 0$, 则对 $\hat{\alpha}_i > \hat{\alpha}_{i-1}$, 如果以下任意一个满足

1. $\hat{\alpha}_i$ 不满足 Armijo 条件.
2. $\phi(\hat{\alpha}_i) \geq \phi(\hat{\alpha}_{i-1})$.
3. $\phi'(\hat{\alpha}_i) \geq 0$.

则 $(\hat{\alpha}_{i-1}, \hat{\alpha}_i)$ 内存在满足 Wolfe 条件的 α, 这一步称为**框选 (bracket)**. 然后在此区间内作类似二分的搜索, 称为**缩选 (zoom)**.

现在我们考虑计算 f 的极小值点.

Theorem 2.4.(Zoutendijk) 设 f 是 $D \subseteq \mathbb{R}^n$ 上的光滑实值函数, 在包含 $f(x) \leq f(x_0)$ 的一个邻域 U 内连续可微且有下界, p_k 均为下降方向, α_k 满足 Wolfe 条件. 如果 $\nabla f(x)$Lipschitz 连续, 则

$$\sum_{k=0}^{\infty} \cos^2\theta_k \|\nabla f(x_k)\|^2$$

收敛, 其中

$$\cos\theta_k = -\frac{\nabla f(x_k)^T p_k}{\|\nabla f(x_k)\|\|p_k\|}.$$

进而若 $\cos\theta_k \geq \delta > 0$ 有正下界, Wolfe 算法收敛到一点 x_*, 则 $\nabla f(x_*) = 0$.

Proof. 根据 Armijo 条件

$$f(x_{k+1}) - f(x_k) \leq c_1\alpha_k \nabla f(x_k)^T p_k.$$

为估计下降值, 根据曲率条件

$$(\nabla f(x_{k+1}) - \nabla f(x_k))^T p_k \geq (c_2 - 1)\nabla f(x_k)^T p_k.$$

根据 Lipschitz 连续

$$(\nabla f(x_{k+1}) - \nabla f(x_k))^T p_k \leq L\alpha_k \|p_k\|^2.$$

代入得

$$\alpha_k \geq \frac{(c_2-1)\nabla f(x_k)^T p_k}{L\|p_k\|^2},$$

由于 $\nabla f(x_k)^T p_k < 0$, $c_2 < 1$, 上式为正. 再代入得

$$f(x_{k+1}) - f(x_k) \leq -c_1 \frac{(1-c_2)\nabla f(x_k)^T p_k}{L\|p_k\|^2} \nabla f(x_k)^T p_k = -\frac{c_1(1-c_2)}{L} \cos^2\theta_k \|\nabla f(x_k)\|^2,$$

求和得

$$\frac{c_1(1-c_2)}{L} \sum_{k=0}^{\infty} \cos^2\theta_k \|\nabla f(x_k)\|^2 \leq f(x_0) - \lim_{k\to\infty} f(x_k),$$

而 f 在 U 上有下界, 于是右边有限, 从而级数收敛. 如果 $\cos\theta_k \geq \delta$, 则级数逐项趋于 0, 即

$$\lim_{k\to\infty} \cos^2\theta_k \|\nabla f(x_k)\|^2 = 0 \implies \lim_{k\to\infty} \|\nabla f(x_k)\|^2 = 0.$$

当 x_k 收敛到 x_* 时, 极限 $\|\nabla f(x_*)\| = 0$, 即 $\nabla f(x_*) = 0$. □

另有一些类似的条件, 例如用两条直线控制的 Goldstein 条件, 相当于两次 Armijo 条件.

Definition 2.3.(Goldstein) 设 f 是 $D \subseteq \mathbb{R}^n$ 上的实值函数, 对第 k 步 x_k 选定的方向 p_k, 如果步长 α 满足

$$f(x_k) + (1-c)\alpha \nabla f(x_k)^T p_k \leq f(x_k + \alpha p_k) \leq f(x_k) + c\alpha \nabla f(x_k)^T p_k,$$

其中 $c \in (0, 0.5)$, 则称步长 α 满足 f 在 x_k 处关于 p_k 的 Goldstein 条件.

Chapter 3

28th Sept. Lecture 3 梯度下降 I

3.1 收敛率

Definition 3.1.(收敛率) 设 $\{x_k\}$ 是一个收敛到 x_* 的迭代序列, 定义误差

$$e_k = \|x_k - x_*\|,$$

如果存在 $p > 0$, 使得极限

$$\lim_{k\to\infty} \frac{e_{k+1}}{e_k^p} = c \geq 0$$

存在, 则称 p 为该序列的**收敛阶 (order of convergence)**, c 为相应的**收敛因子 (convergence factor)**.

如果收敛阶 $p = 1$, 序列收敛必须 $c \in [0, 1]$, 且 c 越小收敛越快. 如果 $p = 1$ 且 $c \in (0, 1)$, 则近似地有 $e_k = c^k e_0$, 称为**线性收敛 (linear convergence)**.

如果 $p = 1$ 且收敛因子 $c = 1$, 在特殊条件下也可以收敛, 例如 $e_k = \frac{A}{k}$ 时, $\frac{k}{k+1}$ 趋于 1 但 e_k 趋于 0, 此时称**次线性收敛 (sublinear convergence)**. 如果 $c = 0$, 则称为**超线性收敛 (superlinear convergence)**.

如果 $p > 1$, 则近似地有 $e_{k+1} = ce_k^p$, 如果初始有 $e_1 = ce_0^p \leq e_0$, 则 $ce_0^{p-1} \leq 1$, 于是 $ce_1^{p-1} \leq ce_0^{p-1} \leq 1$, 进而归纳可得 $e_{k+1} = ce_k^p \leq e_k$, 即误差序列 $\{e_k\}$ 单调下降. 更好的结果是

$$e_k \leq ce_{k-1}^p \leq c^{p+1}e_{k-2}^{p^2} \leq \cdots \leq c^{\frac{p^k-1}{p-1}} e_0^{p^k} = c^{-\frac{1}{p-1}} \left(c^{\frac{1}{p-1}} e_0\right)^{p^k}$$

是双指数衰减.

3.2 凸函数

我们知道凸函数有很好的性质: 几乎处处可微, 内闭 (在紧子集上)Lipschitz 连续, 图像总在切平面 (或支撑平面, 即位于一侧且只有唯一公共点) 上方, 即

$$f(x) \geq f(x_0) + \nabla f(x_0)^T (x - x_0).$$

一般而言, 根据定义

$$\frac{f(\alpha x + (1-\alpha)y) - f(y)}{\alpha} \leq f(x) - f(y),$$

取极限即得

$$\nabla f(y)^T (x - y) \leq f(x) - f(y) \iff f(x) \geq f(y) + \nabla f(y)^T (x - y).$$

交换 x, y 可得

$$f(y) \geq f(x) + \nabla f(x)^T (y - x) \iff f(x) \leq f(y) + \nabla f(x)^T (x - y).$$

即有不等式

$$f(y) + \nabla f(y)^T (x - y) \leq f(x) \leq f(y) + \nabla f(x)^T (x - y).$$

以及 Jensen 不等式. 梯度在内积意义上单调上升, 即

$$(\nabla f(x) - \nabla f(y), x - y) \geq 0,$$

每一点处由

$$f(x + tv) + f(x - tv) \geq 2f(x)$$

做二阶 Taylor 展开得

$$2f(x) + t^2 v^T \nabla^2 f(x) v + o(t^2) \geq 2f(x) \implies v^T \nabla^2 f(x) v \geq 0,$$

即 Hessian 半正定.

Proposition 3.1.(凸函数的最值点) 设 f 是开区域 $D \subseteq \mathbb{R}^n$ 上的光滑凸实值函数, 则 $x_* \in D$ 是全局最小值点当且仅当 $\nabla f(x_*) = 0$.

Proof. 内点作为最值点必然是极值点, 因此 $\nabla f(x_*) = 0$, 反之若 $\nabla f(x_*) = 0$, 对任意一点 $x \in D$, 根据凸函数的性质

$$f(x) - f(x_*) \geq \nabla f(x_*)^T (x - x_*) = 0$$

可知 x_* 是最小值点. □

Definition 3.2.(M-Lipschitz) 设 f 是开区域 $D \subseteq \mathbb{R}^n$ 上的光滑凸实值函数, 如果存在 $M > 0$, 使得对任意 $x, y \in D$, 都有

$$\|\nabla f(x) - \nabla f(y)\| \leq M\|x - y\|,$$

则称 ∇f 是 M-Lipschitz 的.

我们给出一个更简洁的充要条件.

Proposition 3.2.(M-Lipschitz) 设 f 是开区域 $D \subseteq \mathbb{R}^n$ 上的光滑凸实值函数, 则 ∇f 是 M-Lipschitz 当且仅当 $MI - \nabla^2 f(x)$ 是半正定的.

Proof. 如果 $MI - \nabla^2 f(x)$ 是半正定的, 则做相似对角化可见 $\nabla^2 f(x)$ 的每个特征值 $\lambda \leq M$. 由凸函数可知每一点处 $\nabla^2 f(x)$ 半正定, 即 $\lambda \geq 0$. 由于 $H = \nabla^2 f(x)$ 对称, $H^T H$ 的特征值为 H^2 的特征值, 即 λ^2, 于是

$$\|\nabla f(x) - \nabla f(y)\| \leq \left\| \int_0^1 \nabla^2 f(ty + (1-t)x)(y - x) \right\| \mathrm{d}t \leq \|H\|_2 \|x - y\| \leq M\|x - y\|.$$

反之, 假设 $MI - \nabla^2 f(x)$ 是不定的, 且 ∇f 是 M-Lipschitz 的, 则存在一个 x_0 和 v 使得

$$v^T \nabla^2 f(x_0) v > M\|v\|^2.$$

根据 M-Lipschitz 性质有

$$\|\nabla f(x_0 + tv) - \nabla f(x_0)\| \leq M|t|\|v\|,$$

除 $|t|$ 并令 $t \to 0$ 得

$$\|\nabla^2 f(x_0)v\| \leq M\|v\| \implies \|v^T \nabla^2 f(x_0) v\| \leq M\|v\|^2,$$

这就导出了矛盾. □

对于梯度下降, 下面的命题是有用的.

Proposition 3.3. 设 f 是开区域 $D \subseteq \mathbb{R}^n$ 上的光滑凸实值函数, ∇f 是 M-Lipschitz 的. 则对任意 $x, y \in D$, 有

$$\frac{1}{2M}\|\nabla f(x) - \nabla f(y)\|^2 \leq f(y) - f(x) - \nabla f(x)^T (y - x) \leq \frac{M}{2}\|x - y\|^2,$$

以及

$$\frac{1}{M}\|\nabla f(x) - \nabla f(y)\|^2 \leq (\nabla f(x) - \nabla f(y), x - y) \leq M\|x - y\|^2.$$

Proof. 作 Taylor 展开

$$f(y) = f(x) + \nabla f(x)^T(y-x) + \frac{1}{2}(y-x)^T\nabla^2 f(x+t(y-x))(y-x),$$

其中 $t \in (0,1)$ 与 x, y 有关. 由 M-Lipschitz 条件以及**Proposition 3.2.**可知

$$(y-x)^T\nabla^2 f(x+t(y-x))(y-x) \le M\|y-x\|^2,$$

代入得

$$f(y) - f(x) - \nabla f(x)^T(y-x) \le \frac{M}{2}\|y-x\|^2.$$

若 f 存在最小值 x_*, 则左边只要证

$$\frac{1}{2M}\|\nabla f(y)\|^2 \le f(y) - f(x_*).$$

注意到根据已经证明的右边不等式, 有

$$f(x_*) \le \inf_{y\in D}\{f(y)\} \le \inf_{y\in D}\left\{f(x) + \nabla f(x)^T(y-x) + \frac{M}{2}\|y-x\|^2\right\},$$

特别地对右边的最小值点 $y = x - \frac{1}{M}\nabla f(x)$ 也成立, 即

$$\frac{1}{2M}\|\nabla f(y)\|^2 \le f(y) - f(x_*).$$

对一般点 x, 考虑

$$\phi_x(y) = f(y) - f(x) - \nabla f(x)^T(y-x)$$

显然是凸函数, 因为线性部分不影响凸性而 f 是凸函数, 且仍然有 $\nabla\phi_x$ 是 M-Lipschitz 连续的, 以及

$$\nabla\phi_x(x) = \nabla f(x) - 0 - \nabla f(x) = 0,$$

根据**Proposition 3.1.**$y = x$ 是 ϕ_x 的最小值点, 于是根据前述结论

$$\frac{1}{2M}\|\nabla\phi_x(y)\|^2 \le \phi_x(y) - \phi_x(x),$$

代入得

$$\frac{1}{2M}\|\nabla f(y) - \nabla f(x)\|^2 \le f(y) - f(x) - \nabla f(x)^T(y-x).$$

交换 x, y 可得

$$\frac{1}{2M}\|\nabla f(x) - \nabla f(y)\|^2 \le f(x) - f(y) - \nabla f(y)^T(x-y) \le \frac{M}{2}\|x-y\|^2,$$

相加即证第二个不等式. □

特别地, 在第一个不等式中取 $x = x_*$ 是最小值点, 则 $\nabla f(x_*) = 0$, 有

$$\frac{1}{2M}\|\nabla f(y)\|^2 \le f(y) - f(x_*) \le \frac{M}{2}\|x_* - y\|^2.$$

同样, 在第二个不等式中取 $y = x_*$ 是最小值点, 有

$$\frac{1}{M}\|\nabla f(x)\|^2 \le \nabla f(x)^T(x - x_*) \le M\|x - x_*\|^2.$$

3.3 梯度下降

下面我们考虑梯度下降法.

Algorithm 3.1.(梯度下降) 我们知道梯度方向是下降最快的方向, 取方向

$$p_k = -\frac{\nabla f(x_k)}{\|\nabla f(x_k)\|},$$

取步长 α_k 使

$$x_{k+1} = x_k - \alpha_k \nabla f(x_k),$$

得到的序列称为**梯度下降 (gradient descent)**.

如果 ∇f 是 M-Lipschitz 的, 则利用**Proposition 3.3.**有估计

$$f(x_{k+1}) - f(x_k) - \nabla f(x_k)^T(-\alpha_k \nabla f(x_k)) \le \frac{M}{2}\|\alpha_k \nabla f(x_k)\|^2,$$

即得

$$f(x_{k+1}) \le f(x_k) - \alpha_k \|\nabla f(x_k)\|^2 + \frac{M}{2}\alpha_k^2 \|\nabla f(x_k)\|^2.$$

这是一个关于 α_k 的二次函数, 在 $\alpha_k = \frac{1}{M}$ 处取最小值, 而在 $0 < \alpha < \frac{2}{M}$ 时确保下降.

Theorem 3.4.(梯度下降的收敛性) 设 f 是开区域 $D \subseteq \mathbb{R}^n$ 上的光滑凸实值函数且有下界, ∇f 是 M-Lipschitz 的. 若取迭代序列

$$x_{k+1} = x_k - \alpha \nabla f(x_k), \quad \alpha \in \left(0, \frac{2}{M}\right),$$

则 $\nabla f(x_k)$ 收敛到 0, 且若最小值点存在, 则 $\{x_k\}$ 会收敛到某个最小值点.

Proof. 根据**Proposition 3.3.**可知

$$f(x_k) - f(x_{k+1}) \ge \alpha\left(1 - \frac{M}{2}\alpha\right)\|\nabla f(x_k)\|^2,$$

累加得

$$\alpha\left(1 - \frac{M}{2}\alpha\right)\sum_{k=1}^{\infty}\|\nabla f(x_k)\|^2 \le f(x_0) - \liminf_{k\to\infty}\{f(x_k)\},$$

根据有界性可知左边收敛, 于是项 $\|\nabla f(x_k)\|$ 收敛到 0.

现在设 $\bar{x}_*$ 是一个最小值点, 根据范数的定义

$$\|x_{k+1} - \bar{x}_*\|^2 = \|x_k - \bar{x}_*\|^2 - 2\alpha \nabla f(x_k)^T(x_k - \bar{x}_*) + \alpha^2\|\nabla f(x_k)\|^2.$$

根据**Proposition 3.3.**的推论有

$$\nabla f(x_k)^T(x_k - \bar{x}_*) \ge \frac{1}{M}\|\nabla f(x_k)\|^2,$$

于是

$$\|x_{k+1}-\bar{x}_*\|^2 \le \|x_k-\bar{x}_*\|^2 - \alpha\left(\frac{2}{M}-\alpha\right)\|\nabla f(x_k)\|^2.$$

可见 $\{\|x_k-\bar{x}_*\|\}$ 单调下降, 因此 $\{x_k\}$ 有界, 从而必存在子列收敛到 x_*, 此时 $\nabla f(x_*)$ 作为 $\nabla f(x_k)$ 的子列极限, 根据上一步证明必为 0, 于是根据**Proposition 3.1.**可知是最小值点. □

注意上式说明对任意一个最小值点 $\|x_k-\bar{x}_*\|$ 都是单调下降的, 只不过最后只会收敛到一个最小值点.

现在我们说明梯度下降法的收敛速度.

Theorem 3.5.(梯度下降的收敛率) 设 f 是开区域 $D\subseteq\mathbb{R}^n$ 上的光滑凸实值函数且有下界, ∇f 是 M-Lipschitz 的. 若取迭代序列

$$x_{k+1}=x_k-\alpha\nabla f(x_k),\quad \alpha\in\left(0,\frac{2}{M}\right),$$

则

$$f(x_k)-f(x_*)\le\frac{1}{k}\frac{\|x_0-x_*\|^20}{\alpha\left(1-\frac{M}{2}\alpha\right)},$$

从而是次线性收敛.

Proof. 根据**Proposition 3.3.**可知

$$f(x_k)-f(x_{k+1})\ge\alpha\left(1-\frac{M}{2}\alpha\right)\|\nabla f(x_k)\|^2,$$

我们希望由此得到函数值的估计, 因此作变形

$$f(x_{k+1})-f(x_*)\le f(x_k)-f(x_*)-\alpha\left(1-\frac{M}{2}\alpha\right)\|\nabla f(x_k)\|^2.$$

现在还要把 $\|\nabla f(x_k)\|$ 与函数值联系. 根据凸函数的一阶条件 (切平面上方) 可知

$$f(x_*)\ge f(x_k)+\nabla f(x_k)^T(x_*-x_k)\implies\|\nabla f(x_k)\|\ge\frac{f(x_k)-f(x_*)}{\|x_k-x_*\|}.$$

由**Theorem 3.4.**可知 $\|x_k-x_*\|$ 单调下降, 上式放缩后代入得

$$f(x_{k+1})-f(x_*)\le f(x_k)-f(x_*)-\alpha\left(1-\frac{M}{2}\alpha\right)\left(\frac{f(x_k)-f(x_*)}{\|x_0-x_*\|}\right)^2.$$

这是一个关于 $\Delta_k=f(x_k)-f(x_*)$ 的差分不等式

$$\Delta_{k+1}\le\Delta_k-c\Delta_k^2,\quad c=\alpha\left(1-\frac{M}{2}\alpha\right)\frac{1}{\|x_0-x_*\|^2}.$$

取倒数

$$\frac{1}{\Delta_{k+1}} \geq \frac{1}{\Delta_k(1-c\Delta_k)} = \frac{1}{\Delta_k} + \frac{c}{1-c\Delta_k}.$$

由于证明之初就说明了 $\Delta_k = f(x_k) - f(x_*)$ 单调下降, 因此

$$\frac{1}{\Delta_{k+1}} \geq \frac{1}{\Delta_k} + \frac{c}{1-c\Delta_k} \geq \frac{1}{\Delta_k} + \frac{c}{1-c\Delta_0} \implies \frac{1}{\Delta_k} \geq \frac{1}{\Delta_0} + \frac{kc}{1-c\Delta_0} \geq \frac{kc}{1-c\Delta_0}.$$

于是

$$f(x_k) - f(x_*) = \Delta_k \leq \frac{1}{k}\left(\frac{\|x_0 - x_*\|^2 0}{\alpha\left(1-\frac{M}{2}\alpha\right)} - \Delta_0\right) \leq \frac{1}{k}\frac{\|x_0 - x_*\|^2 0}{\alpha\left(1-\frac{M}{2}\alpha\right)}.$$

□

如果要得到更好的收敛速度, 必须给出更强的条件.

Definition 3.3.(m-强凸) 设 f 是开区域 $D \subseteq \mathbb{R}^n$ 上的光滑实值函数, 如果存在 $m > 0$, 使得对任意 $x \in D$, 都有

$$f(x) - \frac{1}{2}m\|x\|^2$$

是凸函数, 则称 f 是 **m-强凸 (m-strongly convex)** 的.

首先给出其在 Hessian 上的等价定义.

Proposition 3.6.(m-强凸) 设 f 是开区域 $D \subseteq \mathbb{R}^n$ 上的光滑实值函数, 则 f 是 m-强凸的当且仅当 $\nabla^2 f(x) - mI$ 是半正定的.

Proof. 如果 f 是 m-强凸的, 则考虑凸函数

$$\varphi(t) = f(x+tv) - \frac{1}{2}m\|x+tv\|^2 \implies \varphi''(t) = v^T(\nabla^2 f(x+tv) - mI)v,$$

由于 φ 凸, 有 $\varphi''(0) \geq 0$, 于是 $\nabla^2 f(x) - mI$ 半正定.

如果 $\nabla^2 f(x) - mI$ 半正定, 则同样道理

$$\varphi''(t) = v^T(\nabla^2 f(x+tv) - mI)v \geq 0,$$

表明 φ 凸, 于是有

$$\varphi(t) \leq (1-t)\varphi(0) + t\varphi(1),$$

令 $v = y - x$ 得

$$f(x+t(y-x)) - \frac{1}{2}m\|x+t(y-x)\|^2 \leq (1-t)\left(f(x) - \frac{1}{2}m\|x\|^2\right) + t\left(f(y) - \frac{1}{2}m\|y\|^2\right),$$

即

$$f(x) - \frac{1}{2}m\|x\|^2$$

是凸函数. □

现在我们推广**Proposition 3.3.**.

Proposition 3.7. 设 f 是开区域 $D \subseteq \mathbb{R}^n$ 上的光滑 m-强凸实值函数, ∇f 是 M-Lipschitz 的. 则对任意 $x, y \in D$, 有

$$\frac{1}{2M}\|\nabla f(x) - \nabla f(y)\|^2 \leq f(y) - f(x) - \nabla f(x)^T(y-x) \leq \frac{1}{2m}\|\nabla f(x) - \nabla f(y)\|^2,$$

以及

$$\frac{1}{M}\|\nabla f(x) - \nabla f(y)\|^2 \leq (\nabla f(x) - \nabla f(y), x - y) \leq \frac{1}{m}\|\nabla f(x) - \nabla f(y)\|^2.$$

特别地, 如果 x_* 是最小值点, 有

$$\frac{1}{M}\|\nabla f(x)\| \leq \|x - x_*\| \leq \frac{1}{m}\|\nabla f(x)\|.$$

Proof. 根据**Proposition 3.3.**两式的左边均成立, 而右边的证明是类似的. 作 Taylor 展开

$$f(y) = f(x) + \nabla f(x)^T(y-x) + \frac{1}{2}(y-x)^T\nabla^2 f(x + t(y-x))(y-x),$$

其中 $t \in (0,1)$ 与 x, y 有关. 由 m-强凸条件以及**Proposition 3.6.**可知

$$(y-x)^T\nabla^2 f(x + t(y-x))(y-x) \geq m\|y-x\|^2,$$

代入得

$$f(y) - f(x) - \nabla f(x)^T(y-x) \geq \frac{m}{2}\|y-x\|^2.$$

若 f 存在最小值 x_*, 则有

$$f(x_*) \geq \inf_{y \in D}\left\{f(x) + \nabla f(x)^T(y-x) + \frac{m}{2}\|y-x\|^2\right\} = f(x) - \frac{1}{2m}\|\nabla f(x)\|^2,$$

这就是右边不等式取 $x = x_*$ 的情形. 对一般点 x, 考虑

$$\phi_x(y) = f(y) - f(x) - \nabla f(x)^T(y-x)$$

仍然是 m-强凸的, 以及 $\nabla\phi_x(x) = 0$, 根据**Proposition 3.1.**$y = x$ 是 ϕ_x 的最小值点, 于是根据前述结论

$$\phi_x(x) \geq \phi_x(y) - \frac{1}{2m}\|\nabla\phi_x(y)\|^2,$$

代入得

$$f(y) - f(x) - \nabla f(x)^T(y-x) \leq \frac{1}{2m}\|\nabla f(x) - \nabla f(y)\|^2.$$

交换 x, y 再相加即证第二个不等式.

最后, 对以下关于 t 的一元函数用微积分基本定理有

$$\nabla f(x) - \nabla f(x_*) = \int_0^1 \nabla^2 f(tx + (1-t)x_*)(x - x_*)\mathrm{d}t,$$

于是根据 m-强凸

$$m\|x - x_*\|^2 \le \int_0^1 (x - x_*)^T \nabla^2 f(tx + (1-t)x_*)(x - x_*)\mathrm{d}t = (\nabla f(x) - \nabla f(x_*), x - x_*),$$

结合第二个不等式右边即知

$$m\|x - x_*\|^2 \le \frac{1}{m}\|\nabla f(x)\|^2 \implies \|x - x_*\| \le \frac{1}{m}\|\nabla f(x)\|.$$

如果取第二个不等式 $y = x_*$, 就得到

$$\frac{1}{M}\|\nabla f(x)\|^2 \le (\nabla f(x), x - x_*) = \|\nabla f(x)\|\|x - x_*\|\cos\theta \le \|\nabla f(x)\|\|x - x_*\|,$$

这就是第三个不等式的另一边. □

Proposition 3.8. 设 f 是开区域 $D \subseteq \mathbb{R}^n$ 上的光滑 m-强凸实值函数, ∇f 是 M-Lipschitz 的. 则对任意 $x, y \in D$, 有

$$\frac{Mm}{M+m}\|x - y\|^2 + \frac{1}{M+m}\|\nabla f(x) - \nabla f(y)\|^2 \le (\nabla f(x) - \nabla f(y), x - y).$$

Proof. 考察

$$h(x) = f(x) - \frac{m}{2}\|x\|^2$$

是凸函数, 且 $\nabla^2 h(x) = \nabla^2 f(x) - mI$, 表明 ∇h 是 $M - m$-Lipschitz 连续的, 于是根据**Proposition 3.3.**

$$\frac{1}{M-m}\|\nabla h(x) - \nabla h(y)\|^2 \le (\nabla h(x) - \nabla h(y), x - y).$$

展开得

$$\frac{1}{M-m}\|\nabla f(x) - \nabla f(y)\|^2 - \frac{M+m}{M-m}(\nabla f(x) - \nabla f(y), x - y) + \frac{Mm}{M-m}\|x - y\|^2 \le 0.$$

整理得

$$\frac{Mm}{M+m}\|x - y\|^2 + \frac{1}{M+m}\|\nabla f(x) - \nabla f(y)\|^2 \le (\nabla f(x) - \nabla f(y), x - y).$$

□

现在我们说明收敛率.

Theorem 3.9.(梯度下降的收敛率) 设 f 是开区域 $D \subseteq \mathbb{R}^n$ 上的光滑 m 强凸实值函数, ∇f 是 M-Lipschitz 的. 若取迭代序列

$$x_{k+1} = x_k - \alpha \nabla f(x_k), \quad \alpha \in \left(0, \frac{2}{M+m}\right],$$

则

$$\|x_k - x_*\|^2 \leq c^k \|x_0 - x_*\|^2, \quad c = 1 - \frac{2Mm}{M+m}\alpha \in (0,1),$$

进而

$$f(x_k) - f(x_*) \leq \frac{M}{2} c^k \|x_0 - x_*\|^2,$$

从而是线性收敛.

Proof. 对

$$x_{k+1} - x_* = x_k - x_* - \alpha \nabla f(x_k)$$

两边取模平方, 展开得

$$\|x_{k+1} - x_*\|^2 = \|x_k - x_*\|^2 - 2\alpha \nabla f(x_k)^T (x_k - x_*) + \alpha^2 \|\nabla f(x_k)\|^2.$$

用**Proposition 3.8.**的估计

$$\nabla f(x_k)^T (x_k - x_*) \geq \frac{Mm}{M+m} \|x_k - x_*\|^2 + \frac{1}{M+m} \|\nabla f(x_k)\|^2,$$

于是

$$\|x_{k+1} - x_*\|^2 \leq \left(1 - \frac{2Mm}{M+m}\alpha\right) \|x_k - x_*\|^2 - \alpha \left(\frac{2}{M+m} - \alpha\right) \|\nabla f(x_k)\|^2.$$

由于 $\alpha \leq \frac{2}{M+m}$, 可得

$$\|x_{k+1} - x_*\|^2 \leq \left(1 - \frac{2Mm}{M+m}\alpha\right) \|x_k - x_*\|^2 = c\|x_k - x_*\|^2.$$

再根据**Proposition 3.3.**的推论

$$f(x) - f(x_*) \leq \frac{M}{2} \|x - x_*\|^2$$

即证. □

Chapter 4

12th Oct. Lecture 4 梯度下降 II

4.1 梯度下降

回顾**Theorem 3.9.**的结果, 对 m-强凸和梯度 M-Lipschitz 的光滑函数 f, 取步长

$$\alpha = \frac{2}{M+m},$$

则

$$c = 1 - \frac{2Mm}{M+m}\alpha = \left(\frac{M-m}{M+m}\right)^2,$$

于是误差

$$e_{k+1} = \|x_{k+1} - x_*\| \leq \frac{M-m}{M+m}\|x_k - x_*\| = \frac{M-m}{M+m}e_k.$$

如果想要误差不超过 ε, 则一个充分条件是

$$e_k \leq e_0\left(\frac{M-m}{M+m}\right)^k \leq \varepsilon.$$

我们称

$$\kappa = \frac{M}{m}$$

为该迭代过程的**条件数 (condition number)**. 一般而言, 矩阵的条件数定义为

$$\kappa(A) = \|A\|_2\|A^{-1}\|_2,$$

依照 2 范数的奇异值定义, 这也是最大奇异值和最小奇异值的比. 现在 $\nabla^2 f(x)$ 是对称阵, 且依照**Proposition 3.2.**和**Proposition 3.6.**可知其特征值被 m, M 控制, 而对称阵的奇异值恰好是其特征值的模长, 因此上述定义的 κ 可视为 $\nabla^2 f(x)$ 的条件数.

现在充分条件改写为

$$e_0\left(\frac{\kappa-1}{\kappa+1}\right)^k \leq \varepsilon \iff k \geq \log\frac{\varepsilon}{e_0}\log\left(1 - \frac{2}{\kappa+1}\right)^{-1}.$$

此即 $k \in O(\log \varepsilon\kappa)$, 即需要的迭代次数按 $\log \varepsilon$ 和 κ 的速度增长, 特别地被 κ 控制下界.

以上只是一个充要条件的推导, 下例说明这一估计是可以达到的, 因此 $k \in \Theta(\log \varepsilon\kappa)$, 即不能够得到更小的下界估计了.

Example 4.1.(二次型的最小迭代次数) 考虑二次型

$$f(x) = \frac{1}{2}x^T Ax - b^T x,$$

其中 A 是正定对称阵, 从而 $\nabla^2 f(x) = A$ 表明 f 是凸函数. 设 A 的最大和最小特征值为 λ, μ, 则依照**Proposition 3.2.**和**Proposition 3.6.**可知 f 是 μ-强凸且梯度是 λ-Lipschitz 的. 现在做梯度下降, 迭代公式

$$x_{k+1} = x_k - \alpha_k \nabla f(x_k) = x_k - \alpha_k(Ax_k - b).$$

设 x_* 为一个最小值点, 则当然满足 $\nabla f(x_k) = 0$, 即 $Ax_* = b$, 于是两边减去 x_* 并取范数得到

$$e_{k+1} = \|x_{k+1} - x_*\| = \|x_k - x_* - \alpha_k(Ax_k - Ax_*)\| \leq \|I - \alpha_k A\|_2 e_k.$$

最好的情况是选择步长让 e_k 下降最多, 即 α_k 应当使得 $I - \alpha_k A$ 的范数最小. 我们知道对称矩阵的 2 范数是最大特征值模长, 因此这就是使

$$\max_{1\leq i\leq n}\{|1 - \alpha_k\lambda_i|\}$$

最小. 注意到 $|1 - \alpha_k\lambda_i|$ 关于 λ_i 是一个线性函数复合绝对值函数, 其最大值必然在 λ_i 的最值 λ, μ 处取到, 因此 α_k 应当使两边的最大值相等

$$1 - \alpha_k\lambda = \alpha_k\mu - 1 \implies \alpha_k = \frac{2}{\lambda + \mu},$$

且此时

$$\|I - \alpha_k A\|_2 = \left|1 - \frac{2}{\lambda + \mu}\lambda\right| = \frac{\kappa - 1}{\kappa + 1}$$

恰好取到以上的估计.

对一般未必光滑的凸函数, 如果取一个定步长, 则梯度下降很可能不收敛, 但我们可以考虑其平均.

Proposition 4.1. 设 f 是开区域 $D \subseteq \mathbb{R}^n$ 上的可微凸实值函数, 且为 G-Lipschitz 的, 则对固定的 $\bar{x}$ 和步长 α, 迭代点 x_k 满足

$$f(x_k) + \frac{\|x_{k+1} - \bar{x}\|^2}{2\alpha} - \frac{\|x_k - \bar{x}\|^2}{2\alpha} \leq f(\bar{x}) + \frac{\alpha}{2}G^2.$$

Proof. 根据梯度下降的迭代公式

$$x_{k+1} - \bar{x} = x_k - \bar{x} - \alpha \nabla f(x_k),$$

取范数展开得

$$\|x_{k+1} - \bar{x}\|^2 = \|x_k - \bar{x}\|^2 - 2\alpha \nabla f(x_k)^T (x_k - \bar{x}) + \alpha^2 \|\nabla f(x_k)\|^2,$$

即得

$$\frac{\|x_{k+1} - \bar{x}\|^2}{2\alpha} - \frac{\|x_k - \bar{x}\|^2}{2\alpha} = -\nabla f(x_k)^T (x_k - \bar{x}) + \frac{\alpha}{2} \|\nabla f(x_k)\|^2.$$

一方面根据 G-Lipschitz 可知 $\|\nabla f(x_k)\| \leq G$, 另一方面根据凸函数的一阶条件

$$f(\bar{x}) \geq f(x_k) + \nabla f(x_k)^T (\bar{x} - x_k),$$

代入即证. □

现在对这些不等式求平均, 则可以得到平均点的收敛性.

Proposition 4.2.(平均点的收敛性) 设 f 是开区域 $D \subseteq \mathbb{R}^n$ 上的可微凸实值函数, 且为 G-Lipschitz 的. 考虑迭代点的平均点

$$\hat{x}_T = \frac{1}{T} \sum_{k=1}^{T} x_k,$$

则对最小值点 x_* 有

$$f(\hat{x}_T) - f(x_*) \leq \frac{\|x_1 - x_*\|^2}{2\alpha T} + \frac{\alpha}{2} G^2.$$

Proof. 根据**Proposition 4.1.**的结果, 取 $\bar{x} = x_*$, 并对 k 求平均, 得到

$$\frac{1}{T} \sum_{k=1}^{T} f(x_k) + \frac{\|x_{T+1} - x_*\|^2}{2\alpha T} - \frac{\|x_1 - x_*\|^2}{2\alpha T} \leq f(x_*) + \frac{\alpha}{2} G^2.$$

利用凸函数的 Jensen 不等式, 得到

$$\frac{1}{T} \sum_{k=1}^{T} f(x_k) \geq f(\hat{x}_T),$$

于是放缩为

$$f(\hat{x}_T) - f(x_*) \leq \frac{\|x_1 - x_*\|^2}{2\alpha T} + \frac{\alpha}{2} G^2.$$

□

这说明当 T 充分大时, 即使函数本身未必光滑, 迭代步长固定, x_k 的平均点仍然会保证迭代结果 $f(\hat{x}_T)$ 与实际值 $f(x_*)$ 的误差在一个充分小, 约为 $\frac{\alpha}{2}G^2$ 的范围内. 因此只要选取充分小的步长, 也可以确保平均点的值与最小值足够接近.

要是以上误差不超过 ε, 选择步长和步数

$$\alpha = \frac{\varepsilon}{G^2}, \quad T = G^2 \max_{x_1} \left\{ \|x_1 - x_*\|^2 \right\} \varepsilon^{-2}$$

即可.

我们知道如果梯度下降总是选择局部最优的步长, 则

$$f(x_{k+1}) = f\left(x_k - \alpha_k \nabla f(x_k)\right)$$

最小, 于是对 α_k 的导数

$$\nabla f(x_{k+1})^T \nabla f(x_k) = 0.$$

如果在平面上, 则每次下降方向都与上一次垂直, 从而与再上一次平行, 会导致迭代路线不断振动.

一个合理的想法是让每次下降方向携带上一次的动量, 称为**重球法 (heavy-ball method)**, 相应的迭代模式为

$$x_{k+1} = x_k - \alpha_k \nabla f(x_k) + \beta_k (x_k - x_{k-1}).$$

我们可以通过常微分方程理解该迭代模式. 首先上式可改写为

$$\beta_k (x_{k+1} - 2x_k + x_{k-1}) = -\alpha_k \nabla f(x_k) - (1 - \beta_k)(x_{k+1} - x_k),$$

取 $\alpha_k = \Delta t^2$ 和 $\beta_k = 1 - \gamma_k \Delta t$, 则以上的差分模式会变为微分方程

$$\frac{\mathrm{d}^2 x}{\mathrm{d}t^2} + \gamma_k \frac{\mathrm{d}x}{\mathrm{d}t} + \nabla f(x) = 0.$$

4.2 临近梯度法

梯度下降的一个迭代步可以视为一次优化问题

$$x_{k+1} = \operatorname{argmin} \left\{ \frac{1}{2\alpha_k} \|x - (x_k - \alpha_k \nabla f(x_k)\|^2 \right\}$$

或者

$$x_{k+1} = \operatorname{argmin} \left\{ f(x_k) + \nabla f(x_k)^T x + \frac{1}{2\alpha_k} \|x - x_k\|^2 \right\},$$

后者是因为对 x 的导数

$$\nabla f(x_k) + \frac{1}{\alpha_k}(x - x_k) = 0 \iff x = x_k - \alpha_k \nabla f(x_k).$$

前两项

$$f(x_k) + \nabla f(x_k)^T x$$

是 $f(x)$ 在 x_k 处的近似.

如果我们把这个近似改为函数本身, 就得到

$$x_{k+1} = \operatorname{argmin}\left\{ f(x) + \frac{1}{2\alpha_k}\|x - x_k\|^2 \right\},$$

相应的点为

$$\nabla f(x) + \frac{1}{\alpha_k}(x - x_k) = 0 \iff x = x_k - \alpha_k \nabla f(x),$$

相应的隐式迭代步

$$x_{k+1} = x_k - \alpha_k \nabla f(x_{k+1}).$$

将迭代模式写为优化问题的一个好处是避免

$$x_{k+1} = x_k - \alpha_k \nabla f(x_k)$$

离开优化范围 D, 即改写为

$$x_{k+1} = \operatorname{argmin}_{x\in D}\left\{ f(x_k) + \nabla f(x_k)^T x + \frac{1}{2\alpha_k}\|x - x_k\|^2 \right\}.$$

一般而言, 我们可以将待优化函数分解为光滑部分和非光滑部分的和 $f + g$, 相应的迭代步是一个综合显式和隐式的优化问题.

Algorithm 4.1.(临近梯度法) 设 h 是开区域 $D \subseteq \mathbb{R}^n$ 上的凸实值函数, 分解为光滑凸函数 f 和未必光滑凸函数 g 的和. 取步长 α_k, 使得迭代步是优化问题

$$x_{k+1} = \operatorname{argmin}_{x\in D}\left\{ f(x_k) + \nabla f(x_k)^T x + g(x) + \frac{1}{2\alpha_k}\|x - x_k\|^2 \right\}$$

的解, 或者整理为

$$x_{k+1} = \operatorname{argmin}_{x\in D}\left\{ \alpha_k g(x) + \frac{1}{2}\|x - (x_k - \alpha_k \nabla f(x_k))\|^2 \right\}.$$

得到的迭代序列称为**临近梯度法 (proximal gradient method)**.

Definition 4.1.(临近映射) 设 h 是开区域 $D \subseteq \mathbb{R}^n$ 上的恰当下半连续凸实值函数, 其中恰当是指 $\|x\| \to \infty$ 时总有 $h(x) \to +\infty$. 对 $\alpha > 0$, 定义**临近映射 (proximal mapping)**

$$\operatorname{prox}_{\alpha,h}(z) = \operatorname{argmin}_{x\in D}\left\{ h(x) + \frac{1}{2\alpha}\|x - z\|^2 \right\}.$$

此时临近梯度法的迭代模式可以写为

$$x_{k+1} = \mathrm{prox}_{\alpha_k, g}(x_k - \alpha_k \nabla f(x_k)).$$

Example 4.2.(带非光滑惩罚项的 ISTA 算法) 考虑带 1 范数惩罚的二次函数

$$f(x) = \lambda \|x\|_1 + \frac{1}{2}\|Ax - b\|^2$$

的优化问题. 采用临近梯度法, 用固定步长 α, 迭代公式

$$x_{k+1} = \mathrm{argmin}\left\{\alpha\lambda\|x\|_1 + \frac{1}{2}\|x - (x_k - \alpha A^T(Ax - b))\|^2\right\}.$$

注意到对每个分量 u

$$\alpha\lambda|u| + \frac{1}{2}(u - (u_k - \alpha A^T(a_u u - b)))^2$$

是关于 u 的分段二次函数, 从而可以求最小值点, 其中 a_u 是 A 相应于 u 的一列.

现在考虑临近梯度法的收敛率.

Proposition 4.3.(临近梯度法的收敛率) 设 h 是开区域 $D \subseteq \mathbb{R}^n$ 上的恰当下半连续凸实值函数, 且梯度 ∇h 是 M-Lipschitz 的, 分解为光滑凸函数 f 和未必光滑凸函数 g 的和. 取固定步长 $\alpha < \frac{1}{M}$ 的临近梯度法, 则对最小值点 x_* 有

$$h(x_N) - h(x_*) \leq \frac{\|x_0 - x_*\|^2}{2\alpha N},$$

从而是次线性收敛.

Proof. 考虑迭代模式

$$x_{k+1} = \mathrm{argmin}_{x \in D}\left\{\alpha g(x) + \frac{1}{2}\|x - (x_k - \alpha\nabla f(x_k))\|^2\right\}.$$

在此优化问题中, 待优化函数可视为

$$Q(x) = g(x) + \frac{1}{2\alpha}\|x - (x_k - \alpha\nabla f(x_k))\|^2 - \frac{\alpha}{2}\|\nabla f(x_k)\|^2,$$

即

$$Q(x) = g(x) + \frac{1}{2\alpha}\|x - x_k\|^2 + \nabla f(x_k)^T(x - x_k).$$

注意到根据**Definition 3.3.**Q 显然是 $\frac{1}{\alpha}$-强凸的, 于是根据**Proposition 3.7.**的不等式

$$Q(x) \geq Q(y) + \nabla f(y)^T(x - y) + \frac{1}{2\alpha}\|x - y\|^2.$$

现在优化结果 x_{k+1} 是其最小值点, 代入 $y = x_{k+1}$ 得

$$Q(x_{k+1}) \leq Q(x) - \frac{1}{2\alpha}\|x - x_{k+1}\|^2$$

对一切 x 都成立. 整理得

$$g(x_{k+1}) - g(x) + \nabla f(x_k)^T(x_{k+1} - x) \leq \frac{1}{2\alpha}\left(\|x - x_k\|^2 - \|x - x_{k+1}\|^2 - \|x_{k+1} - x_k\|^2\right).$$

利用凸函数在切平面上方, 有

$$f(x) \geq f(x_k) + \nabla f(x_k)^T(x - x_k),$$

根据 M-Lipschitz 的条件在**Proposition 3.3.**的结果, 有

$$f(x_{k+1}) - f(x_k) - \nabla f(x_k)^T(x_{k+1} - x_k) \leq \frac{M}{2}\|x_k - x_{k+1}\|^2,$$

相减得到

$$f(x_{k+1}) - f(x) - \nabla f(x_k)^T(x_{k+1} - x) \leq \frac{M}{2}\|x_k - x_{k+1}\|^2.$$

与 g 对应的不等式相加得

$$h(x_{k+1}) - h(x) \leq \frac{\|x - x_k\|^2 - \|x - x_{k+1}\|^2}{2\alpha} + \left(\frac{M}{2} - \frac{1}{2\alpha}\right)\|x_{k+1} - x_k\|^2.$$

先取 $x = x_k$, 得到

$$h(x_{k+1}) - h(x_k) \leq \left(\frac{M}{2} - \frac{1}{\alpha}\right)\|x_{k+1} - x_k\|^2.$$

由于 $\alpha < \frac{1}{M}$, 右边非正, 于是 $h(x_k)$ 关于 k 单调下降. 于是求和

$$\sum_{k=0}^{N-1} h(x_{k+1}) - Nh(x) \leq \frac{\|x - x_0\|^2 - \|x - x_N\|^2}{2\alpha} + \left(\frac{M}{2} - \frac{1}{2\alpha}\right)\sum_{k=0}^{N-1}\|x_{k+1} - x_k\|^2$$

可以放缩为

$$N(h(x_N) - h(x)) \leq \frac{\|x - x_0\|^2}{2\alpha},$$

再取 $x = x_*$ 为最小值即证. □

4.3 镜像梯度法

我们知道对方向导数

$$l_x(v) = \frac{\mathrm{d}}{\mathrm{d}\alpha} f(x + \alpha v),$$

梯度在 Eculid 内积空间中满足

$$l_x(v) = \nabla f(x)^T v.$$

如果考虑其他内积, 则可以定义出一类范数. 我们知道一个 Riemann 流形是带有 Riemann 度量的光滑流形, 每个 Riemann 度量为流形赋予了一个特定的几何结构. 因此 $\mathbb{R}^n$ 上的每个内积也为 $\mathbb{R}^n$ 赋予了一个几何结构, 在这一几何上同样可以构造梯度下降, 且会获得与 Eculid 度量不同的收敛情形.

Definition 4.2.(内积诱导的梯度) 设 f 是开区域 $D \subseteq \mathbb{R}^n$ 上的实值函数, 使得方向导数

$$l_x(v) = \frac{\mathrm{d}}{\mathrm{d}\alpha} f(x + \alpha v)$$

在每处和每个方向存在. 对每个 $\mathbb{R}^n$ 上的内积 g, 即一个正定对称双线性型, 根据 Riesz 表示定理存在唯一的线性泛函 ∇_g, 使得

$$l_x(v) = g(\nabla_g f(x), v).$$

称 $\nabla_g f$ 为 f 由内积 g 诱导的梯度.

反之对每个固定的 $x \in D$, 梯度 $\nabla_g f(x)$ 诱导出线性算子

$$g(\nabla_g f(x), -) = l_x(-),$$

因此 $\nabla_g f(x)$ 可以看作切空间 $T_x\mathbb{R}^n$ 中的元素.

现在考虑梯度下降, x 在 $D \subseteq \mathbb{R}^n$ 中梯度下降到 x_* 时, $\nabla h(x)$ 也会梯度下降到对偶空间中的 $\nabla h(x_*)$, 如果 ∇h 作为 D 到 $T_D\mathbb{R}^n$ 上的映射可逆, 则可以在对偶空间做梯度下降

$$\nabla h(x_{k+1}) = \nabla h(x_k) - \alpha_k \nabla f(x_k),$$

再将结果还原回原空间

$$x_{k+1} = (\nabla h)^{-1}(\nabla h(x_k) - \alpha_k \nabla f(x_k)).$$

这相当于求解优化问题

$$\operatorname{argmin}\left\{ f(x_k) + \nabla f(x_k)^T x + \frac{1}{\alpha_k}\left(h(x) - h(x_k) - \nabla h(x_k)^T(x - x_k)\right)\right\},$$

因为对 x 的导数

$$\nabla f(x_k) + \frac{1}{\alpha_k}(\nabla h(x) - \nabla h(x_k)) = 0 \iff x = (\nabla h)^{-1}(\nabla h(x_k) - \alpha_k \nabla f(x_k)).$$

这也可以看作在梯度下降

$$x_{k+1} = \operatorname{argmin}\left\{f(x_k) + \nabla f(x_k)^T x + \frac{1}{2\alpha_k}\|x - x_k\|^2\right\}$$

中更换最后的惩罚项的结果, 因此可以定义以下的惩罚项.

Definition 4.3.(Bregman 散度) 设 h 是开区域 $D \subseteq \mathbb{R}^n$ 上的光滑实值函数, 定义 x 到 y 关于 h 的 **Bregman 散度 (Bregman divergence)**

$$D_h(y\|x) = h(y) - h(x) - \nabla h(x)^T(y - x).$$

所谓镜像梯度法, 就是在对偶空间做梯度下降.

Algorithm 4.2.(镜像梯度法) 设 f 是开区域 $D \subseteq \mathbb{R}^n$ 上的光滑凸实值函数, h 是 D 上的光滑实值函数, 使得 ∇h 可逆. 对一个迭代点 x_k, 取对偶点 $\theta_k = \nabla h(x_k)$, 取步长 α_k 做梯度下降

$$\theta_{k+1} = \theta_k - \alpha_k \nabla f(x_k),$$

再还原为 $x_{k+1} = (\nabla h)^{-1}(\theta_{k+1})$. 则该迭代序列称为**镜像梯度法 (mirror descent)**.

Chapter 5

19th Oct. Lecture 5 Newton 法

5.1 Newton 法

回顾梯度下降法的方向选择

$$p = -\frac{\nabla f(x)}{\|\nabla f(x)\|}$$

只依赖于一阶导数, 这相当于取方向为使一阶 Taylor 展开

$$f(x+p) \approx f(x) + \nabla f(x)^T p$$

最小的方向.

我们也可以考虑高阶 Taylor 展开, 即使用高阶导数, 例如直接考虑二阶 Taylor 展开

$$f(x+p) \approx f(x) + \nabla f(x)^T p + \frac{1}{2} p^T \nabla^2 f(x) p$$

关于 p 的最小值. 如果没有 $\|p\| = 1$ 的要求, 即 p 混合了最优方向和最优步长的信息, 则问题变为无约束优化, 只要对 p 求梯度

$$\nabla f(x) + \nabla^2 f(x) p = 0 \iff p = -(\nabla^2 f(x))^{-1} \nabla f(x).$$

另一个想法是考虑全局最优解必然满足 $\nabla f(x) = 0$, 但此方程一般非线性. 我们考虑在当前步 x_k 做 Taylor 展开

$$\nabla f(x) \approx \nabla f(x_k) + \nabla^2 f(x_k)(x - x_k),$$

于是可以取

$$x_{k+1} = x_k - (\nabla^2 f(x_k))^{-1} \nabla f(x_k),$$

这里的下降方向也是我们求出的 $p = -(\nabla^2 f(x))^{-1} \nabla f(x)$.

这一类利用二阶近似得到的迭代法称为 Newton 法.

Algorithm 5.1.(纯 Newton 法) 对一个迭代点 x_k, 取下一个迭代点

$$x_{k+1} = x_k - (\nabla^2 f(x_k))^{-1}\nabla f(x_k),$$

得到的序列称为**纯 Newton 法 (pure Newton's method)**.

我们分析纯 Newton 法的收敛率.

Theorem 5.1.(纯 Newton 法的收敛率) 设 f 是在开区域 $D \subseteq \mathbb{R}^n$ 上二阶可微, 且 $\nabla^2 f$ 在最小值点 x_* 处正定, 在 x_* 的某邻域 $\mathcal{N}$ 上 Lipschitz 连续, 即

$$\|\nabla^2 f(x) - \nabla^2 f(y)\|_2 \leq L\|x - y\|.$$

若 x_0 与 x_* 充分接近, 则纯 Newton 法序列 $\{x_k\}$ 收敛到 x_*, 且 x_k 和 $\nabla f(x_k)$ 的收敛阶为 2.

Proof. 由 $\nabla^2 f(x)$ 在 x_* 附近连续, 存在充分小的 δ, 在 x_* 的 δ 邻域内 $\|\nabla^2 f(x)^{-1}\|_2$ 有界 $\frac{2}{\sigma}$, 其中 σ 是 $\nabla^2 f(x_*)$ 的最小特征值.

在迭代模式两边减去 x_* 得到

$$x_{k+1} - x_* = (x_k - x_*) - (\nabla^2 f(x_k))^{-1}\nabla f(x_k),$$

即

$$(\nabla^2 f(x_k))^{-1}\left(\nabla^2 f(x_k)(x_k - x_*) - \nabla f(x_k)\right).$$

根据 $\nabla f(x_*) = 0$, 同**Theorem 3.7.**, 由微积分基本定理有

$$\nabla f(x_k) = \nabla f(x_k) - \nabla f(x_*) = \int_0^1 \nabla^2 f(tx_k + (1-t)x_*)(x_k - x_*)\mathrm{d}t,$$

于是括号内部

$$\nabla^2 f(x_k)(x_k - x_*) - \nabla f(x_k) = (x_k - x_*)\int_0^1 \left(\nabla^2(x_k) - \nabla^2 f(tx_k + (1-t)x_*)\right)\mathrm{d}t.$$

假设

$$\|x_k - x_*\| < \min\left\{\frac{\sigma}{2L}, \delta\right\}$$

就有估计

$$\|x_{k+1} - x_*\| \leq \|\nabla^2 f(x_k))^{-1}\|_2\|x_k - x_*\|\int_0^1 \left\|\nabla^2(x_k) - \nabla^2 f(tx_k + (1-t)x_*)\right\|\mathrm{d}t,$$

于是根据 Lipschitz 条件

$$\|x_{k+1} - x_*\| \leq \frac{2L}{\sigma}\|x_k - x_*\|^2 < \|x_k - x_*\| < \min\left\{\frac{\sigma}{2L}, \delta\right\}.$$

因此只需取一开始的

$$\|x_0 - x_*\| < \min\left\{\frac{\sigma}{2L}, \delta\right\},$$

迭代就能递推地进行, 且 $\|x_k - x_*\|$ 单调下降, 误差

$$\frac{e_{k+1}}{e_k^2} \leq \frac{2L}{\sigma},$$

即收敛阶为 2.

另一方面同样由微积分基本定理

$$\nabla f(x_{k+1}) - \nabla f(x_k) = \nabla f(x_k + p_k) - \nabla f(x_k) = \int_0^1 \nabla^2 f(x_k + tp_k)p_k \mathrm{d}t,$$

根据

$$\nabla f(x_k) = -\nabla^2 f(x_k)p_k$$

可得

$$\nabla f(x_{k+1}) = \int_0^1 (\nabla^2 f(x_k + tp_k) - \nabla^2 f(x_k))p_k \mathrm{d}t,$$

于是有估计

$$\|\nabla f(x_{k+1})\| \leq \int_0^1 \|\nabla^2 f(x_k + tp_k) - \nabla^2 f(x_k)\|_2 \|p_k\| \mathrm{d}t \leq L\|p_k\|^2 \int_0^1 t \mathrm{d}t,$$

计算得

$$\|\nabla f(x_{k+1})\| \leq \frac{L}{2}\|\nabla^2 f(x_k)^{-1}\|_2^2 \|\nabla f(x_k)\|^2 \leq \frac{2L}{\sigma^2}\|\nabla f(x_k)\|^2,$$

即 $\|\nabla f(x_{k+1})\|$ 也是 2 阶收敛. □

注意条件中 Hessian 正定的条件实际上排除了最小值点 x_* 是重根的情况, 否则没有 2 阶的收敛速度.

Example 5.1. 考虑函数 $f(x) = x^4$ 的最小值点 x_* 是重根, 其 Hessian$\nabla^2 f(x) = 12x^2$ 在 0 处半正定, 因此不适用以上定理. 纯 Newton 法的迭代步

$$x_{k+1} = x_k - \frac{4x_k^3}{12x_k^2} = \frac{2}{3}x_k$$

显然只有线性收敛率. 再考虑

$$f(x) = x^2 + \cos x$$

由

$$f''(x) = 2 - \cos x \geq 1$$

可知 f 是 1-强凸函数. 如果初始值 $x_0 = 2\pi$ 离最小值点 $x = 0$ 较远, 则迭代步

$$x_1 = x_0 - f''(x_0)^{-1}f'(x_0) = 2\pi - \frac{4\pi}{2-1} = -2\pi,$$

$$x_2 = x_1 - f''(x_1)^{-1}f'(x_1) = -2\pi - \frac{-4\pi}{2-1} = 2\pi = x_0,$$

说明该迭代模式是循环的, 当然不收敛.

这种情况的产生可以认为是步长设置不合理, 因此可以重新选择步长. 注意到

$$\left(-(\nabla^2 f(x))^{-1}\nabla f(x)\right)^T \nabla f(x) = -\nabla f(x)^T(\nabla^2 f(x))^{-1}\nabla f(x) \le 0$$

因此是下降方向, 把 Newton 迭代步的方法应用于线搜索, 就得到阻尼 Newton 法.

Algorithm 5.2.(阻尼 Newton 法) 对一个迭代点 x_k, 取方向

$$p_k = -(\nabla^2 f(x_k))^{-1}\nabla f(x_k),$$

取步长 $\alpha = 1$, 通过回溯 $\alpha \to \alpha\rho$, 直到满足 Armijo 条件的 $\alpha_k = \alpha\rho^N$, 并取下一个迭代点

$$x_{k+1} = x_k + \alpha_k p_k,$$

得到的序列称为**阻尼 Newton 法 (damped Newton's method)**. 一般当

$$\lambda^2 = \nabla f(x_k)^T(\nabla^2 f(x_k))^{-1}\nabla f(x_k) \le 2\varepsilon$$

时停止.

下面我们考虑阻尼 Newton 法的收敛率.

Theorem 5.2.(阻尼 Newton 法的收敛率) 设 f 是开区域 $D \subseteq \mathbb{R}^n$ 上的光滑 m-强凸实值函数, ∇f 是 M-Lipschitz 的, $\nabla^2 f$ 是 L-Lipschitz 连续的. 设 $\{x_k\}$ 是阻尼 Newton 的迭代步, 则存在常数

$$\eta \in \left(0, \frac{m^2}{L}\right), \quad \gamma > 0,$$

使得当 $\|\nabla f(x_k)\| \ge \eta$ 时, 则迭代下降

$$f(x_{k+1}) - f(x_k) \le -\gamma.$$

当 $\|\nabla f(x_k)\| < \eta$ 时

$$\|\nabla f(x_{k+1})\| \le \left(\frac{L}{2m^2}\right)\|\nabla f(x_k)\|^2.$$

Proof. 设 Armijo 条件参数为 c, 回溯法中 α 每次下降 ρ, 我们证明

$$\tilde{\alpha} = \min\left\{1, \frac{2\beta(1-c)m}{M}\right\}, \quad 0 < \eta < \frac{m^2}{L}\min\{1, 3(1-2c)\}, \quad \gamma = \frac{c\tilde{\alpha}\eta^2}{M}$$

就是满足条件的参数. 不妨设 $\nabla f(x_k) \neq 0$, 否则已经收敛. 根据 M-Lipschitz 可知

$$\nabla f(x_k)^T(\nabla^2 f(x_k))^{-1}\nabla f(x_k) \geq \frac{1}{M}\|\nabla f(x)\|^2.$$

同样根据 m-强凸可知

$$\|\nabla f(x_k)\| = \|\nabla^2 f(x_k)p_k\| \geq m\|p_k\|,$$

以及

$$\nabla f(x_k)^T(\nabla^2 f(x_k))^{-1}\nabla f(x_k) = p_k^T\nabla^2 f(x_k)p_k \geq m\|p_k\|^2.$$

当 $\|\nabla f(x_k)\| \geq \eta$ 时, 根据 2 阶 Taylor 展开

$$f(x_k + \alpha_k p_k) = f(x_k) + \alpha_k \nabla f(x_k)^T p_k + \frac{\alpha_k^2}{2} p_k^T \nabla^2 f(x_k + \theta\alpha_k p_k)p_k,$$

利用 M-Lipschitz

$$f(x_k + \alpha_k p_k) \leq f(x_k) + \alpha_k \nabla f(x_k)^T p_k + \frac{\alpha_k^2}{2} M\|p_k\|^2.$$

当 $\alpha_k < \tilde{\alpha}$ 时, Armijo 条件

$$\alpha_k \leq \frac{2(1-c)m}{M} \leq \frac{2(1-c)(-\nabla f(x_k)^T p_k)}{M\|p_k\|^2},$$

代入即得 Armijo 条件

$$f(x_k + \alpha_k p_k) \leq f(x_k) + c\alpha_k \nabla f(x_k)^T p_k$$

满足, 于是回溯方法返回

$$\alpha_k > \tilde{\alpha} \implies f(x_k) - f(x_{k+1}) \geq c\alpha_k \nabla f(x_k)^T p_k \geq \frac{c\tilde{\alpha}}{M}\|\nabla f(x_k)\|^2 \geq \frac{c\tilde{\alpha}}{M}\eta^2 = \gamma.$$

当 $\|\nabla f(x_k)\| < \eta$ 时, 根据 Taylor 展开有

$$f(x_k + p_k) = f(x_k) + \nabla f(x_k)^T p_k + \int_0^1 (1-t)p_k^T \nabla^2 f(x_k + tp_k)p_k \mathrm{d}t,$$

其中 Hessian 可以拆分出 $\nabla^2 f(x_k)$, 另一部分是两项之差

$$\|\nabla^2 f(x_k + tp_k) - \nabla^2 f(x_k)\|_2 \leq L\|tp_k\|.$$

于是代入得到估计

$$f(x_k + p_k) \leq f(x_k) + \frac{1}{2}\nabla f(x_k)^T p_k + \frac{L}{6}\|p_k\|^3.$$

由于

$$\|\nabla f(x_k)\| < \eta < \frac{m^2}{L}\min\{1, 3(1-2c)\} \implies \frac{3(1-2c)m}{L} \geq \frac{\|\nabla f(x_k)\|}{m} \geq \|p_k\|,$$

于是

$$f(x_k + p_k) \leq f(x_k) + \frac{1}{2}\nabla f(x_k)^T p_k + \frac{L}{6}\|p_k\|^3 \leq f(x_k) - c\nabla f(x_k)^T(\nabla^2 f(x_k))^{-1}\nabla f(x_k)$$

满足 Armijo 条件, 因此 $\alpha_k = 1$, 从而后续是纯 Newton 法, 当然有 2 阶收敛. □

这说明当距离较远时, 阻尼 Newton 法是一个线性收敛, 发生有限次直到迭代点进入纯 Newton 法适用范围内之后, 变为 2 次收敛.

对函数在 x_* 附近凸, 但全局非凸的情况, 我们可以用 Hessian 修正的方法. 具体而言, 可以通过附加一个二次型的方式, 让局部变为凸函数, 且在 x_* 附近附加的二次型趋于 0.

Algorithm 5.3.(Hessian 修正 Newton 法) 对一个迭代点 x_k, 考虑 $\nabla^2 f(x_k)$, 添加一个 E_k 得到 $A_k = \nabla^2 f(x_k) + E_k$ 正定, 并取方向

$$p_k = -A_k^{-1}\nabla f(x_k)$$

以及初始步长 $\alpha = 1$, 减小步长直到满足 Wolfe 条件得到 α_k, 最后取下一个迭代点

$$x_{k+1} = x_k + \alpha_k p_k,$$

得到的序列称为 **Hessian 修正 Newton 法**. 常见的取法是 $E_k = \lambda_k I$ 为数乘阵.

5.2 拟 Newton 法

在 Newton 法中总是要求解方向

$$p_k = -(\nabla^2 f(x_k))^{-1}\nabla f(x_k),$$

但求解矩阵的逆总是非常耗费计算量, 因而一般都是求解方程组

$$\nabla^2 f(x_k)p_k = -\nabla f(x_k).$$

然而此方程一般也不便求解, 因此我们考虑用一个正定的近似矩阵代替 $\nabla^2 f(x_k)$.

如果取近似正定矩阵为 A_k, 当 $A_k = \nabla^2 f(x_k)$ 时

$$A_k p_k = -\nabla f(x_k) \iff A_k p_k + \nabla f(x_k) = 0.$$

因此对一般的近似 A_k, 可以用

$$r_k = A_k p_k + \nabla f(x_k)$$

衡量近似的误差.

Proposition 5.3. 设 f 是开区域 $D \subseteq \mathbb{R}^n$ 上的光滑实值函数, 如果考虑先确定方向 p_k 再对步长做 $\alpha = 1$ 的线搜索的迭代序列

$$x_{k+1} = x_k + \alpha_k p_k,$$

满足参数为 $0 < c_1 < \frac{1}{2}$, $c_1 < c_2 < 1$ 的 Wolfe 条件, 收敛到最小值点 x_*, 使得 $\nabla^2 f(x_*)$ 正定, 近似矩阵 A_k 收敛到 $\nabla^2 f(x_*)$, 满足

$$\lim_{k\to\infty} \frac{\|A_k p_k + \nabla f(x_k)\|}{\|p_k\|} = 0,$$

则当 k 充分大时, 最终步长总为 $\alpha_k = 1$, 且有超线性收敛

$$\lim_{k\to\infty} \frac{\|x_{k+1} - x_*\|}{\|x_k - x_*\|} = 0.$$

Proof. Omit. □

Chapter 6

26th Oct. Lecture 6 拟 Newton 法