

概率论讲义

minamomo

Monday 5th October, 2026

References:

- [1] A Course in Probability Theory(3rd edition), Kai Lai Chung, 2001.
- [2] Propability with Martingales, David Williams, 2014.
- [3] 概率论 (2nd edition), 韩东, 熊德文, 2022.
- [4] 概率论, 复旦大学, 1979.
- [5] Real Analysis(4th edition), Royden, 2020.
- [6] 应用随机过程, 韩东, 熊德文, 2023.

Marks:

1. 代数 $\mathcal{F}$, Borel 代数 $\mathcal{B}_n$, 测度 μ , 外测度 μ^* .
2. 概率空间 Ω , 概率 $\mathbb{P}$, 随机变量 X , 随机向量 $\mathbf{X}$, 分布函数 F , 密度函数 f , 期望 $\mathbb{E}$, 方差 Var , 协方差 Cov , 相关系数 ρ , 特征函数 $\psi(t)$.
3. 二项分布 $\text{Bi}(n, p)$, 几何分布 $\text{Ge}(p)$, 超几何分布 $\text{H}(n, M, N)$, Poisson 分布 $\text{Poi}(\lambda)$, 均匀分布 $U(a, b)$, 指数分布 $\text{Exp}(\lambda)$, Gamma 分布 $\Gamma(\alpha, \lambda)$, 正态分布 $N(\mu, \sigma^2)$.
4. 条件概率 $\mathbb{P}(A | B)$, 条件分布 $F(x | \mathbf{T} \in B)$, 条件密度 $f(x | \mathbf{T} = \mathbf{t}_0)$, 条件期望 $\mathbb{E}(X | \mathbf{T})$, 条件方差 $\text{Var}(X | \mathbf{T})$.
5. 独立同分布 i.i.d., 几乎处处 a.e./a.s., 依概率 pr., 依分布 dist.

1. 定义 **Definition**.
2. 定理 **Theorem**.
3. 例题 **Example**.
4. 习题 **Exercise**.

Preface

本讲义是原先概率论讲义的重制, 主要是引入了概率论的测度化定义.

概率论所研究对象是以各种形式给出的分布, 包括概率 P , 分布 F 以及密度 f , 连同分布的各种特征, 包括期望 $\mathbb{E}$, 方差 Var , 协方差 Cov 等.

minamomo

2026.9 于中国上海

This page intentionally left blank.

Contents

1	测度论	7
1.1	σ 环与 σ 代数	10
1.2	σ -代数上的测度	12
1.3	测度的 Caratheodory 理论 *	16
2	初等概率论	23
2.1	概率空间	25
2.2	随机变量与分布函数	27
2.3	随机向量与分布函数	37
2.4	随机变量的矩	43
2.5	条件概率	56
3	特征函数	65
3.1	特征函数	66
4	随机变量序列	71
4.1	随机变量序列的收敛	72
4.2	大数定律	75
4.3	中心极限定理	83
5	随机过程	91
5.1	随机游走	92
5.2	Poisson 过程	93
5.3	Markov 过程	99
5.4	鞅理论	99

This page intentionally left blank.

Chapter 1

测度论

本章基础知识

Theorem A.1.(De Morgan) 设 $A_k \subseteq X (k \in \mathbb{N}^*)$ 是一列子集, 则有

$$\bigcap_{k=1}^{\infty} A_k = X \setminus \bigcup_{k=1}^{\infty} (X \setminus A_k),$$
$$\bigcup_{k=1}^{\infty} A_k = X \setminus \bigcap_{k=1}^{\infty} (X \setminus A_k).$$

Proof. 设

$$x \in \bigcap_{k=1}^{\infty} A_k,$$

则对任意 $k \in \mathbb{N}^*$, 有 $x \in A_k$, 于是 $x \notin X \setminus A_k$, 则

$$x \notin \bigcup_{k=1}^{\infty} (X \setminus A_k),$$

此即

$$x \in X \setminus \bigcup_{k=1}^{\infty} (X \setminus A_k).$$

再设

$$x \in X \setminus \bigcup_{k=1}^{\infty} (X \setminus A_k),$$

则对任意 $k \in \mathbb{N}^*$, 有 $x \notin X \setminus A_k$, 则有 $x \in A_k$, 进而

$$x \in \bigcap_{k=1}^{\infty} A_k,$$

这就证明了

$$\bigcap_{k=1}^{\infty} A_k = X \setminus \bigcup_{k=1}^{\infty} (X \setminus A_k).$$

设

$$x \in \bigcup_{k=1}^{\infty} A_k,$$

则存在一个 $k_0 \in \mathbb{N}^*$, 使得 $x \in A_{k_0}$, 于是 $x \notin X \setminus A_{k_0}$, 则

$$x \notin \bigcap_{k=1}^{\infty} (X \setminus A_k),$$

此即

$$x \in X \setminus \bigcap_{k=1}^{\infty} (X \setminus A_k).$$

再设

$$x \in X \setminus \bigcap_{k=1}^{\infty} (X \setminus A_k),$$

则存在一个 $k_0 \in \mathbb{N}^*$, 使得 $x \notin X \setminus A_{k_0}$, 则有 $x \in A_{k_0}$, 进而

$$x \in \bigcup_{k=1}^{\infty} A_k$$

这就证明了

$$\bigcup_{k=1}^{\infty} A_k = X \setminus \bigcap_{k=1}^{\infty} (X \setminus A_k).$$

□

Theorem A.2. (ℝ 上开集的结构) 设 $G \subseteq \mathbb{R}$ 是开集, 则存在至多可数个不交开区间 $\{I_k\}_{k=1}^{\infty}$ 使得 G 是其并.

Proof. 对每个 $x \in G$, 可以构造其所在区间

$$I_x = (a_x, b_x) = (\inf\{a : (a, x) \subseteq G\}, \sup\{b : (x, b) \subseteq G\})$$

事实上, 依照定义易见 $I_x \subseteq G$, 而如果 $a_x \in G$, 则由 G 是开集可知存在邻域 $(a_x - r, a_x + r) \subseteq G$, 这就与定义的下确界矛盾, 因此 $a_x, b_x \notin G$. 现在收集

$$\mathcal{J} = \{I_x \subseteq \mathbb{R} : x \in G\},$$

则 $\mathcal{J}$ 的并恰好是 G , 且依照定义 I_x 和 I_y 只可能不交或相等. 最后只要证明可数性, 考虑 $\mathbb{Q}$ 的一个排序 $\{r_k\}_{k=1}^{\infty}$, 对每个 I_x 指定 $I_x \cap \mathbb{Q}$ 的最小下标, 给出了 $\mathcal{J}$ 到 $\mathbb{N}$ 的单射, 因此 $\mathcal{J}$ 可数. □

Definition A.1.(集合的单调性与单调极限) 设 $A_k \subseteq X (k \in \mathbb{N}^*)$ 是一列子集. 若 $A_k \subseteq A_{k+1}$ 对一切 $k \in \mathbb{N}^*$ 成立, 则称该集合列单调上升, 并称

$$\lim_{k \rightarrow \infty} A_k = \bigcup_{k=1}^{\infty} A_k$$

为该集合列的极限. 若 $A_k \supseteq A_{k+1}$ 对一切 $k \in \mathbb{N}^*$ 成立, 则称该集合列单调下降, 并称

$$\lim_{k \rightarrow \infty} A_k = \bigcap_{k=1}^{\infty} A_k$$

为该集合列的极限.

Definition A.2.(集合列的上下极限) 设 $A_k \subseteq X (k \in \mathbb{N}^*)$ 是一列子集. 定义这列子集的上极限

$$\limsup_{k \rightarrow \infty} A_k = \lim_{n \rightarrow \infty} \bigcup_{k=n}^{\infty} A_k = \bigcap_{n=1}^{\infty} \bigcup_{k=n}^{\infty} A_k$$

是所有无限次出现在 A_k 中的元素. 下极限

$$\liminf_{k \rightarrow \infty} A_k = \lim_{n \rightarrow \infty} \bigcap_{k=n}^{\infty} A_k = \bigcup_{n=1}^{\infty} \bigcap_{k=n}^{\infty} A_k$$

是所有仅不出现在有限个 A_k 中的元素.

Proposition A.3. 设 $A_k \subseteq X (k \in \mathbb{N}^*)$ 是一列子集, 则

$$\liminf_{k \rightarrow \infty} A_k \subseteq \limsup_{k \rightarrow \infty} A_k.$$

Proof. 任取

$$x \in \liminf_{k \rightarrow \infty} A_k,$$

则存在某个 $k_0 \in \mathbb{N}^*$, 使得 $x \in A_k$ 对一切 $k \geq k_0$ 都成立. 于是对任意 $n \in \mathbb{N}^*$ 有

$$x \in A_{\max\{k_0, n\}} \subseteq \bigcup_{k=n}^{\infty} A_k \implies x \in \bigcap_{n=1}^{\infty} \bigcup_{k=n}^{\infty} A_k = \limsup_{k \rightarrow \infty} A_k.$$

□

1.1 σ 环与 σ 代数

古典概率论处理离散的事件点, 且这些事件点互相排斥, 即两个事件点不会同时发生, 且所有事件点必有一个发生. 两个事件点 a, b “至少一个发生” 也是事件, 即事件 a 或 b ($a \vee b$). 从集合论的视角看, 一个事件被视为若干事件点的集合, 这些事件点任何一个发生都认为事件发生. 两个事件 A, B 至少一个发生, 是指所有的事件点至少一个发生, 即 $A \cup B$, 两个事件 A, B 同时发生, 是指至少一个同时出现在 A 和 B 的事件点发生, 即 $A \cap B$, 一个事件不发生, 则发生的事件点在 A 的补集中.

由此我们对古典概率论做一个定义. 古典概率论处理的对象是一个离散空间 Ω 及其上的子集族 $\mathcal{F}$, 使得 $\mathcal{F}$ 关于交集, 并集和补集封闭. 我们把这一性质抽象出来, 作为一般概率论中概率空间的基础.

Definition 1.1.1.(代数) 一个集合 X 上的**代数 (algebra)** 是 X 带有一个子集族 $\mathcal{F}$, 满足

1. (全集) $X \in \mathcal{F}$.
2. (补的封闭性) 若 $A \in \mathcal{F}$, 则 $X \setminus A \in \mathcal{F}$.
3. (并的封闭性) 若 $A_k \in \mathcal{F} (k = 1, 2, \dots, n)$, 则

$$\bigcup_{k=1}^n A_k \in \mathcal{F}.$$

注意根据**Theorem A.1**.取无穷个 $A_k = \emptyset$, 有

$$\bigcap_{k=1}^n A_k = X \setminus \bigcup_{k=1}^n (X \setminus A_k) \in \mathcal{F}.$$

之所以称之为代数, 一个原因是 $(\mathcal{F}, \Delta, \cap)$ 构成含么交换环. 首先 $\mathcal{F}$ 关于对称差 Δ 构成群, 单位元是空集 $\emptyset = X \setminus X \in \mathcal{F}$, 因为 $\emptyset \Delta \emptyset = \emptyset$, 任何集合 $A \in \mathcal{F}$ 的加法逆元是 A 自身, 因为 $A \Delta A = (A \setminus A) \Delta (A \setminus A) = \emptyset$. 其次 $\mathcal{F}$ 关于交集 $\cap$ 构成含么交换半群, 单位元是 X , 因为 $X \cap A = A$. 最后有分配律

$$(A \Delta B) \cap C = ((A \setminus B) \cap C) \cup ((B \setminus A) \cap C),$$

$$(A \cap C) \Delta (B \cap C) = ((A \cap C) \setminus (B \cap C)) \cup ((B \cap C) \setminus (A \cap C)),$$

而显然有

$$(A \setminus B) \cap C = (A \cap C) \setminus (B \cap C).$$

我们当然允许无穷个事件至少一个发生.

Definition 1.1.2. (σ -代数) 一个集合 X 上的 σ -代数是一个代数 $\mathcal{F}$, 满足并的封闭性, 即若 $A_k \in \mathcal{F} (k \in \mathbb{N}^*)$, 则

$$\bigcup_{k=1}^{\infty} A_k \in \mathcal{F}.$$

此时称 $(X, \mathcal{F})$ 是可测空间.

根据上述讨论我们知道 σ -代数对可数交, 可数并和补集封闭, 且包含空集和全集. 下面我们给出一种构造可测空间的方式.

Definition 1.1.3. (生成 σ -代数) 设 $\mathcal{C}$ 是 X 上的子集族, 考虑所有满足以下性质的集合 $\mathcal{F}$, 即包含 $\mathcal{C}$ 的 σ -代数.

1. $\mathcal{C} \subseteq \mathcal{F} \subseteq \mathcal{P}(X)$.
2. 若 $A \in \mathcal{F}$, 则 $X \setminus A \in \mathcal{F}$.
3. 若 $A_k \in \mathcal{F} (k \in \mathbb{N}^*)$, 则

$$\bigcup_{k=1}^{\infty} A_k \in \mathcal{F}.$$

这样的 $\mathcal{F}$ 存在, 例如 $\mathcal{P}(X)$, 于是可以取全体这样 $\mathcal{F}$ 的交, 即包含 $\mathcal{C}$ 的所有 σ -代数的最小者, 称为由 $\mathcal{C}$ 生成的 σ -代数.

在概率论中最重要的例子是 Borel 代数.

Example 1.1.1. (Borel 代数) 取 $\mathbb{R}^n$ 上的标准拓扑, 全体开集 $\mathcal{O}$ 作为子集族, 生成的 σ -代数称为 $\mathbb{R}^n$ 上的 Borel 代数, 记作 $\mathcal{B}_n$. 特别地, 对 $\mathbb{R}$ 的情形记作 $\mathcal{B}$. 根据 [Theorem A.2](#) 可知 $\mathcal{O}$ 恰好由全体开区间在并集下生成, 于是 $\mathbb{R}$ 上 Borel 集恰好包含了所有开集 (开区间), 其补集闭集 (闭区间), 以及两者的交半开半闭区间, 和开集, 闭集的可数交并.

1.2 σ -代数上的测度

我们说一个事件有发生的概率, 相当于为 $\mathcal{F}$ 中的元素指定了一个非负实数

$$\begin{aligned}\mathbb{P}: \mathcal{F} &\rightarrow \mathbb{R}_{\geq 0}, \\ A &\mapsto \mathbb{P}(A).\end{aligned}$$

特别地, 所有事件点一定有一个发生, 所以 $\mathbb{P}(\Omega) = 1$.

我们可以将这种指定看成对 $\mathcal{F}$ 中的元素, 即 X 子集的一个测量. 一个事件包含的事件点越多, 例如 $A \subseteq B$, 其发生的概率应该越大, 即有 $\mathbb{P}(A) \leq \mathbb{P}(B)$, 即 $\mathbb{P}$ 应该保持集合包含的偏序关系为实数的偏序关系. 另外两个不交的事件 $A \cap B = \emptyset$, 其概率应该简单相加

$$\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B).$$

由此发展出关于 $\mathbb{P}$ 的完整理论. 我们从一般的集合族上的函数说起.

Definition 1.2.1.(集函数) 设 $\mathcal{F}$ 是 X 上的一个集合族, $\bar{\mathbb{R}}$ 是扩充实数系, 其上带有自然的偏序关系, 特别地对任意实数 r , 有 $r < +\infty$. 其非负部分为 $\bar{\mathbb{R}}_{\geq 0} = [0, +\infty]$. 一个集函数就是指形如 $\mu: \mathcal{F} \rightarrow \bar{\mathbb{R}}_{\geq 0}$ 的映射.

若对任意单调上升的 $\mathcal{F}$ 中集合列 $\{A_k\}$, 都有

$$\mu\left(\lim_{k \rightarrow \infty} A_k\right) = \lim_{k \rightarrow \infty} \mu(A_k),$$

则称集函数 μ **连续 (continuous)**.

若对任意两两交为空的子集列 $A_k \in \mathcal{F} (k \in \mathbb{N}^*)$, 都有

$$\mu\left(\bigcup_{k=1}^n A_k\right) = \sum_{k=1}^n \mu(A_k),$$

则称 μ 满足**有限可加性 (finitely additivity)**. 若对任意两两交为空的子集列 $A_k \in \mathcal{F} (k \in \mathbb{N}^*)$, 都有

$$\mu\left(\bigcup_{k=1}^{\infty} A_k\right) = \sum_{k=1}^{\infty} \mu(A_k),$$

则称 μ 满足**可列可加性 (countably additivity)**.

我们希望 $\mathbb{P}$ 所满足的性质与 σ -代数相容, 从而应当能够进行可列可加. 以下命题说明了可列可加性的性质.

Proposition 1.2.1. 设 $\mathcal{F}$ 是 X 上的一个集合族, $\mu: \mathcal{F} \rightarrow [0, +\infty]$ 是集函数, 则 μ 满足可列可加性的充要条件是 μ 连续且满足有限可加性.

Proof. (必要性) 取 $A_k = \emptyset (k > n)$ 即可推出有限可加性. 设 $\mathcal{F}$ 中集合列 $\{A_k\}$ 单调上升, 则

$$\lim_{k \rightarrow \infty} A_k = \left(\bigcup_{k=1}^{\infty} (A_{k+1} \setminus A_k) \right) \cup A_1.$$

根据可列可加性, 有

$$\begin{aligned} \mu \left(\lim_{k \rightarrow \infty} A_k \right) &= \mu \left(\left(\bigcup_{k=1}^{\infty} (A_{k+1} \setminus A_k) \right) \cup A_1 \right) \\ &= \sum_{k=1}^{\infty} \mu(A_{k+1} \setminus A_k) + \mu(A_1) \\ &= \lim_{n \rightarrow \infty} \left(\sum_{k=1}^n \mu(A_{k+1} \setminus A_k) \right) + \mu(A_1) \\ &= \lim_{n \rightarrow \infty} \left(\sum_{k=1}^n \mu(A_{k+1}) - \sum_{k=1}^n \mu(A_k) + \mu(A_1) \right) \\ &= \lim_{n \rightarrow \infty} \mu(A_{n+1}) \\ &= \lim_{k \rightarrow \infty} \mu(A_k). \end{aligned}$$

(充分性) 任取一个无穷集合列 $\{A_k\}$, 使得对于任意 $i, j \in \mathbb{N}^*$, 满足 $i \neq j$, 都有 $A_i \cap A_j = \emptyset$. 定义

$$B_n = \bigcup_{k=1}^n A_k,$$

则 $\{B_n\}$ 是一列单调上升的集合列. 根据连续性有

$$\mu \left(\lim_{n \rightarrow \infty} B_n \right) = \lim_{n \rightarrow \infty} \mu(B_n).$$

从而根据有限可加性有

$$\mu \left(\bigcup_{k=1}^{\infty} A_k \right) = \mu \left(\lim_{n \rightarrow \infty} B_n \right) = \lim_{n \rightarrow \infty} \mu(B_n) = \lim_{n \rightarrow \infty} \mu \left(\bigcup_{k=1}^n A_k \right) = \lim_{n \rightarrow \infty} \sum_{k=1}^n \mu(A_k).$$

这就证明了可列可加性

$$\mu \left(\bigcup_{k=1}^{\infty} A_k \right) = \sum_{k=1}^{\infty} \mu(A_k).$$

□

现在我们描述 $\mathbb{P}$ 作为 Ω 上的集函数.

Definition 1.2.2. (预测度与测度) 设 $\mathcal{F}$ 是 X 上的代数, $\mu : \mathcal{F} \rightarrow [0, +\infty]$ 是集函数, 满足

1. (空集) $\mu(\emptyset) = 0$.

2. (可列可加性) 若 $A_k \in \mathcal{F} (k \in \mathbb{N}^*)$ 是一列子集, 满足对任意 $i, j \in \mathbb{N}^*$ 使得 $i \neq j$, 都有 $A_i \cap A_j = \emptyset$, 则

$$\mu \left(\bigcup_{k=1}^{\infty} A_k \right) = \sum_{k=1}^{\infty} \mu(A_k).$$

则称 μ 是 $\mathcal{F}$ 上的**预测度 (premeasure)**. 当 $\mathcal{F}$ 是 X 上的 σ -代数时, 称 μ 是 $\mathcal{F}$ 上的**测度 (measure)**.

现在我们说明这样定义的测度满足我们希望 $\mathbb{P}$ 具有的性质. 概率相加已经保证, 根据有限可加性, 若 $A \subseteq B$, 则

$$\mu(B) = \mu((B \setminus A) \cup A) = \mu(A) + \mu(B \setminus A) \geq \mu(A).$$

事实上, 单调性有如下推广.

Proposition 1.2.2.(可列次可加性) 设 $\mathcal{F}$ 是 X 上的 σ -代数, $\mu: \mathcal{F} \rightarrow [0, +\infty]$ 是测度. 若 $A_k \in \mathcal{F} (k \in \mathbb{N}^*)$ 是一列子集, 则

$$\mu \left(\bigcup_{k=1}^{\infty} A_k \right) \leq \sum_{k=1}^{\infty} \mu(A_k).$$

Proof. 定义

$$B_1 = A_1, \quad B_{n+1} = \left\{ x \in A_{n+1} \mid x \notin \bigcup_{k=1}^n A_k \right\}.$$

则任意两个 B_i, B_j 无交. 一方面显然有

$$B_n \subseteq \bigcup_{k=1}^{\infty} A_k \implies \bigcup_{n=1}^{\infty} B_n \subseteq \bigcup_{k=1}^{\infty} A_k.$$

另一方面, 设 x 在 A_k 的并集中, 则必在某些 A_k 中, 记下标最小者为 k_0 , 则 $x \in B_{k_0}$, 进而在 B_k 的并集中. 根据可列可加性

$$\mu \left(\bigcup_{k=1}^{\infty} A_k \right) = \mu \left(\bigcup_{n=1}^{\infty} B_n \right) = \sum_{n=1}^{\infty} \mu(B_n).$$

依照定义, $B_n \subseteq A_n$, 根据有限可加性和非负性

$$\mu(B_n) + \mu(A_n \setminus B_n) = \mu(A_n) \implies \mu(B_n) \leq \mu(A_n).$$

代入得

$$\mu \left(\bigcup_{n=1}^{\infty} A_n \right) = \sum_{n=1}^{\infty} \mu(B_n) \leq \sum_{n=1}^{\infty} \mu(A_n).$$

□

Example 1.2.1.(计数测度) 我们知道在集合上有容斥原理

$$\text{card}(A \cup B) = \text{card}(A) + \text{card}(B) - \text{card}(A \cap B).$$

对集合 X , 有 σ -代数 $\mathcal{P}(X)$, 则可以定义计数函数

$$\text{card} : \mathcal{F} \rightarrow \mathbb{N} \cup \{\infty\}.$$

容易验证这是 $\mathcal{P}(X)$ 上的测度.

1.3 测度的 Caratheodory 理论 *

在这一部分, 我们将说明如何在可测空间上构建一个测度. 首先, Caratheodory 理论说明测度可以由外测度得到.

Definition 1.3.1.(外测度) 设 X 是集合, $\mu^* : \mathcal{P}(X) \rightarrow [0, +\infty]$ 是集函数, 满足

1. (空集) $\mu^*(\emptyset) = 0$.
2. (单调性) 若 $A \subseteq B \subseteq X$, 则 $\mu^*(A) \leq \mu^*(B)$.
3. (可列次可加性) 若 $A_k \subseteq X (k \in \mathbb{N}^*)$ 是一列子集, 则

$$\mu^*\left(\bigcup_{k=1}^{\infty} A_k\right) \leq \sum_{k=1}^{\infty} \mu^*(A_k).$$

则称 μ^* 是 X 上的**外测度 (outer measure)**.

几乎任何集函数都可以诱导外测度.

Theorem 1.3.1.(诱导外测度) 设 X 上的子集族 $\mathcal{F} \subseteq \mathcal{P}(X)$ 包含 $\emptyset$ 和 X , 集函数 $\mu : \mathcal{F} \rightarrow [0, +\infty]$, 使得 $\mu(\emptyset) = 0$. 定义

$$\begin{aligned} \mu^* : \mathcal{P}(X) &\rightarrow [0, +\infty], \\ A &\mapsto \inf \left\{ \sum_{k=1}^{\infty} \mu(E_k) \mid A \subseteq \bigcup_{k=1}^{\infty} E_k, E_k \in \mathcal{F} \right\}. \end{aligned}$$

则这是一个外测度, 称为集函数 μ 诱导的外测度.

Proof. 注意到任意 $A \subseteq X$ 都被 X 覆盖, 故 μ^* 在 $\mathcal{P}(X)$ 上有定义. 我们验证外测度的三条性质.

1. (空集) 取所有 $E_k = \emptyset$ 即知 $\mu^*(\emptyset) = 0$.
2. (单调性) 设 $A \subseteq B \subseteq X$ 都能被可列个 E_k 覆盖, 则任意一个 B 的覆盖都能覆盖 A , 于是

$$B \subseteq \bigcup_{k=1}^{\infty} E_k \implies \mu^*(A) \leq \sum_{k=1}^{\infty} \mu(E_k).$$

取下确界即得 $\mu^*(A) \leq \mu^*(B)$.

3. (可列次可加性) 根据下确界的定义, 对任意 $\varepsilon > 0$, 存在 A_n 的覆盖 $\{E_{n,m}\}$, 使得

$$\sum_{m=1}^{\infty} \mu(E_{n,m}) < \mu^*(A_n) + \frac{\varepsilon}{2^n}.$$

对 n 求和, 可得

$$\sum_{n=1}^{\infty} \sum_{m=1}^{\infty} \mu(E_{n,m}) \leq \sum_{n=1}^{\infty} \mu^*(A_n) + \varepsilon.$$

注意这里不要求右边收敛, 发散时总是取等, 而收敛时根据极限的性质即知取严格不等号. 由于全部 $\{E_{n,m}\}$ 构成 A_n 并集的覆盖, 于是根据定义

$$\mu^*\left(\bigcup_{n=1}^{\infty} A_n\right) \leq \sum_{n=1}^{\infty} \sum_{m=1}^{\infty} \mu(E_{n,m}) \leq \sum_{n=1}^{\infty} \mu^*(A_n) + \varepsilon.$$

根据 ε 的任意性, 可知

$$\mu^*\left(\bigcup_{n=1}^{\infty} A_n\right) \leq \sum_{n=1}^{\infty} \mu^*(A_n).$$

□

Caratheory 理论通过切割描述可测性.

Definition 1.3.2.(可测集) 设 $\mu^* : \mathcal{P}(X) \rightarrow [0, +\infty]$ 是外测度, 定义集合 $A \subseteq X$ 是 μ^* -可测的 (μ^* -measurable) 当且仅当对任意 $E \subseteq X$, 有

$$\mu^*(E) = \mu^*(E \cap A) + \mu^*(E \cap (X \setminus A)).$$

外测度在可测集上的限制总是其上的测度.

Theorem 1.3.2.(Caratheodory) 设 $\mu^* : \mathcal{P}(X) \rightarrow [0, +\infty]$ 是外测度, 则所有 μ^* 可测集构成 σ -代数 $\mathcal{F}$, 且 μ^* 在其上的限制是其上的测度.

Proof. 我们验证 $\mathcal{F}$ 满足 σ -代数的性质.

1. (全集) 显然有

$$\mu^*(E \cap X) + \mu^*(E \cap (X \setminus X)) = \mu^*(E) + \mu^*(\emptyset) = \mu^*(E).$$

2. (补的封闭性) 设 $A \in \mathcal{F}$, 则对任意 $E \subseteq X$, 有

$$\mu^*(E) = \mu^*(E \cap A) + \mu^*(E \cap (X \setminus A)).$$

进而

$$\mu^*(E) = \mu^*(E \cap (X \setminus (X \setminus A))) + \mu^*(E \cap (X \setminus A))$$

表明 $X \setminus E \in \mathcal{F}$.

3. (并的封闭性) 先证明有限并. 设 $A, B \in \mathcal{F}$, 对任意 $E \subseteq X$, 有

$$\begin{aligned}
 & \mu^*(E \cap (A \cup B)) + \mu^*(E \cap (X \setminus (A \cup B))) \\
 &= \mu^*(E \cap (A \cup B) \cap A) + \mu^*(E \cap (A \cup B) \cap (X \setminus A)) + \mu^*(E \cap (X \setminus (A \cup B))) \\
 &= \mu^*(E \cap A) + \mu^*(E \cap B \cap (X \setminus A)) + \mu^*(E \cap (X \setminus A) \cap (X \setminus B)) \\
 &= \mu^*(E \cap A) + \mu^*(E \cap (X \setminus A)) \\
 &= \mu^*(E).
 \end{aligned}$$

特别地, 当 $A \cap B = \emptyset$ 时, 有

$$\begin{aligned}
 \mu^*(E \cap (A \cup B)) &= \mu^*(E \cap (A \cup B) \cap A) + \mu^*(E \cap (A \cup B) \cap (X \setminus A)) \\
 &= \mu^*(E \cap A) + \mu^*(E \cap B).
 \end{aligned}$$

再证明可列并. 设 $A_k \in \mathcal{F} (k \in \mathbb{N}^*)$ 是一列集合, 定义

$$B_1 = A_1, \quad B_{n+1} = \left\{ x \in A_{n+1} \mid x \notin \bigcup_{k=1}^n A_k \right\} = A_{n+1} \cap \left(X \setminus \bigcup_{k=1}^n A_k \right).$$

根据有限并的封闭性, $B_n \in \mathcal{F}$. 显然任意两个 B_i, B_j 无交, 且

$$\bigcup_{n=1}^{\infty} B_n = \bigcup_{n=1}^{\infty} A_n.$$

归纳可得对任意 $E \subseteq X$, 有

$$\mu^* \left(E \cap \left(\bigcup_{k=1}^n B_k \right) \right) = \sum_{k=1}^n \mu^*(E \cap B_k).$$

进而根据有限并的封闭性和外测度的单调性

$$\begin{aligned}
 \mu^*(E) &= \mu^* \left(E \cap \left(\bigcup_{k=1}^n B_k \right) \right) + \mu^* \left(E \cap \left(X \setminus \bigcup_{k=1}^n B_k \right) \right) \\
 &= \sum_{k=1}^n \mu^*(E \cap B_k) + \mu^* \left(E \cap \left(\bigcap_{k=1}^n X \setminus B_k \right) \right) \\
 &\geq \sum_{k=1}^n \mu^*(E \cap B_k) + \mu^* \left(E \cap \left(\bigcap_{k=1}^{\infty} X \setminus B_k \right) \right)
 \end{aligned}$$

取极限并由外测度的可列次可加性有

$$\begin{aligned}
 \mu^*(E) &\geq \sum_{n=1}^{\infty} \mu^*(E \cap B_n) + \mu^* \left(E \cap \left(\bigcap_{n=1}^{\infty} X \setminus B_n \right) \right) \\
 &\geq \mu^* \left(E \cap \left(\bigcup_{n=1}^{\infty} B_n \right) \right) + \mu^* \left(E \cap \left(\bigcap_{n=1}^{\infty} X \setminus B_n \right) \right) \\
 &\geq \mu^* \left(E \cap \left(\left(\bigcup_{n=1}^{\infty} B_n \right) \cup \left(\bigcap_{n=1}^{\infty} X \setminus B_n \right) \right) \right) \\
 &= \mu^*(E)
 \end{aligned}$$

即得

$$\mu^*(E) = \mu^*\left(E \cap \left(\bigcup_{n=1}^{\infty} B_n\right)\right) + \mu^*\left(E \cap \left(\bigcap_{n=1}^{\infty} X \setminus B_n\right)\right),$$

这就说明了

$$\bigcup_{n=1}^{\infty} A_n = \bigcup_{n=1}^{\infty} B_n \in \mathcal{F}.$$

为证 μ^* 是 $\mathcal{F}$ 上的测度, 只要证明可列可加性. 若 $A_k \in \mathcal{F} (k \in \mathbb{N}^*)$ 是一列子集, 满足对任意 $i, j \in \mathbb{N}^*$ 使得 $i \neq j$, 都有 $A_i \cap A_j = \emptyset$, 则取定义中

$$E = \bigcup_{k=1}^{\infty} A_k \subseteq X, \quad A = \bigcup_{k=1}^n A_k$$

有

$$\mu^*\left(\bigcup_{k=1}^{\infty} A_k\right) \geq \mu^*\left(\bigcup_{k=1}^n A_k\right) = \sum_{k=1}^n \mu^*(A_k).$$

取极限即得

$$\mu^*\left(\bigcup_{n=1}^{\infty} A_n\right) \geq \sum_{n=1}^{\infty} \mu^*(A_n).$$

结合可列次可加性即得可列可加性. $\square$

既然集函数可以扩张为外测度, 外测度又可以限制出测度, 那么限制出的测度和原来的集函数是否一致? 这就需要原来的集函数本身是一个预测度.

Theorem 1.3.3.(Caratheodory 测度扩张/延拓定理) 设 $\mathcal{E}$ 是 X 上的代数, $\mu: \mathcal{F} \rightarrow [0, +\infty]$ 是一个预测度, 则其诱导的外测度 $\mu^*: \mathcal{P}(X) \rightarrow [0, +\infty]$ 是 $\mathcal{E}$ 的生成 σ -代数 $\mathcal{F}$ 上的测度. 如果 μ 的取值不含 $+\infty$, 则 $\mu^*|_{\mathcal{F}}$ 是唯一在 $\mathcal{E}$ 上与 μ 相同的测度.

Proof. 根据 **Theorem 1.3.2.**, 诱导的外测度自身的可测集是 σ -代数. 如果 $\mathcal{E}$ 的所有元素都是 μ^* 可测的, 从而是 μ^* 可测集, 则 $\mathcal{E}$ 的生成 σ -代数 $\mathcal{F}$ 必然包含于 μ^* 可测集生成的 σ -代数, 从而 μ^* 是 $\mathcal{F}$ 上的测度. 因此我们只要证明 $\mathcal{E}$ 的所有元素都是 μ^* 可测的. 任取 $A \in \mathcal{E}$, 对任意的 $E \subseteq X$, 依照 μ^* 的下确界定义, 对任意 $\varepsilon > 0$, 存在一系列集合 $\{E_k\} \subseteq \mathcal{E}$ 覆盖 E , 使得

$$\sum_{k=1}^{\infty} \mu(E_k) \leq \mu^*(E) + \varepsilon.$$

根据 μ 作为预测度的可列可加性, 有

$$\sum_{k=1}^{\infty} \mu(E_k) = \sum_{k=1}^{\infty} \mu(E_k \cap A) + \sum_{k=1}^{\infty} \mu(E_k \cap (X \setminus A)).$$

根据 μ^* 的定义, 由于 $\{E_k\}$ 覆盖 E , $\{E_k \cap A\}$ 覆盖 $E \cap A$ 且 $\{E_k \cap (X \setminus A)\}$ 覆盖 $E \cap (X \setminus A)$, 于是

$$\sum_{k=1}^{\infty} \mu(E_k) \geq \mu^*(E \cap A) + \mu^*(E \cap (X \setminus A)).$$

另一方面, $E \cap A$ 和 $E \cap (X \setminus A)$ 覆盖 E , 故有可列次可加性

$$\mu^*(E) + \varepsilon \geq \sum_{k=1}^{\infty} \mu(E_k) \geq \mu^*(E \cap A) + \mu^*(E \cap (X \setminus A)) \geq \mu^*(E).$$

由 ε 的任意性, 上式不等号全部取等, 从而

$$\mu^*(E) = \mu^*(E \cap A) + \mu^*(E \cap (X \setminus A)),$$

这就说明 A 是可测集, 从而 μ^* 是 $\mathcal{F}$ 上的测度.

再证明 μ^* 在 $\mathcal{E}$ 上与 μ 相同. 任取 $A \in \mathcal{E}$, 由于 A 覆盖自身, 由定义

$$\mu^*(A) \leq \mu(A).$$

现在任取一列 $\mathcal{F}$ 中覆盖 A 的集合 $\{E_k\}$, 令

$$F_1 = E_1, \quad F_{n+1} = A \cap \left(E_{n+1} \setminus \bigcup_{k=1}^n E_k \right) \subseteq E_{n+1}.$$

由于这只涉及到补和有限并, 从而在代数 $\mathcal{E}$ 中, 于是根据 μ 作为预测度的可列可加性, 有

$$\mu(A) = \sum_{n=1}^{\infty} \mu(F_n) \leq \sum_{k=1}^{\infty} \mu(E_k).$$

对这样的集合列 $\{E_k\}$ 取下确界, 即得

$$\mu(A) \leq \mu^*(A),$$

这就说明 μ 与 μ^* 在 $\mathcal{E}$ 上相等.

最后假设还有一个测度 $\nu: \mathcal{F} \rightarrow [0, +\infty]$, 使得其在 $\mathcal{E}$ 上与 μ 相等. 任取 $A \in \mathcal{F}$, 对任意一个覆盖 A 的 $\mathcal{E}$ 中集合列 $\{E_k\}$, 根据 ν 作为测度的单调性和可列可加性, 有

$$\nu(A) \leq \sum_{k=1}^{\infty} \nu(E_k) = \sum_{k=1}^{\infty} \mu(E_k).$$

对这样的集合列 $\{E_k\}$ 取下确界, 即得

$$\nu(A) \leq \mu^*(A).$$

同理可得, 对任意 $E \in \mathcal{F}$, 都有 $\nu(E \setminus A) \leq \mu^*(E \setminus A)$. 反之, 对任意 $\varepsilon > 0$, 存在一个覆盖 A 的 $\mathcal{F}$ 中集合列 $\{E_k\}$, 满足

$$\sum_{k=1}^{\infty} \mu(E_k) \leq \mu^*(A) + \varepsilon.$$

定义

$$E_0 = \bigcup_{k=1}^{\infty} E_k, \quad G_n = \bigcup_{k=1}^n E_k,$$

由于 G_n 只涉及到补和有限并, 从而 $G_n \in \mathcal{E}$, 而 E_0 在 $\mathcal{E}$ 的生成 σ -代数 $\mathcal{F}$ 中, 因而有 $\nu(E_0 \setminus A) \leq \mu^*(E_0 \setminus A)$. 根据 μ^* 在 $\mathcal{E}$ 上的限制为 μ 以及作为外测度的可列次可加性, 有

$$\sum_{k=1}^{\infty} \mu(E_k) = \sum_{k=1}^{\infty} \mu^*(E_k) \geq \mu^*(E_0).$$

当 μ 值域不含 $+\infty$ 时, 根据 μ^* 作为 $\mathcal{F}$ 上测度的可列可加性, 有

$$\mu^*(E_0 \setminus A) = \mu^*(E_0) - \mu^*(A) \leq \varepsilon.$$

于是

$$\nu(E_0) = \nu(A) + \nu(E_0 \setminus A) \leq \nu(A) + \mu^*(E_0 \setminus A) \leq \nu(A) + \varepsilon.$$

注意到 $G_n \in \mathcal{E}$ 单调上升到 E_0 , 根据测度的连续性

$$\mu^*(E_0) = \lim_{n \rightarrow \infty} \mu^*(G_n) = \lim_{n \rightarrow \infty} \nu(G_n) = \nu(E_0),$$

即得

$$\mu^*(A) \leq \mu^*(E_0) = \nu(E_0) \leq \nu(A) + \varepsilon.$$

根据 ε 的任意性即知

$$\mu^*(A) \leq \nu(A),$$

于是 $\nu = \mu^*$ 在 $\sigma(\mathcal{F})$ 上恒成立, 即 μ^* 是唯一的. □

Example 1.3.1.(Borel 测度) 取 $\mathbb{R}^n$ 上的标准拓扑, 定义方体

$$\mathcal{R}(a, b) = \{(x_1, x_2, \dots, x_n) \in \mathbb{R}^n \mid a_k < x_k < b_k, \forall 1 \leq k \leq n\}, \quad a_k < b_k, \forall 1 \leq k \leq n$$

的预测度

$$m(\mathcal{R}(a, b)) = \text{vol}(\mathcal{R}(a, b)) = \prod_{k=1}^n (b_k - a_k).$$

由此扩展到 Borel 代数 $\mathcal{B}_n$ 上, 并通过 Caratheodory 延拓为外测度 m^* , 这就是 Lebesgue 外测度, 再限制为 m^* 可测集上的测度. 当然 Borel 代数是 σ -代数, 因此限制在 $\mathcal{B}$ 上恰好是测度 m , 称为 Borel 测度.

Chapter 2

初等概率论

本章基础知识

Theorem B.1.(Borel-Cantelli) 设 $E_k \subseteq \mathbb{R}$ 可测且测度的级数和收敛, 则几乎处处的 $x \in \mathbb{R}$ 落在至多有限个 E_k 中, 即

$$m\left(\limsup_{k \rightarrow \infty} E_k\right) = 0.$$

Proof. 此时每个 E_k 有限可测, 根据单调下降情形的测度的连续性

$$m\left(\limsup_{k \rightarrow \infty} E_k\right) = m\left(\bigcap_{n=1}^{\infty} \bigcup_{k=n}^{\infty} E_k\right) = \lim_{n \rightarrow \infty} m\left(\bigcup_{k=n}^{\infty} E_k\right) \leq \lim_{n \rightarrow \infty} \sum_{k=n}^{\infty} m(E_k).$$

根据级数收敛可知余项趋于 0. □

Theorem B.2.(单调收敛定理)

Theorem B.3.(有界收敛定理)

Theorem B.4.(Fubini)

Theorem B.5.(Tonelli)

Theorem B.6.(Cauchy-Schwarz)

Theorem B.7.(Hahn 分解定理)**Theorem B.8.(Radon-Nikodym)****Theorem B.9.(Gamma 函数)** Gamma 函数

$$\Gamma(s) = \int_0^{+\infty} x^{s-1} e^{-x} dx, \quad s > 0$$

满足 $\Gamma(s+1) = s\Gamma(s)$. 特别地, 在正整数 $n \in \mathbb{N}^*$ 上取值为 $\Gamma(n) = (n-1)!$.

Proof. 利用分部积分

$$\Gamma(s+1) = - \int_0^{+\infty} x^s de^{-x} = s \int_0^{+\infty} e^{-x} x^{s-1} dx - x^s e^{-x} \Big|_0^{+\infty} = s\Gamma(s).$$

特别地

$$\Gamma(1) = \int_0^{+\infty} e^{-x} dx = -e^{-x} \Big|_0^{+\infty} = 1,$$

归纳可知 $\Gamma(n) = (n-1)!$. □

Theorem B.10.(Beta 函数) Beta 函数

$$B(\alpha, \beta) = \int_0^1 x^{\alpha-1} (1-x)^{\beta-1} dx, \quad \alpha, \beta > 0$$

满足

$$B(\alpha, \beta) = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha+\beta)}.$$

Proof. 注意到对任意常数 $y > 0$, 有

$$\Gamma(\alpha) = \int_0^{+\infty} (xy)^{\alpha-1} e^{-xy} d(xy) = y^\alpha \int_0^{+\infty} x^{\alpha-1} e^{-xy} dx.$$

作换元 $x = \frac{y}{1+y}$ 可得

$$B(\alpha, \beta) = \int_0^{+\infty} \left(\frac{y}{1+y} \right)^{\alpha-1} \left(1 - \left(\frac{y}{1+y} \right) \right)^{\beta-1} d\left(\frac{y}{1+y} \right) = \int_0^{+\infty} \frac{y^{\alpha-1}}{(1+y)^{\alpha+\beta}} dy.$$

于是

$$B(\alpha, \beta)\Gamma(\alpha+\beta) = \int_0^{+\infty} \int_0^{+\infty} y^{\alpha-1} x^{\alpha+\beta-1} e^{-x(1+y)} dx dy.$$

先对 y 积分得

$$\int_0^{+\infty} y^{\alpha-1} e^{-xy} dy = x^{-\alpha} \Gamma(\alpha),$$

于是

$$B(\alpha, \beta)\Gamma(\alpha+\beta) = \Gamma(\alpha) \int_0^{+\infty} x^{\beta-1} e^{-x} dx = \Gamma(\alpha)\Gamma(\beta).$$

□

2.1 概率空间

根据上一节的讨论, 我们可以把概率 $\mathbb{P}$ 视为一个特殊的测度, 使得在全空间上的取值为 1, 这就是一般概率空间的定义.

Definition 2.1.1(概率空间) 设 Ω 是集合, $\mathcal{F}$ 是 Ω 上的 σ -代数, $\mathbb{P}$ 是 $\mathcal{F}$ 上的测度, 满足 $\mathbb{P}(\Omega) = 1$, 则称 $\mathbb{P}$ 是 $\mathcal{F}$ 上的**概率 (probability)**, $(\Omega, \mathcal{F}, \mathbb{P})$ 称为**概率空间 (probability space)**.

给定可测空间 $(\Omega, \mathcal{F})$, 根据定义, 集函数 $\mu: \mathcal{F} \rightarrow [0, +\infty]$ 是概率当且仅当满足

1. (非负性) 对任意 $A \in \mathcal{F}$, 有 $\mu(A) \geq 0$.
2. (归一性) $\mu(\emptyset) = 0, \mu(\Omega) = 1$.
3. (可列可加性) 若 $A_k \in \mathcal{F} (k \in \mathbb{N}^*)$ 是一列子集, 满足对任意 $i, j \in \mathbb{N}^*$ 使得 $i \neq j$, 都有 $A_i \cap A_j = \emptyset$, 则

$$\mu\left(\bigcup_{k=1}^{\infty} A_k\right) = \sum_{k=1}^{\infty} \mu(A_k).$$

利用可列可加性容易得到

$$\mathbb{P}(\Omega \setminus A) = \mathbb{P}(\Omega) - \mathbb{P}(A) = 1 - \mathbb{P}(A).$$

下面我们证明一些概率空间的基本性质.

Proposition 2.1.1.(加法公式) 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, $A_k \in \mathcal{F}$, 则有

$$\mathbb{P}\left(\bigcup_{k=1}^n A_k\right) = \sum_{k=1}^n (-1)^{k-1} \left(\sum_{1 \leq i_1 < i_2 < \dots < i_k \leq n} \mathbb{P}\left(\bigcap_{j=1}^k A_{i_j}\right) \right).$$

特别地, 对 $A, B \in \mathcal{F}$, 有容斥原理

$$\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B).$$

Proof. 对 n 归纳证明. 当 $n = 2$ 时有

$$\begin{aligned} \mathbb{P}(A \cup B) &= \mathbb{P}((A \setminus A \cap B) \cup (B \setminus A \cap B) \cup (A \cap B)) \\ &= \mathbb{P}(A \setminus A \cap B) + \mathbb{P}(B \setminus A \cap B) + \mathbb{P}(A \cap B) \\ &= \mathbb{P}((A \setminus A \cap B) \cup (A \cap B)) + \mathbb{P}((B \setminus A \cap B) \cup (A \cap B)) - \mathbb{P}(A \cap B) \\ &= \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B). \end{aligned}$$

现在假设对 $n = m$ 成立, 则对 $n = m + 1$, 可以把

$$\sum_{k=1}^{m+1} (-1)^{k-1} \left(\sum_{1 \leq i_1 < i_2 < \dots < i_k \leq m+1} \mathbb{P} \left(\bigcap_{j=1}^k A_{i_j} \right) \right)$$

拆成两部分, 当 $k = 1$ 时, 即

$$\sum_{1 \leq i \leq m+1} \mathbb{P}(A_i) = \sum_{i=1}^{m+1} \mathbb{P}(A_i).$$

对 $2 \leq k \leq m + 1$, 再拆成两项, 当 $i_k = m + 1$ 时为

$$\sum_{k=2}^{m+1} (-1)^{k-1} \left(\sum_{1 \leq i_1 < i_2 < \dots < i_{k-1} \leq m} \mathbb{P} \left(\bigcap_{j=1}^{k-1} A_{i_j} \cap A_{m+1} \right) \right).$$

以 k 代替 $k - 1$, 运用归纳假设即得

$$- \sum_{k=1}^m (-1)^{k-1} \left(\sum_{1 \leq i_1 < i_2 < \dots < i_k \leq m} \mathbb{P} \left(\bigcap_{j=1}^k A_{i_j} \cap A_{m+1} \right) \right) = -\mathbb{P} \left(\bigcup_{k=1}^m A_k \cap A_{m+1} \right).$$

当 $i_k \leq m$ 时, k 不可能再取 $m + 1$, 从而为

$$\sum_{k=2}^m (-1)^{k-1} \left(\sum_{1 \leq i_1 < i_2 < \dots < i_k \leq m} \mathbb{P} \left(\bigcap_{j=1}^k A_{i_j} \right) \right).$$

补上 $k = 1$ 的项即得

$$\mathbb{P} \left(\bigcup_{k=1}^m A_k \right) - \sum_{i=1}^m \mathbb{P}(A_i).$$

于是原式化为

$$\mathbb{P} \left(\bigcup_{k=1}^m A_k \right) + \mathbb{P}(A_{m+1}) - \mathbb{P} \left(\bigcup_{k=1}^m A_k \cap A_{m+1} \right).$$

利用 [Theorem A.1](#) 和 $n = 2$ 的情形即得

$$\sum_{k=1}^{m+1} (-1)^{k-1} \left(\sum_{1 \leq i_1 < i_2 < \dots < i_k \leq m+1} \mathbb{P} \left(\bigcap_{j=1}^k A_{i_j} \right) \right) = \mathbb{P} \left(\bigcup_{k=1}^{m+1} A_k \right).$$

归纳即证. □

2.2 随机变量与分布函数

现在我们要描述一个事件, 并对其求概率, 都是通过取定 $A \in \mathcal{F}$, 计算 $\mathbb{P}(A)$ 的形式. 这种离散定义的方式往往是不便研究的, 例如当 $\Omega = \mathbb{R}$ 而 $\mathcal{F} = \mathcal{B}$ 时, $\mathbb{P}$ 就是对 $\mathcal{B}$ 逐元素定义的, 这不会具有很好的性质以供研究.

另一种情形下, 考虑从 $n = a + b$ 个白球和黑球混合的箱子中摸 m 个球, 白球的个数为 t 的概率, 则概率空间 Ω 是所有可能的摸出 m 个球的情况, 而 $\mathcal{F} = \mathcal{P}(\Omega)$. 我们需要取 $\mathcal{F}$ 中的一个集合 A , 由所有白球个数为 t 的元素构成. 每更改一次 t 的值, 都会完全改变 A 的组成.

我们需要一种统一的方式来描述一类相似的事件, 因为其他的事件往往不在我们考虑的范围内, 使得在这一类事件上的概率具有一些良好的性质. 一个想法是设定一个函数 $X : \Omega \rightarrow \mathbb{R}$, 使得 $X^{-1}(t)$ 恰好是我们想要的 $\mathcal{F}$ 中元素.

Definition 2.2.1.(随机变量) 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间. 若函数 $X : \Omega \rightarrow \mathbb{R}$ 满足对任意 Borel 集 $B \in \mathcal{B}$, 都有

$$\{\omega \in \Omega \mid X(\omega) \in B\} \in \mathcal{F},$$

则称 X 是一个**随机变量 (random variable, r.v.)**.

有趣的是, 随机变量既不随机 (是一个确定的对应关系), 也不是变量 (是一个映射), 之所以称之为随机变量, 是因为 $X^{-1}(t)$ 是若干互斥的事件点 $\omega \in \Omega$, 我们不知道究竟是其中哪个事件点发生导致 X 取值为 t .

需要注意的是, $\mathcal{F}$ 作为一个离散的集合, 不可能由单个随机变量 X 完全刻画其信息. 例如取 $\mathcal{F} = \mathcal{B}_2$, 但 $\mathbb{R}^2$ 到 $\mathbb{R}$ 不存在保持拓扑结构的一一对应, 因此单个随机变量 X 必然会导致有些 $\mathcal{B}_2$ 中元素的像不是 $\mathcal{B}$ 中元素.

随机变量刻画了 Ω 与 $\mathbb{R}$ 的对应关系, 这种对应关系可以用一个单调实值函数编码.

Definition 2.2.2.(分布函数) 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, X 是其上的一个随机变量. 定义

$$F(x) = \mathbb{P}(X \leq x) = \mathbb{P}(\{\omega \in \Omega \mid X(\omega) \leq x\})$$

为 X 的**概率分布函数 (distribution function, d.f.)**.

现在说明分布函数的若干性质.

Proposition 2.2.1.(分布函数的性质) 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, X 是其上的一个随机变量, 则 X 的概率分布函数 $F(x)$ 满足

1. (单调性) 任意 $x < y$ 都有 $F(x) \leq F(y)$.

2. (右连续) $F(x)$ 在任一点处右连续, 即

$$\lim_{x \rightarrow x_0^+} F(x) = F(x_0),$$

3. (左极限) $F(x)$ 在任一点处左极限存在

$$\lim_{x \rightarrow x_0^-} F(x) = \mathbb{P}(X < x) = \mathbb{P}(\{\omega \in \Omega \mid X(\omega) < x\}).$$

4. 在无穷远处

$$\lim_{x \rightarrow -\infty} F(x) = 0, \quad \lim_{x \rightarrow +\infty} F(x) = 1.$$

Proof.

1. 注意到

$$x < y \implies \{\omega \in \Omega \mid X(\omega) \leq x\} \subseteq \{\omega \in \Omega \mid X(\omega) \leq y\},$$

即知 $F(x) \leq F(y)$.

2. 首先 x_0 处右连续即对于任意 $\varepsilon > 0$, 存在一个 $x(\varepsilon) > x_0$, 使得 $x_0 < x < x(\varepsilon)$ 时有 $|F(x) - F(x_0)| < \varepsilon$. 由于 F 单调上升, 这当且仅当 $F(x(\varepsilon)) - F(x_0) < \varepsilon$. 这恰好是下确界的定义

$$\lim_{x \rightarrow x_0^+} F(x) = \inf_{x > x_0} \{F(x)\}.$$

现在根据确界原理右式有定义, 根据下确界的定义, 存在一列 $\{x_k\}$ 单调下降趋于 x_0 , 使得

$$\inf_{x > x_0} \{F(x)\} = \lim_{k \rightarrow \infty} F(x_k) = \lim_{k \rightarrow \infty} \mathbb{P}(X \leq x_k) = \mathbb{P}\left(\bigcap_{k=1}^{\infty} \{\omega \in \Omega \mid X(\omega) \leq x_k\}\right).$$

利用极限的性质显然有

$$\bigcap_{k=1}^{\infty} \{\omega \in \Omega \mid X(\omega) \leq x_k\} = \{\omega \in \Omega \mid X(\omega) \leq x_0\},$$

即得

$$\lim_{x \rightarrow x_0^+} F(x) = F(x_0).$$

3. 类似地, 根据 $F(x)$ 在 $(-\infty, x_0)$ 上单调有界, 可知左极限存在. 任取 $\{x_k\}$ 单调上升趋于 x_0 , 有

$$\lim_{x \rightarrow x_0^-} F(x) = \mathbb{P}\left(\bigcup_{k=1}^{\infty} \{\omega \in \Omega \mid X(\omega) \leq x_k\}\right) = P(\{\omega \in \Omega \mid X(\omega) < x\}).$$

4. 任取 $\{x_k\}$ 单调下降趋于 $-\infty$, 有

$$\lim_{x \rightarrow -\infty} F(x) = \mathbb{P} \left(\bigcap_{k=1}^{\infty} \{\omega \in \Omega \mid X(\omega) \leq x_k\} \right) = \mathbb{P}(\emptyset) = 0.$$

任取 $\{x_k\}$ 单调上升趋于 $+\infty$, 有

$$\lim_{x \rightarrow +\infty} F(x) = \mathbb{P} \left(\bigcup_{k=1}^{\infty} \{\omega \in \Omega \mid X(\omega) \leq x_k\} \right) = P(\Omega) = 1.$$

□

既然分布函数可以编码随机变量, 我们当然希望随机变量可以通过分布函数解码得到. 但是要注意, 分布函数是 $\mathbb{R}$ 上的实值函数, 失去了概率空间的信息, 因此解码得到的随机变量只能是在概率空间同构意义下唯一的. 这里我们不详细解释概率空间同构的意义, 而只给出存在性的证明.

Theorem 2.2.2.(Lebesgue-Stieljes) 设 $F : \mathbb{R} \rightarrow \mathbb{R}$ 单调上升, 在任意一点处右连续且左极限存在, 满足

$$\lim_{x \rightarrow -\infty} F(x) = 0, \quad \lim_{x \rightarrow +\infty} F(x) = 1,$$

则存在概率空间 $(\mathbb{R}, \mathcal{B}, \mathbb{P})$ 以及其上的随机变量 X , 使得 $F(x)$ 是 X 的概率分布函数.

Proof. 取概率空间 $\Omega = \mathbb{R}$, 事件域 $\mathcal{F} = \mathcal{B}$, 我们定义区间 $(a, b]$ 上的概率为

$$\mathbb{P}((a, b]) = F(b) - F(a),$$

特别地根据右连续

$$\mathbb{P}(\emptyset) = \lim_{b \rightarrow a^+} F(b) - F(a) = 0, \quad \mathbb{P}(\mathbb{R}) = \lim_{b \rightarrow +\infty} F(b) - \lim_{a \rightarrow -\infty} F(a) = 1.$$

注意到

$$\{(a, b] \mid a, b \in \mathbb{R}, a \leq b\} \subseteq \mathcal{P}(\mathbb{R})$$

对有限交封闭, 如果定义 $(a, b]$ 补集的概率

$$\mathbb{P}(\mathbb{R} \setminus (a, b]) = 1 - (F(b) - F(a)),$$

就在一个代数上定义了预测度 $\mathbb{P}$.

我们证明这个代数生成的 σ -代数恰好为 $\mathcal{B}$. 一方面, 任意开集 (a, b) 可由

$$(a, b) = \bigcup_{n=1}^{\infty} \left(a, b - \frac{1}{n} \right]$$

确定, 从而 $\mathcal{B}$ 含于其生成的 σ -代数. 另一方面, 任意 $(a, b]$ 可由

$$(a, b] = \bigcap_{n=1}^{\infty} \left(a, b + \frac{1}{n} \right)$$

确定, 于是 $\mathcal{B}$ 就是其生成的 σ -代数. 从而根据 **Theorem 1.2.3** 可知此预测度可以延拓为测度 $\mathbb{P} : \mathcal{B} \rightarrow \mathbb{R}$, 这当然满足概率的定义, 于是令随机变量 $X = \text{id}_{\mathbb{R}}$ 即可. $\square$

尽管我们不打算说明概率空间同构的含义, 但以下定理给出了另一种通过分布函数确定随机变量的方式, 这给出的概率空间就与上述定理的 $(\mathbb{R}, \mathcal{B}, \mathbb{P})$ 同构.

Theorem 2.2.3.(Skorokhod) 设 $F : \mathbb{R} \rightarrow \mathbb{R}$ 单调上升, 在任意一点处右连续且左极限存在, 满足

$$\lim_{x \rightarrow -\infty} F(x) = 0, \quad \lim_{x \rightarrow +\infty} F(x) = 1.$$

则存在概率空间 $([0, 1], \mathcal{B}([0, 1]), P)$ 及其上的随机变量 X , 使得 $F(x)$ 是 X 的概率分布函数, 其中 $\mathcal{B}([0, 1])$ 是 $\mathcal{B}$ 中元素与 $[0, 1]$ 的交构成的 σ -代数.

Proof. 定义概率

$$\begin{aligned} \mathbb{P} : \{[a, b] \mid 0 \leq a \leq b \leq 1\} &\rightarrow [0, 1], \\ [a, b] &\mapsto F(b) - F(a). \end{aligned}$$

同 **Theorem 2.2.2** 延拓到 $\mathcal{B}([0, 1])$. 定义随机变量

$$\begin{aligned} X : [0, 1] &\rightarrow \mathbb{R}, \\ \omega &\mapsto \inf\{x \in \mathbb{R} \mid F(x) \geq \omega\}. \end{aligned}$$

则当 $\omega \leq F(x)$ 时, $X(\omega) \leq x$, 而 $\omega > F(x)$ 时, 根据 $F(x)$ 单调上升, 任意 $y \leq x$ 都有 $\omega > F(y)$, 从而 $X(\omega) \geq x$, 这就说明 X 的分布函数

$$\mathbb{P}(X \leq x) = \mathbb{P}(\omega \leq F(x)) = F(x) - F(0) = F(x).$$

$\square$

以上说明, 不必指定概率空间, 仅仅指定 $F(x)$ 就可以讨论概率, 因此我们可以直接称满足以上条件的 F 为分布函数, 并依据需要复原一个概率空间和随机变量.

Definition 2.2.3.(离散, 绝对连续与奇异) 设 $F : \mathbb{R} \rightarrow \mathbb{R}$. 若存在严格单调上升序列 $\{x_k\} \subseteq \mathbb{R}$ 和 $p_k \in [0, 1]$, 使得

$$F(x) = \sum_{x_k \leq x} p_k,$$

则称 $F(x)$ **离散 (discrete)**. 若存在 Lebesgue 可积函数 $f(x)$, 使得对任意 $x_1 < x_2$, 有

$$F(x_2) - F(x_1) = \int_{x_1}^{x_2} f(x)dx,$$

则称 $F(x)$ **绝对连续 (absolutely continuous)**. 若 $F(x)$ 几乎处处可导且导数恒为 0, 但 $F(x)$ 不恒为 0, 则称 $F(x)$ **奇异 (singular)**. 一个随机变量被称为离散, 绝对连续或奇异, 如果其分布函数是离散, 绝对连续函数或奇异的.

一个重要的结果是任何随机变量的分布函数可以分解为离散, 绝对连续和奇异部分, 从而我们可以分别研究这三者.

Theorem 2.2.4.(Lebesgue) 设 $F : \mathbb{R} \rightarrow \mathbb{R}$ 是分布函数, 则存在分布函数 F_1, F_2, F_3 分别是离散的, 绝对连续的和奇异的, 以及 $\lambda_1, \lambda_2, \lambda_3 \in [0, 1]$, 使得

$$F(x) = \lambda_1 F_1(x) + \lambda_2 F_2(x) + \lambda_3 F_3(x),$$

且这样的分解唯一.

Proof. 由于 $F(x)$ 单调上升, 至多只有可数个间断点, 且按定义左极限存在而右连续, 设为 $x_n (n \in \mathbb{Z})$. 定义

$$F_d(x) = \sum_{n \in \mathbb{Z}} \left(F(x_n) - \lim_{t \rightarrow x_n^-} F(t) \right) \delta_{x_n}(x),$$

其中

$$\delta_u(x) = \begin{cases} 0, & x < u, \\ 1, & x \geq u. \end{cases}$$

$F_d(x)$ 定义合理, 因为任意一点处

$$F_d(x) \leq \sum_{n \in \mathbb{Z}} \left(F(x_n) - \lim_{t \rightarrow x_n^-} F(t) \right) \leq \lim_{t \rightarrow +\infty} F(t) - \lim_{t \rightarrow -\infty} F(t) = 1.$$

显然 $F_d(x)$ 的间断点恰好是 $F(x)$ 的间断点, 且 $F_d(x)$ 右连续, 左极限存在, 单调上升. 于是 $F(x) - F_d(x)$ 在 $\{x_n\}$ 以外处处连续. 再考虑

$$\begin{aligned} & \lim_{x \rightarrow x_n^-} F_d(x) - F_d(x_n) \\ &= \sum_{m < n} \left(F(x_m) - \lim_{t \rightarrow x_m^-} F(t) \right) \delta_{x_m}(x) - \sum_{m \leq n} \left(F(x_m) - \lim_{t \rightarrow x_m^-} F(t) \right) \delta_{x_m}(x) \\ &= \lim_{x \rightarrow x_n^-} F(x) - F(x_n). \end{aligned}$$

从而

$$\lim_{x \rightarrow x_n^-} (F(x) - F_d(x)) = (F(x_n) - F_d(x_n)),$$

这就说明 $G(x) := F(x) - F_d(x)$ 是连续函数. 对任意 $t_1 < t_2$, 若中间不存在 $t_1 \leq x_n \leq t_2$, 则 $F_d(t_1) = F_d(t_2)$, 进而

$$G(t_1) - G(t_2) = F(t_1) - F(t_2) \leq 0 \implies G(t_1) \leq G(t_2).$$

否则可在 $t_1 < t_2$ 间插入所有的 x_n , $G(x)$ 在每个 (x_{n-1}, x_n) 上单调而在端点处连续, 从而 $G(x)$ 单调上升. 又由于单调函数的不可导点是 Lebesgue 零测的, 从而 $G'(x)$ 是 Lebesgue 可积的, 进而可定义

$$F_{ac}(x) = \int_{-\infty}^x G'(t)dt.$$

由于 $G(x)$ 单调上升, $G'(t) \geq 0$, 从而 $F_{ac}(x)$ 单调上升且连续. 再定义

$$F_s(x) = G(x) - F_{ac}(x),$$

则

$$F'_s(x) = F'(x) - F'_{ac}(x) = 0$$

在所有可导点成立, 从而 $F_s(x)$ 几乎处处可导且导数恒为 0. 依照定义 $F_s(x)$ 右连续且左极限存在. 对任意 $t_1 < t_2$, 有

$$F_s(t_2) - F_s(t_1) = G(t_2) - G(t_1) + \int_{t_1}^{t_2} G'(t)dt \geq 0.$$

显然 F_d, F_{ac}, F_s 均满足在 $-\infty$ 处极限为 0, 以及单调上升, 右连续, 左极限存在. 注意到这表明 F_d, F_{ac}, F_s 均恒正, 于是

$$F(x) = F_d(x) + F_{ac}(x) + F_s(x) \leq 1$$

表明 F_d, F_{ac}, F_s 单调有界, 从而在 $+\infty$ 处收敛到 $[0, 1]$ 中的某个值, 设为 $\lambda_1, \lambda_2, \lambda_3$, 则有 Lebesgue 分解

$$F(x) = \lambda_1 \left(\frac{1}{\lambda_1} F_d(x) \right) + \lambda_2 \left(\frac{1}{\lambda_2} F_{ac}(x) \right) + \lambda_3 \left(\frac{1}{\lambda_3} F_s(x) \right).$$

这三项依次就是离散分布函数, 绝对连续分布函数和奇异分布函数. 若 $\lambda_i = 0$, 只要把分解项取为 0 即可. 取 $x \rightarrow \infty$ 即知 $\lambda_1 + \lambda_2 + \lambda_3 = 1$. 现在假设存在分解

$$F(x) = \lambda_1 F_1(x) + \lambda_2 F_2(x) + \lambda_3 F_3(x) = \lambda_1^* F_1^*(x) + \lambda_2^* F_2^*(x) + \lambda_3^* F_3^*(x),$$

则有

$$\lambda_1 F_1(x) - \lambda_1^* F_1^*(x) = \lambda_2^* F_2^*(x) + \lambda_3^* F_3^*(x) - \lambda_2 F_2(x) - \lambda_3 F_3(x),$$

但左边离散右边连续, 从而必须均为 0. 又有

$$\lambda_2^* F_2^*(x) - \lambda_2 F_2(x) = \lambda_3 F_3(x) - \lambda_3^* F_3^*(x),$$

则左边连续且处处可导, 而右边表明导数几乎处处为 0, 从而只能是常数, 且恰为

$$\lim_{x \rightarrow -\infty} (\lambda_2^* F_2^*(x) - \lambda_2 F_2(x)) = 0.$$

这就说明了 $\lambda_i F_i(x) = \lambda_i^* F_i^*(x)$, 进而

$$\lim_{x \rightarrow +\infty} \lambda_i F_i(x) = \lim_{x \rightarrow +\infty} \lambda_i^* F_i^*(x) \implies \lambda_i = \lambda_i^*,$$

这就证明了唯一性. □

对于绝对连续的情形, 可以定义概率密度的概念.

Definition 2.2.4.(概率密度函数) 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, X 是其上的绝对连续随机变量, $F(x)$ 为 X 的概率分布函数. 则存在 $f: \mathbb{R} \rightarrow [0, +\infty)$ Lebesgue 可积, 使得

$$\int_{-\infty}^x f(t) dt = F(x),$$

称 $f(x)$ 是随机变量 X 的**概率密度函数 (probability density function, p.d.f.)**.

显然, 概率密度的积分

$$\int_{-\infty}^{+\infty} f(t) dt = \lim_{x \rightarrow +\infty} F(x) = 1.$$

根据变上限积分的性质, 若 $f(x)$ 在 x_0 处连续, 则 $F(x)$ 在 x_0 处可导, 且 $F'(x_0) = f(x_0)$, 同时

$$\mathbb{P}(X = x_0) = F(x_0) - \lim_{x \rightarrow x_0^-} F(x) = 0.$$

我们常常需要处理随机变量之间的变换.

Proposition 2.2.5.(随机变量的换元公式) 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, X 是绝对连续随机变量, $\varphi: \mathbb{R} \rightarrow \mathbb{R}$ 严格单调可导, 则随机变量

$$\begin{aligned} Y: \Omega &\rightarrow \mathbb{R}, \\ \omega &\mapsto \varphi(X(\omega)) \end{aligned}$$

的概率密度函数满足

$$f_Y(y) = \frac{f_X(\varphi^{-1}(y))}{|\varphi'(y)|}.$$

Proof. 不妨设 φ 严格单调上升, 则

$$F_Y(y) = \mathbb{P}(Y \leq y) = \mathbb{P}(\varphi(X) \leq y) = \mathbb{P}(X \leq \varphi^{-1}(y)) = \int_{-\infty}^{\varphi^{-1}(y)} f_X(x) dx.$$

两边对 y 求导得

$$f_Y(y) = f_X(\varphi^{-1}(y)) \frac{d}{dy} \varphi^{-1}(y) = \frac{f_X(\varphi^{-1}(y))}{|\varphi'(y)|}.$$

同理可证严格单调下降的情形. □

下面我们给出一些分布函数的实例.

Example 2.2.1.(二项分布) 取概率空间 Ω 为做 n 次随机试验的结果 (成功或失败), 即

$$\Omega = \{(q_1, q_2, \dots, q_n) \mid q_k \in \{\mathbf{T}, \mathbf{F}\}\}.$$

如果每次试验独立, 成功概率为 p , 令随机变量 X 表示成功次数, 即 $X(\omega) = \mathbf{T}(\omega)$ 是 $\omega \in \Omega$ 中 $\mathbf{T}$ 的数量. 则 $X^{-1}(k)$ 的概率

$$\mathbb{P}(X = k) = C_n^k p^k (1-p)^{n-k}.$$

此时称 X 服从**二项分布 (binomial distribution)**, 记作 $X \sim \text{Bi}(n, p)$.

我们很容易写出相应的分布函数是离散分布函数

$$F(x) = \sum_{k \leq x} C_n^k p^k (1-p)^{n-k},$$

但这不会给我们更多好处, 因此对离散随机变量, 之后仅给出概率表达.

Example 2.2.2.(几何分布) 取概率空间 Ω 为做随机试验直到成功的结果, 即

$$\Omega = \{(q_1, q_2, \dots, q_n) \mid n \geq 1, q_1 = q_2 = \dots = q_{n-1} = \mathbf{F}, q_n = \mathbf{T}\}.$$

如果每次试验独立, 成功概率为 p , 令随机变量 X 表示成功时进行的总次数, 即 $X(\omega) = \text{len}(\omega)$ 是 $\omega \in \Omega$ 的长度 n , 则

$$\mathbb{P}(X = k) = p(1-p)^{k-1}.$$

此时称 X 服从**几何分布 (geometric distribution)**, 记作 $X \sim \text{Ge}(p)$.

Example 2.2.3.(超几何分布) 取概率空间 Ω 为从有 $N - M$ 个次品的 N 个产品中不放回地取 n 个的结果, 令随机变量 X 表示非次品的个数, 则

$$\mathbb{P}(X = m) = \frac{C_M^m C_{N-M}^{n-m}}{C_N^n}.$$

此时称 X 服从**超几何分布 (hypergeometric distribution)**, 记作 $X \sim \text{H}(n, M, N)$.

Example 2.2.4.(Poisson 分布) 给定参数 $\lambda > 0$, 任何概率空间上的随机变量 X , 只要满足

$$\mathbb{P}(X = k) = \frac{\lambda^k e^{-\lambda}}{k!},$$

就称 X 服从 **Poisson 分布 (Poisson distribution)**, 记作 $X \sim \text{Poi}(\lambda)$.

注意我们提到过, 上式定义了一个分布函数, 而任何分布函数都存在对应的概率空间和随机变量, 因此上述定义是有意义的.

下面我们考虑一些绝对连续的分布.

Example 2.2.5.(1 维均匀分布) 给定参数 $a < b$, 任何概率空间上的随机变量 X , 只要有分布函数

$$F(x) = \begin{cases} 0, & x \leq a, \\ \frac{x-a}{b-a}, & a \leq x \leq b, \\ 1, & x \geq b, \end{cases}$$

或概率密度函数

$$f(x) = \begin{cases} \frac{1}{b-a}, & a \leq x \leq b, \\ 0, & \text{otherwise,} \end{cases}$$

就称 X 服从 **均匀分布 (uniform distribution)**, 记作 $X \sim U(a, b)$.

Example 2.2.6.(指数分布) 给定参数 $\lambda > 0$, 任何概率空间上的随机变量 X , 只要有概率密度函数

$$f(x) = \begin{cases} \lambda e^{-\lambda x}, & x \geq 0, \\ 0, & x < 0, \end{cases}$$

就称 X 服从 **指数分布 (exponential distribution)**, 记作 $X \sim \text{Exp}(\lambda)$.

Example 2.2.7.(Gamma 分布) 给定参数 $\alpha, \lambda > 0$, 任何概率空间上的随机变量 X , 只要有概率密度函数

$$f(x) = \begin{cases} e^{-\lambda x} \lambda^\alpha \frac{x^{\alpha-1}}{\Gamma(\alpha)}, & x > 0, \\ 0, & x \leq 0, \end{cases}$$

就称 X 服从 **Gamma 分布 (Gamma distribution)**, 记作 $X \sim \Gamma(\alpha, \lambda)$.

Example 2.2.8.(Cauchy 分布) 任何概率空间上的随机变量 X , 只要有概率密度函数

$$f(x) = \frac{1}{\pi(1+x^2)},$$

就称 X 服从 **Cauchy 分布 (Cauchy distribution)**.

Example 2.2.9.(正态分布) 给定参数 μ 和 $\sigma > 0$, 任何概率空间上的随机变量 X , 只要有概率密度函数

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right).$$

就称 X 服从**正态分布 (normal distribution)**, 记作 $X \sim N(\mu, \sigma^2)$.

2.3 随机向量与分布函数

单个随机变量无法刻画概率空间, 很多时候我们需要多个随机变量刻画概率空间的多个侧面, 并研究这些随机变量的关系. 例如取概率空间为 n 个三种颜色的小球摸出 m 个的所有可能结果, 随机变量 X 记录了 A 色小球的个数, Y 记录了 B 色小球的个数, 则 X, Y 之间是有关的: 在 X 取值 m 的点上 Y 只能取值 0.

在同一概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 上取定 n 个随机变量 $X_k (1 \leq k \leq n)$, 则可以写为向量值函数的形式.

Definition 2.3.1. (n 维随机向量) 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, $X_k (1 \leq k \leq n)$ 是 $(\Omega, \mathcal{F}, \mathbb{P})$ 上的随机变量. 定义

$$\mathbf{X}: \Omega \rightarrow \mathbb{R}^n, \\ \omega \mapsto \begin{bmatrix} X_1(\omega) \\ X_2(\omega) \\ \vdots \\ X_n(\omega) \end{bmatrix},$$

称为 $(\Omega, \mathcal{F}, \mathbb{P})$ 上的一个 n 维**随机向量 (random vector)**, 每个 X_k 称为该随机向量的分量.

我们将分布函数的定义相应扩展, 一个自然的方式是扩展为 $\mathbb{R}^n$ 上的函数

$$F(\mathbf{x}) = \mathbb{P}(\mathbf{X} \leq \mathbf{x}) = \mathbb{P}(\{\omega \in \Omega \mid X_k(\omega) \leq x_k, \forall 1 \leq k \leq n\}).$$

Definition 2.3.2. (联合分布函数) 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, $\mathbf{X}$ 为其上的 n 维随机向量. 定义

$$F(\mathbf{x}) = \mathbb{P}\left(\bigcap_{k=1}^n \{\omega \in \Omega \mid X_k(\omega) \leq x_k\}\right) = \mathbb{P}(\{\omega \in \Omega \mid X_k(\omega_k) \leq x_k, 1 \leq k \leq n\})$$

为 X 的**联合分布函数 (joint distribution function)**. 各个分量的分布函数

$$F_k(x) = \mathbb{P}(\{\omega \in \Omega \mid X_k(\omega) \leq x\})$$

称为 X_k 的**边缘分布函数 (marginal distribution function)**. 据测度的连续性, 这也可以由

$$F_k(x_k) = \lim_{x_j \rightarrow +\infty, j \neq k} \mathbb{P}(\{\omega \in \Omega \mid X_j(\omega) \leq x_j, \forall 1 \leq j \leq n\}) = \lim_{x_j \rightarrow +\infty, j \neq k} F(\mathbf{x})$$

得到.

类似于一元的情形, 联合分布函数也可以决定存在一个随机向量, 以自身为分布.

Theorem 2.3.1.(Lebesgue-Stieljes) 设 $F : \mathbb{R}^n \rightarrow \mathbb{R}$ 关于每个分量单调上升, 在任意一点处右连续且左极限存在, 满足

$$\lim_{x_k \rightarrow -\infty, \forall 1 \leq k \leq n} F(\mathbf{x}) = 0, \quad \lim_{x_k \rightarrow +\infty, \forall 1 \leq k \leq n} F(\mathbf{x}) = 1.$$

则存在概率空间 $(\mathbb{R}^n, \mathcal{F}, \mathbb{P})$ 以及其上的随机向量 $\mathbf{X}$, 使得 $F(\mathbf{x})$ 是 $\mathbf{X}$ 的联合分布函数.

Proof. 取概率空间 $\Omega = \mathbb{R}^n$, 事件域 $\mathcal{F} = \mathcal{B}_n$, 我们定义区域

$$\prod_{k=1}^n (a_k, b_k]$$

上的概率为

$$\mathbb{P} \left(\prod_{k=1}^n (a_k, b_k] \right) = F(\mathbf{b}) - F(\mathbf{a}).$$

注意到

$$\left\{ \prod_{k=1}^n (a_k, b_k] \mid a_k, b_k \in \mathbb{R}, a_k \leq b_k, 1 \leq k \leq n \right\} \subseteq \mathcal{P}(\mathbb{R}^n)$$

对有限交封闭, 只要定义其补集的概率

$$\mathbb{P} \left(\mathbb{R}^n \setminus \prod_{k=1}^n (a_k, b_k] \right) = 1 - (F(\mathbf{b}) - F(\mathbf{a})),$$

就在一个代数上定义了概率 $\mathbb{P}$. 同 **Theorem 2.2.2.** 可知这将生成 $\mathcal{B}_n$ 上的测度, 令随机向量 $\mathbf{X} = \text{id}_{\mathbb{R}^n}$ 即可. $\square$

同样我们可以对绝对连续函数建立联合密度的概念.

Definition 2.3.3.(联合密度函数) 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, $\mathbf{X}$ 是其上的 n 维随机向量, $F(\mathbf{x})$ 为 $\mathbf{X}$ 的联合分布函数. 若存在 $f : \mathbb{R}^n \rightarrow [0, +\infty)$ Lebesgue 可积, 使得

$$\int_{t_k \leq x_k} f(\mathbf{t}) dx_1 dx_2 \cdots dx_n = F(\mathbf{x}),$$

则称 $f(\mathbf{x})$ 是随机向量 $\mathbf{X}$ 的**联合密度函数 (joint density function)**.

利用概率分布可以计算边缘分布, 当然也可以利用概率密度计算边缘密度, 我们需要证明这样计算的边缘密度恰好是边缘分布的密度函数.

Proposition 2.3.2.(边缘密度函数) 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, $\mathbf{X}$ 是其上的 n 维随机向量, $f(\mathbf{x})$ 为 $\mathbf{X}$ 的联合密度函数. 则随机变量 X_k 的密度函数为

$$f_k(x_k) = \int_{x_j \in \mathbb{R}, j \neq k} f(\mathbf{x}) dx_1 dx_2 \cdots dx_n.$$

Proof. 由于被积函数 $f(\mathbf{x})$ 非负, 根据 Tonelli 定理 [Theorem B.5](#). 积分次序可交换, 即

$$\int_{-\infty}^{x_k} \int_{t_j \in \mathbb{R}, j \neq k} f(\mathbf{t}) dx_1 dx_2 \cdots dx_n = \lim_{x_j \rightarrow +\infty, j \neq k} \int_{t_j \leq x_j} f(\mathbf{t}) dx_1 dx_2 \cdots dx_n.$$

根据广义积分的定义和边缘分布的定义, 上式即

$$\lim_{x_j \rightarrow +\infty, j \neq k} F(\mathbf{x}) = F_k(x_k).$$

因此

$$f_k(x_k) = \int_{x_j \in \mathbb{R}, j \neq k} f(\mathbf{x}) dx_1 dx_2 \cdots dx_n$$

就是随机变量 X_k 的边缘密度函数. □

类似地有换元公式.

Theorem 2.3.3.(随机向量的换元公式) 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, $\mathbf{X}$ 是 n 维随机向量, 联合密度函数为 $f_{\mathbf{X}}(\mathbf{x})$. 随机向量函数

$$\mathbf{Y} = \Phi(\mathbf{X}) = \begin{bmatrix} \varphi_1(\mathbf{X}) \\ \varphi_2(\mathbf{X}) \\ \vdots \\ \varphi_n(\mathbf{X}) \end{bmatrix}$$

连续可微且反函数存在. 则 $\mathbf{Y}$ 的联合密度函数为

$$f_{\mathbf{Y}}(\mathbf{y}) = f_{\mathbf{X}}(\Phi^{-1}(\mathbf{y})) \det(J),$$

其中 J 是 Φ^{-1} 的 Jacobi 矩阵.

Proof. 依照定义

$$F_{\mathbf{Y}}(\mathbf{y}) = \mathbb{P}(\varphi_k(x_k) \leq y_k, \forall 1 \leq k \leq n) = \int_{\varphi_k(\mathbf{x}) \leq y_k} f_{\mathbf{X}}(\mathbf{x}) dx_1 dx_2 \cdots dx_n.$$

利用积分换元将 $\mathbf{x}$ 换为 $\Phi^{-1}(\mathbf{t})$, 即得

$$F_{\mathbf{Y}}(\mathbf{y}) = \int_{\varphi_k(\Phi^{-1}(\mathbf{t})) \leq y_k} f_{\mathbf{X}}(\Phi^{-1}(\mathbf{t})) \det(J) dx_1 dx_2 \cdots dx_n.$$

根据反函数的定义 $\varphi_k(\Phi^{-1}(\mathbf{t})) = t_k$, 再根据定义 [Definition 2.3.4](#). 即得

$$f_{\mathbf{Y}}(\mathbf{y}) = f_{\mathbf{X}}(\Phi^{-1}(\mathbf{y})) \det(J).$$

□

对多个随机变量组成的随机向量, 我们还关心随机变量之间的组合作为新随机变量的函数, 例如考虑商场估计人均消费, 每个人的消费 $X_k (1 \leq k \leq N)$ 视为随机变量, 而总人数 N 也是随机变量, 则我们需要的平均值

$$A = \frac{1}{N} \left(\sum_{k=1}^N X_k \right)$$

也是随机变量, 且是若干随机变量的函数.

这里我们考虑一个简单的情形.

Example 2.3.1. (随机变量的和与积的分布) 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, $\mathbf{X} = (X_1, X_2)^T$ 是 2 维随机向量, 联合密度函数为 $f(x_1, x_2)$. 考虑 $X_1 + X_2$ 和 $X_1 X_2$ 的概率密度函数. 依照定义

$$F_{X_1+X_2}(x) = \int_{x_1+x_2 \leq x} f(x_1, x_2) dx_1 dx_2 = \int_{-\infty}^{+\infty} \left(\int_{-\infty}^{x-x_1} f(x_1, x_2) dx_2 \right) dx_1.$$

根据 Tonelli 定理 [Theorem B.5](#). 交换次序, 两边对 x 求导可得

$$f_{X_1+X_2}(x) = \int_{-\infty}^{+\infty} f(x_1, x-x_1) dx_1.$$

类似地也有

$$f_{X_1+X_2}(x) = \int_{-\infty}^{+\infty} f(x-x_2, x_2) dx_2.$$

同样

$$F_{X_1 X_2}(x) = \int_{x_1 x_2 \leq x} f(x_1, x_2) dx_1 dx_2.$$

按照 x_1 的范围展开为

$$\int_0^{+\infty} \left(\int_{-\infty}^{\frac{x}{x_1}} f(x_1, x_2) dx_2 \right) dx_1 + \int_{-\infty}^0 \left(\int_{\frac{x}{x_1}}^{+\infty} f(x_1, x_2) dx_2 \right) dx_1.$$

对 x 求导即得

$$f_{X_1 X_2}(x) = \int_0^{+\infty} \frac{1}{x_1} f\left(x_1, \frac{x}{x_1}\right) dx_1 + \int_{-\infty}^0 \frac{1}{-x_1} f\left(x_1, \frac{x}{x_1}\right) dx_1.$$

整理即得

$$f_{X_1 X_2}(x) = \int_{-\infty}^{+\infty} \frac{1}{|x_1|} f\left(x_1, \frac{x}{x_1}\right) dx_1 = \int_{-\infty}^{+\infty} \frac{1}{|x_2|} f\left(\frac{x}{x_2}, x_2\right) dx_2.$$

同样, 我们给出一些分布函数的实例.

Example 2.3.2.(多项式分布) 考虑某种随机试验有 n 个结果, 取概率空间 Ω_0 为 m 次试验的结果, 而 $\Omega = \Omega_0^n$ 是乘积空间. 如果每次试验独立, 且达成第 k 种结果的概率为 p_k , 令随机变量 X_k 表示达成第 k 种结果的次数, 则

$$\mathbb{P}\left(\bigcap_{k=1}^m \{X_k = t_k\}\right) = n! \prod_{k=1}^m \frac{p_k^{t_k}}{t_k!}, \quad \sum_{k=1}^n t_k = n.$$

称 $\mathbf{X}$ 服从**多项式分布 (multinomial distribution)**.

Example 2.3.3.(n 维均匀分布) 给定参数 $a_k < b_k (1 \leq k \leq n)$, 任何概率空间上的随机向量 $\mathbf{X}$, 只要有分布函数

$$F(x) = \begin{cases} 0, & x_k \leq a_k, \exists 1 \leq k \leq n, \\ \prod_{k=1}^n \min\left\{1, \frac{x_k - a_k}{b_k - a_k}\right\}, & \text{otherwise,} \end{cases}$$

或概率密度函数

$$f(x) = \begin{cases} \prod_{k=1}^n \frac{1}{b_k - a_k}, & a_k \leq x_k \leq b_k, \forall 1 \leq k \leq n, \\ 0, & \text{otherwise,} \end{cases}$$

就称 X 服从 n 维均匀分布, 记作 $X \sim U(\mathbf{a}, \mathbf{b})$.

Example 2.3.4.(n 维正态分布) 给定参数 $\mu \in \mathbb{R}^n$ 和 n 维正定矩阵 Σ , 任何概率空间上的随机向量 X , 只要有概率密度函数

$$f(\mathbf{x}) = \frac{1}{(2\pi)^{\frac{n}{2}} \det(\Sigma)} \exp\left(-\frac{1}{2}(\mathbf{x} - \mu)^T \Sigma^{-1}(\mathbf{x} - \mu)\right),$$

就称此随机向量服从 n 维正态分布 $\mathbf{X} \sim N(\mu, \Sigma)$.

Example 2.3.5.(2 维正态分布) 2 维正态分布的参数矩阵 Σ 对称, 从而由 3 个参数决定, 可以表达为

$$\mu = \begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \quad \Sigma = \begin{bmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{bmatrix},$$

其逆矩阵

$$\Sigma^{-1} = \frac{1}{\sigma_1^2\sigma_2^2(1-\rho^2)} \begin{bmatrix} \sigma_2^2 & -\rho\sigma_1\sigma_2 \\ -\rho\sigma_1\sigma_2 & \sigma_1^2 \end{bmatrix} = \frac{1}{1-\rho^2} \begin{bmatrix} \sigma_1^{-2} & -\frac{\rho}{\sigma_1\sigma_2} \\ -\frac{\rho}{\sigma_1\sigma_2} & \sigma_2^{-2} \end{bmatrix}.$$

这样概率密度函数

$$\begin{aligned} f(\mathbf{x}) &= \frac{1}{(2\pi)^{\frac{n}{2}} \det(\Sigma)} \exp\left(-\frac{1}{2}(\mathbf{x} - \mu)^T \Sigma^{-1}(\mathbf{x} - \mu)\right) \\ &= \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp\left(-\frac{\tilde{x}_1^2 - 2\rho\tilde{x}_1\tilde{x}_2 + \tilde{x}_2^2}{2(1-\rho^2)}\right), \end{aligned}$$

其中

$$\tilde{x}_1 = \frac{x_1 - \mu_1}{\sigma_1}, \quad \tilde{x}_2 = \frac{x_2 - \mu_2}{\sigma_2}.$$

2.4 随机变量的矩

回顾随机变量, 概率分布和概率密度的关系

$$F(x) = \int_{-\infty}^x f(t)dt = \mathbb{P}(X \leq x),$$

如果将后者展开写为测度

$$\mathbb{P}(\{\omega \in \Omega \mid X(\omega) \leq x\}),$$

根据简单函数积分的定义, 一个集合的测度相当于对集合上的特征函数做积分, 也即

$$\mathbb{P}(X \leq x) = \int_{X(\omega) \leq x} 1d\mathbb{P}.$$

特别地

$$1 = \mathbb{P}(\Omega) = \int_{\Omega} 1d\mathbb{P}.$$

这带给我们一个观察, 全概率 1 可以视为概率空间 Ω 的元素权重的直接累积. 这样抹除了概率空间本身的信息而只保留了权重求和的信息. 如何才能保留概率空间的信息呢, 一种想法是考虑形式积分

$$\int_{\Omega} \omega d\mathbb{P},$$

得到的结果在 Ω 生成的自由 $\mathbb{R}$ -向量空间中, 从而可以通过作商得到任何想要的信息.

一般而言, 带测度的积分理论要求被积函数是一个到 $\mathbb{R}$ 的映射, 例如 1 可以看作常值映射. 我们知道一个随机变量 $X: \Omega \rightarrow \mathbb{R}$ 就是这样的映射, 且反映了概率空间的一个侧面, 因此考虑

$$\int_{\Omega} X(\omega)d\mathbb{P}$$

是相当合理的. 我们解释此式的意义, 一个随机变量 X 相当于为概率空间 Ω 中的元素分别赋予了一个实数值, 而概率相当于为每个元素赋予了一个权重, 而上述积分就是依权重取随机变量的平均, 即我们期待随机变量平均上取到的值.

Definition 2.4.1.(数学期望) 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, X 是其上的随机变量. 如果积分

$$\mathbb{E}_X(X) = \int_{\Omega} X(\omega)d\mathbb{P}$$

收敛, 则为随机变量 X 的**数学期望 (mathematical expectation)**. 在不致混淆的情况下也记为 $\mathbb{E}(X)$.

容易看出 $\mathbb{E}(c) = c\mathbb{P}(\Omega) = c$, 这就是说如果给概率空间赋予相同的数, 则依概率为权重的平均就是此数本身, 这是符合直觉的.

以下给出数学期望的基本性质.

Proposition 2.4.1.(数学期望的线性) 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, X 是其上的随机变量, 则有线性

$$\mathbb{E}(\lambda X + \mu Y) = \lambda \mathbb{E}(X) + \mu \mathbb{E}(Y).$$

Proof. 依定义直接计算

$$\mathbb{E}(\lambda X + \mu Y) = \int_{\Omega} (\lambda X(\omega) + \mu Y(\omega)) d\mathbb{P} = \lambda \int_{\Omega} X(\omega) d\mathbb{P} + \mu \int_{\Omega} Y(\omega) d\mathbb{P} = \lambda \mathbb{E}(X) + \mu \mathbb{E}(Y).$$

□

数学期望是依测度的积分形式, 并不便于计算, 好在我们可以用分布函数改造为我们熟悉的 Riemann 积分 (求和) 形式.

Proposition 2.4.2.(数学期望的计算) 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, X 是其上的随机变量. 如果随机变量是离散的, 即存在至多可数个点 x_k 和 $p_k \in [0, 1]$, 使得

$$X^{-1}(x_k) \in \mathcal{F}, \quad \bigcup_k X^{-1}(x_k) = \Omega, \quad \mathbb{P}(X = x_k) = p_k.$$

则期望

$$\mathbb{E}(X) = \sum_k x_k p_k.$$

如果随机变量是绝对连续的, 即存在密度函数 $f(x)$, 则期望

$$\mathbb{E}(X) = \int_{\mathbb{R}} x f(x) dx.$$

Proof. 对离散的情形, 根据简单函数积分的定义

$$\mathbb{E}(X) = \sum_k \int_{X^{-1}(x_k)} X(\omega) d\mathbb{P} = \sum_k \int_{X^{-1}(x_k)} x_k d\mathbb{P} = \sum_k x_k \mathbb{P}(X^{-1}(x_k)),$$

而

$$\mathbb{P}(X^{-1}(x_k)) = \mathbb{P}(X = x_k) = p_k,$$

代入即证. 现在考虑绝对连续的情形. 取 $[-n, n]$ 的均匀分割 $x_0, x_1, \dots, x_{l(n)}$, 使得当 n 增大时相邻分割点的距离趋于 0 且覆盖 n 的所有分割点. 定义简单逼近

$$X_n(\omega) = x_{k+1} \iff X(\omega) \in (x_k, x_{k+1}],$$

其他时候均取 0, 则显然关于 n 单调下降几乎一致收敛于 X . 根据非负可测函数积分的定义

$$\mathbb{E}(X) = \int_{\Omega} X(\omega) d\mathbb{P} = \lim_{n \rightarrow \infty} \int_{\Omega} X_n(\omega) d\mathbb{P},$$

根据先前对简单函数的计算

$$\int_{\Omega} X_n(\omega) d\mathbb{P} = \sum_{k=0}^{l(n)} x_k \mathbb{P}(X_n(\omega) = x_k) = \sum_{k=0}^{l(n)} x_k \mathbb{P}(x_{k-1} < X(\omega) \leq x_k).$$

由于概率和分布函数由积分表达

$$\int_{\Omega} X_n(\omega) d\mathbb{P} = \sum_{k=0}^{l(n)} x_k \int_{x_{k-1}}^{x_k} f(x) dx = \sum_{k=0}^{l(n)} \int_{x_{k-1}}^{x_k} x_k f(x) dx.$$

现在定义

$$f_n(x) = x_k f(x), \quad x \in (x_{k-1}, x_k],$$

其他时候均取 0, 则 $f_n(x) \geq x f(x)$ 且单调下降收敛到 $x f(x)$, 于是根据单调收敛定理 [Theorem B.2](#) 积分

$$\mathbb{E}(X) = \lim_{n \rightarrow \infty} \int_{\Omega} X_n(\omega) d\mathbb{P} = \lim_{n \rightarrow \infty} \int_{\mathbb{R}} f_n(x) dx = \int_{\mathbb{R}} x f(x) dx.$$

□

这说明要计算随机变量, 以至随机变量函数的期望, 只要计算出相应的分布函数或密度函数, 做积分即可.

Example 2.4.1.(Cauchy 分布的期望) 考虑 Cauchy 分布, 如果期望存在, 则必然可以通过 [Proposition 2.4.2](#) 计算, 因为有密度函数

$$f(x) = \frac{1}{\pi(1+x^2)}.$$

然而实际计算会发现

$$\int_{-\infty}^{+\infty} |x| dF(x) = \int_{-\infty}^{+\infty} |x| f(x) dx = \int_{-\infty}^{+\infty} \frac{|x|}{\pi(1+x^2)} dx = \int_0^{+\infty} \frac{2x}{\pi(1+x^2)} dx,$$

这一积分的结果是

$$\lim_{x \rightarrow +\infty} \frac{1}{\pi} \ln(1+x^2) = +\infty,$$

说明积分不收敛, 于是数学期望不存在.

对于非负随机变量, 可以用概率代替密度函数进行计算.

Proposition 2.4.3.(非负随机变量的期望) 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, $X: \Omega \rightarrow \mathbb{R}_{\geq 0}$ 是随机变量, 使得数学期望 $\mathbb{E}(X)$ 存在, 则

$$\mathbb{E}(X) = \int_0^{+\infty} \mathbb{P}(X > x) dx.$$

Proof. 我们在乘积空间 $\Omega \times [0, +\infty)$ 上考虑此问题. 对一个固定的 $\omega \in \Omega$, 随机变量可以写为积分

$$X(\omega) = \int_0^{X(\omega)} 1dx = \int_0^{+\infty} \chi_{\{x < X(\omega)\}} dx.$$

两边在 Ω 上关于测度 $\mathbb{P}$ 求积分

$$\mathbb{E}(X) = \int_{\Omega} X(\omega) d\mathbb{P} = \int_{\Omega} \left(\int_0^{+\infty} \chi_{\{x < X(\omega)\}} dx \right) d\mathbb{P}.$$

根据 Tonelli 定理 [Theorem B.5](#) 可以换序

$$\mathbb{E}(X) = \int_0^{+\infty} \left(\int_{\Omega} \chi_{\{x < X(\omega)\}} d\mathbb{P} \right) dx = \int_0^{+\infty} \mathbb{P}(X > x) dx.$$

□

特别地, 当 X 是离散型随机变量时, 设随机变量的取值为

$$0 = x_0 < x_1 < x_2 < \cdots < x_n < \cdots$$

则上式为

$$\mathbb{E}(X) = \sum_{k=1}^{\infty} (x_k - x_{k-1}) \mathbb{P}(X > x_k).$$

当 X 恰好取正整数值时, 上式可进一步写为

$$\mathbb{E}(X) = \sum_{k=1}^{\infty} \mathbb{P}(X > k).$$

现在我们考虑更一般的情况, 随机变量并不直接由熟悉的对应关系 $X : \Omega \rightarrow \mathbb{R}$ 给出, 而是由若干较为简单随机变量 X_k 的函数的形式给出, 以下定理给出结果说明了如何计算这种随机变量期望. 该定理的证明与普通随机变量是类似的.

Proposition 2.4.4.(随机变量函数数学期望的计算) 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, $\mathbf{X}$ 是其上的绝对连续 m 维随机向量, $\varphi : \mathbb{R}^m \rightarrow \mathbb{R}$ 是可测函数. 设 $\mathbf{X}$ 的密度函数为 $f(\mathbf{x})$, 则随机变量函数 $\varphi(\mathbf{X}) = \varphi \circ \mathbf{X} : \Omega \rightarrow \mathbb{R}$ 作为随机变量的期望

$$\mathbb{E}(\mathbf{X}) = \int_{\mathbb{R}^m} \varphi(\mathbf{x}) f(\mathbf{x}) dx_1 dx_2 \cdots dx_m.$$

Proof. 取 $[-n, n]$ 的均匀分割 $x_0, x_1, \dots, x_{l(n)}$, 使得当 n 增大时相邻分割点的距离趋于 0 且覆盖 n 的所有分割点. 定义简单逼近

$$Y_n(\omega) = \varphi \left(\begin{bmatrix} x_{k_1+1} \\ x_{k_2+1} \\ \vdots \\ x_{k_m+1} \end{bmatrix} \right) \iff X_i(\omega) \in (x_{k_i}, x_{k_i+1}], \forall 1 \leq i \leq m,$$

其他时候均取 0, 则显然关于 n 几乎一致收敛于 $\varphi \circ \mathbf{X}$. 根据非负可测函数积分的定义

$$\mathbb{E}(\varphi(\mathbf{X})) = \int_{\Omega} \varphi(\mathbf{X}(\omega)) d\mathbb{P} = \lim_{n \rightarrow \infty} \int_{\Omega} Y_n(\omega) d\mathbb{P},$$

根据 **Proposition 2.4.2** 对简单函数的结果

$$\int_{\Omega} Y_n(\omega) d\mathbb{P} = \sum_{0 \leq k_i \leq l(n), 1 \leq i \leq m} \varphi \left(\begin{bmatrix} x_{k_1+1} \\ x_{k_2+1} \\ \vdots \\ x_{k_m+1} \end{bmatrix} \right) \mathbb{P}(x_{k_i-1} < X_i(\omega) \leq x_{k_i}, \forall 1 \leq i \leq m).$$

由于概率和分布函数由积分表达

$$\int_{\Omega} X_n(\omega) d\mathbb{P} = \sum_{0 \leq k_i \leq l(n), 1 \leq i \leq m} \varphi \left(\begin{bmatrix} x_{k_1+1} \\ x_{k_2+1} \\ \vdots \\ x_{k_m+1} \end{bmatrix} \right) \int_{x_{k_i-1} < t_i \leq x_{k_i}} f(\mathbf{x}) dx_1 dx_2 \cdots dx_m.$$

现在定义

$$f_n(\mathbf{x}) = \varphi \left(\begin{bmatrix} x_{k_1+1} \\ x_{k_2+1} \\ \vdots \\ x_{k_m+1} \end{bmatrix} \right) f(\mathbf{x}), \quad x_i \in (x_{k_i-1}, x_{k_i}], \quad \forall 1 \leq i \leq m,$$

其他时候均取 0, 则 $f_n(\mathbf{x})$ 点点收敛到 $\varphi(\mathbf{x})f(\mathbf{x})$, 于是根据有界收敛定理 **Theorem B.3** 积分

$$\mathbb{E}(\varphi(\mathbf{X})) = \lim_{n \rightarrow \infty} \int_{\Omega} Y_n(\omega) d\mathbb{P} = \lim_{n \rightarrow \infty} \int_{\mathbb{R}^n} f_n(\mathbf{x}) d\mathbf{x} = \int_{\mathbb{R}^n} \varphi(\mathbf{x}) f(\mathbf{x}) dx_1 dx_2 \cdots dx_m.$$

□

由此我们可以计算一类特殊的期望, 称为随机变量的矩.

Definition 2.4.2. (α 阶矩) 给定 $\alpha > 0$. 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, X 是其上的随机变量, 使得 X, X^2 和 X^α 的数学期望存在, 则称 $\mathbb{E}(X^\alpha)$ 为随机变量 X 的 α 阶矩 (moment).

根据 **Proposition 2.4.4** 中取 $n = 1$ 和 $\varphi(x) = x^\alpha$, 可得 X 的 α 阶矩

$$\mathbb{E}(X^\alpha) = \int_{\mathbb{R}} x^\alpha f(x) dx.$$

这样, $\mathbb{P}(\Omega) = 1$ 可以视作 0 阶矩 $\mathbb{E}(X^0)$, 期望当然就是 1 阶矩, 另外我们还关心 2 阶矩.

Definition 2.4.3.(方差) 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, X 是其上的随机变量, 使得 X 的 1, 2 阶矩存在, 则称

$$\text{Var}_X(X) = \mathbb{E}((X - \mathbb{E}(X))^2)$$

为随机变量 X 的**方差 (variance)**. 在不致混淆的情况下也记为 $\text{Var}(X)$.

以下命题说明了方差与 1, 2 阶矩的关系.

Proposition 2.4.5.(方差的计算) 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, X 是其上的随机变量, 使得 X 的 1, 2 阶矩存在, 则方差

$$\text{Var}(X) = \mathbb{E}(X^2) - \mathbb{E}(X)^2.$$

特别地, 若 X 非负, 则

$$\text{Var}(X) = 2 \int_0^{+\infty} x \mathbb{P}(X > x) dx - \mathbb{E}(X)^2.$$

Proof. 利用期望的线性**Proposition 2.4.1.**, 有

$$\text{Var}(X) = \mathbb{E}(X^2 - 2\mathbb{E}(X)X + \mathbb{E}(X)^2) = \mathbb{E}(X^2) - 2\mathbb{E}(X)^2 + \mathbb{E}(X)^2 = \mathbb{E}(X^2) - \mathbb{E}(X)^2.$$

若 X 非负, 结合**Proposition 2.4.3.**的结果, 取 $\alpha = 2$ 即得

$$\text{Var}(X) = 2 \int_0^{+\infty} x \mathbb{P}(X > x) dx - \mathbb{E}(X)^2.$$

□

我们接着说明方差的性质.

Proposition 2.4.6.(方差的二阶线性) 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, X 是其上的随机变量, 使得 1, 2 阶矩存在, 则方差有二阶线性

$$\text{Var}(\lambda X + \mu Y) = \lambda^2 \text{Var}(X) + \mu^2 \text{Var}(Y) + 2\lambda\mu (\mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y)).$$

特别地

$$\text{Var}(\lambda X + \mu) = \lambda^2 \text{Var}(X),$$

进而常数的方差为 0.

Proof. 根据定义

$$\text{Var}(\lambda X + \mu Y) = \mathbb{E}((\lambda X + \mu Y - \mathbb{E}(\lambda X + \mu Y))^2).$$

根据期望的线性 **Proposition 2.4.1.**

$$\mathbb{E}((\lambda(X - \mathbb{E}(X)) + \mu(Y - \mathbb{E}(Y)))^2),$$

展开得

$$\mathbb{E}(\lambda^2(X - \mathbb{E}(X))^2 + \mu^2(Y - \mathbb{E}(Y))^2 + 2\lambda\mu(X - \mathbb{E}(X))(Y - \mathbb{E}(Y))).$$

再次用线性变为

$$\lambda^2\mathbb{E}((X - \mathbb{E}(X))^2) + \mu^2\mathbb{E}((Y - \mathbb{E}(Y))^2) + 2\lambda\mu\mathbb{E}((X - \mathbb{E}(X))(Y - \mathbb{E}(Y))).$$

前两个期望恰好就是 $\text{Var}(X)$ 和 $\text{Var}(Y)$ 的定义, 最后一个期望展开得

$$\mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y) - \mathbb{E}(Y)\mathbb{E}(X) + \mathbb{E}(X)\mathbb{E}(Y) = \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y).$$

现在令 $Y = 1$, 则由于常数的期望是自身, 有 $Y - \mathbb{E}(Y) = 0$, 代入最后一个期望未展开的式子得

$$\lambda^2\mathbb{E}((X - \mathbb{E}(X))^2) + \mu^2\mathbb{E}(0) + 2\lambda\mu\mathbb{E}((X - \mathbb{E}(X))0) = \lambda^2\text{Var}(X).$$

再令 X 为常数即知方差为 0. □

上述分解表明, 对两个随机变量 X, Y 而言, 交叉项的期望

$$\mathbb{E}((X - \mathbb{E}(X))(Y - \mathbb{E}(Y))) = \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y)$$

衡量了和的方差与方差的和的差异, 这是两个随机变量之间的某种关系.

Definition 2.4.4. (协方差) 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, X, Y 是其上的随机变量, 使得 X, Y 的 1, 2 阶矩存在. 如果期望

$$\mathbb{E}((X - \mathbb{E}(X))(Y - \mathbb{E}(Y))) = \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y)$$

存在, 则称为 X 与 Y 的**协方差 (covariance)**, 记作 $\text{Cov}(X, Y)$. 若 $\mathbf{X}$ 是 n 维随机向量, 两两协方差存在, 则称

$$\Sigma(\mathbf{X}) = \begin{bmatrix} \text{Cov}(X_1, X_1) & \text{Cov}(X_1, X_2) & \cdots & \text{Cov}(X_1, X_n) \\ \text{Cov}(X_2, X_1) & \text{Cov}(X_2, X_2) & \cdots & \text{Cov}(X_2, X_n) \\ \vdots & \vdots & \ddots & \vdots \\ \text{Cov}(X_n, X_1) & \text{Cov}(X_n, X_2) & \cdots & \text{Cov}(X_n, X_n) \end{bmatrix}$$

为随机向量 $\mathbf{X}$ 的协方差矩阵.

现在我们可以将方差的二阶线性写为更紧凑的形式, 分为二阶线性部分

$$\text{Var}(\lambda X + \mu) = \lambda^2 \text{Var}(X)$$

和协方差部分

$$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2 \text{Cov}(X, Y).$$

与向量内积

$$\|u + v\|^2 = \|u\|^2 + \|v\|^2 + 2u \cdot v$$

比较, 我们知道向量夹角由

$$\cos \theta = \frac{u \cdot v}{\|u\| \|v\|}$$

定义, 类似地可以认为

$$\frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)} \sqrt{\text{Var}(Y)}}$$

定义了某种意义上随机变量的夹角.

Definition 2.4.5.(相关系数) 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, X, Y 是其上的随机变量, 使得 X, Y 的 1, 2 阶矩存在. 如果期望

$$\mathbb{E} \left(\frac{X - \mathbb{E}(X)}{\sqrt{\text{Var}(X)}} \frac{Y - \mathbb{E}(Y)}{\sqrt{\text{Var}(Y)}} \right) = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)} \sqrt{\text{Var}(Y)}}$$

存在, 则称为 X 与 Y 的相关系数, 记作 $\rho(X, Y)$.

从另一个角度看, 计算

$$\frac{X - \mathbb{E}(X)}{\sqrt{\text{Var}(X)}}$$

即减掉期望作为平均, 再除掉标准差作归一化, 所得随机变量的协方差. 根据这个可以猜测, 相关系数在线性变换下是不变的, 因为线性变换只会改变期望和方差, 而不会改变随机变量的结构.

Proposition 2.4.7.(协方差和相关系数的线性) 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, X 是其上的随机变量, 使得 1, 2 阶矩存在, 则协方差具有双线性

$$\text{Cov}(\lambda X + \mu Y, Z) = \lambda \text{Cov}(X, Z) + \mu \text{Cov}(Y, Z).$$

相关系数具有双线性不变性

$$|\rho(\lambda X + \mu Y, Z)| = |\rho(X, Y)|.$$

Proof. 直接计算

$$\text{Cov}(\lambda X + \mu Y, Z) = \mathbb{E}(\lambda X Z + \mu Y Z) - \mathbb{E}(\lambda X + \mu Y)\mathbb{E}(Z).$$

根据期望的线性 **Proposition 2.4.1.** 展开得

$$\lambda \mathbb{E}(X Z) + \mu \mathbb{E}(Y Z) - \lambda \mathbb{E}(X)\mathbb{E}(Z) - \mu \mathbb{E}(Y)\mathbb{E}(Z) = \lambda \text{Cov}(X, Z) + \mu \text{Cov}(Y, Z),$$

根据对称性可知双线性. 根据方差的二阶线性 **Proposition 2.4.6.** 以及相关系数的定义可知

$$\rho(\lambda X + \mu, Y) = \frac{\text{Cov}(\lambda X + \mu, Y)}{\sqrt{\text{Var}(\lambda X + \mu)}\sqrt{\text{Var}(Y)}} = \frac{\lambda \text{Cov}(X, Y) + \mu \text{Cov}(1, Y)}{\sqrt{\lambda^2 \text{Var}(X)}\sqrt{\text{Var}(Y)}}.$$

根据协方差的定义显然任意一个为常数都导致 $c - \mathbb{E}(c) = 0$, 从而协方差为 0, 于是

$$|\rho(\lambda X + \mu, Y)| = \frac{|\lambda \text{Cov}(X, Y)|}{|\lambda|\sqrt{\text{Var}(X)}\sqrt{\text{Var}(Y)}} = |\rho(X, Y)|.$$

□

下面定理说明相关系数与夹角余弦有十分相似的性质.

Proposition 2.4.8.(相关系数的取值范围) 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, X, Y 是其上的随机变量, 使得相关系数 $\rho(X, Y)$ 存在, 则 $|\rho(X, Y)| \leq 1$.

Proof. 利用积分的 Cauchy-Schwarz 不等式 **Theorem B.6.**, 容易得到

$$\mathbb{E}(XY)^2 = \left(\int_{\Omega} X(\omega)Y(\omega)d\mathbb{P} \right)^2 \leq \int_{\Omega} X(\omega)^2 d\mathbb{P} \int_{\Omega} Y(\omega)^2 d\mathbb{P} = \mathbb{E}(X^2) \mathbb{E}(Y^2).$$

于是展开 $\text{Cov}(X, Y)^2$ 会得到

$$\mathbb{E}((X - \mathbb{E}(X))(Y - \mathbb{E}(Y)))^2 \leq \mathbb{E}(((X - \mathbb{E}(X)))^2) \mathbb{E}(((Y - \mathbb{E}(Y)))^2) = \text{Var}(X) \text{Var}(Y).$$

这就说明了

$$\rho(X, Y)^2 \leq 1 \implies |\rho(X, Y)| \leq 1.$$

□

接下来我们照例给出一些分布低阶矩的计算.

Example 2.4.2.(二项分布的期望和方差) 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, X 是其上的随机变量, 服从二项分布 $X \sim \text{Bi}(n, p)$, 则利用组合恒等式, 期望

$$\mathbb{E}(X) = \sum_{k=0}^n k C_n^k p^k (1-p)^{n-k} = np.$$

二阶矩

$$\mathbb{E}(X^2) = \sum_{k=0}^n k^2 C_n^k p^k (1-p)^{n-k} = n(n-1)p^2 + np,$$

于是方差

$$\text{Var}(X) = n(n-1)p^2 + np - (np)^2 = np(1-p).$$

Example 2.4.3.(几何分布的期望和方差) 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, X 是其上的随机变量, 服从几何分布 $X \sim \text{Ge}(p)$, 即

$$\mathbb{P}(X = k) = p(1-p)^{k-1}.$$

则期望

$$\mathbb{E}(X) = \sum_{k=1}^{\infty} kp(1-p)^{k-1} = \frac{1}{p}.$$

二阶矩

$$\mathbb{E}(X^2) = \sum_{k=1}^{\infty} k^2 p(1-p)^{k-1} = \frac{2-p}{p^2},$$

于是方差

$$\text{Var}(X) = \frac{2-p}{p^2} - \frac{1}{p^2} = \frac{1-p}{p^2}.$$

Example 2.4.4.(超几何分布的期望和方差) 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, X 是其上的随机变量, 服从超几何分布 $X \sim H(n, M, N)$

$$\mathbb{P}(X = m) = \frac{C_M^m C_{N-M}^{n-m}}{C_N^n}.$$

则期望

$$\mathbb{E}(X) = \sum_{m=1}^{\infty} m \frac{C_M^m C_{N-M}^{n-m}}{C_N^n} = \frac{M}{N}n.$$

二阶矩

$$\mathbb{E}(X^2) = \sum_{m=1}^{\infty} m^2 \frac{C_M^m C_{N-M}^{n-m}}{C_N^n} = \frac{M(M-1)n(n-1) + nM(N-1)}{N(N-1)},$$

于是方差

$$\text{Var}(X) = \frac{Mn(M-N)(n-N)}{N^2(N-1)}.$$

Example 2.4.5.(Poisson 分布的期望和方差) 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, X 是其上的随机变量, 服从 Poisson 分布 $X \sim \text{Poi}(\lambda)$

$$\mathbb{P}(X = k) = \frac{\lambda^k e^{-\lambda}}{k!}.$$

则期望

$$\mathbb{E}(X) = \sum_{k=1}^{\infty} k \frac{\lambda^k e^{-\lambda}}{k!} = \lambda \sum_{k=1}^{\infty} \frac{\lambda^{k-1} e^{-\lambda}}{(k-1)!} = \lambda.$$

二阶矩

$$\mathbb{E}(X^2) = \sum_{k=1}^{\infty} k^2 \frac{\lambda^k e^{-\lambda}}{k!} = \lambda^2 \sum_{k=2}^{\infty} \frac{\lambda^{k-2} e^{-\lambda}}{(k-2)!} + \mathbb{E}(\lambda) = \lambda^2 + \lambda,$$

于是方差

$$\text{Var}(X) = \lambda^2 + \lambda - \lambda^2 = \lambda.$$

Example 2.4.6.(1 维均匀分布的期望和方差) 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, X 是其上的随机变量, 服从均匀分布 $X \sim U(a, b)$. 则期望

$$\mathbb{E}(X) = \int_a^b \frac{x}{b-a} dx = \frac{a+b}{2}.$$

二阶矩

$$\mathbb{E}(X^2) = \int_a^b \frac{x^2}{b-a} dx = \frac{a^2 + ab + b^2}{3},$$

于是方差

$$\text{Var}(X) = \frac{a^2 + ab + b^2}{3} - \frac{a^2 + 2ab + b^2}{4} = \frac{(a-b)^2}{12}.$$

Example 2.4.7.(指数分布的期望和方差) 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, X 是其上的随机变量, 服从指数分布 $X \sim \text{Exp}(\lambda)$. 则期望

$$\mathbb{E}(X) = \int_0^{+\infty} x \lambda e^{-\lambda x} dx = \frac{1}{\lambda}.$$

二阶矩

$$\mathbb{E}(X^2) = \int_0^{+\infty} x^2 \lambda e^{-\lambda x} dx = \frac{2}{\lambda^2},$$

于是方差

$$\text{Var}(X) = \frac{2}{\lambda^2} - \frac{1}{\lambda^2} = \frac{1}{\lambda^2}.$$

Example 2.4.8. (Gamma 分布的期望和方差) 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, X 是其上的随机变量, 服从 Gamma 分布 $X \sim \Gamma(\alpha, \lambda)$. 则期望

$$\mathbb{E}(X) = \int_0^{+\infty} x e^{-\lambda x} \lambda^\alpha \frac{x^{\alpha-1}}{\Gamma(\alpha)} dx = \frac{\alpha}{\lambda}.$$

二阶矩

$$\mathbb{E}(X^2) = \int_0^{+\infty} x^2 e^{-\lambda x} \lambda^\alpha \frac{x^{\alpha-1}}{\Gamma(\alpha)} dx = \frac{\alpha(\alpha+1)}{\lambda^2},$$

于是方差

$$\text{Var}(X) = \frac{\alpha(\alpha+1)}{\lambda^2} - \frac{\alpha^2}{\lambda^2} = \frac{\alpha}{\lambda^2}.$$

Example 2.4.9. (正态分布的期望和方差) 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, X 是其上的随机变量, 服从正态分布 $X \sim N(\mu, \sigma^2)$. 则期望

$$\mathbb{E}(X) = \int_{-\infty}^{+\infty} x \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) dx = \mu.$$

二阶矩

$$\mathbb{E}(X^2) = \int_{-\infty}^{+\infty} x^2 \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) dx = \sigma^2 + \mu^2,$$

于是方差

$$\text{Var}(X) = \sigma^2 + \mu^2 - \mu^2 = \sigma^2.$$

这说明正态分布的参数恰好是期望和方差.

下面的例子计算了最常用的一个协方差和相关系数.

Example 2.4.10. (2 维正态分布的协方差) 对 **Example 2.3.5.** 给出的概率密度函数, 计算

$$\mathbb{E}(X_1 X_2) = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} \frac{x_1 x_2}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp\left(-\frac{\tilde{x}_1^2 - 2\rho\tilde{x}_1\tilde{x}_2 + \tilde{x}_2^2}{2(1-\rho^2)}\right) dx_1 dx_2.$$

换元得到

$$E(X_1 X_2) = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} \frac{(\sigma_1 \tilde{x}_1 + \mu_1)(\sigma_2 \tilde{x}_2 + \mu_2)}{2\pi\sqrt{1-\rho^2}} \exp\left(-\frac{\tilde{x}_1^2 - 2\rho\tilde{x}_1\tilde{x}_2 + \tilde{x}_2^2}{2(1-\rho^2)}\right) d\tilde{x}_1 d\tilde{x}_2.$$

利用 Gauss 积分的结果容易得到

$$\int_{-\infty}^{+\infty} e^{-(ax^2+bx+c)} dx = \int_{-\infty}^{+\infty} \exp\left(-a\left(x + \frac{b}{2a}\right)^2 + \frac{b^2}{4a} - c\right) dx = \sqrt{\frac{\pi}{a}} \exp\left(\frac{b^2}{4a} - c\right).$$

而显然有

$$\int_{-\infty}^{+\infty} (2ax + b)e^{-(ax^2+bx+c)} dx = 0,$$

于是

$$\int_{-\infty}^{+\infty} xe^{-(ax^2+bx+c)} dx = -\frac{b}{2a} \sqrt{\frac{\pi}{a}} \exp\left(\frac{b^2}{4a} - c\right).$$

代入计算内层积分

$$\mathbb{E}(X_1 X_2) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{+\infty} (\rho\sigma_1 \tilde{x}_2 + \mu_1)(\sigma_2 \tilde{x}_2 + \mu_2) \exp\left(-\frac{\tilde{x}_2^2}{2}\right) d\tilde{x}_2.$$

利用分部积分

$$\int_{-\infty}^{+\infty} x^2 e^{-ax^2} dx = -\frac{1}{2a} \int_{-\infty}^{+\infty} x dx e^{-ax^2} = \frac{1}{2a} \int_{-\infty}^{+\infty} e^{-ax^2} dx = \frac{1}{2a} \sqrt{\frac{\pi}{a}},$$

于是

$$\mathbb{E}(X_1 X_2) = \frac{1}{\sqrt{2\pi}} \left(\rho\sigma_1\sigma_2\sqrt{2\pi} + (\rho\sigma_1\mu_2 + \sigma_2\mu_1)0 + \mu_1\mu_2\sqrt{2\pi} \right) = \rho\sigma_1\sigma_2 + \mu_1\mu_2.$$

类似地边缘密度函数

$$f_{X_1}(x_1) = \int_{-\infty}^{+\infty} \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp\left(-\frac{\tilde{x}_1^2 - 2\rho\tilde{x}_1\tilde{x}_2 + \tilde{x}_2^2}{2(1-\rho^2)}\right) dx_2,$$

计算得

$$f_{X_1}(x_1) = \frac{1}{\sqrt{2\pi}\sigma_1} \exp\left(-\frac{(x_1 - \mu_1)^2}{2\sigma_1^2}\right)$$

是正态分布, 从而 $\mathbb{E}(X_1) = \mu_1$, $\text{Var}(X_1) = \sigma_1^2$. 于是协方差

$$\text{Cov}(X_1, X_2) = \mathbb{E}(X_1 X_2) - \mathbb{E}(X_1)\mathbb{E}(X_2) = \rho\sigma_1\sigma_2 + \mu_1\mu_2 - \mu_1\mu_2 = \rho\sigma_1\sigma_2$$

相关系数

$$\rho(X_1, X_2) = \frac{\text{Cov}(X_1, X_2)}{\sqrt{\text{Var}(X_1)\text{Var}(X_2)}} = \frac{\rho\sigma_1\sigma_2}{\sigma_1\sigma_2} = \rho.$$

这说明 2 维正态分布的参数 ρ 就是相关系数.

2.5 条件概率

概率论有别于一般测度论的最特殊之处在于独立和条件的概念. 独立描述了随机变量的无关性, 条件刻画了随机变量之间如何依赖. 一些联合分布区别于各自分布的乘积, 其原因就是失去了独立性. 我们从独立性的一般定义开始.

Definition 2.5.1.(独立性) 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, $A_i \in \mathcal{F} (1 \leq i \leq n)$. 称这 n 个事件**独立 (independent)** 当且仅当对任意多个的排列 $1 \leq i_1 < i_2 < \cdots < i_k \leq n$, 都有

$$\mathbb{P} \left(\bigcap_{j=1}^k A_{i_j} \right) = \prod_{j=1}^k \mathbb{P}(A_{i_j}).$$

设 $X_i (1 \leq i \leq n)$ 是 n 个随机变量, 称这 n 个随机变量独立当且仅当对任意多个的排列 $1 \leq i_1 < i_2 < \cdots < i_k \leq n$, 以及任意 Borel 集 $B_i \in \mathcal{B}$, 都有

$$\mathbb{P} \left(\bigcap_{j=1}^k X_{i_j}^{-1}(B_{i_j}) \right) = \prod_{j=1}^k \mathbb{P}(X_{i_j} \in B_{i_j}).$$

独立性的定义是对概率而言的, 而分布函数等都从概率得来, 因此独立性一定在分布函数, 密度函数, 协方差和相关系数上有所体现.

Proposition 2.5.1.(独立随机变量) 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, X, Y 是其上独立的随机变量, 当且仅当联合分布函数 $F_{X,Y}(x, y) = F_X(x)F_Y(y)$, 如果有联合密度函数, 当且仅当 $f_{X,Y}(x, y) = f_X(x)f_Y(y)$. 此时

$$\mathbb{E}(XY) = \mathbb{E}(X)\mathbb{E}(Y),$$

于是协方差和相关系数为 0.

Proof. 依照定义

$$F_{X,Y}(x, y) = \mathbb{P}(X^{-1}(-\infty, x) \cap Y^{-1}(-\infty, y)),$$

当 X, Y 独立时

$$F_{X,Y}(x, y) = \mathbb{P}(X^{-1}(-\infty, x))\mathbb{P}(Y^{-1}(-\infty, y)) = F_X(x)F_Y(y).$$

反之立即得到

$$\mathbb{P}(X^{-1}(B_1) \cap Y^{-1}(B_2)) = \mathbb{P}(X^{-1}(B_1))\mathbb{P}(Y^{-1}(B_2))$$

对 $B = (-\infty, c)$ 都成立, 而 Borel 集由这些生成, 从而在 Borel 集上也成立. 如果存在概率密度函数, 则

$$\int_{-\infty}^x \int_{-\infty}^y f_{X,Y}(x, y) dy dx = \int_{-\infty}^x f_X(x) dx \int_{-\infty}^y f_Y(y) dy$$

两边依次对 x, y 求偏导可得 $f_{X,Y}(x, y) = f_X(x)f_Y(y)$, 反之分别积分即证. 最后计算期望

$$\mathbb{E}(XY) = \int_{\mathbb{R}^2} xy f_{X,Y}(x, y) dx dy = \int_{\mathbb{R}} x f_X(x) dx \int_{\mathbb{R}} y f_Y(y) dy = \mathbb{E}(X)\mathbb{E}(Y).$$

于是协方差

$$\text{Cov}(X, Y) = \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y) = 0,$$

相应地相关系数也为 0. □

如果两个事件或随机变量不独立, 则观察到其中一个必然提供另一个的信息. 在极端的例子上, 例如从黑白两球中随机选择一个, 用 X, Y 表示黑球和白球的数量, 则在 $X = 1$ 的条件下必有 $Y = 0$. 我们首先定义事件的条件概率.

Definition 2.5.2.(条件概率) 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, $A, B \in \mathcal{F}$, 使得 $\mathbb{P}(B) > 0$, 称

$$\frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}$$

为条件 B 下事件 A 的概率, 记作 $\mathbb{P}(A | B)$.

从条件概率的角度看, 两个事件 $A, B \in \mathcal{F}$ 独立当且仅当

$$\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B) \iff \mathbb{P}(A) = \mathbb{P}(A | B) \iff \mathbb{P}(B) = \mathbb{P}(B | A).$$

条件概率相应的定义对象是随机变量, 例如

$$\mathbb{P}(X \in B_1 | Y \in B_2) = \frac{\mathbb{P}(X^{-1}(B_1) \cap Y^{-1}(B_2))}{\mathbb{P}(Y^{-1}(B_2))},$$

这与之后条件分布定义在分布函数, 条件期望定义在矩上是一致的.

如果能确定一个事件在所有互斥条件下发生的概率, 就能确定该事件发生的概率, 即所谓全概率公式.

Theorem 2.5.2.(全概率公式) 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, $A, B_k \in \mathcal{F} (1 \leq k \leq n)$, 使得对任意 $i \neq j$ 都有 $B_i \cap B_j = \emptyset$, 对任意 $1 \leq k \leq n$ 都有 $\mathbb{P}(B_k) > 0$, 以及

$$A \subseteq \bigcup_{k=1}^n B_k.$$

则有

$$\mathbb{P}(A) = \sum_{k=1}^n \mathbb{P}(B_k)\mathbb{P}(A | B_k).$$

Proof. 包含关系两边交 A 即得

$$A = \bigcup_{k=1}^n B_k \cap A.$$

两边取概率, 由于 B_k 两两不交, 有

$$\mathbb{P}(A) = \sum_{k=1}^n \mathbb{P}(B_k \cap A).$$

根据**Definition 2.5.2**即得

$$\mathbb{P}(A) = \sum_{k=1}^n \mathbb{P}(B_k) \mathbb{P}(A | B_k).$$

□

有的时候计算 $\mathbb{P}(A | B)$ 类型的概率不易, 可以通过 Bayes 定理转换为计算 $\mathbb{P}(B | A)$ 类型.

Theorem 2.5.3.(Bayes) 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, $A, B_k \in \mathcal{F} (1 \leq k \leq n)$, 使得对任意 $i \neq j$ 都有 $B_i \cap B_j = \emptyset$, 对任意 $1 \leq k \leq n$ 都有 $\mathbb{P}(B_k) > 0$ 并且 $\mathbb{P}(A) > 0$, 以及

$$A \subseteq \bigcup_{k=1}^n B_k.$$

则对任意 $1 \leq i \leq n$ 有

$$\mathbb{P}(B_i | A) = \frac{\mathbb{P}(B_i) \mathbb{P}(A | B_i)}{\sum_{k=1}^n \mathbb{P}(B_k) \mathbb{P}(A | B_k)}.$$

Proof. 根据定义有

$$\mathbb{P}(B_i | A) = \frac{\mathbb{P}(A \cap B_i)}{\mathbb{P}(A)} = \frac{\mathbb{P}(B_i) \mathbb{P}(A | B_i)}{\mathbb{P}(A)}.$$

利用**Theorem 2.5.2**的结果即得

$$\mathbb{P}(B_i | A) = \frac{\mathbb{P}(B_i) \mathbb{P}(A | B_i)}{\sum_{k=1}^n \mathbb{P}(B_k) \mathbb{P}(A | B_k)}.$$

□

作为条件概率的推广, 我们考虑条件分布, 即给定一个随机变量条件 $T \in B$ 后的概率分布

$$F(x | T \in B) = \frac{\mathbb{P}(X^{-1}(-\infty, x) \cap T^{-1}(B))}{\mathbb{P}(T^{-1}(B))}.$$

我们直接在 n 维随机向量上定义.

Definition 2.5.3.(条件分布) 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, $\mathbf{X}$ 是 n 维随机向量, $\mathbf{T}$ 是 m 维随机向量, 如果联合分布函数为 $F_{\mathbf{X}, \mathbf{T}}(\mathbf{x}, \mathbf{t})$, 对 $B \in \mathcal{B}_m$ 和任意 $\mathbf{x} \in \mathbb{R}^n$, 表达式

$$\frac{1}{\mathbb{P}(\mathbf{T} \in B)} \mathbb{P} \left(\mathbf{T}^{-1}(B) \cap \bigcap_{k=1}^n X_k^{-1}(-\infty, x_k) \right)$$

有限存在, 则称为条件 $\mathbf{T} \in B$ 下 $\mathbf{X}$ 的联合分布, 记作 $F_{\mathbf{X}}(\mathbf{x} | \mathbf{T} \in B)$.

如果联合密度函数为 $f_{\mathbf{X}, \mathbf{T}}(\mathbf{x}, \mathbf{t})$, 对 $\mathbf{t}_0 \in \mathbb{R}^m$, 在上式中取 $B \rightarrow \{\mathbf{t}_0\}$ 的极限, 根据 L'Hospital 法则, 如果

$$\frac{1}{f_{\mathbf{T}}(\mathbf{t}_0)} \int_{u_k \leq x_k} f_{\mathbf{X}, \mathbf{T}}(\mathbf{u}, \mathbf{t}_0) du_1 du_2 \cdots du_n$$

有限存在, 则称为条件 $\mathbf{T} = \mathbf{t}_0$ 下 $\mathbf{X}$ 的联合分布, 记作 $F_{\mathbf{X}}(\mathbf{x} | \mathbf{T} = \mathbf{t}_0)$. 此时相应的联合密度函数

$$f_{\mathbf{X}}(\mathbf{x} | \mathbf{T} = \mathbf{t}_0) = \frac{f_{\mathbf{X}, \mathbf{T}}(\mathbf{x}, \mathbf{t}_0)}{f_{\mathbf{T}}(\mathbf{t}_0)}.$$

全概率公式自然地推广到条件分布. 关于

$$F_{\mathbf{X}}(\mathbf{x} | \mathbf{T} \in B) = \frac{1}{\mathbb{P}(\mathbf{T} \in B)} \mathbb{P} \left(\mathbf{T}^{-1}(B) \cap \bigcap_{k=1}^n X_k^{-1}(-\infty, x_k) \right)$$

的条件分布由 **Theorem 2.5.2.** 直接得到, 而关于条件密度的则需要证明.

Theorem 2.5.4.(全概率公式) 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, $\mathbf{X}$ 是 n 维随机向量, $\mathbf{T}$ 是 m 维随机向量, 联合密度函数为 $f_{\mathbf{X}, \mathbf{T}}(\mathbf{x}, \mathbf{t})$. 则对任意 $B \in \mathcal{B}_n$, 有

$$\mathbb{P}(\mathbf{X} \in B) = \int_{\mathbb{R}^m} f_{\mathbf{T}}(\mathbf{t}) \mathbb{P}(\mathbf{X} \in B | \mathbf{T} = \mathbf{t}) dt_1 dt_2 \cdots dt_m.$$

Proof. 按照定义

$$\mathbb{P}(\mathbf{X} \in B) = \int_B f_{\mathbf{X}}(\mathbf{x}) dx_1 dx_2 \cdots dx_n,$$

根据边缘分布函数的定义上式即

$$\int_B \int_{\mathbb{R}^m} f_{\mathbf{X}, \mathbf{T}}(\mathbf{x}, \mathbf{t}) dt_1 dt_2 \cdots dt_m dx_1 dx_2 \cdots dx_n,$$

展开为

$$\int_B \int_{\mathbb{R}^m} f_{\mathbf{X}}(\mathbf{x} | \mathbf{T} = \mathbf{t}) f_{\mathbf{T}}(\mathbf{t}) dt_1 dt_2 \cdots dt_m dx_1 dx_2 \cdots dx_n.$$

根据 Fubini 定理 **Theorem B.4.** 先对 $\mathbf{x}$ 积分得

$$\int_{\mathbb{R}^m} f_{\mathbf{T}}(\mathbf{t}) \mathbb{P}(\mathbf{X} \in B | \mathbf{T} = \mathbf{t}) dt_1 dt_2 \cdots dt_m.$$

□

要注意的是, 尽管 $\mathbf{X} \mid \mathbf{T} \in B$ 有分布函数 $F_{\mathbf{X}}(\mathbf{x} \mid \mathbf{T} \in B)$, 但不直接成为随机变量, 因为原来 $\mathbf{T}(\omega) \notin B$ 的点在 $\mathbf{X} \mid \mathbf{T} \in B$ 下失去意义. 因此我们只能利用 **Theorem 2.3.1.** 和 $F_{\mathbf{X}}(\mathbf{x} \mid \mathbf{T} \in B)$ 的单调连续条件构建一个随机变量.

我们知道只有随机变量 (1 维随机向量) 能够自然地求期望和方差, 因此对随机变量 X 和 m 维随机向量 $\mathbf{T}$, 定义条件期望即随机变量 $X \mid \mathbf{T} \in B$ 的期望. 特别地, 对每个 $\mathbf{t} \in \mathbb{R}^m$, 条件期望 $\mathbb{E}(X \mid \mathbf{T} = \mathbf{t})$ 指定了一个实数, 从而成为一个关于 $\mathbf{t}$ 的实值函数 h .

Definition 2.5.4.(条件期望 I) 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, X 是随机变量, $\mathbf{T}$ 是 m 维随机向量. 对任意 $B \in \mathcal{B}_m$, 条件分布 $F_X(x \mid \mathbf{T} \in B)$ 诱导一个随机变量 $X \mid \mathbf{T} \in B$. 定义 X 在条件 $\mathbf{T} \in B$ 下的条件期望为该随机变量的期望 $\mathbb{E}(X \mid \mathbf{T} \in B)$. 特别地, 如果联合密度 $f_{X, \mathbf{T}}(x, \mathbf{t})$ 存在, 则可以绕过随机变量的构造, 直接用密度函数定义条件 $\mathbf{T} = \mathbf{t}_0$ 下 X 的期望

$$\mathbb{E}(X \mid \mathbf{T} = \mathbf{t}_0) = \int_{\mathbb{R}} x f_X(x \mid \mathbf{T} = \mathbf{t}_0) dx = \int_{\mathbb{R}} x \frac{f_{X, \mathbf{T}}(x, \mathbf{t}_0)}{f_{\mathbf{T}}(\mathbf{t}_0)} dx.$$

则 $h(\mathbf{t}) = \mathbb{E}(X \mid \mathbf{T} = \mathbf{t})$ 给出了一个实变函数, 其生成的随机变量 $h(\mathbf{T}) = \mathbb{E}(X \mid \mathbf{T})$ 称为 X 关于 $\mathbf{T}$ 的条件期望变量.

要注意, 这里虽然 $\mathbf{T}$ 是随机向量, 但条件期望 $\mathbb{E}(X \mid \mathbf{T})$ 总是随机变量.

逐点地看, 条件期望还是期望, 因此对随机变量 X 仍然具有线性.

我们看一个特殊的例子.

Example 2.5.1.(关于自身的条件期望变量) 当 $\mathbf{T} = X$ 时, 可以计算联合密度函数

$$f_{X, X}(x, y) = \frac{\partial^2}{\partial x \partial y} F_{X, X}(x, y) = \frac{\partial^2}{\partial x \partial y} \mathbb{P}(X \leq x, X \leq y) = \frac{\partial^2}{\partial x \partial y} \mathbb{P}(X \leq \min\{x, y\}).$$

利用

$$\min\{x, y\} = \frac{x + y - |x - y|}{2},$$

上式可以求导

$$\frac{\partial^2}{\partial x \partial y} F_X \left(\frac{x + y - |x - y|}{2} \right) = \frac{\partial}{\partial x} \left(f_X \left(\frac{x + y - |x - y|}{2} \right) \frac{1 + \operatorname{sgn}(x - y)}{2} \right).$$

而 sgn 在 0 处导数为 Dirac 函数 $2\delta(0)$, 因此

$$f_{X, X}(x, y) = f'_X \left(\frac{x + y - |x - y|}{2} \right) \frac{1 - \operatorname{sgn}(x - y)^2}{4} + f_X \left(\frac{x + y - |x - y|}{2} \right) \delta(x - y).$$

当 $x \neq y$ 时第一项为 0, 而 $x = y$ 时第一项是有限数, 积分后为 0, 因此可以认为

$$f_{X, X}(x, y) = f_X(\min\{x, y\})\delta(x - y).$$

代入得

$$\mathbb{E}(X | X = y) = \int_{\mathbb{R}} x \frac{f_{X,X}(x, y)}{f_X(y)} dx = \int_{\mathbb{R}} x \frac{f_X(x) \delta(x - y)}{f_X(y)} dx = \int_{\mathbb{R}} x \delta(x - y) dx = y,$$

从而 $\mathbb{E}(X | X) = X$.

这里我们看出 $\mathbb{E}(\mathbb{E}(X | X)) = \mathbb{E}(X)$, 可以推广为下述定理.

Theorem 2.5.5.(重期望公式) 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, X 是随机变量, $\mathbf{T}$ 是 m 维随机向量, 联合密度函数为 $f_{X, \mathbf{T}}(\mathbf{x}, \mathbf{t})$. 则对任意 $S \subseteq \mathbb{R}^m$, 有特征随机变量作为 $\mathbf{T}$ 的随机变量函数

$$\begin{aligned} \chi_{\mathbf{T} \in S} : \Omega &\rightarrow \mathbb{R}, \\ \omega &\mapsto \begin{cases} 1, & \mathbf{T}(\omega) \in S, \\ 0, & \text{otherwise.} \end{cases} \end{aligned}$$

则对任意 $B \in \mathcal{B}_m$, 有

$$\mathbb{E}_{\mathbf{T}}(\mathbb{E}_X(X | \mathbf{T}) \chi_{\mathbf{T} \in B}) = \mathbb{E}_{X, \mathbf{T}}(X \chi_{\mathbf{T} \in B}).$$

特别地当 $B = \mathbb{R}^m$ 时

$$\mathbb{E}_{\mathbf{T}}(\mathbb{E}_X(X | \mathbf{T})) = \mathbb{E}(X).$$

Proof. 根据**Proposition 2.4.4.**, 将 $\mathbb{E}_X(X | \mathbf{T}) \chi_{\mathbf{T} \in B}$ 视为 $\mathbf{T}$ 的函数, 有

$$\mathbb{E}_{\mathbf{T}}(\mathbb{E}_X(X | \mathbf{T}) \chi_{\mathbf{T} \in B}) = \int_{\mathbb{R}^m} h(\mathbf{t}) \chi_{\mathbf{t} \in B} f_{\mathbf{T}}(\mathbf{t}) dt_1 dt_2 \cdots dt_m,$$

代入 $h(\mathbf{t})$ 的定义

$$\mathbb{E}_{\mathbf{T}}(\mathbb{E}_X(X | \mathbf{T}) \chi_{\mathbf{T} \in B}) = \int_{\mathbb{R}^m} \left(\int_{\mathbb{R}} x \frac{f_{X, \mathbf{T}}(x, \mathbf{t})}{f_{\mathbf{T}}(\mathbf{t})} dx \right) \chi_{\mathbf{t} \in B} f_{\mathbf{T}}(\mathbf{t}) dt_1 dt_2 \cdots dt_m,$$

利用**Theorem B.5.**得到

$$\mathbb{E}_{\mathbf{T}}(\mathbb{E}_X(X | \mathbf{T}) \chi_{\mathbf{T} \in B}) = \int_{\mathbb{R}^{m+1}} x f_{X, \mathbf{T}}(x, \mathbf{t}) \chi_{\mathbf{t} \in B} dx dt_1 dt_2 \cdots dt_m = \mathbb{E}_{X, \mathbf{T}}(X \chi_{\mathbf{T} \in B}).$$

□

如果我们将公式

$$\mathbb{E}_{\mathbf{T}}(\mathbb{E}_X(X | \mathbf{T}) \chi_{\mathbf{T} \in B}) = \mathbb{E}_{X, \mathbf{T}}(X \chi_{\mathbf{T} \in B})$$

用期望的原始定义写出, 即

$$\int_{\Omega} \mathbb{E}_X(X | \mathbf{T})(\omega) \chi_{\mathbf{T} \in B}(\omega) d\mathbb{P} = \int_{\Omega} X(\omega) \chi_{\mathbf{T} \in B}(\omega) d\mathbb{P}.$$

注意到

$$\chi_{\mathbf{T} \in B}(\omega) = \begin{cases} 1, & \mathbf{T}(\omega) \in B, \\ 0, & \text{otherwise,} \end{cases}$$

可以整理为

$$\int_{\mathbf{T}^{-1}(B)} \mathbb{E}_X(X | \mathbf{T})(\omega) d\mathbb{P} = \int_{\mathbf{T}^{-1}(B)} X(\omega) d\mathbb{P}.$$

这并不依赖于随机变量 $X, \mathbf{T}$ 的联合密度函数存在, 因而给我们一种推广条件期望变量的方式.

由于当 B 遍历 $\mathcal{B}_m$ 时, $\mathbf{T}^{-1}(B)$ 构成 Ω 中的一个 σ -代数, 且是 $\mathcal{F}$ 的子 σ -代数, 如果能对任意 $\mathcal{F}$ 的子 σ -代数定义条件期望变量, 使得对该代数中的任意集合 $\mathcal{E}$ 都有

$$\int_{\mathcal{E}} \mathbb{E}_X(X | \mathbf{T})(\omega) d\mathbb{P} = \int_{\mathcal{E}} X(\omega) d\mathbb{P},$$

就能对任何 m 维随机变量 $\mathbf{T}$ 定义条件期望.

Definition 2.5.5.(条件期望 II) 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, X 是随机变量, $\mathcal{E}$ 是 $\mathcal{F}$ 的一个子 σ -代数. 根据 Radon-Nikodym 定理 [Theorem B.8.](#), 存在唯一的随机变量 Y 关于 $\mathcal{E}$ 可测, 即对任意 $B \in \mathcal{B}$, 有 $Y^{-1}(B) \in \mathcal{E}$, 且对任意 $E \in \mathcal{E}$, 满足

$$\int_E Y(\omega) d\mathbb{P} = \int_E X(\omega) d\mathbb{P},$$

称这样的 Y 是 X 关于 $\mathcal{E}$ 的条件期望, 记作 $\mathbb{E}(X | \mathcal{E})$.

特别地, 对任意 m 维随机向量 $\mathbf{T}$, 集合

$$\mathcal{E} = \{\mathbf{T}^{-1}(B) \in \mathcal{F} \mid B \in \mathcal{B}_m\}$$

自然构成 $\mathcal{F}$ 的一个子 σ -代数, 相应的条件期望变量记作 $\mathbb{E}(X | \mathbf{T})$.

注意 Y 关于 $\mathcal{E}$ 可测的条件表明 $\mathbb{E}(X | \mathcal{E})$ 一般不是平凡的 X , 因为 $X^{-1}(B)$ 只能保证在 $\mathcal{F}$ 中而未必在子 σ -代数 $\mathcal{E}$ 中. 因此条件期望可以理解为 X 在子空间上的某种投影.

由于对任意 $B \in \mathcal{B}$, $\mathbb{E}(X | \mathbf{T})(\omega) \in B$ 当且仅当 $h(\mathbf{T}(\omega)) \in B$, 当且仅当 $\omega \in \mathbf{T}^{-1}(h^{-1}(B))$, 而 h 显然是 Borel 可测的, 因此 $h^{-1}(B) \in \mathcal{B}_m$, 即 $\mathbb{E}(X | \mathbf{T})$ 是 $\mathcal{E}$ 可测的, 这就证明了 [Definition 2.5.4.](#) 中定义的条件期望与 [Definition 2.5.5.](#) 中的特殊情况是一致的.

条件期望被视为某种投影, 当然可以分离出投影部分和误差部分, 这恰好就是条件期望的方差和条件方差.

Definition 2.5.6.(条件方差) 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, X 是随机变量, $\mathbf{T}$ 是 m 维随机向量. 定义条件方差是一个随机变量, 也是一个 $\mathbf{T}$ 的函数

$$\text{Var}(X | \mathbf{T}) = \mathbb{E}((X - \mathbb{E}(X | \mathbf{T}))^2 | \mathbf{T}) = \mathbb{E}(X^2 | \mathbf{T}) - \mathbb{E}(X | \mathbf{T})^2.$$

现在我们证明分解定理.

Theorem 2.5.6.(方差的条件分解) 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, X 是随机变量, $\mathbf{T}$ 是 m 维随机向量, 则方差可以分解为条件方差的期望与条件期望的方差之和

$$\text{Var}(X) = \mathbb{E}(\text{Var}(X | \mathbf{T})) + \text{Var}(\mathbb{E}(X | \mathbf{T})).$$

Proof. 依照定义

$$\text{Var}(X) = \mathbb{E} \left((X - \mathbb{E}(X | \mathbf{T}) + \mathbb{E}(X | \mathbf{T}) - \mathbb{E}(X))^2 \right),$$

记 $h(\mathbf{T}) = \mathbb{E}(X | \mathbf{T})$, 分为两项按完全平方公式展开为

$$\mathbb{E} \left((X - h(\mathbf{T}))^2 \right) + \mathbb{E} \left((h(\mathbf{T}) - \mathbb{E}(X))^2 \right) + 2\mathbb{E}((X - h(\mathbf{T}))(h(\mathbf{T}) - \mathbb{E}(X))).$$

根据重期望公式 **Theorem 2.5.5.** 对条件方差求期望

$$\mathbb{E}(\text{Var}(X | \mathbf{T})) = \mathbb{E}_{\mathbf{T}} \left(\mathbb{E}_X \left((X - \mathbb{E}(X | \mathbf{T}))^2 | \mathbf{T} \right) \right) = \mathbb{E} \left((X - \mathbb{E}(X | \mathbf{T}))^2 \right)$$

恰为第一项, 而再次由重期望公式 $\mathbb{E}(\mathbb{E}(X | \mathbf{T})) = \mathbb{E}(X)$, 于是第二项

$$\mathbb{E} \left((h(\mathbf{T}) - \mathbb{E}(X))^2 \right) = \mathbb{E} \left((\mathbb{E}(X | \mathbf{T}) - \mathbb{E}(\mathbb{E}(X | \mathbf{T})))^2 \right) = \text{Var}(\mathbb{E}(X | \mathbf{T})).$$

最后根据重期望公式

$$\mathbb{E}((X - h(\mathbf{T}))(h(\mathbf{T}) - \mathbb{E}(X))) = \mathbb{E}_{\mathbf{T}}(\mathbb{E}_X((X - h(\mathbf{T}))(h(\mathbf{T}) - \mathbb{E}(X)) | \mathbf{T})),$$

由于内层仅对 X 求期望, 有关 $\mathbf{T}$ 的项提出, 可直接计算

$$\mathbb{E}_X((X - h(\mathbf{T}))(h(\mathbf{T}) - \mathbb{E}(X)) | \mathbf{T}) = (h(\mathbf{T}) - \mathbb{E}(X))\mathbb{E}_X(X - h(\mathbf{T}) | \mathbf{T}),$$

而

$$\mathbb{E}_X(X - h(\mathbf{T}) | \mathbf{T}) = \mathbb{E}_X(X | \mathbf{T}) - h(\mathbf{T}) = h(\mathbf{T}) - h(\mathbf{T}) = 0,$$

因此这项恒为 0. □

Chapter 3

特征函数

本章基础知识

Theorem C.1.(Fourier 变换)

Theorem C.2.(留数定理)

3.1 特征函数

计算随机变量的矩需要计算复杂的积分, 且对每个正整数给出了离散的值. 我们知道 Fourier 变换可以把离散的点编码为连续的函数, 因此我们考虑用 Fourier 变换刻画随机变量的分布.

Definition 3.1.1.(特征函数) 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, X 是其上的随机变量. 定义

$$\psi_X(t) = \mathbb{E}(e^{itX})$$

为随机变量 X 的**特征函数 (characteristic function)**. 如果 X 是连续随机变量, 密度函数为 $f_X(x)$, 则

$$\psi_X(t) = \int_{\mathbb{R}} e^{itx} f_X(x) dx$$

恰好是密度函数 $f(x)$ 的 Fourier 变换.

利用 Fourier 变换

$$f_X(x) = \frac{1}{2\pi} \int_{\mathbb{R}} e^{-itx} \psi_X(t) dt.$$

此时有

$$|\psi_X(t + \Delta t) - \psi_X(t)| \leq \int_{\mathbb{R}} |e^{i\Delta tx} - 1| f_X(x) dx$$

可知 $\psi_X(t)$ 一致连续.

特征函数显然满足

$$|\psi_X(t)| \leq \psi_X(0) = 1, \quad \psi_X(-t) = \psi_{-X}(t) = \overline{\psi_X(t)}.$$

在特征函数的语境下, 独立随机变量和会变得容易计算.

Proposition 3.1.1.(独立随机变量和的特征函数) 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, X, Y 是其上的随机变量, $\psi_X(t), \psi_Y(t)$ 为相应的特征函数, 则 $X + Y$ 的特征函数

$$\psi_{X+Y}(t) = \psi_X(t)\psi_Y(t).$$

Proof. 利用独立随机变量的期望的性质 **Proposition 2.5.1.** 有

$$\psi_{X+Y}(t) = \mathbb{E}(e^{it(X+Y)}) = \mathbb{E}(e^{itX}) \mathbb{E}(e^{itY}) = \psi_X(t)\psi_Y(t).$$

□

我们知道 Fourier 变换把原函数的卷积变为变换后函数的乘积, 因此特征函数相乘意味着 $X + Y$ 的密度函数是 $f_X * f_Y$, 积分并用 Fubini 定理换序又可得 $F_{X+Y} =$

$F_X * F_Y$, 这与 **Example 2.3.1.** 的结果是一致的. 简单地说, 独立随机变量相加, 特征函数相乘, 分布与密度卷积.

利用特征函数可以很方便地还原各阶矩. 为简便起见, 我们只证明连续随机变量的情形.

Proposition 3.1.2.(特征函数与 n 阶矩) 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, X 是其上的随机变量, $\psi_X(t)$ 为相应的特征函数, 若 X 的 n 阶矩存在, 则

$$\mathbb{E}(X^n) = i^{-n} \lim_{t \rightarrow 0} \frac{d^n}{dt^n} \psi_X(t).$$

Proof. 由各阶矩存在可知 $\psi_X(t)$ 是 n 阶一致连续可导, 于是

$$\lim_{t \rightarrow 0} \frac{d^n}{dt^n} \psi_X(t) = \int_{\mathbb{R}} \lim_{t \rightarrow 0} \frac{d^n}{dt^n} e^{itx} f_X(x) dx = i^n \int_{\mathbb{R}} x^n f_X(x) dx = i^n \mathbb{E}(X^n).$$

□

关于特征函数和分布函数的关系, 以下定理是重要的. 我们采用 Lebesgue-Stieljes 积分记号

$$\int_{\Omega} \varphi(X(\omega)) \mathbb{P}(d\omega) = \int_{\mathbb{R}} \varphi(x) dF_X(x).$$

Theorem 3.1.3.(Laha-Rohatgi) 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, X 是其上的随机变量, 概率分布函数为 $F_X(x)$, 相应的特征函数为 $\psi_X(t)$. 则对任意 $x_1 < x_2$, 有

$$\mathbb{P}(x_1 < X < x_2) + \frac{\mathbb{P}(X = x_1) + \mathbb{P}(X = x_2)}{2} = \lim_{T \rightarrow +\infty} \frac{1}{2\pi} \int_{-T}^T \frac{e^{-itx_1} - e^{-itx_2}}{it} \psi_X(t) dt.$$

Proof. 代入得极限号内是

$$\frac{1}{2\pi} \int_{-T}^T \int_{-\infty}^{+\infty} \frac{e^{-itx_1} - e^{-itx_2}}{it} e^{itx} dF_X(x) dt.$$

被积函数有估计

$$\left| \frac{e^{it(x-x_1)} - e^{it(x-x_2)}}{it} \right| = \left| \int_{x_1}^{x_2} e^{-itu} du \right| \leq \int_{x_1}^{x_2} du = x_2 - x_1,$$

这表明原积分有估计

$$\frac{1}{2\pi} \int_{-T}^T \int_{-\infty}^{+\infty} (x_2 - x_1) dF_X(x) dt = \frac{T}{\pi} (x_2 - x_1)$$

收敛, 于是由 Fubini 定理 **Theorem B.4.** 可以换序为

$$\frac{1}{2\pi} \int_{-\infty}^{+\infty} \int_{-T}^T \frac{e^{-itx_1} - e^{-itx_2}}{it} e^{itx} dt dF_X(x).$$

将指数展开为三角函数, 注意到积分区间对称, 只有偶函数部分非零, 于是内层积分即

$$\int_{-T}^T \frac{e^{-itx_1} - e^{-itx_2}}{it} e^{itx} dt = 2 \int_0^T \frac{\sin t(x - x_1) - \sin t(x - x_2)}{t} dt.$$

为了进一步将极限号搬到积分内, 注意到上式有估计

$$\begin{aligned} \left| 2 \int_0^T \frac{\sin t(x - x_1) - \sin t(x - x_2)}{t} dt \right| &\leq 2 \left(\left| \int_0^T \frac{\sin t(x - x_1)}{t} dt \right| + \left| \int_0^T \frac{\sin t(x - x_2)}{t} dt \right| \right) \\ &= 2 \left(\left| \int_0^{T(x-x_1)} \frac{\sin t}{t} dt \right| + \left| \int_0^{T(x-x_2)} \frac{\sin t}{t} dt \right| \right) \\ &\leq 4 \int_0^\pi \frac{\sin t}{t} dt \end{aligned}$$

关于 T 一致有界, 于是根据有界收敛定理 **Theorem B.3**, 极限可交换, 右边变为

$$\frac{1}{\pi} \int_{-\infty}^{+\infty} \left(\lim_{T \rightarrow +\infty} \int_0^T \frac{\sin t(x - x_1) - \sin t(x - x_2)}{t} dt \right) dF_X(x).$$

根据 Dirichlet 核的性质, 内层积分取极限在 (x_1, x_2) 上结果为 π , 而在端点处为 $\pm \frac{\pi}{2}$, 外部为 0, 于是计算可得上式即

$$\int_{x_1 < x < x_2} dF_X(x) + \frac{1}{2} \int_{x=x_1, x=x_2} dF(x),$$

也即

$$\mathbb{P}(x_1 < X < x_2) + \frac{\mathbb{P}(X = x_1) + \mathbb{P}(X = x_2)}{2}.$$

□

由此可以证明分布函数与特征函数的一一对应关系.

Theorem 3.1.4.(唯一性定理) 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, X, Y 是其上的随机变量, 则概率分布函数 $F_X(x) = F_Y(x)$ 当且仅当相应的特征函数 $\psi_X(t) = \psi_Y(t)$.

Proof. 根据特征函数的定义可知必要性. 注意到分布函数是单调函数, 因此其不连续点至多可数, 从而是 $\mathbb{R}$ 上的零测集, 进而端点连续的开区间 (x_1, x_2) 的生成 σ -代数恰好是 $\mathcal{B}$. 根据 **Theorem 3.1.3** 可知, 在这些区间上满足

$$F_X(x_2) - F_X(x_1) = F_Y(x_2) - F_Y(x_1),$$

进而生成的 σ -代数上也有分布函数相同.

□

我们给出常见分布的特征函数.

Example 3.1.1.(Bernoulli 分布的特征函数) $n = 1$ 的二项分布 $X \sim \text{Bi}(1, p)$ 称为 Bernoulli 分布, 容易看出

$$\mathbb{P}(X = 0) = 1 - p, \quad \mathbb{P}(X = 1) = p.$$

于是定义 $\delta_{x_0}(x)$ 表示在 x_0 一点处由 0 突越为 1 的分布函数, 则 Bernoulli 分布的分布函数

$$F(x) = (1 - p)\delta_0 + p\delta_1.$$

依照离散随机变量期望的计算方式 **Proposition 2.4.2.**, 特征函数

$$\psi(t) = (1 - p)e^0 + pe^{it} = 1 + p(e^{it} - 1)$$

是光滑函数.

Example 3.1.2.(几何分布的特征函数) 几何分布 $X \sim \text{Ge}(p)$ 是离散分布, 其分布函数

$$F(x) = \sum_{n=0}^{\infty} (1 - p)^n p \delta_n(x).$$

于是特征函数

$$\psi(t) = \sum_{n=0}^{\infty} (1 - p)^n p e^{itn} = \frac{p}{1 - (1 - p)e^{it}}.$$

Example 3.1.3.(Poisson 分布) Poisson 分布 $X \sim \text{Poi}(\lambda)$ 是离散分布, 分布函数

$$F(x) = \sum_{n=0}^{\infty} \frac{\lambda^n e^{-\lambda}}{n!} \delta_n(x).$$

于是特征函数

$$\psi(t) = \sum_{n=0}^{\infty} \frac{\lambda^n e^{-\lambda}}{n!} e^{itn} = e^{-\lambda} \sum_{n=0}^{\infty} \frac{(\lambda e^{it})^n}{n!} = \exp(\lambda(e^{it} - 1)).$$

如果有 n 个独立 Poisson 分布 $X_1, X_2, \dots, X_n$, 参数为 $\lambda_1, \lambda_2, \dots, \lambda_n$, 则和 $S = X_1 + X_2 + \dots + X_n$ 的特征函数

$$\psi_S(t) = \prod_{k=1}^n \exp(\lambda_k(e^{it} - 1)) = \exp\left(\left(\sum_{k=1}^n \lambda_k\right)(e^{it} - 1)\right),$$

根据特征函数与分布函数的一一对应关系, S 只能是参数为 $\lambda = \lambda_1 + \lambda_2 + \dots + \lambda_n$ 的 Poisson 分布.

Example 3.1.4.(1 维均匀分布) 1 维均匀分布 $X \sim U(a, b)$ 的概率密度函数

$$f(x) = \begin{cases} \frac{1}{b-a}, & a \leq x \leq b, \\ 0, & \text{otherwise,} \end{cases}$$

于是特征函数

$$\psi(t) = \int_a^b \frac{1}{b-a} e^{itx} dx = \exp\left(it \frac{a+b}{2}\right) \frac{\sin \frac{t(b-a)}{2}}{\frac{t(b-a)}{2}}.$$

Example 3.1.5.(指数分布) 指数分布 $X \sim \text{Exp}(\lambda)$ 的概率密度函数

$$f(x) = \begin{cases} \lambda e^{-\lambda x}, & x \geq 0, \\ 0, & x < 0, \end{cases}$$

于是特征函数

$$\psi(t) = \int_0^{+\infty} \lambda e^{-\lambda x} e^{itx} dx = \frac{\lambda}{\lambda - it}.$$

Example 3.1.6.(Cauchy 分布) Cauchy 分布的概率密度函数

$$f(x) = \frac{1}{\pi(1+x^2)},$$

于是特征函数

$$\psi(t) = \int_{\mathbb{R}} \frac{1}{\pi(1+x^2)} e^{itx} dx.$$

当 $t > 0$ 时, 被积函数在上半平面有一阶极点 $x = i$, 相应的留数

$$\text{Res}\left(i, \frac{1}{\pi(1+x^2)} e^{itx}\right) = \frac{1}{\pi(i+i)} e^{iti} = \frac{e^{-t}}{2\pi i}.$$

于是积分结果为 e^{-t} . 同理可得 $t < 0$ 时结果为 e^t , 于是特征函数 $\psi(t) = e^{-|t|}$. 其导函数在 0 处极限不存在, 这对应了 **Example 2.4.1.** 期望不存在的结果.

Example 3.1.7.(正态分布) 正态分布 $X \sim N(\mu, \sigma^2)$ 的概率密度函数

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right).$$

于是特征函数

$$\psi(t) = \int_{\mathbb{R}} \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) e^{itx} dx = \exp\left(i\mu t - \frac{\sigma^2}{2} t^2\right).$$

Chapter 4

随机变量序列

本章基础知识

Theorem D.1.(Chebyshev) 给定 $\alpha > 0$, 设 $(\Omega, \mathcal{F}, P)$ 是概率空间, X 是其上的随机变量, $\varphi(x)$ 是在 $(0, +\infty)$ 上非负严格单调上升的偶函数, 使得 $\varphi(X)$ 的数学期望存在, 则对任意 $\varepsilon > 0$, 有不等式

$$P(|X| \geq \varepsilon) \leq \frac{E(\varphi(X))}{\varphi(\varepsilon)}.$$

特别地, 取随机变量 X 为 $X - E(X)$, $\varphi(x) = x^2$, 则有

$$P(|X - E(X)| \geq \varepsilon) \leq \frac{D(X)}{\varepsilon^2}.$$

Proof. 按期望的定义

$$\begin{aligned} E(\varphi(x)) &= \int_{-\infty}^{+\infty} \varphi(x) dF(x) \\ &\geq \int_{|x| \geq \varepsilon} \varphi(x) dF(x) \\ &\geq \int_{|x| \geq \varepsilon} \varphi(\varepsilon) dF(x) \\ &= \varphi(\varepsilon) P(|X| \geq \varepsilon). \end{aligned}$$

□

Theorem D.2.(Jensen)

4.1 随机变量序列的收敛

在这一章中, 我们开始考虑随机变量序列. 一个随机变量可以视为一次随机试验的结果, 那么一个随机变量序列就是进行充分多次试验之后, 观察其总体上的表现. 从朴素的数学观我们知道, 同一种随机试验进行足够多次后, 其平均会接近其真实分布的平均, 即所谓噪声被抵消了. 我们就要在这一章刻画这些总体现象.

所谓平均只能基于有限项定义, 因此我们实际上考虑的是

$$S_n = \sum_{k=1}^n X_k, \quad \bar{X}_n = \frac{1}{n} \sum_{k=1}^n X_k$$

的极限. 为此, 我们需要首先刻画随机变量序列的收敛. 由于随机变量是测度空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 到 $\mathbb{R}$ 的可测函数, 因此这一收敛性就是可测函数列的收敛性.

Definition 4.1.1.(随机变量序列的收敛) 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, X_n 是其上的随机变量序列, X 是一个随机变量, 分别有分布函数 F_n 和 F .

1. 如果存在零测集 $N \subseteq \Omega$, 使得对任意 $\omega \in \Omega \setminus N$, 都有

$$\lim_{n \rightarrow \infty} X_n(\omega) = X(\omega),$$

称 $\{X_n\}$ **几乎处处** (almost everywhere, a.e.) 收敛到 X .

2. 如果对任意 $\varepsilon > 0$, 有

$$\lim_{n \rightarrow \infty} \mathbb{P}(\{\omega \in \Omega \mid |X_n(\omega) - X(\omega)| < \varepsilon\}) = 1,$$

称 $\{X_n\}$ **依概率** (in probability, pr.) 收敛到 X .

3. 如果对给定的 $\alpha > 0$, 有

$$\lim_{n \rightarrow \infty} \mathbb{E}(|X_n - X|^\alpha) = 0,$$

称 $\{X_n\}$ 为 L^α 收敛或 α 阶矩收敛到 X .

4. 如果对任意 $F(x)$ 的连续点 $x \in \mathbb{R}$, 都有

$$\lim_{n \rightarrow \infty} F_n(x) = F(x),$$

则称 X_n **依分布** (in distribution, dist.) 收敛到 $F(x)$.

$F(x)$ 作为概率分布函数只有可数个不连续点, 从而在一个零测集上不连续, 因此以上的收敛都是非平凡的.

Theorem 4.1.1.(几乎处处收敛的概率刻画) 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, X_n 是其上的随机变量序列, X 是一个随机变量. 则 $\{X_n\}$ 几乎处处收敛到 X 当且仅当对任意 $\varepsilon > 0$, 有

$$\lim_{m \rightarrow \infty} \mathbb{P}(\{\omega \in \Omega \mid |X_n(\omega) - X(\omega)| < \varepsilon, n \geq m\}) = 1.$$

特别地, $\{X_n\}$ 依概率收敛到 X .

Proof. (必要性) 定义

$$A_m(\varepsilon) = \bigcap_{n=m}^{\infty} \{|X_n - X| < \varepsilon\}.$$

则这是一个单调上升的集合序列, 依照几乎处处收敛的定义, 对任意 $\omega \in \Omega \setminus N$, 存在 $m(\omega, \varepsilon) \in \mathbb{N}^*$, 使得对任意 $n \geq m(\omega, \varepsilon)$, 都有 $|X_n(\omega) - X(\omega)| < \varepsilon$. 于是任意 $\omega \in \Omega \setminus N$ 都在某个 $A_{m(\omega, \varepsilon)}(\varepsilon)$ 中, 于是

$$\Omega \setminus N \subseteq \bigcup_{m=1}^{\infty} A_m(\varepsilon).$$

利用概率的连续性和单调性可得

$$\mathbb{P}(\Omega \setminus N) \leq \mathbb{P}\left(\bigcup_{m=1}^{\infty} A_m(\varepsilon)\right) = \lim_{m \rightarrow \infty} \mathbb{P}(A_m(\varepsilon)) \leq 1,$$

注意到 N 是零测集, 于是 $\mathbb{P}(\Omega \setminus N) = 1$, 这就证明了

$$\lim_{m \rightarrow \infty} \mathbb{P}(A_m(\varepsilon)) = 1.$$

(充分性) 定义

$$A(\varepsilon) = \bigcup_{m=1}^{\infty} A_m(\varepsilon),$$

则同样根据连续性可得 $\mathbb{P}(A(\varepsilon)) = 1$. 对任意 $\omega \in A(\varepsilon)$, 按定义和单调上升, 存在一个 $m(\omega, \varepsilon) \in \mathbb{N}^*$, 当 $n \geq m(\omega, \varepsilon)$ 时, 有 $\omega \in A_n(\varepsilon)$, 即 $|X_n(\omega) - X(\omega)| < \varepsilon$. 现在取

$$\varepsilon = \frac{1}{p}, \quad A = \bigcap_{p=1}^{\infty} A\left(\frac{1}{p}\right),$$

则根据连续性

$$\mathbb{P}(A) = \lim_{p \rightarrow \infty} \mathbb{P}\left(A\left(\frac{1}{p}\right)\right) = 1,$$

这说明 $N = \Omega \setminus A$ 是零测集, 且对任意 $\omega \in \Omega \setminus N = A$ 和任意 $\varepsilon > 0$, 根据交集的性质必有

$$\omega \in A\left(\frac{1}{[\varepsilon^{-1}] + 1}\right),$$

这说明只要 $n > m(\omega, ([\varepsilon^{-1}] + 1)^{-1})$, 就有

$$|X_n(\omega) - X(\omega)| < \frac{1}{[\varepsilon^{-1}] + 1} < \varepsilon.$$

□

L^α 收敛蕴含依概率收敛.

Theorem 4.1.2. (L^α 收敛蕴含依概率收敛) 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, X_n 是其上的随机变量序列, X 是一个随机变量或常数. 如果 $\{X_n\}$ 按 L^α 收敛到 X , 则 $\{X_n\}$ 依概率收敛到 X .

Proof. 在 Chebyshev 不等式 **Theorem D.1.** 中取随机变量为 $X_n - X$, $\varphi(x) = |x|^\alpha$, 即得

$$\mathbb{P}(|X_n - X| \geq \varepsilon) \leq \frac{\mathbb{E}(|X_n - X|^\alpha)}{\varepsilon^\alpha}.$$

按照 L^α 收敛的定义, 取极限即得

$$\lim_{n \rightarrow \infty} \mathbb{P}(|X_n - X| \geq \varepsilon) = 0.$$

□

4.2 大数定律

现在我们开始研究 $\bar{X}_n$ 的收敛性质, 即所谓的大数定律. 这里我们特别注明, 如果随机变量不独立, 例如当 $X_k = n$ 时, 固定下一个随机变量 $X_{k+1} = 2n$, 则 $\bar{X}_n$ 当然不收敛. 因此总体性质一定是对一些特殊的随机变量序列成立.

简而言之, 大数定律和中心极限定理是一个定义, 某些特殊的随机变量序列满足大数定律或中心极限定理才是一个定理.

Definition 4.2.1.(大数定律) 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, X_n 是其上的随机变量序列, 定义随机变量

$$\bar{X}_n = \frac{1}{n} \sum_{k=1}^n X_k.$$

如果 $\bar{X}_n$ 依概率收敛到 $\mathbb{E}(\bar{X}_n)$, 则称 $\{X_n\}$ 满足**弱大数定律** (weak law of large numbers). 如果 $\bar{X}_n$ 几乎处处收敛到 $\mathbb{E}(\bar{X}_n)$, 则称 $\{X_n\}$ 满足**强大数定律** (strong law of large numbers). 显然根据**Theorem 4.1.1.**, 弱大数定律蕴含强大数定律.

从历史上看, 最经典的大数定律是 Bernoulli 大数定律, 描述了 Bernoulli 分布随机变量序列的收敛.

Theorem 4.2.1.(Bernoulli) 设 X_n 独立同 Bernoulli 分布 $\text{Bi}(1, p)$, 则 $\{X_n\}$ 满足弱大数定律.

Proof. 依照**Example 2.4.2.**可知期望

$$\mathbb{E}(\bar{X}_n) = \frac{1}{n} \sum_{k=1}^n \mathbb{E}(X_k) = \frac{np}{n} = p,$$

方差

$$\text{Var}(\bar{X}_n) = \frac{1}{n^2} \sum_{k=1}^n \text{Var}(X_k) = \frac{np(1-p)}{n^2} = \frac{p(1-p)}{n}.$$

对任意 $\varepsilon > 0$, 利用 Chebyshev 不等式**Theorem D.1.**可得

$$\mathbb{P}(|\bar{X}_n - p| \geq \varepsilon) \leq \frac{\text{Var}(\bar{X}_n)}{\varepsilon^2} = \frac{p(1-p)}{n\varepsilon^2}.$$

取极限即得

$$0 \leq \lim_{n \rightarrow \infty} \mathbb{P}(|\bar{X}_n - p| \geq \varepsilon) \leq 0.$$

□

作为推广, 对一般的随机变量序列, 只要有应用 Chebshev 不等式的条件, 都可以通过以上方法证明满足弱大数定律, 这给出了以下两种大数定律.

Theorem 4.2.2.(Markov) 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, X_n 是其上的随机变量序列. 若

$$\lim_{n \rightarrow \infty} \frac{1}{n^2} \text{Var} \left(\sum_{k=1}^n X_k \right) = 0,$$

则 $\{X_n\}$ 满足弱大数定律.

Proof. 对任意 $\varepsilon > 0$, 利用 Chebyshev 不等式 **Theorem D.1.** 可得

$$\mathbb{P}(|\bar{X}_n - \mathbb{E}(\bar{X}_n)| \geq \varepsilon) \leq \frac{\text{Var}(\bar{X}_n)}{\varepsilon^2}.$$

利用随机变量方差的性质

$$\text{Var}(\bar{X}_n) = \text{Var} \left(\frac{1}{n} \sum_{k=1}^n X_k \right) = \frac{1}{n^2} \text{Var} \left(\sum_{k=1}^n X_k \right).$$

取极限即得

$$0 \leq \lim_{n \rightarrow \infty} \mathbb{P}(|\bar{X}_n - \mathbb{E}(\bar{X}_n)| \geq \varepsilon) \leq 0.$$

□

Theorem 4.2.3.(Chebyshev) 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, X_n 是其上的随机变量序列. 若 X_k 两两独立且方差 $\text{Var}(X_k)$ 一致有界, 则 $\{X_n\}$ 满足弱大数定律.

Proof. 对任意 $\varepsilon > 0$, 利用 Chebyshev 不等式 **Theorem D.1.** 可得

$$\mathbb{P}(|\bar{X}_n - \mathbb{E}(\bar{X}_n)| \geq \varepsilon) \leq \frac{\text{Var}(\bar{X}_n)}{\varepsilon^2}.$$

利用独立随机变量方差的性质和一致有界

$$\text{Var}(\bar{X}_n) = \text{Var} \left(\frac{1}{n} \sum_{k=1}^n X_k \right) = \frac{1}{n^2} \sum_{k=1}^n \text{Var}(X_k) \leq \frac{nM}{n^2} = \frac{M}{n}.$$

取极限即得

$$0 \leq \lim_{n \rightarrow \infty} \mathbb{P}(|\bar{X}_n - \mathbb{E}(\bar{X}_n)| \geq \varepsilon) \leq 0.$$

□

有时不能直接应用 Chebyshev 不等式, 但可以通过一些技巧转换为可以应用的情形. 这一技巧被称为**截断 (truncating)**.

Theorem 4.2.4.(Khinchin) 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, X_n 是其上的随机变量序列. 若 X_k 独立同分布, 且均值 $\mathbb{E}(X_k) = \mu$ 有限存在, 则 $\{X_n\}$ 满足弱大数定律.

Proof. 构造随机变量

$$Y_n(\omega) = \begin{cases} X_n(\omega), & |X_n(\omega)| \leq n, \\ 0, & |X_n(\omega)| > n. \end{cases}$$

则 $\mathbb{P}(|X_n| > n) = \mathbb{P}(X_n \neq Y_n)$. 注意到期望有限存在, 根据 **Proposition 2.4.3** 可知

$$\mathbb{E}(X_n) = \sum_{n=1}^{\infty} \mathbb{P}(|X_n| > n).$$

这里不区分下标 n 是因为独立同分布. 于是

$$\lim_{n \rightarrow \infty} \mathbb{P}(|X_n| > n) = \lim_{n \rightarrow \infty} \mathbb{P}(X_n \neq Y_n) = 0,$$

因此我们只要对 $\{Y_n\}$ 证明弱大数定律即可. 根据 Chebyshev 不等式有

$$\mathbb{P}\left(\left|\bar{Y}_n - \mathbb{E}(\bar{Y}_n)\right| \geq \varepsilon\right) \leq \frac{1}{\varepsilon^2} \text{Var}(\bar{Y}_n - \mathbb{E}(\bar{Y}_n)) = \frac{1}{n^2 \varepsilon^2} \sum_{k=1}^n \text{Var}(Y_k).$$

有估计

$$\text{Var}(Y_k) = \mathbb{E}(Y_k^2) - \mathbb{E}(Y_k)^2 \leq \mathbb{E}(Y_k^2) = \int_{|x| \leq k} x^2 dF(x).$$

为了得到一个精细的上界, 取一个数列 $\{a_n\}$, 使得

$$0 < a_n < n, \quad \lim_{n \rightarrow \infty} a_n = \infty, \quad \lim_{n \rightarrow \infty} \frac{a_n}{n} = 0,$$

例如 $a_n = [\ln n]$. 此时有

$$\begin{aligned} & \sum_{k=1}^n \int_{|x| \leq k} x^2 dF(x) \\ &= \sum_{k=1}^{a_n} \int_{|x| \leq k} x^2 dF(x) + \sum_{k=a_n+1}^n \int_{|x| \leq k} x^2 dF(x) \\ &\leq \sum_{k=1}^{a_n} a_n \int_{|x| \leq a_n} |x| dF(x) + \sum_{k=a_n+1}^n a_n \int_{|x| \leq a_n} |x| dF(x) + \sum_{k=a_n+1}^n n \int_{a_n < |x| \leq n} |x| dF(x) \\ &\leq n a_n \int_{-\infty}^{+\infty} |x| dF(x) + n^2 \int_{|x| > a_n} |x| dF(x). \end{aligned}$$

这就说明

$$\lim_{n \rightarrow \infty} \frac{1}{n^2} \sum_{k=1}^n \text{Var}(Y_k) \leq \lim_{n \rightarrow \infty} \frac{a_n}{n} \mu + \lim_{n \rightarrow \infty} \int_{|x| > a_n} |x| dF(x) = 0,$$

进而

$$\lim_{n \rightarrow \infty} \mathbb{P}\left(\left|\bar{Y}_n - \mathbb{E}(\bar{Y}_n)\right| \geq \varepsilon\right) = 0.$$

□

尽管在此情形下有强大数定律成立, 我们还是给出这个证明, 以此让读者熟悉截断法. 在正式研究强大数定律之前, 我们还要对截断法作更仔细的阐释, 这依赖于以下几个引理.

Theorem 4.2.5.(Kronecker) 设 $\{x_n\} \subseteq \mathbb{R}$, 正实数列 $\{a_n\}$ 单调上升趋于无穷, 若级数

$$\sum_{n=1}^{\infty} \frac{x_n}{a_n}$$

收敛, 则有

$$\lim_{n \rightarrow \infty} \frac{1}{a_n} \sum_{k=1}^n x_k = 0.$$

Proof. 定义

$$S_n = \sum_{k=1}^n \frac{x_k}{a_k},$$

则 $\{S_n\}$ 极限存在, 记为 S , 从而对任意 $\varepsilon > 0$, 存在 $N(\varepsilon) \in \mathbb{N}^*$, 当 $n > N(\varepsilon)$ 时, $|S_n - S| < \varepsilon$. 补充定义 $S_0 = 0$, 利用 Abel 变换可得

$$\frac{1}{a_n} \sum_{k=1}^n x_k = \frac{1}{a_n} \sum_{k=1}^n a_k (S_k - S_{k-1}) = S_n - \frac{1}{a_n} \sum_{k=1}^{n-1} (a_{k+1} - a_k) S_k.$$

由于 $\{a_n\}$ 单调上升, 有

$$\left| S - \frac{1}{a_n} \sum_{k=N(\varepsilon)+1}^{n-1} (a_{k+1} - a_k) S_k \right| = \left| \frac{1}{a_n} \sum_{k=N(\varepsilon)+1}^{n-1} (a_{k+1} - a_k) (S_k - S) + \frac{a_{N(\varepsilon)+1}}{a_n} S \right|,$$

由三角不等式上式有上界

$$\left(1 - \frac{a_{N(\varepsilon)+1}}{a_n}\right) \varepsilon + \frac{a_{N(\varepsilon)+1}}{a_n} |S|.$$

于是

$$\lim_{n \rightarrow \infty} \left| \frac{1}{a_n} \sum_{k=1}^n x_k \right| \leq \lim_{n \rightarrow \infty} \left(\left(1 - \frac{a_{N(\varepsilon)+1}}{a_n}\right) \varepsilon + \frac{a_{N(\varepsilon)+1}}{a_n} |S| \right) = \varepsilon.$$

根据 ε 的任意性即得

$$\lim_{n \rightarrow \infty} \frac{1}{a_n} \sum_{k=1}^n x_k = 0.$$

□

Theorem 4.2.6.(Kolmogorov) 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, X_n 是其上相互独立的随机变量序列, 且各项方差有限存在. 定义

$$S_n = \sum_{k=1}^n (X_k - \mathbb{E}(X_k)),$$

则对任意 $\varepsilon > 0$, 有

$$\mathbb{P}\left(\max_{1 \leq k \leq n} \{|S_k|\} \geq \varepsilon\right) \leq \frac{1}{\varepsilon^2} \sum_{k=1}^n \text{Var}(X_k).$$

Proof. 定义

$$A_0 = \emptyset, \quad A_k = \{\omega \in \Omega \mid |S_k(\omega)| \geq \varepsilon\},$$

而 B_k 为 $\Omega \setminus A_i (0 \leq i \leq k-1)$ 与 A_k 之交集, 则

$$A = \left\{\omega \in \Omega \mid \max_{1 \leq k \leq n} \{|S_k(\omega)|\} \geq \varepsilon\right\} = \sum_{k=1}^n B_k.$$

于是

$$\mathbb{E}(S_n^2) \geq \mathbb{E}(S_n^2 \chi_A) = \sum_{k=1}^n \mathbb{E}((S_n - S_k + S_k)^2 \chi_{B_k}).$$

注意到 χ_{B_k} , S_k 和 $S_n - S_k$ 独立, 有

$$\mathbb{E}((S_n - S_k + S_k)^2 \chi_{B_k}) = \mathbb{E}((S_n - S_k)^2 \chi_{B_k}) + 2\mathbb{E}(S_n - S_k)\mathbb{E}(S_k \chi_{B_k}) + \mathbb{E}(S_k^2 \chi_{B_k}),$$

其中

$$\mathbb{E}(S_n - S_k) = \mathbb{E}(S_n) - \mathbb{E}(S_k) = 0 - 0 = 0.$$

从而

$$\mathbb{E}(S_n^2) \geq \sum_{k=1}^n \mathbb{E}(S_k^2 \chi_{B_k}) \geq \varepsilon^2 \sum_{k=1}^n \mathbb{P}(B_k) = \varepsilon^2 \mathbb{P}(A).$$

这就说明了

$$\mathbb{P}(A) \leq \frac{1}{\varepsilon^2} \mathbb{E}(S_n^2) = \frac{1}{\varepsilon^2} (\text{Var}(S_n) + \mathbb{E}(S_n)^2) = \frac{1}{\varepsilon^2} \text{Var}(S_n) = \frac{1}{\varepsilon^2} \sum_{k=1}^n \text{Var}(X_k).$$

□

Theorem 4.2.7.(Kolmogorov) 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, X_n 是其上相互独立的随机变量序列. 对某个定常数 $A > 0$, 定义随机变量

$$Y_n(\omega) = \begin{cases} X_n(\omega), & |X_n(\omega)| \leq A, \\ 0, & |X_n(\omega)| > A. \end{cases}$$

若级数

1.

$$\sum_{n=1}^{\infty} \mathbb{P}(|X_n| > A) = \sum_{n=1}^{\infty} \mathbb{P}(X_n \neq Y_n),$$

2.

$$\sum_{n=1}^{\infty} \mathbb{E}(Y_n),$$

3.

$$\sum_{n=1}^{\infty} \text{Var}(Y_n)$$

均收敛, 则 X_n 的级数和收敛.

Proof. 根据 **Theorem 4.2.6** 有

$$\mathbb{P} \left(\max_{n_1 \leq k \leq n_2} \left\{ \left| \sum_{j=n_1}^k (Y_j - \mathbb{E}(Y_j)) \right| \right\} \leq \frac{1}{m} \right) \geq 1 - m^2 \sum_{j=n_1}^{n_2} \text{Var}(Y_j).$$

利用方差的收敛性, 依次取极限 $n_2 \rightarrow \infty$ 和 $n_1 \rightarrow \infty$ 可得概率收敛到 1, 于是

$$\sum_{n=1}^{\infty} (Y_n - \mathbb{E}(Y_n))$$

收敛. 注意到期望也收敛, 从而求和可知级数 Y_n 收敛, 进而由于 $\mathbb{P}(X_n \neq Y_n)$ 趋于 0 可知级数 X_n 收敛. $\square$

现在我们证明第一个强大数定律.

Theorem 4.2.8. (Kolmogorov-Marcinkiewicz-Zygmund) 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, X_n 是其上相互独立的随机变量序列, 均值均为 0. 正实数列 $\{a_n\}$ 单调上升趋于无穷, $\varphi: \mathbb{R} \rightarrow \mathbb{R}$ 是非负连续偶函数, 使得 $\frac{\varphi(x)}{|x|}$ 单调上升, $\frac{\varphi(x)}{x^2}$ 单调下降, 且级数

$$\sum_{n=1}^{\infty} \frac{\mathbb{E}(\varphi(X_n))}{\varphi(a_n)}$$

收敛, 则 $\{X_n\}$ 满足强大数定律.

Proof. 构造随机变量

$$Y_n(\omega) = \begin{cases} X_n(\omega), & |X_n(\omega)| \leq a_n, \\ 0, & |X_n(\omega)| > a_n. \end{cases}$$

则由 $\frac{\varphi(x)}{x^2}$ 单调下降可得

$$\sum_{n=1}^{\infty} \mathbb{E} \left(\frac{Y_n^2}{a_n^2} \right) = \sum_{n=1}^{\infty} \int_{|x| \leq a_n} \frac{x^2}{a_n^2} dF_n(x) \leq \sum_{n=1}^{\infty} \int_{|x| \leq a_n} \frac{\varphi(x)}{\varphi(a_n)} dF_n(x),$$

利用 **Proposition 2.4.5** 放缩得

$$\sum_{n=1}^{\infty} \text{Var} \left(\frac{Y_n}{a_n} \right) \leq \sum_{n=1}^{\infty} \int_{|x| \leq a_n} \frac{\varphi(x)}{\varphi(a_n)} dF_n(x) \leq \sum_{n=1}^{\infty} \frac{\mathbb{E}(\varphi(X_n))}{\varphi(a_n)}$$

收敛. 注意到

$$|Y_n - E(Y_n)| \leq |Y_n| + |\mathbb{E}(Y_n)| \leq 2a_n \implies \left| \frac{Y_n - \mathbb{E}(Y_n)}{a_n} \right| \leq 2,$$

在 **Theorem 4.2.7** 中取 $A = 2$ 即知级数和

$$\sum_{n=1}^{\infty} \frac{Y_n - \mathbb{E}(Y_n)}{a_n}$$

收敛. 作估计

$$\sum_{n=1}^{\infty} \frac{|\mathbb{E}(Y_n)|}{a_n} = \sum_{n=1}^{\infty} \frac{1}{a_n} \left| \int_{|x| \leq a_n} x dF_n(x) \right|,$$

注意到 X_n 的均值为 0, 有

$$\sum_{n=1}^{\infty} \frac{|\mathbb{E}(Y_n)|}{a_n} = \sum_{n=1}^{\infty} \frac{1}{a_n} \left| \int_{|x| > a_n} x dF_n(x) \right| \leq \sum_{n=1}^{\infty} \int_{|x| > a_n} \frac{|x|}{a_n} dF_n(x).$$

由于 $\frac{\varphi(x)}{|x|}$ 单调上升, 有

$$\sum_{n=1}^{\infty} \frac{|\mathbb{E}(Y_n)|}{a_n} \leq \sum_{n=1}^{\infty} \int_{|x| > a_n} \frac{\varphi(x)}{\varphi(a_n)} dF_n(x) \leq \sum_{n=1}^{\infty} \frac{\mathbb{E}(\varphi(X_n))}{\varphi(a_n)}$$

收敛, 于是级数和 $\frac{Y_n}{a_n}$ 几乎处处收敛, 进而级数和 $\frac{X_n}{a_n}$ 几乎处处收敛. 利用 **Theorem 4.2.5** 可知 $\{X_n\}$ 满足强大数定律. $\square$

取 $\varphi(x) = |x|^p$ 和 $a_n = n$, 其中 $p = 2$ 的情形由 Kolmogorov 给出, $1 \leq p < 2$ 的情形由 Marcinkiewicz 和 Zygmund 给出.

以下 Kolmogorov 大数定律是 Khinchin 大数定律的推广, 也称为独立同分布大数定律.

Theorem 4.2.9.(Kolmogorov) 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, X_n 是其上的随机变量序列. 若 X_k 独立同分布, 且均值 $\mathbb{E}(X_k) = \mu$ 有限存在, 则 $\{X_n\}$ 满足强大数定律.

Proof. 构造随机变量

$$Y_n(\omega) = \begin{cases} X_n(\omega), & |X_n(\omega)| \leq n, \\ 0, & |X_n(\omega)| > n. \end{cases}$$

注意到

$$\sum_{n=1}^{\infty} \frac{\mathbb{E}(Y_n^2)}{n^2} = \sum_{n=1}^{\infty} \frac{1}{n^2} \int_{|x| \leq n} x^2 dF(x),$$

作估计

$$\begin{aligned}
 \sum_{n=1}^{\infty} \frac{1}{n^2} \int_{|x| \leq n} x^2 dF(x) &= \sum_{n=1}^{\infty} \frac{1}{n^2} \sum_{j=1}^n \int_{j-1 < |x| \leq j} x^2 dF(x) \\
 &= \sum_{j=1}^{\infty} \left(\sum_{n=j}^{\infty} \frac{1}{n^2} \int_{j-1 < |x| \leq j} x^2 dF(x) \right) \\
 &\leq \sum_{j=1}^{\infty} \left(\frac{C}{j} \int_{j-1 < |x| \leq j} |x| dF(x) \right) \\
 &\leq C\mu.
 \end{aligned}$$

根据Theorem 4.2.8.的结果即知 $\{X_n\}$ 满足强大数定律.

□

4.3 中心极限定理

大数定律给出了消除噪声后随机变量序列 X_n 的平均极限, 而在中心极限定理一节, 我们将解释被消除的噪声的分布.

Definition 4.3.1.(中心极限定理) 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, X_n 是其上的随机变量序列, 记标准正态分布的概率分布函数为 $\Phi(x)$, 随机变量

$$S_n = \frac{\sum_{k=1}^n (X_k - \mathbb{E}(X_n))}{\sqrt{\sum_{k=1}^n \text{Var}(X_k)}}.$$

如果 S_n 依分布收敛到 $\Phi(x)$, 即对任意 $x \in \mathbb{R}$, 有

$$\lim_{n \rightarrow \infty} \mathbb{P} \left(\frac{\sum_{k=1}^n (X_k - \mathbb{E}(X_n))}{\sqrt{\sum_{k=1}^n \text{Var}(X_k)}} \leq x \right) = \Phi(x),$$

则称 $\{X_n\}$ 满足中心极限定理.

同样我们从最简单的情形开始, 即独立同分布的中心极限定理.

Theorem 4.3.1.(Levy) 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, X_n 是其上独立同分布的随机变量序列, 则 $\{X_n\}$ 满足中心极限定理.

Proof. 设均值为 μ , 方差为 σ^2 , 则相当于证明

$$\lim_{n \rightarrow \infty} \mathbb{P} \left(\frac{\sum_{k=1}^n X_k - n\mu}{\sigma\sqrt{n}} \leq x \right) = \Phi(x).$$

设 $X_n - \mu$ 的特征函数为 $\psi_X(t)$, 考虑随机变量 S_n 的特征函数

$$\psi_n(t) = \mathbb{E}(\exp(itS_n)) = \mathbb{E} \left(\exp \left(it \frac{X_k - \mu}{\sigma\sqrt{n}} \right) \right)^n.$$

注意到

$$\int_{-\infty}^{+\infty} \exp \left(it \frac{X_k - \mu}{\sigma\sqrt{n}} \right) dF_X(x) = \int_{-\infty}^{+\infty} \exp \left(i \frac{t}{\sigma\sqrt{n}} (X_k - \mu) \right) dF_X(x) = \psi_X \left(\frac{t}{\sigma\sqrt{n}} \right),$$

作 Taylor 展开

$$\psi_X \left(\frac{t}{\sigma\sqrt{n}} \right) = \psi_X(0) + \frac{i\mathbb{E}(X_k - \mu)}{\sigma\sqrt{n}} t + \frac{i^2 \mathbb{E}((X_k - \mu)^2)}{2\sigma^2 n} t^2 + o \left(\frac{t^2}{n} \right),$$

计算得

$$\psi_X\left(\frac{t}{\sigma\sqrt{n}}\right) = 1 - \frac{\text{Var}(X_k - \mu)}{2\sigma^2 n} t^2 + o\left(\frac{t^2}{n}\right) = 1 - \frac{t^2}{2n} + o\left(\frac{t^2}{n}\right).$$

于是

$$\lim_{n \rightarrow \infty} \psi_n(t) = \lim_{n \rightarrow \infty} \left(1 - \frac{t^2}{2n} + o\left(\frac{t^2}{n}\right)\right)^n = \exp\left(-\frac{t^2}{2}\right).$$

根据唯一性定理 **Theorem 3.1.4.**, 极限分布的特征函数是标准正态分布的特征函数, 表明极限分布就是标准正态分布 $\Phi(x)$. $\square$

接下来我们证明最经典的 Lindeberg-Feller 中心极限定理. 为此需要一些关于收敛性的引理.

Theorem 4.3.2. 设复数列 $\{\theta_{nj}\} (1 \leq j \leq k_n, n \geq 1)$ 满足

1. $\lim_{n \rightarrow \infty} \max_{1 \leq j \leq k_n} \{|\theta_{nj}|\} = 0$,
2. 对 $n \in \mathbb{N}^*$, 序列绝对和 $\sum_{j=1}^{k_n} |\theta_{nj}|$ 一致有界 M ,
3. $\lim_{n \rightarrow \infty} \sum_{j=1}^{k_n} \theta_{nj} = \theta$ 收敛,

则

$$\lim_{n \rightarrow \infty} \prod_{j=1}^{k_n} (1 + \theta_{nj}) = e^\theta.$$

Proof. 每一项均可做展开

$$\log(1 + \theta_{nj}) = \theta_{nj} + \lambda_{nj} |\theta_{nj}|^2,$$

累加可得

$$\sum_{j=1}^{k_n} \log(1 + \theta_{nj}) - \theta = \left(\sum_{j=1}^{k_n} \theta_{nj} - \theta \right) + \sum_{j=1}^{k_n} \lambda_{nj} |\theta_{nj}|^2,$$

作估计

$$|\log(1 + \theta_{nj}) - \theta_{nj}| = \left| \sum_{m=2}^{\infty} \frac{(-1)^{m-1}}{m} \theta_{nj}^m \right| \leq \sum_{m=2}^{\infty} \frac{|\theta_{nj}|^m}{m}.$$

注意 θ_{nj} 一致收敛于 0, 于是当 $n \geq n_0$ 充分大时, 有 $|\theta_{nj}| < \frac{1}{2}$, 于是进一步有

$$\sum_{m=2}^{\infty} \frac{|\theta_{nj}|^m}{m} \leq \frac{|\theta_{nj}|^2}{2} \sum_{m=2}^{\infty} \left(\frac{1}{2}\right)^{m-2} = |\theta_{nj}|^2,$$

这表明 λ_{nj} 有界 1. 作估计

$$\left| \sum_{j=1}^{k_n} \lambda_{nj} |\theta_{nj}|^2 \right| \leq \max_{1 \leq k \leq k_n} \{|\lambda_{nk}|\} \max_{1 \leq k \leq k_n} \{|\theta_{nk}|\} \sum_{j=1}^{k_n} |\theta_{nj}| \leq M \max_{1 \leq k \leq k_n} \{|\theta_{nk}|\},$$

因而由控制收敛可知收敛到 0. 在

$$\sum_{j=1}^{k_n} \log(1 + \theta_{nj}) - \theta = \left(\sum_{j=1}^{k_n} \theta_{nj} - \theta \right) + \sum_{j=1}^{k_n} \lambda_{nj} |\theta_{nj}|^2$$

两边同时取极限即得

$$\lim_{n \rightarrow \infty} \sum_{j=1}^{k_n} \log(1 + \theta_{nj}) = \theta \iff \lim_{n \rightarrow \infty} \prod_{j=1}^{k_n} (1 + \theta_{nj}) = e^\theta.$$

□

Theorem 4.3.3.(Liapounov) 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, $X_{nj}(1 \leq j \leq k_n)$ 是其上的随机变量阵列, 其中当 $n \rightarrow \infty$ 有 $k_n \rightarrow \infty$, 各行内随机变量独立, 满足

$$\sum_{j=1}^{k_n} \text{Var}(X_{nj}) = 1, \quad \mathbb{E}(X_{nj}) = 0,$$

且 $\mathbb{E}(|X_{nj}|^3)$ 有限存在, 以及

$$\lim_{n \rightarrow \infty} \sum_{j=1}^{k_n} \mathbb{E}(|X_{nj}|^3) = 0,$$

则 $\{S_n\}$ 依分布收敛到 $\Phi(x)$, 其中 $S_n = \sum_{j=1}^{k_n} X_{nj}$.

Proof. 为了应用 **Theorem 4.3.2.**, 考虑 $\psi_{nj}(t)$ 的 Taylor 展开

$$\psi_{nj}(t) = 1 - \frac{1}{2} \text{Var}(X_{nj})t^2 + \lambda_{nj} \mathbb{E}(|X_{nj}|^3)|t|^3 + o(|t|^4),$$

一次项为 0 是因为期望为 0, 对 Taylor 展开的余项估计可得 $|\lambda_{nj}| \leq \frac{1}{6}$. 取

$$\theta_{nj} = -\frac{1}{2} \text{Var}(X_{nj})t^2 + \lambda_{nj} \mathbb{E}(|X_{nj}|^3)|t|^3,$$

则

$$\max_{1 \leq j \leq k_n} \{|\theta_{nj}|\} \leq \frac{t^2}{2} \max_{1 \leq j \leq k_n} \{\text{Var}(X_{nj})\} + \max_{1 \leq j \leq k_n} \{|\lambda_{nj}|\} \max_{1 \leq j \leq k_n} \{\mathbb{E}(|X_{nj}|^3)\} |t|^3.$$

对期望的积分用 Jensen 不等式 **Theorem D.2.** 可得

$$\max_{1 \leq j \leq k_n} \left\{ \mathbb{E}(X_{nj}^2)^{\frac{3}{2}} \right\}, \max_{1 \leq j \leq k_n} \{\text{Var}(X_{nj})\}^{\frac{3}{2}} < \max_{1 \leq j \leq k_n} \left\{ \mathbb{E}(|X_{nj}|^3) \right\} \leq \sum_{j=1}^{k_n} \mathbb{E}(|X_{nj}|^3),$$

而右边收敛到 0, 于是由控制收敛可知

$$\lim_{n \rightarrow \infty} \max_{1 \leq j \leq k_n} \{|\theta_{nj}|\} = 0.$$

另一方面

$$\sum_{j=1}^{k_n} |\theta_{nj}| \leq \frac{t^2}{2} \sum_{j=1}^{k_n} \text{Var}(X_{nj}) + \frac{1}{6} \sum_{j=1}^{k_n} \mathbb{E}(|X_{nj}|^3) |t|^3,$$

右边极限为 $\frac{t^2}{2}$ 有界. 最后

$$\left| \sum_{j=1}^{k_n} \theta_{nj} + \frac{t^2}{2} \right| \leq \frac{1}{6} \sum_{j=1}^{k_n} \mathbb{E}(|X_{nj}|^3) |t|^3$$

收敛到 0, 即

$$\lim_{n \rightarrow \infty} \sum_{j=1}^{k_n} \theta_{nj} = -\frac{t^2}{2}.$$

用 **Theorem 4.3.2** 即得

$$\psi_n(t) = \prod_{j=1}^{k_n} \psi_{nj}(t) = \exp\left(-\frac{t^2}{2}\right),$$

根据唯一性定理 **Theorem 3.1.4**, 极限分布就是标准正态分布 $\Phi(x)$. □

以上给出的是标准化后的情形, 如果为进行标准化, 则要将 X_{nj} 变为

$$\frac{X_{nj} - \mathbb{E}(X_{nj})}{\sqrt{\sum_{j=1}^{k_n} \text{Var}(X_{nj})}},$$

代入得 Liapounov 条件

$$\lim_{n \rightarrow \infty} \left(\sum_{j=1}^{k_n} \text{Var}(X_{nj}) \right)^{-\frac{3}{2}} \sum_{j=1}^{k_n} \mathbb{E}(|X_{nj} - \mathbb{E}(X_{nj})|^3) = 0.$$

此时随机变量阵列不再有行内要求, 于是可以取 $X_j = X_{nj}$ 和 $k_n = n$, 使之成为随机变量序列, 即在条件

$$\lim_{n \rightarrow \infty} \left(\sum_{j=1}^n \text{Var}(X_j) \right)^{-\frac{3}{2}} \sum_{j=1}^n \mathbb{E}(|X_j - \mathbb{E}(X_j)|^3) = 0$$

下, 有 $\{X_n\}$ 满足中心极限定理.

Proposition 4.3.4. 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, $X_{nj} (1 \leq j \leq k_n)$ 是其上的随机变量阵列, 其中当 $n \rightarrow \infty$ 有 $k_n \rightarrow \infty$, 各行内随机变量独立, 满足

$$\sum_{j=1}^{k_n} \text{Var}(X_{nj}) = 1,$$

$|X_{nj}| \leq M_{nj}$ 有界几乎处处成立, 使得

$$\lim_{n \rightarrow \infty} \max_{1 \leq j \leq k_n} \{M_{nj}\} = 0,$$

则 $\{S_n - \mathbb{E}(S_n)\}$ 依分布收敛到 $\Phi(x)$, 其中 $S_n = \sum_{j=1}^{k_n} X_{nj}$.

Proof. 我们证明 **Theorem 4.3.3** 的条件. 注意到

$$\sum_{j=1}^{k_n} \mathbb{E}(|X_{nj} - \mathbb{E}(X_{nj})|^3) \leq 2 \max_{1 \leq j \leq k_n} \{M_{nj}\} \sum_{j=1}^{k_n} \text{Var}(X_{nj}) = 2 \max_{1 \leq j \leq k_n} \{M_{nj}\}$$

收敛于 0 即可. □

现在我们证明 Lindeberg-Feller 中心极限定理, 其中的关键就是 Lindeberg-Feller 条件

$$\lim_{n \rightarrow \infty} \sum_{j=1}^{k_n} \int_{|x| > \varepsilon} x^2 dF_{nj}(x) = 0.$$

一个更好的结果是, 中心极限定理和此条件仅相差一个性质, 就成为充要条件.

Definition 4.3.2. (一致渐近可忽略) 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, X_n 是其上的随机变量序列, 若对任意 $\varepsilon > 0$, 都有

$$\lim_{n \rightarrow \infty} \max_{1 \leq k \leq n} \{\mathbb{P}(|X_k| > \varepsilon)\} = 0,$$

则称随机变量序列 $\{X_k\}$ 一致渐近可忽略 (holospoudic).

Theorem 4.3.5. (Lindeberg-Feller) 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, $X_{nj} (1 \leq j \leq k_n)$ 是其上的随机变量阵列, 其中当 $n \rightarrow \infty$ 有 $k_n \rightarrow \infty$, 各行内随机变量独立, 满足

$$\sum_{j=1}^{k_n} \text{Var}(X_{nj}) = 1, \quad \mathbb{E}(X_{nj}) = 0,$$

且对任意 $\varepsilon > 0$, 有

$$\lim_{n \rightarrow \infty} \sum_{j=1}^{k_n} \int_{|x| > \varepsilon} x^2 dF_{nj}(x) = 0,$$

则随机变量序列 $\{X_n\}$ 一致渐近可忽略且满足中心极限定理.

Proof. 由 Chebyshev 不等式的证明方法可得

$$\mathbb{P}(|X_{nj}| > \varepsilon) \leq \frac{1}{\varepsilon^2} \int_{|x| > \varepsilon} x^2 dF_{nj}(x) \leq \frac{1}{\varepsilon^2} \sum_{j=1}^{k_n} \int_{|x| > \varepsilon} x^2 dF_{nj}(x),$$

于是其最大值被控制收敛到 0, 于是一致渐近可忽略. 考虑截断随机变量

$$Y_{nj} = \begin{cases} X_{nj}, & |X_{nj}| \leq \varepsilon, \\ 0, & \text{otherwise.} \end{cases}$$

记对 $1 \leq j \leq k_n$ 求和为 T_n , 则由于 $\mathbb{E}(X_{nj}) = 0$, 有

$$\mathbb{E}(Y_{nj}) = \int_{|x| \leq \varepsilon} x dF_{nj}(x) = - \int_{|x| > \varepsilon} x dF_{nj}(x).$$

从而

$$|\mathbb{E}(Y_{nj})| \leq \int_{|x| > \varepsilon} |x| dF_{nj}(x) \leq \frac{1}{\varepsilon} \int_{|x| > \varepsilon} x^2 dF_{nj}(x),$$

求和即得

$$|\mathbb{E}(T_n)| \leq \frac{1}{\varepsilon} \sum_{j=1}^{k_n} \int_{|x| > \varepsilon} x^2 dF_{nj}(x)$$

控制收敛到 0. 根据 Cauchy-Schwarz 不等式有

$$\mathbb{E}(Y_{nj})^2 \leq \int_{|x| > \varepsilon} x^2 dF_{nj}(x) \int_{|x| > \varepsilon} dF_{nj}(x) \leq \int_{|x| > \varepsilon} x^2 dF_{nj}(x).$$

于是

$$\text{Var}(Y_{nj}) = \int_{|x| \leq \varepsilon} x^2 dF_{nj}(x) - \mathbb{E}(Y_{nj})^2 \geq \int_{|x| \leq \varepsilon} x^2 dF_{nj}(x) - \int_{|x| > \varepsilon} x^2 dF_{nj}(x).$$

注意到

$$1 = \text{Var}(S_n) \geq \text{Var}(T_n) \geq \sum_{j=1}^{k_n} \int_{|x| \leq \varepsilon} x^2 dF_{nj}(x) - \sum_{j=1}^{k_n} \int_{|x| > \varepsilon} x^2 dF_{nj}(x)$$

取极限可知右边为 $1 - 0 = 1$, 于是

$$\lim_{n \rightarrow \infty} \text{Var}(T_n) = 1, \quad \lim_{n \rightarrow \infty} \mathbb{E}(T_n) = 0,$$

为了应用 [Proposition 4.3.4](#) 的结果, 我们需要把截断 $|X_{nj}| \leq \varepsilon$ 变成动态截断 $|X_{nj}| \leq \varepsilon_n = M_{nj}$, 且使得 ε_n 的极限为 0. 为此考虑条件的推论

$$\lim_{n \rightarrow \infty} m^2 \sum_{j=1}^{k_n} \int_{|x| > \frac{1}{m}} x^2 dF_{nj}(x) = 0,$$

于是可以选取适当的序列 ε_n 是某个 $\frac{1}{m}$, 使得

$$\lim_{n \rightarrow \infty} \frac{1}{\varepsilon_n^2} \sum_{j=1}^{k_n} \int_{|x| > \varepsilon_n} x^2 dF_{nj}(x) = 0.$$

这样由 **Proposition 4.3.4** 可知 $\frac{T_n - \mathbb{E}(T_n)}{\sqrt{\text{Var}(T_n)}}$ 依分布收敛到 $\Phi(x)$. 由依分布收敛的定义和 $\mathbb{E}(T_n)$ 收敛到 0 可知 $\frac{T_n}{\sqrt{\text{Var}(T_n)}}$ 依分布收敛到 $\Phi(x)$. 最后对 S_n 我们有

$$\mathbb{P}(S_n \neq T_n) \leq \mathbb{P}\left(\bigcup_{j=1}^{k_n} \{X_{nj} \neq Y_{nj}\}\right) \leq \sum_{j=1}^{k_n} \mathbb{P}(|X_{nj}| > \varepsilon_n) \leq \sum_{j=1}^{k_n} \frac{1}{\varepsilon_n^2} \int_{|x| > \varepsilon_n} x^2 dF_{nj}(x),$$

最后一个不等式是根据一致渐近可忽略而右边收敛到 0, 于是再次由依分布收敛的定义可得 $\frac{S_n}{\sqrt{\text{Var}(S_n)}}$ 依分布收敛到 $\Phi(x)$, 即随机变量序列 $\{X_n\}$ 满足中心极限定理. $\square$

类似地, 我们有随机变量序列的版本. 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, X_n 是其上的随机变量序列, 对任意 $\varepsilon > 0$, 有

$$\lim_{n \rightarrow \infty} \left(\sum_{k=1}^n \text{Var}(X_k) \right)^{-1} \sum_{k=1}^n \int_{|x| > \varepsilon} (x - \mathbb{E}(X_k))^2 dF_k(x) = 0,$$

则随机变量序列 $\{X_n\}$ 一致渐近可忽略且满足中心极限定理.

Chapter 5

随机过程

本章基础知识

Theorem E.1.

5.1 随机游走

随机变量序列可以视为若干次随机试验的结果, 即下标 k 可以视为一个依时间发展的指标, 一个自然的推广是对任何一个 (未必可数的) 时间集 $\mathcal{T} \subseteq \mathbb{R}$, 定义一系列随机变量 $X_t (t \in \mathcal{T})$, 并研究这些随机变量之间的依赖关系, 这就是随机过程.

Definition 5.1.1.(随机过程) 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, $\mathcal{T} \subseteq \mathbb{R}$ 是时间指标集. 对每个指标 $t \in \mathcal{T}$, X_t 都是 $(\Omega, \mathcal{F}, \mathbb{P})$ 上的随机变量, 则称 $\{X_t \mid t \in \mathcal{T}\}$ 是**随机过程** (stochastic process).

5.2 Poisson 过程

我们先考虑一个所谓独立增量过程, 即在不交的时间内, 随机变量的增量是独立随机变量. 这在处理流问题的时候是常见的. 例如, 客流量在一定的时间内较大, 但在两段不交的时间是彼此独立的. 类似的情况也出现在粒子放射性, 机器损坏等问题中.

一个简化的情形是不考虑峰时和谷时的流量差异, 认为在固定长度时间的平均流量都是相等的, 即平均速率关于时间是不变的, 这样的过程称为时齐的.

Example 5.2.1.(Poisson 过程) 考虑 $\mathcal{T} = [0, +\infty)$ 上的一个随机过程 X_t , 使得 X_t 只能取非负整数值, 且关于 t 单调上升, 满足以下条件.

1. 这是一个**独立增量 (independent increments)** 过程, 即对任何两段不交的时间 $[t_1, t_2]$ 和 $[s_1, s_2]$, 增量 $X_{t_2} - X_{t_1}$ 和 $X_{s_2} - X_{s_1}$ 作为随机变量是独立的.
2. 这是一个**时齐 (temporally homogeneous)** 过程, 即对不交的时间 $[t_1, t_1 + s]$ 与 $[t_2, t_2 + s]$, 增量 $X_{t_1+s} - X_{t_1}$ 和 $X_{t_2+s} - X_{t_2}$ 同分布.
3. 初值 $X_0 = 0$.
4. 当时间充分短时, 增量与时间近似成正比, 且比例系数 λ 恒定, 即

$$\mathbb{P}(X_{t+\Delta t} - X_t = 1) = \lambda \Delta t + o(\Delta t), \quad \mathbb{P}(X_{t+\Delta t} - X_t \geq 2) = o(\Delta t).$$

现在我们分析这样的随机过程的分布. 根据时齐和独立增量的条件, 令

$$P_k(t) = \mathbb{P}(X_{s+t} - X_s = k) = \mathbb{P}(X_t - X_0 = k) = \mathbb{P}(X_t = k).$$

考虑其导数

$$P'_k(t) = \lim_{\Delta t \rightarrow 0} \frac{1}{\Delta t} (\mathbb{P}(X_{t+\Delta t} = k) - \mathbb{P}(X_t = k)).$$

根据概率的可加性和独立增量条件, $\mathbb{P}(X_{t+\Delta t} = k)$ 可以分解为

$$\sum_{n=0}^k \mathbb{P}(X_t = k - n, X_{t+\Delta t} - X_t = n) = \sum_{n=0}^k \mathbb{P}(X_t = k - n) \mathbb{P}(X_{t+\Delta t} - X_t = n).$$

在 $\Delta t \rightarrow 0$ 时, 对 $n \geq 2$ 的项都有 $o(\Delta t)$, 从而变为 0, 于是上式为两项

$$\mathbb{P}(X_t = k) \mathbb{P}(X_{t+\Delta t} - X_t = 0) + \mathbb{P}(X_t = k - 1) \mathbb{P}(X_{t+\Delta t} - X_t = 1).$$

代入得

$$P'_k(t) = P_k(t) \lim_{\Delta t \rightarrow 0} \frac{1}{\Delta t} (\mathbb{P}(X_{t+\Delta t} - X_t = 0) - 1) + P_{k-1}(t) \lim_{\Delta t \rightarrow 0} \frac{1}{\Delta t} \mathbb{P}(X_{t+\Delta t} - X_t = 1).$$

注意到

$$\mathbb{P}(X_{t+\Delta t} - X_t = 1) = \lambda\Delta t + o(\Delta t),$$

第二项恰好是 $\lambda P_{k-1}(t)$. 同样有

$$\mathbb{P}(X_{t+\Delta t} - X_t = 0) = 1 - \lambda\Delta t + o(\Delta t),$$

从而第一项是 $-\lambda P_k(t)$, 即有微分方程

$$P'_k(t) = -\lambda P_k(t) + \lambda P_{k-1}(t),$$

同样道理 $k = 0$ 时有 $P'_0(t) = -\lambda P_0(t)$. 为求解这一列常微分方程组, 将这些函数编码为

$$\Phi(t, z) = \sum_{k=0}^{\infty} P_k(t) z^k \implies \frac{\partial}{\partial t} \Phi(t, z) = \sum_{k=0}^{\infty} P'_k(t) z^k = -\lambda(1-z)\Phi(t, z).$$

解此偏微分方程容易得到

$$\Phi(t, z) = C(z)e^{-\lambda(1-z)t}.$$

注意到 $t = 0$ 时, $P_0(0) = \mathbb{P}(X_0 = 0) = 1$ 而其余各项均为 0, 于是

$$\Phi(0, z) = C(z) = 1 \implies \Phi(t, z) = e^{-\lambda(1-z)t} = \sum_{k=0}^{\infty} e^{-\lambda t} \frac{(\lambda t)^k}{k!} z^k,$$

比较系数即得

$$\mathbb{P}(X_t = k) = P_k(t) = e^{-\lambda t} \frac{(\lambda t)^k}{k!}.$$

要注意在使用时齐和独立增量条件时, 由于独立同分布可以

$$\mathbb{P}(X_{s+t} - X_s = k) = \mathbb{P}(X_t - X_0 = k),$$

但不能

$$\mathbb{P}(X_s = i, X_{s+t} - X_s = j) = \mathbb{P}(X_s = i, X_t = j),$$

因为 X_s 与 X_t 未必独立. 正确的分拆应该是

$$\mathbb{P}(X_s = i, X_{s+t} - X_s = j) = \mathbb{P}(X_s = i)\mathbb{P}(X_{s+t} - X_s = j) = \mathbb{P}(X_s = i)\mathbb{P}(X_t = j).$$

上例给出的随机过程的分布是局部强度 $\lambda\Delta t$ 的 Poisson 分布, 相应地称为时齐 Poisson 过程.

Definition 5.2.1.(时齐 Poisson 过程) 一个随机过程 $\{X_t \mid t \in \mathcal{T}\}$ 称为时齐 Poisson 过程, 如果满足以下条件.

1. 这是一个独立增量过程, 即对任何两段不交的时间 $[t_1, t_2]$ 和 $[s_1, s_2]$, 增量 $X_{t_2} - X_{t_1}$ 和 $X_{s_2} - X_{s_1}$ 作为随机变量是独立的.
2. 这是一个时齐过程, 即对不交的时间 $[t_1, t_1 + s]$ 与 $[t_2, t_2 + s]$, 增量 $X_{t_1+s} - X_{t_1}$ 和 $X_{t_2+s} - X_{t_2}$ 同分布.
3. X_t 只能取非负整数值, 且关于 t 单调上升, 初值 $X_0 = 0$.
4. 在时间段 $[s, s + t]$ 内的增量 $X_{s+t} - X_s$ 服从 Poisson 分布 $\text{Poi}(\lambda t)$, 即

$$\mathbb{P}(X_{s+t} - X_s = k) = e^{-\lambda t} \frac{(\lambda t)^k}{k!}.$$

我们计算时齐 Poisson 过程的统计特征.

Proposition 5.1.1.(时齐 Poisson 过程的统计特征) 设 $\{X_t \mid t \in \mathcal{T}\}$ 为时齐 Poisson 过程, 则期望和方差 $\mathbb{E}(X_t) = \text{Var}(X_t) = \lambda t$, 协方差

$$\text{Cov}(X_s, X_t) = \lambda \min\{s, t\}.$$

Proof. 期望和方差由定义和 **Example 2.4.5.** 直接得到, 下面计算协方差, 由对称性不妨设 $s < t$, 则

$$\text{Cov}(X_s, X_t) = \mathbb{E}(X_s X_t) - \mathbb{E}(X_s) \mathbb{E}(X_t) = \mathbb{E}(X_s X_t) - \lambda^2 s t.$$

由于 X_s 与 $X_t - X_s$ 独立, 第一项

$$\mathbb{E}(X_s X_t) = \mathbb{E}(X_s^2 + X_s(X_t - X_s)) = \mathbb{E}(X_s^2) + \mathbb{E}(X_s) \mathbb{E}(X_t - X_s).$$

代入得

$$\text{Cov}(X_s, X_t) = \lambda s + (\lambda s)^2 + (\lambda s)(\lambda(t - s)) - \lambda^2 s t = \lambda s.$$

当然 $s > t$ 时为 λt , 而 $s = t$ 时退化为 $\text{Cov}(X_t, X_t) = \text{Var}(X_t) = \lambda t$, 因此

$$\text{Cov}(X_s, X_t) = \lambda \min\{s, t\}.$$

□

现在我们考虑第 n 个事件的到达时间 τ_n , 即 $\tau_n \leq t$ 表示第 n 个事件在 t 时刻前发生, 即累积发生次数 $X_t \geq n$.

Definition 5.2.2.(到达时间) 设 $\{X_t \mid t \in \mathcal{T}\}$ 为时齐 Poisson 过程, 定义随机变量 τ_n 由分布函数

$$\mathbb{P}(\tau_n \leq t) = \mathbb{P}(X_t \geq n)$$

决定, 称为时齐 Poisson 过程的到达时间变量.

现在计算到达时间的联合分布.

Theorem 5.1.2.(到达时间的联合分布) 设 $\{X_t \mid t \in \mathcal{T}\}$ 为时齐 Poisson 过程, τ_k 为到达时间变量, 则 $\tau_1, \tau_2, \dots, \tau_n$ 的联合密度函数为

$$f(t_1, t_2, \dots, t_n) = \begin{cases} \lambda^n e^{-\lambda t_n}, & 0 \leq t_1 < \dots < t_n, \\ 0, & \text{otherwise.} \end{cases}$$

Proof. 根据全概率公式 **Theorem 2.5.4.**

$$\mathbb{P}(\tau_1 \leq t_1, \tau_2 \leq t_2, \dots, \tau_n \leq t_n) = \int_{\mathbb{R}} f_{\tau_1}(s) \mathbb{P}(\tau_2 \leq t_2, \dots, \tau_n \leq t_n \mid \tau_1 = s) ds.$$

一方面, 我们计算

$$\mathbb{P}(\tau_1 \leq s) = \mathbb{P}(X_s \geq 1) = 1 - \mathbb{P}(X_s = 0) = 1 - e^{-\lambda s},$$

于是

$$f_{\tau_1}(s) = (-e^{-\lambda s})(-\lambda) = \lambda e^{-\lambda s}.$$

另一方面

$$\mathbb{P}(\tau_2 \leq t_2, \dots, \tau_n \leq t_n \mid \tau_1 = s) = \mathbb{P}(X_{t_2} \geq 2, \dots, X_{t_n} \geq n \mid X_s = 1),$$

根据时齐和独立增量条件, 这就是

$$\mathbb{P}(X_{t_2-s} \geq 1, \dots, X_{t_n-s} \geq n-1 \mid X_s = 1) = \mathbb{P}(X_{t_2-s} \geq 1, \dots, X_{t_n-s} \geq n-1),$$

也就是

$$\mathbb{P}(\tau_2 \leq t_2, \dots, \tau_n \leq t_n \mid \tau_1 = s) = \mathbb{P}(\tau_1 \leq t_2 - s, \dots, \tau_{n-1} \leq t_n - s).$$

代入得

$$\mathbb{P}(\tau_1 \leq t_1, \tau_2 \leq t_2, \dots, \tau_n \leq t_n) = \int_0^{t_1} f_{\tau_1}(s) \mathbb{P}(\tau_1 \leq t_2 - s, \dots, \tau_{n-1} \leq t_n - s) ds,$$

对 t_1 求偏导得

$$\frac{\partial}{\partial t_1} \mathbb{P}(\tau_1 \leq t_1, \tau_2 \leq t_2, \dots, \tau_n \leq t_n) = f_{\tau_1}(t_1) \mathbb{P}(\tau_1 \leq t_2 - t_1, \dots, \tau_{n-1} \leq t_n - t_1).$$

以此类推, 求第 $n-1$ 阶偏导后右边变为

$$\prod_{k=1}^{n-1} f_{\tau_1}(t_k - t_{k-1}) \mathbb{P}(\tau_1 \leq t_n - t_{n-1}),$$

其中 $t_0 = 0$. 再对 t_n 求导, 左边就是联合密度函数的定义

$$f(t_1, t_2, \dots, t_n) = \prod_{k=1}^n f_{\tau_1}(t_k - t_{k-1}) = \prod_{k=1}^n \lambda e^{-\lambda((t_k - t_{k-1}))} = \lambda^n e^{-\lambda t_n}.$$

由于其中会出现 $\tau_1 \leq t_k - t_{k-1}$ 的概率, 如果任何一个 $t_k \leq t_{k-1}$, 都会导致 $\tau_1 \leq 0$, 当然概率恒为 0, 因此密度函数只在 $0 < t_1 < \dots < t_n$ 上有定义. $\square$

另一个重要的结果是条件分布.

Proposition 5.1.3.(到达时间的条件分布) 设 $\{X_t \mid t \in \mathcal{T}\}$ 为时齐 Poisson 过程, τ_k 为到达时间变量, 则在条件 $X_t = n$ 下 $\tau_1, \tau_2, \dots, \tau_n$ 的联合密度函数为

$$f(t_1, t_2, \dots, t_n \mid X_t = n) = \begin{cases} \frac{n!}{t^n}, & 0 < t_1 < \dots < t_n \leq t, \\ 0, & \text{otherwise,} \end{cases}$$

恰好是均匀分布的顺序统计量且与强度 λ 无关.

Proof. 同样根据全概率公式 **Theorem 2.5.4.**

$$\mathbb{P}(\tau_1 \leq t_1, \dots, \tau_n \leq t_n \mid X_t = n) = \int_{\mathbb{R}} f_{\tau_1}(s \mid X_t = n) \mathbb{P}(\tau_2 \leq t_2, \dots \mid \tau_1 = s, X_t = n) ds.$$

一方面, 我们计算

$$\mathbb{P}(\tau_1 \leq s \mid X_t = n) = 1 - \frac{\mathbb{P}(X_s = 0, X_t = n)}{\mathbb{P}(X_t = n)} = 1 - \frac{\mathbb{P}(X_s = 0) \mathbb{P}(X_{t-s} = n)}{\mathbb{P}(X_t = n)},$$

代入定义得

$$\mathbb{P}(\tau_1 \leq s \mid X_t = n) = 1 - \left(\frac{t-s}{t} \right)^n,$$

于是

$$f_{\tau_1}(s \mid X_t = n) = n \frac{(t-s)^{n-1}}{t^n}.$$

另一方面同理有

$$\mathbb{P}(\tau_2 \leq t_2, \dots, \tau_n \leq t_n \mid \tau_1 = s, X_t = n) = \mathbb{P}(\tau_1 \leq t_2 - s, \dots, \tau_{n-1} \leq t_n - s \mid X_{t-s} = n-1).$$

代入并对 t_1 求偏导得

$$n \frac{(t-t_1)^{n-1}}{t^n} \mathbb{P}(\tau_1 \leq t_2 - t_1, \dots, \tau_{n-1} \leq t_n - t_1 \mid X_{t-t_1} = n-1).$$

以此类推, 求第 $n-1$ 阶偏导后变为

$$\left(\prod_{k=1}^{n-1} (n+1-k) \frac{(t-t_k)^{n-k}}{(t-t_{k-1})^{n+1-k}} \right) \mathbb{P}(\tau_1 \leq t_n - t_{n-1} \mid X_{t-t_{n-1}} = 1),$$

其中 $t_0 = 0$. 注意到

$$\mathbb{P}(\tau_1 \leq t_n - t_{n-1} \mid X_{t-t_{n-1}} = 1) = 1 - \frac{(t - t_{n-1}) - (t_n - t_{n-1})}{t - t_{n-1}} = \frac{t_n - t_{n-1}}{t - t_{n-1}}$$

再对 t_n 求导, 左边就是联合密度函数的定义

$$f(t_1, t_2, \dots, t_n) = \left(\prod_{k=1}^{n-1} (n+1-k) \frac{(t - t_k)^{n-k}}{(t - t_{k-1})^{n+1-k}} \right) \frac{1}{t - t_{n-1}} = \frac{n!}{t^n}.$$

同样道理密度函数只在 $0 < t_1 < \dots < t_n$ 上有定义.

□

5.3 Markov 过程

5.4 鞅理论