概率论讲义

minamomo

Friday 13th November, 2026

References:

[1] A Course in Probability Theory(3rd edition), Kai Lai Chung, 2001.
[2] Propability with Martingales, David Williams, 2014.
[3] 概率论 (2nd edition), 韩东, 熊德文, 2022.
[4] 概率论, 复旦大学, 1979.
[5] Real Analysis(4th edition), Royden, 2020.
[6] 应用随机过程, 韩东, 熊德文, 2023.

Marks:

1. 代数 $\mathscr{F}$, Borel 代数 $\mathscr{B}_n$, 测度 μ, 外测度 μ^*.
2. 概率空间 Ω, 概率 $\mathbb{P}$, 随机变量 X, 随机向量 $\mathbf{X}$, 分布函数 F, 密度函数 f, 期望 $\mathbb{E}$, 方差 Var, 协方差 Cov, 相关系数 ρ, 特征函数 $\psi(t)$.
3. 二项分布 $\mathrm{Bi}(n,p)$, 几何分布 $\mathrm{Ge}(p)$, 超几何分布 $\mathrm{H}(n,M,N)$, Poisson 分布 $\mathrm{Poi}(\lambda)$, 均匀分布 $U(a,b)$, 指数分布 $\mathrm{Exp}(\lambda)$, Gamma 分布 $\Gamma(\alpha,\lambda)$, 正态分布 $N(\mu,\sigma^2)$.
4. 条件概率 $\mathbb{P}(A \mid B)$, 条件分布 $F(x \mid \mathbf{T} \in B)$, 条件密度 $f(x \mid \mathbf{T} = \mathbf{t}_0)$, 条件期望 $\mathbb{E}(X \mid \mathbf{T})$, 条件方差 $\mathrm{Var}(X \mid \mathbf{T})$.
5. 独立同分布 i.i.d., 几乎处处 a.e./a.s., 依概率 pr., 依分布 dist.

1. 定义 **Definition**.
2. 定理 **Theorem**.
3. 例题 **Example**.
4. 习题 **Exercise**.

Preface

本讲义是原先概率论讲义的重制, 主要是引入了概率论的测度化定义.

概率论所研究对象是以各种形式给出的分布, 包括概率 P, 分布 F 以及密度 f, 连同分布的各种特征, 包括期望 $\mathbb{E}$, 方差 Var, 协方差 Cov 等.

minamomo

2026.9 于中国上海

This page intentionally left blank.

Contents

1 测度论 **7**

1.1 σ 环与 σ 代数 10

1.2 σ-代数上的测度 12

1.3 测度的 Caratheodory 理论 * 16

2 初等概率论 **23**

2.1 概率空间 25

2.2 随机变量与分布函数 27

2.3 随机向量与分布函数 37

2.4 随机变量的矩 43

2.5 条件概率 56

3 特征函数 **65**

3.1 特征函数 66

4 随机变量序列 **71**

4.1 随机变量序列的收敛 72

4.2 大数定律 75

4.3 中心极限定理 83

5 随机过程 **91**

5.1 随机游走 92

5.2 Poisson 过程 100

5.3 Markov 过程 108

5.4 鞅理论 124

This page intentionally left blank.

Chapter 1

测度论

本章基础知识

Theorem A.1.(De Morgan) 设 $A_k \subseteq X (k \in \mathbb{N}^*)$ 是一列子集, 则有

$$\bigcap_{k=1}^{\infty} A_k = X \setminus \bigcup_{k=1}^{\infty} (X \setminus A_k),$$

$$\bigcup_{k=1}^{\infty} A_k = X \setminus \bigcap_{k=1}^{\infty} (X \setminus A_k).$$

Proof. 设

$$x \in \bigcap_{k=1}^{\infty} A_k,$$

则对任意 $k \in \mathbb{N}^*$, 有 $x \in A_k$, 于是 $x \notin X \setminus A_k$, 则

$$x \notin \bigcup_{k=1}^{\infty} (X \setminus A_k),$$

此即

$$x \in X \setminus \bigcup_{k=1}^{\infty} (X \setminus A_k).$$

再设

$$x \in X \setminus \bigcup_{k=1}^{\infty} (X \setminus A_k),$$

则对任意 $k \in \mathbb{N}^*$, 有 $x \notin X \setminus A_k$, 则有 $x \in A_k$, 进而

$$x \in \bigcap_{k=1}^{\infty} A_k,$$

这就证明了

$$\bigcap_{k=1}^{\infty} A_k = X \setminus \bigcup_{k=1}^{\infty} (X \setminus A_k).$$

设

$$x \in \bigcup_{k=1}^{\infty} A_k,$$

则存在一个 $k_0 \in \mathbb{N}^*$, 使得 $x \in A_{k_0}$, 于是 $x \notin X \setminus A_{k_0}$, 则

$$x \notin \bigcap_{k=1}^{\infty} (X \setminus A_k),$$

此即

$$x \in X \setminus \bigcap_{k=1}^{\infty} (X \setminus A_k).$$

再设

$$x \in X \setminus \bigcap_{k=1}^{\infty} (X \setminus A_k),$$

则存在一个 $k_0 \in \mathbb{N}^*$, 使得 $x \notin X \setminus A_{k_0}$, 则有 $x \in A_{k_0}$, 进而

$$x \in \bigcup_{k=1}^{\infty} A_k$$

这就证明了

$$\bigcup_{k=1}^{\infty} A_k = X \setminus \bigcap_{k=1}^{\infty} (X \setminus A_k).$$

□

Theorem A.2.(ℝ 上开集的结构) 设 $G \subseteq \mathbb{R}$ 是开集, 则存在至多可数个不交开区间 $\{I_k\}_{k=1}^{\infty}$ 使得 G 是其并.

Proof. 对每个 $x \in G$, 可以构造其所在区间

$$I_x = (a_x, b_x) = (\inf\{a : (a, x) \subseteq G\}, \sup\{b : (x, b) \subseteq G\})$$

事实上, 依照定义易见 $I_x \subseteq G$, 而如果 $a_x \in G$, 则由 G 是开集可知存在邻域 $(a_x - r, a_x + r) \subseteq G$, 这就与定义的下确界矛盾, 因此 $a_x, b_x \notin G$. 现在收集

$$\mathscr{I} = \{I_x \subseteq \mathbb{R} : x \in G\},$$

则 $\mathscr{I}$ 的并恰好是 G, 且依照定义 I_x 和 I_y 只可能不交或相等. 最后只要证明可数性, 考虑 $\mathbb{Q}$ 的一个排序 $\{r_k\}_{k=1}^{\infty}$, 对每个 I_x 指定 $I_x \cap \mathbb{Q}$ 的最小下标, 给出了 $\mathscr{I}$ 到 $\mathbb{N}$ 的单射, 因此 $\mathscr{I}$ 可数. □

Definition A.1.(集合的单调性与单调极限) 设 $A_k \subseteq X(k \in \mathbb{N}^*)$ 是一列子集. 若 $A_k \subseteq A_{k+1}$ 对一切 $k \in \mathbb{N}^*$ 成立, 则称该集合列单调上升, 并称

$$\lim_{k\to\infty} A_k = \bigcup_{k=1}^{\infty} A_k$$

为该集合列的极限. 若 $A_k \supseteq A_{k+1}$ 对一切 $k \in \mathbb{N}^*$ 成立, 则称该集合列单调下降, 并称

$$\lim_{k\to\infty} A_k = \bigcap_{k=1}^{\infty} A_k$$

为该集合列的极限.

Definition A.2.(集合列的上下极限) 设 $A_k \subseteq X(k \in \mathbb{N}^*)$ 是一列子集. 定义这列子集的上极限

$$\limsup_{k\to\infty} A_k = \lim_{n\to\infty} \bigcup_{k=n}^{\infty} A_k = \bigcap_{n=1}^{\infty} \bigcup_{k=n}^{\infty} A_k$$

是所有无限次出现在 A_k 中的元素. 下极限

$$\liminf_{k\to\infty} A_k = \lim_{n\to\infty} \bigcap_{k=n}^{\infty} A_k = \bigcup_{n=1}^{\infty} \bigcap_{k=n}^{\infty} A_k$$

是所有仅不出现在有限个 A_k 中的元素.

Proposition A.3. 设 $A_k \subseteq X(k \in \mathbb{N}^*)$ 是一列子集, 则

$$\liminf_{k\to\infty} A_k \subseteq \limsup_{k\to\infty} A_k.$$

Proof. 任取

$$x \in \liminf_{k\to\infty} A_k,$$

则存在某个 $k_0 \in \mathbb{N}^*$, 使得 $x \in A_k$ 对一切 $k \geq k_0$ 都成立. 于是对任意 $n \in \mathbb{N}^*$ 有

$$x \in A_{\max\{k_0,n\}} \subseteq \bigcup_{k=n}^{\infty} A_k \implies x \in \bigcap_{n=1}^{\infty} \bigcup_{k=n}^{\infty} A_k = \limsup_{k\to\infty} A_k.$$

□

1.1 σ 环与 σ 代数

古典概率论处理离散的事件点, 且这些事件点互相排斥, 即两个事件点不会同时发生, 且所有事件点必有一个发生. 两个事件点 a, b"至少一个发生" 也是事件, 即事件 a 或 $b(a \vee b)$. 从集合论的视角看, 一个事件被视为若干事件点的集合, 这些事件点任何一个发生都认为事件发生. 两个事件 A, B 至少一个发生, 是指所有的事件点至少一个发生, 即 $A \cup B$, 两个事件 A, B 同时发生, 是指至少一个同时出现在 A 和 B 的事件点发生, 即 $A \cap B$, 一个事件不发生, 则发生的事件点在 A 的补集中.

由此我们对古典概率论做一个定义. 古典概率论处理的对象是一个离散空间 Ω 以及其上的子集族 $\mathscr{F}$, 使得 $\mathscr{F}$ 关于交集, 并集和补集封闭. 我们把这一性质抽象出来, 作为一般概率论中概率空间的基础.

Definition 1.1.1.(代数) 一个集合 X 上的**代数 (algebra)** 是 X 带有一个子集族 $\mathscr{F}$, 满足

1. (全集) $X \in \mathscr{F}$.
2. (补的封闭性) 若 $A \in \mathscr{F}$, 则 $X \setminus A \in \mathscr{F}$.
3. (并的封闭性) 若 $A_k \in \mathscr{F}(k = 1, 2, \ldots, n)$, 则

$$\bigcup_{k=1}^{n} A_k \in \mathscr{F}.$$

注意根据**Theorem A.1.**取无穷个 $A_k = \emptyset$, 有

$$\bigcap_{k=1}^{n} A_k = X \setminus \bigcup_{k=1}^{n} (X \setminus A_k) \in \mathscr{F}.$$

之所以称之为代数, 一个原因是 $(\mathscr{F}, \Delta, \cap)$ 构成含幺交换环. 首先 $\mathscr{F}$ 关于对称差 Δ 构成群, 单位元是空集 $\emptyset = X \setminus X \in \mathscr{F}$, 因为 $\emptyset \Delta \emptyset = \emptyset$, 任何集合 $A \in \mathscr{F}$ 的加法逆元是 A 自身, 因为 $A \Delta A = (A \setminus A) \Delta (A \setminus A) = \emptyset$. 其次 $\mathscr{F}$ 关于交集 $\cap$ 构成含幺交换半群, 单位元是 X, 因为 $X \cap A = A$. 最后有分配律

$$(A \Delta B) \cap C = ((A \setminus B) \cap C) \cup ((B \setminus A) \cap C),$$

$$(A \cap C) \Delta (B \cap C) = ((A \cap C) \setminus (B \cap C)) \cup ((B \cap C) \setminus (A \cap C)),$$

而显然有

$$(A \setminus B) \cap C = (A \cap C) \setminus (B \cap C).$$

我们当然允许无穷个事件至少一个发生.

Definition 1.1.2.(σ-代数) 一个集合 X 上的 σ-代数是一个代数 $\mathscr{F}$, 满足并的封闭性, 即若 $A_k \in \mathscr{F}(k \in \mathbb{N}^*)$, 则

$$\bigcup_{k=1}^{\infty} A_k \in \mathscr{F}.$$

此时称 $(X, \mathscr{F})$ 是可测空间.

根据上述讨论我们知道 σ-代数对可数交, 可数并和补集封闭, 且包含空集和全集. 以下我们给出一种构造可测空间的方式.

Definition 1.1.3.(生成 σ-代数) 设 $\mathscr{E}$ 是 X 上的子集族, 考虑所有满足以下性质的集合 $\mathscr{F}$, 即包含 $\mathscr{E}$ 的 σ-代数.

1. $\mathscr{E} \subseteq \mathscr{F} \subseteq \mathcal{P}(X)$.
2. 若 $A \in \mathscr{F}$, 则 $X \setminus A \in \mathscr{F}$.
3. 若 $A_k \in \mathscr{F}(k \in \mathbb{N}^*)$, 则
$$\bigcup_{k=1}^{\infty} A_k \in \mathscr{F}.$$

这样的 $\mathscr{F}$ 存在, 例如 $\mathcal{P}(X)$, 于是可以取全体这样 $\mathscr{F}$ 的交, 即包含 $\mathscr{E}$ 的所有 σ-代数的最小者, 称为由 $\mathscr{E}$ 生成的 σ-代数.

在概率论中最重要的例子是 Borel 代数.

Example 1.1.1.(Borel 代数) 取 $\mathbb{R}^n$ 上的标准拓扑, 全体开集 $\mathcal{O}$ 作为子集族, 生成的 σ-代数称为 $\mathbb{R}^n$ 上的 Borel 代数, 记作 $\mathscr{B}_n$. 特别地, 对 $\mathbb{R}$ 的情形记作 $\mathscr{B}$. 根据**Theorem A.2.**可知 $\mathcal{O}$ 恰好由全体开区间在并集下生成, 于是 $\mathbb{R}$ 上 Borel 集恰好包含了所有开集 (开区间), 其补集闭集 (闭区间), 以及两者的交半开半闭区间, 和开集, 闭集的可数交并.

1.2 σ-代数上的测度

我们说一个事件有发生的概率, 相当于为 $\mathscr{F}$ 中的元素指定了一个非负实数

$$\begin{aligned} \mathbb{P}: \quad \mathscr{F} &\to \mathbb{R}_{\geq 0}, \\ A &\mapsto \mathbb{P}(A). \end{aligned}$$

特别地, 所有事件点一定有一个发生, 所以 $\mathbb{P}(\Omega) = 1$.

我们可以将这种指定看成对 $\mathscr{F}$ 中的元素, 即 X 子集的一个测量. 一个事件包含的事件点越多, 例如 $A \subseteq B$, 其发生的概率应该越大, 即有 $\mathbb{P}(A) \leq \mathbb{P}(B)$, 即 $\mathbb{P}$ 应该保持集合包含的偏序关系为实数的偏序关系. 另外两个不交的事件 $A \cap B = \emptyset$, 其概率应该简单相加

$$\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B).$$

由此发展出关于 $\mathbb{P}$ 的完整理论. 我们从一般的集合族上的函数说起.

Definition 1.2.1.(集函数) 设 $\mathscr{F}$ 是 X 上的一个集合族, $\bar{\mathbb{R}}$ 是扩充实数系, 其上带有自然的偏序关系, 特别地对任意实数 r, 有 $r < +\infty$. 其非负部分为 $\bar{\mathbb{R}}_{\geq 0} = [0, +\infty]$. 一个集函数就是指形如 $\mu : \mathscr{F} \to \bar{\mathbb{R}}_{\geq 0}$ 的映射.
若对任意单调上升的 $\mathscr{F}$ 中集合列 $\{A_k\}$, 都有

$$\mu\left(\lim_{k\to\infty} A_k\right) = \lim_{k\to\infty} \mu(A_k),$$

则称集函数 μ **连续 (continuous)**.
若对任意两两交为空的子集列 $A_k \in \mathscr{F} (k \in \mathbb{N}^*)$, 都有

$$\mu\left(\bigcup_{k=1}^{n} A_k\right) = \sum_{k=1}^{n} \mu(A_k),$$

则称 μ 满足**有限可加性 (finitely additivity)**. 若对任意两两交为空的子集列 $A_k \in \mathscr{F} (k \in \mathbb{N}^*)$, 都有

$$\mu\left(\bigcup_{k=1}^{\infty} A_k\right) = \sum_{k=1}^{\infty} \mu(A_k),$$

则称 μ 满足**可列可加性 (countably additivity)**.

我们希望 $\mathbb{P}$ 所满足的性质与 σ-代数相容, 从而应当能够进行可列可加. 以下命题说明了可列可加性的性质.

Proposition 1.2.1. 设 $\mathscr{F}$ 是 X 上的一个集合族, $\mu : \mathscr{F} \to [0, +\infty]$ 是集函数, 则 μ 满足可列可加性的充要条件是 μ 连续且满足有限可加性.

Proof. (必要性) 取 $A_k = \emptyset (k > n)$ 即可推出有限可加性. 设 $\mathscr{F}$ 中集合列 $\{A_k\}$ 单调上升, 则

$$\lim_{k\to\infty} A_k = \left(\bigcup_{k=1}^{\infty} (A_{k+1} \setminus A_k)\right) \cup A_1.$$

根据可列可加性, 有

$$\begin{aligned}
\mu\left(\lim_{k\to\infty} A_k\right) &= \mu\left(\left(\bigcup_{k=1}^{\infty} (A_{k+1} \setminus A_k)\right) \cup A_1\right) \\
&= \sum_{k=1}^{\infty} \mu(A_{k+1} \setminus A_k) + \mu(A_1) \\
&= \lim_{n\to\infty} \left(\sum_{k=1}^{n} \mu(A_{k+1} \setminus A_k)\right) + \mu(A_1) \\
&= \lim_{n\to\infty} \left(\sum_{k=1}^{n} \mu(A_{k+1}) - \sum_{n=1}^{n} \mu(A_k) + \mu(A_1)\right) \\
&= \lim_{n\to\infty} \mu(A_{n+1}) \\
&= \lim_{k\to\infty} \mu(A_k).
\end{aligned}$$

(充分性) 任取一个无穷集合列 $\{A_k\}$, 使得对于任意 $i, j \in \mathbb{N}^*$, 满足 $i \neq j$, 都有 $A_i \cap A_j = \emptyset$. 定义

$$B_n = \bigcup_{k=1}^{n} A_k,$$

则 $\{B_n\}$ 是一列单调上升的集合列. 根据连续性有

$$\mu\left(\lim_{n\to\infty} B_n\right) = \lim_{n\to\infty} \mu(B_n).$$

从而根据有限可加性有

$$\mu\left(\bigcup_{k=1}^{\infty} A_k\right) = \mu\left(\lim_{n\to\infty} B_n\right) = \lim_{n\to\infty} \mu(B_n) = \lim_{n\to\infty} \mu\left(\bigcup_{k=1}^{n} A_n\right) = \lim_{n\to\infty} \sum_{k=1}^{n} \mu(A_k).$$

这就证明了可列可加性

$$\mu\left(\bigcup_{k=1}^{\infty} A_k\right) = \sum_{k=1}^{\infty} \mu(A_k).$$

□

现在我们描述 $\mathbb{P}$ 作为 Ω 上的集函数.

Definition 1.2.2.(预测度与测度) 设 $\mathscr{F}$ 是 X 上的代数, $\mu : \mathscr{F} \to [0, +\infty]$ 是集函数, 满足

1. (空集) $\mu(\emptyset) = 0$.

2. (可列可加性) 若 $A_k \in \mathscr{F}(k \in \mathbb{N}^*)$ 是一列子集, 满足对任意 $i, j \in \mathbb{N}^*$ 使得 $i \neq j$, 都有 $A_i \cap A_j = \emptyset$, 则
$$\mu\left(\bigcup_{k=1}^{\infty} A_k\right) = \sum_{k=1}^{\infty} \mu(A_k).$$

则称 μ 是 $\mathscr{F}$ 上的**预测度 (premeasure)**. 当 $\mathscr{F}$ 是 X 上的 σ-代数时, 称 μ 是 $\mathscr{F}$ 上的**测度 (measure)**.

现在我们说明这样定义的测度满足我们希望 $\mathbb{P}$ 具有的性质. 概率相加已经保证, 根据有限可加性, 若 $A \subseteq B$, 则
$$\mu(B) = \mu((B \setminus A) \cup A) = \mu(A) + \mu(B \setminus A) \geq \mu(A).$$

事实上, 单调性有如下推广.

Proposition 1.2.2.(可列次可加性) 设 $\mathscr{F}$ 是 X 上的 σ-代数, $\mu : \mathscr{F} \to [0, +\infty]$ 是测度. 若 $A_k \in \mathscr{F}(k \in \mathbb{N}^*)$ 是一列子集, 则
$$\mu\left(\bigcup_{k=1}^{\infty} A_k\right) \leq \sum_{k=1}^{\infty} \mu(A_k).$$

Proof. 定义
$$B_1 = A_1, \quad B_{n+1} = \left\{x \in A_{n+1} \mid x \notin \bigcup_{k=1}^{n} A_k\right\}.$$
则任意两个 B_i, B_j 无交. 一方面显然有
$$B_n \subseteq \bigcup_{k=1}^{\infty} A_k \implies \bigcup_{n=1}^{\infty} B_n \subseteq \bigcup_{k=1}^{\infty} A_k.$$
另一方面, 设 x 在 A_k 的并集中, 则必在某些 A_k 中, 记下标最小者为 k_0, 则 $x \in B_{k_0}$, 进而在 B_k 的并集中. 根据可列可加性
$$\mu\left(\bigcup_{k=1}^{\infty} A_k\right) = \mu\left(\bigcup_{n=1}^{\infty} B_n\right) = \sum_{n=1}^{\infty} \mu(B_n).$$
依照定义, $B_n \subseteq A_n$, 根据有限可加性和非负性
$$\mu(B_n) + \mu(A_n \setminus B_n) = \mu(A_n) \implies \mu(B_n) \leq \mu(A_n).$$
代入得
$$\mu\left(\bigcup_{n=1}^{\infty} A_n\right) = \sum_{n=1}^{\infty} \mu(B_n) \leq \sum_{n=1}^{\infty} \mu(A_n).$$
□

Example 1.2.1.(计数测度) 我们知道在集合上有容斥原理

$$\operatorname{card}(A \cup B) = \operatorname{card}(A) + \operatorname{card}(B) - \operatorname{card}(A \cap B).$$

对集合 X, 有 σ-代数 $\mathcal{P}(X)$, 则可以定义计数函数

$$\operatorname{card} : \mathscr{F} \to \mathbb{N} \cup \{\infty\}.$$

容易验证这是 $\mathcal{P}(X)$ 上的测度.

1.3 测度的 Caratheodory 理论 *

在这一部分, 我们将说明如何在可测空间上构建一个测度. 首先, Caratheodory 理论说明测度可以由外测度得到.

Definition 1.3.1.(外测度) 设 X 是集合, $\mu^*:\mathcal{P}(X)\to[0,+\infty]$ 是集函数, 满足

1. (空集) $\mu^*(\emptyset)=0$.
2. (单调性) 若 $A\subseteq B\subseteq X$, 则 $\mu^*(A)\leq\mu^*(B)$.
3. (可列次可加性) 若 $A_k\subseteq X(k\in\mathbb{N}^*)$ 是一列子集, 则

$$\mu^*\left(\bigcup_{k=1}^{\infty}A_k\right)\leq\sum_{k=1}^{\infty}\mu^*(A_k).$$

则称 μ^* 是 X 上的**外测度 (outer measure)**.

几乎任何集函数都可以诱导外测度.

Theorem 1.3.1.(诱导外测度) 设 X 上的子集族 $\mathscr{F}\subseteq\mathcal{P}(X)$ 包含 $\emptyset$ 和 X, 集函数 $\mu:\mathscr{F}\to[0,+\infty]$, 使得 $\mu(\emptyset)=0$. 定义

$$\begin{aligned}\mu^*:\ \mathcal{P}(X)&\to[0,+\infty],\\ A&\mapsto\inf\left\{\sum_{k=1}^{\infty}\mu(E_k)\mid A\subseteq\bigcup_{k=1}^{\infty}E_k,E_k\in\mathscr{F}\right\}.\end{aligned}$$

则这是一个外测度, 称为集函数 μ 诱导的外测度.

Proof. 注意到任意 $A\subseteq X$ 都被 X 覆盖, 故 μ^* 在 $\mathcal{P}(X)$ 上有定义. 我们验证外测度的三条性质.

1. (空集) 取所有 $E_k=\emptyset$ 即知 $\mu(\emptyset)=0$.
2. (单调性) 设 $A\subseteq B\subseteq X$ 都能被可列个 E_k 覆盖, 则任意一个 B 的覆盖都能覆盖 A, 于是

$$B\subseteq\bigcup_{k=1}^{\infty}E_k\implies\mu^*(A)\leq\sum_{k=1}^{\infty}\mu(E_k).$$

取下确界即得 $\mu^*(A)\leq\mu^*(B)$.

3. (可列次可加性) 根据下确界的定义, 对任意 $\varepsilon>0$, 存在 A_n 的覆盖 $\{E_{n,m}\}$, 使得

$$\sum_{m=1}^{\infty}\mu(E_{n,m})<\mu^*(A_n)+\frac{\varepsilon}{2^n}.$$

对 n 求和, 可得

$$\sum_{n=1}^{\infty}\sum_{m=1}^{\infty}\mu(E_{n,m}) \leq \sum_{n=1}^{\infty}\mu^*(A_n)+\varepsilon.$$

注意这里不要求右边收敛, 发散时总是取等, 而收敛时根据极限的性质即知取严格不等号. 由于全部 $\{E_{n,m}\}$ 构成 A_n 并集的覆盖, 于是根据定义

$$\mu^*\left(\bigcup_{n=1}^{\infty}A_n\right) \leq \sum_{n=1}^{\infty}\sum_{m=1}^{\infty}\mu(E_{n,m}) \leq \sum_{n=1}^{\infty}\mu^*(A_n)+\varepsilon.$$

根据 ε 的任意性, 可知

$$\mu^*\left(\bigcup_{n=1}^{\infty}A_n\right) \leq \sum_{n=1}^{\infty}\mu^*(A_n).$$

□

Caratheory 理论通过切割描述可测性.

Definition 1.3.2.(可测集) 设 $\mu^*:\mathcal{P}(X)\to[0,+\infty]$ 是外测度, 定义集合 $A\subseteq X$ 是 **μ^*-可测的 (μ^*-measurable)** 当且仅当对任意 $E\subseteq X$, 有

$$\mu^*(E)=\mu^*(E\cap A)+\mu^*(E\cap(X\setminus A)).$$

外测度在可测集上的限制总是其上的测度.

Theorem 1.3.2.(Caratheodory) 设 $\mu^*:\mathcal{P}(X)\to[0,+\infty]$ 是外测度, 则所有 μ^* 可测集构成 σ-代数 $\mathscr{F}$, 且 μ^* 在其上的限制是其上的测度.

Proof. 我们验证 $\mathscr{F}$ 满足 σ-代数的性质.

1. (全集) 显然有

$$\mu^*(E\cap X)+\mu^*(E\cap(X\setminus X))=\mu^*(E)+\mu^*(\emptyset)=\mu^*(E).$$

2. (补的封闭性) 设 $A\in\mathscr{F}$, 则对任意 $E\subseteq X$, 有

$$\mu^*(E)=\mu^*(E\cap A)+\mu^*(E\cap(X\setminus A)).$$

进而

$$\mu^*(E)=\mu^*(E\cap(X\setminus(X\setminus A)))+\mu^*(E\cap(X\setminus A))$$

表明 $X\setminus E\in\mathscr{F}$.

3. (并的封闭性) 先证明有限并. 设 $A, B \in \mathscr{F}$, 对任意 $E \subseteq X$, 有

$$\begin{aligned}
&\mu^*(E \cap (A \cup B)) + \mu^*(E \cap (X \setminus (A \cup B))) \\
=&\mu^*(E \cap (A \cup B) \cap A) + \mu^*(E \cap (A \cup B) \cap (X \setminus A)) + \mu^*(E \cap (X \setminus (A \cup B))) \\
=&\mu^*(E \cap A) + \mu^*(E \cap B \cap (X \setminus A)) + \mu^*(E \cap (X \setminus A) \cap (X \setminus B)) \\
=&\mu^*(E \cap A) + \mu^*(E \cap (X \setminus A)) \\
=&\mu^*(E).
\end{aligned}$$

特别地, 当 $A \cap B = \emptyset$ 时, 有

$$\begin{aligned}
\mu^*(E \cap (A \cup B)) &= \mu^*(E \cap (A \cup B) \cap A) + \mu^*(E \cap (A \cup B) \cap (X \setminus A)) \\
&= \mu^*(E \cap A) + \mu^*(E \cap B).
\end{aligned}$$

再证明可列并. 设 $A_k \in \mathscr{F} (k \in \mathbb{N}^*)$ 是一列集合, 定义

$$B_1 = A_1, \quad B_{n+1} = \left\{ x \in A_{n+1} \mid x \notin \bigcup_{k=1}^{n} A_k \right\} = A_{n+1} \cap \left(X \setminus \bigcup_{k=1}^{n} A_k \right).$$

根据有限并的封闭性, $B_n \in \mathscr{F}$. 显然任意两个 B_i, B_j 无交, 且

$$\bigcup_{n=1}^{\infty} B_n = \bigcup_{n=1}^{\infty} A_n.$$

归纳可得对任意 $E \subseteq X$, 有

$$\mu^* \left(E \cap \left(\bigcup_{k=1}^{n} B_k \right) \right) = \sum_{k=1}^{n} \mu^*(E \cap B_k).$$

进而根据有限并的封闭性和外测度的单调性

$$\begin{aligned}
\mu^*(E) &= \mu^* \left(E \cap \left(\bigcup_{k=1}^{n} B_k \right) \right) + \mu^* \left(E \cap \left(X \setminus \bigcup_{k=1}^{n} B_k \right) \right) \\
&= \sum_{k=1}^{n} \mu^*(E \cap B_k) + \mu^* \left(E \cap \left(\bigcap_{k=1}^{n} X \setminus B_k \right) \right) \\
&\geq \sum_{k=1}^{n} \mu^*(E \cap B_k) + \mu^* \left(E \cap \left(\bigcap_{k=1}^{\infty} X \setminus B_k \right) \right)
\end{aligned}$$

取极限并由外测度的可列次可加性有

$$\begin{aligned}
\mu^*(E) &\geq \sum_{n=1}^{\infty} \mu^*(E \cap B_n) + \mu^* \left(E \cap \left(\bigcap_{n=1}^{\infty} X \setminus B_n \right) \right) \\
&\geq \mu^* \left(E \cap \left(\bigcup_{n=1}^{\infty} B_n \right) \right) + \mu^* \left(E \cap \left(\bigcap_{n=1}^{\infty} X \setminus B_n \right) \right) \\
&\geq \mu^* \left(E \cap \left(\left(\bigcup_{n=1}^{\infty} B_n \right) \cup \left(\bigcap_{n=1}^{\infty} X \setminus B_n \right) \right) \right) \\
&= \mu^*(E)
\end{aligned}$$

即得

$$\mu^*(E)=\mu^*\left(E\cap\left(\bigcup_{n=1}^{\infty}B_n\right)\right)+\mu^*\left(E\cap\left(\bigcap_{n=1}^{\infty}X\setminus B_n\right)\right),$$

这就说明了

$$\bigcup_{n=1}^{\infty}A_n=\bigcup_{n=1}^{\infty}B_n\in\mathscr{F}.$$

为证 μ^* 是 $\mathscr{F}$ 上的测度, 只要证明可列可加性. 若 $A_k\in\mathscr{F}(k\in\mathbb{N}^*)$ 是一列子集, 满足对任意 $i,j\in\mathbb{N}^*$ 使得 $i\neq j$, 都有 $A_i\cap A_j=\emptyset$, 则取定义中

$$E=\bigcup_{k=1}^{\infty}A_k\subseteq X,\quad A=\bigcup_{k=1}^{n}A_k$$

有

$$\mu^*\left(\bigcup_{k=1}^{\infty}A_k\right)\geq\mu^*\left(\bigcup_{k=1}^{n}A_k\right)=\sum_{k=1}^{n}\mu^*(A_k).$$

取极限即得

$$\mu^*\left(\bigcup_{n=1}^{\infty}A_n\right)\geq\sum_{n=1}^{\infty}\mu^*(A_n).$$

结合可列次可加性即得可列可加性. □

既然集函数可以扩张为外测度, 外测度又可以限制出测度, 那么限制出的测度和原来的集函数是否一致? 这就需要原来的集函数本身是一个预测度.

Theorem 1.3.3.(Caratheodory 测度扩张/延拓定理) 设 $\mathscr{E}$ 是 X 上的代数, $\mu:\mathscr{F}\to[0,+\infty]$ 是一个预测度, 则其诱导的外测度 $\mu^*:\mathcal{P}(X)\to[0,+\infty]$ 是 $\mathscr{E}$ 的生成 σ-代数 $\mathscr{F}$ 上的测度. 如果 μ 的取值不含 $+\infty$, 则 $\mu^*|_{\mathscr{F}}$ 是唯一在 $\mathscr{E}$ 上与 μ 相同的测度.

Proof. 根据**Theorem 1.3.2.**, 诱导的外测度自身的可测集是 σ-代数. 如果 $\mathscr{E}$ 的所有元素都是 μ^* 可测的, 从而是 μ^* 可测集, 则 $\mathscr{E}$ 的生成 σ-代数 $\mathscr{F}$ 必然包含于 μ^* 可测集生成的 σ-代数, 从而 μ^* 是 $\mathscr{F}$ 上的测度. 因此我们只要证明 $\mathscr{E}$ 的所有元素都是 μ^* 可测的. 任取 $A\in\mathscr{E}$, 对任意的 $E\subseteq X$, 依照 μ^* 的下确界定义, 对任意 $\varepsilon>0$, 存在一列集合 $\{E_k\}\subseteq\mathscr{E}$ 覆盖 E, 使得

$$\sum_{k=1}^{\infty}\mu(E_k)\leq\mu^*(E)+\varepsilon.$$

根据 μ 作为预测度的可列可加性, 有

$$\sum_{k=1}^{\infty}\mu(E_k)=\sum_{k=1}^{\infty}\mu(E_k\cap A)+\sum_{k=1}^{\infty}\mu(E_k\cap(X\setminus A)).$$

根据 μ^* 的定义, 由于 $\{E_k\}$ 覆盖 E, $\{E_k \cap A\}$ 覆盖 $E \cap A$ 且 $\{E_k \cap (X \setminus A)\}$ 覆盖 $E \cap (X \setminus A)$, 于是

$$\sum_{k=1}^{\infty} \mu(E_k) \geq \mu^*(E \cap A) + \mu^*(E \cap (X \setminus A)).$$

另一方面, $E \cap A$ 和 E $(X \setminus A)$ 覆盖 E, 故有可列次可加性

$$\mu^*(E) + \varepsilon \geq \sum_{k=1}^{\infty} \mu(E_k) \geq \mu^*(E \cap A) + \mu^*(E \cap (X \setminus A)) \geq \mu^*(E).$$

由 ε 的任意性, 上式不等号全部取等, 从而

$$\mu^*(E) = \mu^*(E \cap A) + \mu^*(E \cap (X \setminus A)),$$

这就说明 A 是可测集, 从而 μ^* 是 $\mathscr{F}$ 上的测度.
再证明 μ^* 在 $\mathscr{E}$ 上与 μ 相同. 任取 $A \in \mathscr{E}$, 由于 A 覆盖自身, 由定义

$$\mu^*(A) \leq \mu(A).$$

现在任取一列 $\mathscr{F}$ 中覆盖 A 的集合 $\{E_k\}$, 令

$$F_1 = E_1, \quad F_{n+1} = A \cap \left(E_{n+1} \setminus \bigcup_{k=1}^{n} E_k \right) \subseteq E_{n+1}.$$

由于这只涉及到补和有限并, 从而在代数 $\mathscr{E}$ 中, 于是根据 μ 作为预测度的可列可加性, 有

$$\mu(A) = \sum_{n=1}^{\infty} \mu(F_n) \leq \sum_{k=1}^{\infty} \mu(E_k).$$

对这样的集合列 $\{E_k\}$ 取下确界, 即得

$$\mu(A) \leq \mu^*(A),$$

这就说明 μ 与 μ^* 在 $\mathscr{E}$ 上相等.
最后假设还有一个测度 $\nu : \mathscr{F} \to [0, +\infty]$, 使得其在 $\mathscr{E}$ 上与 μ 相等. 任取 $A \in \mathscr{F}$, 对任意一个覆盖 A 的 $\mathscr{E}$ 中集合列 $\{E_k\}$, 根据 ν 作为测度的单调性和可列可加性, 有

$$\nu(A) \leq \sum_{k=1}^{\infty} \nu(E_k) = \sum_{k=1}^{\infty} \mu(E_k).$$

对这样的集合列 $\{E_k\}$ 取下确界, 即得

$$\nu(A) \leq \mu^*(A).$$

同理可得, 对任意 $E \in \mathscr{F}$, 都有 $\nu(E \setminus A) \leq \mu^*(E \setminus A)$. 反之, 对任意 $\varepsilon > 0$, 存在一个覆盖 A 的 $\mathscr{F}$ 中集合列 $\{E_k\}$, 满足

$$\sum_{k=1}^{\infty} \mu(E_k) \leq \mu^*(A) + \varepsilon.$$

定义

$$E_0 = \bigcup_{k=1}^{\infty} E_k, \quad G_n = \bigcup_{k=1}^{n} E_k,$$

由于 G_n 只涉及到补和有限并, 从而 $G_n \in \mathscr{E}$, 而 E_0 在 $\mathscr{E}$ 的生成 σ-代数 $\mathscr{F}$ 中, 因而有 $\nu(E_0 \setminus A) \leq \mu^*(E_0 \setminus A)$. 根据 μ^* 在 $\mathscr{E}$ 上的限制为 μ 以及作为外测度的可列次可加性, 有

$$\sum_{k=1}^{\infty} \mu(E_k) = \sum_{k=1}^{\infty} \mu^*(E_k) \geq \mu^*(E_0).$$

当 μ 值域不含 $+\infty$ 时, 根据 μ^* 作为 $\mathscr{F}$ 上测度的可列可加性, 有

$$\mu^*(E_0 \setminus A) = \mu^*(E_0) - \mu^*(A) \leq \varepsilon.$$

于是

$$\nu(E_0) = \nu(A) + \nu(E_0 \setminus A) \leq \nu(A) + \mu^*(E_0 \setminus A) \leq \nu(A) + \varepsilon.$$

注意到 $G_n \in \mathscr{E}$ 单调上升到 E_0, 根据测度的连续性

$$\mu^*(E_0) = \lim_{n\to\infty} \mu^*(G_n) = \lim_{n\to\infty} \nu(G_n) = \nu(E_0),$$

即得

$$\mu^*(A) \leq \mu^*(E_0) = \nu(E_0) \leq \nu(A) + \varepsilon.$$

根据 ε 的任意性即知

$$\mu^*(A) \leq \nu(A),$$

于是 $\nu = \mu^*$ 在 $\sigma(\mathscr{F})$ 上恒成立, 即 μ^* 是唯一的. □

Example 1.3.1.(Borel 测度) 取 $\mathbb{R}^n$ 上的标准拓扑, 定义方体

$$\mathcal{R}(a,b) = \{(x_1, x_2, \ldots, x_n) \in \mathbb{R}^n \mid a_k < x_k < b_k, \forall 1 \leq k \leq n\}, \quad a_k < b_k, \forall 1 \leq k \leq n$$

的预测度

$$m(\mathcal{R}(a,b)) = \mathrm{vol}(\mathcal{R}(a,b)) = \prod_{k=1}^{n} (b_k - a_k).$$

由此扩展到 Borel 代数 $\mathscr{B}_n$ 上, 并通过 Caratheodory 延拓为外测度 m^*, 这就是 Lebesgue 外测度, 再限制为 m^* 可测集上的测度. 当然 Borel 代数是 σ-代数, 因此限制在 $\mathscr{B}$ 上恰好是测度 m, 称为 Borel 测度.

Chapter 2

初等概率论

本章基础知识

Theorem B.1.(Borel-Cantelli) 设 $E_k \subseteq \mathbb{R}$ 可测且测度的级数和收敛, 则几乎处处的 $x \in \mathbb{R}$ 落在至多有限个 E_k 中, 即

$$m\left(\limsup_{k\to\infty} E_k\right) = 0.$$

Proof. 此时每个 E_k 有限可测, 根据单调下降情形的测度的连续性

$$m\left(\limsup_{k\to\infty} E_k\right) = m\left(\bigcap_{n=1}^{\infty}\bigcup_{k=n}^{\infty} E_k\right) = \lim_{n\to\infty} m\left(\bigcup_{k=n}^{\infty} E_k\right) \le \lim_{n\to\infty}\sum_{k=n}^{\infty} m(E_k).$$

根据级数收敛可知余项趋于 0. □

Theorem B.2.(单调收敛定理)

Theorem B.3.(有界收敛定理)

Theorem B.4.(Fubini)

Theorem B.5.(Tonelli)

Theorem B.6.(Cauchy-Schwarz)

Theorem B.7.(Hahn 分解定理)

Theorem B.8.(Radon-Nikodym)

Theorem B.9.(Gamma 函数) Gamma 函数

$$\Gamma(s)=\int_0^{+\infty}x^{s-1}\mathrm{e}^{-x}\mathrm{d}x,\quad s>0$$

满足 $\Gamma(s+1)=s\Gamma(s)$. 特别地, 在正整数 $n\in\mathbb{N}^*$ 上取值为 $\Gamma(n)=(n-1)!$.

Proof. 利用分部积分

$$\Gamma(s+1)=-\int_0^{+\infty}x^s\mathrm{d}\mathrm{e}^{-x}=s\int_0^{+\infty}\mathrm{e}^{-x}x^{s-1}\mathrm{d}x-x^s\mathrm{e}^{-x}\Big|_0^{+\infty}=s\Gamma(s).$$

特别地

$$\Gamma(1)=\int_0^{+\infty}\mathrm{e}^{-x}\mathrm{d}x=-\mathrm{e}^{-x}\Big|_0^{+\infty}=1,$$

归纳可知 $\Gamma(n)=(n-1)!$. □

Theorem B.10.(Beta 函数) Beta 函数

$$B(\alpha,\beta)=\int_0^1x^{\alpha-1}(1-x)^{\beta-1}\mathrm{d}x,\quad \alpha,\beta>0$$

满足

$$B(\alpha,\beta)=\frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha+\beta)}.$$

Proof. 注意到对任意常数 $y>0$, 有

$$\Gamma(\alpha)=\int_0^{+\infty}(xy)^{\alpha-1}\mathrm{e}^{-xy}\mathrm{d}(xy)=y^\alpha\int_0^{+\infty}x^{\alpha-1}\mathrm{e}^{-xy}\mathrm{d}x.$$

作换元 $x=\frac{y}{1+y}$ 可得

$$B(\alpha,\beta)=\int_0^{+\infty}\left(\frac{y}{1+y}\right)^{\alpha-1}\left(1-\left(\frac{y}{1+y}\right)\right)^{\beta-1}\mathrm{d}\left(\frac{y}{1+y}\right)=\int_0^{+\infty}\frac{y^{\alpha-1}}{(1+y)^{\alpha+\beta}}\mathrm{d}y.$$

于是

$$B(\alpha,\beta)\Gamma(\alpha+\beta)=\int_0^{+\infty}\int_0^{+\infty}y^{\alpha-1}x^{\alpha+\beta-1}\mathrm{e}^{-x(1+y)}\mathrm{d}x\mathrm{d}y.$$

先对 y 积分得

$$\int_0^{+\infty}y^{\alpha-1}\mathrm{e}^{-xy}\mathrm{d}y=x^{-\alpha}\Gamma(\alpha),$$

于是

$$B(\alpha,\beta)\Gamma(\alpha+\beta)=\Gamma(\alpha)\int_0^{+\infty}x^{\beta-1}\mathrm{e}^{-x}\mathrm{d}x=\Gamma(\alpha)\Gamma(\beta).$$

□

2.1 概率空间

根据上一节的讨论, 我们可以把概率 $\mathbb{P}$ 视为一个特殊的测度, 使得在全空间上的取值为 1, 这就是一般概率空间的定义.

Definition 2.1.1(概率空间) 设 Ω 是集合, $\mathscr{F}$ 是 Ω 上的 σ-代数, $\mathbb{P}$ 是 $\mathscr{F}$ 上的测度, 满足 $\mathbb{P}(\Omega)=1$, 则称 $\mathbb{P}$ 是 $\mathscr{F}$ 上的**概率 (probability)**, $(\Omega,\mathscr{F},\mathbb{P})$ 称为**概率空间 (probability space)**.

给定可测空间 $(\Omega,\mathscr{F})$, 根据定义, 集函数 $\mu:\mathscr{F}\to[0,+\infty]$ 是概率当且仅当满足

1. (非负性) 对任意 $A\in\mathscr{F}$, 有 $\mu(A)\geq 0$.
2. (归一性) $\mu(\emptyset)=0$, $\mu(\Omega)=1$.
3. (可列可加性) 若 $A_k\in\mathscr{F}(k\in\mathbb{N}^*)$ 是一列子集, 满足对任意 $i,j\in\mathbb{N}^*$ 使得 $i\neq j$, 都有 $A_i\cap A_j=\emptyset$, 则
$$\mu\left(\bigcup_{k=1}^{\infty}A_k\right)=\sum_{k=1}^{\infty}\mu(A_k).$$

利用可列可加性容易得到

$$\mathbb{P}(\Omega\setminus A)=\mathbb{P}(\Omega)-\mathbb{P}(A)=1-\mathbb{P}(A).$$

下面我们证明一些概率空间的基本性质.

Proposition 2.1.1.(加法公式) 设 $(\Omega,\mathscr{F},\mathbb{P})$ 是概率空间, $A_k\in\mathscr{F}$, 则有

$$\mathbb{P}\left(\bigcup_{k=1}^{n}A_k\right)=\sum_{k=1}^{n}(-1)^{k-1}\left(\sum_{1\leq i_1<i_2<\cdots<i_k\leq n}\mathbb{P}\left(\bigcap_{j=1}^{k}A_{i_j}\right)\right).$$

特别地, 对 $A,B\in\mathscr{F}$, 有容斥原理

$$\mathbb{P}(A\cup B)=\mathbb{P}(A)+\mathbb{P}(B)-\mathbb{P}(A\cap B).$$

Proof. 对 n 归纳证明. 当 $n=2$ 时有

$$\begin{aligned}\mathbb{P}(A\cup B)&=\mathbb{P}((A\setminus A\cap B)\cup(B\setminus A\cap B)\cup(A\cap B))\\&=\mathbb{P}(A\setminus A\cap B)+\mathbb{P}(B\setminus A\cap B)+\mathbb{P}(A\cap B)\\&=\mathbb{P}((A\setminus A\cap B)\cup(A\cap B))+\mathbb{P}((B\setminus A\cap B)\cup(A\cap B))-\mathbb{P}(A\cap B)\\&=\mathbb{P}(A)+\mathbb{P}(B)-\mathbb{P}(A\cap B).\end{aligned}$$

现在假设对 $n=m$ 成立, 则对 $n=m+1$, 可以把

$$\sum_{k=1}^{m+1}(-1)^{k-1}\left(\sum_{1\leq i_1<i_2<\cdots<i_k\leq m+1}\mathbb{P}\left(\bigcap_{j=1}^{k}A_{i_j}\right)\right)$$

拆成两部分, 当 $k=1$ 时, 即

$$\sum_{1\leq i\leq m+1}\mathbb{P}\left(A_i\right)=\sum_{i=1}^{m+1}\mathbb{P}(A_i).$$

对 $2\leq k\leq m+1$, 再拆成两项, 当 $i_k=m+1$ 时为

$$\sum_{k=2}^{m+1}(-1)^{k-1}\left(\sum_{1\leq i_1<i_2<\cdots<i_{k-1}\leq m}\mathbb{P}\left(\bigcap_{j=1}^{k-1}A_{i_j}\cap A_{m+1}\right)\right).$$

以 k 代替 $k-1$, 运用归纳假设即得

$$-\sum_{k=1}^{m}(-1)^{k-1}\left(\sum_{1\leq i_1<i_2<\cdots<i_k\leq m}\mathbb{P}\left(\bigcap_{j=1}^{k}A_{i_j}\cap A_{m+1}\right)\right)=-\mathbb{P}\left(\bigcup_{k=1}^{m}A_k\cap A_{m+1}\right).$$

当 $i_k\leq m$ 时, k 不可能再取 $m+1$, 从而为

$$\sum_{k=2}^{m}(-1)^{k-1}\left(\sum_{1\leq i_1<i_2<\cdots<i_k\leq m}\mathbb{P}\left(\bigcap_{j=1}^{k}A_{i_j}\right)\right).$$

补上 $k=1$ 的项即得

$$\mathbb{P}\left(\bigcup_{k=1}^{m}A_k\right)-\sum_{i=1}^{m}\mathbb{P}(A_i).$$

于是原式化为

$$\mathbb{P}\left(\bigcup_{k=1}^{m}A_k\right)+\mathbb{P}(A_{m+1})-\mathbb{P}\left(\bigcup_{k=1}^{m}A_k\cap A_{m+1}\right).$$

利用**Theorem A.1.**和 $n=2$ 的情形即得

$$\sum_{k=1}^{m+1}(-1)^{k-1}\left(\sum_{1\leq i_1<i_2<\cdots<i_k\leq m+1}\mathbb{P}\left(\bigcap_{j=1}^{k}A_{i_j}\right)\right)=\mathbb{P}\left(\bigcup_{k=1}^{m+1}A_k\right).$$

归纳即证. □

2.2 随机变量与分布函数

现在我们要描述一个事件, 并对其求概率, 都是通过取定 $A \in \mathscr{F}$, 计算 $\mathbb{P}(A)$ 的形式. 这种离散定义的方式往往是不便研究的, 例如当 $\Omega = \mathbb{R}$ 而 $\mathscr{F} = \mathscr{B}$ 时, $\mathbb{P}$ 就是对 $\mathscr{B}$ 逐元素定义的, 这不会具有很好的性质以供研究.

另一种情形下, 考虑从 $n = a + b$ 个白球和黑球混合的箱子中摸 m 个球, 白球的个数为 t 的概率, 则概率空间 Ω 是所有可能的摸出 m 个球的情况, 而 $\mathscr{F} = \mathcal{P}(\Omega)$. 我们需要取 $\mathscr{F}$ 中的一个集合 A, 由所有白球个数为 t 的元素构成. 每更改一次 t 的值, 都会完全改变 A 的组成.

我们需要一种统一的方式来描述一类相似的事件, 因为其他的事件往往不在我们考虑的范围内, 使得在这一类事件上的概率具有一些良好的性质. 一个想法是设定一个函数 $X : \Omega \to \mathbb{R}$, 使得 $X^{-1}(t)$ 恰好是我们想要的 $\mathscr{F}$ 中元素.

Definition 2.2.1.(随机变量) 设 $(\Omega, \mathscr{F}, \mathbb{P})$ 是概率空间. 若函数 $X : \Omega \to \mathbb{R}$ 满足对任意 Borel 集 $B \in \mathscr{B}$, 都有

$$\{\omega \in \Omega \mid X(\omega) \in B\} \in \mathscr{F},$$

则称 X 是一个**随机变量 (random variable, r.v.)**.

有趣的是, 随机变量既不随机 (是一个确定的对应关系), 也不是变量 (是一个映射), 之所以称之为随机变量, 是因为 $X^{-1}(t)$ 是若干互斥的事件点 $\omega \in \Omega$, 我们不知道究竟是其中哪个事件点发生导致 X 取值为 t.

需要注意的是, $\mathscr{F}$ 作为一个离散的集合, 不可能由单个随机变量 X 完全刻画其信息. 例如取 $\mathscr{F} = \mathscr{B}_2$, 但 $\mathbb{R}^2$ 到 $\mathbb{R}$ 不存在保持拓扑结构的一一对应, 因此单个随机变量 X 必然会导致有些 $\mathscr{B}_2$ 中元素的像不是 $\mathscr{B}$ 中元素.

随机变量刻画了 Ω 与 $\mathbb{R}$ 的对应关系, 这种对应关系可以用一个单调实值函数编码.

Definition 2.2.2.(分布函数) 设 $(\Omega, \mathscr{F}, \mathbb{P})$ 是概率空间, X 是其上的一个随机变量. 定义

$$F(x) = \mathbb{P}(X \leq x) = \mathbb{P}(\{\omega \in \Omega \mid X(\omega) \leq x\})$$

为 X 的**概率分布函数 (diistribution function, d.f.)**.

现在说明分布函数的若干性质.

Proposition 2.2.1.(分布函数的性质) 设 $(\Omega, \mathscr{F}, \mathbb{P})$ 是概率空间, X 是其上的一个随机变量, 则 X 的概率分布函数 $F(x)$ 满足

1. (单调性) 任意 $x < y$ 都有 $F(x) \leq F(y)$.

2. (右连续) $F(x)$ 在任一点处右连续, 即

$$\lim_{x\to x_0^+} F(x) = F(x_0),$$

3. (左极限) $F(x)$ 在任一点处左极限存在

$$\lim_{x\to x_0^-} F(x) = \mathbb{P}(X < x) = \mathbb{P}(\{\omega \in \Omega \mid X(\omega) < x\}).$$

4. 在无穷远处

$$\lim_{x\to-\infty} F(x) = 0, \quad \lim_{x\to+\infty} F(x) = 1.$$

Proof.

1. 注意到

$$x < y \implies \{\omega \in \Omega \mid X(\omega) \le x\} \subseteq \{\omega \in \Omega \mid X(\omega) \le y\},$$

即知 $F(x) \le F(y)$.

2. 首先 x_0 处右连续即对于任意 $\varepsilon > 0$, 存在一个 $x(\varepsilon) > x_0$, 使得 $x_0 < x < x(\varepsilon)$ 时有 $|F(x) - F(x_0)| < \varepsilon$. 由于 F 单调上升, 这当且仅当 $F(x(\varepsilon)) - F(x_0) < \varepsilon$. 这恰好是下确界的定义

$$\lim_{x\to x_0^+} F(x) = \inf_{x>x_0}\{F(x)\}.$$

现在根据确界原理右式有定义, 根据下确界的定义, 存在一列 $\{x_k\}$ 单调下降趋于 x_0, 使得

$$\inf_{x>x_0}\{F(x)\} = \lim_{k\to\infty} F(x_k) = \lim_{k\to\infty} \mathbb{P}(X \le x_k) = \mathbb{P}\left(\bigcap_{k=1}^{\infty}\{\omega \in \Omega \mid X(\omega) \le x_k\}\right).$$

利用极限的性质显然有

$$\bigcap_{k=1}^{\infty}\{\omega \in \Omega \mid X(\omega) \le x_k\} = \{\omega \in \Omega \mid X(\omega) \le x_0\},$$

即得

$$\lim_{x\to x_0^+} F(x) = F(x_0).$$

3. 类似地, 根据 $F(x)$ 在 $(-\infty, x_0)$ 上单调有界, 可知左极限存在. 任取 $\{x_k\}$ 单调上升趋于 x_0, 有

$$\lim_{x\to x_0^-} F(x) = \mathbb{P}\left(\bigcup_{k=1}^{\infty}\{\omega \in \Omega \mid X(\omega) \le x_k\}\right) = P(\{\omega \in \Omega \mid X(\omega) < x\}).$$

4. 任取 $\{x_k\}$ 单调下降趋于 $-\infty$, 有

$$\lim_{x\to-\infty} F(x) = \mathbb{P}\left(\bigcap_{k=1}^{\infty}\{\omega\in\Omega \mid X(\omega)\le x_k\}\right) = \mathbb{P}(\emptyset) = 0.$$

任取 $\{x_k\}$ 单调上升趋于 $+\infty$, 有

$$\lim_{x\to+\infty} F(x) = \mathbb{P}\left(\bigcup_{k=1}^{\infty}\{\omega\in\Omega \mid X(\omega)\le x_k\}\right) = P(\Omega) = 1.$$

□

既然分布函数可以编码随机变量, 我们当然希望随机变量可以通过分布函数解码得到. 但是要注意, 分布函数是 $\mathbb{R}$ 上的实值函数, 失去了概率空间的信息, 因此解码得到的随机变量只能是在概率空间同构意义下唯一的. 这里我们不详细解释概率空间同构的意义, 而只给出存在性的证明.

Theorem 2.2.2.(Lebesgue-Stieljes) 设 $F:\mathbb{R}\to\mathbb{R}$ 单调上升, 在任意一点处右连续且左极限存在, 满足

$$\lim_{x\to-\infty} F(x) = 0, \quad \lim_{x\to+\infty} F(x) = 1,$$

则存在概率空间 $(\mathbb{R},\mathscr{B},\mathbb{P})$ 以及其上的随机变量 X, 使得 $F(x)$ 是 X 的概率分布函数.

Proof. 取概率空间 $\Omega=\mathbb{R}$, 事件域 $\mathscr{F}=\mathscr{B}$, 我们定义区间 $(a,b]$ 上的概率为

$$\mathbb{P}((a,b]) = F(b) - F(a),$$

特别地根据右连续

$$\mathbb{P}(\emptyset) = \lim_{b\to a^+} F(b) - F(a) = 0, \quad \mathbb{P}(\mathbb{R}) = \lim_{b\to+\infty} F(b) - \lim_{a\to-\infty} F(a) = 1.$$

注意到

$$\{(a,b] \mid a,b\in\mathbb{R}, a\le b\} \subseteq \mathcal{P}(\mathbb{R})$$

对有限交封闭, 如果定义 $(a,b]$ 补集的概率

$$\mathbb{P}(\mathbb{R}\setminus(a,b]) = 1 - (F(b) - F(a)),$$

就在一个代数上定义了预测度 $\mathbb{P}$.
我们证明这个代数生成的 σ-代数恰好为 $\mathscr{B}$. 一方面, 任意开集 (a,b) 可由

$$(a,b) = \bigcup_{n=1}^{\infty}\left(a, b-\frac{1}{n}\right]$$

确定, 从而 $\mathscr{B}$ 含于其生成的 σ 代数. 另一方面, 任意 $(a,b]$ 可由

$$(a,b]=\bigcap_{n=1}^{\infty}\left(a,b+\frac{1}{n}\right)$$

确定, 于是 $\mathscr{B}$ 就是其生成的 σ-代数. 从而根据**Theorem 1.2.3.**可知此预测度可以延拓为测度 $\mathbb{P}:\mathscr{B}\to\mathbb{R}$, 这当然满足概率的定义, 于是令随机变量 $X=\mathrm{id}_{\mathbb{R}}$ 即可. □

尽管我们不打算说明概率空间同构的含义, 但以下定理给出了另一种通过分布函数确定随机变量的方式, 这给出的概率空间就与上述定理的 $(\mathbb{R},\mathscr{B},\mathbb{P})$ 同构.

Theorem 2.2.3.(Skorokhod) 设 $F:\mathbb{R}\to\mathbb{R}$ 单调上升, 在任意一点处右连续且左极限存在, 满足

$$\lim_{x\to-\infty}F(x)=0,\quad \lim_{x\to+\infty}F(x)=1.$$

则存在概率空间 $([0,1],\mathscr{B}([0,1]),P)$ 以及其上的随机变量 X, 使得 $F(x)$ 是 X 的概率分布函数, 其中 $\mathscr{B}([0,1])$ 是 $\mathscr{B}$ 中元素与 $[0,1]$ 的交构成的 σ-代数.

Proof. 定义概率

$$\begin{aligned}\mathbb{P}:\ \{[a,b]\mid 0\le a\le b\le 1\}&\to [0,1],\\ [a,b]&\mapsto F(b)-F(a).\end{aligned}$$

同**Theorem 2.2.2.**延拓到 $\mathscr{B}([0,1])$. 定义随机变量

$$\begin{aligned}X:\ [0,1]&\to \mathbb{R},\\ \omega&\mapsto \inf\{x\in\mathbb{R}\mid F(x)\ge\omega\}.\end{aligned}$$

则当 $\omega\le F(x)$ 时, $X(\omega)\le x$, 而 $\omega>F(x)$ 时, 根据 $F(x)$ 单调上升, 任意 $y\le x$ 都有 $\omega>F(y)$, 从而 $X(\omega)\ge x$, 这就说明 X 的分布函数

$$\mathbb{P}(X\le x)=\mathbb{P}(\omega\le F(x))=F(x)-F(0)=F(x).$$

□

以上说明, 不必指定概率空间, 仅仅指定 $F(x)$ 就可以讨论概率, 因此我们可以直接称满足以上条件的 F 为分布函数, 并依据需要复原一个概率空间和随机变量.

Definition 2.2.3.(离散, 绝对连续与奇异) 设 $F:\mathbb{R}\to\mathbb{R}$. 若存在严格单调上升序列 $\{x_k\}\subseteq\mathbb{R}$ 和 $p_k\in[0,1]$, 使得

$$F(x)=\sum_{x_k\le x}p_k,$$

则称 $F(x)$ **离散 (discrete)**. 若存在 Lebesgue 可积函数 $f(x)$, 使得对任意 $x_1 < x_2$, 有

$$F(x_2) - F(x_1) = \int_{x_1}^{x_2} f(x)\mathrm{d}x,$$

则称 $F(x)$ **绝对连续 (absolutely continuous)**. 若 $F(x)$ 几乎处处可导且导数恒为 0, 但 $F(x)$ 不恒为 0, 则称 $F(x)$ **奇异 (singular)**. 一个随机变量被称为离散, 绝对连续或奇异, 如果其分布函数是离散, 绝对连续函数或奇异的.

一个重要的结果是任何随机变量的分布函数可以分解为离散, 绝对连续和奇异部分, 从而我们可以分别研究这三者.

Theorem 2.2.4.(Lebesgue) 设 $F : \mathbb{R} \to \mathbb{R}$ 是分布函数, 则存在分布函数 F_1, F_2, F_3 分别是离散的, 绝对连续的和奇异的, 以及 $\lambda_1, \lambda_2, \lambda_3 \in [0, 1]$, 使得

$$F(x) = \lambda_1 F_1(x) + \lambda_2 F_2(x) + \lambda_3 F_3(x),$$

且这样的分解唯一.

Proof. 由于 $F(x)$ 单调上升, 至多只有可数个间断点, 且按定义左极限存在而右连续, 设为 $x_n (n \in \mathbb{Z})$. 定义

$$F_d(x) = \sum_{n\in\mathbb{Z}} \left(F(x_n) - \lim_{t\to x_n^-} F(t) \right) \delta_{x_n}(x),$$

其中

$$\delta_u(x) = \begin{cases} 0, & x < u, \\ 1, & x \geq u. \end{cases}$$

$F_d(x)$ 定义合理, 因为任意一点处

$$F_d(x) \leq \sum_{n\in\mathbb{Z}} \left(F(x_n) - \lim_{t\to x_n^-} F(t) \right) \leq \lim_{t\to+\infty} F(t) - \lim_{t\to-\infty} F(t) = 1.$$

显然 $F_d(x)$ 的间断点恰好是 $F(x)$ 的间断点, 且 $F_d(x)$ 右连续, 左极限存在, 单调上升. 于是 $F(x) - F_d(x)$ 在 $\{x_n\}$ 以外处处连续. 再考虑

$$\begin{aligned} &\lim_{x\to x_n^-} F_d(x) - F_d(x_n) \\ =& \sum_{m<n} \left(F(x_m) - \lim_{t\to x_m^-} F(t) \right) \delta_{x_m}(x) - \sum_{m\leq n} \left(F(x_m) - \lim_{t\to x_m^-} F(t) \right) \delta_{x_m}(x) \\ =& \lim_{x\to x_n^-} F(x) - F(x_n). \end{aligned}$$

从而

$$\lim_{x\to x_n^-} (F(x) - F_d(x)) = (F(x_n) - F_d(x_n)),$$

这就说明 $G(x) := F(x) - F_d(x)$ 是连续函数. 对任意 $t_1 < t_2$, 若中间不存在 $t_1 \leq x_n \leq t_2$, 则 $F_d(t_1) = F_d(t_2)$, 进而

$$G(t_1) - G(t_2) = F(t_1) - F(t_2) \leq 0 \implies G(t_1) \leq G(t_2).$$

否则可在 $t_1 < t_2$ 间插入所有的 x_n, $G(x)$ 在每个 (x_{n-1}, x_n) 上单调而在端点处连续, 从而 $G(x)$ 单调上升. 又由于单调函数的不可导点是 Lebesgue 零测的, 从而 $G'(x)$ 是 Lebesgue 可积的, 进而可定义

$$F_{ac}(x) = \int_{-\infty}^{x} G'(t)\mathrm{d}t.$$

由于 $G(x)$ 单调上升, $G'(t) \geq 0$, 从而 $F_{ac}(x)$ 单调上升且连续. 再定义

$$F_s(x) = G(x) - F_{ac}(x),$$

则

$$F_s'(x) = F'(x) - F_{ac}'(x) = 0$$

在所有可导点成立, 从而 $F_s(x)$ 几乎处处可导且导数恒为 0. 依照定义 $F_s(x)$ 右连续且左极限存在. 对任意 $t_1 < t_2$, 有

$$F_s(t_2) - F_s(t_1) = G(t_2) - G(t_1) + \int_{t_1}^{t_2} G'(t)\mathrm{d}t \geq 0.$$

显然 F_d, F_{ac}, F_s 均满足在 $-\infty$ 处极限为 0, 以及单调上升, 右连续, 左极限存在. 注意到这表明 F_d, F_{ac}, F_s 均恒正, 于是

$$F(x) = F_d(x) + F_{ac}(x) + F_s(x) \leq 1$$

表明 F_d, F_{ac}, F_s 单调有界, 从而在 $+\infty$ 处收敛到 $[0, 1]$ 中的某个值, 设为 $\lambda_1, \lambda_2, \lambda_3$, 则有 Lebesgue 分解

$$F(x) = \lambda_1 \left(\frac{1}{\lambda_1} F_d(x)\right) + \lambda_2 \left(\frac{1}{\lambda_2} F_d(x)\right) + \lambda_3 \left(\frac{1}{\lambda_3} F_d(x)\right).$$

这三项依次就是离散分布函数, 绝对连续分布函数和奇异分布函数. 若 $\lambda_i = 0$, 只要把分解项取为 0 即可. 取 $x \to \infty$ 即知 $\lambda_1 + \lambda_2 + \lambda_3 = 1$. 现在假设存在分解

$$F(x) = \lambda_1 F_1(x) + \lambda_2 F_2(x) + \lambda_3 F_3(x) = \lambda_1^* F_1^*(x) + \lambda_2^* F_2^*(x) + \lambda_3^* F_3^*(x),$$

则有

$$\lambda_1 F_1(x) - \lambda_1^* F_1^*(x) = \lambda_2^* F_2^*(x) + \lambda_3^* F_3^*(x) - \lambda_2 F_2(x) - \lambda_3 F_3(x),$$

但左边离散右边连续, 从而必须均为 0. 又有

$$\lambda_2^* F_2^*(x) - \lambda_2 F_2(x) = \lambda_3 F_3(x) - \lambda_3^* F_3^*(x),$$

则左边连续且处处可导, 而右边表明导数几乎处处为 0, 从而只能是常数, 且恰为

$$\lim_{x\to-\infty}(\lambda_2^*F_2^*(x)-\lambda_2F_2(x))=0.$$

这就说明了 $\lambda_iF_i(x)=\lambda_i^*F_i^*(x)$, 进而

$$\lim_{x\to+\infty}\lambda_iF_i(x)=\lim_{x\to+\infty}\lambda_i^*F_i^*(x)\implies\lambda_i=\lambda_i^*,$$

这就证明了唯一性. □

对于绝对连续的情形, 可以定义概率密度的概念.

Definition 2.2.4.(概率密度函数) 设 $(\Omega,\mathscr{F},\mathbb{P})$ 是概率空间, X 是其上的绝对连续随机变量, $F(x)$ 为 X 的概率分布函数. 则存在 $f:\mathbb{R}\to[0,+\infty)$Lebesgue 可积, 使得

$$\int_{-\infty}^{x}f(t)\mathrm{d}t=F(x),$$

称 $f(x)$ 是随机变量 X 的**概率密度函数 (probability density function, p.d.f.)**.

显然, 概率密度的积分

$$\int_{-\infty}^{+\infty}f(t)\mathrm{d}t=\lim_{x\to+\infty}F(x)=1.$$

根据变上限积分的性质, 若 $f(x)$ 在 x_0 处连续, 则 $F(x)$ 在 x_0 处可导, 且 $F'(x_0)=f(x_0)$, 同时

$$\mathbb{P}(X=x_0)=F(x_0)-\lim_{x\to x_0^-}F(x)=0.$$

我们常常需要处理随机变量之间的变换.

Proposition 2.2.5.(随机变量的换元公式) 设 $(\Omega,\mathscr{F},\mathbb{P})$ 是概率空间, X 是绝对连续随机变量, $\varphi:\mathbb{R}\to\mathbb{R}$ 严格单调可导, 则随机变量

$$\begin{array}{rccc} Y: & \Omega & \to & \mathbb{R}, \\ & \omega & \mapsto & \varphi(X(\omega)) \end{array}$$

的概率密度函数满足

$$f_Y(y)=\frac{f_X(\varphi^{-1}(y))}{|\varphi'(y)|}.$$

Proof. 不妨设 φ 严格单调上升, 则

$$F_Y(y)=\mathbb{P}(Y\le y)=\mathbb{P}(\varphi(X)\le y)=\mathbb{P}(X\le\varphi^{-1}(y))=\int_{-\infty}^{\varphi^{-1}(y)}f_X(x)\mathrm{d}x.$$

两边对 y 求导得

$$f_Y(y)=f_X(\varphi^{-1}(y))\frac{\mathrm{d}}{\mathrm{d}y}\varphi^{-1}(y)=\frac{f_X(\varphi^{-1}(y))}{|\varphi'(y)|}.$$

同理可证严格单调下降的情形. □

下面我们给出一些分布函数的实例.

Example 2.2.1.(二项分布) 取概率空间 Ω 为做 n 次随机试验的结果 (成功或失败), 即

$$\Omega = \{(q_1, q_2, \ldots, q_n) \mid q_k \in \{\mathbf{T}, \mathbf{F}\}\}.$$

如果每次试验独立, 成功概率为 p, 令随机变量 X 表示成功次数, 即 $X(\omega) = \mathbf{T}(\omega)$ 是 $\omega \in \Omega$ 中 $\mathbf{T}$ 的数量. 则 $X^{-1}(k)$ 的概率

$$\mathbb{P}(X = k) = C_n^k p^k (1-p)^{n-k}.$$

此时称 X 服从**二项分布 (binomial distribution)**, 记作 $X \sim \mathrm{Bi}(n, p)$.

我们很容易写出相应的分布函数是离散分布函数

$$F(x) = \sum_{k \le x} C_n^k p^k (1-p)^{n-k},$$

但这不会给我们更多好处, 因此对离散随机变量, 之后仅给出概率表达.

Example 2.2.2.(几何分布) 取概率空间 Ω 为做随机试验直到成功的结果, 即

$$\Omega = \{(q_1, q_2, \ldots, q_n) \mid n \ge 1, q_1 = q_2 = \cdots = q_{n-1} = \mathbf{F}, q_n = \mathbf{T}\}.$$

如果每次试验独立, 成功概率为 p, 令随机变量 X 表示成功时进行的总次数, 即 $X(\omega) = \mathrm{len}(\omega)$ 是 $\omega \in \Omega$ 的长度 n, 则

$$\mathbb{P}(X = k) = p(1-p)^{k-1}.$$

此时称 X 服从**几何分布 (geometric distribution)**, 记作 $X \sim \mathrm{Ge}(p)$.

Example 2.2.3.(超几何分布) 取概率空间 Ω 为从有 $N - M$ 个次品的 N 个产品中不放回地取 n 个的结果, 令随机变量 X 表示非次品的个数, 则

$$\mathbb{P}(X = m) = \frac{C_M^m C_{N-M}^{n-m}}{C_N^n}.$$

此时称 X 服从**超几何分布 (hypergeometric distribution)**, 记作 $X \sim \mathrm{H}(n, M, N)$.

Example 2.2.4.(Poisson 分布) 给定参数 $\lambda > 0$, 任何概率空间上的随机变量 X, 只要满足

$$\mathbb{P}(X = k) = \frac{\lambda^k \mathrm{e}^{-\lambda}}{k!},$$

就称 X 服从 **Poisson 分布 (Poisson distribution)**, 记作 $X \sim \mathrm{Poi}(\lambda)$.

注意我们提到过, 上式定义了一个分布函数, 而任何分布函数都存在对应的概率空间和随机变量, 因此上述定义是有意义的.

下面我们考虑一些绝对连续的分布.

Example 2.2.5.(1 维均匀分布) 给定参数 $a < b$, 任何概率空间上的随机变量 X, 只要有分布函数

$$F(x) = \begin{cases} 0, & x \le a, \\ \frac{x-a}{b-a}, & a \le x \le b, \\ 1, & x \ge b, \end{cases}$$

或概率密度函数

$$f(x) = \begin{cases} \frac{1}{b-a}, & a \le x \le b, \\ 0, & \text{otherwise}, \end{cases}$$

就称 X 服从**均匀分布 (uniform distribution)**, 记作 $X \sim U(a, b)$.

Example 2.2.6.(指数分布) 给定参数 $\lambda > 0$, 任何概率空间上的随机变量 X, 只要有概率密度函数

$$f(x) = \begin{cases} \lambda \mathrm{e}^{-\lambda x}, & x \ge 0, \\ 0, & x < 0, \end{cases}$$

就称 X 服从**指数分布 (exponential distribution)**, 记作 $X \sim \mathrm{Exp}(\lambda)$.

Example 2.2.7.(Gamma 分布) 给定参数 $\alpha, \lambda > 0$, 任何概率空间上的随机变量 X, 只要有概率密度函数

$$f(x) = \begin{cases} \mathrm{e}^{-\lambda x} \lambda^{\alpha} \frac{x^{\alpha-1}}{\Gamma(\alpha)}, & x > 0, \\ 0, & x \le 0, \end{cases}$$

就称 X 服从 **Gamma 分布 (Gamma distribution)**, 记作 $X \sim \Gamma(\alpha, \lambda)$.

Example 2.2.8.(Cauchy 分布) 任何概率空间上的随机变量 X, 只要有概率密度函数

$$f(x) = \frac{1}{\pi(1 + x^2)},$$

就称 X 服从 **Cauchy 分布 (Cauchy distribution)**.

Example 2.2.9.(正态分布) 给定参数 μ 和 $\sigma > 0$, 任何概率空间上的随机变量 X, 只要有概率密度函数

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right).$$

就称 X 服从**正态分布 (normal distribution)**, 记作 $X \sim N(\mu, \sigma^2)$.

2.3 随机向量与分布函数

单个随机变量无法刻画概率空间, 很多时候我们需要多个随机变量刻画概率空间的多个侧面, 并研究这些随机变量的关系. 例如取概率空间为 n 个三种颜色的小球摸出 m 个的所有可能结果, 随机变量 X 记录了 A 色小球的个数, Y 记录了 B 色小球的个数, 则 X,Y 之间是有关的: 在 X 取值 m 的点上 Y 只能取值 0.

在同一概率空间 $(\Omega,\mathscr{F},\mathbb{P})$ 上取定 n 个随机变量 $X_k(1\leq k\leq n)$, 则可以写为向量值函数的形式.

Definition 2.3.1.(n 维随机向量) 设 $(\Omega,\mathscr{F},\mathbb{P})$ 是概率空间, $X_k(1\leq k\leq n)$ 是 $(\Omega,\mathscr{F},\mathbb{P})$ 上的随机变量. 定义

$$\begin{aligned}\mathbf{X}:\ \Omega &\to \mathbb{R}^n,\\ \omega &\mapsto \begin{bmatrix}X_1(\omega)\\ X_2(\omega)\\ \vdots\\ X_n(\omega)\end{bmatrix},\end{aligned}$$

称为 $(\Omega,\mathscr{F},\mathbb{P})$ 上的一个 n 维**随机向量 (random vector)**, 每个 X_k 称为该随机向量的分量.

我们将分布函数的定义相应扩展, 一个自然的方式是扩展为 $\mathbb{R}^n$ 上的函数

$$F(\mathbf{x})=\mathbb{P}(\mathbf{X}\leq\mathbf{x})=\mathbb{P}(\{\omega\in\Omega\mid X_k(\omega)\leq x_k,\forall 1\leq k\leq n\}).$$

Definition 2.3.2.(联合分布函数) 设 $(\Omega,\mathscr{F},\mathbb{P})$ 是概率空间, $\mathbf{X}$ 为其上的 n 维随机向量. 定义

$$F(\mathbf{x})=\mathbb{P}\left(\bigcap_{k=1}^{n}\{\omega\in\Omega\mid X_k(\omega)\leq x_k\}\right)=\mathbb{P}(\{\omega\in\Omega\mid X_k(\omega_k)\leq x_k,1\leq k\leq n\})$$

为 X 的**联合分布函数 (joint distribution function)**. 各个分量的分布函数

$$F_k(x)=\mathbb{P}\left(\{\omega\in\Omega\mid X_k(\omega)\leq x\}\right)$$

称为 X_k 的**边缘分布函数 (marginal distribution function)**. 据测度的连续性, 这也可以由

$$F_k(x_k)=\lim_{x_j\to+\infty,j\neq k}\mathbb{P}(\{\omega\in\Omega\mid X_j(\omega)\leq x_j,\forall 1\leq j\leq n\})=\lim_{x_j\to+\infty,j\neq k}F(\mathbf{x})$$

得到.

类似于一元的情形, 联合分布函数也可以决定存在一个随机向量, 以自身为分布.

Theorem 2.3.1.(Lebesgue-Stieljes) 设 $F:\mathbb{R}^n\to\mathbb{R}$ 关于每个分量单调上升, 在任意一点处右连续且左极限存在, 满足

$$\lim_{x_k\to-\infty,\forall 1\le k\le n}F(\mathbf{x})=0,\qquad \lim_{x_k\to+\infty,\forall 1\le k\le n}F(\mathbf{x})=1.$$

则存在概率空间 $(\mathbb{R}^n,\mathscr{F},\mathbb{P})$ 以及其上的随机向量 $\mathbf{X}$, 使得 $F(\mathbf{x})$ 是 $\mathbf{X}$ 的联合分布函数.

Proof. 取概率空间 $\Omega=\mathbb{R}^n$, 事件域 $\mathscr{F}=\mathscr{B}_n$, 我们定义区域

$$\prod_{k=1}^n(a_k,b_k]$$

上的概率为

$$\mathbb{P}\left(\prod_{k=1}^n(a_k,b_k]\right)=F(\mathbf{b})-F(\mathbf{a}).$$

注意到

$$\left\{\prod_{k=1}^n(a_k,b_k]\mid a_k,b_k\in\mathbb{R},a_k\le b_k,1\le k\le n\right\}\subseteq\mathcal{P}(\mathbb{R}^n)$$

对有限交封闭, 只要定义其补集的概率

$$\mathbb{P}\left(\mathbb{R}^n\setminus\prod_{k=1}^n(a_k,b_k]\right)=1-(F(\mathbf{b})-F(\mathbf{a})),$$

就在一个代数上定义了概率 $\mathbb{P}$. 同**Theorem 2.2.2.**可知这将生成 $\mathscr{B}_n$ 上的测度, 令随机向量 $\mathbf{X}=\mathrm{id}_{\mathbb{R}^n}$ 即可. □

同样我们可以对绝对连续函数建立联合密度的概念.

Definition 2.3.3.(联合密度函数) 设 $(\Omega,\mathscr{F},\mathbb{P})$ 是概率空间, $\mathbf{X}$ 是其上的 n 维随机向量, $F(\mathbf{x})$ 为 $\mathbf{X}$ 的联合分布函数. 若存在 $f:\mathbb{R}^n\to[0,+\infty)$Lebesgue 可积, 使得

$$\int_{t_k\le x_k}f(\mathbf{t})\mathrm{d}x_1\mathrm{d}x_2\cdots\mathrm{d}x_n=F(\mathbf{x}),$$

则称 $f(\mathbf{x})$ 是随机向量 $\mathbf{X}$ 的**联合密度函数 (joint density function)**.

利用概率分布可以计算边缘分布, 当然也可以利用概率密度计算边缘密度, 我们需要证明这样计算的边缘密度恰好是边缘分布的密度函数.

Proposition 2.3.2.(边缘密度函数) 设 $(\Omega,\mathscr{F},\mathbb{P})$ 是概率空间, $\mathbf{X}$ 是其上的 n 维随机向量, $f(\mathbf{x})$ 为 $\mathbf{X}$ 的联合密度函数. 则随机变量 X_k 的密度函数为

$$f_k(x_k)=\int_{x_j\in\mathbb{R},j\ne k}f(\mathbf{x})\mathrm{d}x_1\mathrm{d}x_2\cdots\mathrm{d}x_n.$$

Proof. 由于被积函数 $f(\mathbf{x})$ 非负, 根据 Tonelli 定理**Theorem B.5.**积分次序可交换, 即

$$\int_{-\infty}^{x_k}\int_{t_j\in\mathbb{R},j\neq k} f(\mathbf{t})\mathrm{d}x_1\mathrm{d}x_2\cdots\mathrm{d}x_n = \lim_{x_j\to+\infty,j\neq k}\int_{t_j\leq x_j} f(\mathbf{t})\mathrm{d}x_1\mathrm{d}x_2\cdots\mathrm{d}x_n.$$

根据广义积分的定义和边缘分布的定义, 上式即

$$\lim_{x_j\to+\infty,j\neq k} F(\mathbf{x}) = F_k(x_k).$$

因此

$$f_k(x_k) = \int_{x_j\in\mathbb{R},j\neq k} f(\mathbf{x})\mathrm{d}x_1\mathrm{d}x_2\cdots\mathrm{d}x_n$$

就是随机变量 X_k 的边缘密度函数. □

类似地有换元公式.

Theorem 2.3.3.(随机向量的换元公式) 设 $(\Omega,\mathscr{F},\mathbb{P})$ 是概率空间, $\mathbf{X}$ 是 n 维随机向量, 联合密度函数为 $f_{\mathbf{X}}(\mathbf{x})$. 随机向量函数

$$\mathbf{Y} = \Phi(\mathbf{X}) = \begin{bmatrix}\varphi_1(\mathbf{X})\\ \varphi_2(\mathbf{X})\\ \vdots\\ \varphi_n(\mathbf{X})\end{bmatrix}$$

连续可微且反函数存在. 则 $\mathbf{Y}$ 的联合密度函数为

$$f_{\mathbf{Y}}(\mathbf{y}) = f_{\mathbf{X}}(\Phi^{-1}(\mathbf{y}))\det(J),$$

其中 J 是 Φ^{-1} 的 Jacobi 矩阵.

Proof. 依照定义

$$F_{\mathbf{Y}}(\mathbf{y}) = \mathbb{P}\left(\varphi_k(x_k)\leq y_k, \forall 1\leq k\leq n\right) = \int_{\varphi_k(\mathbf{x})\leq y_k} f_{\mathbf{X}}(\mathbf{x})\mathrm{d}x_1\mathrm{d}x_2\cdots\mathrm{d}x_n.$$

利用积分换元将 $\mathbf{x}$ 换为 $\Phi^{-1}(\mathbf{t})$, 即得

$$F_{\mathbf{Y}}(\mathbf{y}) = \int_{\varphi_k(\Phi^{-1}(\mathbf{t}))\leq y_k} f_{\mathbf{X}}(\Phi^{-1}(\mathbf{t}))\det(J)\mathrm{d}x_1\mathrm{d}x_2\cdots\mathrm{d}x_n.$$

根据反函数的定义 $\varphi_k(\Phi^{-1}(\mathbf{t})) = t_k$, 再根据定义**Definition 2.3.4.**即得

$$f_{\mathbf{Y}}(\mathbf{y}) = f_{\mathbf{X}}(\Phi^{-1}(\mathbf{y}))\det(J).$$

□

对多个随机变量组成的随机向量, 我们还关心随机变量之间的组合作为新随机变量的函数, 例如考虑商场估计人均消费, 每个人的消费 $X_k(1 \leq k \leq N)$ 视为随机变量, 而总人数 N 也是随机变量, 则我们需要的平均值

$$A = \frac{1}{N}\left(\sum_{k=1}^{N} X_k\right)$$

也是随机变量, 且是若干随机变量的函数.

这里我们考虑一个简单的情形.

Example 2.3.1.(随机变量的和与积的分布) 设 $(\Omega, \mathscr{F}, \mathbb{P})$ 是概率空间, $\mathbf{X} = (X_1, X_2)^T$ 是 2 维随机向量, 联合密度函数为 $f(x_1, x_2)$. 考虑 $X_1 + X_2$ 和 X_1X_2 的概率密度函数. 依照定义

$$F_{X_1+X_2}(x) = \int_{x_1+x_2\leq x} f(x_1, x_2)\mathrm{d}x_1\mathrm{d}x_2 = \int_{-\infty}^{+\infty}\left(\int_{-\infty}^{x-x_1} f(x_1, x_2)\mathrm{d}x_2\right)\mathrm{d}x_1.$$

根据 Tonelli 定理**Theorem B.5.**交换次序, 两边对 x 求导可得

$$f_{X_1+X_2}(x) = \int_{-\infty}^{+\infty} f(x_1, x - x_1)\mathrm{d}x_1.$$

类似地也有

$$f_{X_1+X_2}(x) = \int_{-\infty}^{+\infty} f(x - x_2, x_2)\mathrm{d}x_2.$$

同样

$$F_{X_1X_2}(x) = \int_{x_1x_2\leq x} f(x_1, x_2)\mathrm{d}x_1\mathrm{d}x_2.$$

按照 x_1 的范围展开为

$$\int_0^{+\infty}\left(\int_{-\infty}^{\frac{x}{x_1}} f(x_1, x_2)\mathrm{d}x_2\right)\mathrm{d}x_1 + \int_{-\infty}^{0}\left(\int_{\frac{x}{x_1}}^{+\infty} f(x_1, x_2)\mathrm{d}x_2\right)\mathrm{d}x_1.$$

对 x 求导即得

$$f_{X_1X_2}(x) = \int_0^{+\infty}\frac{1}{x_1}f\left(x_1, \frac{x}{x_1}\right)\mathrm{d}x_1 + \int_{-\infty}^{0}\frac{1}{-x_1}f\left(x_1, \frac{x}{x_1}\right)\mathrm{d}x_1.$$

整理即得

$$f_{X_1X_2}(x) = \int_{-\infty}^{+\infty}\frac{1}{|x_1|}f\left(x_1, \frac{x}{x_1}\right)\mathrm{d}x_1 = \int_{-\infty}^{+\infty}\frac{1}{|x_2|}f\left(\frac{x}{x_2}, x_2\right)\mathrm{d}x_2.$$

同样, 我们给出一些分布函数的实例.

Example 2.3.2.(多项式分布) 考虑某种随机试验有 n 个结果, 取概率空间 Ω_0 为 m 次试验的结果, 而 $\Omega = \Omega_0^n$ 是乘积空间. 如果每次试验独立, 且达成第 k 种结果的概率为 p_k, 令随机变量 X_k 表示达成第 k 种结果的次数, 则

$$\mathbb{P}\left(\bigcap_{k=1}^{m}\{X_k = t_k\}\right) = n!\prod_{k=1}^{m}\frac{p_k^{t_k}}{t_k!}, \quad \sum_{k=1}^{n} t_k = n.$$

称 **X** 服从**多项式分布 (multinomial distribution)**.

Example 2.3.3.(n 维均匀分布) 给定参数 $a_k < b_k (1 \le k \le n)$, 任何概率空间上的随机向量 **X**, 只要有分布函数

$$F(x) = \begin{cases} 0, & x_k \le a_k, \exists 1 \le k \le n, \\ \prod_{k=1}^{n} \min\left\{1, \frac{x_k - a_k}{b_k - a_k}\right\}, & \text{otherwise}, \end{cases}$$

或概率密度函数

$$f(x) = \begin{cases} \prod_{k=1}^{n} \frac{1}{b_k - a_k}, & a_k \le x_k \le b_k, \forall 1 \le k \le n, \\ 0, & \text{otherwise}, \end{cases}$$

就称 X 服从 n 维均匀分布, 记作 $X \sim U(\mathbf{a}, \mathbf{b})$.

Example 2.3.4.(n 维正态分布) 给定参数 $\mu \in \mathbb{R}^n$ 和 n 维正定矩阵 Σ, 任何概率空间上的随机向量 X, 只要有概率密度函数

$$f(\mathbf{x}) = \frac{1}{(2\pi)^{\frac{n}{2}}\det(\Sigma)} \exp\left(-\frac{1}{2}(\mathbf{x}-\mu)^T\Sigma^{-1}(\mathbf{x}-\mu)\right),$$

就称此随机向量服从 n 维正态分布 $\mathbf{X} \sim N(\mu, \Sigma)$.

Example 2.3.5.(2 维正态分布) 2 维正态分布的参数矩阵 Σ 对称, 从而由 3 个参数决定, 可以表达为

$$\mu = \begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \quad \Sigma = \begin{bmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{bmatrix},$$

其逆矩阵

$$\Sigma^{-1} = \frac{1}{\sigma_1^2\sigma_2^2(1-\rho^2)}\begin{bmatrix} \sigma_2^2 & -\rho\sigma_1\sigma_2 \\ -\rho\sigma_1\sigma_2 & \sigma_1^2 \end{bmatrix} = \frac{1}{1-\rho^2}\begin{bmatrix} \sigma_1^{-2} & -\frac{\rho}{\sigma_1\sigma_2} \\ -\frac{\rho}{\sigma_1\sigma_2} & \sigma_2^{-2} \end{bmatrix}.$$

这样概率密度函数

$$\begin{aligned} f(\mathbf{x}) &= \frac{1}{(2\pi)^{\frac{n}{2}}\det(\Sigma)}\exp\left(-\frac{1}{2}(\mathbf{x}-\mu)^T\Sigma^{-1}(\mathbf{x}-\mu)\right) \\ &= \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}}\exp\left(-\frac{\tilde{x_1}^2-2\rho\tilde{x_1}\tilde{x_2}+\tilde{x_2}^2}{2(1-\rho^2)}\right), \end{aligned}$$

其中

$$\tilde{x_1}=\frac{x_1-\mu_1}{\sigma_1},\quad \tilde{x_2}=\frac{x_2-\mu_2}{\sigma_2}.$$

2.4 随机变量的矩

回顾随机变量, 概率分布和概率密度的关系

$$F(x) = \int_{-\infty}^{x} f(t)\mathrm{d}t = \mathbb{P}(X \leq x),$$

如果将后者展开写为测度

$$\mathbb{P}(\{\omega \in \Omega \mid X(\omega) \leq x\}),$$

根据简单函数积分的定义, 一个集合的测度相当于对集合上的特征函数做积分, 也即

$$\mathbb{P}(X \leq x) = \int_{X(\omega)\leq x} 1\mathrm{d}\mathbb{P}.$$

特别地

$$1 = \mathbb{P}(\Omega) = \int_{\Omega} 1\mathrm{d}\mathbb{P}.$$

这带给我们一个观察, 全概率 1 可以视为概率空间 Ω 的元素权重的直接累积. 这样抹除了概率空间本身的信息而只保留了权重求和的信息. 如何才能保留概率空间的信息呢, 一种想法是考虑形式积分

$$\int_{\Omega} \omega\mathrm{d}\mathbb{P},$$

得到的结果在 Ω 生成的自由 $\mathbb{R}$-向量空间中, 从而可以通过作商得到任何想要的信息.

一般而言, 带测度的积分理论要求被积函数是一个到 $\mathbb{R}$ 的映射, 例如 1 可以看作常值映射. 我们知道一个随机变量 $X : \Omega \to \mathbb{R}$ 就是这样的映射, 且反映了概率空间的一个侧面, 因此考虑

$$\int_{\Omega} X(\omega)\mathrm{d}\mathbb{P}$$

是相当合理的. 我们解释此式的意义, 一个随机变量 X 相当于为概率空间 Ω 中的元素分别赋予了一个实数值, 而概率相当于为每个元素赋予了一个权重, 而上述积分就是依权重取随机变量的平均, 即我们期待随机变量平均上取到的值.

Definition 2.4.1.(数学期望) 设 $(\Omega, \mathscr{F}, \mathbb{P})$ 是概率空间, X 是其上的随机变量. 如果积分

$$\mathbb{E}_X(X) = \int_{\Omega} X(\omega)\mathrm{d}\mathbb{P}$$

收敛, 则为随机变量 X 的**数学期望 (mathematical expectation)**. 在不致混淆的情况下也记为 $\mathbb{E}(X)$.

容易看出 $\mathbb{E}(c) = c\mathbb{P}(\Omega) = c$, 这就是说如果给概率空间赋予相同的数, 则依概率为权重的平均就是此数本身, 这是符合直觉的.

以下给出数学期望的基本性质.

Proposition 2.4.1.(数学期望的线性) 设 $(\Omega, \mathscr{F}, \mathbb{P})$ 是概率空间, X 是其上的随机变量, 则有线性

$$\mathbb{E}(\lambda X + \mu Y) = \lambda \mathbb{E}(X) + \mu \mathbb{E}(Y).$$

Proof. 依定义直接计算

$$\mathbb{E}(\lambda X+\mu Y) = \int_\Omega (\lambda X(\omega)+\mu Y(\omega))\mathrm{d}\mathbb{P} = \lambda \int_\Omega X(\omega)\mathrm{d}\mathbb{P}+\mu \int_\Omega Y(\omega)\mathrm{d}\mathbb{P} = \lambda\mathbb{E}(X)+\mu\mathbb{E}(Y).$$

□

数学期望是依测度的积分形式, 并不便于计算, 好在我们可以用分布函数改造为我们熟悉的 Riemann 积分 (求和) 形式.

Proposition 2.4.2.(数学期望的计算) 设 $(\Omega, \mathscr{F}, \mathbb{P})$ 是概率空间, X 是其上的随机变量. 如果随机变量是离散的, 即存在至多可数个点 x_k 和 $p_k \in [0,1]$, 使得

$$X^{-1}(x_k) \in \mathscr{F}, \quad \bigcup_k X^{-1}(x_k) = \Omega, \quad \mathbb{P}(X = x_k) = p_k.$$

则期望

$$\mathbb{E}(X) = \sum_k x_k p_k.$$

如果随机变量是绝对连续的, 即存在密度函数 $f(x)$, 则期望

$$\mathbb{E}(X) = \int_{\mathbb{R}} x f(x)\mathrm{d}x.$$

Proof. 对离散的情形, 根据简单函数积分的定义

$$\mathbb{E}(X) = \sum_k \int_{X^{-1}(x_k)} X(\omega)\mathrm{d}\mathbb{P} = \sum_k \int_{X^{-1}(x_k)} x_k \mathrm{d}\mathbb{P} = \sum_k x_k \mathbb{P}(X^{-1}(x_k)),$$

而

$$\mathbb{P}(X^{-1}(x_k)) = \mathbb{P}(X = x_k) = p_k,$$

代入即证. 现在考虑绝对连续的情形. 取 $[-n, n]$ 的均匀分割 $x_0, x_1, \ldots, x_{l(n)}$, 使得当 n 增大时相邻分割点的距离趋于 0 且覆盖 n 的所有分割点. 定义简单逼近

$$X_n(\omega) = x_{k+1} \iff X(\omega) \in (x_k, x_{k+1}],$$

其他时候均取 0, 则显然关于 n 单调下降几乎一致收敛于 X. 根据非负可测函数积分的定义

$$\mathbb{E}(X) = \int_\Omega X(\omega)\mathrm{d}\mathbb{P} = \lim_{n\to\infty} \int_\Omega X_n(\omega)\mathrm{d}\mathbb{P},$$

根据先前对简单函数的计算

$$\int_\Omega X_n(\omega)\mathrm{d}\mathbb{P} = \sum_{k=0}^{l(n)} x_k \mathbb{P}(X_n(\omega) = x_k) = \sum_{k=0}^{l(n)} x_k \mathbb{P}(x_{k-1} < X(\omega) \leq x_k).$$

由于概率和分布函数由积分表达

$$\int_\Omega X_n(\omega)\mathrm{d}\mathbb{P} = \sum_{k=0}^{l(n)} x_k \int_{x_{k-1}}^{x_k} f(x)\mathrm{d}x = \sum_{k=0}^{l(n)} \int_{x_{k-1}}^{x_k} x_k f(x)\mathrm{d}x.$$

现在定义

$$f_n(x) = x_k f(x), \quad x \in (x_{k-1}, x_k],$$

其他时候均取 0, 则 $f_n(x) \geq xf(x)$ 且单调下降收敛到 $xf(x)$, 于是根据单调收敛定理**Theorem B.2.**积分

$$\mathbb{E}(X) = \lim_{n\to\infty} \int_\Omega X_n(\omega)\mathrm{d}\mathbb{P} = \lim_{n\to\infty} \int_{\mathbb{R}} f_n(x)\mathrm{d}x = \int_{\mathbb{R}} xf(x)\mathrm{d}x.$$

□

这说明要计算随机变量, 以至随机变量函数的期望, 只要计算出相应的分布函数或密度函数, 做积分即可.

Example 2.4.1.(Cauchy 分布的期望) 考虑 Cauchy 分布, 如果期望存在, 则必然可以通过**Proposition 2.4.2.**计算, 因为有密度函数

$$f(x) = \frac{1}{\pi(1+x^2)}.$$

然而实际计算会发现

$$\int_{-\infty}^{+\infty} |x|\mathrm{d}F(x) = \int_{-\infty}^{+\infty} |x| f(x)\mathrm{d}x = \int_{-\infty}^{+\infty} \frac{|x|}{\pi(1+x^2)}\mathrm{d}x = \int_0^{+\infty} \frac{2x}{\pi(1+x^2)}\mathrm{d}x,$$

这一积分的结果是

$$\lim_{x\to+\infty} \frac{1}{\pi} \ln(1+x^2) = +\infty,$$

说明积分不收敛, 于是数学期望不存在.

对于非负随机变量, 可以用概率代替密度函数进行计算.

Proposition 2.4.3.(非负随机变量的期望) 设 $(\Omega, \mathscr{F}, \mathbb{P})$ 是概率空间, $X : \Omega \to \mathbb{R}_{\geq 0}$ 是随机变量, 使得数学期望 $\mathbb{E}(X)$ 存在, 则

$$\mathbb{E}(X) = \int_0^{+\infty} \mathbb{P}(X > x)\mathrm{d}x.$$

Proof. 我们在乘积空间 $\Omega \times [0,+\infty)$ 上考虑此问题. 对一个固定的 $\omega \in \Omega$, 随机变量可以写为积分

$$X(\omega) = \int_0^{X(\omega)} 1\mathrm{d}x = \int_0^{+\infty} \chi_{\{x<X(\omega)\}}\mathrm{d}x.$$

两边在 Ω 上关于测度 $\mathbb{P}$ 求积分

$$\mathbb{E}(X) = \int_\Omega X(\omega)\mathrm{d}\mathbb{P} = \int_\Omega \left(\int_0^{+\infty} \chi_{\{x<X(\omega)\}}\mathrm{d}x\right)\mathrm{d}\mathbb{P}.$$

根据 Tonelli 定理**Theorem B.5.**可以换序

$$\mathbb{E}(X) = \int_0^{+\infty} \left(\int_\Omega \chi_{\{x<X(\omega)\}}\mathrm{d}\mathbb{P}\right)\mathrm{d}x = \int_0^{+\infty} \mathbb{P}(X>x)\mathrm{d}x.$$

□

特别地, 当 X 是离散型随机变量时, 设随机变量的取值为

$$0 = x_0 < x_1 < x_2 < \cdots < x_n < \cdots$$

则上式为

$$\mathbb{E}(X) = \sum_{k=1}^{\infty}(x_k - x_{k-1})\mathbb{P}(X > x_k).$$

当 X 恰好取正整数值时, 上式可进一步写为

$$\mathbb{E}(X) = \sum_{k=1}^{\infty}\mathbb{P}(X > k).$$

现在我们考虑更一般的情况, 随机变量并不直接由熟悉的对应关系 $X:\Omega\to\mathbb{R}$ 给出, 而是由若干较为简单随机变量 X_k 的函数的形式给出, 以下定理给出结果说明了如何计算这种随机变量期望. 该定理的证明与普通随机变量是类似的.

Proposition 2.4.4.(随机变量函数数学期望的计算) 设 $(\Omega,\mathscr{F},\mathbb{P})$ 是概率空间, $\mathbf{X}$ 是其上的绝对连续 m 维随机向量, $\varphi:\mathbb{R}^m\to\mathbb{R}$ 是可测函数. 设 $\mathbf{X}$ 的密度函数为 $f(\mathbf{x})$, 则随机变量函数 $\varphi(\mathbf{X}) = \varphi\circ\mathbf{X}:\Omega\to\mathbb{R}$ 作为随机变量的期望

$$\mathbb{E}(\mathbf{X}) = \int_{\mathbb{R}^m}\varphi(\mathbf{x})f(\mathbf{x})\mathrm{d}x_1\mathrm{d}x_2\cdots\mathrm{d}x_m.$$

Proof. 取 $[-n,n]$ 的均匀分割 $x_0, x_1, \ldots, x_{l(n)}$, 使得当 n 增大时相邻分割点的距离趋于 0 且覆盖 n 的所有分割点. 定义简单逼近

$$Y_n(\omega) = \varphi\left(\begin{bmatrix} x_{k_1+1} \\ x_{k_2+1} \\ \vdots \\ x_{k_m+1}\end{bmatrix}\right) \iff X_i(\omega)\in(x_{k_i}, x_{k_i+1}], \forall 1\le i\le m,$$

其他时候均取 0, 则显然关于 n 几乎一致收敛于 $\varphi\circ\mathbf{X}$. 根据非负可测函数积分的定义

$$\mathbb{E}(\varphi(\mathbf{X}))=\int_\Omega\varphi(\mathbf{X}(\omega))\mathrm{d}\mathbb{P}=\lim_{n\to\infty}\int_\Omega Y_n(\omega)\mathrm{d}\mathbb{P},$$

根据**Proposition 2.4.2.**对简单函数的结果

$$\int_\Omega Y_n(\omega)\mathrm{d}\mathbb{P}=\sum_{0\le k_i\le l(n),1\le i\le m}\varphi\left(\begin{bmatrix}x_{k_1+1}\\x_{k_2+1}\\\vdots\\x_{k_m+1}\end{bmatrix}\right)\mathbb{P}(x_{k_i-1}<X_i(\omega)\le x_{k_i},\forall 1\le i\le m).$$

由于概率和分布函数由积分表达

$$\int_\Omega X_n(\omega)\mathrm{d}\mathbb{P}=\sum_{0\le k_i\le l(n),1\le i\le m}\varphi\left(\begin{bmatrix}x_{k_1+1}\\x_{k_2+1}\\\vdots\\x_{k_m+1}\end{bmatrix}\right)\int_{x_{k_i}-1<t_i\le x_{k_i}}f(\mathbf{x})\mathrm{d}x_1\mathrm{d}x_2\cdots\mathrm{d}x_m.$$

现在定义

$$f_n(\mathbf{x})=\varphi\left(\begin{bmatrix}x_{k_1+1}\\x_{k_2+1}\\\vdots\\x_{k_m+1}\end{bmatrix}\right)f(\mathbf{x}),\quad x_i\in(x_{k_i-1},x_{k_i}],\quad\forall 1\le i\le m,$$

其他时候均取 0, 则 $f_n(\mathbf{x})$ 点点收敛到 $\varphi(\mathbf{x})f(\mathbf{x})$, 于是根据有界收敛定理**Theorem B.3.**积分

$$\mathbb{E}(\varphi(\mathbf{X}))=\lim_{n\to\infty}\int_\Omega Y_n(\omega)\mathrm{d}\mathbb{P}=\lim_{n\to\infty}\int_{\mathbb{R}^n}f_n(\mathbf{x})\mathrm{d}x=\int_{\mathbb{R}^n}\varphi(\mathbf{x})f(\mathbf{x})\mathrm{d}x_1\mathrm{d}x_2\cdots\mathrm{d}x_m.$$

□

由此我们可以计算一类特殊的期望, 称为随机变量的矩.

Definition 2.4.2.(α 阶矩) 给定 $\alpha>0$. 设 $(\Omega,\mathscr{F},\mathbb{P})$ 是概率空间, X 是其上的随机变量, 使得 X, X^2 和 X^α 的数学期望存在, 则称 $\mathbb{E}(X^\alpha)$ 为随机变量 X 的 α 阶**矩 (moment)**.

根据**Proposition 2.4.4.**中取 $n=1$ 和 $\varphi(x)=x^\alpha$, 可得 X 的 α 阶矩

$$\mathbb{E}(X^\alpha)=\int_{\mathbb{R}}x^\alpha f(x)\mathrm{d}x.$$

这样, $\mathbb{P}(\Omega)=1$ 可以视作 0 阶矩 $\mathbb{E}(X^0)$, 期望当然就是 1 阶矩, 另外我们还关心 2 阶矩.

Definition 2.4.3.(方差) 设 $(\Omega,\mathscr{F},\mathbb{P})$ 是概率空间, X 是其上的随机变量, 使得 X 的 $1,2$ 阶矩存在, 则称

$$\mathrm{Var}_X(X)=\mathbb{E}((X-\mathbb{E}(X))^2)$$

为随机变量 X 的**方差 (variance)**. 在不致混淆的情况下也记为 $\mathrm{Var}(X)$.

以下命题说明了方差与 $1,2$ 阶矩的关系.

Proposition 2.4.5.(方差的计算) 设 $(\Omega,\mathscr{F},\mathbb{P})$ 是概率空间, X 是其上的随机变量, 使得 X 的 $1,2$ 阶矩存在, 则方差

$$\mathrm{Var}(X)=\mathbb{E}\left(X^2\right)-\mathbb{E}(X)^2.$$

特别地, 若 X 非负, 则

$$\mathrm{Var}(X)=2\int_0^{+\infty}x\mathbb{P}(X>x)\mathrm{d}x-\mathbb{E}(X)^2.$$

Proof. 利用期望的线性**Proposition 2.4.1.**, 有

$$\mathrm{Var}(X)=\mathbb{E}(X^2-2\mathbb{E}(X)X+\mathbb{E}(X)^2)=\mathbb{E}\left(X^2\right)-2\mathbb{E}(X)^2+\mathbb{E}(X)^2=\mathbb{E}\left(X^2\right)-\mathbb{E}(X)^2.$$

若 X 非负, 结合**Proposition 2.4.3.**的结果, 取 $\alpha=2$ 即得

$$\mathrm{Var}(X)=2\int_0^{+\infty}x\mathbb{P}(X>x)\mathrm{d}x-\mathbb{E}(X)^2.$$

□

我们接着说明方差的性质.

Proposition 2.4.6.(方差的二阶线性) 设 $(\Omega,\mathscr{F},\mathbb{P})$ 是概率空间, X 是其上的随机变量, 使得 $1,2$ 阶矩存在, 则方差有二阶线性

$$\mathrm{Var}(\lambda X+\mu Y)=\lambda^2\,\mathrm{Var}(X)+\mu^2\,\mathrm{Var}(Y)+2\lambda\mu\left(\mathbb{E}(XY)-\mathbb{E}(X)\mathbb{E}(Y)\right).$$

特别地

$$\mathrm{Var}(\lambda X+\mu)=\lambda^2\,\mathrm{Var}(X),$$

进而常数的方差为 0.

Proof. 根据定义

$$\mathrm{Var}(\lambda X+\mu Y)=\mathbb{E}\left((\lambda X+\mu Y-\mathbb{E}(\lambda X+\mu Y))^2\right).$$

根据期望的线性**Proposition 2.4.1.**

$$\mathbb{E}\left((\lambda(X-\mathbb{E}(X))+\mu(Y-\mathbb{E}(Y))^2\right),$$

展开得

$$\mathbb{E}\left(\lambda^2(X-\mathbb{E}(X))^2+\mu^2(Y-\mathbb{E}(Y))^2+2\lambda\mu(X-\mathbb{E}(X))(Y-\mathbb{E}(Y))\right).$$

再次用线性变为

$$\lambda^2\mathbb{E}\left((X-\mathbb{E}(X))^2\right)+\mu^2\mathbb{E}\left((Y-\mathbb{E}(Y))^2\right)+2\lambda\mu\mathbb{E}\left((X-\mathbb{E}(X))(Y-\mathbb{E}(Y))\right).$$

前两个期望恰好就是 $\mathrm{Var}(X)$ 和 $\mathrm{Var}(Y)$ 的定义, 最后一个期望展开得

$$\mathbb{E}(XY)-\mathbb{E}(X)\mathbb{E}(Y)-\mathbb{E}(Y)\mathbb{E}(X)+\mathbb{E}(X)\mathbb{E}(Y)=\mathbb{E}(XY)-\mathbb{E}(X)\mathbb{E}(Y).$$

现在令 $Y=1$, 则由于常数的期望是自身, 有 $Y-\mathbb{E}(Y)=0$, 代入最后一个期望未展开的式子得

$$\lambda^2\mathbb{E}\left((X-\mathbb{E}(X))^2\right)+\mu^2\mathbb{E}\left(0\right)+2\lambda\mu\mathbb{E}\left((X-\mathbb{E}(X))0\right)=\lambda^2\,\mathrm{Var}(X).$$

再令 X 为常数即知方差为 0. □

上述分解表明, 对两个随机变量 X,Y 而言, 交叉项的期望

$$\mathbb{E}\left((X-\mathbb{E}(X))(Y-\mathbb{E}(Y))\right)=\mathbb{E}(XY)-\mathbb{E}(X)\mathbb{E}(Y)$$

衡量了和的方差与方差的和的差异, 这是两个随机变量之间的某种关系.

Definition 2.4.4.(协方差) 设 $(\Omega,\mathscr{F},\mathbb{P})$ 是概率空间, X,Y 是其上的随机变量, 使得 X,Y 的 $1,2$ 阶矩存在. 如果期望

$$\mathbb{E}((X-\mathbb{E}(X))(Y-\mathbb{E}(Y)))=\mathbb{E}(XY)-\mathbb{E}(X)\mathbb{E}(Y)$$

存在, 则称为 X 与 Y 的**协方差 (covariance)**, 记作 $\mathrm{Cov}(X,Y)$. 若 $\mathbf{X}$ 是 n 维随机向量, 两两协方差存在, 则称

$$\Sigma(\mathbf{X})=\begin{bmatrix}\mathrm{Cov}(X_1,X_1) & \mathrm{Cov}(X_1,X_2) & \cdots & \mathrm{Cov}(X_1,X_n)\\ \mathrm{Cov}(X_2,X_1) & \mathrm{Cov}(X_2,X_2) & \cdots & \mathrm{Cov}(X_2,X_n)\\ \vdots & \vdots & \ddots & \vdots\\ \mathrm{Cov}(X_n,X_1) & \mathrm{Cov}(X_n,X_2) & \cdots & \mathrm{Cov}(X_n,X_n)\end{bmatrix}$$

为随机向量 $\mathbf{X}$ 的协方差矩阵.

现在我们可以将方差的二阶线性写为更紧凑的形式, 分为二阶线性部分

$$\mathrm{Var}(\lambda X+\mu)=\lambda^2\,\mathrm{Var}(X)$$

和协方差部分

$$\mathrm{Var}(X+Y)=\mathrm{Var}(X)+\mathrm{Var}(Y)+2\,\mathrm{Cov}(X,Y).$$

与向量内积

$$\|u+v\|^2=\|u\|^2+\|v\|^2+2u\cdot v$$

比较, 我们知道向量夹角由

$$\cos\theta=\frac{u\cdot v}{\|u\|\|v\|}$$

定义, 类似地可以认为

$$\frac{\mathrm{Cov}(X,Y)}{\sqrt{\mathrm{Var}(X)}\sqrt{\mathrm{Var}(Y)}}$$

定义了某种意义上随机变量的夹角.

Definition 2.4.5.(相关系数) 设 $(\Omega,\mathscr{F},\mathbb{P})$ 是概率空间, X,Y 是其上的随机变量, 使得 X,Y 的 $1,2$ 阶矩存在. 如果期望

$$\mathbb{E}\left(\frac{X-\mathbb{E}(X)}{\sqrt{\mathrm{Var}(X)}}\frac{Y-\mathbb{E}(Y)}{\sqrt{\mathrm{Var}(Y)}}\right)=\frac{\mathrm{Cov}(X,Y)}{\sqrt{\mathrm{Var}(X)}\sqrt{\mathrm{Var}(Y)}}$$

存在, 则称为 X 与 Y 的相关系数, 记作 $\rho(X,Y)$.

从另一个角度看, 计算

$$\frac{X-\mathbb{E}(X)}{\sqrt{\mathrm{Var}(X)}}$$

即减掉期望作为平均, 再除掉标准差作归一化, 所得到随机变量的协方差. 根据这个可以猜测, 相关系数在线性变换下是不变的, 因为线性变换只会改变期望和方差, 而不会改变随机变量的结构.

Proposition 2.4.7.(协方差和相关系数的线性) 设 $(\Omega,\mathscr{F},\mathbb{P})$ 是概率空间, X 是其上的随机变量, 使得 $1,2$ 阶矩存在, 则协方差具有双线性

$$\mathrm{Cov}(\lambda X+\mu Y,Z)=\lambda\,\mathrm{Cov(X,Z)}+\mu\,\mathrm{Cov}(Y,Z).$$

相关系数具有双线性不变性

$$|\rho(\lambda X+\mu,Y)|=|\rho(X,Y)|.$$

Proof. 直接计算

$$\mathrm{Cov}(\lambda X+\mu Y,Z)=\mathbb{E}(\lambda XZ+\mu YZ)-\mathbb{E}(\lambda X+\mu Y)\mathbb{E}(Z).$$

根据期望的线性**Proposition 2.4.1.**展开得

$$\lambda\mathbb{E}(XZ)+\mu\mathbb{E}(YZ)-\lambda\mathbb{E}(X)\mathbb{E}(Z)-\mu\mathbb{E}(Y)\mathbb{E}(Z)=\lambda\,\mathrm{Cov}(X,Z)+\mu\,\mathrm{Cov}(Y,Z),$$

根据对称性可知双线性. 根据方差的二阶线性**Proposition 2.4.6.**以及相关系数的定义可知

$$\rho(\lambda X+\mu,Y)=\frac{\mathrm{Cov}(\lambda X+\mu,Y)}{\sqrt{\mathrm{Var}(\lambda X+\mu)}\sqrt{\mathrm{Var}(Y)}}=\frac{\lambda\,\mathrm{Cov}(X,Y)+\mu\,\mathrm{Cov}(1,Y)}{\sqrt{\lambda^2\,\mathrm{Var}(X)}\sqrt{\mathrm{Var}(Y)}}.$$

根据协方差的定义显然任意一个为常数都导致 $c-\mathbb{E}(c)=0$, 从而协方差为 0, 于是

$$|\rho(\lambda X+\mu,Y)|=\frac{|\lambda\,\mathrm{Cov}(X,Y)|}{|\lambda|\sqrt{\mathrm{Var}(X)}\sqrt{\mathrm{Var}(Y)}}=|\rho(X,Y)|.$$

□

下面定理说明相关系数与夹角余弦有十分相似的性质.

Proposition 2.4.8.(相关系数的取值范围) 设 $(\Omega,\mathscr{F},\mathbb{P})$ 是概率空间, X,Y 是其上的随机变量, 使得相关系数 $\rho(X,Y)$ 存在, 则 $|\rho(X,Y)|\leq 1$.

Proof. 利用积分的 Cauchy-Schwarz 不等式**Theorem B.6.**, 容易得到

$$\mathbb{E}(XY)^2=\left(\int_\Omega X(\omega)Y(\omega)\mathrm{d}\mathbb{P}\right)^2\leq\int_\Omega X(\omega)^2\mathrm{d}\mathbb{P}\int_\Omega Y(\omega)^2\mathrm{d}\mathbb{P}=\mathbb{E}\left(X^2\right)\mathbb{E}\left(Y^2\right).$$

于是展开 $\mathrm{Cov}(X,Y)^2$ 会得到

$$\mathbb{E}((X-\mathbb{E}(X))(Y-\mathbb{E}(Y)))^2\leq\mathbb{E}\left(((X-\mathbb{E}(X))^2\right)\mathbb{E}\left(((Y-\mathbb{E}(Y))^2\right)=\mathrm{Var}(X)\,\mathrm{Var}(Y).$$

这就说明了

$$\rho(X,Y)^2\leq 1\implies|\rho(X,Y)|\leq 1.$$

□

接下来我们照例给出一些分布低阶矩的计算.

Example 2.4.2.(二项分布的期望和方差) 设 $(\Omega,\mathscr{F},\mathbb{P})$ 是概率空间, X 是其上的随机变量, 服从二项分布 $X\sim\mathrm{Bi}(n,p)$, 则利用组合恒等式, 期望

$$\mathbb{E}(X)=\sum_{k=0}^{n}kC_n^kp^k(1-p)^{n-k}=np.$$

二阶矩

$$\mathbb{E}\left(X^2\right)=\sum_{k=0}^{n}k^2C_n^kp^k(1-p)^{n-k}=n(n-1)p^2+np,$$

于是方差

$$\mathrm{Var}(X)=n(n-1)p^2+np-(np)^2=np(1-p).$$

Example 2.4.3.(几何分布的期望和方差) 设 $(\Omega,\mathscr{F},\mathbb{P})$ 是概率空间, X 是其上的随机变量, 服从几何分布 $X\sim\mathrm{Ge}(p)$, 即

$$\mathbb{P}(X=k)=p(1-p)^{k-1}.$$

则期望

$$\mathbb{E}(X)=\sum_{k=1}^{\infty}kp(1-p)^{k-1}=\frac{1}{p}.$$

二阶矩

$$\mathbb{E}\left(X^2\right)=\sum_{k=1}^{\infty}k^2p(1-p)^{k-1}=\frac{2-p}{p^2},$$

于是方差

$$\mathrm{Var}(X)=\frac{2-p}{p^2}-\frac{1}{p^2}=\frac{1-p}{p^2}.$$

Example 2.4.4.(超几何分布的期望和方差) 设 $(\Omega,\mathscr{F},\mathbb{P})$ 是概率空间, X 是其上的随机变量, 服从超几何分布 $X\sim\mathrm{H}(n,M,N)$

$$\mathbb{P}(X=m)=\frac{C_M^mC_{N-M}^{n-m}}{C_N^n}.$$

则期望

$$\mathbb{E}(X)=\sum_{m=1}^{\infty}m\frac{C_M^mC_{N-M}^{n-m}}{C_N^n}=\frac{M}{N}n.$$

二阶矩

$$\mathbb{E}\left(X^2\right)=\sum_{m=1}^{\infty}m^2\frac{C_M^mC_{N-M}^{n-m}}{C_N^n}=\frac{M(M-1)n(n-1)+nM(N-1)}{N(N-1)},$$

于是方差

$$\mathrm{Var}(X)=\frac{Mn(M-N)(n-N)}{N^2(N-1)}.$$

Example 2.4.5.(Poisson 分布的期望和方差) 设 $(\Omega, \mathscr{F}, \mathbb{P})$ 是概率空间, X 是其上的随机变量, 服从 Poisson 分布 $X \sim \mathrm{Poi}(\lambda)$

$$\mathbb{P}(X=k)=\frac{\lambda^k \mathrm{e}^{-\lambda}}{k!}.$$

则期望

$$\mathbb{E}(X)=\sum_{k=1}^{\infty} k\frac{\lambda^k \mathrm{e}^{-\lambda}}{k!}=\lambda\sum_{k=1}^{\infty}\frac{\lambda^{k-1}\mathrm{e}^{-\lambda}}{(k-1)!}=\lambda.$$

二阶矩

$$\mathbb{E}\left(X^2\right)=\sum_{k=1}^{\infty} k^2\frac{\lambda^k \mathrm{e}^{-\lambda}}{k!}=\lambda^2\sum_{k=2}^{\infty}\frac{\lambda^{k-2}\mathrm{e}^{-\lambda}}{(k-2)!}+\mathbb{E}(\lambda)=\lambda^2+\lambda,$$

于是方差

$$\mathrm{Var}(X)=\lambda^2+\lambda-\lambda^2=\lambda.$$

Example 2.4.6.(1 维均匀分布的期望和方差) 设 $(\Omega, \mathscr{F}, \mathbb{P})$ 是概率空间, X 是其上的随机变量, 服从均匀分布 $X \sim U(a,b)$. 则期望

$$\mathbb{E}(X)=\int_a^b \frac{x}{b-a}\mathrm{d}x=\frac{a+b}{2}.$$

二阶矩

$$\mathbb{E}\left(X^2\right)=\int_a^b \frac{x^2}{b-a}\mathrm{d}x=\frac{a^2+ab+b^2}{3},$$

于是方差

$$\mathrm{Var}(X)=\frac{a^2+ab+b^2}{3}-\frac{a^2+2ab+b^2}{4}=\frac{(a-b)^2}{12}.$$

Example 2.4.7.(指数分布的期望和方差) 设 $(\Omega, \mathscr{F}, \mathbb{P})$ 是概率空间, X 是其上的随机变量, 服从指数分布 $X \sim \mathrm{Exp}(\lambda)$. 则期望

$$\mathbb{E}(X)=\int_0^{+\infty} x\lambda \mathrm{e}^{-\lambda x}\mathrm{d}x=\frac{1}{\lambda}.$$

二阶矩

$$\mathbb{E}\left(X^2\right)=\int_0^{+\infty} x^2\lambda \mathrm{e}^{-\lambda x}\mathrm{d}x=\frac{2}{\lambda^2},$$

于是方差

$$\mathrm{Var}(X)=\frac{2}{\lambda^2}-\frac{1}{\lambda^2}=\frac{1}{\lambda^2}.$$

Example 2.4.8.(Gamma 分布的期望和方差) 设 $(\Omega, \mathscr{F}, \mathbb{P})$ 是概率空间, X 是其上的随机变量, 服从 Gamma 分布 $X \sim \Gamma(\alpha, \lambda)$. 则期望

$$\mathbb{E}(X) = \int_0^{+\infty} x \mathrm{e}^{-\lambda x} \lambda^\alpha \frac{x^{\alpha-1}}{\Gamma(\alpha)} \mathrm{d}x = \frac{\alpha}{\lambda}.$$

二阶矩

$$\mathbb{E}\left(X^2\right) = \int_0^{+\infty} x^2 \mathrm{e}^{-\lambda x} \lambda^\alpha \frac{x^{\alpha-1}}{\Gamma(\alpha)} \mathrm{d}x = \frac{\alpha(\alpha+1)}{\lambda^2},$$

于是方差

$$\mathrm{Var}(X) = \frac{\alpha(\alpha+1)}{\lambda^2} - \frac{\alpha^2}{\lambda^2} = \frac{\alpha}{\lambda^2}.$$

Example 2.4.9.(正态分布的期望和方差) 设 $(\Omega, \mathscr{F}, \mathbb{P})$ 是概率空间, X 是其上的随机变量, 服从正态分布 $X \sim N(\mu, \sigma^2)$. 则期望

$$\mathbb{E}(X) = \int_{-\infty}^{+\infty} x \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) \mathrm{d}x = \mu.$$

二阶矩

$$\mathbb{E}\left(X^2\right) = \int_{-\infty}^{+\infty} x^2 \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) \mathrm{d}x = \sigma^2 + \mu^2,$$

于是方差

$$\mathrm{Var}(X) = \sigma^2 + \mu^2 - \mu^2 = \sigma^2.$$

这说明正态分布的参数恰好是期望和方差.

下面的例子计算了最常用的一个协方差和相关系数.

Example 2.4.10.(2 维正态分布的协方差) 对**Example 2.3.5.**给出的概率密度函数, 计算

$$\mathbb{E}(X_1 X_2) = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} \frac{x_1 x_2}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp\left(-\frac{\tilde{x_1}^2 - 2\rho\tilde{x_1}\tilde{x_2} + \tilde{x_1}^2}{2(1-\rho^2)}\right) \mathrm{d}x_1 \mathrm{d}x_2.$$

换元得到

$$E(X_1 X_2) = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} \frac{(\sigma_1\tilde{x_1} + \mu_1)(\sigma_2\tilde{x_2} + \mu_2)}{2\pi\sqrt{1-\rho^2}} \exp\left(-\frac{\tilde{x_1}^2 - 2\rho\tilde{x_1}\tilde{x_2} + \tilde{x_2}^2}{2(1-\rho^2)}\right) \mathrm{d}\tilde{x_1} \mathrm{d}\tilde{x_2}.$$

利用 Gauss 积分的结果容易得到

$$\int_{-\infty}^{+\infty} \mathrm{e}^{-(ax^2+bx+c)} \mathrm{d}x = \int_{-\infty}^{+\infty} \exp\left(-a\left(x + \frac{b}{2a}\right)^2 + \frac{b^2}{4a} - c\right) \mathrm{d}x = \sqrt{\frac{\pi}{a}} \exp\left(\frac{b^2}{4a} - c\right).$$

而显然有

$$\int_{-\infty}^{+\infty}(2ax+b)\mathrm{e}^{-(ax^2+bx+c)}\mathrm{d}x=0,$$

于是

$$\int_{-\infty}^{+\infty}x\mathrm{e}^{-(ax^2+bx+c)}\mathrm{d}x=-\frac{b}{2a}\sqrt{\frac{\pi}{a}}\exp\left(\frac{b^2}{4a}-c\right).$$

代入计算内层积分

$$\mathbb{E}(X_1X_2)=\frac{1}{\sqrt{2\pi}}\int_{-\infty}^{+\infty}(\rho\sigma_1\tilde{x_2}+\mu_1)(\sigma_2\tilde{x_2}+\mu_2)\exp\left(-\frac{\tilde{x_2}^2}{2}\right)\mathrm{d}\tilde{x_2}.$$

利用分部积分

$$\int_{-\infty}^{+\infty}x^2\mathrm{e}^{-ax^2}\mathrm{d}x=-\frac{1}{2a}\int_{-\infty}^{+\infty}x\mathrm{d}\mathrm{e}^{-ax^2}=\frac{1}{2a}\int_{-\infty}^{+\infty}\mathrm{e}^{-ax^2}\mathrm{d}x=\frac{1}{2a}\sqrt{\frac{\pi}{a}},$$

于是

$$\mathbb{E}(X_1X_2)=\frac{1}{\sqrt{2\pi}}\left(\rho\sigma_1\sigma_2\sqrt{2\pi}+(\rho\sigma_1\mu_2+\sigma_2\mu_1)0+\mu_1\mu_2\sqrt{2\pi}\right)=\rho\sigma_1\sigma_2+\mu_1\mu_2.$$

类似地边缘密度函数

$$f_{X_1}(x_1)=\int_{-\infty}^{+\infty}\frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}}\exp\left(-\frac{\tilde{x_1}^2-2\rho\tilde{x_1}\tilde{x_2}+\tilde{x_1}^2}{2(1-\rho^2)}\right)\mathrm{d}x_2,$$

计算得

$$f_{X_1}(x_1)=\frac{1}{\sqrt{2\pi}\sigma_1}\exp\left(-\frac{(x_1-\mu_1)^2}{2\sigma_1^2}\right)$$

是正态分布, 从而 $\mathbb{E}(X_1)=\mu_1$, $\mathrm{Var}(X_1)=\sigma_1^2$. 于是协方差

$$\mathrm{Cov}(X_1,X_2)=\mathbb{E}(X_1X_2)-\mathbb{E}(X_1)\mathbb{E}(X_2)=\rho\sigma_1\sigma_2+\mu_1\mu_2-\mu_1\mu_2=\rho\sigma_1\sigma_2$$

相关系数

$$\rho(X_1,X_2)=\frac{\mathrm{Cov}(X_1,X_2)}{\sqrt{\mathrm{Var}(X_1)\,\mathrm{Var}(X_2)}}=\frac{\rho\sigma_1\sigma_2}{\sigma_1\sigma_2}=\rho.$$

这说明 2 维正态分布的参数 ρ 就是相关系数.

2.5 条件概率

概率论有别于一般测度论的最特殊之处在于独立和条件的概念. 独立描述了随机变量的无关性, 条件刻画了随机变量之间如何依赖. 一些联合分布区别于各自分布的乘积, 其原因就是失去了独立性. 我们从独立性的一般定义开始.

Definition 2.5.1.(独立性) 设 $(\Omega, \mathscr{F}, \mathbb{P})$ 是概率空间, $A_i \in \mathscr{F}(1 \leq i \leq n)$. 称这 n 个事件**独立 (independent)** 当且仅当对任意多个的排列 $1 \leq i_1 < i_2 < \cdots < i_k \leq n$, 都有

$$\mathbb{P}\left(\bigcap_{j=1}^{k} A_{i_j}\right) = \prod_{j=1}^{k} \mathbb{P}(A_{i_j}).$$

设 $X_i(1 \leq i \leq n)$ 是 n 个随机变量, 称这 n 个随机变量独立当且仅当对任意多个的排列 $1 \leq i_1 < i_2 < \cdots < i_k \leq n$, 以及任意 Borel 集 $B_i \in \mathscr{B}$, 都有

$$\mathbb{P}\left(\bigcap_{j=1}^{k} X_{i_j}^{-1}(B_{i_j})\right) = \prod_{j=1}^{k} \mathbb{P}(X_{i_j} \in B_{i_j}).$$

独立性的定义是对概率而言的, 而分布函数等都从概率得来, 因此独立性一定在分布函数, 密度函数, 协方差和相关系数上有所体现.

Proposition 2.5.1.(独立随机变量) 设 $(\Omega, \mathscr{F}, \mathbb{P})$ 是概率空间, X, Y 是其上独立的随机变量, 当且仅当联合分布函数 $F_{X,Y}(x, y) = F_X(x)F_Y(y)$, 如果有联合密度函数, 当且仅当 $f_{X,Y}(x, y) = f_X(x)f_Y(y)$。此时

$$\mathbb{E}(XY) = \mathbb{E}(X)\mathbb{E}(Y),$$

于是协方差和相关系数为 0.

Proof. 依照定义

$$F_{X,Y}(x, y) = \mathbb{P}(X^{-1}(-\infty, x) \cap Y^{-1}(-\infty, y)),$$

当 X, Y 独立时

$$F_{X,Y}(x, y) = \mathbb{P}(X^{-1}(-\infty, x))\mathbb{P}(Y^{-1}(-\infty, y)) = F_X(x)F_Y(y).$$

反之立即得到

$$\mathbb{P}\left(X^{-1}(B_1) \cap Y^{-1}(B_2)\right) = \mathbb{P}\left(X^{-1}(B_1))\mathbb{P}(Y^{-1}(B_2)\right)$$

对 $B=(-\infty,c)$ 都成立, 而 Borel 集由这些生成, 从而在 Borel 集上也成立. 如果存在概率密度函数, 则

$$\int_{-\infty}^{x}\int_{-\infty}^{y} f_{X,Y}(x,y)\mathrm{d}y\mathrm{d}x=\int_{-\infty}^{x} f_X(x)\mathrm{d}x\int_{-\infty}^{y} f_Y(y)\mathrm{d}y$$

两边依次对 x,y 求偏导可得 $f_{X,Y}(x,y)=f_X(x)f_Y(y)$, 反之分别积分即证. 最后计算期望

$$\mathbb{E}(XY)=\int_{\mathbb{R}^2} xyf_{X,Y}(x,y)\mathrm{d}x\mathrm{d}y=\int_{\mathbb{R}} xf_X(x)\mathrm{d}x\int_{\mathbb{R}} yf_Y(y)\mathrm{d}y=\mathbb{E}(X)\mathbb{E}(Y).$$

于是协方差

$$\mathrm{Cov}(X,Y)=\mathbb{E}(XY)-\mathbb{E}(X)\mathbb{E}(Y)=0,$$

相应地相关系数也为 0. □

如果两个事件或随机变量不独立, 则观察到其中一个必然提供另一个的信息. 在极端的例子上, 例如从黑白两球中随机选择一个, 用 X,Y 表示黑球和白球的数量, 则在 $X=1$ 的条件下必有 $Y=0$. 我们首先定义事件的条件概率.

Definition 2.5.2.(条件概率) 设 $(\Omega,\mathscr{F},\mathbb{P})$ 是概率空间, $A,B\in\mathscr{F}$, 使得 $\mathbb{P}(B)>0$, 称

$$\frac{\mathbb{P}(A\cap B)}{\mathbb{P}(B)}$$

为条件 B 下事件 A 的概率, 记作 $\mathbb{P}(A\mid B)$.

从条件概率的角度看, 两个事件 $A,B\in\mathscr{F}$ 独立当且仅当

$$\mathbb{P}(A\cap B)=\mathbb{P}(A)\mathbb{P}(B)\iff\mathbb{P}(A)=\mathbb{P}(A\mid B)\iff\mathbb{P}(B)=\mathbb{P}(B\mid A).$$

条件概率相应的定义对象是随机变量, 例如

$$\mathbb{P}(X\in B_1\mid Y\in B_2)=\frac{\mathbb{P}(X^{-1}(B_1)\cap Y^{-1}(B_2))}{\mathbb{P}(Y^{-1}(B_2))},$$

这与之后条件分布定义在分布函数, 条件期望定义在矩上是一致的.

如果能确定一个事件在所有互斥条件下发生的概率, 就能确定该事件发生的概率, 即所谓全概率公式.

Theorem 2.5.2.(全概率公式) 设 $(\Omega,\mathscr{F},\mathbb{P})$ 是概率空间, $A,B_k\in\mathscr{F}(1\leq k\leq n)$, 使得对任意 $i\neq j$ 都有 $B_i\cap B_j=\emptyset$, 对任意 $1\leq k\leq n$ 都有 $P(B_k)>0$, 以及

$$A\subseteq\bigcup_{k=1}^{n}B_k.$$

则有

$$\mathbb{P}(A)=\sum_{k=1}^{n}\mathbb{P}(B_k)\mathbb{P}(A\mid B_k).$$

Proof. 包含关系两边交 A 即得

$$A = \bigcup_{k=1}^{n} B_k \cap A.$$

两边取概率, 由于 B_k 两两不交, 有

$$\mathbb{P}(A) = \bigcup_{k=1}^{n} P(B_k \cap A).$$

根据**Definition 2.5.2.**即得

$$\mathbb{P}(A) = \sum_{k=1}^{n} \mathbb{P}(B_k)\mathbb{P}(A \mid B_k).$$

□

有的时候计算 $\mathbb{P}(A \mid B)$ 类型的概率不易, 可以通过 Bayes 定理转换为计算 $\mathbb{P}(B \mid A)$ 类型.

Theorem 2.5.3.(Bayes) 设 $(\Omega, \mathscr{F}, \mathbb{P})$ 是概率空间, $A, B_k \in \mathscr{F}(1 \leq k \leq n)$, 使得对任意 $i \neq j$ 都有 $B_i \cap B_j = \emptyset$, 对任意 $1 \leq k \leq n$ 都有 $\mathbb{P}(B_k) > 0$ 并且 $\mathbb{P}(A) > 0$, 以及

$$A \subseteq \bigcup_{k=1}^{n} B_k.$$

则对任意 $1 \leq i \leq n$ 有

$$\mathbb{P}(B_i \mid A) = \frac{\mathbb{P}(B_i)\mathbb{P}(A \mid B_i)}{\sum_{k=1}^{n} \mathbb{P}(B_k)\mathbb{P}(A \mid B_k)}.$$

Proof. 根据定义有

$$\mathbb{P}(B_i \mid A) = \frac{\mathbb{P}(A \cap B_i)}{\mathbb{P}(A)} = \frac{\mathbb{P}(B_i)\mathbb{P}(A \mid B_i)}{\mathbb{P}(A)}.$$

利用**Theorem 2.5.2.**的结果即得

$$\mathbb{P}(B_i \mid A) = \frac{\mathbb{P}(B_i)\mathbb{P}(A \mid B_i)}{\sum_{k=1}^{n} \mathbb{P}(B_k)\mathbb{P}(A \mid B_k)}.$$

□

作为条件概率的推广, 我们考虑条件分布, 即给定一个随机变量条件 $T \in B$ 后的概率分布

$$F(x \mid T \in B) = \frac{\mathbb{P}(X^{-1}(-\infty, x) \cap T^{-1}(B))}{\mathbb{P}(T^{-1}(B))}.$$

我们直接在 n 维随机向量上定义.

Definition 2.5.3.(条件分布) 设 $(\Omega, \mathscr{F}, \mathbb{P})$ 是概率空间, $\mathbf{X}$ 是 n 维随机向量, $\mathbf{T}$ 是 m 维随机向量, 如果联合分布函数为 $F_{\mathbf{X},\mathbf{T}}(\mathbf{x},\mathbf{t})$, 对 $B \in \mathscr{B}_m$ 和任意 $\mathbf{x} \in \mathbb{R}^n$, 表达式

$$\frac{1}{\mathbb{P}(\mathbf{T} \in B)} \mathbb{P}\left(\mathbf{T}^{-1}(B) \cap \bigcap_{k=1}^{n} X_k^{-1}(-\infty, x_k)\right)$$

有限存在, 则称为条件 $\mathbf{T} \in B$ 下 $\mathbf{X}$ 的联合分布, 记作 $F_{\mathbf{X}}(\mathbf{x} \mid \mathbf{T} \in B)$.
如果联合密度函数为 $f_{\mathbf{X},\mathbf{T}}(\mathbf{x},\mathbf{t})$, 对 $\mathbf{t}_0 \in \mathbb{R}^m$, 在上式中取 $B \to \{\mathbf{t}_0\}$ 的极限, 根据 L'Hospital 法则, 如果

$$\frac{1}{f_{\mathbf{T}}(t_0)} \int_{u_k \le x_k} f_{\mathbf{X},\mathbf{T}}(\mathbf{u}, \mathbf{t}_0) \mathrm{d}u_1 \mathrm{d}u_2 \cdots \mathrm{d}u_n$$

有限存在, 则称为条件 $\mathbf{T} = \mathbf{t}_0$ 下 $\mathbf{X}$ 的联合分布, 记作 $F_{\mathbf{X}}(\mathbf{x} \mid \mathbf{T} = \mathbf{t}_0)$. 此时相应的联合密度函数

$$f_{\mathbf{X}}(\mathbf{x} \mid \mathbf{T} = \mathbf{t}_0) = \frac{f_{\mathbf{X},\mathbf{T}}(\mathbf{x}, \mathbf{t}_0)}{f_{\mathbf{T}}(\mathbf{t}_0)}.$$

全概率公式自然地推广到条件分布. 关于

$$F_{\mathbf{X}}(\mathbf{x} \mid \mathbf{T} \in B) = \frac{1}{\mathbb{P}(\mathbf{T} \in B)} \mathbb{P}\left(\mathbf{T}^{-1}(B) \cap \bigcap_{k=1}^{n} X_k^{-1}(-\infty, x_k)\right)$$

的条件分布由**Theorem 2.5.2.**直接得到, 而关于条件密度的则需要证明.

Theorem 2.5.4.(全概率公式) 设 $(\Omega, \mathscr{F}, \mathbb{P})$ 是概率空间, $\mathbf{X}$ 是 n 维随机向量, T 是 m 维随机向量, 联合密度函数为 $f_{\mathbf{X},\mathbf{T}}(\mathbf{x},\mathbf{t})$. 则对任意 $B \in \mathscr{B}_n$, 有

$$\mathbb{P}(\mathbf{X} \in B) = \int_{\mathbb{R}^n} f_{\mathbf{T}}(\mathbf{t}) \mathbb{P}(\mathbf{X} \in B \mid \mathbf{T} = \mathbf{t}) \mathrm{d}t_1 \mathrm{d}t_2 \cdots \mathrm{d}t_m.$$

Proof. 按照定义

$$\mathbb{P}(\mathbf{X} \in B) = \int_B f_{\mathbf{X}}(\mathbf{x}) \mathrm{d}x_1 \mathrm{d}x_2 \cdots \mathrm{d}x_n,$$

根据边缘分布函数的定义上式即

$$\int_B \int_{\mathbb{R}^n} f_{\mathbf{X},\mathbf{T}}(\mathbf{x},\mathbf{t}) \mathrm{d}t_1 \mathrm{d}t_2 \cdots \mathrm{d}t_m \mathrm{d}x_1 \mathrm{d}x_2 \cdots \mathrm{d}x_n,$$

展开为

$$\int_B \int_{\mathbb{R}^n} f_{\mathbf{X}}(\mathbf{x} \mid \mathbf{T} = \mathbf{t}) f_{\mathbf{T}}(\mathbf{t}) \mathrm{d}t_1 \mathrm{d}t_2 \cdots \mathrm{d}t_m \mathrm{d}x_1 \mathrm{d}x_2 \cdots \mathrm{d}x_n.$$

根据 Fubini 定理**Theorem B.4.**先对 $\mathbf{x}$ 积分得

$$\int_{\mathbb{R}^m} f_{\mathbf{T}}(\mathbf{t}) \mathbb{P}(\mathbf{X} \in B \mid \mathbf{T} = \mathbf{t}) \mathrm{d}t_1 \mathrm{d}t_2 \cdots \mathrm{d}t_m.$$

□

要注意的是, 尽管 $\mathbf{X} \mid \mathbf{T} \in B$ 有分布函数 $F_{\mathbf{X}}(\mathbf{x} \mid \mathbf{T} \in B)$, 但不直接成为随机变量, 因为原来 $\mathbf{T}(\omega) \notin B$ 的点在 $\mathbf{X} \mid \mathbf{T} \in B$ 下失去意义. 因此我们只能利用**Theorem 2.3.1.**和 $F_{\mathbf{X}}(\mathbf{x} \mid \mathbf{T} \in B)$ 的单调连续条件构建一个随机变量.

我们知道只有随机变量 (1 维随机向量) 能够自然地求期望和方差, 因此对随机变量 X 和 m 维随机向量 T, 定义条件期望即随机变量 $X \mid \mathbf{T} \in B$ 的期望. 特别地, 对每个 $\mathbf{t} \in \mathbb{R}^m$, 条件期望 $\mathbb{E}(X \mid \mathbf{T} = \mathbf{t})$ 指定了一个实数, 从而成为一个关于 $\mathbf{t}$ 的实值函数 h.

Definition 2.5.4.(条件期望 I) 设 $(\Omega, \mathscr{F}, \mathbb{P})$ 是概率空间, X 是随机变量, $\mathbf{T}$ 是 m 维随机向量. 对任意 $B \in \mathscr{B}_m$, 条件分布 $F_X(x \mid \mathbf{T} \in B)$ 诱导一个随机变量 $X \mid \mathbf{T} \in B$. 定义 X 在条件 $\mathbf{T} \in B$ 下的条件期望为该随机变量的期望 $\mathbb{E}(X \mid \mathbf{T} \in B)$.
特别地, 如果联合密度 $f_{X,\mathbf{T}}(x, \mathbf{t})$ 存在, 则可以绕过随机变量的构造, 直接用密度函数定义条件 $\mathbf{T} = \mathbf{t}_0$ 下 X 的期望

$$\mathbb{E}(X \mid \mathbf{T} = \mathbf{t}_0) = \int_{\mathbb{R}} x f_X(x \mid \mathbf{T} = \mathbf{t}_0) \mathrm{d}x = \int_{\mathbb{R}} x \frac{f_{X,\mathbf{T}}(x, \mathbf{t}_0)}{f_{\mathbf{T}}(\mathbf{t}_0)} \mathrm{d}x.$$

则 $h(\mathbf{t}) = \mathbb{E}(X \mid \mathbf{T} = \mathbf{t})$ 给出了一个实变函数, 其生成的随机变量 $h(\mathbf{T}) = \mathbb{E}(X \mid \mathbf{T})$ 称为 X 关于 $\mathbf{T}$ 的条件期望变量.

要注意, 这里虽然 $\mathbf{T}$ 是随机向量, 但条件期望 $\mathbb{E}(X \mid \mathbf{T})$ 总是随机变量.
逐点地看, 条件期望还是期望, 因此对随机变量 X 仍然具有线性.
我们看一个特殊的例子.

Example 2.5.1.(关于自身的条件期望变量) 当 $\mathbf{T} = X$ 时, 可以计算联合密度函数

$$f_{X,X}(x, y) = \frac{\partial^2}{\partial x \partial y} F_{X,X}(x, y) = \frac{\partial^2}{\partial x \partial y} \mathbb{P}(X \leq x, X \leq y) = \frac{\partial^2}{\partial x \partial y} \mathbb{P}(X \leq \min\{x, y\}).$$

利用

$$\min\{x, y\} = \frac{x + y - |x - y|}{2},$$

上式可以求导

$$\frac{\partial^2}{\partial x \partial y} F_X\left(\frac{x + y - |x - y|}{2}\right) = \frac{\partial}{\partial x}\left(f_X\left(\frac{x + y - |x - y|}{2}\right) \frac{1 + \operatorname{sgn}(x - y)}{2}\right).$$

而 sgn 在 0 处导数为 Dirac 函数 $2\delta(0)$, 因此

$$f_{X,X}(x, y) = f_X'\left(\frac{x + y - |x - y|}{2}\right) \frac{1 - \operatorname{sgn}(x - y)^2}{4} + f_X\left(\frac{x + y - |x - y|}{2}\right) \delta(x - y).$$

当 $x \neq y$ 时第一项为 0, 而 $x = y$ 时第一项是有限数, 积分后为 0, 因此可以认为

$$f_{X,X}(x, y) = f_X(\min\{x, y\}) \delta(x - y).$$

代入得

$$\mathbb{E}(X \mid X=y)=\int_{\mathbb{R}} x \frac{f_{X,X}(x,y)}{f_X(y)}\mathrm{d}x=\int_{\mathbb{R}} x \frac{f_X(x)\delta(x-y)}{f_X(y)}\mathrm{d}x=\int_{\mathbb{R}} x\delta(x-y)\mathrm{d}x=y,$$

从而 $\mathbb{E}(X \mid X)=X$.

这里我们看出 $\mathbb{E}(\mathbb{E}(X \mid X))=\mathbb{E}(X)$, 可以推广为下述定理.

Theorem 2.5.5.(重期望公式) 设 $(\Omega,\mathscr{F},\mathbb{P})$ 是概率空间, X 是随机变量, $\mathbf{T}$ 是 m 维随机向量, 联合密度函数为 $f_{X,\mathbf{T}}(\mathbf{x},\mathbf{t})$. 则对任意 $S\subseteq\mathbb{R}^m$, 有特征随机变量作为 $\mathbf{T}$ 的随机变量函数

$$\begin{aligned}\chi_{\mathbf{T}\in S}:\ \Omega &\to \mathbb{R},\\ \omega &\mapsto \begin{cases}1, & \mathbf{T}(\omega)\in S,\\ 0, & \text{otherwise.}\end{cases}\end{aligned}$$

则对任意 $B\in\mathscr{B}_m$, 有

$$\mathbb{E}_{\mathbf{T}}(\mathbb{E}_X(X \mid \mathbf{T})\chi_{\mathbf{T}\in B})=\mathbb{E}_{X,\mathbf{T}}(X\chi_{\mathbf{T}\in B}).$$

特别地当 $B=\mathbb{R}_m$ 时

$$\mathbb{E}_{\mathbf{T}}(\mathbb{E}_X(X \mid \mathbf{T}))=\mathbb{E}(X).$$

Proof. 根据**Propsition 2.4.4.**, 将 $\mathbb{E}_X(X \mid \mathbf{T})\chi_{\mathbf{T}\in B}$ 视为 $\mathbf{T}$ 的函数, 有

$$\mathbb{E}_{\mathbf{T}}(\mathbb{E}_X(X \mid \mathbf{T})\chi_{\mathbf{T}\in B})=\int_{\mathbb{R}^m} h(\mathbf{t})\chi_{\mathbf{t}\in B}f_{\mathbf{T}}(\mathbf{t})\mathrm{d}t_1\mathrm{d}t_2\cdots\mathrm{d}t_m,$$

代入 $h(\mathbf{t})$ 的定义

$$\mathbb{E}_{\mathbf{T}}(\mathbb{E}_X(X \mid \mathbf{T})\chi_{\mathbf{T}\in B})=\int_{\mathbb{R}^m}\left(\int_{\mathbb{R}} x\frac{f_{X,\mathbf{T}}(x,\mathbf{t})}{f_{\mathbf{T}}(\mathbf{t})}\mathrm{d}x\right)\chi_{\mathbf{t}\in B}f_{\mathbf{T}}(\mathbf{t})\mathrm{d}t_1\mathrm{d}t_2\cdots\mathrm{d}t_m,$$

利用**Theorem B.5.**得到

$$\mathbb{E}_{\mathbf{T}}(\mathbb{E}_X(X \mid \mathbf{T})\chi_{\mathbf{T}\in B})=\int_{\mathbb{R}^{m+1}} xf_{X,\mathbf{T}}(x,\mathbf{t})\chi_{\mathbf{t}\in B}\mathrm{d}x\mathrm{d}t_1\mathrm{d}t_2\cdots\mathrm{d}t_m=\mathbb{E}_{X,\mathbf{T}}(X\chi_{\mathbf{T}\in B}).$$

□

如果我们将公式

$$\mathbb{E}_{\mathbf{T}}(\mathbb{E}_X(X \mid \mathbf{T})\chi_{\mathbf{T}\in B})=\mathbb{E}_{X,\mathbf{T}}(X\chi_{\mathbf{T}\in B})$$

用期望的原始定义写出, 即

$$\int_\Omega \mathbb{E}_X(X \mid \mathbf{T})(\omega)\chi_{\mathbf{T}\in B}(\omega)\mathrm{d}\mathbb{P}=\int_\Omega X(\omega)\chi_{\mathbf{T}\in B}(\omega)\mathrm{d}\mathbb{P}.$$

注意到

$$\chi_{\mathbf{T}\in B}(\omega)=\begin{cases}1, & \mathbf{T}(\omega)\in B,\\ 0, & \text{otherwise},\end{cases}$$

可以整理为

$$\int_{\mathbf{T}^{-1}(B)}\mathbb{E}_X(X\mid\mathbf{T})(\omega)\mathrm{d}\mathbb{P}=\int_{\mathbf{T}^{-1}(B)}X(\omega)\mathrm{d}\mathbb{P}.$$

这并不依赖于随机变量 $X,\mathbf{T}$ 的联合密度函数存在, 因而给我们一种推广条件期望变量的方式.

由于当 B 遍历 $\mathscr{B}_m$ 时, $\mathbf{T}^{-1}(B)$ 构成 Ω 中的一个 σ-代数, 且是 $\mathscr{F}$ 的子 σ-代数, 如果能对任意 $\mathscr{F}$ 的子 σ-代数定义条件期望变量, 使得对该代数中的任意集合 $\mathscr{E}$ 都有

$$\int_{\mathscr{E}}\mathbb{E}_X(X\mid\mathbf{T})(\omega)\mathrm{d}\mathbb{P}=\int_{\mathscr{E}}X(\omega)\mathrm{d}\mathbb{P},$$

就能对任何 m 维随机变量 $\mathbf{T}$ 定义条件期望.

Definition 2.5.5.(条件期望 II) 设 $(\Omega,\mathscr{F},\mathbb{P})$ 是概率空间, X 是随机变量, $\mathscr{E}$ 是 $\mathscr{F}$ 的一个子 σ-代数. 根据 Radon-Nikodym 定理**Theorem B.8.**, 存在唯一的随机变量 Y 关于 $\mathscr{E}$ 可测, 即对任意 $B\in\mathscr{B}$, 有 $Y^{-1}(B)\in\mathscr{E}$, 且对任意 $E\in\mathscr{E}$, 满足

$$\int_E Y(\omega)\mathrm{d}\mathbb{P}=\int_E X(\omega)\mathrm{d}\mathbb{P},$$

称这样的 Y 是 X 关于 $\mathscr{E}$ 的条件期望, 记作 $\mathbb{E}(X\mid\mathscr{E})$.
特别地, 对任意 m 维随机向量 $\mathbf{T}$, 集合

$$\mathscr{E}=\left\{\mathbf{T}^{-1}(B)\in\mathscr{F}\mid B\in\mathscr{B}_m\right\}$$

自然构成 $\mathscr{F}$ 的一个子 σ-代数, 相应的条件期望变量记作 $\mathbb{E}(X\mid\mathbf{T})$.

注意 Y 关于 $\mathscr{E}$ 可测的条件表明 $\mathbb{E}(X\mid\mathscr{E})$ 一般不是平凡的 X, 因为 $X^{-1}(B)$ 只能保证在 $\mathscr{F}$ 中而未必在子 σ-代数 $\mathscr{E}$ 中. 因此条件期望可以理解为 X 在子空间上的某种投影.

由于对任意 $B\in\mathscr{B}$, $\mathbb{E}(X\mid\mathbf{T})(\omega)\in B$ 当且仅当 $h(\mathbf{T}(\omega))\in B$, 当且仅当 $\omega\in\mathbf{T}^{-1}(h^{-1}(B))$, 而 h 显然是 Borel 可测的, 因此 $h^{-1}(B)\in\mathscr{B}_m$, 即 $\mathbb{E}(X\mid\mathbf{T})$ 是 $\mathscr{E}$ 可测的, 这就证明了**Definition 2.5.4.**中定义的条件期望与**Definition 2.5.5.**中的特殊情况是一致的.

条件期望被视为某种投影, 当然可以分离出投影部分和误差部分, 这恰好就是条件期望的方差和条件方差.

Definition 2.5.6.(条件方差) 设 $(\Omega,\mathscr{F},\mathbb{P})$ 是概率空间, X 是随机变量, $\mathbf{T}$ 是 m 维随机向量. 定义条件方差是一个随机变量, 也是一个 $\mathbf{T}$ 的函数

$$\mathrm{Var}(X\mid\mathbf{T})=\mathbb{E}\left((X-\mathbb{E}(X\mid\mathbf{T}))^2\mid\mathbf{T}\right)=\mathbb{E}(X^2\mid\mathbf{T})-\mathbb{E}(X\mid\mathbf{T})^2.$$

现在我们证明分解定理.

Theorem 2.5.6.(方差的条件分解) 设 $(\Omega, \mathscr{F}, \mathbb{P})$ 是概率空间, X 是随机变量, $\mathbf{T}$ 是 m 维随机向量, 则方差可以分解为条件方差的期望与条件期望的方差之和

$$\mathrm{Var}(X) = \mathbb{E}\left(\mathrm{Var}(X \mid \mathbf{T})\right) + \mathrm{Var}(\mathbb{E}(X \mid \mathbf{T})).$$

Proof. 依照定义

$$\mathrm{Var}(X) = \mathbb{E}\left((X - \mathbb{E}(X \mid \mathbf{T}) + \mathbb{E}(X \mid \mathbf{T}) - \mathbb{E}(X))^2\right),$$

记 $h(\mathbf{T}) = \mathbb{E}(X \mid \mathbf{T})$, 分为两项按完全平方公式展开为

$$\mathbb{E}\left((X - h(\mathbf{T}))^2\right) + \mathbb{E}\left((h(\mathbf{T}) - \mathbb{E}(X))^2\right) + 2\mathbb{E}\left((X - h(\mathbf{T}))(h(\mathbf{T}) - \mathbb{E}(X))\right).$$

根据重期望公式**Theorem 2.5.5.**对条件方差求期望

$$\mathbb{E}(\mathrm{Var}(X \mid \mathbf{T})) = \mathbb{E}_{\mathbf{T}}\left(\mathbb{E}_X\left((X - \mathbb{E}(X \mid \mathbf{T}))^2 \mid \mathbf{T}\right)\right) = \mathbb{E}\left((X - \mathbb{E}(X \mid \mathbf{T}))^2\right)$$

恰为第一项, 而再次由重期望公式 $\mathbb{E}(\mathbb{E}(X \mid \mathbf{T})) = \mathbb{E}(X)$, 于是第二项

$$\mathbb{E}\left((h(\mathbf{T}) - \mathbb{E}(X))^2\right) = \mathbb{E}\left((\mathbb{E}(X \mid \mathbf{T}) - \mathbb{E}(\mathbb{E}(X \mid \mathbf{T})))^2\right) = \mathrm{Var}(\mathbb{E}(X \mid \mathbf{T})).$$

最后根据重期望公式

$$\mathbb{E}\left((X - h(\mathbf{T}))(h(\mathbf{T}) - \mathbb{E}(X))\right) = \mathbb{E}_{\mathbf{T}}\left(\mathbb{E}_X\left((X - h(\mathbf{T}))(h(\mathbf{T}) - \mathbb{E}(X)) \mid \mathbf{T}\right)\right),$$

由于内层仅对 X 求期望, 有关 $\mathbf{T}$ 的项提出, 可直接计算

$$\mathbb{E}_X\left((X - h(\mathbf{T}))(h(\mathbf{T}) - \mathbb{E}(X)) \mid \mathbf{T}\right) = (h(\mathbf{T}) - \mathbb{E}(X))\mathbb{E}_X\left(X - h(\mathbf{T}) \mid \mathbf{T}\right),$$

而

$$\mathbb{E}_X\left(X - h(\mathbf{T}) \mid \mathbf{T}\right) = \mathbb{E}_X\left(X \mid \mathbf{T}\right) - h(\mathbf{T}) = h(\mathbf{T}) - h(\mathbf{T}) = 0,$$

因此这项恒为 0. □

Chapter 3

特征函数

本章基础知识

Theorem C.1.(Fourier 变换)

Theorem C.2.(留数定理)

3.1 特征函数

计算随机变量的矩需要计算复杂的积分, 且对每个正整数给出了离散的值. 我们知道 Fourier 变换可以把离散的点编码为连续的函数, 因此我们考虑用 Fourier 变换刻画随机变量的分布.

Definition 3.1.1.(特征函数) 设 $(\Omega, \mathscr{F}, \mathbb{P})$ 是概率空间, X 是其上的随机变量. 定义

$$\psi_X(t) = \mathbb{E}\left(\mathrm{e}^{\mathrm{i}tX}\right)$$

为随机变量 X 的**特征函数 (characteristic function)**. 如果 X 是连续随机变量, 密度函数为 $f_X(x)$, 则

$$\psi_X(t) = \int_{\mathbb{R}} \mathrm{e}^{\mathrm{i}tx} f_X(x)\mathrm{d}x$$

恰好是密度函数 $f(x)$ 的 Fourier 变换.

利用 Fourier 变换

$$f_X(x) = \frac{1}{2\pi}\int_{\mathbb{R}} \mathrm{e}^{-\mathrm{i}tx}\psi_X(t)\mathrm{d}t.$$

此时有

$$|\psi_X(t+\Delta t) - \psi_X(t)| \le \int_{\mathbb{R}} \left|\mathrm{e}^{\mathrm{i}\Delta tx} - 1\right| f_X(x)\mathrm{d}x$$

可知 $\psi_X(t)$ 一致连续.

特征函数显然满足

$$|\psi_X(t)| \le \psi_X(0) = 1, \quad \psi_X(-t) = \psi_{-X}(t) = \overline{\psi_X(t)}.$$

在特征函数的语境下, 独立随机变量和会变得容易计算.

Proposition 3.1.1.(独立随机变量和的特征函数) 设 $(\Omega, \mathscr{F}, \mathbb{P})$ 是概率空间, X, Y 是其上的随机变量, $\psi_X(t), \psi_Y(t)$ 为相应的特征函数, 则 $X+Y$ 的特征函数

$$\psi_{X+Y}(t) = \psi_X(t)\psi_Y(t).$$

Proof. 利用独立随机变量的期望的性质**Proposition 2.5.1.**有

$$\psi_{X+Y}(t) = \mathbb{E}\left(\mathrm{e}^{\mathrm{i}t(X+Y)}\right) = \mathbb{E}\left(\mathrm{e}^{\mathrm{i}tX}\right)\mathbb{E}\left(\mathrm{e}^{\mathrm{i}tY}\right) = \psi_X(t)\psi_Y(t).$$

□

我们知道 Fourier 变换把原函数的卷积变为变换后函数的乘积, 因此特征函数相乘意味着 $X+Y$ 的密度函数是 $f_X * f_Y$, 积分并用 Fubini 定理换序又可得 $F_{X+Y} =$

$F_X * F_Y$, 这与Example 2.3.1.的结果是一致的. 简单地说, 独立随机变量相加, 特征函数相乘, 分布与密度卷积.

利用特征函数可以很方便地还原各阶矩. 为简便起见, 我们只证明连续随机变量的情形.

Proposition 3.1.2.(特征函数与 n 阶矩) 设 $(\Omega, \mathscr{F}, \mathbb{P})$ 是概率空间, X 是其上的随机变量, $\psi_X(t)$ 为相应的特征函数, 若 X 的 n 阶矩存在, 则

$$\mathbb{E}\left(X^n\right) = \mathrm{i}^{-n} \lim_{t\to 0} \frac{\mathrm{d}^n}{\mathrm{d}t^n}\psi_X(t).$$

Proof. 由各阶矩存在可知 $\psi_X(t)$ 是 n 阶一致连续可导, 于是

$$\lim_{t\to 0} \frac{\mathrm{d}^n}{\mathrm{d}t^n}\psi_X(t) = \int_{\mathbb{R}} \lim_{t\to 0} \frac{\mathrm{d}^n}{\mathrm{d}t^n} \mathrm{e}^{\mathrm{i}tx} f_X(x)\mathrm{d}x = \mathrm{i}^n \int_{\mathbb{R}} x^n f_X(x)\mathrm{d}x = \mathrm{i}^n \mathbb{E}\left(X^n\right).$$

□

关于特征函数和分布函数的关系, 以下定理是重要的. 我们采用 Lebesgue-Stieljes 积分记号

$$\int_\Omega \varphi(X(\omega))\mathbb{P}(\mathrm{d}\omega) = \int_{\mathbb{R}} \varphi(x)\mathrm{d}F_X(x).$$

Theorem 3.1.3.(Laha-Rohatgi) 设 $(\Omega, \mathscr{F}, \mathbb{P})$ 是概率空间, X 是其上的随机变量, 概率分布函数为 $F_X(x)$, 相应的特征函数为 $\psi_X(t)$. 则对任意 $x_1 < x_2$, 有

$$\mathbb{P}(x_1 < X < x_2) + \frac{\mathbb{P}(X = x_1) + \mathbb{P}(X = x_2)}{2} = \lim_{T\to+\infty} \frac{1}{2\pi} \int_{-T}^{T} \frac{\mathrm{e}^{-\mathrm{i}tx_1} - \mathrm{e}^{-\mathrm{i}tx_2}}{\mathrm{i}t} \psi_X(t)\mathrm{d}t.$$

Proof. 代入得极限号内是

$$\frac{1}{2\pi} \int_{-T}^{T} \int_{-\infty}^{+\infty} \frac{\mathrm{e}^{-\mathrm{i}tx_1} - \mathrm{e}^{-\mathrm{i}tx_2}}{\mathrm{i}t} \mathrm{e}^{\mathrm{i}tx} \mathrm{d}F_X(x)\mathrm{d}t.$$

被积函数有估计

$$\left|\frac{\mathrm{e}^{\mathrm{i}t(x-x_1)} - \mathrm{e}^{\mathrm{i}t(x-x_2)}}{\mathrm{i}t}\right| = \left|\int_{x_1}^{x_2} \mathrm{e}^{-\mathrm{i}tu}\mathrm{d}u\right| \le \int_{x_1}^{x_2} \mathrm{d}u = x_2 - x_1,$$

这表明原积分有估计

$$\frac{1}{2\pi} \int_{-T}^{T} \int_{-\infty}^{+\infty} (x_2 - x_1)\mathrm{d}F_X(x)\mathrm{d}t = \frac{T}{\pi}(x_2 - x_1)$$

收敛, 于是由 Fubini 定理Theorem B.4.可以换序为

$$\frac{1}{2\pi} \int_{-\infty}^{+\infty} \int_{-T}^{T} \frac{\mathrm{e}^{-\mathrm{i}tx_1} - \mathrm{e}^{-\mathrm{i}tx_2}}{\mathrm{i}t} \mathrm{e}^{\mathrm{i}tx} \mathrm{d}t\mathrm{d}F_X(x).$$

将指数展开为三角函数, 注意到积分区间对称, 只有偶函数部分非零, 于是内层积分即

$$\int_{-T}^{T} \frac{\mathrm{e}^{-\mathrm{i}tx_1} - \mathrm{e}^{-\mathrm{i}tx_2}}{\mathrm{i}t} \mathrm{e}^{\mathrm{i}tx} \mathrm{d}t = 2\int_0^T \frac{\sin t(x-x_1) - \sin t(x-x_2)}{t} \mathrm{d}t.$$

为了进一步将极限号搬到积分内, 注意到上式有估计

$$\begin{aligned}
\left| 2\int_0^T \frac{\sin t(x-x_1) - \sin t(x-x_2)}{t} \mathrm{d}t \right| &\leq 2\left(\left| \int_0^T \frac{\sin t(x-x_1)}{t} \mathrm{d}t \right| + \left| \int_0^T \frac{\sin t(x-x_2)}{t} \mathrm{d}t \right| \right) \\
&= 2\left(\left| \int_0^{T(x-x_1)} \frac{\sin t}{t} \mathrm{d}t \right| + \left| \int_0^{T(x-x_2)} \frac{\sin t}{t} \mathrm{d}t \right| \right) \\
&\leq 4\int_0^{\pi} \frac{\sin t}{t} \mathrm{d}t
\end{aligned}$$

关于 T 一致有界, 于是根据有界收敛定理**Theorem B.3.**极限可交换, 右边变为

$$\frac{1}{\pi} \int_{-\infty}^{+\infty} \left(\lim_{T\to+\infty} \int_0^T \frac{\sin t(x-x_1) - \sin t(x-x_2)}{t} \mathrm{d}t \right) \mathrm{d}F_X(x).$$

根据 Dirichlet 核的性质, 内层积分取极限在 (x_1, x_2) 上结果为 π, 而在端点处为 $\pm\frac{\pi}{2}$, 外部为 0, 于是计算可得上式即

$$\int_{x_1<x<x_2} \mathrm{d}F_X(x) + \frac{1}{2}\int_{x=x_1, x=x_2} \mathrm{d}F(x),$$

也即

$$\mathbb{P}(x_1 < X < x_2) + \frac{\mathbb{P}(X=x_1) + \mathbb{P}(X=x_2)}{2}.$$

□

由此可以证明分布函数与特征函数的一一对应关系.

Theorem 3.1.4.(唯一性定理) 设 $(\Omega, \mathscr{F}, \mathbb{P})$ 是概率空间, X, Y 是其上的随机变量, 则概率分布函数 $F_X(x) = F_Y(x)$ 当且仅当相应的特征函数 $\psi_X(t) = \psi_Y(t)$.

Proof. 根据特征函数的定义可知必要性. 注意到分布函数是单调函数, 因此其不连续点至多可数, 从而是 $\mathbb{R}$ 上的零测集, 进而端点连续的开区间 (x_1, x_2) 的生成 σ-代数恰好是 $\mathscr{B}$. 根据**Theorem 3.1.3.**可知, 在这些区间上满足

$$F_X(x_2) - F_X(x_1) = F_Y(x_2) - F_Y(x_1),$$

进而生成的 σ-代数上也有分布函数相同. □

我们给出常见分布的特征函数.

Example 3.1.1.(Bernoulli 分布的特征函数) $n=1$ 的二项分布 $X\sim \mathrm{Bi}(1,p)$ 称为 Bernoulli 分布, 容易看出

$$\mathbb{P}(X=0)=1-p,\quad \mathbb{P}(X=1)=p.$$

于是定义 $\delta_{x_0}(x)$ 表示在 x_0 一点处由 0 突越为 1 的分布函数, 则 Bernoulli 分布的分布函数

$$F(x)=(1-p)\delta_0+p\delta_1.$$

依照离散随机变量期望的计算方式**Proposition 2.4.2.**, 特征函数

$$\psi(t)=(1-p)\mathrm{e}^0+p\mathrm{e}^{\mathrm{i}t}=1+p\left(\mathrm{e}^{\mathrm{i}t}-1\right)$$

是光滑函数.

Example 3.1.2.(几何分布的特征函数) 几何分布 $X\sim \mathrm{Ge}(p)$ 是离散分布, 其分布函数

$$F(x)=\sum_{n=0}^{\infty}(1-p)^n p\delta_n(x).$$

于是特征函数

$$\psi(t)=\sum_{n=0}^{\infty}(1-p)^n p\mathrm{e}^{\mathrm{i}tn}=\frac{p}{1-(1-p)\mathrm{e}^{\mathrm{i}t}}.$$

Example 3.1.3.(Poisson 分布) Poisson 分布 $X\sim \mathrm{Poi}(\lambda)$ 是离散分布, 分布函数

$$F(x)=\sum_{n=0}^{\infty}\frac{\lambda^n\mathrm{e}^{-\lambda}}{n!}\delta_n(x).$$

于是特征函数

$$\psi(t)=\sum_{n=0}^{\infty}\frac{\lambda^n\mathrm{e}^{-\lambda}}{n!}\mathrm{e}^{\mathrm{i}tn}=\mathrm{e}^{-\lambda}\sum_{n=0}^{\infty}\frac{(\lambda\mathrm{e}^{\mathrm{i}t})^n}{n!}=\exp\left(\lambda\left(\mathrm{e}^{\mathrm{i}t}-1\right)\right).$$

如果有 n 个独立 Poisson 分布 $X_1,X_2,\ldots,X_n$, 参数为 $\lambda_1,\lambda_2,\ldots,\lambda_n$, 则和 $S=X_1+X_2+\cdots+X_n$ 的特征函数

$$\psi_S(t)=\prod_{k=1}^{n}\exp\left(\lambda_k\left(\mathrm{e}^{\mathrm{i}t}-1\right)\right)=\exp\left(\left(\sum_{k=1}^{n}\lambda_k\right)\left(\mathrm{e}^{\mathrm{i}t}-1\right)\right),$$

根据特征函数与分布函数的一一对应关系, S 只能是参数为 $\lambda=\lambda_1+\lambda_2+\cdots+\lambda_n$ 的 Poisson 分布.

Example 3.1.4.(1 维均匀分布) 1 维均匀分布 $X \sim U(a,b)$ 的概率密度函数

$$f(x) = \begin{cases} \frac{1}{b-a}, & a \le x \le b, \\ 0, & \text{otherwise}, \end{cases}$$

于是特征函数

$$\psi(t) = \int_a^b \frac{1}{b-a} \mathrm{e}^{\mathrm{i}tx} \mathrm{d}x = \exp\left(\mathrm{i}t\frac{a+b}{2}\right) \frac{\sin\frac{t(b-a)}{2}}{\frac{t(b-a)}{2}}.$$

Example 3.1.5.(指数分布) 指数分布 $X \sim \mathrm{Exp}(\lambda)$ 的概率密度函数

$$f(x) = \begin{cases} \lambda \mathrm{e}^{-\lambda x}, & x \ge 0, \\ 0, & x < 0, \end{cases}$$

于是特征函数

$$\psi(t) = \int_0^{+\infty} \lambda \mathrm{e}^{-\lambda x} \mathrm{e}^{\mathrm{i}tx} \mathrm{d}x = \frac{\lambda}{\lambda - \mathrm{i}t}.$$

Example 3.1.6.(Cauchy 分布) Cauchy 分布的概率密度函数

$$f(x) = \frac{1}{\pi(1+x^2)},$$

于是特征函数

$$\psi(t) = \int_{\mathbb{R}} \frac{1}{\pi(1+x^2)} \mathrm{e}^{\mathrm{i}tx} \mathrm{d}x.$$

当 $t > 0$ 时, 被积函数在上半平面有一阶极点 $x = \mathrm{i}$, 相应的留数

$$\mathrm{Res}\left(\mathrm{i}, \frac{1}{\pi(1+x^2)} \mathrm{e}^{\mathrm{i}tx}\right) = \frac{1}{\pi(\mathrm{i}+\mathrm{i})} \mathrm{e}^{\mathrm{i}t\mathrm{i}} = \frac{\mathrm{e}^{-t}}{2\pi\mathrm{i}}.$$

于是积分结果为 e^{-t}. 同理可得 $t < 0$ 时结果为 e^{t}, 于是特征函数 $\psi(t) = \mathrm{e}^{-|t|}$. 其导函数在 0 处极限不存在, 这对应了**Example 2.4.1.**期望不存在的结果.

Example 3.1.7.(正态分布) 正态分布 $X \sim N(\mu, \sigma^2)$ 的概率密度函数

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right).$$

于是特征函数

$$\psi(t) = \int_{\mathbb{R}} \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) \mathrm{e}^{\mathrm{i}tx} \mathrm{d}x = \exp\left(\mathrm{i}\mu t - \frac{\sigma^2}{2}t^2\right).$$

Chapter 4

随机变量序列

本章基础知识

Theorem D.1.(Chebyshev) 给定 $\alpha > 0$, 设 $(\Omega, \mathscr{F}, P)$ 是概率空间, X 是其上的随机变量, $\varphi(x)$ 是在 $(0, +\infty)$ 上非负严格单调上升的偶函数, 使得 $\varphi(X)$ 的数学期望存在, 则对任意 $\varepsilon > 0$, 有不等式

$$P(|X| \geq \varepsilon) \leq \frac{E(\varphi(X))}{\varphi(\varepsilon)}.$$

特别地, 取随机变量 X 为 $X - E(X)$, $\varphi(x) = x^2$, 则有

$$P(|X - E(X)| \geq \varepsilon) \leq \frac{D(X)}{\varepsilon^2}.$$

Proof. 按期望的定义

$$\begin{aligned} E(\varphi(x)) &= \int_{-\infty}^{+\infty} \varphi(x) \mathrm{d}F(x) \\ &\geq \int_{|x| \geq \varepsilon} \varphi(x) \mathrm{d}F(x) \\ &\geq \int_{|x| \geq \varepsilon} \varphi(\varepsilon) \mathrm{d}F(x) \\ &= \varphi(\varepsilon) P(|X| \geq \varepsilon). \end{aligned}$$

□

Theorem D.2.(Jensen)

4.1 随机变量序列的收敛

在这一章中, 我们开始考虑随机变量序列. 一个随机变量可以视为一次随机试验的结果, 那么一个随机变量序列就是进行充分多次试验之后, 观察其总体上的表现. 从朴素的数学观我们知道, 同一种随机试验进行足够多次后, 其平均会接近其真实分布的平均, 即所谓噪声被抵消了. 我们就要在这一章刻画这些总体现象.

所谓平均只能基于有限项定义, 因此我们实际上考虑的是

$$S_n = \sum_{k=1}^{n} X_n, \quad \overline{X}_n = \frac{1}{n}\sum_{k=1}^{n} X_n$$

的极限. 为此, 我们需要首先刻画随机变量序列的收敛. 由于随机变量是测度空间 $(\Omega, \mathscr{F}, \mathbb{P})$ 到 $\mathbb{R}$ 的可测函数, 因此这一收敛性就是可测函数列的收敛性.

Definition 4.1.1.(随机变量序列的收敛) 设 $(\Omega, \mathscr{F}, \mathbb{P})$ 是概率空间, X_n 是其上的随机变量序列, X 是一个随机变量, 分别有分布函数 F_n 和 F.

1. 如果存在零测集 $N \subseteq \Omega$, 使得对任意 $\omega \in \Omega \setminus N$, 都有

$$\lim_{n\to\infty} X_n(\omega) = X(\omega),$$

称 $\{X_n\}$ **几乎处处 (almost everywhere, a.e.)** 收敛到 X.

2. 如果对任意 $\varepsilon > 0$, 有

$$\lim_{n\to\infty} \mathbb{P}\left(\{\omega \in \Omega \mid |X_n(\omega) - X(\omega)| < \varepsilon\}\right) = 1,$$

称 $\{X_n\}$ **依概率 (in probability, pr.)** 收敛到 X.

3. 如果对给定的 $\alpha > 0$, 有

$$\lim_{n\to\infty} \mathbb{E}(|X_n - X|^\alpha) = 0,$$

称 $\{X_n\}$ 为 L^α 收敛或 α 阶矩收敛到 X.

4. 如果对任意 $F(x)$ 的连续点 $x \in \mathbb{R}$, 都有

$$\lim_{n\to\infty} F_n(x) = F(x),$$

则称 X_n **依分布 (in distribution, dist.)** 收敛到 $F(x)$.

$F(x)$ 作为概率分布函数只有可数个不连续点, 从而在一个零测集上不连续, 因此以上的收敛都是非平凡的.

Theorem 4.1.1.(几乎处处收敛的概率刻画) 设 $(\Omega,\mathscr{F},\mathbb{P})$ 是概率空间, X_n 是其上的随机变量序列, X 是一个随机变量. 则 $\{X_n\}$ 几乎处处收敛到 X 当且仅当对任意 $\varepsilon>0$, 有

$$\lim_{m\to\infty}\mathbb{P}(\{\omega\in\Omega\mid |X_n(\omega)-X(\omega)|<\varepsilon, n\geq m\})=1.$$

特别地, $\{X_n\}$ 依概率收敛到 X.

Proof. (必要性) 定义

$$A_m(\varepsilon)=\bigcap_{n=m}^{\infty}\{|X_n-X|<\varepsilon\}.$$

则这是一个单调上升的集合序列, 依照几乎处处收敛的定义, 对任意 $\omega\in\Omega\setminus N$, 存在 $m(\omega,\varepsilon)\in\mathbb{N}^*$, 使得对任意 $n\geq m(\omega,\varepsilon)$, 都有 $|X_n(\omega)-X(\omega)|<\varepsilon$. 于是任意 $\omega\in\Omega\setminus N$ 都在某个 $A_{m(\omega,\varepsilon)}(\varepsilon)$ 中, 于是

$$\Omega\setminus N\subseteq\bigcup_{m=1}^{\infty}A_m(\varepsilon).$$

利用概率的连续性和单调性可得

$$\mathbb{P}(\Omega\setminus N)\leq\mathbb{P}\left(\bigcup_{m=1}^{\infty}A_m(\varepsilon)\right)=\lim_{m\to\infty}\mathbb{P}(A_m(\varepsilon))\leq 1,$$

注意到 N 是零测集, 于是 $\mathbb{P}(\Omega\setminus N)=1$, 这就证明了

$$\lim_{m\to\infty}\mathbb{P}(A_m(\varepsilon))=1.$$

(充分性) 定义

$$A(\varepsilon)=\bigcup_{m=1}^{\infty}A_m(\varepsilon),$$

则同样根据连续性可得 $\mathbb{P}(A(\varepsilon))=1$. 对任意 $\omega\in A(\varepsilon)$, 按定义和单调上升, 存在一个 $m(\omega,\varepsilon)\in\mathbb{N}^*$, 当 $n\geq m(\omega,\varepsilon)$ 时, 有 $\omega\in A_n(\varepsilon)$, 即 $|X_n(\omega)-X(\omega)|<\varepsilon$. 现在取

$$\varepsilon=\frac{1}{p},\quad A=\bigcap_{p=1}^{\infty}A\left(\frac{1}{p}\right),$$

则根据连续性

$$\mathbb{P}(A)=\lim_{p\to\infty}\mathbb{P}\left(A\left(\frac{1}{p}\right)\right)=1,$$

这说明 $N=\Omega\setminus A$ 是零测集, 且对任意 $\omega\in\Omega\setminus N=A$ 和任意 $\varepsilon>0$, 根据交集的性质必有

$$\omega\in A\left(\frac{1}{[\varepsilon^{-1}]+1}\right),$$

这说明只要 $n>m(\omega,([\varepsilon^{-1}]+1)^{-1})$, 就有

$$|X_n(\omega)-X(\omega)|<\frac{1}{[\varepsilon^{-1}]+1}<\varepsilon.$$

□

L^α 收敛蕴含依概率收敛.

Theorem 4.1.2.(L^α 收敛蕴含依概率收敛) 设 $(\Omega, \mathscr{F}, \mathbb{P})$ 是概率空间, X_n 是其上的随机变量序列, X 是一个随机变量或常数. 如果 $\{X_n\}$ 按 L^α 收敛到 X, 则 $\{X_n\}$ 依概率收敛到 X.

Proof. 在 Chebyshev 不等式**Theorem D.1.**中取随机变量为 $X_n - X$, $\varphi(x) = |x|^\alpha$, 即得

$$\mathbb{P}(|X_n - X| \geq \varepsilon) \leq \frac{\mathbb{E}(|X_n - X|^\alpha)}{\varepsilon^\alpha}.$$

按照 L^α 收敛的定义, 取极限即得

$$\lim_{n\to\infty} \mathbb{P}(|X_n - X| \geq \varepsilon) = 0.$$

□

4.2 大数定律

现在我们开始研究 $\overline{X}_n$ 的收敛性质, 即所谓的大数定律. 这里我们特别注明, 如果随机变量不独立, 例如当 $X_k = n$ 时, 固定下一个随机变量 $X_{k+1} = 2n$, 则 $\overline{X}_n$ 当然不收敛. 因此总体性质一定是对一些特殊的随机变量序列成立.

简而言之, 大数定律和中心极限定理是一个定义, 某些特殊的随机变量序列满足大数定律或中心极限定理才是一个定理.

Definition 4.2.1.(大数定律) 设 $(\Omega, \mathscr{F}, \mathbb{P})$ 是概率空间, X_n 是其上的随机变量序列, 定义随机变量

$$\overline{X}_n = \frac{1}{n}\sum_{k=1}^{n} X_k.$$

如果 $\overline{X}_n$ 依概率收敛到 $\mathbb{E}(\overline{X}_n)$, 则称 $\{X_n\}$ 满足**弱大数定律 (weak law of large numbers)**. 如果 $\overline{X}_n$ 几乎处处收敛到 $\mathbb{E}(\overline{X}_n)$, 则称 $\{X_n\}$ 满足**强大数定律 (strong law of large numbers)**. 显然根据**Theorem 4.1.1.**, 弱大数定律蕴含强大数定律.

从历史上看, 最经典的大数定律是 Bernoulli 大数定律, 描述了 Bernoulli 分布随机变量序列的收敛.

Theorem 4.2.1.(Bernoulli) 设 X_n 独立同 Bernoulli 分布 $\mathrm{Bi}(1, p)$, 则 $\{X_n\}$ 满足弱大数定律.

Proof. 依照**Example 2.4.2.**可知期望

$$\mathbb{E}(\overline{X}_n) = \frac{1}{n}\sum_{k=1}^{n}\mathbb{E}(X_k) = \frac{np}{n} = p,$$

方差

$$\mathrm{Var}(\overline{X}_n) = \frac{1}{n^2}\sum_{k=1}^{n}\mathrm{Var}(X_k) = \frac{np(1-p)}{n^2} = \frac{p(1-p)}{n}.$$

对任意 $\varepsilon > 0$, 利用 Chebyshev 不等式**Theorem D.1.**可得

$$\mathbb{P}(|\overline{X}_n - p| \geq \varepsilon) \leq \frac{\mathrm{Var}(\overline{X}_n)}{\varepsilon^2} = \frac{p(1-p)}{n\varepsilon^2}.$$

取极限即得

$$0 \leq \lim_{n\to\infty}\mathbb{P}(|\overline{X}_n - p| \geq \varepsilon) \leq 0.$$

□

作为推广, 对一般的随机变量序列, 只要有应用 Chebshev 不等式的条件, 都可以通过以上方法证明满足弱大数定律, 这给出了以下两种大数定律.

Theorem 4.2.2.(Markov) 设 $(\Omega, \mathscr{F}, \mathbb{P})$ 是概率空间, X_n 是其上的随机变量序列. 若

$$\lim_{n\to\infty} \frac{1}{n^2} \operatorname{Var}\left(\sum_{k=1}^{n} X_k\right) = 0,$$

则 $\{X_n\}$ 满足弱大数定律.

Proof. 对任意 $\varepsilon > 0$, 利用 Chebyshev 不等式**Theorem D.1.**可得

$$\mathbb{P}(|\overline{X}_n - \mathbb{E}(\overline{X}_n)| \geq \varepsilon) \leq \frac{\operatorname{Var}(\overline{X}_n)}{\varepsilon^2}.$$

利用随机变量方差的性质

$$\operatorname{Var}(\overline{X}_n) = \operatorname{Var}\left(\frac{1}{n}\sum_{k=1}^{n} X_k\right) = \frac{1}{n^2} \operatorname{Var}\left(\sum_{k=1}^{n} X_k\right).$$

取极限即得

$$0 \leq \lim_{n\to\infty} P(|\overline{X}_n - E(\overline{X}_n)| \geq \varepsilon) \leq 0.$$

□

Theorem 4.2.3.(Chebyshev) 设 $(\Omega, \mathscr{F}, \mathbb{P})$ 是概率空间, X_n 是其上的随机变量序列. 若 X_k 两两独立且方差 $\operatorname{Var}(X_k)$ 一致有界, 则 $\{X_n\}$ 满足弱大数定律.

Proof. 对任意 $\varepsilon > 0$, 利用 Chebyshev 不等式**Theorem D.1.**可得

$$\mathbb{P}(|\overline{X}_n - \mathbb{E}(\overline{X}_n)| \geq \varepsilon) \leq \frac{\operatorname{Var}(\overline{X}_n)}{\varepsilon^2}.$$

利用独立随机变量方差的性质和一致有界

$$\operatorname{Var}(\overline{X}_n) = \operatorname{Var}\left(\frac{1}{n}\sum_{k=1}^{n} X_k\right) = \frac{1}{n^2}\sum_{k=1}^{n} \operatorname{Var}(X_k) \leq \frac{nM}{n^2} = \frac{M}{n}.$$

取极限即得

$$0 \leq \lim_{n\to\infty} \mathbb{P}(|\overline{X}_n - \mathbb{E}(\overline{X}_n)| \geq \varepsilon) \leq 0.$$

□

有时不能直接应用 Chebyshev 不等式, 但可以通过一些技巧转换为可以应用的情形. 这一技巧被称为**截断 (truncating)**.

Theorem 4.2.4.(Khinchin) 设 $(\Omega, \mathscr{F}, \mathbb{P})$ 是概率空间, X_n 是其上的随机变量序列. 若 X_k 独立同分布, 且均值 $\mathbb{E}(X_k) = \mu$ 有限存在, 则 $\{X_n\}$ 满足弱大数定律.

Proof. 构造随机变量

$$Y_n(\omega)=\begin{cases}X_n(\omega), & |X_n(\omega)|\leq n,\\ 0, & |X_n(\omega)|>n.\end{cases}$$

则 $\mathbb{P}(|X_n|>n)=\mathbb{P}(X_n\neq Y_n)$. 注意到期望有限存在, 根据**Proposition 2.4.3.**可知

$$\mathbb{E}(X_n)=\sum_{n=1}^{\infty}\mathbb{P}(|X_n|>n).$$

这里不区分下标 n 是因为独立同分布. 于是

$$\lim_{n\to\infty}\mathbb{P}(|X_n|>n)=\lim_{n\to\infty}\mathbb{P}(X_n\neq Y_n)=0,$$

因此我们只要对 $\{Y_n\}$ 证明弱大数定律即可. 根据 Chebyshev 不等式有

$$\mathbb{P}\left(\left|\overline{Y}_n-\mathbb{E}\left(\overline{Y}_n\right)\right|\geq\varepsilon\right)\leq\frac{1}{\varepsilon^2}\operatorname{Var}\left(\overline{Y}_n-\mathbb{E}\left(\overline{Y}_n\right)\right)=\frac{1}{n^2\varepsilon^2}\sum_{k=1}^{n}\operatorname{Var}(Y_k).$$

有估计

$$\operatorname{Var}(Y_k)=\mathbb{E}\left(Y_k^2\right)-\mathbb{E}(Y_k)^2\leq\mathbb{E}\left(Y_k^2\right)=\int_{|x|\leq k}x^2\mathrm{d}F(x).$$

为了得到一个精细的上界, 取一个数列 $\{a_n\}$, 使得

$$0<a_n<n,\quad \lim_{n\to\infty}a_n=\infty,\quad \lim_{n\to\infty}\frac{a_n}{n}=0,$$

例如 $a_n=[\ln n]$. 此时有

$$\begin{aligned}&\sum_{k=1}^{n}\int_{|x|\leq k}x^2\mathrm{d}F(x)\\ =&\sum_{k=1}^{a_n}\int_{|x|\leq k}x^2\mathrm{d}F(x)+\sum_{k=a_n+1}^{n}\int_{|x|\leq k}x^2\mathrm{d}F(x)\\ \leq&\sum_{k=1}^{a_n}a_n\int_{|x|\leq a_n}|x|\mathrm{d}F(x)+\sum_{k=a_n+1}^{n}a_n\int_{|x|\leq a_n}|x|\mathrm{d}F(x)+\sum_{k=a_n+1}^{n}n\int_{a_n<|x|\leq n}|x|\mathrm{d}F(x)\\ \leq&na_n\int_{-\infty}^{+\infty}|x|\mathrm{d}F(x)+n^2\int_{|x|>a_n}|x|\mathrm{d}F(x).\end{aligned}$$

这就说明

$$\lim_{n\to\infty}\frac{1}{n^2}\sum_{k=1}^{n}\operatorname{Var}(Y_k)\leq\lim_{n\to\infty}\frac{a_n}{n}\mu+\lim_{n\to\infty}\int_{|x|>a_n}|x|\mathrm{d}F(x)=0,$$

进而

$$\lim_{n\to\infty}\mathbb{P}\left(\left|\overline{Y}_n-\mathbb{E}\left(\overline{Y}_n\right)\right|\geq\varepsilon\right)=0.$$

□

尽管在此情形下有强大数定律成立, 我们还是给出这个证明, 以此让读者熟悉截断法. 在正式研究强大数定律之前, 我们还要对截断法作更仔细的阐释, 这依赖于以下几个引理.

Theorem 4.2.5.(Kronecker) 设 $\{x_n\} \subseteq \mathbb{R}$, 正实数列 $\{a_n\}$ 单调上升趋于无穷, 若级数

$$\sum_{n=1}^{\infty} \frac{x_n}{a_n}$$

收敛, 则有

$$\lim_{n\to\infty} \frac{1}{a_n} \sum_{k=1}^{n} x_k = 0.$$

Proof. 定义

$$S_n = \sum_{k=1}^{n} \frac{x_k}{a_k},$$

则 $\{S_n\}$ 极限存在, 记为 S, 从而对任意 $\varepsilon > 0$, 存在 $N(\varepsilon) \in \mathbb{N}^*$, 当 $n > N(\varepsilon)$ 时, $|S_n - S| < \varepsilon$. 补充定义 $S_0 = 0$, 利用 Abel 变换可得

$$\frac{1}{a_n} \sum_{k=1}^{n} x_k = \frac{1}{a_n} \sum_{k=1}^{n} a_k(S_k - S_{k-1}) = S_n - \frac{1}{a_n} \sum_{k=1}^{n-1} (a_{k+1} - a_k) S_k.$$

由于 $\{a_n\}$ 单调上升, 有

$$\left| S - \frac{1}{a_n} \sum_{k=N(\varepsilon)+1}^{n-1} (a_{k+1} - a_k) S_k \right| = \left| \frac{1}{a_n} \sum_{k=N(\varepsilon)+1}^{n-1} (a_{k+1} - a_k)(S_k - S) + \frac{a_{N(\varepsilon)+1}}{a_n} S \right|,$$

由三角不等式上式有上界

$$\left(1 - \frac{a_{N(\varepsilon)+1}}{a_n}\right) \varepsilon + \frac{a_{N(\varepsilon)+1}}{a_n} |S|.$$

于是

$$\lim_{n\to\infty} \left| \frac{1}{a_n} \sum_{k=1}^{n} x_k \right| \leq \lim_{n\to\infty} \left(\left(1 - \frac{a_{N(\varepsilon)+1}}{a_n}\right) \varepsilon + \frac{a_{N(\varepsilon)+1}}{a_n} |S| \right) = \varepsilon.$$

根据 ε 的任意性即得

$$\lim_{n\to\infty} \frac{1}{a_n} \sum_{k=1}^{n} x_k = 0.$$

□

Theorem 4.2.6.(Kolmogorov) 设 $(\Omega, \mathscr{F}, \mathbb{P})$ 是概率空间, X_n 是其上相互独立的随机变量序列, 且各项方差有限存在. 定义

$$S_n = \sum_{k=1}^{n} (X_k - \mathbb{E}(X_k)),$$

则对任意 $\varepsilon > 0$, 有

$$\mathbb{P}\left(\max_{1\le k\le n}\{|S_k|\} \ge \varepsilon\right) \le \frac{1}{\varepsilon^2}\sum_{k=1}^{n}\mathrm{Var}(X_k).$$

Proof. 定义

$$A_0 = \emptyset, \quad A_k = \{\omega \in \Omega \mid |S_k(\omega)| \ge \varepsilon\},$$

而 B_k 为 $\Omega \setminus A_i (0 \le i \le k-1)$ 与 A_k 之交集, 则

$$A = \left\{\omega \in \Omega \mid \max_{1\le k\le n}\{|S_k(\omega)|\} \ge \varepsilon\right\} = \sum_{k=1}^{n} B_k.$$

于是

$$\mathbb{E}\left(S_n^2\right) \ge \mathbb{E}\left(S_n^2\chi_A\right) = \sum_{k=1}^{n}\mathbb{E}\left((S_n - S_k + S_k)^2\chi_{B_k}\right).$$

注意到 χ_{B_k}, S_k 和 $S_n - S_k$ 独立, 有

$$\mathbb{E}\left((S_n - S_k + S_k)^2\chi_{B_k}\right) = \mathbb{E}\left((S_n - S_k)^2\chi_{B_k}\right) + 2\mathbb{E}(S_n - S_k)\mathbb{E}(S_k\chi_{B_k}) + \mathbb{E}\left(S_k^2\chi_{B_k}\right),$$

其中

$$\mathbb{E}(S_n - S_k) = \mathbb{E}(S_n) - \mathbb{E}(S_k) = 0 - 0 = 0.$$

从而

$$\mathbb{E}\left(S_n^2\right) \ge \sum_{k=1}^{n}\mathbb{E}\left(S_k^2\chi_{B_k}\right) \ge \varepsilon^2\sum_{k=1}^{n}\mathbb{P}(B_k) = \varepsilon^2\mathbb{P}(A).$$

这就说明了

$$\mathbb{P}(A) \le \frac{1}{\varepsilon^2}\mathbb{E}\left(S_n^2\right) = \frac{1}{\varepsilon^2}\left(\mathrm{Var}(S_n) + \mathbb{E}(S_n)^2\right) = \frac{1}{\varepsilon^2}\mathrm{Var}(S_n) = \frac{1}{\varepsilon^2}\sum_{k=1}^{n}\mathrm{Var}(X_k).$$

□

Theorem 4.2.7.(Kolmogorov) 设 $(\Omega, \mathscr{F}, \mathbb{P})$ 是概率空间, X_n 是其上相互独立的随机变量序列. 对某个定常数 $A > 0$, 定义随机变量

$$Y_n(\omega) = \begin{cases} X_n(\omega), & |X_n(\omega)| \le A, \\ 0, & |X_n(\omega)| > A. \end{cases}$$

若级数

1.

$$\sum_{n=1}^{\infty}\mathbb{P}(|X_n| > A) = \sum_{n=1}^{\infty}\mathbb{P}(X_n \ne Y_n),$$

2.
$$\sum_{n=1}^{\infty}\mathbb{E}(Y_n),$$

3.
$$\sum_{n=1}^{\infty}\mathrm{Var}(Y_n)$$

均收敛, 则 X_n 的级数和收敛.

Proof. 根据**Theorem 4.2.6.**有

$$\mathbb{P}\left(\max_{n_1\le k\le n_2}\left\{\left|\sum_{j=n_1}^{k}(Y_j-\mathbb{E}(Y_j))\right|\right\}\le\frac{1}{m}\right)\ge 1-m^2\sum_{j=n_1}^{n_2}\mathrm{Var}(Y_j).$$

利用方差的收敛性, 依次取极限 $n_2\to\infty$ 和 $n_1\to\infty$ 可得概率收敛到 1, 于是

$$\sum_{n=1}^{\infty}(Y_n-\mathbb{E}(Y_n))$$

收敛. 注意到期望也收敛, 从而求和可知级数 Y_n 收敛, 进而由于 $\mathbb{P}(X_n\neq Y_n)$ 趋于 0 可知级数 X_n 收敛. □

现在我们证明第一个强大数定律.

Theorem 4.2.8.(Kolmogorov-Marcinkiewicz-Zygmund) 设 $(\Omega,\mathscr{F},\mathbb{P})$ 是概率空间, X_n 是其上相互独立的随机变量序列, 均值均为 0. 正实数列 $\{a_n\}$ 单调上升趋于无穷, $\varphi:\mathbb{R}\to\mathbb{R}$ 是非负连续偶函数, 使得 $\frac{\varphi(x)}{|x|}$ 单调上升, $\frac{\varphi(x)}{x^2}$ 单调下降, 且级数

$$\sum_{n=1}^{\infty}\frac{\mathbb{E}(\varphi(X_n))}{\varphi(a_n)}$$

收敛, 则 $\{X_n\}$ 满足强大数定律.

Proof. 构造随机变量

$$Y_n(\omega)=\begin{cases}X_n(\omega), & |X_n(\omega)|\le a_n,\\ 0, & |X_n(\omega)|>a_n.\end{cases}$$

则由 $\frac{\varphi(x)}{x^2}$ 单调下降可得

$$\sum_{n=1}^{\infty}\mathbb{E}\left(\frac{Y_n^2}{a_n^2}\right)=\sum_{n=1}^{\infty}\int_{|x|\le a_n}\frac{x^2}{a_n^2}\mathrm{d}F_n(x)\le\sum_{n=1}^{\infty}\int_{|x|\le a_n}\frac{\varphi(x)}{\varphi(a_n)}\mathrm{d}F_n(x),$$

利用**Proposition 2.4.5.**放缩得

$$\sum_{n=1}^{\infty}\mathrm{Var}\left(\frac{Y_n}{a_n}\right)\le\sum_{n=1}^{\infty}\int_{|x|\le a_n}\frac{\varphi(x)}{\varphi(a_n)}\mathrm{d}F_n(x)\le\sum_{n=1}^{\infty}\frac{E(\varphi(X_n))}{\varphi(a_n)}$$

收敛. 注意到

$$|Y_n - E(Y_n)| \leq |Y_n| + |\mathbb{E}(Y_n)| \leq 2a_n \implies \left|\frac{Y_n - \mathbb{E}(Y_n)}{a_n}\right| \leq 2,$$

在**Theorem 4.2.7.**中取 $A = 2$ 即知级数和

$$\sum_{n=1}^{\infty} \frac{Y_n - \mathbb{E}(Y_n)}{a_n}$$

收敛. 作估计

$$\sum_{n=1}^{\infty} \frac{|\mathbb{E}(Y_n)|}{a_n} = \sum_{n=1}^{\infty} \frac{1}{a_n} \left| \int_{|x|\leq a_n} x \mathrm{d}F_n(x) \right|,$$

注意到 X_n 的均值为 0, 有

$$\sum_{n=1}^{\infty} \frac{|\mathbb{E}(Y_n)|}{a_n} = \sum_{n=1}^{\infty} \frac{1}{a_n} \left| \int_{|x|>a_n} x \mathrm{d}F_n(x) \right| \leq \sum_{n=1}^{\infty} \int_{|x|>a_n} \frac{|x|}{a_n} \mathrm{d}F_n(x).$$

由于 $\frac{\varphi(x)}{|x|}$ 单调上升, 有

$$\sum_{n=1}^{\infty} \frac{|\mathbb{E}(Y_n)|}{a_n} \leq \sum_{n=1}^{\infty} \int_{|x|>a_n} \frac{\varphi(x)}{\varphi(a_n)} \mathrm{d}F_n(x) \leq \sum_{n=1}^{\infty} \frac{\mathbb{E}(\varphi(X_n))}{\varphi(a_n)}$$

收敛, 于是级数和 $\frac{Y_n}{a_n}$ 几乎处处收敛, 进而级数和 $\frac{X_n}{a_n}$ 几乎处处收敛. 利用**Theorem 4.2.5.**可知 $\{X_n\}$ 满足强大数定律. □

取 $\varphi(x) = |x|^p$ 和 $a_n = n$, 其中 $p = 2$ 的情形由 Kolmogorov 给出, $1 \leq p < 2$ 的情形由 Marcinkiewicz 和 Zygmund 给出.

以下 Kolmogorov 大数定律是 Khinchin 大数定律的推广, 也称为独立同分布大数定律.

Theorem 4.2.9.(Kolmogorov) 设 $(\Omega, \mathscr{F}, \mathbb{P})$ 是概率空间, X_n 是其上的随机变量序列. 若 X_k 独立同分布, 且均值 $\mathbb{E}(X_k) = \mu$ 有限存在, 则 $\{X_n\}$ 满足强大数定律.

Proof. 构造随机变量

$$Y_n(\omega) = \begin{cases} X_n(\omega), & |X_n(\omega)| \leq n, \\ 0, & |X_n(\omega)| > n. \end{cases}$$

注意到

$$\sum_{n=1}^{\infty} \frac{\mathbb{E}\left(Y_n^2\right)}{n^2} = \sum_{n=1}^{\infty} \frac{1}{n^2} \int_{|x|\leq n} x^2 \mathrm{d}F(x),$$

作估计

$$\begin{aligned}\sum_{n=1}^{\infty}\frac{1}{n^2}\int_{|x|\le n}x^2\mathrm{d}F(x) &= \sum_{n=1}^{\infty}\frac{1}{n^2}\sum_{j=1}^{n}\int_{j-1<|x|\le j}x^2\mathrm{d}F(x)\\ &= \sum_{j=1}^{\infty}\left(\sum_{n=j}^{\infty}\frac{1}{n^2}\int_{j-1<|x|\le j}x^2\mathrm{d}F(x)\right)\\ &\le \sum_{j=1}^{\infty}\left(\frac{C}{j}j\int_{j-1<|x|\le j}|x|\mathrm{d}F(x)\right)\\ &\le C\mu.\end{aligned}$$

根据**Theorem 4.2.8.**的结果即知 $\{X_n\}$ 满足强大数定律. □

4.3 中心极限定理

大数定律给出了消除噪声后随机变量序列 X_n 的平均极限, 而在中心极限定理一节, 我们将解释被消除的噪声的分布.

Definition 4.3.1.(中心极限定理) 设 $(\Omega,\mathscr{F},\mathbb{P})$ 是概率空间, X_n 是其上的随机变量序列, 记标准正态分布的概率分布函数为 $\Phi(x)$, 随机变量

$$S_n=\frac{\sum\limits_{k=1}^{n}(X_k-\mathbb{E}(X_n))}{\sqrt{\sum\limits_{k=1}^{n}\mathrm{Var}(X_k)}}.$$

如果 S_n 依分布收敛到 $\Phi(x)$, 即对任意 $x\in\mathbb{R}$, 有

$$\lim_{n\to\infty}\mathbb{P}\left(\frac{\sum\limits_{k=1}^{n}(X_k-\mathbb{E}(X_n))}{\sqrt{\sum\limits_{k=1}^{n}\mathrm{Var}(X_k)}}\leq x\right)=\Phi(x),$$

则称 $\{X_n\}$ 满足中心极限定理.

同样我们从最简单的情形开始, 即独立同分布的中心极限定理.

Theorem 4.3.1.(Levy) 设 $(\Omega,\mathscr{F},\mathbb{P})$ 是概率空间, X_n 是其上独立同分布的随机变量序列, 则 $\{X_n\}$ 满足中心极限定理.

Proof. 设均值为 μ, 方差为 σ^2, 则相当于证明

$$\lim_{n\to\infty}\mathbb{P}\left(\frac{\sum\limits_{k=1}^{n}X_k-n\mu}{\sigma\sqrt{n}}\leq x\right)=\Phi(x).$$

设 $X_n-\mu$ 的特征函数为 $\psi_X(t)$, 考虑随机变量 S_n 的特征函数

$$\psi_n(t)=\mathbb{E}\left(\exp\left(\mathrm{i}tS_n\right)\right)=\mathbb{E}\left(\exp\left(\mathrm{i}t\frac{X_k-\mu}{\sigma\sqrt{n}}\right)\right)^n.$$

注意到

$$\int_{-\infty}^{+\infty}\exp\left(\mathrm{i}t\frac{X_k-\mu}{\sigma\sqrt{n}}\right)\mathrm{d}F_X(x)=\int_{-\infty}^{+\infty}\exp\left(\mathrm{i}\frac{t}{\sigma\sqrt{n}}(X_k-\mu)\right)\mathrm{d}F_X(x)=\psi_X\left(\frac{t}{\sigma\sqrt{n}}\right),$$

作 Taylor 展开

$$\psi_X\left(\frac{t}{\sigma\sqrt{n}}\right)=\psi_X(0)+\frac{\mathrm{i}\mathbb{E}(X_k-\mu)}{\sigma\sqrt{n}}t+\frac{\mathrm{i}^2\mathbb{E}((X_k-\mu)^2)}{2\sigma^2n}t^2+o\left(\frac{t^2}{n}\right),$$

计算得

$$\psi_X\left(\frac{t}{\sigma\sqrt{n}}\right)=1-\frac{\mathrm{Var}(X_k-\mu)}{2\sigma^2 n}t^2+o\left(\frac{t^2}{n}\right)=1-\frac{t^2}{2n}+o\left(\frac{t^2}{n}\right).$$

于是

$$\lim_{n\to\infty}\psi_n(t)=\lim_{n\to\infty}\left(1-\frac{t^2}{2n}+o\left(\frac{t^2}{n}\right)\right)^n=\exp\left(-\frac{t^2}{2}\right).$$

根据唯一性定理**Theorem 3.1.4.**, 极限分布的特征函数是标准正态分布的特征函数, 表明极限分布就是标准正态分布 $\Phi(x)$. □

接下来我们证明最经典的 Lindeberg-Feller 中心极限定理. 为此需要一些关于收敛性的引理.

Theorem 4.3.2. 设复数列 $\{\theta_{nj}\}(1\le j\le k_n, n\ge 1)$ 满足

1. $\lim\limits_{n\to\infty}\max\limits_{1\le j\le k_n}\{|\theta_{nj}|\}=0$,
2. 对 $n\in\mathbb{N}^*$, 序列绝对和 $\sum\limits_{j=1}^{k_n}|\theta_{nj}|$ 一致有界 M,
3. $\lim\limits_{n\to\infty}\sum\limits_{j=1}^{k_n}\theta_{nj}=\theta$ 收敛,

则

$$\lim_{n\to\infty}\prod_{j=1}^{k_n}(1+\theta_{nj})=\mathrm{e}^{\theta}.$$

Proof. 每一项均可做展开

$$\log(1+\theta_{nj})=\theta_{nj}+\lambda_{nj}|\theta_{nj}|^2,$$

累加可得

$$\sum_{j=1}^{k_n}\log(1+\theta_{nj})-\theta=\left(\sum_{j=1}^{k_n}\theta_{nj}-\theta\right)+\sum_{j=1}^{k_n}\lambda_{nj}|\theta_{nj}|^2,$$

作估计

$$|\log(1+\theta_{nj})-\theta_{nj}|=\left|\sum_{m=2}^{\infty}\frac{(-1)^{m-1}}{m}\theta_{nj}^m\right|\le\sum_{m=2}^{\infty}\frac{|\theta_{nj}|^m}{m}.$$

注意 θ_{nj} 一致收敛于 0, 于是当 $n\ge n_0$ 充分大时, 有 $|\theta_{nj}|<\frac{1}{2}$, 于是进一步有

$$\sum_{m=2}^{\infty}\frac{|\theta_{nj}|^m}{m}\le\frac{|\theta_{nj}|^2}{2}\sum_{m=2}^{\infty}\left(\frac{1}{2}\right)^{m-2}=|\theta_{nj}|^2,$$

这表明 λ_{nj} 有界 1. 作估计

$$\left|\sum_{j=1}^{k_n}\lambda_{nj}|\theta_{nj}|^2\right| \le \max_{1\le k\le k_n}\{|\lambda_{nj}|\}\max_{1\le k\le k_n}\{|\theta_{nj}|\}\sum_{j=1}^{k_n}|\theta_{nj}| \le M\max_{1\le k\le k_n}\{|\theta_{nj}|\},$$

因而由控制收敛可知收敛到 0. 在

$$\sum_{j=1}^{k_n}\log(1+\theta_{nj})-\theta = \left(\sum_{j=1}^{k_n}\theta_{nj}-\theta\right)+\sum_{j=1}^{k_n}\lambda_{nj}|\theta_{nj}|^2$$

两边同时取极限即得

$$\lim_{n\to\infty}\sum_{j=1}^{k_n}\log(1+\theta_{nj})=\theta \iff \lim_{n\to\infty}\prod_{j=1}^{k_n}(1+\theta_{nj})=\mathrm{e}^{\theta}.$$

□

Theorem 4.3.3.(Liapounov) 设 $(\Omega,\mathscr{F},\mathbb{P})$ 是概率空间, $X_{nj}(1\le j\le k_n)$ 是其上的随机变量阵列, 其中当 $n\to\infty$ 有 $k_n\to\infty$, 各行内随机变量独立, 满足

$$\sum_{j=1}^{k_n}\mathrm{Var}(X_{nj})=1,\quad \mathbb{E}(X_{nj})=0,$$

且 $\mathbb{E}(|X_{nj}|^3)$ 有限存在, 以及

$$\lim_{n\to\infty}\sum_{j=1}^{k_n}\mathbb{E}(|X_{nj}|^3)=0,$$

则 $\{S_n\}$ 依分布收敛到 $\Phi(x)$, 其中 $S_n=\sum\limits_{j=1}^{k_n}X_{nj}$.

Proof. 为了应用**Theorem 4.3.2.**, 考虑 $\psi_{nj}(t)$ 的 Taylor 展开

$$\psi_{nj}(t)=1-\frac{1}{2}\mathrm{Var}(X_{nj})t^2+\lambda_{nj}\mathbb{E}(|X_{nj}|^3)|t|^3+o(|t|^4),$$

一次项为 0 是因为期望为 0, 对 Taylor 展开的余项估计可得 $|\lambda_{nj}|\le\frac{1}{6}$. 取

$$\theta_{nj}=-\frac{1}{2}\mathrm{Var}(X_{nj})t^2+\lambda_{nj}\mathbb{E}(|X_{nj}|^3)|t|^3,$$

则

$$\max_{1\le j\le k_n}\{|\theta_{nj}|\}\le\frac{t^2}{2}\max_{1\le j\le k_n}\{\mathrm{Var}(X_{nj})\}+\max_{1\le j\le k_n}\{|\lambda_{nj}|\}\max_{1\le j\le k_n}\left\{\mathbb{E}(|X_{nj}|^3)\right\}|t|^3.$$

对期望的积分用 Jensen 不等式**Theorem D.2.**可得

$$\max_{1\le j\le k_n}\left\{\mathbb{E}(X_{nj}^2)^{\frac{3}{2}}\right\},\max_{1\le j\le k_n}\{\mathrm{Var}(X_{nj})\}^{\frac{3}{2}}<\max_{1\le j\le k_n}\left\{\mathbb{E}(|X_{nj}|^3)\right\}\le\sum_{j=1}^{k_n}\mathbb{E}(|X_{nj}|^3),$$

而右边收敛到 0, 于是由控制收敛可知

$$\lim_{n\to\infty}\max_{1\le j\le k_n}\{|\theta_{nj}|\}=0.$$

另一方面

$$\sum_{j=1}^{k_n}|\theta_{nj}|\le\frac{t^2}{2}\sum_{j=1}^{k_n}\mathrm{Var}(X_{nj})+\frac{1}{6}\sum_{j=1}^{k_n}\mathbb{E}(|X_{nj}|^3)|t|^3,$$

右边极限为 $\frac{t^2}{2}$ 有界. 最后

$$\left|\sum_{j=1}^{k_n}\theta_{nj}+\frac{t^2}{2}\right|\le\frac{1}{6}\sum_{j=1}^{k_n}\mathbb{E}(|X_{nj}|^3)|t|^3$$

收敛到 0, 即

$$\lim_{n\to\infty}\sum_{j=1}^{k_n}\theta_{nj}=-\frac{t^2}{2}.$$

用**Theorem 4.3.2.**即得

$$\psi_n(t)=\prod_{j=1}^{k_n}\psi_{nj}(t)=\exp\left(-\frac{t^2}{2}\right),$$

根据唯一性定理**Theorem 3.1.4.**, 极限分布就是标准正态分布 $\Phi(x)$. □

以上给出的是标准化后的情形, 如果为进行标准化, 则要将 X_{nj} 变为

$$\frac{X_{nj}-\mathbb{E}(X_{nj})}{\sqrt{\sum\limits_{j=1}^{k_n}\mathrm{Var}(X_{nj})}},$$

代入得 Liapounov 条件

$$\lim_{n\to\infty}\left(\sum_{j=1}^{k_n}\mathrm{Var}(X_{nj})\right)^{-\frac{3}{2}}\sum_{j=1}^{k_n}\mathbb{E}(|X_{nj}-\mathbb{E}(X_{nj})|^3)=0.$$

此时随机变量阵列不再有行内要求, 于是可以取 $X_j=X_{nj}$ 和 $k_n=n$, 使之成为随机变量序列, 即在条件

$$\lim_{n\to\infty}\left(\sum_{j=1}^{n}\mathrm{Var}(X_j)\right)^{-\frac{3}{2}}\sum_{j=1}^{n}\mathbb{E}(|X_j-\mathbb{E}(X_j)|^3)=0$$

下, 有 $\{X_n\}$ 满足中心极限定理.

Proposition 4.3.4. 设 $(\Omega,\mathscr{F},\mathbb{P})$ 是概率空间, $X_{nj}(1\le j\le k_n)$ 是其上的随机变量阵列, 其中当 $n\to\infty$ 有 $k_n\to\infty$, 各行内随机变量独立, 满足

$$\sum_{j=1}^{k_n}\mathrm{Var}(X_{nj})=1,$$

$|X_{nj}| \leq M_{nj}$ 有界几乎处处成立, 使得

$$\lim_{n\to\infty} \max_{1\leq j\leq k_n} \{M_{nj}\} = 0,$$

则 $\{S_n - \mathbb{E}(S_n)\}$ 依分布收敛到 $\Phi(x)$, 其中 $S_n = \sum_{j=1}^{k_n} X_{nj}$.

Proof. 我们证明**Theorem 4.3.3.**的条件. 注意到

$$\sum_{j=1}^{k_n} \mathbb{E}(|X_{nj} - \mathbb{E}(X_{nj})|^3) \leq 2 \max_{1\leq j\leq k_n} \{M_{nj}\} \sum_{j=1}^{k_n} \mathrm{Var}(X_{nj}) = 2 \max_{1\leq j\leq k_n} \{M_{nj}\}$$

收敛于 0 即可. □

现在我们证明 Lindeberg-Feller 中心极限定理, 其中的关键就是 Lindeberg-Feller 条件

$$\lim_{n\to\infty} \sum_{j=1}^{k_n} \int_{|x|>\varepsilon} x^2 \mathrm{d}F_{nj}(x) = 0.$$

一个更好的结果是, 中心极限定理和此条件仅相差一个性质, 就成为充要条件.

Definition 4.3.2.(一致渐近可忽略) 设 $(\Omega, \mathscr{F}, \mathbb{P})$ 是概率空间, X_n 是其上的随机变量序列, 若对任意 $\varepsilon > 0$, 都有

$$\lim_{n\to\infty} \max_{1\leq k\leq n} \{\mathbb{P}(|X_k| > \varepsilon)\} = 0,$$

则称随机变量序列 $\{X_k\}$ **一致渐近可忽略 (holospoudic)**.

Theorem 4.3.5.(Lindeberg-Feller) 设 $(\Omega, \mathscr{F}, \mathbb{P})$ 是概率空间, $X_{nj}(1 \leq j \leq k_n)$ 是其上的随机变量阵列, 其中当 $n \to \infty$ 有 $k_n \to \infty$, 各行内随机变量独立, 满足

$$\sum_{j=1}^{k_n} \mathrm{Var}(X_{nj}) = 1, \quad \mathbb{E}(X_{nj}) = 0,$$

且对任意 $\varepsilon > 0$, 有

$$\lim_{n\to\infty} \sum_{j=1}^{k_n} \int_{|x|>\varepsilon} x^2 \mathrm{d}F_{nj}(x) = 0,$$

则随机变量序列 $\{X_n\}$ 一致渐近可忽略且满足中心极限定理.

Proof. 由 Chebyshev 不等式的证明方法可得

$$\mathbb{P}(|X_{nj}| > \varepsilon) \leq \frac{1}{\varepsilon^2} \int_{|x|>\varepsilon} x^2 \mathrm{d}F_{nj}(x) \leq \frac{1}{\varepsilon^2} \sum_{j=1}^{k_n} \int_{|x|>\varepsilon} x^2 \mathrm{d}F_{nj}(x),$$

于是其最大值被控制收敛到 0, 于是一致渐近可忽略. 考虑截断随机变量

$$Y_{nj} = \begin{cases} X_{nj}, & |X_{nj}| \leq \varepsilon, \\ 0, & \text{otherwise.} \end{cases}$$

记对 $1 \leq j \leq k_n$ 求和为 T_n, 则由于 $\mathbb{E}(X_{nj}) = 0$, 有

$$\mathbb{E}(Y_{nj}) = \int_{|x|\leq\varepsilon} x \mathrm{d}F_{nj}(x) = -\int_{|x|>\varepsilon} x \mathrm{d}F_{nj}(x).$$

从而

$$|\mathbb{E}(Y_{nj})| \leq \int_{|x|>\varepsilon} |x| \mathrm{d}F_{nj}(x) \leq \frac{1}{\varepsilon} \int_{|x|>\varepsilon} x^2 \mathrm{d}F_{nj}(x),$$

求和即得

$$|\mathbb{E}(T_n)| \leq \frac{1}{\varepsilon} \sum_{j=1}^{k_n} \int_{|x|>\varepsilon} x^2 \mathrm{d}F_{nj}(x)$$

控制收敛到 0. 根据 Cauchy-Schwarz 不等式有

$$\mathbb{E}(Y_{nj})^2 \leq \int_{|x|>\varepsilon} x^2 \mathrm{d}F_{nj}(x) \int_{|x|>\varepsilon} \mathrm{d}F_{nj}(x) \leq \int_{|x|>\varepsilon} x^2 \mathrm{d}F_{nj}(x).$$

于是

$$\mathrm{Var}(Y_{nj}) = \int_{|x|\leq\varepsilon} x^2 \mathrm{d}F_{nj}(x) - \mathbb{E}(Y_{nj})^2 \geq \int_{|x|\leq\varepsilon} x^2 \mathrm{d}F_{nj}(x) - \int_{|x|>\varepsilon} x^2 \mathrm{d}F_{nj}(x).$$

注意到

$$1 = \mathrm{Var}(S_n) \geq \mathrm{Var}(T_n) \geq \sum_{j=1}^{k_n} \int_{|x|\leq\varepsilon} x^2 \mathrm{d}F_{nj}(x) - \sum_{j=1}^{k_n} \int_{|x|>\varepsilon} x^2 \mathrm{d}F_{nj}(x)$$

取极限可知右边为 $1 - 0 = 1$, 于是

$$\lim_{n\to\infty} \mathrm{Var}(T_n) = 1, \quad \lim_{n\to\infty} \mathbb{E}(T_n) = 0,$$

为了应用**Proposition 4.3.4.**的结果, 我们需要把截断 $|X_{nj}| \leq \varepsilon$ 变成动态截断 $|X_{nj}| \leq \varepsilon_n = M_{nj}$, 且使得 ε_n 的极限为 0. 为此考虑条件的推论

$$\lim_{n\to\infty} m^2 \sum_{j=1}^{k_n} \int_{|x|>\frac{1}{m}} x^2 \mathrm{d}F_{nj}(x) = 0,$$

于是可以选取适当的序列 ε_n 是某个 $\frac{1}{m}$, 使得

$$\lim_{n\to\infty} \frac{1}{\varepsilon_n^2} \sum_{j=1}^{k_n} \int_{|x|>\varepsilon_n} x^2 \mathrm{d}F_{nj}(x) = 0.$$

这样由**Proposition 4.3.4.**可知 $\frac{T_n-\mathbb{E}(T_n)}{\sqrt{\mathrm{Var}(T_n)}}$ 依分布收敛到 $\Phi(x)$. 由依分布收敛的定义和 $\mathbb{E}(T_n)$ 收敛到 0 可知 $\frac{T_n}{\sqrt{\mathrm{Var}(T_n)}}$ 依分布收敛到 $\Phi(x)$. 最后对 S_n 我们有

$$\mathbb{P}(S_n \neq T_n) \leq \mathbb{P}\left(\bigcup_{j=1}^{k_n}\{X_{nj} \neq Y_{nj}\}\right) \leq \sum_{j=1}^{k_n}\mathbb{P}(|X_{nj}| > \varepsilon_n) \leq \sum_{j=1}^{k_n}\frac{1}{\varepsilon_n^2}\int_{|x|>\varepsilon_n} x^2 \mathrm{d}F_{nj}(x),$$

最后一个不等式是根据一致渐近可忽略而右边收敛到 0, 于是再次由依分布收敛的定义可得 $\frac{S_n}{\sqrt{\mathrm{Var}(S_n)}}$ 依分布收敛到 $\Phi(x)$, 即随机变量序列 $\{X_n\}$ 满足中心极限定理. □

类似地, 我们有随机变量序列的版本. 设 $(\Omega, \mathscr{F}, \mathbb{P})$ 是概率空间, X_n 是其上的随机变量序列, 对任意 $\varepsilon > 0$, 有

$$\lim_{n\to\infty}\left(\sum_{k=1}^{n}\mathrm{Var}(X_k)\right)^{-1}\sum_{k=1}^{n}\int_{|x|>\varepsilon}(x-\mathbb{E}(X_k))^2\mathrm{d}F_k(x) = 0,$$

则随机变量序列 $\{X_n\}$ 一致渐近可忽略且满足中心极限定理.

Chapter 5

随机过程

本章基础知识

Theorem E.1.(Hardy–Littlewood) 如果幂级数

$$\sum_{n=0}^{\infty} a_n x^n, \quad a_n \geq 0$$

在 $0 \leq x < 1$ 上收敛, 则

$$\lim_{n\to\infty} \frac{1}{n+1} \sum_{k=0}^{n} a_k = \lim_{x\to 1^-} \left((1-x) \sum_{n=0}^{\infty} a_n x^n \right).$$

Proof. □

5.1 随机游走

我们知道独立同分布且均值和方差有限的随机变量序列 X_n 满足大数定律和中心极限定理, 这是对随机变量序列平均的估计.

有的时候随机变量的作用效果是累加的, 即我们需要考虑随机变量和的估计. 例如 Brown 运动中, 分子每时刻会随机选定一个方向按某个速度前进, 其位移就是这些随机变量作用效果的累加. 我们先考虑其 1 维离散模型, 称为随机游走. 在本节中, 我们将以随机游走为例, 介绍随机过程中的重要概念.

Definition 5.1.1.(随机游走) 设 $(\Omega, \mathscr{F}, \mathbb{P})$ 是概率空间, X_n 是其上独立同分布的随机变量序列. 定义随机变量

$$S_n = \sum_{k=1}^{n} X_k,$$

则随机变量序列 S_n 称为 X 的**随机游走 (random walk)**.

如果我们要考虑 Brown 运动的连续情形, 必须把 S 的下标变为一个连续指标. 一般地, 随机变量序列可以视为若干次随机试验的结果, 即下标 k 可以视为一个依时间发展的指标, 我们可以推广为对任何一个 (未必可数的) 时间集 $\mathscr{T} \subseteq \mathbb{R}$, 定义一系列随机变量 $X_t (t \in \mathscr{T})$, 并研究这些随机变量之间的依赖关系, 这就是随机过程.

Definition 5.1.2.(随机过程) 设 $(\Omega, \mathscr{F}, \mathbb{P})$ 是概率空间, $\mathscr{T} \subseteq \mathbb{R}$ 是时间指标集. 对每个指标 $t \in \mathscr{T}$, X_t 都是 $(\Omega, \mathscr{F}, \mathbb{P})$ 上的随机变量, 则称 $\{X_t \mid t \in \mathscr{T}\}$ 是**随机过程 (stochastic process)**.

现在我们分析 X 的随机游走 S_n 作为离散随机过程有何性质.

考虑 $n, m \in \mathbb{N}$, 则

$$S_{m+n} - S_m = \sum_{k=m+1}^{m+n} X_k.$$

由于 X_k 独立同分布, 该随机变量的分布与

$$S_n = \sum_{k=1}^{n} X_k$$

相同, 即增量随机变量 $S_{m+n} - S_m$ 与 $S_n = S_n - S_0$ 同分布. 我们称这种类型的随机过程为时齐的. 另外当 $m \geq n$ 时, $X_k (1 \leq k \leq n)$ 和 $X_k (m+1 \leq k \leq m+n)$ 不相交, 当然是独立的, 因此 $S_{m+n} - S_m$ 与 S_n 独立. 我们称这种类型的随机过程为独立增量的. 关于另一类时齐独立增量随机过程, 我们将在 5.2 节仔细讨论.

再考虑条件概率. 如果给定 $X_k (1 \leq k \leq n)$, 则 S_n 也被确定, 但给定 $X_k (1 \leq k \leq n-1)$ 时

$$\mathbb{P}(S_n = s \mid X_k = a_k (1 \leq k \leq n-1)) = \frac{\mathbb{P}(S_n = s, X_k = a_k (1 \leq k \leq n-1))}{\mathbb{P}(X_k = a_k (1 \leq k \leq n-1))},$$

由随机游走的定义

$$\mathbb{P}(S_n = s, X_k = a_k(1 \le k \le n-1)) = \mathbb{P}\left(X_n = s - \sum_{k=1}^{n-1} a_k, X_k = a_k(1 \le k \le n-1)\right),$$

再根据独立性

$$\mathbb{P}(S_n = s \mid X_k = a_k(1 \le k \le n-1)) = \mathbb{P}\left(X_n = s - \sum_{k=1}^{n-1} a_k\right).$$

现在我们希望统一用 S_k 表出, 定义

$$s_n = \sum_{k=1}^{n} a_k,$$

则以上改写为

$$\mathbb{P}(S_n = s \mid S_k = s_k(1 \le k \le n-1)) = \mathbb{P}\left(X_n = s - s_{n-1}\right).$$

注意到 $X_n = S_n - S_{n-1}$, 有

$$\mathbb{P}\left(S_n = s \mid S_{n-1} = s_{n-1}\right) = \mathbb{P}\left(X_n = s - s_{n-1} \mid S_{n-1} = s_{n-1}\right) = \mathbb{P}\left(X_n = s - s_{n-1}\right),$$

这说明

$$\mathbb{P}(S_n = s \mid S_k = s_k(1 \le k \le n-1)) = \mathbb{P}\left(S_n = s \mid S_{n-1} = s_{n-1}\right),$$

即 S_n 的分布仅依赖于前一时间 S_{n-1}, 而不依赖于更早的 $S_k(1 \le k \le n-1)$. 我们称这一性质为 Markov 性质, 将在 5.3 节详细讨论.

现在开始我们刻画随机游走的一些重要特征. 首先考虑随机游走的一个例子: 两人携带相同初始资金 A 以 $\frac{1}{2}$ 的胜率对赌, 每次负者给胜者 1 资金, 直到宣布离开或资金归零. 如果 $A = +\infty$, 则赌局不会产生资金归零, 这相当于

$$\mathbb{P}(X = 1) = \mathbb{P}(X = -1) = \frac{1}{2}$$

的随机游走. 否则, $-A \le S_n \le A$, 一旦 $S_n = \pm A$ 就停止, 称为带吸收壁的随机游走.

如果你是一位赌徒, 必须要选择一个合适的时间结束赌局, 以免资金归零, 这一选择可以基于你当前时刻之前的轮数获得的所有信息. 为此, 我们需要刻画 “获得的信息” 和 “离开的时间” 这两点.

假设现在进行到了第 n 轮结束, 那么你得到了 $1 \le k \le n$ 轮的所有信息. 回顾**Definition 2.5.5.**, 一个条件对应于一个 σ-子代数, 即所有可能发生的结果对应的事件. 因此我们将

$$\mathscr{E}_n = \left\{X_n^{-1}(B) \in \mathscr{F} \mid B \in \mathscr{B}\right\}$$

视为 X_n 所携带的信息, 则 $\mathscr{E}_k(1 \leq k \leq n)$ 的并生成的 σ-代数 $\mathscr{F}_n$ 被视为第 n 轮结束时的所有信息. 从这个角度看, 条件期望就是在给定 $\mathscr{F}_n$ 的信息下计算期望.

现在你依据这些信息下了一个决定: 如果上一把输了就离开. 我们把离开的时间作为随机变量 α, 则第 n 轮结束后离开的概率

$$\mathbb{P}(\alpha = n) = \mathbb{P}(X_1 = 1, X_2 = 1, \ldots, X_{n-1} = 1, X_n = -1).$$

根据独立性

$$\alpha^{-1}(n) = \left(\bigcap_{k=1}^{n-1} X_k^{-1}(1)\right) \cap X_n^{-1}(-1) \in \mathscr{F}_n.$$

由于我们是基于已有的信息 $\mathscr{F}_n$ 作决定, 因此上面的结果是可以预见到的. 既然这一随机变量告诉我们何时离开, 我们就称之为停时.

Definition 5.1.3.(停时) 设 $(\Omega, \mathscr{F}, \mathbb{P})$ 是概率空间, $\{X_t \mid t \in \mathscr{T}\}$ 是其上的随机过程. 定义 t_0 时刻的信息是由

$$\mathscr{E}_t = \left\{X_t^{-1}(B) \in \mathscr{F} \mid B \in \mathscr{B}\right\}$$

在 $t \leq t_0$ 上的并生成的 $\mathscr{F}$ 的 σ-子代数, 称为 t_0 时刻随机过程 X_t 的**滤过 (filtration)**, 记作 $\mathscr{F}_{t_0}$, 同样在 $t > t_0$ 上的并生成的 $\mathscr{F}$ 的 σ-子代数记作 $\mathscr{F}'_{t_0}$. 一个随机变量 $\alpha : \Omega \to \mathscr{T} \cup \{\infty\}$ 称为随机过程 X_t 的**选择随机变量 (optional random variable)/停时 (stopping time)**, 如果对任意 $t \in \mathscr{T} \cup \{\infty\}$, 都有

$$\alpha^{-1}\left((-\infty, t] \cap (\mathscr{T} \cup \{\infty\})\right) \in \mathscr{F}_t.$$

即停时是一个随机变量, 仅依靠 t 时刻之前的信息给出在 t 时刻离开的概率. 在上述随机游走的例子中, 资金归零也可以视作一个停时

$$\mathbb{P}(\alpha = n) = \mathbb{P}\left(\sum_{k=1}^{n} X_k = -A, -A < \sum_{k=1}^{n'} X_k < A (1 \leq n' \leq n-1)\right).$$

这样我们就可以统一刻画一类性质.

另一个问题是随机游走是否有遍历性质. 例如对于 d 维空间的随机游走, 其整体上的性质是会徘徊于出发点附近, 还是会不断遍历全空间. 首先仍然考虑模型

$$\mathbb{P}(X = 1) = \mathbb{P}(X = -1) = \frac{1}{2},$$

问题就变成 S_n 会无限次取到任何一个整数值, 还是只能无限次取到一个范围内的整数值. 对一般的随机过程, X_t 的取值未必是整数, 从而应当考虑极限, 即对任意小的 ε 邻域, X_t 是否都会经过无穷次.

Definition 5.1.4.(常返值) 设 $(\Omega,\mathscr{F},\mathbb{P})$ 是概率空间, $\{X_t \mid t\in\mathscr{T}\}$ 是其上的随机过程. 对一点 $x\in\mathbb{R}$, 如果 X_t 会到 x 任意近的地方无穷多次, 即

$$\mathbb{P}\left(\liminf_{t\to\infty}|X_t-x|=0\right)=1,$$

则称 x 是一个**常返值 (recurrent value)**.

对随机游走而言

$$\liminf_{n\to\infty}|S_n-x|=0<\varepsilon$$

即存在无穷多个 S_n 取到 x 的任意邻域, 即随机游走会访问 x 附近无穷多次. 我们接下来分析随机游走的常返值的结构.

Theorem 5.1.1.(随机游走常返值的结构) 设 $(\Omega,\mathscr{F},\mathbb{P})$ 是概率空间, X_n 是其上独立同分布的随机过程, S_n 是相应的随机游走. 设 S_n 的常返值集合为 $\mathfrak{R}$, 则 $\mathfrak{R}$ 是 $\mathbb{R}$ 的加法子群, 特别地是 $\emptyset$, $c\mathbb{Z}$ 与 $\mathbb{R}$ 其中之一.

Proof. $\mathfrak{R}=\emptyset$ 显然符合结论, 否则任取 $x,y\in\mathfrak{R}$, 如果 $x-y\notin\mathfrak{R}$, 则依照定义

$$1-\mathbb{P}\left(\liminf_{n\to\infty}|S_n-(x-y)|=0\right)=\mathbb{P}\left(\liminf_{n\to\infty}|S_n-(x-y)|>0\right)>0$$

于是存在 $m\in\mathbb{N}^*$ 和 $\varepsilon>0$, 使得

$$\mathbb{P}\left(\bigcap_{n=m}^{\infty}\{|S_n-(x-y)|\geq 2\varepsilon\}\right)>0.$$

由于 $x,y\in\mathfrak{R}$, 存在 $k\in\mathbb{N}^*$ 使得

$$\mathbb{P}(|S_k-y|<\varepsilon)>0.$$

注意到

$$\{|S_k-y|<\varepsilon\}\cap\left(\bigcap_{n=m+k}^{\infty}\{|(S_n-S_k)-(x-y)|\geq 2\varepsilon\}\right)\subseteq\bigcap_{n=m+k}^{\infty}\{|S_n-x|\geq\varepsilon\},$$

结合 $n\geq k,m$ 时, S_k 与 S_n-S_k 独立, 就有

$$\mathbb{P}\left(\bigcap_{n=m+k}^{\infty}\{|S_n-x|\geq\varepsilon\}\right)\geq\mathbb{P}(|S_k-y|<\varepsilon)\mathbb{P}\left(\bigcap_{n=m+k}^{\infty}\{|(S_n-S_k)-(x-y)|\geq 2\varepsilon\}\right),$$

但右边两项均正, 导致左边也正, 这当且仅当 $x\notin\mathfrak{R}$, 从而矛盾, 因此 $x-y\in\mathfrak{R}$, 即 $\mathfrak{R}$ 是加法群. 由于常返值的极限点显然是常返值, 只要取充分接近极限点的常返值的返回点即可看出, 因此 $\mathfrak{R}$ 是 $\mathbb{R}$ 的闭加法群, 当然只有 $\emptyset$, $c\mathbb{Z}$ 和 $\mathbb{R}$. □

现在我们尝试判断一点是否为常返值.

Theorem 5.1.2.(随机游走的常返值) 设 $(\Omega, \mathscr{F}, \mathbb{P})$ 是概率空间, X_n 是其上独立同分布的随机过程, S_n 是相应的随机游走. 则 0 是常返值当且仅当对任意 $\varepsilon > 0$, 级数

$$\sum_{n=1}^{\infty} \mathbb{P}(|S_n| < \varepsilon)$$

发散.

Proof. 利用 Borel-Cantelli 引理**Theorem B.1.**, 如果存在一个 $\varepsilon > 0$ 使得级数收敛, 则

$$\mathbb{P}\left(\bigcap_{m=1}^{\infty}\bigcup_{n=m}^{\infty}\{|S_n| < \varepsilon\}\right) = 0 \iff \mathbb{P}\left(\bigcup_{m=1}^{\infty}\bigcap_{n=m}^{\infty}\{|S_n| \geq \varepsilon\}\right) = 1,$$

于是至少存在一个 m 使得

$$\mathbb{P}\left(\bigcap_{n=m}^{\infty}\{|S_n| \geq \varepsilon\}\right) > 0,$$

从而 x 不是常返值. 如果对任意 $\varepsilon > 0$, 级数都发散, 则考虑

$$\mathbb{P}\left(\liminf_{n\to\infty}\{|S_n| \geq \varepsilon\}\right) = \sum_{m=0}^{\infty}\mathbb{P}\left(\{|S_m| < \varepsilon\} \cap \left(\bigcap_{n=m+1}^{\infty}\{|S_n| \geq \varepsilon\}\right)\right),$$

这是因为 ω 在下极限集中当且仅当从某个 m 开始满足所有 $n \geq m$ 的 $|S_n(\omega)| \geq \varepsilon$, 且这些情况是不交的. 注意到

$$\{|S_m| < \varepsilon\} \cap \left(\bigcap_{n=m+1}^{\infty}\{|S_n - S_m| \geq 2\varepsilon\}\right) \subseteq \bigcap_{n=m+1}^{\infty}\{|S_n| \geq \varepsilon\},$$

结合 $n \geq m$ 时, S_m 与 $S_n - S_m$ 独立, 就有

$$\mathbb{P}\left(\liminf_{n\to\infty}\{|S_n| \geq \varepsilon\}\right) \geq \sum_{m=0}^{\infty}\mathbb{P}\left(|S_m| < \varepsilon\right)\mathbb{P}\left(\bigcap_{n=m+1}^{\infty}\{|S_{n-m}| \geq 2\varepsilon\}\right).$$

左边是有限值, 但右边级数发散, 导致必须有

$$\mathbb{P}\left(\bigcap_{n=1}^{\infty}\{|S_n| \geq 2\varepsilon\}\right) = 0.$$

现在对固定的 k, 考察

$$A_m = \{|S_m| < \varepsilon\} \cap \left(\bigcap_{n=m+k}^{\infty}\{|S_n| \geq \varepsilon\}\right),$$

显然当 $m' \geq m + k$ 时, A_m 中元素使得 $|S_{m+k}| \geq \varepsilon$ 但 $A_{m'}$ 不然, 因此 $A_m \cap A_{m'} = \emptyset$. 于是将 $A_m (m \in \mathbb{N}^*)$ 按模 k 余数分类, 同一类中必定无交, 从而

$$\sum_{m=1}^{\infty}\mathbb{P}(A_m) = \sum_{r=0}^{k-1}\mathbb{P}\left(\bigcup_{m=0}^{\infty}A_{mk+r+1}\right) \leq \sum_{r=0}^{k-1}1 = k.$$

再次利用集合的包含关系和独立增量可得

$$\mathbb{P}(A_m) \geq \mathbb{P}\left(|S_m| < \varepsilon\right) \mathbb{P}\left(\bigcap_{n=k}^{\infty} \{|S_n| \geq 2\varepsilon\}\right),$$

同理可证

$$\mathbb{P}\left(\bigcap_{n=k}^{\infty} \{|S_n| \geq 2\varepsilon\}\right) = 0.$$

现在利用次可加性

$$\mathbb{P}\left(\bigcup_{t=1}^{\infty}\bigcup_{k=1}^{\infty}\bigcap_{n=k}^{\infty}\left\{|S_n| \geq \frac{1}{t}\right\}\right) \leq \sum_{t=1}^{\infty}\sum_{k=1}^{\infty}\mathbb{P}\left(\bigcap_{n=k}^{\infty}\left\{|S_n| \geq \frac{1}{t}\right\}\right) = 0,$$

即得

$$\mathbb{P}\left(\bigcup_{t=1}^{\infty}\bigcup_{k=1}^{\infty}\bigcap_{n=k}^{\infty}\left\{|S_n| \geq \frac{1}{t}\right\}\right) = 0 \iff \mathbb{P}\left(\bigcap_{t=1}^{\infty}\bigcap_{k=1}^{\infty}\bigcup_{n=k}^{\infty}\left\{|S_n| < \frac{1}{t}\right\}\right) = 1.$$

若

$$\omega \in \bigcap_{t=1}^{\infty}\bigcap_{k=1}^{\infty}\bigcup_{n=k}^{\infty}\left\{|S_n| < \frac{1}{t}\right\},$$

则对每个 t 都可以找到一个子列使得 $|S_{n_k}(\omega)| < \frac{1}{t}$, 即得

$$\liminf_{n\to\infty} |S_n(\omega)| < \frac{1}{t},$$

于是

$$\liminf_{n\to\infty} |S_n(\omega)| = 0.$$

这就给出了

$$\mathbb{P}\left(\liminf_{n\to\infty} |S_n| = 0\right) \geq \mathbb{P}\left(\bigcap_{t=1}^{\infty}\bigcap_{k=1}^{\infty}\bigcup_{n=k}^{\infty}\left\{|S_n| < \frac{1}{t}\right\}\right) = 1,$$

即证 0 是常返值. □

下面我们给出常返的一个充分条件.

Theorem 5.1.3.(弱大数定律的常返性) 设 $(\Omega, \mathscr{F}, \mathbb{P})$ 是概率空间, X_n 是其上独立同分布的随机过程, 满足弱大数定律, 即对任意 $\varepsilon > 0$, 有

$$\lim_{n\to\infty} \mathbb{P}\left(|\overline{X}_n| < \varepsilon\right) = 1,$$

S_n 是相应的随机游走, 则必然存在 0 常返值.

Proof. 我们证明两个引理. 第一, 设 $\varepsilon > 0$ 且 $m \in \mathbb{N}$, 有

$$\sum_{n=0}^{\infty} \mathbb{P}(|S_n| < m\varepsilon) \leq 2m \sum_{n=0}^{\infty} \mathbb{P}(|S_n| < \varepsilon).$$

取 $I = (-\varepsilon, \varepsilon)$ 和 $J = [j\varepsilon, (j+1)\varepsilon)$, 并取 α 是首次进入 J 的停时, 则有

$$\mathbb{E}\left(\sum_{n=1}^{\infty} \chi_{S_n \in J}\right) = \sum_{k=1}^{\infty} \int_{\alpha=k} \sum_{n=1}^{\infty} \chi_{S_n \in J} \mathrm{d}\mathbb{P}.$$

根据 α 的定义, $\alpha(\omega) = k$ 导致 $S_k(\omega) \in J$, 以及 $S_k(\omega), S_n(\omega) \in J$ 导致 $S_n - S_k \in I$, 可得

$$\int_{\alpha=k} \left(1 + \sum_{n=k+1}^{\infty} \chi_{S_n \in J}\right) \mathrm{d}\mathbb{P} \leq \int_{\alpha=k} \left(1 + \sum_{n=k+1}^{\infty} \chi_{S_n - S_k \in I}\right) \mathrm{d}\mathbb{P},$$

其中的 1 来源于 S_k 第一次访问 J. 现在根据独立增量, 上式右边恰好是

$$\mathbb{P}(\alpha = k)\left(1 + \int_{\Omega} \sum_{n=k+1}^{\infty} \chi_{S_n - S_k \in I} \mathrm{d}\mathbb{P}\right) = \mathbb{P}(\alpha = k)\mathbb{E}\left(\sum_{n=0}^{\infty} \chi_{S_n \in I}\right),$$

其中的 1 被 $S_0 = 0 \in I$ 吸收. 代入得

$$\mathbb{E}\left(\sum_{n=1}^{\infty} \chi_{S_n \in J}\right) \leq \sum_{k=1}^{\infty} \mathbb{P}(\alpha = k)\mathbb{E}\left(\sum_{n=0}^{\infty} \chi_{S_n \in I}\right) \leq \mathbb{E}\left(\sum_{n=0}^{\infty} \chi_{S_n \in I}\right),$$

最后一个不等号是对 $\alpha = \infty$ 情况的放缩. 现在对 J 的参数 $-m \leq j \leq m-1$ 求和, 即得

$$\mathbb{E}\left(\sum_{n=1}^{\infty} \chi_{|S_n| < m\varepsilon}\right) \leq 2m\mathbb{E}\left(\sum_{n=0}^{\infty} \chi_{S_n \in I}\right),$$

根据期望的定义即证.

第二, 设函数值序列 $u_n(m)$ 关于变量 $m \geq 1$ 单调上升收敛到 1, 存在 $c > 0$ 使得

$$\sum_{n=0}^{\infty} u_n(m) \leq cm \sum_{n=0}^{\infty} u_n(1)$$

对一切 $m \geq 1$ 恒成立, 以及对任意 $\delta > 0$, 函数值序列 $u_n(\delta n)$ 收敛到 1, 则数项级数

$$\sum_{n=0}^{\infty} u_n(1)$$

发散. 采用反证法, 如果级数收敛, 则对任意 $A \in \mathbb{N}^*$ 有

$$\frac{1}{cm} \sum_{n=0}^{[Am]} u_n\left(\frac{n}{A}\right) \leq \frac{1}{cm} \sum_{n=0}^{[Am]} u_n(m) \leq \sum_{n=0}^{\infty} u_n(1)$$

收敛. 取 $\delta = \frac{1}{A}$, 则当 $m \to \infty$ 时利用 Stolz 定理

$$\lim_{m\to\infty} \frac{1}{cm} \sum_{n=0}^{[Am]} u_n\left(\frac{n}{A}\right) = \lim_{m\to\infty} \frac{[Am] - [A(m-1)]}{c} = \frac{A}{c} \leq \sum_{n=0}^{\infty} u_n(1).$$

由 A 任意可知发散, 矛盾.

现在证明原定理. 取引理中

$$u_n(m) = \mathbb{P}(|S_n| < m)$$

显然关于 m 单调上升收敛到 1, 且对 $c = 2$, 根据引理有

$$\sum_{n=0}^{\infty} u_n(m) \leq cm \sum_{n=0}^{\infty} u_n(1),$$

最后根据弱大数定律得到

$$\lim_{n\to\infty} u_n(\delta n) = \lim_{n\to\infty} \mathbb{P}\left(\left|\frac{S_n}{n}\right| < \delta\right) = 1.$$

于是根据引理的结果级数

$$\sum_{n=0}^{\infty} \mathbb{P}(|S_n| < 1)$$

发散. 由于上述证明对任意满足弱大数定律且独立同分布的随机游走都成立, 特别地对任意 $\frac{X_n}{\varepsilon}$ 也成立, 于是对任意 $\varepsilon > 0$, 有级数

$$\sum_{n=0}^{\infty} \mathbb{P}\left(|\frac{S_n}{\varepsilon}| < 1\right) = \sum_{n=0}^{\infty} \mathbb{P}(|S_n| < \varepsilon)$$

发散. 根据**Theorem 5.1.2.**可知 0 是一个常返值. □

独立同分布且均值存在时必然满足弱大数定律, 因此更常用的一个判别准则如下.

Theorem 5.1.4.(Chung-Fuchs) 设 $(\Omega, \mathscr{F}, \mathbb{P})$ 是概率空间, X_n 是其上独立同分布的随机过程, 使得期望

$$\mathbb{E}(\max\{X, 0\}), \quad \mathbb{E}(\min\{X, 0\})$$

均存在, 则存在 0 常返值当且仅当 $\mathbb{E}(X) = 0$.

Proof. 此时

$$\mathbb{E}(X) = \mathbb{E}(\max\{X, 0\}) + \mathbb{E}(\min\{X, 0\})$$

存在. 如果 $\mathbb{E}(X) = 0$, 根据**Theorem 4.2.9.**满足强大数定律. 根据**Theorem 5.1.3.**可知存在常返值. 否则不妨设 $\mathbb{E}(X) > 0$, 则根据强大数定律有 S_n 几乎处处收敛到 $+\infty$, 当然不可能存在有限的常返值. □

以后我们讨论其他随机过程时, 主要还是按照分布函数, 停时和常返值介绍.

5.2 Poisson 过程

考虑一个所谓独立增量过程, 即在不交的时间内, 随机变量的增量是独立随机变量. 这在处理流问题的时候是常见的. 例如, 客流量在一定的时间较大, 但在两段不交的时间是彼此独立的. 类似的情况也出现在粒子放射性衰变, 机器损坏等问题中.

一个简化的情形是不考虑峰时和谷时的流量差异, 认为在固定长度时间的平均流量都是相等的, 即平均速率关于时间是不变的, 这样的过程称为时齐的.

Example 5.2.1.(Poisson 过程) 考虑 $\mathscr{T} = [0, +\infty)$ 上的一个随机过程 X_t, 使得 X_t 只能取非负整数值, 且关于 t 单调上升, 满足以下条件.

1. 这是一个**独立增量 (independent increments)** 过程, 即对任何若干段不交的时间 $[t_1, t_2]$ 和 $[s_1, s_2]$, 增量 $X_{t_2} - X_{t_1}$ 和 $X_{s_2} - X_{s_1}$ 作为随机变量是独立的.

2. 这是一个**时齐 (temporally homogeneous)** 过程, 即对不交的时间 $[t_1, t_1 + s]$ 与 $[t_2, t_2 + s]$, 增量 $X_{t_1+s} - X_{t_1}$ 和 $X_{t_2+s} - X_{t_2}$ 同分布.

3. 初值 $X_0 = 0$.

4. 当时间充分短时, 增量与时间近似成正比, 且比例系数 λ 恒定, 即

$$\mathbb{P}(X_{t+\Delta t} - X_t = 1) = \lambda \Delta t + o(\Delta t), \quad \mathbb{P}(X_{t+\Delta t} - X_t \geq 2) = o(\Delta t).$$

现在我们分析这样的随机过程的分布. 根据时齐和独立增量的条件, 令

$$P_k(t) = \mathbb{P}(X_{s+t} - X_s = k) = \mathbb{P}(X_t - X_0 = k) = \mathbb{P}(X_t = k).$$

考虑其导数

$$P_k'(t) = \lim_{\Delta t \to 0} \frac{1}{\Delta t} \left(\mathbb{P}(X_{t+\Delta t} = k) - \mathbb{P}(X_t = k) \right).$$

根据概率的可加性和独立增量条件, $\mathbb{P}(X_{t+\Delta t} = k)$ 可以分解为

$$\sum_{n=0}^{k} \mathbb{P}(X_t = k - n, X_{t+\Delta t} - X_t = n) = \sum_{n=0}^{k} \mathbb{P}(X_t = k - n) \mathbb{P}(X_{t+\Delta t} - X_t = n).$$

在 $\Delta t \to 0$ 时, 对 $n \geq 2$ 的项都有 $o(\Delta t)$, 从而变为 0, 于是上式为两项

$$\mathbb{P}(X_t = k) \mathbb{P}(X_{t+\Delta t} - X_t = 0) + \mathbb{P}(X_t = k - 1) \mathbb{P}(X_{t+\Delta t} - X_t = 1).$$

代入得

$$P_k'(t) = P_k(t) \lim_{\Delta t \to 0} \frac{1}{\Delta t} (\mathbb{P}(X_{t+\Delta t} - X_t = 0) - 1) + P_{k-1}(t) \lim_{\Delta t \to 0} \frac{1}{\Delta t} \mathbb{P}(X_{t+\Delta t} - X_t = 1).$$

注意到

$$\mathbb{P}(X_{t+\Delta t} - X_t = 1) = \lambda \Delta t + o(\Delta t),$$

第二项恰好是 $\lambda P_{k-1}(t)$. 同样有

$$\mathbb{P}(X_{t+\Delta t} - X_t = 0) = 1 - \lambda \Delta t + o(\Delta t),$$

从而第一项是 $-\lambda P_k(t)$, 即有微分方程

$$P_k'(t) = -\lambda P_k(t) + \lambda P_{k-1}(t),$$

同样道理 $k = 0$ 时有 $P_0'(t) = -\lambda P_0(t)$. 为求解这一列常微分方程组, 将这些函数编码为

$$\Phi(t, z) = \sum_{k=0}^{\infty} P_k(t) z^k \implies \frac{\partial}{\partial t}\Phi(t, z) = \sum_{k=0}^{\infty} P_k'(t) z^k = -\lambda(1 - z)\Phi(t, z).$$

解此偏微分方程容易得到

$$\Phi(t, z) = C(z)\mathrm{e}^{-\lambda(1-z)t}.$$

注意到 $t = 0$ 时, $P_0(0) = \mathbb{P}(X_0 = 0) = 1$ 而其余各项均为 0, 于是

$$\Phi(0, z) = C(z) = 1 \implies \Phi(t, z) = \mathrm{e}^{-\lambda(1-z)t} = \sum_{k=0}^{\infty} \mathrm{e}^{-\lambda t} \frac{(\lambda t)^k}{k!} z^k,$$

比较系数即得

$$\mathbb{P}(X_t = k) = P_k(t) = \mathrm{e}^{-\lambda t} \frac{(\lambda t)^k}{k!}.$$

要注意在使用时齐和独立增量条件时, 由于独立同分布可以

$$\mathbb{P}(X_{s+t} - X_s = k) = \mathbb{P}(X_t - X_0 = k),$$

但不能

$$\mathbb{P}(X_s = i, X_{s+t} - X_s = j) = \mathbb{P}(X_s = i, X_t = j),$$

因为 X_s 与 X_t 未必独立. 正确的分拆应该是

$$\mathbb{P}(X_s = i, X_{s+t} - X_s = j) = \mathbb{P}(X_s = i)\mathbb{P}(X_{s+t} - X_s = j) = \mathbb{P}(X_s = i)\mathbb{P}(X_t = j).$$

上例给出的随机过程的分布是局部强度 $\lambda \Delta t$ 的 Poisson 分布, 相应地称为时齐 Poisson 过程.

Definition 5.2.1.(时齐 Poisson 过程) 一个随机过程 $\{X_t \mid t \in \mathscr{T}\}$ 称为**时齐 Poisson 过程 (homogeneous Poisson process)**, 如果满足以下条件.

1. 这是一个独立增量过程, 即对任何若干段不交的时间 $[t_1, t_2]$ 和 $[s_1, s_2]$, 增量 $X_{t_2} - X_{t_1}$ 和 $X_{s_2} - X_{s_1}$ 作为随机变量是独立的.
2. 这是一个时齐过程, 即对不交的时间 $[t_1, t_1 + s]$ 与 $[t_2, t_2 + s]$, 增量 $X_{t_1+s} - X_{t_1}$ 和 $X_{t_2+s} - X_{t_2}$ 同分布.
3. X_t 只能取非负整数值, 且关于 t 单调上升, 初值 $X_0 = 0$.
4. 在时间段 $[s, s + t]$ 内的增量 $X_{s+t} - X_s$ 服从 Poisson 分布 $\mathrm{Poi}(\lambda t)$, 即

$$\mathbb{P}(X_{s+t} - X_s = k) = \mathrm{e}^{-\lambda t}\frac{(\lambda t)^k}{k!}.$$

我们计算时齐 Poisson 过程的统计特征.

Proposition 5.2.1.(时齐 Poisson 过程的统计特征) 设 $\{X_t \mid t \in \mathscr{T}\}$ 为时齐 Poisson 过程, 则期望和方差 $\mathbb{E}(X_t) = \mathrm{Var}(X_t) = \lambda t$, 协方差

$$\mathrm{Cov}(X_s, X_t) = \lambda \min\{s, t\}.$$

Proof. 期望和方差由定义和**Example 2.4.5.**直接得到, 下面计算协方差, 由对称性不妨设 $s < t$, 则

$$\mathrm{Cov}(X_s, X_t) = \mathbb{E}(X_s X_t) - \mathbb{E}(X_s)\mathbb{E}(X_t) = \mathbb{E}(X_s X_t) - \lambda^2 st.$$

由于 X_s 与 $X_t - X_s$ 独立, 第一项

$$\mathbb{E}(X_s X_t) = \mathbb{E}(X_s^2 + X_s(X_t - X_s)) = \mathbb{E}(X_s^2) + \mathbb{E}(X_s)\mathbb{E}(X_t - X_s).$$

代入得

$$\mathrm{Cov}(X_s, X_t) = \lambda s + (\lambda s)^2 + (\lambda s)(\lambda(t - s)) - \lambda^2 st = \lambda s.$$

当然 $s > t$ 时为 λt, 而 $s = t$ 时退化为 $\mathrm{Cov}(X_t, X_t) = \mathrm{Var}(X_t) = \lambda t$, 因此

$$\mathrm{Cov}(X_s, X_t) = \lambda \min\{s, t\}.$$

□

现在我们开始研究停时. 考虑第 n 个事件的到达时间 τ_n, 即 $\tau_n \le t$ 表示第 n 个事件在 t 时刻前发生, 即累积发生次数 $X_t \ge n$.

Definition 5.2.2.(到达时间) 设 $\{X_t \mid t \in \mathscr{T}\}$ 为时齐 Poisson 过程, 定义随机变量

$$\tau_n = \inf\{t \ge 0 \mid X_t \ge n\},$$

则显然分布函数

$$\mathbb{P}(\tau_n \leq t) = \mathbb{P}(X_t \geq n),$$

称 τ_n 为时齐 Poisson 过程第 n 次事件的**到达时间 (interarrival time)**.

容易看出这是一个停时, 因为根据定义, 对任意 $t \in \mathscr{T} \cup \{\infty\}$, 都有

$$\tau_n^{-1}\left((-\infty, t]\right) = X_t^{-1}([n, +\infty)) \in \mathscr{E}_t \subseteq \mathscr{F}_t.$$

现在计算到达时间的联合分布.

Theorem 5.2.2.(到达时间的联合分布) 设 $\{X_t \mid t \in \mathscr{T}\}$ 为时齐 Poisson 过程, τ_k 为到达时间变量, 则 $\tau_1, \tau_2, \ldots, \tau_n$ 的联合密度函数为

$$f(t_1, t_2, \ldots, t_n) = \begin{cases} \lambda^n \mathrm{e}^{-\lambda t_n}, & 0 \leq t_1 < \cdots < t_n, \\ 0, & \text{otherwise.} \end{cases}$$

Proof. 根据全概率公式**Theorem 2.5.4.**

$$\mathbb{P}(\tau_1 \leq t_1, \tau_2 \leq t_2, \ldots, \tau_n \leq t_n) = \int_{\mathbb{R}} f_{\tau_1}(s)\mathbb{P}(\tau_2 \leq t_2, \ldots, \tau_n \leq t_n \mid \tau_1 = s)\mathrm{d}s.$$

一方面, 我们计算

$$\mathbb{P}(\tau_1 \leq s) = \mathbb{P}(X_s \geq 1) = 1 - \mathbb{P}(X_s = 0) = 1 - \mathrm{e}^{-\lambda s},$$

于是

$$f_{\tau_1}(s) = (-\mathrm{e}^{-\lambda s})(-\lambda) = \lambda \mathrm{e}^{-\lambda s}.$$

另一方面

$$\mathbb{P}(\tau_2 \leq t_2, \ldots, \tau_n \leq t_n \mid \tau_1 = s) = \mathbb{P}(X_{t_2} \geq 2, \ldots, X_{t_n} \geq n \mid X_s = 1),$$

根据时齐和独立增量条件, 这就是

$$\mathbb{P}(X_{t_2 - s} \geq 1, \ldots, X_{t_n - s} \geq n - 1 \mid X_s = 1) = \mathbb{P}(X_{t_2 - s} \geq 1, \ldots, X_{t_n - s} \geq n - 1),$$

也就是

$$\mathbb{P}(\tau_2 \leq t_2, \ldots, \tau_n \leq t_n \mid \tau_1 = s) = \mathbb{P}(\tau_1 \leq t_2 - s, \ldots, \tau_{n-1} \leq t_n - s).$$

代入得

$$\mathbb{P}(\tau_1 \leq t_1, \tau_2 \leq t_2, \ldots, \tau_n \leq t_n) = \int_0^{t_1} f_{\tau_1}(s)\mathbb{P}(\tau_1 \leq t_2 - s, \ldots, \tau_{n-1} \leq t_n - s)\mathrm{d}s,$$

对 t_1 求偏导得

$$\frac{\partial}{\partial t_1}\mathbb{P}(\tau_1 \le t_1, \tau_2 \le t_2, \dots, \tau_n \le t_n) = f_{\tau_1}(t_1)\mathbb{P}(\tau_1 \le t_2 - t_1, \dots, \tau_{n-1} \le t_n - t_1).$$

以此类推, 求第 $n-1$ 阶偏导后右边变为

$$\prod_{k=1}^{n-1} f_{\tau_1}(t_k - t_{k-1})\mathbb{P}(\tau_1 \le t_n - t_{n-1}),$$

其中 $t_0 = 0$. 再对 t_n 求导, 左边就是联合密度函数的定义

$$f(t_1, t_2, \dots, t_n) = \prod_{k=1}^{n} f_{\tau_1}(t_k - t_{k-1}) = \prod_{k=1}^{n} \lambda \mathrm{e}^{-\lambda((t_k - t_{k-1}))} = \lambda^n \mathrm{e}^{-\lambda t_n}.$$

由于其中会出现 $\tau_1 \le t_k - t_{k-1}$ 的概率, 如果任何一个 $t_k \le t_{k-1}$, 都会导致 $\tau_1 \le 0$, 当然概率恒为 0, 因此密度函数只在 $0 < t_1 < \cdots < t_n$ 上有定义. □

另一个重要的结果是条件分布.

Proposition 5.2.3.(到达时间的条件分布) 设 $\{X_t \mid t \in \mathscr{T}\}$ 为时齐 Poisson 过程, τ_k 为到达时间变量, 则在条件 $X_t = n$ 下 $\tau_1, \tau_2, \dots, \tau_n$ 的联合密度函数为

$$f(t_1, t_2, \dots, t_n \mid X_t = n) = \begin{cases} \frac{n!}{t^n}, & 0 < t_1 < \cdots < t_n \le t, \\ 0, & \text{otherwise}, \end{cases}$$

恰好是均匀分布的顺序统计量且与强度 λ 无关.

Proof. 同样根据全概率公式 **Theorem 2.5.4.**

$$\mathbb{P}(\tau_1 \le t_1, \dots, \tau_n \le t_n \mid X_t = n) = \int_{\mathbb{R}} f_{\tau_1}(s \mid X_t = n)\mathbb{P}(\tau_2 \le t_2, \cdots \mid \tau_1 = s, X_t = n)\mathrm{d}s.$$

一方面, 我们计算

$$\mathbb{P}(\tau_1 \le s \mid X_t = n) = 1 - \frac{\mathbb{P}(X_s = 0, X_t = n)}{\mathbb{P}(X_t = n)} = 1 - \frac{\mathbb{P}(X_s = 0)\mathbb{P}(X_{t-s} = n)}{\mathbb{P}(X_t = n)},$$

代入定义得

$$\mathbb{P}(\tau_1 \le s \mid X_t = n) = 1 - \left(\frac{t-s}{t}\right)^n,$$

于是

$$f_{\tau_1}(s \mid X_t = n) = n\frac{(t-s)^{n-1}}{t^n}.$$

另一方面同理有

$$\mathbb{P}(\tau_2 \le t_2, \dots, \tau_n \le t_n \mid \tau_1 = s, X_t = n) = \mathbb{P}(\tau_1 \le t_2 - s, \dots, \tau_{n-1} \le t_n - s \mid X_{t-s} = n-1).$$

代入并对 t_1 求偏导得

$$n\frac{(t-t_1)^{n-1}}{t^n}\mathbb{P}(\tau_1 \le t_2-t_1,\dots,\tau_{n-1}\le t_n-t_1 \mid X_{t-t_1}=n-1).$$

以此类推, 求第 $n-1$ 阶偏导后变为

$$\left(\prod_{k=1}^{n-1}(n+1-k)\frac{(t-t_k)^{n-k}}{(t-t_{k-1})^{n+1-k}}\right)\mathbb{P}(\tau_1 \le t_n-t_{n-1} \mid X_{t-t_{n-1}}=1),$$

其中 $t_0=0$. 注意到

$$\mathbb{P}(\tau_1 \le t_n-t_{n-1} \mid X_{t-t_{n-1}}=1)=1-\frac{(t-t_{n-1})-(t_n-t_{n-1})}{t-t_{n-1}}=\frac{t_n-t_{n-1}}{t-t_{n-1}}$$

再对 t_n 求导, 左边就是联合密度函数的定义

$$f(t_1,t_2,\dots,t_n)=\left(\prod_{k=1}^{n-1}(n+1-k)\frac{(t-t_k)^{n-k}}{(t-t_{k-1})^{n+1-k}}\right)\frac{1}{t-t_{n-1}}=\frac{n!}{t^n}.$$

同样道理密度函数只在 $0<t_1<\cdots<t_n\le t$ 上有定义. □

我们不研究 Poisson 过程的常返值, 因为其关于 t 单调上升. 以下我们介绍一些 Poisson 过程的推广.

Example 5.2.2.(非时齐 Poisson 过程) 如果我们在**Example 5.2.1.**中修改时齐条件, 即当时间充分短时, 增量的比例系数和时间有关, 即

$$\mathbb{P}(X_{t+\Delta t}-X_t=1)=\lambda(t)\Delta t+o(\Delta t),\quad \mathbb{P}(X_{t+\Delta t}-X_t\ge 2)=o(\Delta t).$$

则**Example 5.2.1.**的推导仍然成立, 只是要在积分过程中改为

$$\frac{\partial}{\partial t}\Phi(t,z)=-\lambda(t)(1-z)\Phi(t,z)\implies \Phi(t,z)=C(z)\exp\left(-(1-z)\int_0^t\lambda(t)\mathrm{d}t\right),$$

同样会得到 $C(z)=1$, 于是展开

$$\mathbb{P}(X_t=k)=P_k(t)=\frac{1}{k!}\left(\int_0^t\lambda(t)\mathrm{d}t\right)^k\exp\left(-\int_0^t\lambda(t)\mathrm{d}t\right),$$

或者更一般地

$$\mathbb{P}(X_t-X_s=k)=\frac{1}{k!}\left(\int_s^t\lambda(t)\mathrm{d}t\right)^k\exp\left(-\int_s^t\lambda(t)\mathrm{d}t\right).$$

Example 5.2.3.(复合 Poisson 过程) 在给定的离散过程 $X_k(k \geq 1)$ 独立同分布的基础上, 复合一个 Poisson 过程 N_t, 使之与所有 X_k 都独立, 得到随机过程

$$S_t = \sum_{k=1}^{N_t} X_k$$

称为复合 Poisson 过程. 如果给定 $N_t = n$, 则能够根据独立同分布计算各阶矩, 因此处理此类随机变量矩的一般方法是条件分解. 根据全概率公式**Theorem 2.5.2.**有

$$\mathbb{E}(S_t) = \sum_{n=1}^{\infty} \mathbb{E}\left(\sum_{k=1}^{N_t} X_k \mid N_t = n\right) \mathbb{P}(N_t = n) = \sum_{n=1}^{\infty} n\mathbb{E}(X)\mathbb{P}(N_t = n) = \mathbb{E}(X)\mathbb{E}(N_t).$$

同样道理, 对 $s < t$ 有

$$\mathbb{E}(S_s S_t) = \sum_{n=1}^{\infty} \mathbb{E}\left(\left(\sum_{i=1}^{N_s} X_i\right)\left(\sum_{j=1}^{N_t} X_j\right) \mid N_s = n\right) \mathbb{P}(N_s = n).$$

在 $N_s = n$ 的条件下, 每一项可以分解为 1 到 $N_s = n$ 的求和和 $n+1$ 到 N_t 的求和

$$\mathbb{E}\left(\left(\sum_{i=1}^{n} X_i\right)^2 \mid N_s = n\right) + \mathbb{E}\left(\left(\sum_{i=1}^{n} X_i\right)\left(\sum_{j=N_s+1}^{N_t} X_j\right) \mid N_s = n\right)$$

而 $n+1$ 到 N_t 的求和可以变为与前面独立

$$\mathbb{E}\left(\left(\sum_{i=1}^{n} X_i\right)\left(\sum_{j=N_s+1}^{N_t} X_j\right) \mid N_s = n\right) = \sum_{i=1}^{n} \mathbb{E}(X_i)\mathbb{E}\left(\sum_{j'=1}^{N_{t-s}} X_{j'}\right) = n\mathbb{E}(N_{t-s})\mathbb{E}(X)^2.$$

而根据方差的定义, 第一项可以写为

$$\mathbb{E}\left(\left(\sum_{i=1}^{n} X_i\right)\right)^2 + \operatorname{Var}\left(\sum_{i=1}^{n} X_i\right) = n^2\mathbb{E}(X)^2 + n\operatorname{Var}(X).$$

代入得

$$\mathbb{E}(S_s S_t) = \sum_{n=1}^{\infty} \left(n^2\mathbb{E}(X)^2 + n\operatorname{Var}(X) + n\mathbb{E}(N_{t-s})\mathbb{E}(X)^2\right) \mathbb{P}(N_s = n),$$

也可以写为

$$\mathbb{E}(S_s S_t) = \mathbb{E}(N_s^2)\mathbb{E}(X)^2 + \mathbb{E}(N_s)\left(\operatorname{Var}(X) + \mathbb{E}(N_{t-s})\mathbb{E}(X)^2\right).$$

根据**Proposition 5.1.1.**代入 N_t 的矩, 得到

$$\mathbb{E}(S_t) = \lambda t\mathbb{E}(X), \quad \mathbb{E}(S_s S_t) = \lambda s\operatorname{Var}(X) + (\lambda s + \lambda^2 st)\mathbb{E}(X)^2.$$

进而协方差

$$\operatorname{Cov}(S_s, S_t) = \lambda s\operatorname{Var}(X) + \lambda s\mathbb{E}(X)^2 = \lambda s\mathbb{E}(X^2).$$

一般而言

$$\mathbb{E}(S_t) = \lambda t \mathbb{E}(X), \quad \mathrm{Cov}(S_s, S_t) = \lambda \min\{s,t\} \mathbb{E}(X^2).$$

Example 5.2.4.(条件 Poisson 过程) 我们也可以把强度 λ 作为某个随机变量的取值, 即

$$\mathbb{P}(X_{t+s} - X_s = k \mid \Lambda = \lambda) = \mathrm{e}^{-\lambda t} \frac{(\lambda t)^k}{k!}.$$

于是无条件的分布函数为

$$\mathbb{P}(X_{t+s} - X_s = k) = \int_0^{+\infty} \mathrm{e}^{-\lambda t} \frac{(\lambda t)^k}{k!} f_\Lambda(\lambda) \mathrm{d}\lambda.$$

一般而言 Λ 的分布是困难的, 但其在某个 Poisson 过程的表征是容易测量的, 于是可以通过 Bayes 公式估计 Λ 的分布.

5.3 Markov 过程

回顾随机游走Definition 5.1.1., 我们曾说明过其具有 Markov 性质

$$\mathbb{P}(S_n = s \mid S_k = s_k(1 \le k \le n-1)) = \mathbb{P}\left(S_n = s \mid S_{n-1} = s_{n-1}\right).$$

一般而言, 一个 Markov 过程是指在给定的时间条件下的概率总是等于在最新时间条件下的概率的随机过程.

Definition 5.3.1.(Markov 过程) 一个随机过程 $\{X_t \mid t \in \mathscr{T}\}$ 称为 **Markov 过程 (Markov process)**, 如果对任意一列 $t_1 < t_2 < \cdots < t_n$ 在 $\mathscr{T}$ 中, 以及 $B \in \mathscr{B}$, 都有

$$\mathbb{P}(X_{t_n} \in B \mid X_{t_k} = x_k, 1 \le k \le n-1) = \mathbb{P}(X_{t_n} \in B \mid X_{t_{n-1}} = x_{n-1}).$$

如果对任意 s, t 都有

$$\mathbb{P}(X_{t+s} \in B \mid X_s = x) = P^{(t)}(x, B)$$

与 s 无关, 而只与时间差 t 有关, 则称该 Markov 过程是时齐的. 如果 $\mathscr{T} = \mathbb{N}$, 则称该 Markov 过程是**离散的 (discrete)**. 对连续的情形, 一般还要求概率关于连续变量 t 连续.

根据定义, 离散 Markov 过程满足

$$\mathbb{P}(X_n = x \mid X_k = x_k(1 \le k \le n-1)) = \mathbb{P}\left(X_n = x \mid X_{n-1} = x_{n-1}\right).$$

一个离散的时齐 Markov 过程是指

$$\mathbb{P}(X_{n+1} \in B \mid X_n = x) = P(x, B)$$

与 n 无关.

以上我们提到在 $X_n = x$ 的条件下 $X_{n+1} \in B$ 的概率, 其一般的提法是 $X_n = x$ 的条件下 $X_{n+1} = y$ 的概率. 如果 Markov 过程是时齐的, 则这与 n 的值无关, 即为 $\mathbb{P}(X_1 = y \mid X_0 = x)$, 相当于从状态 x 经过一步转移到 y 这一状态的概率.

Definition 5.3.2.(转移矩阵) 设 $\{X_t \mid t \in \mathscr{T}\}$ 为 Markov 过程. 定义在 s 时刻经过 t 时间从状态 x 转移到状态 y 的概率

$$\mathbb{P}(X_{t+s} = y \mid X_s = x) = P_s^{(t)}(x, y).$$

对所有的 (x, y), 以上构成的矩阵 $P_s^{(t)}$ 称为在 s 时刻步长为 t 的**概率转移矩阵 (probability transition matrix)**, 在 $t = 0$ 处的导数

$$Q_s = \frac{\mathrm{d}}{\mathrm{d}t} P_s^{(t)}|_{t=0} = \lim_{t \to 0^+} \frac{P_s^{(t)} - P_s^{(0)}}{t}$$

称为 s 时刻的**转移速率矩阵 (transition rate matrix)**, 其中 $P_s^{(0)} = I$. 如果 Markov 过程是时齐的, 则该矩阵与 s 无关, 记为 $P^{(t)}(x,y)$. 如果 Markov 过程是离散的, 则 s,t 只能取整数值. 特别地, 对离散 Markov 过程, 记 $P_n^{(1)}(x,y) = P_n(x,y)$.

这样就完整描述了 Markov 过程的分布函数, 即任意概率分布都可用初值 X_0 和转移矩阵计算得出.

Example 5.3.1.(随机游走作为 Markov 过程) 回顾随机游走的例子

$$\mathbb{P}(X=1)=p,\quad \mathbb{P}(X=-1)=q=1-p,$$

带有吸收壁 $X=1$ 和 $X=N$, 则这是一个时齐 Markov 过程. 当 $2\leq x\leq N-1$ 时, 向 $x+1$ 和 $x-1$ 的转移概率分别为 p 和 q, 而当 $x=1,N$ 时, 只能恒定不动, 即以 1 的概率向自身转移, 从而 1 步转移矩阵为

$$P=\begin{bmatrix}1&0&0&\cdots&0\\ q&0&p&\cdots&0\\ 0&q&0&\cdots&0\\ \vdots&\vdots&\vdots&\ddots&\vdots\\ 0&0&0&\cdots&1\end{bmatrix}$$

是三对角矩阵. 依照定义, 转移矩阵的行是所有转移情况, 因而行和必然为 1.

下面命题对转移矩阵而言是基本的.

Proposition 5.3.1.(Chapman-Kolmogorov) 设 $\{X_t \mid t\in\mathscr{T}\}$ 为 Markov 过程且取有限个值. 则对任意 $u,v\geq 0$ 使得 $t,t+u,t+v,t+u+v\in\mathscr{T}$, 以及状态 x,y, 有

$$P_t^{(u+v)}(x,y)=\sum_z P_t^{(u)}(x,z)P_{t+u}^{(v)}(z,y),$$

进而

$$P_t^{(u+v)}=P_t^{(u)}P_{t+u}^{(v)}=P_t^{(v)}P_{t+v}^{(u)}.$$

Proof. 依照定义右边为

$$\sum_z \mathbb{P}(X_{t+u}=z\mid X_t=x)\mathbb{P}(X_{t+u+v}=y\mid X_{t+u}=z),$$

利用 Markov 性, 这就是

$$\sum_z \mathbb{P}(X_{t+u}=z\mid X_t=x)\mathbb{P}(X_{t+u+v}=y\mid X_{t+u}=z,X_t=x).$$

展开得

$$\frac{1}{\mathbb{P}(X_t=x)}\sum_z \mathbb{P}(X_{t+u+v}=y, X_{t+u}=z, X_t=x).$$

根据全概率这当然是

$$\frac{1}{\mathbb{P}(X_t=x)}\mathbb{P}(X_{t+u+v}=y, X_t=x)=\mathbb{P}(X_{t+u+v}=y \mid X_t=x)=P_t^{(u+v)}(x,y).$$

□

如果记 s 时刻在 x 的概率为 $\pi_s(x)=\mathbb{P}(X_s=x)$, 并关于所有 x 构成行向量 π_s. 根据全概率公式

$$\sum_x \pi_s(x)P_s^{(t)}(x,y)=\sum_x \mathbb{P}(X_s=x)\mathbb{P}(X_{t+s}=y \mid X_s=x)=\mathbb{P}(X_{t+s}=y)=\pi_{t+s}(y),$$

可知 $\pi_s P_s^{(t)}=\pi_{t+s}$, 即状态转移矩阵是右乘作用于表示状态的行向量上的.

由此可见, 对离散时齐 Markov 过程, 从任意状态出发的 k 步转移矩阵, 相当于在该状态的行向量上乘 k 次 $P=P^{(1)}$, 即 $P^{(k)}=P^k$.

我们简要地分析一下连续 Markov 过程的性质.

Example 5.3.2.(连续 Markov 过程) 连续 Markov 过程是指时间参数 t 的取值是 $\mathbb{R}$ 的一段连续子集. 对时齐连续 Markov 过程而言, 转移矩阵 $P^{(t)}$ 关于 t 的连续性可以归约到 0 处的连续性. 根据**Proposition 5.3.1.**的结果

$$P^{(t+\Delta t)}(x,y)-P^{(t)}(x,y)=\sum_{z\neq x}P^{(\Delta t)}(x,z)P^{(t)}(z,y)-\left(1-P^{(\Delta t)}(x,x)\right)P^{(t)}(x,y).$$

一方面

$$P^{(t+\Delta t)}(x,y)-P^{(t)}(x,y)\leq\sum_{z\neq x}P^{(\Delta t)}(x,z)P^{(t)}(z,y)\leq\sum_{z\neq x}P^{(\Delta t)}(x,z)=1-P^{(\Delta t)}(x,x),$$

另一方面

$$P^{(t+\Delta t)}(x,y)-P^{(t)}(x,y)\geq-\left(1-P^{(\Delta t)}(x,x)\right)P^{(t)}(x,y)\geq-\left(1-P^{(\Delta t)}(x,x)\right),$$

立即看出有控制

$$\left|P^{(t+\Delta t)}(x,y)-P^{(t)}(x,y)\right|\leq 1-P^{(\Delta t)}(x,x),$$

从而根据 0 处的连续性可知右边在 $\Delta t\to 0$ 时趋于 0, 从而左边关于一切 t 一致连续.

对一个固定状态 x, 时齐导致对充分大的 n

$$P^{(t)}(x,x)\geq P^{\left(\frac{t}{n}\right)}(x,x)^n>0,$$

最后一个不等号是因为 $P^{(t)}(x,x)$ 在 0 处的极限是 1, 根据连续条件可知 n 充分大时为正.

对连续性进一步推广可以得到转移速率矩阵和概率转移矩阵的微分关系.

Example 5.3.3.(Kolmogorov 方程) 在**Example 5.3.2.**的基础上

$$P^{(t+\Delta t)}(x,y)-P^{(t)}(x,y)=\sum_z P^{(\Delta t)}(x,z)P^{(t)}(z,y)-\sum_z \delta_{xz}P^{(t)}(z,y)$$

两边除 Δt 得到

$$\frac{P^{(t+\Delta t)}(x,y)-P^{(t)}(x,y)}{\Delta t}=\sum_z P^{(t)}(z,y)\frac{P^{(\Delta t)}(x,z)-\delta_{xz}}{\Delta t},$$

取 $\Delta t\to 0$ 得到

$$\frac{\mathrm{d}}{\mathrm{d}t}P^{(t)}(x,y)=\sum_z P^{(t)}(z,y)Q(x,z),$$

即

$$\frac{\mathrm{d}}{\mathrm{d}t}P^{(t)}=QP^{(t)},$$

称为 Kolmogorov 向后方程. 同样有 Kolmogorov 向前方程

$$\frac{\mathrm{d}}{\mathrm{d}t}P^{(t)}=P^{(t)}Q.$$

由此可以解出 $P^{(t)}$ 和 Q 的关系

$$P^{(t)}=\mathrm{e}^{Qt}=\sum_{k=0}^{\infty}\frac{t^k}{k!}Q^k,$$

即时齐 Markov 过程的概率转移矩阵

一旦满足连续性条件, 转移速率就一定存在.

Proposition 5.3.2.(转移速率矩阵) 设 $\{X_t\mid t\in\mathscr{T}\}$ 为时齐 Markov 过程, 转移矩阵 $P^{(t)}$ 关于 t 连续, 则转移速率矩阵 Q 存在, 且非对角线元素有限.

Proof. 先考虑对角元. 根据**Proposition 5.3.1.**有

$$P^{(s+t)}(x,x)=\sum_z P^{(s)}(x,z)P^{(t)}(z,x)\geq P^{(s)}(x,x)P^{(t)}(x,x),$$

两边取对得到

$$\ln P^{(s+t)}(x,x)\geq \ln P^{(s)}(x,x)+\ln P^{(t)}(x,x).$$

现在对一个固定的 $t\in\mathscr{T}$, 以及任意的 $0<h<t$, 令 $\varepsilon(h,t)=t-n(h,t)h\in[0,h)$, 则

$$\frac{\ln P^{(t)}(x,x)}{t}\geq\frac{n(h,t)h}{t}\frac{\ln P^{(h)}(x,x)}{h}+\frac{\ln P^{(\varepsilon(h,t))}(x,x)}{t}.$$

取 $h \to 0^+$ 的上极限, 再取 $t > 0$ 的下确界, 得到

$$\inf_{t>0} \frac{\ln P^{(t)}(x,x)}{t} \geq \limsup_{h\to 0^+} \frac{\ln P^{(h)}(x,x)}{h}.$$

另一方面, 显然有

$$\inf_{t>0} \frac{\ln P^{(t)}(x,x)}{t} \leq \liminf_{t\to 0^+} \frac{\ln P^{(t)}(x,x)}{t},$$

立即看出极限存在

$$\lim_{t\to 0^+} \frac{\ln P^{(t)}(x,x)}{t} = \inf_{t>0} \frac{\ln P^{(t)}(x,x)}{t}.$$

最后根据等价无穷小就知道

$$Q(x,x) = \lim_{t\to 0^+} \frac{P^{(t)}(x,x)-1}{t} = \inf_{t>0} \frac{\ln P^{(t)}(x,x)}{t}$$

存在.

再考虑非对角元, 对任意 $\varepsilon > 0$, 存在 $\delta(x,y,\varepsilon) > 0$, 使得 $0 \leq t \leq \delta(x,y,\varepsilon)$ 时, $1 - P^{(t)}(x,x)$ 和 $1 - P^{(t)}(y,y)$ 均不超过 ε. 仍然用 $\varepsilon(h,t) = t - n(h,t)h$ 的记号, 并递推地构造

$$p_{z,x,y}(h) = P^{(h)}(x,y), \quad p_{z,x,y}((k+1)h) = \sum_{w\neq z} p_{z,x,y}(kh)P^{(h)}(w,y)$$

表示 kh 时刻在状态 y, 但在 $h,\ldots,(k-1)h$ 不在 z 的概率. 则有

$$P^{(mh)}(x,z) = \sum_{k=1}^{m-1} p_{y,x,y}(kh)P^{((m-k)h)}(y,z) + p_{y,x,z}(mh).$$

现在

$$\varepsilon \geq 1 - P^{(t)}(x,x) \geq P^{(t)}(x,y) \geq \sum_{m=1}^{n(h,t)} p_{y,x,y}(mh)P^{(t-mh)}(y,y) \geq (1-\varepsilon)\sum_{m=1}^{n(h,t)} p_{y,x,y}(mh).$$

于是

$$\sum_{m=1}^{n(h,t)} p_{y,x,y}(mh) \leq \frac{\varepsilon}{1-\varepsilon}.$$

进而

$$p_{y,x,x}(mh) \geq P^{(mh)}(x,x) - \sum_{k=1}^{m-1} p_{y,x,y}(kh) \geq 1 - \varepsilon - \frac{1}{1-\varepsilon}.$$

综上放缩得

$$P^{(t)}(x,y) \geq \sum_{m=1}^{n(h,t)} p_{y,x,y}((m-1)h)P^{(h)}(x,y)P^{(t-mh)}(y,y) \geq n(1-3\varepsilon)P^{(h)}(x,y),$$

即得

$$P^{(h)}(x,y) \leq \frac{P^{(t)}(x,y)}{n(h,t)}\frac{1}{1-3\varepsilon}.$$

现在两边除 h, 并取 $h \to 0^+$ 的上极限, 得到

$$\limsup_{h\to 0^+} \frac{P^{(h)}(x,y)}{h} \le \frac{1}{1-3\varepsilon}\frac{P^{(t)}(x,y)}{t}.$$

再取 $t \to 0^+$ 的下极限, 结合 ε 的任意性得到极限存在且有限. □

我们知道一个行列表示同样意义 (在这里是所有状态) 的矩阵可以视作一个有向图, 矩阵的元素即边的权重. 对一个时齐 Markov 过程, 如果存在某个转移矩阵的元素 $P^{(t)}(x,y) > 0$, 则称状态 x 到状态 y 是可达的, 这相当于有一条边 $e(x,y)$. 如果两个状态在同一个强连通子图中, 则称 x, y 是互通的.

Definition 5.3.3.(可达与互通) 设 $\{X_t \mid t \in \mathscr{T}\}$ 为时齐 Markov 过程. 对两个状态 $x, y \in \mathbb{R}$, 如果存在一个 $t \in \mathscr{T}$, 使得

$$P^{(t)}(x,y) = \mathbb{P}(X_t = y \mid X_0 = x) > 0,$$

则称 x 到 y **可达 (accessible)**. 如果 x 到 y 和 y 到 x 都可达, 则称 x 与 y ***互通*** **(communicate)**. 以互通为等价关系分划得到的等价类称为**不可约的 (irreducible)** 子 Markov 过程.

显然, 对离散时齐 Markov 过程而言, 如果 $P^{(1)}(x,y) = 0$ 对一切 $x \in S$ 和 $y \notin S$ 都成立, 则根据**Proposition 5.3.1.**归纳可知 $P^{(n)}(x,y) = 0$ 恒成立, 从而与外界不可达, 进而可以分解为不可约部分的并.

如果从初值 $X_0 = x$ 到 y 是可达的, 则可以考虑以下非平凡的停时.

Definition 5.3.4.(首达时) 设 $\{X_t \mid t \in \mathscr{T}\}$ 为时齐 Markov 过程, 状态 x 到 y 可达. 定义

$$\tau(x,y) = \inf\{n \in \mathbb{N}^* \mid X_0 = x, X_n = y\}$$

称为**首达时 (hitting time)**. 概率分布

$$\mathbb{P}(\tau(x,y) = n) = \mathbb{P}\left(X_n = y, X_k \neq y (1 \le k \le n-1) \mid X_0 = x\right)$$

称为在 n 时刻的**首达概率 (first passage probability)**. 为方便讨论, 定义任意两点之间通过 0 步到达的概率 $\mathbb{P}(\tau(x,y) = 0) = 0$. 在所有时刻到达的总概率

$$\sum_{n=1}^{\infty} \mathbb{P}(\tau(x,y) = n) = 1 - \mathbb{P}(\tau(x,y) = \infty)$$

称为 (x,y) 的**到达概率 (hitting probability)**.

下面命题展示了首达时和转移矩阵的关系.

Proposition 5.3.3.(首达时与转移矩阵) 设 X_n 为离散时齐 Markov 过程. 则对任意状态 x, y, 有

$$P^{(n)}(x,y) = \sum_{k=1}^{n} \mathbb{P}(\tau(x,y)=k) P^{(n-k)}(y,y).$$

Proof. 根据全概率公式**Theorem 2.5.4.**, 显然有

$$P^{(n)}(x,y) = \sum_{k=1}^{n} \mathbb{P}(X_{n-k}=y \mid X_0=y)\mathbb{P}(\tau(x,y)=k) = \sum_{k=1}^{n} P^{(n-k)}(y,y)\mathbb{P}(\tau(x,y)=k).$$

□

如果 (x,x) 的到达概率为 1, 可以视为从 x 出发总是会回到 x, 因此我们期待 x 是一个常返值.

Theorem 5.3.4.(离散时齐 Markov 过程的常返值 I) 设 X_n 为离散时齐 Markov 过程且取有限个值, $X_0 = x$, $\tau(x,y)$ 为首达时. 如果

$$\sum_{n=1}^{\infty} \mathbb{P}(\tau(x,x)=n) = 1,$$

当且仅当 x 是常返值, 即

$$\mathbb{P}\left(\liminf_{n\to\infty} |X_n - x| = 0\right) = 1.$$

Proof. 考虑停时

$$\tau_k(x,y) = \inf\{n > \tau_{k-1}(x,y) \mid X_{\tau_{k-1}(x,y)} = x, X_n = y\}$$

为第 k 次回到 x 的时刻, 则 $\tau_1(x,y) = \tau(x,y)$, 依照条件

$$\mathbb{P}(\tau_1(x,x) < \infty) = \sum_{n=1}^{\infty} \mathbb{P}(\tau_1(x,x)=n) = 1.$$

现在利用时齐 Markov 性质

$$\mathbb{P}(\tau_k(x,x) < \infty \mid \tau_{k-1}(x,x)=n) = \mathbb{P}(\tau_1(x,x) < \infty) = 1,$$

于是利用全概率公式并归纳得

$$\mathbb{P}(\tau_k(x,x) < \infty) = \sum_{n=1}^{\infty} \mathbb{P}(\tau_k(x,x) < \infty \mid \tau_{k-1}(x,x)=n)\mathbb{P}(\tau_{k-1}(x,x)=n),$$

即得

$$\mathbb{P}(\tau_k(x,x) < \infty) = \sum_{n=1}^{\infty} \mathbb{P}(\tau_{k-1}(x,x)=n) = 1.$$

根据次可加性

$$\mathbb{P}\left(\bigcup_{k=1}^{\infty}\{\tau_k(x,x)=\infty\}\right)\leq\sum_{k=1}^{\infty}\mathbb{P}(\tau_k(x,x)=\infty)=0,$$

于是

$$\mathbb{P}\left(\bigcap_{k=1}^{\infty}\{\tau_k(x,x)<\infty\}\right)=1.$$

而若

$$\omega\in\bigcap_{k=1}^{\infty}\{\tau_k(x,x)<\infty\},$$

则

$$X_{\tau_k(x,x)}(\omega)=X_0(\omega)=x,$$

即得

$$\mathbb{P}\left(\liminf_{n\to\infty}|X_n-x|=0\right)=1.$$

反之, 若

$$\liminf_{n\to\infty}|X_n(\omega)-x|=0,$$

由于 X_n 只能取有限个值, 存在一列 $X_{n_k}(\omega)=x$, 于是可以取所有这些列中的最小下标 n, 立即有

$$\tau(x,x)(\omega)=n.$$

于是

$$\mathbb{P}(\tau(x,x)<\infty)\geq\mathbb{P}\left(\liminf_{n\to\infty}|X_n-x|=0\right)=1.$$

□

既然转移矩阵 $P_s^{(t)}$ 可以完全刻画 Markov 过程, 我们也可以用转移矩阵刻画常返值. 事实上, 常返就是说到达 x 的次数为无限多, 而到达 x 的次数其实就是在第 n 时刻到达 x 的特征随机变量的和, 这给出了下面的命题.

Theorem 5.3.5.(离散时齐 Markov 过程的常返值 II) 设 X_n 为离散时齐 Markov 过程且取有限个值, $X_0=x$, $P_n^{(k)}$ 是转移矩阵. 则 x 是常返值当且仅当级数

$$\sum_{k=1}^{\infty}P^{(k)}(x,x)$$

发散.

Proof. 只要证明这一结果和**Theorem 5.3.4.**的条件等价. 注意到可以对 $P^{(k)}(x,y)$ 作条件分解, 在条件 $\tau(x,y)=i$ 下, 即第一次到达 y 的时间间隔为 i, 则根据时齐 Markov 性质, 条件概率为

$$\mathbb{P}(X_k=y\mid X_0=x,X_i=y,X_j\neq y,1\leq j\leq i-1)=\mathbb{P}(X_{k-i}=y\mid X_0=y).$$

于是由**Proposition 5.3.3**

$$P^{(k)}(x,y)=\sum_{i=1}^{k}P^{(k-i)}(y,y)\mathbb{P}(\tau(x,y)=i).$$

现在令 $y=x$, 则由于各项均非负, 由 Tonelli 定理**Theorem B.5.**

$$\sum_{k=1}^{\infty}P^{(k)}(x,x)=\sum_{k=1}^{\infty}\sum_{i=1}^{k}P^{(k-i)}(x,x)\mathbb{P}(\tau(x,x)=i)=\sum_{i=1}^{\infty}\sum_{k=i}^{\infty}P^{(k-i)}(x,x)\mathbb{P}(\tau(x,x)=i).$$

注意到内层求和

$$\sum_{k=i}^{\infty}P^{(k-i)}(x,x)=\sum_{k=0}^{\infty}P^{(k)}(x,x)=1+\sum_{k=1}^{\infty}P^{(k)}(x,x)$$

实际上与 i 无关, 外层求和就是

$$\sum_{k=1}^{\infty}P^{(k)}(x,x)=\left(1+\sum_{k=1}^{\infty}P^{(k)}(x,x)\right)\left(\sum_{i=1}^{\infty}\mathbb{P}(\tau(x,x)=i)\right),$$

即

$$\sum_{i=1}^{\infty}\mathbb{P}(\tau(x,x)=i)=\left(\sum_{k=1}^{\infty}P^{(k)}(x,x)\right)\left(1+\sum_{k=1}^{\infty}P^{(k)}(x,x)\right)^{-1}.$$

于是级数发散当且仅当

$$\sum_{i=1}^{\infty}\mathbb{P}(\tau(x,x)=i)=1,$$

根据**Theorem 5.3.4.**此即 x 是常返值. □

如果固定一个常返值 x_0, 则从任意一点 x 出发, 可能能够到达 x_0, 从而常返, 也可能不能到达 x_0, 从而级数收敛. 但是其平均必然收敛, 即对 x_0 的平均访问次数是一个有限值.

Proposition 5.3.6.(离散时齐 Markov 过程的 Cesaro 极限) 设 X_n 为离散时齐 Markov 过程且取有限个值, $P_n^{(k)}$ 是转移矩阵, x_0 是常返值. 则对任意状态 x, 有

$$\lim_{n\to\infty}\frac{1}{n+1}\sum_{k=0}^{n}P^{(k)}(x,x_0)=\mathbb{P}(\tau(x,x_0)<\infty)\mathbb{E}(\tau(x_0,x_0))^{-1}.$$

Proof. 构造幂级数

$$f_x(t)=\sum_{n=0}^{\infty}P^{(n)}(x,x_0)t^n,\quad g_x(t)=\sum_{n=0}^{\infty}\mathbb{P}(\tau(x,x_0)=n)t^n,$$

显然在 $0\le t<1$ 收敛, 因为系数和不超过 1. 利用**Theorem E.1.**只要证明

$$\lim_{t\to1^-}(1-t)f_x(t)=\mathbb{P}(\tau(x,x_0)<\infty)\mathbb{E}(\tau(x,x_0))^{-1}.$$

由 Tonelli 定理**Theorem B.5.**换序, 当 $x\neq x_0$ 时 $f_{x_0}(t)g_x(t)$ 的结果为

$$\sum_{i=0}^{\infty}\sum_{k=i}^{\infty}P^{(k-i)}(x_0,x_0)\mathbb{P}(\tau(x,x_0)=i)t^k=\sum_{k=0}^{\infty}\sum_{i=0}^{k}P^{(k-i)}(x_0,x_0)\mathbb{P}(\tau(x,x_0)=i)t^k,$$

这就是

$$f_{x_0}(t)g_x(t)=\sum_{k=0}^{\infty}P^{(k)}(x,x_0)t^k=f_x(t),$$

而当 $x=x_0$ 时, $i=0$ 的项永远为 0, 因此实际上

$$f_{x_0}(t)g_{x_0}(t)=\sum_{k=1}^{\infty}P^{(k)}(x_0,x_0)t^k=f_{x_0}(t)-1\implies f_{x_0}(t)=\frac{1}{1-g_{x_0}(t)}.$$

于是

$$\lim_{t\to1^-}(1-t)f_x(t)=\lim_{t\to1^-}\frac{1-t}{1-g_{x_0}(t)}g_x(t).$$

用 L'Hospital 法则即得

$$\frac{1}{g'_{x_0}(1)}g_x(1)=\left(\sum_{n=0}^{\infty}\mathbb{P}(\tau(x,x_0)=n)\right)\left(\sum_{n=0}^{\infty}n\mathbb{P}(\tau(x,x_0)=n)\right)^{-1},$$

这恰好就是

$$\mathbb{P}(\tau(x,x_0)<\infty)\mathbb{E}(\tau(x_0,x_0))^{-1}.$$

□

如果 x 是常返值, 我们还要考虑其平均返回时间, 即首达时的期望 $\mathbb{E}(\tau(x,x))$.

Definition 5.3.5.(时齐 Markov 过程常返值的分类) 设 $\{X_t\mid t\in\mathscr{T}\}$ 为时齐 Markov 过程, 状态 x 常返. 如果期望 $\mathbb{E}(\tau(x,x))$ 为有限值, 则称 x 为**正常返值 (positive recurrence)**, 否则称为**零常返值 (null recurrence)**. $P^{(n)}(x,x)>0$ 成立的所有 n 的最大公约数称为该离散时齐 Markov 过程的**周期 (period)**.

如果周期为 T, 则前 $nT+1$ 项只有 T 的倍数项非零, 其平均

$$\lim_{n\to\infty}\frac{1}{nT+1}\sum_{k=0}^{n}P^{(kT)}(x,x_0)=\mathbb{P}(\tau(x,x_0)<\infty)\mathbb{E}(\tau(x,x_0))^{-1}.$$

根据**Proposition 5.3.3.**可知

$$\mathbb{P}(\tau(x,x_0)<\infty)=\sum_{n=1}^{\infty}\mathbb{P}(\tau(x,x_0)=n)=1.$$

注意到

$$\lim_{n\to\infty}\frac{nT+1}{n+1}=T,$$

可得

$$\lim_{n\to\infty}\frac{1}{n+1}\sum_{k=0}^{n}P^{(kT)}(x,x_0)=\frac{T}{\mathbb{E}(\tau(x,x_0))}.$$

事实上, 我们有以下更好的结果.

Proposition 5.3.7.(离散时齐 Markov 过程常返值的访问次数) 设 X_n 为离散时齐 Markov 过程且取有限个值, $P^{(k)}$ 是转移矩阵, x 是周期 T 的常返值. 则有

$$\lim_{n\to\infty}P^{(nT)}(x,x)=\frac{T}{\mathbb{E}(\tau(x,x))}.$$

Proof. 考察余项

$$r_n=\sum_{k=n+1}^{\infty}\mathbb{P}(\tau(x,x)=k),$$

有 $r_0=1$, 且其求和恰好是 $\mathbb{E}(\tau(x,x))$. 现在根据**Proposition 5.3.3**有

$$P^{(k)}(x,x)=\sum_{i=1}^{k}P^{(k-i)}(x,x)\mathbb{P}(\tau(x,x)=i)=\sum_{i=1}^{k}P^{(k-i)}(x,x)(r_{i-1}-r_i).$$

整理得

$$\sum_{i=0}^{k}r_iP^{(k-i)}(x,x)=\sum_{i=0}^{k-1}r_iP^{(k-1-i)}(x,x),$$

这说明可以将 k 降到 0, 即

$$\sum_{i=0}^{k}r_iP^{(k-i)}(x,x)=r_0P^{(0)}(x,x)=1.$$

由于 x 的周期为 T, 只有 T 的倍数

$$P^{(kT)}(x,x)=\mathbb{P}(X_{kT}=x\mid X_0=x)>0,$$

于是

$$\limsup_{n\to\infty}P^{(n)}(x,x)=\limsup_{n\to\infty}P^{(nT)}(x,x),$$

取子列 n_m 取到这一极限, 再次由**Theorem 5.3.5.**中的全概率分解, 该极限

$$\lim_{m\to\infty}P^{(n_mT)}(x,x)=\lim_{m\to\infty}\sum_{i=1}^{n_m}P^{((n_m-i)T)}(x,x)\mathbb{P}(\tau(x,x)=iT),$$

对每个 j 可以放大到

$$\mathbb{P}(\tau(x,x)=jT)\liminf_{m\to\infty}P^{((n_m-j)T)}(x,x)+\sum_{i\neq j}\mathbb{P}(\tau(x,x)=iT)\limsup_{m\to\infty}P^{((n_m-i)T)}(x,x).$$

由常返值和**Theorem 5.3.4.**可得上式即

$$\mathbb{P}(\tau(x,x)=jT)\liminf_{m\to\infty}P^{((n_m-j)T)}(x,x)+(1-\mathbb{P}(\tau(x,x)=jT))\limsup_{n\to\infty}P^{(n)}(x,x).$$

于是

$$\limsup_{n\to\infty}P^{(n)}(x,x)\leq\lim_{m\to\infty}P^{((n_m-j)T)}(x,x)$$

对一切 j 成立, 从而上式右边是对所有 nT 取 $\liminf$, 于是恒取等, 即当 j 充分大时

$$\limsup_{n\to\infty}P^{(n)}(x,x)=\liminf_{m\to\infty}P^{((n_m-j)T)}(x,x).$$

立即得到

$$\sum_{i=0}^{n_m-j}r_{iT}P^{((n_m-j-i)T)}(x,x)=1,$$

令 $m\to\infty$, 逐项趋于其公共极限, 于是

$$\limsup_{n\to\infty}P^{(n)}(x,x)\left(\sum_{i=0}^{\infty}r_{iT}\right)=1\implies\limsup_{n\to\infty}P^{(n)}(x,x)=\frac{T}{\mathbb{E}(\tau(x,x))},$$

同理可证下确界. □

现在可以做分类, x 是常返值当且仅当级数

$$\sum_{k=1}^{\infty}P^{(k)}(x,x)$$

发散, 其中如果 x 是零常返值, 则通项极限为 0, 如果 x 是正常返值, 则通项极限为正.

如果 x,y 是互通的, 则存在 $P^{(s)}(x,y),P^{(t)}(y,x)>0$, 可以考虑一条路径 $x\to y\to y\to x$, 其中从 x 到 y 的路径长 s, y 到 x 的路径长 t, 则通过这条路径的概率不超过 $x\to x$ 的总概率

$$P^{(s+t+u)}(x,x)\geq P^{(s)}(x,y)P^{(t)}(y,x)P^{(u)}(y,y).$$

如果 y 是常返值, 则

$$\sum_{k=0}^{\infty}P^{(k)}(x,x)\geq P^{(s)}(x,y)P^{(t)}(y,x)\sum_{k=0}^{\infty}P^{(k)}(y,y)=\infty,$$

这说明 x 也是常返值, 反之亦然. 同样的讨论可以说明周期互相整除, 从而有相同的周期.

事实上, 我们只需要 x 到 y 可达, 就可以由 x 是常返值推出 y 是常返值. 这是符合直觉的, 因为 x 出发会无限次返回 x, 而每次返回都可能会导向 y, 之后再回到 x. 因此 x 常返和 x 到 y 可达导致 x, y 互通.

综合上述讨论, 一个常返值 x_0 总是属于一个常返值的子集, 在这个子集中从任何一点出发都会遍历整个子集. 然而由于转移概率不同, 遍历的概率也不同. 这个概率最终只会取决于子集上的转移矩阵, 而与出发点无关. 这启示我们研究 $n \to \infty$ 下极限 $P^{(n)}(x, y)$ 的表现.

Theorem 5.3.8.(离散时齐 Markov 过程的极限定理) 设 X_n 为离散时齐 Markov 过程且取有限个值, $P^{(n)}$ 是转移矩阵. 如果 x_0 为非常返值或零常返值, 则

$$\lim_{n\to\infty} P^{(n)}(x, x_0) = 0,$$

如果 x_0 为正常返值, 周期为 T, 则对任意状态 x 和 $0 \le r \le T-1$, 有

$$\lim_{n\to\infty} P^{(nT+r)}(x, x_0) = \frac{T}{\mathbb{E}(\tau(x_0, x_0))} \sum_{k=0}^{\infty} \mathbb{P}(\tau(x, x_0) = kT + r).$$

Proof. 根据**Theorem 5.3.5.**可知对非常返值 x_0, 级数

$$\sum_{n=1}^{\infty} P^{(n)}(x_0, x_0)$$

收敛, 于是通项收敛到 0, 而对零常返值 x_0, 根据定义**Definition 5.3.5.**可知 $\tau(x_0, x_0)$ 的期望无穷, 结合**Proposition 5.3.7.**可知

$$\lim_{n\to\infty} P^{(nT)}(x_0, x_0) = \frac{T}{\mathbb{E}(\tau(x_0, x_0))} = 0,$$

而当步长 n 不被 T 整除时, 根据定义 $P^{(n)}(x_0, x_0) = 0$. 综上可知, x_0 为非常返值或零常返值时

$$\lim_{n\to\infty} P^{(n)}(x_0, x_0) = 0.$$

由于

$$\sum_{n=1}^{\infty} \mathbb{P}(\tau(x, x_0) = n) = 1 - \mathbb{P}(\tau(x, x_0) = \infty)$$

有限, 可知尾部收敛

$$\lim_{m\to\infty} \sum_{n=m}^{\infty} \mathbb{P}(\tau(x_0, x_0) = n) = 0.$$

于是对任意 $\varepsilon > 0$, 存在 $N(\varepsilon) > 0$, 当 $n > N(\varepsilon)$ 时, $\mathbb{P}(\tau(x_0, x_0) = n)$ 在 $N(\varepsilon)+1$ 到 n 求和不超过 ε. 现在根据**Proposition 5.3.3.**有

$$P^{(n)}(x, x_0) = \sum_{k=1}^{n} \mathbb{P}(\tau(x, x_0) = k) P^{(n-k)}(x_0, x_0),$$

由于概率均不超过 1, 其中 $N(\varepsilon)+1$ 到 n 的求和不超过 ε, 于是有估计

$$P^{(n)}(x,x_0) \leq \sum_{k=1}^{N(\varepsilon)} \mathbb{P}(\tau(x,x_0)=k)P^{(n-k)}(x_0,x_0)+\varepsilon,$$

对右边先取上极限得到

$$P^{(n)}(x,x_0) \leq \left(\sum_{k=1}^{N(\varepsilon)} \mathbb{P}(\tau(x,x_0)=k)\right)\left(\limsup_{n\to\infty} P^{(n)}(x_0,x_0)\right)+\varepsilon=\varepsilon,$$

最后一个等号是因为上极限等于极限. 由于上式对一切 $n>N(\varepsilon)$ 都成立, 对左边取上极限

$$\limsup_{n\to\infty} P^{(n)}(x,x_0) \leq \varepsilon$$

对一切 $\varepsilon>0$ 都成立, 当然上极限为 0, 但另一方面概率是非负的, 因此极限为 0.

如果 x_0 是周期 T 的正常返值, 则当 T 不整除 m 时 $P^{(m)}(x_0,x_0)=0$, 于是根据**Proposition 5.3.3.**有

$$P^{(nT+r)}(x,x_0)=\sum_{k=0}^{n} \mathbb{P}(\tau(x,x_0)=kT+r)P^{((n-k)T)}(x_0,x_0).$$

同上对任意 $\varepsilon>0$, 存在 $N(\varepsilon)>0$, 当 $n>N(\varepsilon)$ 时, $\mathbb{P}(\tau(x_0,x_0)=n)$ 在 $N(\varepsilon)+1$ 到 n 求和不超过 ε. 有估计

$$P^{(nT+r)}(x,x_0) \leq \sum_{k=0}^{N(\varepsilon)} \mathbb{P}(\tau(x,x_0)=kT+r)P^{((n-k)T)}(x_0,x_0)+\varepsilon,$$

对右边先取上极限, 利用得到

$$P^{(n)}(x,x_0) \leq \left(\sum_{k=0}^{N(\varepsilon)} \mathbb{P}(\tau(x,x_0)=kT+r)\right)\frac{T}{\mathbb{E}(\tau(x_0,x_0))}+\varepsilon.$$

由于上式对一切 $n>N(\varepsilon)$ 都成立, 对左边取上极限, 结合对一切 $\varepsilon>0$ 都成立, 得到

$$\limsup_{n\to\infty} P^{(n)}(x,x_0) \leq \frac{T}{\mathbb{E}(\tau(x_0,x_0))}\sum_{k=0}^{\infty} \mathbb{P}(\tau(x,x_0)=kT+r).$$

另一边可以先放缩到

$$P^{(nT+r)}(x,x_0) \geq \sum_{k=0}^{N(\varepsilon)} \mathbb{P}(\tau(x,x_0)=kT+r)P^{((n-k)T)}(x_0,x_0),$$

依次取下极限即得

$$\limsup_{n\to\infty} P^{(n)}(x,x_0) \geq \frac{T}{\mathbb{E}(\tau(x_0,x_0))}\sum_{k=0}^{\infty} \mathbb{P}(\tau(x,x_0)=kT+r),$$

结合两式就完成了证明. □

以上讨论说明周期 $T=1$ 的常返值有

$$\lim_{n\to\infty} P^{(n)}(x,x_0)=\frac{1}{\mathbb{E}(\tau(x_0,x_0))}\sum_{k=1}^{\infty}\mathbb{P}(\tau(x,x_0)=k)>0.$$

接下来我们证明上式实际上与初始状态 x 无关.

Theorem 5.3.9.(离散时齐 Markov 过程的极限分布) 设 X_n 为离散时齐 Markov 过程且取有限个值, $P^{(n)}$ 是转移矩阵, 使得任意两个状态都是可达的正常返值. 则极限

$$\pi(x_0)=\lim_{n\to\infty} P^{(n)}(x,x_0)=\lim_{n\to\infty}\mathbb{P}(X_n=x_0)$$

只与 x_0 有关而与 x 无关. 此外上述 $\pi(x)$ 满足

$$\pi(x_0)=\sum_x \pi(x)P^{(1)}(x,x_0),\quad \sum_x \pi(x)=1.$$

Proof. 由于任何两个状态可达且总状态数有限, 当然有

$$\mathbb{P}(\tau(x,x_0)=\infty)=0,$$

于是根据**Theorem 5.3.8.**可得

$$\lim_{n\to\infty} P^{(n)}(x,x_0)=\frac{1}{\mathbb{E}(\tau(x_0,x_0))}\sum_{k=1}^{\infty}\mathbb{P}(\tau(x,x_0)=k)=\frac{1}{\mathbb{E}(\tau(x_0,x_0))}$$

与 x 无关. 第二个等式只要考虑

$$\lim_{n\to\infty}\mathbb{P}(X_n=x_0)=\lim_{n\to\infty}\sum_x P^{(n)}(x,x_0)\mathbb{P}(X_0=x)=\pi(x_0)\sum_x\mathbb{P}(X_0=x)=\pi(x_0)$$

即可. 根据**Proposition 5.3.1.**有

$$P^{(n)}(x,x_0)=\sum_z P^{(n-1)}(x,z)P^{(1)}(z,x_0),$$

两边令 $n\to\infty$ 得到

$$\pi(x_0)=\sum_z \pi(z)P^{(1)}(z,x_0).$$

由于步长为 n 到达所有点的概率

$$\sum_x P^{(n)}(x',x)=1,$$

取极限得

$$\sum_x \pi(x)=1.$$

□

关于性质

$$\pi(x_0) = \sum_x \pi(x) P^{(1)}(x, x_0),$$

如果将 π 视作以状态为分量的行向量, 则可以写为 $\pi = \pi P^{(1)} = \pi P$, 这给出了如下定义.

Definition 5.3.6.(极限分布与平稳分布) 设 $\{X_t \mid t \in \mathscr{T}\}$ 为时齐 Markov 过程, $P^{(t)}$ 是转移矩阵, 使得任意两个状态都是可达的正常返值. 如果极限

$$\pi(x_0) = \lim_{t\to\infty} P^{(t)}(x, x_0) = \lim_{t\to\infty} \mathbb{P}(X_t = x_0)$$

存在且与 x 无关, 则称定义在所有状态上的函数 π 是 Markov 过程 X_t 的**极限分布 (limiting distribution)**. 一般地, 对任意时间 $t \in \mathscr{T}$ 满足Theorem 5.3.9.中两条性质

$$v(x_0) = \int_x v(x) P^{(t)}(x, x_0), \quad \int_x v(x) = 1$$

的定义在状态空间上的函数 v 称为 Markov 过程 X_t 的**平稳分布 (stationary distribution)**.

显然极限分布是平稳分布. 平稳分布具有吸收性 $v = vP^n$. 对有限状态的情形, 平稳分布的定义性质就变为 $v = vP^{(t)}$ 和 $v\mathbf{1} = 1$. 如果问题还是连续的, 则第一个式子可以两边对 t 求导, 根据 Kolmogorov 方程Example 5.3.3.得到 $vP^{(t)}Q = 0$, 即得 $vQ = 0$.

5.4 鞅理论